“参数统计教程”习题解答

目　录

第一章　统计分布基础 1

第二章　充分统计量与样本信息 27

第三章　点估计基本方法 48

第四章　同变估计 84

第五章　点估计的性质 100

第六章　参数假设检验 119

第七章　区间估计 176

第八章　Bayes 统计基础 207

第一章　统计分布基础

1. 设 x_p 为 $F(x)$ 的 p 分位数，如定义 1.1.1 所述。证明：

(1) $F(x') < p$ 的充要条件为 $x' < x_p$ ； $F(x') \geq p$ 的充要条件为 $x' \geq x_p$ 。是否有“ $F(x') > p$ 的充要条件为 $x' > x_p$ ”？

(2) $F(x_p - 0) \leq p \leq F(x_p)$ ；若 x_p 为 $F(x)$ 的连续点，则 $F(x_p) = p$ ；

(3) 若 $F(x' - 0) > p$ ，则 $x' > x_p$ 。

证明. (1) 首先证明： $F(x') < p$ 的充要条件为 $x' < x_p$ 。用反证法。假设 $x' < x_p$ 而 $F(x') \geq p$ ，则由分位数的定义可知 $x' \geq x_p$ ，这与 $x' < x_p$ 相矛盾，所以由 $x' < x_p$ 可得 $F(x') < p$ ；反之，若 $F(x') < p$ 而 $x' \geq x_p$ ，则由分布函数的单调性可知 $F(x') \geq F(x_p) \geq p$ ，这与 $F(x') < p$ 相矛盾，所以由 $F(x') < p$ 可得 $x' < x_p$ 。

其次证明： $F(x') \geq p$ 的充要条件为 $x' \geq x_p$ 。若 $x' \geq x_p$ ，则由分布函数的单调性知 $F(x') \geq F(x_p) \geq p$ ；反之，若 $F(x') \geq p$ ，则由分位点的定义可知 $x' \geq x_p$ 。

最后说明“ $F(x') > p$ 的充要条件为 $x' > x_p$ ”这一命题的充分性和必要性都是不正确的。例如对于离散型的二项分布 $X \sim b(n, \theta)$ ，令 $p = P\{X \leq i\}$ ，其中 $0 < i < n$ ， i 为整数，则 $x_p = i$ 。一方面，对任意的 $x_p = i < x' < i + 1$ ，显然有 $F(x') = p$ ，这表明命题的充分性不成立。另一方面，对任意满足 $P\{X \leq i - 1\} < p_1 < p$ 的 p_1 ，显然有 $F(x_p) > p_1$ ，而且 x_p 也是 p_1 分位数；即 $x_p = x_{p_1}$ ，这表明命题的必要性不成立。

(2) 由 (1) 可知，若 $x' < x_p$, 则 $F(x') < p$ ，令 $x' \longrightarrow x_p - 0$ ，则有 $F(x_p - 0) \leq p$ ，所以 $F(x_p - 0) \leq p \leq F(x_p)$ 。若 x_p 为 $F(x)$ 的连续点，则由上式可得 $F(x_p) = p$ 。

(3) 用反证法。若 $F(x' - 0) > p$ ，而 $x' \leq x_p$ ，则由分布函数的单调性及 (2) 可知 $F(x' - 0) \leq F(x_p - 0) \leq p$ ，这与 $F(x' - 0) > p$ 相矛盾. 所以若 $F(x' - 0) > p$ ，则必有 $x' > x_p$ 。 ∎

2. 设随机变量 X 和 Y 的分位数分别为 x_p 和 y_p ，证明：

(1) 若 X 服从 Pascal 分布 $PA(\theta, r)$ ，Y 服从负二项分布 $NB(\theta, r)$ ，则 $x_p = y_p + r$ ；

(2) 若 X 服从 Γ 分布 $\Gamma(1/\sigma, k)$ ，则 $x_p = (\sigma/2)\chi^2(2k, p)$ ；其中 $\chi^2(2k, p)$ 表示自由度为 $2k$ 的卡方分布的 p 分位数；

(3) 若 X 服从极值分布 $EV(\alpha, \lambda)$ ，则 $x_p = (1/\alpha)(\log\lambda - \log\log p^{-1})$ ；

(4) 对于 F 分布： $F(n, m; \alpha) = [F(m, n; 1 - \alpha)]^{-1}$ 。

证明. (1) 由 Pascal 分布和负二项分布的关系知 $X - r = Y$ ，设随机变量 X 和 Y 的分布函数分别为 $F(x)$ 和 $G(y)$ ，则有 $G(y) = F(y + r)$ 。由分位数的定义可得

$$\begin{aligned} y_p &= \inf\{y : G(y) \geq p\} = \inf\{y : F(y + r) \geq p\} \\ &= \inf\{x - r : F(x) \geq p\} = \inf\{x : F(x) \geq p\} - r \\ &= x_p - r. \end{aligned}$$

以上第二等式做了变换 $y+r=x$ 。

(2) 由 $X\sim\Gamma(\frac{1}{\sigma},k)$ 可知 $Y=(2/\sigma)X\sim\chi^2(2k)$ 。仍记为 $X\sim F(x),\,Y\sim G(y)$ ，则有 $G(y)=F(\frac{\sigma}{2}y)$ 。又由分位数的定义可得

$$\begin{aligned}\chi^2(2k,p)=y_p &= \inf\{y:G(y)\geq p\}=\inf\{y:F(\frac{\sigma}{2}y)\geq p\}\\ &= \inf\{\frac{2}{\sigma}x:F(x)\geq p\}=\frac{2}{\sigma}\inf\{x:F(x)\geq p\}\\ &= \frac{2}{\sigma}x_p.\end{aligned}$$

以上第二等式做了变换 $(\sigma/2)y=x$ ，因此有 $x_p=(\sigma/2)\chi^2(2k,p)$ 。

注. 更一般地，我们有：若 $Y=\sigma X+\mu$ ，则 $y_p=\sigma x_p+\mu$ ；其中 $\sigma>0,\mu\in R$; y_p 和 x_p 分别是 Y 和 X 的 p 分位数。事实上，仍记 $X\sim F(x),\,Y\sim G(y)$ ，则有 $G(y)=F(\frac{y-\mu}{\sigma})$ 。又由分位数的定义可得

$$\begin{aligned}y_p &= \inf\{y:G(y)\geq p\}=\inf\{y:F(\frac{y-\mu}{\sigma})\geq p\}\\ &= \inf\{\sigma x+\mu:F(x)\geq p\}=\sigma\inf\{x:F(x)\geq p\}+\mu\\ &= \sigma x_p+\mu.\end{aligned}$$

(3) 因为极值分布 $EV(\alpha,\lambda)$ 的分布函数 $F(x)=\exp\{-\lambda e^{-\alpha x}\}$ 连续，所以 x_p 满足方程 $F(x_p)=\exp\{-\lambda e^{-\alpha x_p}\}=p$ ，由该式反解可得 $\lambda e^{-\alpha x_p}=-\log p$ ，因而其 p 分位数为 $x_p=\frac{1}{\alpha}(\log\lambda-\log\log p^{-1})$ 。

(4) 设 $X\sim F(n,m)$ ，则 $Y=X^{-1}\sim F(m,n)$ 。记 $x_\alpha=F(n,m;\alpha)$ ，$y_\beta=F(m,n;\beta)$ ，由于 F 分布的分布函数连续，所以有

$$\begin{aligned}P\{X\leq x_\alpha\}=\alpha &\iff P\{X^{-1}\geq x_\alpha^{-1}\}=\alpha\\ &\iff 1-P\{X^{-1}\leq x_\alpha^{-1}\}=\alpha\\ &\iff P\{X^{-1}\leq x_\alpha^{-1}\}=1-\alpha\\ &\iff x_\alpha^{-1}=y_{1-\alpha}\\ &\iff F(n,m;\alpha)=[F(m,n;1-\alpha)]^{-1}.\end{aligned}$$

∎

3.* 设 α 分位函数定义为

$$\rho_\alpha(t)=(\alpha-I\{t<0\})t=|t|[\alpha I\{t>0\}+(1-\alpha)I\{t<0\}],\ 0<\alpha<1,\ t\in R.$$

(1) 设随机变量 X 的概率密度函数为 $f(x;\alpha,\theta)=\alpha(1-\alpha)\exp\{-\rho_\alpha(x-\theta)\}$ ，证明：X 的 α 分位数为 θ ；

(2) 设 Y 为连续型随机变量，$g(\mu)=\mathrm{E}[\rho_\alpha(Y-\mu)]$ 关于一切 μ 存在，则当 $\mu=y_\alpha$ 时 $g(\mu)$ 达到最小值，其中 y_α 为 Y 的 α 分位数。

证明. (1) 随机变量 X 的密度函数为

$$f(x;\alpha,\theta)=\begin{cases}\alpha(1-\alpha)\exp\{-(1-\alpha)(\theta-x)\} & x\le\theta\\ \alpha(1-\alpha)\exp\{-\alpha(x-\theta)\} & x>\theta\end{cases}$$

由此易得其分布函数为

$$F(x;\alpha,\theta)=\begin{cases}\alpha\exp\{-(1-\alpha)(\theta-x)\} & x\le\theta\\ 1-(1-\alpha)\exp\{-\alpha(x-\theta)\} & x>\theta\end{cases}$$

显然，当且仅当 $x=\theta$ 时 $F(x;\alpha,\theta)=\alpha$ ，所以 X 的 α 分位数为 θ 。

(2) 设 Y 的密度函数为 $f(y)$ ，则

$$\begin{aligned}g(\mu) &= \mathrm{E}[\rho_\alpha(Y-\mu)]=\int_{-\infty}^{\infty}\rho_\alpha(y-\mu)f(y)dy\\ &= \int_{\mu}^{\infty}\alpha(y-\mu)f(y)dy+\int_{-\infty}^{\mu}(1-\alpha)(\mu-y)f(y)dy\\ &= \alpha\int_{-\infty}^{\infty}(y-\mu)f(y)dy-\int_{-\infty}^{\mu}(y-\mu)f(y)dy\\ &= \alpha\mathrm{E}Y-\alpha\mu-\int_{-\infty}^{\mu}(y-\mu)f(y)dy\end{aligned}$$

对 $g(\mu)$ 求导得 $g'(\mu)=-\alpha+\int_{-\infty}^{\mu}f(y)dy$ ，令 $g'(\mu)=0$ 解得 $\alpha=\int_{-\infty}^{\mu}f(y)dy=F(\mu)$ ，从而 $\mu=y_\alpha$ 。由于 $g''(\mu)=f(\mu)>0$ ，所以 $g(\mu)$ 在 $\mu=y_\alpha$ 时达到最小值。 ∎

注. 若 $\alpha=1/2$ ，则 $g(\mu)=(1/2)\mathrm{E}|Y-\mu|$ ， $\mu=y_{1/2}$ 时达到最小值，这一结果与本书定理 1.1.1 一致。

4. 设 $T(X)$ 为随机变量 X 的可测函数, $\mathrm{E}[T(X)-\theta]^2$ 在 $\theta\in[a,b]$ 上存在, 记 $S(x)=T(x)$ ，若 $a\le T(x)\le b$ ； $S(x)=a$ ，若 $T(x)<a$ ； $S(x)=b$ ，若 $T(x)>b$ 。证明: $\mathrm{E}[S(X)-\theta]^2\le\mathrm{E}[T(X)-\theta]^2$ 。

证明. 设 $T(X)$ 的分布函数为 $F_T(t)$ ，由于

$$S(x)=\begin{cases}a & T(x)<a\\ T(X) & a\le T(x)\le b\\ b & T(x)>b\end{cases}$$

所以

$$\begin{aligned}\mathrm{E}[S(X)-\theta]^2 &= \int_{-\infty}^{a}(a-\theta)^2dF_T(t)+\int_{a}^{b}(t-\theta)^2dF_T(t)+\int_{b}^{+\infty}(b-\theta)^2dF_T(t)\\ &\le \int_{-\infty}^{a}(t-\theta)^2dF_T(t)+\int_{a}^{b}(t-\theta)^2dF_T(t)+\int_{b}^{+\infty}(t-\theta)^2dF_T(t)\\ &= \int_{-\infty}^{\infty}(t-\theta)^2dF_T(t)=\mathrm{E}[T(X)-\theta]^2\end{aligned}$$ ∎

5. 称随机变量 X 的分布关于某一点 ξ_0 对称，若其密度函数 $f(x)$ 满足 $f(\xi_0+x)=f(\xi_0-x)$ 。证明:

(1) X 的分布关于 ξ_0 对称的充要条件为 $X-\xi_0$ 的分布关于原点对称； X 的分布关于原点对称的充要条件为 X 与 $-X$ 同分布；

(2) 若 X 的分布关于 ξ_0 对称，则 $EX=\xi_0$ ； $\mathrm{E}(X-\xi_0)^{2k-1}=0$ ，其中 k 为正整数；

(3) 设 $X_1,\cdots,X_n$ 为 $i.i.d.$ 样本，X_1 服从某一对称分布;则其样本均值 $\overline{X}=n^{-1}\sum_{i=1}^n X_i$ 与样本方差 $S^2=(n-1)^{-1}\sum_{i=1}^n(X_i-\overline{X})^2$ 不相关，即 $\mathrm{Cov}(\overline{X},S^2)=0$ 。

证明. (1) 设 $Y=X-\xi_0$ 的密度函数为 $g(y)$, 则有 $g(y)=f(y+\xi_0)$ 。因此 $Y=X-\xi_0$ 的分布关于原点对称的充要条件 $g(y)=g(-y)$ 等价于 $f(y+\xi_0)=f(-y+\xi_0)$ ，而该式就是 X 的分布关于 ξ_0 对称的充要条件。其次再证 X 的分布关于原点对称的充要条件为 X 与 $-X$ 同分布。设 $Y=-X$ 的密度函数为 $g(y)$, 则有 $g(y)=f(-y)$ 。由于 X 的分布关于原点对称的充要条件为 $f(x)=f(-x)$ ，这等价于 $f(-y)=f(y)$ ，也等价于 $Y=-X$ 的密度函数为 $g(y)=f(y)$ ，即 $Y=-X$ 与 X 同分布。

(2) 注意，若 X 的分布关于 ξ_0 对称，则密度函数 $f(\xi_0+x)$ 为偶函数，因此有

$$\begin{aligned}\mathrm{E}X &= \int_{-\infty}^{\infty} xf(x)dx=\int_{-\infty}^{\infty}(t+\xi_0)f(t+\xi_0)dt\\ &= \int_{-\infty}^{\infty} tf(t+\xi_0)dt+\int_{-\infty}^{\infty}\xi_0 f(t+\xi_0)dt.\end{aligned}$$

其中第 2 个等号用到了变换 $x=t+\xi_0$ 。因为 $f(\xi_0+x)$ 为偶函数，所以 $tf(t+\xi_0)$ 是奇函数，从而

$$\mathrm{E}X=0+\int_{-\infty}^{\infty}\xi_0 f(t+\xi_0)dt=\int_{-\infty}^{\infty}\xi_0 f(x)dx=\xi_0.$$

同理，若令 $t=x-\xi_0$ ，则有

$$\mathrm{E}(X-\xi_0)^{2k-1}=\int_{-\infty}^{\infty}(x-\xi_0)^{2k-1}f(x)dx=\int_{-\infty}^{\infty}t^{2k-1}f(t+\xi_0)dt.$$

又因为 $t^{2k-1}f(t+\xi_0)$ 是奇函数，所以 $\mathrm{E}(X-\xi_0)^{2k-1}=0$ 。

(3) 不妨设 X_1 的密度函数为 $f(x_1)$ ，则由对称性可知 $f(\xi_0+x_1)=f(\xi_0-x_1)$ ，由 (1) 易得 $\mathrm{E}(\bar{X})=n^{-1}\sum_{i=1}^n\mathrm{E}X_i=\xi_0$ ，记 $s^2(x)=(n-1)^{-1}\sum_{i=1}^n(x_i-\bar{x})^2$ ，则有

$$\begin{aligned}\mathrm{Cov}(\bar{X},S^2) &= \mathrm{E}[(\bar{X}-\xi_0)(S^2-\mathrm{E}S^2)]\\ &= \int_{R^n}(\bar{x}-\xi_0)[s^2(x)-\mathrm{E}S^2]f(x_1),\cdots,f(x_n)dx_1\cdots dx_n.\end{aligned}$$

今做变换 $x_i=t_i+\xi_0$ ， $i=1,2,\cdots,n$ ，则有 $\bar{x}-\xi_0=\bar{t}$ ， $s^2(x)=s^2(t)$ ，因此

$$\mathrm{Cov}(\bar{X},S^2)=\int_{R^n}\bar{t}\,[s^2(t)-\mathrm{E}S^2]f(t_1+\xi_0),\cdots,f(t_n+\xi_0)dt_1\cdots dt_n.$$

由定义可知 $s^2(-t)=s^2(t)$ ，因此 $[s^2(t)-\mathrm{E}S^2]$ 为 t 的偶函数，显然 $\bar{t}$ 为奇函数，因而以上被积函数是奇函数，所以 $\mathrm{Cov}(\bar{X},S^2)=0$ 。 ∎

6. 设随机变量 X 的 r 阶累积量为 $\mathcal{K}_r$ ，证明：

(1) 若 X,Y 独立，则有 $\mathcal{K}_r(X+Y)=\mathcal{K}_r(X)+\mathcal{K}_r(Y)$ ；

(2) $\mathcal{K}_r(X+C)=\mathcal{K}_r(X),\ (r>1)$ 。

证明. (1) 由于 X 与 Y 独立，所以 $\varphi_{X+Y}(t)=\varphi_X(t)\varphi_Y(t)$ ，因此有 $\log\varphi_{X+Y}(t)=\log\varphi_X(t)+\log\varphi_Y(t)$ ，即

$$\sum_{r=1}^{\infty}\mathcal{K}_r(X+Y)\frac{(it)^r}{r!}=\sum_{r=1}^{\infty}\mathcal{K}_r(X)\frac{(it)^r}{r!}+\sum_{r=1}^{\infty}\mathcal{K}_r(Y)\frac{(it)^r}{r!}.$$

所以 $\mathcal{K}_r(X+Y)=\mathcal{K}_r(X)+\mathcal{K}_r(Y), r=1,2,\cdots$ 。

(2) 因为 $\varphi_{X+C}(t)=\varphi_X(t)e^{iCt}$ ，所以 $\log\varphi_{X+C}(t)=\log\varphi_X(t)+iCt$ ，即

$$\sum_{r=1}^{\infty}\mathcal{K}_r(X+C)\frac{(it)^r}{r!}=\sum_{r=2}^{\infty}\mathcal{K}_r(X)\frac{(it)^r}{r!}+(C+\mathcal{K}_1(X))it.$$

所以 $\mathcal{K}_r(X+C)=\mathcal{K}_r(X), r>1;\ \mathcal{K}_1(X+C)=\mathcal{K}_1(X)+C$ 。 ∎

7. 设 ξ 为连续型正值随机变量，其分布函数为 $F(t)$ ， $F'(t)=f(t)$ ，记 $h(t)=f(t)/[1-F(t)]$ ，通常称 $h(t)$ 为危险率函数。证明

(1) $h(t)$ 表示 ξ 大于 t ，但不超过 $t+\triangle t$ 的相对概率，或危险率：

$$h(t)=\lim_{\triangle t\to 0}\frac{P\{t<\xi\le t+\triangle t|\xi>t\}}{\triangle t};$$

(2) 危险率函数 $h(t)$ 与密度函数 $f(t)$ 有以下一一对应的关系：

$$f(t)=h(t)e^{-H(t)};\quad H(t)=\int_0^t h(x)dx.$$

证明. (1)

$$\begin{aligned}&\lim_{\Delta t\to 0}\frac{P\{t<\xi\le t+\Delta t|\xi>t\}}{\Delta t}\\&=\lim_{\Delta t\to 0}\frac{F(t+\Delta t)-F(t)}{\Delta t(1-F(t))}=\frac{F'(t)}{1-F(t)}\\&=\frac{f(t)}{1-F(t)}=h(t)\end{aligned}$$

(2) 对 $h(t)=f(t)/(1-F(t))$ 积分得

$$H(t)=\int_0^t h(u)du=\int_0^t\frac{-d(1-F(u))}{1-F(u)}=-\log(1-F(t)).$$

所以 $\log(1-F(t))=-H(t), 1-F(t)=e^{-H(t)}$ ，两边求导得 $-f(t)=e^{-H(t)}(-H'(t))$ ，即 $f(t)=h(t)e^{-H(t)}$ 。 ∎

8. 设随机变量 X 服从 Poisson 分布 $P(\lambda)$ ，并已知事件 {X=0} 不可能发生，求此时 X 的分布 (截尾 Poisson 分布) 及其期望和方差。

解. 由于 $X>0$ ，所以对任意的正整数 k 有

$$P\{X=k|X>0\}\quad=\quad\frac{P\{X=k,X>0\}}{P\{X>0\}}=\frac{P\{X=k\}}{P\{X>0\}}$$

$$
\begin{aligned}
&= \frac{e^{-\lambda}\cdot\frac{\lambda^k}{k!}}{1-e^{-\lambda}} = \frac{\lambda^k}{k!(e^{\lambda}-1)} \\
\mathrm{E}(X|X>0) &= \sum_{k=1}^{\infty} k\cdot\frac{e^{-\lambda}\cdot\lambda^k}{k!(1-e^{-\lambda})} = \frac{\lambda e^{-\lambda}}{1-e^{-\lambda}}\sum_{k=1}^{\infty}\frac{\lambda^{k-1}}{(k-1)!} \\
&= \frac{\lambda e^{-\lambda}}{1-e^{-\lambda}}\cdot e^{\lambda} = \frac{\lambda}{1-e^{-\lambda}} \\
\mathrm{Var}(X|X>0) &= \mathrm{E}(X^2|X>0) - [\mathrm{E}(X|X>0)]^2
\end{aligned}
$$

而

$$
\begin{aligned}
\mathrm{E}(X^2|X>0) &= \sum_{k=1}^{\infty} k^2\cdot\frac{e^{-\lambda}\cdot\lambda^k}{k!(1-e^{-\lambda})} = \frac{e^{-\lambda}}{1-e^{-\lambda}}\sum_{k=1}^{\infty}\frac{k\lambda^k}{(k-1)!} \\
&= \frac{e^{-\lambda}}{1-e^{-\lambda}}\sum_{k=0}^{\infty}\frac{(k+1)\lambda^{k+1}}{k!} \\
&= \frac{e^{-\lambda}}{1-e^{-\lambda}}(\sum_{k=0}^{\infty}\frac{k\cdot\lambda^{k+1}}{k!} + \sum_{k=0}^{\infty}\frac{\lambda^{k+1}}{k!}) \\
&= \frac{e^{-\lambda}}{1-e^{-\lambda}}(\lambda^2+\lambda)\cdot e^{\lambda} = \frac{\lambda^2+\lambda}{1-e^{-\lambda}}
\end{aligned}
$$

所以 $\mathrm{Var}(X|X>0) = \lambda[1-(1+\lambda)e^{-\lambda}]/(1-e^{-\lambda})^2$ 。 ∎

9. (1) 设 T 的期望和方差分别为 1 和 τ ， $(N|T=t)$ 服从 Poisson 分布 $P(\lambda t)$ ，求 N 的期望与方差;

(2) 设 N 服从 Poisson 分布 $P(\lambda)$ ， $(X|N=n)$ 服从二项分布 $B(n,\theta)$ ，证明 X 服从 Poisson 分布 $P(\lambda\theta)$ 。

(1) **解**.

$$
\begin{aligned}
\mathrm{E}(N) &= \mathrm{E}_T\{\mathrm{E}(N|T)\} = \mathrm{E}_T(\lambda T) = \lambda \\
\mathrm{Var}(N) &= \mathrm{E}_T\{\mathrm{Var}(N|T)\} + \mathrm{Var}_T\{\mathrm{E}(N|T)\} \\
&= \mathrm{E}_T(\lambda T) + \mathrm{Var}_T(\lambda T) \\
&= \lambda + \lambda^2\tau
\end{aligned}
$$

(2) **证明**. X 的特征函数为

$$
\begin{aligned}
\varphi_X(t) &= \mathrm{E}(e^{iXt}) = \mathrm{E}_N\{\mathrm{E}(e^{i(X|N)t})\} = \mathrm{E}_N\{[(1-\theta)+\theta e^{it}]^N\} \\
&= \sum_{n=0}^{\infty}[(1-\theta)+\theta e^{it}]^n\frac{\lambda^n e^{-\lambda}}{n!} \\
&= e^{\lambda[(1-\theta)+\theta e^{it}]}e^{-\lambda} = e^{\lambda\theta(e^{it}-1)}
\end{aligned}
$$

这与 Poisson 分布 $P(\lambda\theta)$ 的特征函数相同，由唯一性知 $X\sim P(\lambda\theta)$ 。 ∎

10. 设 T 服从 Γ 分布 $\Gamma(\lambda,\nu)$ ， $(X|T=t)$ 服从 Poisson 分布 $P(t)$ 。证明 X 服从负二项分布 $NB(\theta,\nu)$ ，其中 $\theta=\lambda/(1+\lambda)$ ；而 $(T|X=x)$ 服从 Γ 分布 $\Gamma(\lambda+1,x+\nu)$ ， (提示：用特征函数证明 $X\sim NB(\theta,\nu)$) 。

证明. X 的特征函数为

$$\begin{aligned}
\varphi_X(s) &= \mathrm{E}(e^{iXs}) = \mathrm{E}_T\{\mathrm{E}(e^{i(X|T)s})\} = \mathrm{E}_T\{e^{T(e^{is}-1)}\} \\
&= \int_0^\infty \frac{\lambda^\nu}{\Gamma(\nu)} e^{-\lambda t}\cdot t^{\nu-1}\cdot e^{t(e^{is}-1)}dt = \int_0^\infty \frac{\lambda^\nu}{\Gamma(\nu)} e^{-(\lambda+1-e^{is})t}\cdot t^{\nu-1}dt \\
&= \lambda^\nu/(\lambda+1-e^{is})^\nu = (\frac{\lambda}{1+\lambda})^\nu\cdot(1-\frac{1}{1+\lambda}e^{is})^{-\nu} \\
&= \theta^\nu[1-(1-\theta)e^{is}]^{-\nu}
\end{aligned}$$

这与负二项分布 $NB(\theta,\nu)$ 的特征函数相同，因此由唯一性可知 $X\sim NB(\theta,\nu)$ ，其中 $\theta=\lambda/(1+\lambda)$ 。

另外，由于 (T,X) 的联合分布密度函数为

$$\begin{aligned}
p(t,x) &= p(t)p(x|t) = \frac{\lambda^\nu}{\Gamma(\nu)}e^{-\lambda t}t^{\nu-1}\cdot e^{-t}\frac{t^x}{x!} \\
&= \frac{\lambda^\nu}{\Gamma(\nu)x!}e^{-(\lambda+1)t}t^{\nu+x-1}
\end{aligned}$$

所以 $(T|X=x)$ 的密度函数为

$$\begin{aligned}
p(t|x) &= p(t,x)/p(x) \\
&= \frac{\lambda^\nu}{\Gamma(\nu)x!}e^{-(\lambda+1)t}t^{\nu+x-1}\cdot\left[\binom{\nu+x-1}{x}(\frac{\lambda}{1+\lambda})^\nu(\frac{1}{1+\lambda})^x\right]^{-1} \\
&= \frac{(1+\lambda)^{\nu+x}}{\Gamma(\nu+x)}e^{-(1+\lambda)t}t^{\nu+x-1}
\end{aligned}$$

这是 Γ 分布 $\Gamma(\lambda+1,\nu+x)$ 的密度函数，所以 $(T|X=x)$ 服从 Γ 分布 $\Gamma(\lambda+1,\nu+x)$ 。 ∎

11.★ 设 X 服从二项分布， $P(X=i)=b(i|n,\theta)$ 。证明其分布函数 $F(i)=P(X\le i)$ 与不完全 β 函数 (见 (1.2.1) 式) 有以下关系：

$$\sum_{j=i}^n b(j|n,\theta) = I_\theta(i,n-i+1);$$

$$F(i) = 1-I_\theta(i+1,n-i) = I_{1-\theta}(n-i,i+1).$$

(提示：对第一式，令左端 $=f_1(\theta)$ ，右端 $=f_2(\theta)$，$f(\theta)=f_1(\theta)-f_2(\theta)$ ，易得 $f'(\theta)=0$ ，从而 $f(\theta)=0$ ；第 12 ， 13 题的证明类似) 。

证明. 令 $f_1(\theta)=\sum_{j=i}^n b(j|n,\theta)$，$f_2(\theta)=I_\theta(i,n-i+1)$，$f(\theta)=f_1(\theta)-f_2(\theta)$ ，则

$$\begin{aligned}
f(\theta) &= \sum_{j=i}^n \frac{n!}{j!(n-j)!}\theta^j(1-\theta)^{n-j} - \frac{n!}{(i-1)!(n-i)!}\int_0^\theta x^{i-1}(1-x)^{n-i}dx \\
f'(\theta) &= \sum_{j=i}^n \frac{n!}{(j-1)!(n-j)!}\theta^{j-1}(1-\theta)^{n-j} - \sum_{j=i}^{n-1}\frac{n!}{j!(n-j-1)!}\theta^j(1-\theta)^{n-j-1} \\
&\quad -\frac{n!}{(i-1)!(n-i)!}\theta^{i-1}(1-\theta)^{n-i} \\
&= \sum_{j=i+1}^n \frac{n!}{(j-1)!(n-j)!}\theta^{j-1}(1-\theta)^{n-j} - \sum_{k=i+1}^n \frac{n!}{(k-1)!(n-k)!}\theta^{k-1}(1-\theta)^{n-k} \\
&= 0
\end{aligned}$$

所以 $f(\theta)\equiv c$， c 为常数。又因为 $f(0)=0$，且 $f(\theta)$ 在 $\theta=0$ 处连续，所以 $f(\theta)=0$，即 $\sum_{j=i}^{n} b(j|n,\theta)=I_\theta(i,n-i+1)$ 。

另外，由于

$$\begin{aligned} F(i) &= \sum_{j=1}^{i} b(j|n,\theta)=1-\sum_{j=i+1}^{n} b(j|n,\theta) \\ &= 1-I_\theta(i+1,n-i) \end{aligned}$$

为计算 $I_\theta(i+1,n-i)$，做变换 $x=1-y$，则有

$$\begin{aligned} I_\theta(i+1,n-i) &= \frac{1}{\beta(i+1,n-i)}\int_0^\theta x^i(1-x)^{n-i-1}dx \\ &= \frac{1}{\beta(i+1,n-i)}\int_1^{1-\theta}(1-y)^i y^{n-i-1}(-dy) \\ &= \frac{1}{\beta(i+1,n-i)}[\int_0^1 y^{n-i-1}(1-y)^i dy-\int_0^{1-\theta} y^{n-i-1}(1-y)^i dy] \\ &= 1-\frac{1}{\beta(n-i,i+1)}\int_0^{1-\theta} y^{n-i-1}(1-y)^i dy \\ &= 1-I_{1-\theta}(n-i,i+1) \end{aligned}$$

所以 $F(i)=1-I_\theta(i+1,n-i)=I_{1-\theta}(n-i,i+1)$ 。 ∎

12.* 若 X 服从负二项分布 $NB(\theta,r)$，则其分布函数 $F(i)=P(X\le i)$ 可由不完全 β 函数表示为 $I_\theta(r,\ i+1)$ 。

证明. 令

$$\begin{aligned} f_1(\theta) &= F(i)=P(X\le i)=\sum_{k=0}^{i}\binom{k+r-1}{k}\theta^r(1-\theta)^k, \\ f_2(\theta) &= I_\theta(r,i+1)=\frac{1}{\beta(r,i+1)}\int_0^\theta x^{r-1}(1-x)^i dx, \\ f(\theta) &= f_1(\theta)-f_2(\theta) \end{aligned}$$

下面我们用数学归纳法证明：对任意的自然数 i 有 $f'(\theta)=0$ 。

当 $i=0$ 时， $f'(\theta)=f_1'(\theta)-f_2'(\theta)=r\theta^{r-1}-r\theta^{r-1}=0$；

当 $i=1$ 时，

$$\begin{aligned} f'(\theta) &= f_1'(\theta)-f_2'(\theta) \\ &= [r\theta^{r-1}+r\cdot r\theta^{r-1}(1-\theta)-r\theta^r]-r(r+1)\theta^{r-1}(1-\theta) \\ &= 0; \end{aligned}$$

假设当 $i=m$ 时， $f'(\theta)=0$，

那么，当 $i=m+1$ 时，我们有

$$\begin{aligned} f'(\theta) &= [\sum_{k=0}^{m}\binom{k+r-1}{k}\theta^r(1-\theta)^k]'+[\binom{m+1+r-1}{m+1}\theta^r(1-\theta)^{m+1}]' \\ &\quad -\frac{1}{\beta(r,m+2)}\theta^{r-1}(1-\theta)^{m+1} \end{aligned}$$

$$
\begin{aligned}
&= [F'(m) - I'_\theta(r, m+1)] + \frac{(m+r)!}{m!(r-1)!}\theta^{r-1}(1-\theta)^m \\
&\quad + \binom{m+r}{m+1} r\theta^{r-1}(1-\theta)^{m+1} - \binom{m+r}{m+1}\theta^r(m+1)(1-\theta)^m \\
&\quad - \frac{(m+r+1)!}{(m+1)!(r-1)!}\theta^{r-1}(1-\theta)^{m+1} \\
&= 0 + \frac{(m+r)!}{m!(r-1)!}\theta^{r-1}(1-\theta)^m \\
&\quad + \frac{(m+r)!}{(m+1)!(r-1)!} r\theta^{r-1}(1-\theta)^{m+1} - \frac{(m+r)!}{(m+1)!(r-1)!}\theta^r(m+1)(1-\theta)^m \\
&\quad - \frac{(m+r+1)!}{(m+1)!(r-1)!}\theta^{r-1}(1-\theta)^{m+1} \\
&= 0.
\end{aligned}
$$

最后一式各项加以合并，经简单计算，即可得到 $f'(\theta) = 0$ 。综上所述，根据数学归纳法，对任意自然数 i 有 $f'(\theta) = 0$; 又因 $f(0) = 0$ ，而且 $f(\theta)$ 在 $\theta = 0$ 处连续，所以 $f(\theta) = 0$ ，即 $F(i) = P(X \le i) = I_\theta(r, i+1)$ 。 ∎

13.* 设 X 服从 Poisson 分布 $P(\lambda)$ ，则其分布函数 $F(i) = P(X \le i)$ 可由不完全 Γ 函数 $\Gamma(\lambda,\ i+1)$ 表示为

$$
F(i) = \sum_{k=0}^{i} e^{-\lambda}\frac{\lambda^k}{k!} = \int_\lambda^\infty e^{-x}x^i dx/\Gamma(i+1) \triangleq \Gamma(\lambda,\ i+1).
$$

证明. 令

$$
\begin{aligned}
f_1(\lambda) &= F(i) = \sum_{k=0}^{i} e^{-\lambda}\frac{\lambda^k}{k!}, \\
f_2(\lambda) &= \Gamma(\lambda, i+1) = \frac{1}{\Gamma(i+1)}\int_\lambda^\infty e^{-x}x^i dx, \\
f(\lambda) &= f_1(\lambda) - f_2(\lambda).
\end{aligned}
$$

则

$$
\begin{aligned}
f'(\lambda) &= \sum_{k=1}^{i} e^{-\lambda}\frac{\lambda^{k-1}}{(k-1)!} - \sum_{k=0}^{i} e^{-\lambda}\frac{\lambda^k}{k!} + e^{-\lambda}\frac{\lambda^i}{i!} \\
&= \sum_{k=0}^{i-1} e^{-\lambda}\frac{\lambda^k}{k!} - \sum_{k=0}^{i} e^{-\lambda}\frac{\lambda^k}{k!} + e^{-\lambda}\frac{\lambda^i}{i!} \\
&= 0.
\end{aligned}
$$

所以 $f(\lambda) \equiv c$ ，为常数。又因为 $f(0) = 1 - 1 = 0$ ，而且 $f(\lambda)$ 在 $\lambda = 0$ 处连续，所以 $f(\lambda) \equiv 0$ ，即 $F(i) = \Gamma(\lambda, i+1)$ 。 ∎

14. 若 $X_i \sim P(\lambda_i),\ i = 1, \cdots, k$ 相互独立，则 $\{(X_1, \cdots, X_k) | X_1 + \cdots + X_k = n\} \sim MN(n, \pi)$ ，其中 $\pi = (\pi_1, \cdots, \pi_k)^T,\ \pi_i = \lambda_i / \sum_{j=1}^k \lambda_j$ 。

证明.

$$
P\{(X_1 = x_1, \cdots, X_k = x_k) | X_1 + \cdots, X_k = n\}
$$

$$
\begin{aligned}
&= P\{X_1=x_1,\cdots,X_k=x_k,\sum_{i=1}^k x_i=n\}/P\{X_1+\cdots,X_k=n\}\\
&= [e^{-\lambda_1}\frac{\lambda_1^{x_1}}{x_1!}\cdots e^{-\lambda_k}\frac{\lambda_k^{x_k}}{x_k!}]/[e^{-\sum_{i=1}^k\lambda_i}\frac{(\sum_{i=1}^k\lambda_i)^n}{n!}]\\
&= \frac{n!}{x_1!\cdots x_k!}(\frac{\lambda_1}{\sum_{i=1}^k\lambda_i})^{x_1}\cdots(\frac{\lambda_k}{\sum_{i=1}^k\lambda_i})^{x_k} \qquad (\text{其中}\sum_{i=1}^k x_i=n)
\end{aligned}
$$

所以 $\{(X_1,\cdots,X_k)|X_1+\cdots+X_k=n\}$ 服从多项分布 $MN(n,\pi)$，其中 $\pi=(\pi_1,\cdots,\pi_k)^T$，而 $\pi_i=\lambda_i/\sum_{j=1}^k\lambda_j,\ i=1,\cdots,k$。 ∎

15.★ 设 $\Phi(x)$ 为标准正态分布的分布函数，证明：

(1) 若 $X\sim N(\mu,\sigma^2)$，则 $\mathrm{E}[\Phi(X)]=\Phi(\frac{\mu}{\sqrt{1+\sigma^2}})$ (提示：把 $\mathrm{E}[\Phi(X)]$ 表示为二重积分；或令 $I(\mu)=\mathrm{E}[\Phi(X)]$，在积分号下对 μ 求导，再对 μ 积分； (2) 和 (3) 类似)；

(2) 若 $X\sim(\chi^2(1))^{1/2}$，则 $\mathrm{E}[\Phi(X)]=3/4$；

(3) 若 $X\sim N(0,1)$，则相关系数 $\rho(X,\ \Phi(X))=\sqrt{3/\pi}$。

证明. (1) 今记正态分布 $N(\mu,\sigma^2)$ 的密度函数为 $\varphi_{(\mu,\sigma)}(\cdot)$， 则有

$$
\begin{aligned}
\mathrm{E}[\Phi(X)] &= \int_{-\infty}^{+\infty}\Phi(x)\varphi_{(\mu,\sigma)}(x)dx\\
&= \int_{-\infty}^{+\infty}\int_{-\infty}^{x}\varphi_{(0,1)}(y)dy\varphi_{(\mu,\sigma)}(x)dx.
\end{aligned}
$$

若记 $X\sim N(\mu,\sigma^2)$， $Y\sim N(0,1)$，则由上可得

$$\mathrm{E}[\Phi(X)]=P\{-\infty<X<+\infty;\ -\infty<Y<X\}=P\{Y<X\}=P\{Y-X<0\}.$$

而 $Y-X\sim N(-\mu,1+\sigma^2)$， $(Y-X+\mu)/\sqrt{1+\sigma^2}\sim N(0,1)$，因此有

$$\mathrm{E}[\Phi(X)]=P\{\frac{Y-X+\mu}{\sqrt{1+\sigma^2}}<\frac{\mu}{\sqrt{1+\sigma^2}}\}=\Phi(\frac{\mu}{\sqrt{1+\sigma^2}}).$$

注. 本题亦可证明如下。令 $\mathrm{E}[\Phi(X)]=I(\mu)$，即把 $\mathrm{E}[\Phi(X)]$ 看作 μ 的函数，则有

$$I(\mu)=\mathrm{E}[\Phi(X)]=\int_{-\infty}^{+\infty}\Phi(x)\frac{1}{\sigma}\phi(\frac{x-\mu}{\sigma})dx$$

其中 $\phi(.)$ 是标准正态分布 $N(0,1)$ 的密度函数。作变换 $t=\frac{x-\mu}{\sigma}$，则

$$I(\mu)=\int_{-\infty}^{+\infty}\Phi(\mu+\sigma t)\phi(t)dt$$

上式满足积分号下对 μ 求导的条件，因此有

$$I'(\mu)=\frac{1}{\sqrt{2\pi}}\frac{1}{\sqrt{1+\sigma^2}}\exp\{-\frac{\mu^2}{2(1+\sigma^2)}\}.$$

该式再积分即可得到 $\mathrm{E}[\Phi(X)]=\Phi(\frac{\mu}{\sqrt{1+\sigma^2}})$。

(2) X 的密度函数为 $f(x)=\sqrt{\frac{2}{\pi}}e^{-\frac{1}{2}x^2}I\{x>0\}$ ，因此有

$$\begin{aligned}
\mathrm{E}[\Phi(X)] &= \int_0^{+\infty}\Phi(x)\sqrt{\frac{2}{\pi}}e^{-\frac{1}{2}x^2}dx \\
&= 2\int_0^{+\infty}\int_{-\infty}^{x}\varphi_{(0,1)}(y)dy\varphi_{(0,1)}(x)dx. \\
&= 2P\{0<X<+\infty;\ -\infty<Y<X\};\quad (X\sim N(0,1),\ Y\sim N(0,1)) \\
&= 2P\{0<X;\ 0<Y<X\}+2P\{0<X;\ Y<X;\ Y<0\} \\
&= 2P\{0<X;\ 0<Y<X\}+2P\{0<X;\ Y<0\}.
\end{aligned}$$

由对称性可知

$$P\{0<X;\ Y<0\}=P\{0<X;\ Y>0\}=\frac{1}{2}P\{0<X\}=\frac{1}{4};$$

$$P\{0<X;\ 0<Y<X\}=P\{0<X;\ Y>X\}=\frac{1}{2}P\{0<X;\ 0<Y\}=\frac{1}{8}.$$

代入上式可得 $\mathrm{E}[\Phi(X)]=3/4$ 。

注. 本题亦可证明如下。令 $I(\sigma)=\int_0^{\infty}\Phi(\sigma x)f(x)dx\ \ (\sigma\geq 0)$ ，则有 $I(1)=\mathrm{E}[\Phi(X)]$ 。对 $I(\sigma)$ 求导再积分，即可得到 $I(1)=3/4$ 。

(3) 由于 $X\sim N(0,1)$ ，因此 $Y=\Phi(X)\sim R(0,1)$ ，所以有 $\mathrm{Var}(\Phi(X))=1/12$ 。

$$\begin{aligned}
\rho(X,\Phi(X)) &= \mathrm{Cov}(X,\Phi(X))/\sqrt{\mathrm{Var}(X)\mathrm{Var}(\Phi(X))} \\
&= [\mathrm{E}(X\Phi(X))-\mathrm{E}(X)\mathrm{E}(\Phi(X))]/\sqrt{1\cdot 1/12} \\
&= 2\sqrt{3}\mathrm{E}[X\Phi(X)].
\end{aligned}$$

以下应用类似的方法计算 $\mathrm{E}[X\Phi(X)]$

$$\begin{aligned}
\mathrm{E}[X\Phi(X)] &= \int_{-\infty}^{+\infty}x\Phi(x)\varphi_{(0,1)}(x)dx \\
&= \int_{-\infty}^{+\infty}\int_{-\infty}^{x}x\frac{1}{\sqrt{2\pi}}e^{-\frac{y^2}{2}}dy\frac{1}{\sqrt{2\pi}}e^{-\frac{x^2}{2}}dx.
\end{aligned}$$

以上积分交换次序可得

$$\begin{aligned}
\mathrm{E}[X\Phi(X)] &= \int_{-\infty}^{+\infty}\int_{y}^{+\infty}\frac{1}{\sqrt{2\pi}}e^{-\frac{y^2}{2}}\frac{1}{\sqrt{2\pi}}xe^{-\frac{x^2}{2}}dxdy \\
&= \int_{-\infty}^{+\infty}\frac{1}{\sqrt{2\pi}}e^{-\frac{y^2}{2}}\int_{y}^{+\infty}\frac{1}{\sqrt{2\pi}}xe^{-\frac{x^2}{2}}dxdy \\
&= \int_{-\infty}^{+\infty}\frac{1}{\sqrt{2\pi}}e^{-\frac{y^2}{2}}\frac{1}{\sqrt{2\pi}}e^{-\frac{y^2}{2}}dy \\
&= \frac{1}{2\pi}\int_{-\infty}^{+\infty}e^{-y^2}dy=\frac{1}{2\sqrt{\pi}}.
\end{aligned}$$

代入上式可得 $\rho(X,\Phi(X))=\sqrt{3/\pi}$ 。 ∎

16. 设 $X_1,\cdots,X_n$ 为 *i.i.d.* 样本，若 $X_1\sim N(\mu,1)$ ，其样本均值 $\overline{X}=n^{-1}\sum_{i=1}^{n}X_i$ ， $\Phi(x)$ 为标准正态分布的分布函数。求 α ，使 $\mathrm{E}[\Phi(\alpha\overline{X})]=\Phi(\mu)$ 。

解. 由于 $\overline{X} \sim N(\mu, 1/n)$ ，所以 $\alpha\overline{X} \sim N(\alpha\mu, \alpha^2/n)$ 。由第 15 题第 (1) 小题的结论知：

$$\mathrm{E}[\Phi(\alpha\overline{X})] = \Phi(\alpha\mu/\sqrt{1+\alpha^2/n})$$

要使其等于 $\Phi(\mu)$ ，则需 $\alpha/\sqrt{1+\alpha^2/n} = 1 \quad (\alpha > 0)$ ，由此解得 $\alpha = \sqrt{n/(n-1)}$ ，即 $\mathrm{E}[\Phi(\sqrt{n/(n-1)}\,\overline{X})] = \Phi(\mu)$ 。 ∎

17. 设 X_1, X_2, X_3 为 *i.i.d.* 样本，且 $X_1 \sim \mathrm{E}(\lambda)$ 。

(1) 令 $Y_1 = X_1 + X_2 + X_3$, $Y_2 = \frac{X_1}{X_1+X_2}$, $Y_3 = \frac{X_1+X_2}{X_1+X_2+X_3}$ ，求 (Y_1, Y_2, Y_3) 的联合密度函数，并判断 Y_1, Y_2, Y_3 是否独立;

(2) 令 $Z_1 = X_1/Y_1$, $Z_2 = X_2/Y_1$ ，求 (Z_1, Z_2) 的联合密度函数。

解. (1) 作变换 $\begin{cases} Y_1 = X_1 + X_2 + X_3 \\ Y_2 = \frac{X_1}{X_1+X_2} \\ Y_3 = \frac{X_1+X_2}{X_1+X_2+X_3} \end{cases}$ 则 $\begin{cases} X_1 = Y_1Y_2Y_3 \\ X_2 = Y_1Y_3 - Y_1Y_2Y_3, \\ X_3 = Y_1 - Y_1Y_3 \end{cases}$

所以变换 Jacobi 为 $\frac{\partial(x_1,x_2,x_3)}{\partial(y_1,y_2,y_3)^T} = y_1^2 y_3$ 。由

$$f(x_1, x_2, x_3) = \lambda^3 e^{-\lambda(x_1+x_2+x_3)} I\{x_{(1)} \geq 0\}$$

可得

$$f(y_1, y_2, y_3) = \lambda^3 e^{-\lambda y_1} y_1^2 y_3 I\{y_1 \geq 0;\ 0 \leq y_2,\ y_3 \leq 1\}.$$

又因为

$$\begin{aligned} Y_1 &= X_1 + X_2 + X_3 \sim \Gamma(\lambda, 3), \quad \text{即} f(y_1) = \frac{1}{2}\lambda^3 e^{-\lambda y_1} y_1^2 \cdot I\{y_1 \geq 0\}, \\ Y_2 &= \frac{X_1}{X_1+X_2} \sim BE(1,1), \qquad \text{即} f(y_2) = 1 \cdot I\{0 \leq y_2 \leq 1\}, \\ Y_3 &= \frac{X_1+X_2}{X_1+X_2+X_3} \sim BE(2,1), \quad \text{即} f(y_3) = 2y_3 \cdot I\{0 \leq y_3 \leq 1\}. \end{aligned}$$

这时有 $f(y_1, y_2, y_3) = f(y_1)f(y_2)f(y_3)$ ，所以 Y_1, Y_2, Y_3 独立。

(2) 作变换 $\begin{cases} Z_1 = X_1/Y_1 \\ Z_2 = X_2/Y_1 \\ Z_3 = Y_1 \end{cases}$ 则 $\begin{cases} X_1 = Z_1Z_3 \\ X_2 = Z_2Z_3 \\ X_3 = Z_3 - X_1 - X_2 = (1 - Z_1 - Z_2)Z_3 \end{cases}$

所以变换 Jacobi 为 $\frac{\partial(x_1,x_2,x_3)}{\partial(z_1,z_2,z_3)^T} = z_3^2$ 。由

$$f(x_1, x_2, x_3) = \lambda^3 e^{-\lambda(x_1+x_2+x_3)} I\{x_i \geq 0, i = 1, 2, 3\}$$

得

$$f(z_1, z_2, z_3) = \lambda^3 e^{-\lambda z_3} \cdot z_3^2 I\{0 \leq z_1, z_2;\ z_1 + z_2 \leq 1;\ z_3 \geq 0\}.$$

所以 (Z_1, Z_2) 的联合密度函数为

$$f(z_1, z_2) = \int_0^\infty f(z_1, z_2, z_3) dz_3 = 2I\{0 \leq z_1, z_2;\ z_1 + z_2 \leq 1\}.$$

∎

18. (1) 设 $X \sim \Gamma(1,\alpha_1)$ ， $Y \sim \Gamma(1,\alpha_2)$ ，且 X 与 Y 独立。证明： $X+Y$ 与 X/Y 独立；

(2) 设 X_1, X_2 独立同分布， $X_1 \sim BE(n,1)$ ，令 $Y = X_{(1)}/X_{(2)}$, $Z = X_{(2)}$, 证明： Y 与 Z 独立。

证明. (1) 作变换 $\begin{cases} U = X+Y \\ V = X/Y \end{cases}$ 则 $\begin{cases} X = \frac{UV}{1+V} \\ Y = \frac{U}{1+V} \end{cases}$

所以变换 Jacobi 为 $|\frac{\partial(x,y)}{\partial(u,v)^T}| = \frac{u}{(1+v)^2}$ 。由

$$f(x,y) = \frac{1}{\Gamma(\alpha_1)\Gamma(\alpha_2)} e^{-(x+y)} x^{\alpha_1-1} y^{\alpha_2-1} I\{x \geq 0, y \geq 0\}$$

得

$$\begin{aligned} f(u,v) &= \frac{1}{\Gamma(\alpha_1)\Gamma(\alpha_2)} e^{-u} (\frac{uv}{1+v})^{\alpha_1-1} (\frac{u}{1+v})^{\alpha_2-1} \frac{u}{(1+v)^2} \cdot I\{u>0\} \cdot I\{v>0\} \\ &= \left(\frac{1}{\Gamma(\alpha_1+\alpha_2)} e^{-u} u^{\alpha_1+\alpha_2-1} \cdot I\{u>0\} \right) \times \\ &\quad \left(\frac{\Gamma(\alpha_1+\alpha_2)}{\Gamma(\alpha_1)\Gamma(\alpha_2)} \cdot v^{\alpha_1-1} (1+v)^{-(\alpha_1+\alpha_2)} \cdot I\{v>0\} \right) \\ &= f(u)f(v) \end{aligned}$$

所以 U 与 V 独立，即 $X+Y$ 与 X/Y 独立。

(2) 作变换 $\begin{cases} Y = X_{(1)}/X_{(2)} \\ Z = X_{(2)} \end{cases}$ 则 $\begin{cases} X_{(1)} = YZ \\ X_{(2)} = Z \end{cases}$

所以变换 Jacobi 为 $\frac{\partial(x_{(1)}, x_{(2)})}{\partial(y,z)^T} = z$ 。由

$$f(x_{(1)}, x_{(2)}) = 2n^2 x_{(1)}^{n-1} x_{(2)}^{n-1} I\{0 \leq x_{(1)} \leq x_{(2)} \leq 1\}$$

可得

$$\begin{aligned} f(y,z) &= 2n^2 (yz)^{n-1} z^{n-1} \cdot z \cdot I\{0 \leq y, z \leq 1\} \\ &= (ny^{n-1} I\{0 \leq y \leq 1\}) \cdot (2nz^{2n-1} I\{0 \leq z \leq 1\}) \\ &= f(y)f(z) \end{aligned}$$

所以 Y 与 Z 独立，并且 $Y \sim BE(n,1)$ ， $Z \sim BE(2n,1)$ 。 ∎

19.* 设 $X_1, \cdots, X_m$, 独立， $X_i \sim \chi^2(n_i)$, $i = 1, \cdots, m$ 。令 $U_1 = \frac{X_1}{X_1+X_2}, U_2 = \frac{X_1+X_2}{X_1+X_2+X_3}$, $\cdots, U_{m-1} = \frac{X_1+\cdots+X_{m-1}}{X_1+\cdots+X_m}$ 。证明： $U_1, \cdots, U_{m-1}$ 相互独立，且 $U_i \sim \beta(\frac{n_1+\cdots+n_i}{2}, \frac{n_{i+1}}{2})$, $i = 1, \cdots, m-1$ (提示：令 $U_m = X_1 + \cdots + X_m$ ，作变换 $X_1 = U_1 \cdots U_m$, $X_2 = U_2 \cdots U_m - U_1 \cdots U_m$, $\cdots, X_m = U_m - U_{m-1}U_m$) 。

证明. 令 $U_m = X_1 + \cdots + X_m$ ，则 $\begin{cases} X_1 = U_1 \cdots U_m \\ X_2 = U_2 \cdots U_m - U_1 \cdots U_m \\ \quad \vdots \\ X_m = U_m - U_{m-1}U_m \end{cases}$

再令 $S_t = U_t U_{t+1} \cdots U_m, t = 1, 2, \cdots, m$ ，则 $\begin{cases} X_1 = S_1 \\ X_2 = S_2 - S_1 \\ \quad \vdots \\ X_m = S_m - S_{m-1} \end{cases}$

所以变换的 Jacobi 行列式为

$$J = \frac{\partial(x_1, \cdots, x_m)}{\partial(u_1, \cdots, u_m)^T} = \begin{vmatrix} \frac{s_1}{u_1} & \frac{s_1}{u_2} & \frac{s_1}{u_3} & \cdots & \frac{s_1}{u_m} \\ -\frac{s_1}{u_1} & \frac{s_2 - s_1}{u_2} & \frac{s_2 - s_1}{u_3} & \cdots & \frac{s_2 - s_1}{u_m} \\ 0 & -\frac{s_2}{u_2} & \frac{s_3 - s_2}{u_3} & \cdots & \frac{s_3 - s_2}{u_m} \\ \vdots & & \ddots & \ddots & \vdots \\ 0 & \cdots & & -\frac{s_{m-1}}{u_{m-1}} & \frac{s_m - s_{m-1}}{u_m} \end{vmatrix}$$

行列式的第一行加到第二行；然后第二行加到第三行； $\cdots$ ；如此继续可得

$$J = \frac{s_1}{u_1}\frac{s_2}{u_2}\cdots\frac{s_m}{u_m} = s_2 \cdots s_m = \prod_{i=2}^{m} u_i^{i-1}$$

因为

$$f(x_1, \cdots, x_m) = \left(\prod_{i=1}^{m} \frac{1}{2^{\frac{n_i}{2}}\Gamma(\frac{n_i}{2})}\right) \cdot \exp\{-\frac{1}{2}\sum_{i=1}^{m} x_i\} \prod_{i=1}^{m} x_i^{\frac{n_i}{2}-1}.$$

注意到 $x_i = s_i - s_{i-1} = (1 - u_{i-1})u_i u_{i+1} \cdots u_m$, $\sum_{i=1}^{m} x_i = s_m = u_m$, 因此有

$$\prod_{i=1}^{m} x_i^{\frac{n_i}{2}-1} = \left[\prod_{i=1}^{m} u_i^{\sum_{j=1}^{i}(\frac{n_j}{2}-1)}\right] \cdot \left[\prod_{i=1}^{m-1} (1 - u_i)^{\frac{n_{i+1}}{2}-1}\right]$$

所以把 Jacobi 行列式 J 代入上式可得

$$f(u_1, \cdots, u_m) = \left(\prod_{i=1}^{m} \frac{1}{2^{\frac{n_i}{2}}\Gamma(\frac{n_i}{2})}\right) \exp\{-\frac{1}{2}u_m\} u_m^{\frac{n_1+\cdots+n_m}{2}-1} \cdot \prod_{i=1}^{m-1} u_i^{\frac{n_1+\cdots+n_i}{2}-1}(1 - u_i)^{\frac{n_{i+1}}{2}-1}$$

由此可知 $U_1, \cdots, U_m$ 独立，且 $U_i \sim BE(\frac{n_1+\cdots+n_i}{2}, \frac{n_{i+1}}{2})$, $\quad i = 1, 2, \cdots, m-1$ 。 ∎

20. 设 $X_1, \cdots, X_4$ 为 *i.i.d.* 样本，若 $X_1 \sim N(0, \sigma^2)$ ，则 $Z = (X_1^2 + X_2^2)/(X_1^2 + X_2^2 + X_3^2 + X_4^2) \sim R(0, 1)$ 。

证明. 由定理 (1.3.1) 的推论 3 可知：

$$Z \sim BE(\frac{2}{2}, \frac{2}{2}) \sim BE(1, 1) \sim R(0, 1).$$

∎

21. 设 $X_1, \cdots, X_n$ 为 *i.i.d.* 样本,

(1) 设 X_1 服从均匀分布 $R(0, \theta)$ ，证明： $T = -2\sum_{i=1}^{n} \log(X_i/\theta)$ 服从 $\chi^2(2n)$ ；

(2) 设 X_1 服从 β 分布 $BE(\theta, 1)$ ，证明： $T = -2\theta\sum_{i=1}^{n} \log X_i$ 服从 $\chi^2(2n)$ ；

(3) 设 X_1 服从 Weibull 分布，即 $f(x_1) = \alpha\lambda x_1^{\alpha-1} exp\{-\lambda {x_1}^{\alpha}\} I\{x_1 > 0\}$ ，证明：$T = 2\lambda \sum_{i=1}^n X_i^\alpha$ 服从 $\chi^2(2n)$ 。

证明. (1) 由 $X_1 \sim R(0,\theta)$ 得 $X_1/\theta \sim R(0,1)$ ，所以

$$-\log(Z_1/\theta) \sim \Gamma(1,1), \quad -2\log(X_1/\theta) \sim \Gamma(\frac{1}{2},1) \sim \chi^2(2).$$

因为 $X_1,\cdots,X_n \quad i.i.d.$ ，所以 $-2\log(X_1/\theta),\cdots,-2\log(X_n/\theta) \quad i.i.d.$ ；由 χ^2 分布的可加性可知

$$T = -2\sum_{i=1}^n \log(X_i/\theta) \sim \chi^2(2n).$$

(2) 令 $y_1 = -\log x_1$ ，则 $x_1 = e^{-y_1}, \quad dx_1 = -e^{-y_1}dy_1$ 。因为

$$f(x_1,\theta) = \theta x_1^{\theta-1} I\{0 \le x_1 \le 1\},$$

所以

$$f(y_1,\theta) = \theta e^{-(\theta-1)y_1} e^{-y_1} I\{y_1 \ge 0\} = \theta e^{-\theta y_1} I\{y_1 \ge 0\},$$

从而

$$Y_1 = -\log X_1 \ \sim \Gamma(\theta,1), \quad 2\theta Y_1 = -2\theta\log X_1 \sim \Gamma(\frac{1}{2},1) \sim \chi^2(2).$$

又因为 $X_1,\cdots,X_n \quad i.i.d.$ ，所以 $-2\theta\log X_1,\cdots,-2\theta\log X_n \quad i.i.d.$ ；由 χ^2 分布的可加性可知

$$-2\theta\sum_{i=1}^n \log X_i \sim \chi^2(2n).$$

(3) 令 $Y_1 = X_1^\alpha$ ，则 $X_1 = Y_1^{\frac{1}{\alpha}}, \quad dx_1 = \frac{1}{\alpha} y_1^{\frac{1}{\alpha}-1} dy_1$ ，所以

$$\begin{aligned} f(y_1) &= \alpha\lambda y_1^{\frac{1}{\alpha}(\alpha-1)} e^{-\lambda y_1} \cdot \frac{1}{\alpha} y_1^{\frac{1}{\alpha}-1} I\{y_1 \ge 0\} \\ &= \lambda e^{-\lambda y_1} I\{y_1 \ge 0\} \end{aligned}$$

由此可知

$$Y_1 \sim \Gamma(\lambda,1), \quad 2\lambda X_1^\alpha \sim \Gamma(\frac{1}{2},1) \sim \chi^2(2).$$

又因为 $X_1,\cdots,X_n \quad i.i.d.$ ，所以 $2\lambda X_1^\alpha,\cdots,2\lambda X_n^\alpha \quad i.i.d.$ ；由 χ^2 分布的可加性知

$$T = 2\lambda\sum_{i=1}^n X_i^\alpha \sim \chi^2(2n).$$

∎

22. (1) 设 X 服从 Poisson 分布 $P(\lambda)$ ，证明：$(X-\lambda)/\sqrt{\lambda}$ 的渐近分布为标准正态分布 $N(0,1)$ (当 $\lambda \to +\infty$) (提示：用特征函数证明) ；

(2) 设 X 服从 $\chi^2(n)$ 分布，证明：$(X-n)/\sqrt{2n}$ 的渐近分布为标准正态分布 $N(0,1)$ (当 $n \to +\infty$) 。

证明. (1) $(X-\lambda)/\sqrt{\lambda}$ 的特征函数为

$$\begin{aligned}\varphi(t) &= \mathrm{E}(e^{i\frac{X-\lambda}{\sqrt{\lambda}}t}) = e^{-it\sqrt{\lambda}}\cdot \mathrm{E}(e^{iX\frac{t}{\sqrt{\lambda}}}) \\ &= \exp\{-it\sqrt{\lambda}\}\cdot\exp\{\lambda(e^{it/\sqrt{\lambda}}-1)\} \\ &= \exp\{\lambda(e^{it/\sqrt{\lambda}}-1)-it\sqrt{\lambda}\} \\ &= \exp\{\lambda[1+\frac{it}{\sqrt{\lambda}}+\frac{(it)^2}{2\lambda}+o(\frac{1}{\lambda})]-\lambda-it\sqrt{\lambda}\} \\ &= \exp\{-\frac{1}{2}t^2+o(1)\}\end{aligned}$$

其中当 $\lambda\longrightarrow\infty$ 时， $o(1)\longrightarrow 0$ 。所以

$$\varphi(t)\longrightarrow\exp\{-\frac{1}{2}t^2\}.$$

而 $\exp\{-\frac{1}{2}t^2\}$ 是标准正态分布 $N(0,1)$ 的特征函数，由唯一性知： $(X-\lambda)/\sqrt{\lambda}$ 的渐近分布为 $N(0,1)(\lambda\longrightarrow\infty)$ 。

(2) 由标准正态分布与 χ^2 分布的关系可知， X 可被表示为 $X=\sum_{i=1}^n Y_i^2$ ，其中 $Y_1,\cdots,Y_n$ *i.i.d.* 且 $Y_1\sim N(0,1)$， $Y_i^2\sim\chi^2(1)$ 。根据中心极限定理，我们有

$$\frac{\sum_{i=1}^n Y_i^2-\sum_{i=1}^n \mathrm{E}Y_i^2}{\sqrt{\sum_{i=1}^n \mathrm{Var}(Y_i^2)}}\xrightarrow{L}N(0,1),$$

所以有

$$(X-n)/\sqrt{2n}\xrightarrow{L}N(0,1)\ (n\longrightarrow\infty).$$

注. 本题亦可通过计算特征函数来加以证明。另外，以上公式可用来计算 χ^2 分布的分位数。因为在一般的 χ^2 分布表中，只有自由度从 $1-45$ 的表，对于自由度 $n>45$ 的 χ^2 分布，可认为样本比较大，因而由以上公式有 $P\{(X-n)/\sqrt{2n}\le z_\alpha\}\approx\alpha$ ，由此可得 $\chi^2(n,\alpha)\approx n+\sqrt{2n}z_\alpha$ ，其中 z_α 为标准正态分布的 α 分位数。 ∎

23. 设 $X_1,\cdots,X_n$ 为 *i.i.d.* 样本， X_1 服从 Pareto 分布 $PR(\alpha,\theta)$ ，即 X_1 的密度函数为 $f(x_1)=\alpha\theta^\alpha {x_1}^{-(\alpha+1)}I\{x_1\ge\theta\}$ ，令 $T=\prod_{i=1}^n X_i$ ，证明：

(1) $2\alpha(\log T-n\log\theta)$ 服从 $\chi^2(2n)$ ； (2) $X_{(1)}\sim PR(n\alpha,\theta)$ 。

证明. (1) 令 $y_1=\log x_1$ ，则 $x_1=e^{y_1}$， $dx_1=e^{y_1}dy_1$ ，由此可得 Y_1 的密度函数为

$$\begin{aligned}f(y_1) &= \alpha\theta^\alpha e^{-(\alpha+1)y_1}\cdot e^{y_1}I\{y_1\ge\log\theta\} \\ &= \alpha e^{-\alpha(y_1-\log\theta)}I\{y_1-\log\theta\ge 0\}\end{aligned}$$

所以

$$Y_1-\log\theta=\log X_1-\log\theta\sim\Gamma(\alpha,1),$$

从而

$$2\alpha(\log X_1-\log\theta)\sim\Gamma(\frac{1}{2},1)\sim\chi^2(2).$$

又因为 $X_1,\cdots,X_n$ *i.i.d.* ，所以 $2\alpha(\log X_1-\log\theta),\cdots,2\alpha(\log X_n-\log\theta)$ *i.i.d.* ；由 χ^2 分布的可加性知

$$2\alpha(\log T-n\log\theta)\sim\chi^2(2n).$$

(2) X_1 的分布函数为

$$F(x_1)=\int_{\theta}^{x_1}\alpha\theta^{\alpha}t^{-(\alpha+1)}dt=-\theta^{\alpha}\cdot t^{-\alpha}|_{\theta}^{x_1}=1-(\frac{\theta}{x_1})^{\alpha},$$

由极小次序统计量 $S=X_{(1)}$ 的密度函数公式可得 $X_{(1)}$ 的密度函数为

$$f(s)=n\alpha\theta^{\alpha}s^{-(\alpha+1)}(\frac{\theta}{s})^{(n-1)\alpha}I\{s\geq\theta\}=n\alpha\theta^{n\alpha}s^{-(n\alpha+1)}I\{s\geq\theta\}\sim PR(n\alpha,\theta),$$

所以 $X_{(1)}\sim PR(n\alpha,\theta)$ 。 ∎

24. (1) 若 X_1, X_2 独立同分布，且 $X_1\sim N(0,1)$ ，则 $Y=X_1/|X_2|\sim CA(0,1)$ ；

(2) 设 $X_1,\cdots,X_n$ 为 *i.i.d.* 样本，且 X_1 服从 $CA(0,1)$ ，证明： $\overline{X}=n^{-1}\sum_{i=1}^{n}X_i$ 与 X_1 同分布。

证明. (1) 由两个随机变量商的密度函数公式可知

$$f_Y(y)=f_{X_1/|X_2|}(y)=\int_{-\infty}^{\infty}f_{X_1}(yx_2)f_{|X_2|}(x_2)|x_2|dx_2,$$

因为

$$f_{|X_2|}(x_2)=\frac{2}{\sqrt{2\pi}}e^{-x_2^2/2},\quad \text{其中 } |X_2|\in[0,+\infty),$$

所以

$$\begin{aligned}f_{X_1/|X_2|}(y)&=\int_0^{+\infty}\frac{1}{\sqrt{2\pi}}e^{-(yx_2)^2/2}\cdot\frac{2}{\sqrt{2\pi}}e^{-x_2^2/2}x_2dx_2\\&=\frac{1}{\pi}\int_0^{+\infty}e^{-(x_2^2/2)(y^2+1)}x_2dx_2\\&=\frac{1}{\pi}\frac{1}{1+y^2}\end{aligned}$$

所以 $Y=X_1/|X_2|\sim CA(0,1)$ 。

注. 本题亦可如下证明。因为 X_1, X_2 独立同分布，且 $X_1\sim N(0,1)$ ，所以

$$Y=\frac{X_1}{|X_2|}=\frac{X_1}{\sqrt{X_2^2}}\sim t(1).$$

又因为自由度为 1 的 t 分布就是标准 Cauchy 分布，所以 $Y=\frac{X_1}{|X_2|}\sim CA(0,1)$ 。

(2) 因为 X_1 的特征函数为

$$\varphi_{X_1}(t)=\exp\{it-|t|\},$$

所以 $\overline{X}$ 的特征函数为

$$\varphi_{\overline{X}}(t)=\mathrm{E}(e^{it\overline{X}})=\prod_{j=1}^{n}\varphi_{X_j}(t/n)=\exp\{it-|t|\},$$

由唯一性定理知： $\overline{X}$ 与 X_1 同分布。 ∎

25.* 设 $X_2 \sim N(\mu_2, V_2)$ ， $X_1|X_2 \sim N(AX_2, B)$ ；证明： $X_1 \sim N(A\mu_2,\ B + AV_2A^T)$;

$$\begin{pmatrix} X_1 \\ X_2 \end{pmatrix} \sim N\left(\begin{pmatrix} A\mu_2 \\ \mu_2 \end{pmatrix}, \begin{pmatrix} B + AV_2A^T & AV_2 \\ V_2A^T & V_2 \end{pmatrix}\right).$$

(提示：应用条件期望公式计算特征函数) 。

证明. 由多元正态分布的特征函数的计算公式可算得 X_1 的特征函数为

$$\begin{aligned}
\varphi_{X_1}(t_1) &= \mathrm{E}(e^{it_1^TX_1}) = \mathrm{E}_{X_2}\{E[e^{it_1^TX_1}|X_2]\} \\
&= \mathrm{E}_{X_2}\{e^{it_1^TAX_2-\frac{1}{2}t_1^TBt_1}\} = e^{-\frac{1}{2}t_1^TBt_1}\cdot \mathrm{E}_{X_2}\{e^{i(A^Tt_1)^TX_2}\} \\
&= e^{-\frac{1}{2}t_1^TBt_1}\cdot e^{i(A^Tt_1)^T\mu_2-\frac{1}{2}(A^Tt_1)^TV_2(A^Tt_1)} \\
&= e^{it_1^TA\mu_2-\frac{1}{2}t_1^T(B+AV_2A^T)t_1}
\end{aligned}$$

由唯一性知 $X_1 \sim N(A\mu_2,\ B + AV_2A^T)$ 。

记

$$X = \begin{pmatrix} X_1 \\ X_2 \end{pmatrix}, \quad \mu = \begin{pmatrix} A\mu_2 \\ \mu_2 \end{pmatrix}, \quad t = \begin{pmatrix} t_1 \\ t_2 \end{pmatrix}, \quad V = \begin{pmatrix} B + AV_2A^T & AV_2 \\ V_2A^T & V_2 \end{pmatrix},$$

则 $X = (X_1^T, X_2^T)^T$ 的特征函数为

$$\begin{aligned}
\varphi(t) &= \mathrm{E}(e^{iX^Tt}) = \mathrm{E}\{e^{iX_1^Tt_1+iX_2^Tt_2}\} \\
&= \mathrm{E}_{X_2}\{\mathrm{E}[\exp(iX_1^Tt_1 + iX_2^Tt_2)|X_2]\} = \mathrm{E}_{X_2}\{e^{iX_2^Tt_2}\cdot \mathrm{E}[e^{iX_1^Tt_1}|X_2]\} \\
&= \mathrm{E}_{X_2}\{\exp[iX_2^Tt_2 + i(AX_2)^Tt_1 - \frac{1}{2}t_1^TBt_1]\} = e^{-\frac{1}{2}t_1^TBt_1}\cdot \mathrm{E}_{X_2}\{e^{iX_2^T(A^Tt_1+t_2)}\} \\
&= e^{-\frac{1}{2}t_1^TBt_1}\cdot \exp\{i\mu_2^T(A^Tt_1 + t_2) - \frac{1}{2}(A^Tt_1 + t_2)^TV_2(A^Tt_1 + t_2)\} \\
&= \exp\{i\mu^Tt - \frac{1}{2}t^TVt\}.
\end{aligned}$$

这与多元正态分布 $N(\mu, V)$ 的特征函数相一致，所以由唯一性知 $X \sim N(\mu, V)$ 。注意，在求 $\varphi(t)$ 的过程中，我们用到了

$$\begin{aligned}
\mu^Tt &= \mu_2^TA^Tt_1 + \mu_2^Tt_2 = \mu_2^T(A^Tt_1 + t_2), \\
t^TVt &= t_1^TAV_2A^Tt_1 + t_1^TBt_1 + t_1^TAV_2t_2 + t_2^TV_2A^Tt_1 + t_2^TV_2t_2 \\
&= (A^Tt_1 + t_2)^TV_2(A^Tt_1 + t_2) + t_1^TBt_1.
\end{aligned}$$

注. 本题亦可如下证明。由于 $X_2 \sim N(\mu_2, V_2)$, $X_1|X_2 \sim N(AX_2, B)$ ，因此可令 $X_1 = AX_2 + \epsilon$ 。经简单计算可知， $\epsilon \sim N(0, B)$ ，且与 X_2 独立。因为

$$\begin{pmatrix} X_2 \\ \epsilon \end{pmatrix} \sim N\left(\begin{pmatrix} \mu_2 \\ 0 \end{pmatrix}, \begin{pmatrix} V_2 & 0 \\ 0 & B \end{pmatrix}\right), \quad X_1 = \begin{pmatrix} A & I_1 \end{pmatrix}\cdot \begin{pmatrix} X_2 \\ \epsilon \end{pmatrix}$$

所以 $X_1 \sim N(A\mu_2,\ B + AV_2A^T)$ 。又因为

$$\begin{pmatrix} X_1 \\ X_2 \end{pmatrix} = \begin{pmatrix} A & I_1 \\ I_2 & 0 \end{pmatrix}\cdot \begin{pmatrix} X_2 \\ \epsilon \end{pmatrix},$$

其中 I_1, I_2 是维数分别与 X_1, X_2 的维数相一致的单位阵。所以有

$$\begin{pmatrix} X_1 \\ X_2 \end{pmatrix} \sim N\left(\begin{pmatrix} A\mu_2 \\ \mu_2 \end{pmatrix}, \begin{pmatrix} B + AV_2A^T & AV_2 \\ V_2A^T & V_2 \end{pmatrix}\right). \qquad \blacksquare$$

26. 设 $X \sim N(\mu, 1)$ ，求 X^2 的特征函数，并证明它服从非中心 χ^2 分布 $\chi^2(1, \mu^2)$ 。

证明. X^2 的特征函数为

$$\begin{aligned} \varphi(t) &= \mathrm{E}(e^{itX^2}) = \int_{-\infty}^{\infty} e^{itx^2} \cdot \frac{1}{\sqrt{2\pi}} e^{-\frac{(x-\mu)^2}{2}} dx \\ &= \int_{-\infty}^{\infty} \frac{1}{\sqrt{2\pi}} \exp\{-\frac{1}{2}[(1-2it)x^2 - 2\mu x + \mu^2]\} dx. \end{aligned}$$

令 $u = \sqrt{(1-2it)}x$ ，则有

$$\begin{aligned} \varphi(t) &= \int_{-\infty}^{\infty} \frac{1}{\sqrt{2\pi}} \exp\{-\frac{1}{2}(u^2 - \frac{2\mu}{\sqrt{1-2it}}u + \mu^2)\} \cdot (1-2it)^{-\frac{1}{2}} du \\ &= (1-2it)^{-\frac{1}{2}} \exp\{\frac{1}{2}(\frac{\mu^2}{1-2it} - \mu^2)\} \cdot \int_{-\infty}^{\infty} \frac{1}{\sqrt{2\pi}} e^{-\frac{1}{2}(u - \frac{\mu}{\sqrt{1-2it}})^2} du \\ &= (1-2it)^{-\frac{1}{2}} \exp\{\frac{it\mu^2}{1-2it}\}. \end{aligned}$$

这恰好是非中心 χ^2 分布 $\chi^2(1, \mu^2)$ 的特征函数，由唯一性知 $X^2 \sim \chi^2(1, \mu^2)$ 。 $\blacksquare$

27. 设 X 服从非中心 χ^2 分布 $\chi^2(n, \delta)$ 。证明：当 $n \to +\infty$ 时， $[X - (n+\delta)]/\sqrt{2(n+2\delta)}$ 的渐近分布为标准正态分布 $N(0, 1)$ 。

证明. 由非中心 χ^2 分布的可加性知, X 可分解为: $X = \sum_{i=1}^n Y_i^2$,其中 $Y_1, \cdots, Y_n \quad i.i.d.$, $Y_1 \sim N(\mu, 1),\ \mu = \pm\sqrt{\delta/n}$ 。由于 $Y_1^2 \sim \chi^2(1, \delta/n)$ ，所以 $\mathrm{E}(Y_1^2) = 1 + \delta/n,\ \mathrm{Var}(Y_1^2) = 2(1 + 2\delta/n)$ 。从而由中心极限定理得:

$$\frac{X - (n+\delta)}{\sqrt{2(n+2\delta)}} = \frac{\sum_{i=1}^n Y_i^2 - \sum_{i=1}^n \mathrm{E}(Y_i^2)}{\sqrt{\sum_{i=1}^n \mathrm{Var}(Y_i^2)}} \xrightarrow{L} N(0, 1)\ (n \longrightarrow \infty).$$

注. 本题亦可通过计算特征函数来加以证明。 $\blacksquare$

28.* 设 $X_1 \sim P(\lambda x)$ ， $X_2 \sim P(\delta/2)$ ，二者都服从 Poisson 分布。证明： $P(X_1 - X_2 \geq \nu) = \Gamma(x; \lambda, \nu, \delta)$ 为非中心 Γ 分布 $\Gamma(\lambda, \nu; \delta)$ 的分布函数 (提示：应用关于 X_2 的全概公式及第 13 题的结果) 。

证明. 今记 $G(x) = P(X_1 - X_2 \geq \nu)$ ，则有

$$\begin{aligned} G(x) &= P(X_1 - X_2 \geq \nu) = 1 - P(X_1 - X_2 < \nu) \\ &= 1 - P(X_1 - X_2 \leq \nu - 1) = 1 - P(X_1 \leq X_2 + \nu - 1) \\ &= 1 - \sum_{j=0}^{\infty} P(X_1 \leq X_2 + \nu - 1 | X_2 = j) P(X_2 = j) \\ &= 1 - \sum_{j=0}^{\infty} e^{-\frac{\delta}{2}} \frac{(\delta/2)^j}{j!} \cdot P(X_1 \leq \nu + j - 1) \\ &= 1 - \sum_{j=0}^{\infty} e^{-\frac{\delta}{2}} \frac{(\delta/2)^j}{j!} \cdot \frac{1}{\Gamma(\nu + j)} \int_{\lambda x}^{\infty} e^{-t} t^{\nu+j-1} dt \end{aligned}$$

以上最后一式用到了第 13 题的结果。另一方面，若记非中心 Γ 分布 $\Gamma(\lambda,\nu;\delta)$ 的密度函数为 $\gamma(x;\lambda,\nu,\delta)$ ，则有

$$\begin{aligned}
\Gamma(x;\lambda,\nu,\delta) &= \int_0^x \gamma(t;\lambda,\nu,\delta)dt = 1-\int_x^\infty \gamma(t;\lambda,\nu,\delta)dt \\
&= 1-\int_x^\infty \sum_{j=0}^\infty \frac{\lambda^{\nu+j}}{\Gamma(\nu+j)} e^{-\lambda t} t^{\nu+j-1}\cdot e^{-\frac{\delta}{2}}\frac{(\delta/2)^j}{j!}dt \\
&= 1-\sum_{j=0}^\infty e^{-\frac{\delta}{2}}\frac{(\delta/2)^j}{j!}\cdot\frac{1}{\Gamma(\nu+j)}\int_{\lambda x}^\infty e^{-u}u^{\nu+j-1}du \\
&= G(x)
\end{aligned}$$

其中上面第三个等式用到了变换 $\lambda t = u$ ， 所以 $P(X_1-X_2\ge\nu)=\Gamma(x;\lambda,\nu,\delta)$ 。 ∎

29.★ 设 $X\sim\chi^2(n)$ ， $Y=X/\delta,\ 0<\delta<1$ 。利用特征函数的展开证明： Y 可视为 (Y,J) 中 Y 的边缘分布，其中 $J\sim NB(\delta,n/2)$ ， $Y|J\sim\chi^2(n+2J)$ 。

证明. 易见， X 和 Y 都是连续型分布，都存在特征函数。 X 的特征函数为

$$\phi_X(t)=\mathrm{E}(e^{iXt})=(1-2it)^{-\frac{n}{2}}.$$

Y 的特征函数为

$$\begin{aligned}
\phi_Y(t) &= \mathrm{E}(e^{iYt})=\mathrm{E}(e^{i(X/\delta)t})=\mathrm{E}(e^{iXt/\delta})=(1-2it/\delta)^{-\frac{n}{2}} \\
&= (1-\delta^{-1}+\delta^{-1}-2it/\delta)^{-\frac{n}{2}}=[(1-\delta^{-1})+\delta^{-1}(1-2it)]^{-\frac{n}{2}} \\
&= [\delta^{-1}(1-2it)]^{-\frac{n}{2}}[1+\frac{1-\delta^{-1}}{\delta^{-1}(1-2it)}]^{-n/2} \\
&= (1-2it)^{-\frac{n}{2}}\delta^{\frac{n}{2}}[1-(1-\delta)(1-2it)^{-1}]^{-\frac{n}{2}}.
\end{aligned}$$

$0<\delta<1$ 时，该式可以进行 Taylor 展开，从而得到

$$\begin{aligned}
\phi_Y(t) &= (1-2it)^{-\frac{n}{2}}\delta^{\frac{n}{2}}\sum_{j=0}^\infty \frac{\frac{n}{2}\cdots(\frac{n}{2}+j-1)}{j!}\cdot(1-\delta)^j(1-2it)^{-j} \\
&= \sum_{j=0}^\infty (1-2it)^{-\frac{n}{2}-j}\times\frac{(\frac{n}{2}+j-1)!}{j!(\frac{n}{2}-1)!}\delta^{\frac{n}{2}}(1-\delta)^j.
\end{aligned}$$

该式右端第一项为 $\chi^2(n+2j)$ 的特征函数，第二项为 $NB(\delta,n/2)$ 的分布密度。根据特征函数的逆转公式，上式两端乘以 $(2\pi)^{-1}e^{-ixt}$ ，然后积分。由于 $0<\delta<1$ 时以上级数收敛，相应的分布密度都存在，因此可以逐项积分，从而得到

$$\begin{aligned}
\frac{1}{2\pi}\int_{-\infty}^\infty \phi_Y(t)e^{-ixt}dt &= \sum_{j=0}^\infty \frac{1}{2\pi}\int_{-\infty}^\infty (1-2it)^{-\frac{n}{2}-j}e^{-ixt}dt\times\frac{(\frac{n}{2}+j-1)!}{j!(\frac{n}{2}-1)!}\delta^{\frac{n}{2}}(1-\delta)^j \\
f_Y(x) &= \sum_{j=0}^\infty \chi^2(x;\ n+2j)\times\frac{(\frac{n}{2}+j-1)!}{j!(\frac{n}{2}-1)!}\delta^{\frac{n}{2}}(1-\delta)^j.
\end{aligned}$$

其中 $f_Y(x)$ 和 $\chi^2(x;\ n+2j)$ 分别为 Y 和 $\chi^2(n+2j)$ 分布的密度函数。上式与原书 (1.4.1) 式 (见 p.25) 完全类似，只是上式第二项为负二项分布，不再是 Poisson 分布。因此， Y 可视为 (Y,J) 中 Y 的边缘分布，其中 $J\sim NB(\delta,n/2)$ ， $Y|J\sim\chi^2(n+2J)$ 。 ∎

30. (1) 设 X 服从负二项分布 $NB(\theta,r)$ 。若 r 已知， θ 未知，则为指数族；若 θ ， r 都未知，则负二项分布不是指数族；

(2) 设 X 服从 Laplace 分布 $LA(\mu,\sigma)$ ，若 μ,σ 都未知，则 $LA(\mu,\sigma)$ 不是指数族；若 μ 为常数， σ 未知，则 $LA(\mu,\sigma)$ 为指数族。

证明. (1) 负二项分布的密度函数为

$$\begin{aligned} f(x) &= \binom{x+r-1}{x}\theta^r(1-\theta)^x \qquad (x=0,1,2,\cdots) \\ &= \exp\{x\log(1-\theta)+r\log\theta+\log(x+r-1)!-\log(x)!-\log(r-1)!\}. \end{aligned}$$

当 r 已知， θ 未知时，显然是指数族；当 θ ， r 都未知时， $\log(x+r-1)!$ 无法表示为 $T(x)Q(r)$ 的形式，所以不是指数族。

(2) Laplace 分布 $LA(\mu,\sigma)$ 的密度函数为

$$f(x)=\frac{1}{2\sigma}\exp\{-\frac{|x-\mu|}{\sigma}\}=\frac{1}{2}\exp\{-\frac{x-\mu}{\sigma}I\{x\geq\mu\}+\frac{x-\mu}{\sigma}I\{x<\mu\}-\log\sigma\}.$$

在 $I\{x\geq\mu\}$ 和 $I\{x<\mu\}$ 中显然无法将 x 和 μ 分开，表示为 $T(x)Q(\mu)$ 的形式，所以当 μ,σ 都未知时，$LA(\mu,\sigma)$ 不是指数族；但是当 μ 为常数，σ 未知时，若记 $T(x)=|x-\mu|$ ，则有

$$f(x)=\frac{1}{2}\exp\{-\frac{T(x)}{\sigma}-\log\sigma\}.$$

显然为指数族。 ∎

31. 设 $Y_1,\cdots,Y_n$ 独立同分布， Y_1 服从指数族分布 $ED(\theta,\sigma^2)$, 即

$$f(y_1;\theta,\phi)=\exp\left\{\phi\left[\theta^Ty_1-b(\theta)-c(y_1,\phi)\right]\right\},\quad \phi=\sigma^{-2}.$$

求 Y_1 的特征函数，并证明： $\overline{Y}=n^{-1}\sum_{i=1}^nY_i$ 服从指数族分布 $ED(\theta,\sigma^2/n)$

解. Y_1 的特征函数为

$$\begin{aligned} \varphi_{Y_1}(t) &= \mathrm{E}(e^{it^TY_1})=\int_{R^p}e^{it^Ty_1}\cdot f(y_1;\theta,\phi)d\mu(y_1) \\ &= \int_{R^p}\exp\{\phi[(\theta+it/\phi)^Ty_1-b(\theta+it/\phi)-c(y_1,\phi)]\}\times \\ &\quad \exp\{\phi[b(\theta+it/\phi)-b(\theta)]\}d\mu(y_1) \\ &= \exp\{\phi[b(\theta+it/\phi)-b(\theta)]\} \end{aligned}$$

其中 p 为 Y_1 的维数。由此易得 $\overline{Y}=n^{-1}\sum_{k=1}^nY_k$ 的特征函数为

$$\begin{aligned} \varphi_{\overline{Y}}(t) &= \mathrm{E}(e^{it^T\overline{Y}})=\prod_{k=1}^n\mathrm{E}(e^{it^TY_k/n}) \\ &= \prod_{k=1}^n\exp\{\phi[b(\theta+\frac{it}{n\phi})-b(\theta)]\} \\ &= \exp\{n\phi[b(\theta+\frac{it}{n\phi})-b(\theta)]\} \end{aligned}$$

由唯一性知 $\overline{Y}$ 服从指数族分布 $ED(\theta,\sigma^2/n)$ 。 ∎

32. 设 $X_1,\cdots,X_n$ 为 *i.i.d.* 样本，X_1 的密度函数 $f(x)$ 关于某一点 ξ_0 对称，即 $f(\xi_0+x)=f(\xi_0-x)$ 。设其第 i 个次序统计量的密度函数为 $g_{(i)}(y)$ ，证明：$g_{(i)}(\xi_0+y)=g_{(n-i+1)}(\xi_0-y)$ ，对任意的 y 及 $i=1,\cdots,n$ 都成立。

证明. 设 X_1 的分布函数为 $F(x)$ ，则由次序统计量的密度函数公式可知

$$g_{(i)}(\xi_0+y)=\frac{n!}{(i-1)!(n-i)!}F^{i-1}(\xi_0+y)f(\xi_0+y)[1-F(\xi_0+y)]^{n-i}.$$

由密度函数 $f(x)$ 的对称性可以看出： $F(\xi_0-x)+F(\xi_0+x)=1$ ，事实上

$$\begin{aligned}F(\xi_0+x) &= \int_{-\infty}^{\xi_0+x}f(t)dt=\int_{-\infty}^{x}f(\xi_0+u)du\\ &= \int_{-\infty}^{x}f(\xi_0-u)du=\int_{\infty}^{\xi_0-x}f(s)(-ds)=\int_{\xi_0-x}^{\infty}f(s)ds\\ &= 1-\int_{-\infty}^{\xi_0-x}f(s)ds=1-F(\xi_0-x)\end{aligned}$$

其中第二个等号处用到了变换 $t=\xi_0+u$ ，第四个等号处用到了变换 $s=\xi_0-u$ 。所以

$$\begin{aligned}g_{(i)}(\xi_0+y) &= \frac{n!}{(i-1)!(n-i)!}F^{i-1}(\xi_0+y)f(\xi_0+y)[1-F(\xi_0+y)]^{n-i}\\ &= \frac{n!}{(i-1)!(n-i)!}[1-F(\xi_0-y)]^{i-1}f(\xi_0-y)F^{n-i}(\xi_0-y)\\ &= g_{(n-i+1)}(\xi_0-y).\end{aligned}$$

∎

33. 设 $X_1,\cdots,X_n$ 为 *i.i.d.* 样本， X_1 服从指数分布 $E(1)$ 。证明： $Y=X_{(n)}-\log n$ 收敛到标准极值分布 $f(y)=\exp\{-e^{-y}-y\}$ 。

证明. X_1 的分布函数为 $F(x_1)=(1-e^{-x_1})I\{x_1\geq 0\}$ ，所以 $X_{(n)}$ 的密度函数为

$$f(t)=n(1-e^{-t})^{n-1}e^{-t}I\{t\geq 0\}.$$

令 $Y=X_{(n)}-\log n$ ，则 Y 的密度函数为

$$\begin{aligned}f(y) &= n(1-e^{-y-\log n})^{n-1}e^{-y-\log n}=(1-\frac{1}{n}e^{-y})^{n-1}\cdot e^{-y}\\ &= (1-\frac{1}{n}e^{-y})^{(-\frac{n}{e^{-y}})\cdot\frac{-e^{-y}}{n}\cdot(n-1)}\cdot e^{-y}\\ &\to \exp\{-e^{-y}\}e^{-y}\qquad (n\to\infty)\\ &= \exp\{-e^{-y}-y\}.\end{aligned}$$

所以 $Y=X_{(n)}-\log n$ 收敛到标准极值分布。 ∎

34. 设 $X_1^i,\cdots,X_n^i$ 为 *i.i.d.* 样本， $X_1^i\sim R(0,1)$ ， $i=1,\cdots,k$ ，且各组间也独立。设 $X_{(n)}^i=Y_{in}$ 为第 i 组的最大值， $V=\prod_{i=1}^k Y_{in}$ 。证明： V 的分布密度为

$$g(v)=\frac{n^k}{\Gamma(k)}v^{n-1}(-\log v)^{k-1}I\{0\leq v\leq 1\}$$

(提示：先求 $U=-\log V$ 的分布密度) 。

解. 令 $T_i=Y_{in}$ ，则 $T_i\sim f(t_i)=nt_i^{n-1}I\{0\le t_i\le 1\}$ ，由此易得 $Z_i=-\log T_i\sim ne^{-nz_i}I\{z_i\ge 0\}\sim\Gamma(n,1)$ 。由于组间相互独立，所以 $T_1,\cdots,T_k$ 独立同分布，从而 $Z_1,\cdots,Z_k$ 也独立同分布。所以

$$U=-\log V=\sum_{i=1}^{k}(-\log T_i)=\sum_{i=1}^{k}Z_i\sim\Gamma(n,k).$$

即

$$U\sim f(u)=\frac{n^k}{\Gamma(k)}e^{-nu}u^{k-1}I\{u\ge 0\}.$$

所以

$$g(v)=\frac{n^k}{\Gamma(k)}v^{n-1}(-\log v)^{k-1}I\{0\le v\le 1\}.$$ ∎

35. 设 $(U_{(1)},\cdots,U_{(n)})$ 为均匀分布 $R(0,1)$ 的次序统计量，若记 $Y_1=U_{(1)}/U_{(2)},\cdots,\ Y_k=U_{(k)}/U_{(k+1)},\cdots,\ Y_{n-1}=U_{(n-1)}/U_{(n)},\ Y_n=U_{(n)}$ ，证明： $Y_1,\cdots,Y_k,\cdots,Y_n$ 独立，且有 $Y_k\sim BE(k,1)\sim ky^{k-1}I\{0\le y\le 1\},\ k=1,\cdots,n$ 。

证明. 由 $\begin{cases}Y_1=U_{(1)}/U_{(2)}\\ \quad\vdots\\ Y_{n-1}=U_{(n-1)}/U_{(n)}\\ Y_n=U_{(n)}\end{cases}$ 可得 $\begin{cases}U_{(1)}=Y_1Y_2\cdots Y_n\\ \quad\vdots\\ U_{(n-1)}=Y_{n-1}Y_n\\ U_{(n)}=Y_n\end{cases}$

所以变换 Jacobi 为

$$J=\frac{\partial(u_1,\cdots,u_n)}{\partial(y_1,\cdots,y_n)^T}=\prod_{k=1}^{n}y_k^{k-1}.$$

由于 $(U_{(1)},\cdots,U_{(n)})$ 的分布密度函数为

$$f(u_1,\cdots,u_n)=n!I\{0\le u_1<u_2<\cdots<u_n\le 1\},$$

所以有

$$\begin{aligned}f(y_1,\cdots,y_n)&=f(u_1,\cdots,u_n)\cdot|J|\\&=n!\prod_{k=1}^{n}y_k^{k-1}I\{0<y_k<1,\ k=1,2,\cdots,n\}\\&=\prod_{k=1}^{n}ky_k^{k-1}I\{0<y_k<1\}.\end{aligned}$$

由此可知 $Y_1,\cdots,Y_n$ 独立，且有 $Y_k\sim BE(k,1)$ 。 ∎

36.★ 设 $X_1,\cdots,X_n$ 为 *i.i.d.* 样本，且 X_1 服从均匀分布 $R(0,1)$ 。证明：

(1) $(\frac{X_{(1)}}{X_{(r+1)}},\cdots,\frac{X_{(r)}}{X_{(r+1)}})$ 与 $(X_{(r+1)},\cdots,X_{(n)})$ 独立， $r=1,\cdots,n-1$ ；

(2) 利用 (1) 来证明 $X_{(n)},\frac{X_{(n)}}{X_{(n-1)}},\frac{X_{(n-1)}}{X_{(n-2)}},\cdots,\frac{X_{(2)}}{X_{(1)}}$ 独立。 (提示：在 (1) 中求联合分布) 。

证明. (1) 作变换 $\begin{cases} Z_1 & = & \frac{X_{(1)}}{X_{(r+1)}} \\ & \vdots & \\ Z_r & = & \frac{X_{(r)}}{X_{(r+1)}} \\ Z_{r+1} & = & X_{(r+1)} \\ & \vdots & \\ Z_n & = & X_{(n)} \end{cases}$ 则 $\begin{cases} X_{(1)} & = & Z_{r+1}Z_1 \\ & \vdots & \\ X_{(r)} & = & Z_{r+1}Z_r \\ X_{(r+1)} & = & Z_{r+1} \\ & \vdots & \\ X_{(n)} & = & Z_n \end{cases}$

所以变换的 Jacobi 行列式为

$$J = \frac{\partial(x_{(1)}, \cdots, x_{(n)})}{\partial(z_1, \cdots, z_n)^T} = z_{r+1}^r,$$

由

$$f(x_{(1)}, \cdots, x_{(n)}) = n! I\{0 < x_{(1)} < \cdots < x_{(n)} < 1)\},$$

可得

$$f(z_1, \cdots, z_n) = n! z_{r+1}^r I\{0 < z_1 < \cdots < z_r < 1\} I\{0 < z_{r+1} < \cdots < z_n < 1\}.$$

又因为

$$\begin{aligned} f(z_{r+1}, \cdots, z_n) &= f(x_{(r+1)}, \cdots, x_{(n)}) = \frac{n!}{r!} z_{r+1}^r I\{0 < z_{r+1} < \cdots < z_n < 1\} \\ f(z_1, \cdots, z_r) &= \int_0^1 \int_0^{z_n} \cdots \int_0^{z_{r+3}} \int_0^{z_{r+2}} n! z_{r+1}^r dz_{r+1} dz_{r+2} \cdots dz_{n-1} dz_n \\ &= r! I\{0 < z_1 < \cdots < z_r < 1\}. \end{aligned}$$

所以

$$f(z_1, \cdots, z_n) = f(z_1, \cdots, z_r) \cdot f(z_{r+1}, \cdots, z_n),$$

即 $(\frac{X_{(1)}}{X_{(r+1)}}, \cdots, \frac{X_{(r)}}{X_{(r+1)}})$ 与 $(X_{(r+1)}, \cdots, X_{(n)})$ 独立， $r = 1, \cdots, n-1$ 。

(2) 在 (1) 中，当 $r = 1$ 时，则有 $\frac{X_{(1)}}{X_{(2)}}$ 与 $(X_{(2)}, \cdots, X_{(n)})$ 独立，所以

$$\begin{aligned} P(.) &\triangleq P(X_{(n)} \le y_n, \frac{X_{(n)}}{X_{(n-1)}} \le y_{n-1}, \cdots, \frac{X_{(3)}}{X_{(2)}} \le y_2, \frac{X_{(2)}}{X_{(1)}} \le y_1) \\ &= P(X_{(n)} \le y_n, \frac{X_{(n)}}{X_{(n-1)}} \le y_{n-1}, \cdots, \frac{X_{(3)}}{X_{(2)}} \le y_2) \cdot P(\frac{X_{(2)}}{X_{(1)}} \le y_1). \end{aligned}$$

依此类推，有

$$P(.) = P(X_{(n)} \le y_n) \cdot P(\frac{X_{(n)}}{X_{(n-1)}} \le y_{n-1}) \cdots P(\frac{X_{(3)}}{X_{(2)}} \le y_2) \cdot P(\frac{X_{(2)}}{X_{(1)}} \le y_1),$$

所以 $X_{(n)}, \frac{X_{(n)}}{X_{(n-1)}}, \frac{X_{(n-1)}}{X_{(n-2)}}, \cdots, \frac{X_{(2)}}{X_{(1)}}$ 独立。 ∎

37. 设 $X_1, \cdots, X_n$ 为 *i.i.d.* 样本, 且 X_1 服从 (σ, μ) 上的均匀分布， $-\infty < \sigma < \mu < +\infty$ 。证明： $X_{(1)}|X_{(n)} = x$ 与 $Y_{(1)}$ 同分布，其中 $X_{(1)}, \cdots, X_{(n)}$ 是 $X_1, \cdots, X_n$ 的次序统计量; $Y_1, \cdots, Y_{n-1}$ 为 *i.i.d.* 样本, 且 Y_1 服从 (σ, x) 上的均匀分布; $Y_{(1)}, \cdots, Y_{(n-1)}$ 是 $Y_1, \cdots, Y_{n-1}$ 的次序统计量。

证明. 令 $(T_1,T_2)=(X_{(1)},X_{(n)})$ ，易得 (T_1,T_2) 的联合密度函数为

$$f(t_1,t_2)=n(n-1)(t_2-t_1)^{n-2}\cdot(\mu-\sigma)^{-n}I\{\sigma<t_1<t_2<\mu\},$$

所以 $T_2=X_{(n)}$ 的边缘分布密度函数为

$$f_2(t_2)=\int_\sigma^{t_2}f(t_1,t_2)dt_1=n(t_2-\sigma)^{n-1}(\mu-\sigma)^{-n}.$$

从而 $T_1|T_2=x$ 的分布密度函数为

$$f(t_1|T_2=x)=\frac{f(t_1,x)}{f_2(x)}=(n-1)\frac{(x-t_1)^{n-2}}{(x-\sigma)^{n-1}}.$$

另一方面，因为 $Y_1,\cdots,Y_{n-1}$ 为 *i.i.d.* 样本，且 $Y_1\sim R(\sigma,x)$ ，所以根据最小次序统计量 $T=Y_{(1)}$ 的密度函数公式可得

$$f(t)=(n-1)\frac{(x-t)^{n-2}}{(x-\sigma)^{n-1}}.$$

所以 $X_{(1)}|X_{(n)}=x$ 与 $Y_{(1)}$ 同分布。 ∎

38. 设 $X_1,\cdots,X_n$ 为 *i.i.d.* 样本，且 $X_1\sim\mu+\Gamma(1/\sigma,\ 1)$ 。

(1) 证明： $e^{-X_1/\sigma}\sim R(0,e^{-\mu/\sigma})$ ；

(2) 求 $\frac{X_{(1)}-\mu}{S}$ 的分布，其中 $X_{(1)}$ 为次序统计量中最小的， $S=\sum_{i=1}^n X_{(i)}-nX_{(1)}$ ；

(3) 证明：$X_{(1)},\ X_{(2)}-X_{(1)},\ \cdots,\ X_{(n)}-X_{(n-1)}$ 相互独立；并且 $X_{(i)}$ 与 $X_{(i+k)}-X_{(i)}$ 独立；对任意的 $i,\ k$ 成立。

证明. (1) 令 $e^{-x_1/\sigma}=y$ ，则 $x_1=-\sigma\log y,\quad dx_1=-(\sigma/y)dy$ ，所以 Y 的密度函数为

$$\begin{aligned}f(y)&=\frac{1}{\sigma}e^{-\frac{1}{\sigma}(-\sigma\log y-\mu)}\cdot\frac{\sigma}{y}I\{0<y<e^{-\frac{\mu}{\sigma}}\}\\&=e^{\frac{\mu}{\sigma}}I\{0<y<e^{-\frac{\mu}{\sigma}}\}.\end{aligned}$$

所以 $e^{-X_1/\sigma}\sim R(0,e^{-\mu/\sigma})$ 。

(2) 因为

$$X_{(1)}\sim\mu+\Gamma(\frac{n}{\sigma},1),\ S\sim\Gamma(\frac{1}{\sigma},n-1)$$

且 $X_{(1)}$ 与 S 独立，所以

$$\frac{2n}{\sigma}(X_{(1)}-\mu)\sim\chi^2(2),\ \frac{2}{\sigma}S\sim\chi^2(2(n-1))$$

且二者相互独立，从而

$$\frac{\frac{2n}{\sigma}(X_{(1)}-\mu)/2}{\frac{2}{\sigma}S/2(n-1)}=\frac{n(n-1)(X_{(1)}-\mu)}{S}\sim F(2,2(n-1)).$$

由此易得 $Z=\frac{X_{(1)}-\mu}{S}$ 的分布密度函数为

$$f(z)=n(1+\frac{z}{n(n-1)})^{-n}I\{z\geq 0\}.$$

(3) 令 $Y_i = X_{(i)} - X_{(i-1)},\ i = 2, 3, \cdots, n,\ Y_1 = X_{(1)}$，则由指数族分布次序统计量的性质知 $Y_1, \cdots, Y_n$ 相互独立 (见原书定理 1.6.2, p.41)。又因 $X_{(i)} = \sum_{k=1}^{i} Y_k,\ X_{(i+k)} - X_{(i)} = \sum_{j=i+1}^{i+k} Y_j$，所以对任意的 $i,\ k$， $X_{(i)}$ 与 $X_{(i+k)} - X_{(i)}$ 独立。 ∎

第二章　充分统计量与样本信息

1. 设 $X_1,\cdots,X_n$ 为 $i.i.d.$ 样本，$X_1\sim\Gamma(\lambda,p)$, 但 p 已知。根据定义直接证明 $T=\sum_{i=1}^n X_i$ 是充分统计量。

证明. 因为 $X_1,\cdots,X_n$ 为 $i.i.d.$ 样本， $X_1\sim\Gamma(\lambda,p)$ ，所以

$$T=\sum_{i=1}^n X_i\sim\Gamma(\lambda,np)\sim f(t;\lambda)=\frac{\lambda^{np}}{\Gamma(np)}\ e^{-\lambda t}\ t^{np-1}\ I\{t>0\}.$$

$X_1,\cdots,X_n$ 的联合密度函数为

$$\begin{aligned} f(x_1,\cdots,x_n;\lambda) &= \prod_{i=1}^n\frac{\lambda^p}{\Gamma(p)}\ e^{-\lambda x_i}\ {x_i}^{p-1}\ I\{x_i>0\} \\ &= \frac{\lambda^{np}}{[\Gamma(p)]^n}\ e^{-\lambda\sum_{i=1}^n x_i}\ (\prod_{i=1}^n x_i)^{p-1}\ I\{x_{(1)}>0\}. \end{aligned}$$

又因为

$$\begin{aligned} f(x|t;\lambda) &= \frac{f(x;\lambda)\ I\{x:T(x)=t\}}{f(t;\lambda)} \\ &= \frac{\Gamma(np)(\prod_{i=1}^n x_i)^{p-1}\ I\{x_{(1)}>0\}\ I\{x:\sum_{i=1}^n x_i=t\}}{[\Gamma(p)]^n\ t^{np-1}\ I\{t>0\}} \end{aligned}$$

与参数 λ 无关，所以由充分统计量的定义可知 $T=\sum_{i=1}^n X_i$ 是充分统计量。 ∎

2. 设 $X_1,\cdots,X_n$ 为 $i.i.d.$ 样本， $X_1\sim\mu+\Gamma(\lambda,1)$ 。试用定义直接证明：

(1) 当 $\mu=0$ 时， $T_1=\sum_{i=1}^n X_i$ 是充分统计量；

(2) 当 $\lambda=1$ 时， $T_2=X_{(1)}$ 是充分统计量；但 T_1 不是充分统计量；

(3) 当 μ, λ 都未知时， $T_3=(T_2,T_1)$ 是充分统计量。

证明. (1) 因为 $X_1,\cdots,X_n$ 为 $i.i.d.$ 样本， $X_1\sim\Gamma(\lambda,1)$.
所以

$$T_1\sim\Gamma(\lambda,n)\sim f(t_1;\lambda)=\frac{\lambda^n}{\Gamma(n)}\ e^{-\lambda t_1}\ t_1^{n-1}\ I\{t_1\geq 0\}.$$

$X_1,\cdots,X_n$ 的联合密度函数为

$$f(x_1,\cdots,x_n;\lambda)=\lambda^n\ e^{-\lambda\sum_{i=1}^n x_i}\ I\{x_{(1)}\geq 0\}.$$

又因为

$$\begin{aligned} f(x|t_1;\lambda) &= \frac{f(x_1,\cdots,x_n;\lambda)\ I\{x:T_1=t_1\}}{f(t_1;\lambda)} \\ &= \frac{\Gamma(n)I\{x_{(1)}\geq 0\}\cdot I\{x:\sum_{i=1}^n x_i=t_1\}}{t_1^{n-1}I\{t_1\geq 0\}} \end{aligned}$$

与参数 λ 无关，所以由充分统计量的定义知 $T_1=\sum_{i=1}^n X_i$ 是充分统计量。

(2) $T_2=X_{(1)}$ 的密度函数为

$$f(t_2;\mu)=ne^{-n(t_2-\mu)}I\{t_2\geq\mu\}.$$

$X_1,\cdots,X_n$ 的联合密度函数为

$$f(x_1,\cdots,x_n;\mu)=e^{-\sum_{i=1}^n(x_i-\mu)}I\{x_{(1)}\geq\mu\}.$$

因为条件密度

$$\begin{aligned}f(x|t_2;\mu) &= \frac{f(x_1,\cdots,x_n;\mu)I\{x:T_2=t_2\}}{f(t_2;\mu)}\\ &= \frac{1}{n}\exp\{-\sum_{i=1}^n(x_i-t_2)\}I\{x:x_{(1)}=t_2\},\end{aligned}$$

与参数 μ 无关，所以由充分统计量的定义知 $T_2=X_{(1)}$ 是充分统计量。

当 $\lambda=1$ 时，

$$f(x|t_1;\mu)=\frac{\Gamma(n)\ I\{x_{(1)}\geq\mu\}\cdot I\{x:\sum_{i=1}^n x_i=t_1\}}{(t_1-n\mu)^{n-1}I\{t_1\geq n\mu\}}.$$

以上条件密度与参数 μ 有关，所以 T_1 不是充分统计量。

(3) 令 $T_4=T_1-nT_2=\sum_{i=1}^n(X_i-X_{(1)})$ ，由第一章定理 1.6.2 知， $T_2=X_{(1)}\sim\mu+\Gamma(n\lambda,1)$ 与 $T_4\sim\Gamma(\lambda,n-1)$ 独立，所以 $(T_1,\ T_2)$ 的密度函数可以由 $(T_4,\ T_2)$ 的密度函数经过变换而得到，因此有

$$\begin{aligned}&f(t_1,t_2;\mu,\lambda)\\ =\ &\frac{\lambda^{n-1}}{\Gamma(n-1)}\exp\{-\lambda(t_1-nt_2)\}(t_1-nt_2)^{n-2}I\{t_1\geq nt_2\}\times\\ &n\lambda\exp\{-n\lambda(t_2-\mu)\}I\{t_2\geq\mu\}\\ =\ &\frac{n}{\Gamma(n-1)}\lambda^n e^{-\lambda t_1}e^{n\lambda\mu}(t_1-nt_2)^{n-2}I\{t_2\geq\mu\}I\{t_1\geq nt_2\}.\end{aligned}$$

所以条件密度为

$$\begin{aligned}f(x|t_3,\mu,\lambda) &= \frac{f(x_1,\cdots,x_n;\lambda,\mu)I\{x:\sum_{i=1}^n x_i=t_1,x_{(1)}=t_2\}}{f(t_1,t_2;\mu,\lambda)}\\ &= \frac{\lambda^n e^{-\lambda\sum_{i=1}^n x_i}e^{n\lambda\mu}I\{x_{(1)}\geq\mu\}I\{x:\sum_{i=1}^n x_i=t_1,x_{(1)}=t_2\}}{\frac{n}{\Gamma(n-1)}\lambda^n e^{-\lambda t_1}e^{n\lambda\mu}(t_1-nt_2)^{n-2}I\{t_2\geq\mu\}I\{t_1\geq nt_2\}}\\ &= \frac{\Gamma(n-1)I\{x:\sum_{i=1}^n x_i=t_1,x_{(1)}=t_2\}}{n(t_1-nt_2)^{n-2}}.\end{aligned}$$

该式与参数 μ 和 λ 无关，所以由充分统计量的定义可知 T_3 是充分统计量。 ∎

3. 设 $X_1,\cdots,X_n$ 为 *i.i.d.* 样本， X_1 服从以下分布，求相应的充分统计量：

(1) 负二项分布： $X_1\sim NB(\theta,r)$ ， r 已知;

(2) 离散均匀分布： $X_1\sim U(m)$ ， m 未知;

(3) Γ 分布： $X_1\sim\Gamma(\lambda,p)$;

(4) β 分布： $X_1\sim BE(p,q)$;

(5) 对数正态分布： $X_1\sim LN(\mu,\sigma^2)$;

(6) Rayleigh 分布： $X_1\sim W(\lambda,2)$ 。

解. (1) $X=(X_1,\cdots,X_n)^T$ 的密度函数为

$$\begin{aligned} f(x;\theta) &= \prod_{i=1}^{n}\binom{x_i+r-1}{r-1}\theta^r(1-\theta)^{x_i} \\ &= \left(\prod_{i=1}^{n}\binom{x_i+r-1}{r-1}\right)\cdot\theta^{nr}(1-\theta)^{\sum_{i=1}^n x_i} \\ &= h(x)\cdot\theta^{nr}\ (1-\theta)^{\sum_{i=1}^n x_i}, \end{aligned}$$

其中 $h(x)=\prod_{i=1}^n\binom{x_i+r-1}{r-1}$ 。由因子分解定理知 $T=\sum_{i=1}^n X_i$ 是充分统计量。

(2) $X=(X_1,\cdots,X_n)^T$ 的密度函数为

$$f(x;m)=\frac{1}{m^n}I\{X_{(1)}\geq 1\}I\{X_{(n)}\leq m\}$$

由因子分解定理易知 $T=X_{(n)}$ 是充分统计量。

(3) $X=(X_1,\cdots,X_n)^T$ 的密度函数为

$$\begin{aligned} f(x;\lambda,p) &= \prod_{i=1}^{n}\frac{\lambda^p}{\Gamma(p)}e^{-\lambda x_i}{x_i}^{p-1}I\{x_i\geq 0\} \\ &= \frac{\lambda^{np}}{[\Gamma(p)]^n}e^{-\lambda\sum_{i=1}^n x_i}(\prod_{i=1}^n x_i)^{p-1}I\{x_{(1)}\geq 0\}, \end{aligned}$$

由因子分解定理知 $T=(\sum_{i=1}^n X_i,\ \prod_{i=1}^n X_i)$ 是充分统计量。

(4) $X=(X_1,\cdots,X_n)^T$ 的密度函数为

$$f(x;p,q)=\prod_{i=1}^n x_i^{p-1}(1-x_i)^{q-1}=(\prod_{i=1}^n x_i)^{p-1}[\prod_{i=1}^n(1-x_i)]^{q-1},$$

由因子分解定理知 $T=(\prod_{i=1}^n X_i,\ \prod_{i=1}^n(1-X_i))$ 是充分统计量。

(5) $X=(X_1,\cdots,X_n)^T$ 的密度函数为

$$\begin{aligned} f(x;\mu,\sigma^2) &= \prod_{i=1}^{n}\frac{1}{\sqrt{2\pi}\sigma x_i}\ \exp\ \{-\frac{1}{2\sigma^2}\ (\log x_i-\mu)^2\} \\ &= (\prod_{i=1}^{n}\frac{1}{\sqrt{2\pi}x_i})\cdot\sigma^{-n}\ \exp\{-\frac{1}{2\sigma^2}\sum_{i=1}^n\log^2 x_i+\frac{\mu}{\sigma^2}\sum_{i=1}^n\log x_i-\frac{n\mu}{2\sigma^2}\}, \end{aligned}$$

由因子分解定理知 $T=(\sum_{i=1}^n\log X_i,\ \sum_{i=1}^n\log^2 X_i)$ 是充分统计量。

(6) $X=(X_1,\cdots,X_n)^T$ 的密度函数为

$$f(x;\lambda)=\prod_{i=1}^n[2\lambda x_i e^{-\lambda x_i^2}\cdot I\{x_i\geq 0\}]=2^n(\prod_{i=1}^n x_i)\lambda^n e^{-\lambda\sum_{i=1}^n x_i^2}I\{x_{(1)}\geq 0\},$$

由因子分解定理知 $T=\sum_{i=1}^n {X_i}^2$ 是充分统计量。 ∎

4. 设 $X_1,\cdots,X_n$ 为 *i.i.d.* 样本， X_1 服从以下分布，求相应的极小充分统计量：

(1) $X_1\sim PR(\alpha,\theta)$ ， Pareto 分布 $\alpha\theta^\alpha x_1^{-(\alpha+1)}I\{x_1\geq\theta\}$ ；

(2) $X_1 \sim PF(\theta, c)$ ，幂函数分布 $\theta^{-c} c x_1^{c-1} I\{0 \le x_1 \le \theta\}$ ；

(3) $X_1 \sim BE(a, a)$ ， $a > 0$ ， β 分布。

解. (1) $X = (X_1, \cdots, X_n)^T$ 的密度函数为

$$\begin{aligned} f(x;\alpha,\theta) &= \prod_{i=1}^{n} [\alpha\ \theta^{\alpha}\ x_i{}^{-(\alpha+1)} I\{x_i \ge \theta\}] \\ &= \alpha^n \theta^{n\alpha} (\prod_{i=1}^{n} x_i)^{-(\alpha+1)} I\{x_{(1)} \ge \theta\}, \end{aligned}$$

由因子分解定理知 $T = (X_{(1)},\ \prod_{i=1}^{n} X_i)$ 是充分统计量。

因为似然比

$$\frac{f(x;\alpha,\theta)}{f(y;\alpha,\theta)} = \left(\frac{\prod_{i=1}^{n} x_i}{\prod_{i=1}^{n} y_i}\right)^{-(\alpha+1)} \cdot \frac{I\{x_{(1)} \ge \theta\}}{I\{y_{(1)} \ge \theta\}}$$

与 α, θ 无关等价于 $x_{(1)} = y_{(1)}$, $\prod_{i=1}^{n} x_i = \prod_{i=1}^{n} y_i$ ，所以 $T = (X_{(1)},\ \prod_{i=1}^{n} X_i)$ 是极小充分统计量。

(2) $X = (X_1, \cdots, X_n)^T$ 的密度函数为

$$\begin{aligned} f(x;\theta,c) &= \prod_{i=1}^{n} [c\theta^{-c} x_i^{c-1} I\{0 \le x_i \le \theta\}] \\ &= c^n \theta^{-nc} (\prod_{i=1}^{n} x_i)^{c-1} I\{0 \le x_{(1)} \le x_{(n)} \le \theta\}, \end{aligned}$$

由因子分解定理知 $T = (\prod_{i=1}^{n} X_i,\ X_{(n)})$ 是充分统计量。

因为似然比

$$\frac{f(x;\theta,c)}{f(y;\theta,c)} = \left(\frac{\prod_{i=1}^{n} x_i}{\prod_{i=1}^{n} y_i}\right)^{c-1} \cdot \frac{I\{0 \le x_{(1)}\} \cdot I\{x_{(n)} \le \theta\}}{I\{0 \le y_{(1)}\} \cdot I\{y_{(n)} \le \theta\}}$$

与 θ, c 无关等价于 $\prod_{i=1}^{n} x_i = \prod_{i=1}^{n} y_i$, $x_{(n)} = y_{(n)}$ ，所以 $T = (\prod_{i=1}^{n} X_i,\ X_{(n)})$ 是极小充分统计量。

(3) $X = (X_1, \cdots, X_n)^T$ 的密度函数为

$$\begin{aligned} f(x;a) &= \prod_{i=1}^{n} \frac{1}{\beta(a,a)} x_i^{a-1}\ (1-x_i)^{a-1} \\ &= [\beta(a,a)]^{-n} \cdot \left(\prod_{i=1}^{n} x_i(1-x_i)\right)^{a-1}, \end{aligned}$$

由因子分解定理知 $T(X) = \prod_{i=1}^{n} X_i(1-X_i)$ 是充分统计量。

因为似然比

$$\frac{f(x;a)}{f(y;a)} = \left(\frac{\prod_{i=1}^{n} x_i(1-x_i)}{\prod_{i=1}^{n} y_i(1-y_i)}\right)^{a-1}$$

与 a 无关等价于 $T(x) = T(y)$ ，所以 $T = \prod_{i=1}^{n} X_i(1-X_i)$ 是极小充分统计量。 ∎

5. 设 $X_1, \cdots, X_n$ 为 *i.i.d.* 样本， $X_1 \sim f(x_1;\theta) = \exp\{-(\frac{x_1-\mu}{\sigma})^4 - \xi(\theta)\}$, 其中 $\theta = (\mu, \sigma) \in \Theta = R \times (0, +\infty)$. 试证： $f(x;\theta) = \prod_{i=1}^{n} f(x_i;\theta)$ 为指数分布族，并求极小充分统计量。

证明. $X=(X_1,\cdots,X_n)^T$ 的密度函数为

$$\begin{aligned}
f(x;\theta) &= \prod_{i=1}^n f(x_i;\theta)=\exp\{-\sum_{i=1}^n(\frac{x_i-\mu}{\sigma})^4\ -n\xi(\theta)\}\\
&= \exp\left\{-\frac{1}{\sigma^4}\ \sum_{i=1}^n x_i^4+\frac{4\mu}{\sigma^4}\ \sum_{i=1}^n x_i^3-\frac{6\mu^2}{\sigma^4}\ \sum_{i=1}^n x_i^2+\frac{4\mu^3}{\sigma^4}\ \sum_{i=1}^n x_i-(\frac{n\mu^4}{\sigma^4}+n\xi(\theta))\right\}\\
&= \exp\left\{Q^T(\theta)\ T(x)-b(\theta)\right\}
\end{aligned}$$

其中 $Q(\theta)=(\frac{4\mu^3}{\sigma^4},\ -\frac{6\mu^2}{\sigma^4},\ \frac{4\mu}{\sigma^4},\ -\frac{1}{\sigma^4})^T$, $T(X)=(\sum_{i=1}^n X_i,\ \sum_{i=1}^n X_i^2,\ \sum_{i=1}^n X_i^3,\ \sum_{i=1}^n X_i^4)^T$, $b(\theta)=n\mu^4/\sigma^4+n\xi(\theta)$ 。显然 $f(x;\theta)$ 是指数族分布，由指数族分布的性质可知，$T(X)$ 是极小充分统计量。 ∎

6. 设 $X_1,\cdots,X_n$ 为 *i.i.d.* 样本， $X_1\sim N(\alpha+\beta m_i,\sigma^2)$ ，其中 $0<\sigma<+\infty$ ， $-\infty<\alpha,\beta<+\infty$ 是未知参数。 $m_i,\ i=1,\cdots,n$ 是已知常数。试求其极小充分统计量。

解. $X=(X_1,\cdots,X_n)^T$ 的密度函数为

$$\begin{aligned}
f(x;\alpha,\beta,\sigma) &= \prod_{i=1}^n\frac{1}{\sqrt{2\pi}\sigma}\ \exp\left\{-\frac{1}{2\sigma^2}\ (x_i-\alpha-\beta m_i)^2\right\}\\
&= (2\pi)^{-n/2}\cdot\sigma^{-n}\exp\{-\frac{1}{2\sigma^2}\sum_{i=1}^n x_i^2+\frac{\alpha}{\sigma^2}\sum_{i=1}^n x_i+\frac{\beta}{\sigma^2}\sum_{i=1}^n m_ix_i-\frac{n}{2\sigma^2}(\alpha+\beta m_i)^2\}
\end{aligned}$$

由因子分解定理知 $T=(\sum_{i=1}^n X_i^2,\ \sum_{i=1}^n X_i,\ \sum_{i=1}^n m_iX_i)$ 是充分统计量。

因为似然比

$$\frac{f(x;\alpha,\beta,\sigma)}{f(y;\alpha,\beta,\sigma)}=\exp\left\{\frac{1}{2\sigma^2}(\sum_{i=1}^n y_i^2-\sum_{i=1}^n x_i^2)+\frac{\alpha}{\sigma^2}(\sum_{i=1}^n x_i-\sum_{i=1}^n y_i)+\frac{\beta}{\sigma^2}(\sum_{i=1}^n m_ix_i-\sum_{i=1}^n m_iy_i)\right\}$$

与 α,β,σ 无关等价于 $T(x)=T(y)$ ，所以 $T=(\sum_{i=1}^n X_i^2,\ \sum_{i=1}^n X_i,\ \sum_{i=1}^n m_iX_i)$ 是极小充分统计量。 ∎

7. 设 $X_1,\cdots,X_n$ 为 *i.i.d.* 样本，$X_1\sim f(x_1;\theta)=h(x_1)I\{\theta_1\le x_1\le\theta_2\}\sum_{i=3}^k\exp\{\theta_iT_i(x_1)-b(\theta_i)\}$ ，其中 $-\infty<\theta_1<\theta_2<+\infty$ 。求其极小充分统计量。

解. 当 $k=3$ 时， $X=(X_1,\cdots,X_n)^T$ 的密度函数为

$$f(x;\theta)=[\prod_{j=1}^n h(x_j)]\cdot I\{\theta_1\le x_{(1)}\le x_{(n)}\le\theta_2\}\cdot\exp\{\theta_3\sum_{j=1}^n T_3(x_j)-nb(\theta_3)\}$$

由因子分解定理知 $T=(X_{(1)},X_{(n)},\sum_{j=1}^n T_3(X_j))$ 是充分统计量。

因为似然比

$$\frac{f(x;\theta)}{f(y;\theta)}=\prod_{j=1}^n\left(\frac{h(x_j)}{h(y_j)}\right)\cdot\frac{I\{\theta_1\le x_{(1)}\}\cdot I\{x_{(n)}\le\theta_2\}}{I\{\theta_1\le y_{(1)}\}\cdot I\{y_{(n)}\le\theta_2\}}\cdot\exp\left\{\theta_3\ [\sum_{j=1}^n T_3(x_j)-\sum_{j=1}^n T_3(y_j)]\right\}$$

与 θ 无关等价于 $x_{(1)}=y_{(1)},\ x_{(n)}=y_{(n)},\ \sum_{j=1}^n T_3(x_j)=\sum_{j=1}^n T_3(y_j)$ ，所以 $T=(X_{(1)},X_{(n)},\sum_{j=1}^n T_3(X_j))$ 是极小充分统计量。

当 $k>3$ 时， $X=(X_1,\cdots,X_n)^T$ 的密度函数为

$$\begin{aligned} f(x;\theta) &= [\prod_{j=1}^n h(x_j)]\cdot I\{\theta_1\le x_{(1)}\le x_{(n)}\le\theta_2\}\cdot\prod_{j=1}^n\left(\sum_{i=3}^k\exp\{\theta_i\ T_i(x_j)-b(\theta_i)\}\right)\\ &= [\prod_{j=1}^n h(x_j)]\cdot I\{\theta_1\le x_{(1)}\le x_{(n)}\le\theta_2\}\cdot\prod_{j=1}^n\left(\sum_{i=3}^k\exp\{\theta_i\ T_i(x_{(j)})-b(\theta_i)\}\right)\end{aligned}$$

由因子分解定理知 $T(X)=(X_{(1)},\cdots,X_{(n)})$ 是充分统计量。

似然比 $f(x;\theta)/f(y;\theta)$ 与 θ 无关等价于 $T(x)=T(y)$ 。事实上，必要性显然成立，下面证充分性。显然可得 $x_{(1)}=y_{(1)},\ x_{(n)}=y_{(n)}$ 。若在 $x_{(2)},\cdots,x_{(n-1)}$ 和 $y_{(2)},\cdots,y_{(n-1)}$ 中，有一个 $x_{(i)}\ne y_{(i)}$ ， $i=2,\ 3,\ \cdots,n-1$ ，则似然比与 θ_3 有关，所以必有 $x_{(i)}=y_{(i)}$ ， $i=2,\ 3,\ \cdots,n-1$ 。所以 $T(X)=(X_{(1)},\cdots,X_{(n)})$ 是极小充分统计量。

注. 如果 X_1 的密度函数为 $f(x_1;\theta)=h(x_1)I\{\theta_1\le x_1\le\theta_2\}\prod_{i=3}^k\exp\{\theta_iT_i(x_1)-b(\theta_i)\}$ ，则极小充分统计量为 $T=(X_{(1)},X_{(n)},\sum_{j=1}^nT_3(X_j),\ \cdots,\sum_{j=1}^nT_k(X_j))$ 。 ∎

8. 设 $X_1,\cdots,X_n$ 为 *i.i.d.* 样本，当 X_1 服从以下分布时，求相应的完备充分统计量。

(1) $X_1\sim f(x_1,\theta)=2x_1\theta^{-2}I\{0\le x_1\le\theta\}$ ；

(2) $X_1\sim f(x_1,\theta)=\theta x_1^{-2}I\{x_1\ge\theta\}$ ；

(3) X_1 服从 Rayleigh 分布 $f(x_1,\theta)=2\theta^{-1}x_1e^{-x_1^2/\theta}I\{x_1>0\}$ ；

(4) X_1 服从 Laplace 分 $f(x_1,\theta)=\frac{1}{2\theta}e^{-|x_1|/\theta}$ 。

解. (1) $X=(X_1,\cdots,X_n)^T$ 的密度函数为

$$\begin{aligned} f(x;\theta) &= \prod_{i=1}^n(2x_i\theta^{-2}I\{0\le x_i\le\theta\})\\ &= 2^n\prod_{i=1}^n x_i\cdot\theta^{-2n}I\{0\le x_{(1)}\}\cdot I\{x_{(n)}\le\theta\},\end{aligned}$$

由因子分解定理知 $T=X_{(n)}$ 是充分统计量。

因为 X_1 的分布函数为 $F(x_1)=\int_0^{x_1}2t\cdot\theta^{-2}\ dt=x_1^2/\theta^2$ ，所以 $T=X_{(n)}$ 的密度函数为

$$\begin{aligned} f(t;\theta) &= n\cdot\left(\frac{t^2}{\theta^2}\right)^{n-1}\cdot 2t\cdot\theta^{-2}I\{0\le t\le\theta\}\\ &= 2n\cdot\theta^{-2n}\cdot t^{2n-1}I\{0\le t\le\theta\}.\end{aligned}$$

对于任意的 $h(t)$ ，由 $\mathrm{E}_\theta[h(T)]=0\ (\forall\ \theta)$, 可得 $\int_0^\theta h(t)\cdot 2n\cdot\theta^{-2n}\cdot t^{2n-1}dt=0,\ \forall\theta$ ，即 $\int_0^\theta h(t)t^{2n-1}dt=0,\ \forall\ \theta$ 。该式两边对 θ 求导可得 $h(\theta)\theta^{2n-1}=0$ ，所以 $h(\theta)=0,\forall\ \theta>0$ ，所以 $T=X_{(n)}$ 是完备的充分统计量。

(2) $X=(X_1,\cdots,X_n)^T$ 的密度函数为

$$f(x;\theta)=\theta^n(\prod_{i=1}^n x_i)^{-2}\cdot I\{x_{(1)}\ge\theta\},$$

由因子分解定理知 $T=X_{(1)}$ 是充分统计量。

因为 X_1 的分布函数为 $F(x_1)=\int_\theta^{x_1}\theta t^{-2}dt=1-\theta/x_1$，所以 $T=X_{(1)}$ 的密度函数为

$$f(t;\theta)=n\cdot\theta t^{-2}\cdot(\frac{\theta}{t})^{n-1}I\{t\geq\theta\}=n\theta^n t^{-(n+1)}I\{t\geq\theta\}.$$

对于任意的 $h(t)$，由 $\mathrm{E}_\theta[h(T)]=\int_\theta^\infty h(t)\cdot f(t;\theta)dt=0\ (\forall\theta>0)$ 可得 $\int_\theta^\infty h(t)\cdot t^{-(n+1)}dt=0,\ \forall\theta>0$。该式两边对 θ 求导可得 $-h(\theta)\theta^{-(n+1)}=0$，所以 $h(\theta)=0,\ \forall\theta>0$，所以 $T=X_{(1)}$ 是完备的充分统计量。

(3) $X=(X_1,\cdots,X_n)^T$ 的密度函数为

$$\begin{aligned}f(x;\theta) &= \prod_{i=1}^n(2\theta^{-1}x_ie^{-x_i^2/\theta}I\{x_i>0\})\\ &= \theta^{-n}e^{-\sum_{i=1}^n x_i^2/\theta}\cdot 2^n\prod_{i=1}^n x_iI\{x_{(1)}>0\},\end{aligned}$$

由因子分解定理知 $T=\sum_{i=1}^n X_i^2$ 是充分统计量。

令 $Y_i=X_i^2,\ i=1,2,\cdots,n$，则 Y_1 的密度函数为

$$f(y_1,\theta)=\frac{2}{\theta}y_1^{\frac{1}{2}}e^{-y_1/\theta}\cdot\frac{1}{2\sqrt{y_1}}=\frac{1}{\theta}e^{-y_1/\theta}\sim\Gamma(\frac{1}{\theta},1).$$

因为 $X_1,\cdots,X_n$ 为 *i.i.d.* 样本，所以 $Y_1,\cdots,Y_n$ 为 *i.i.d.* 样本。由 Γ 分布的可加性知 $T=\sum_{i=1}^n X_i^2=\sum_{i=1}^n Y_i\sim\Gamma(\frac{1}{\theta},n)$，又由 Γ 分布族的完备性知 $T=\sum_{i=1}^n X_i^2$ 是完备的充分统计量。

(4) $X=(X_1,\cdots,X_n)^T$ 的密度函数为

$$f(x;\theta)\frac{1}{2^n}\theta^{-n}e^{-\sum_{i=1}^n|x_i|/\theta},$$

由因子分解定理知 $T=\sum_{i=1}^n|X_i|$ 是充分统计量。

令 $Y_i=|X_i|,\ i=1,2,\cdots,n$，则 Y_1 的密度函数为

$$f(y_1,\theta)=\frac{1}{\theta}e^{-y_1/\theta}\sim\Gamma(\frac{1}{\theta},1).$$

因为 $X_1,\cdots,X_n$ 为 *i.i.d.* 样本，所以 $Y_1,\cdots,Y_n$ 为 *i.i.d.* 样本,。由 Γ 分布的可加性知 $T=\sum_{i=1}^n|X_i|=\sum_{i=1}^n Y_i\sim\Gamma(\frac{1}{\theta},n)$，又由 Γ 分布族的完备性知 $T=\sum_{i=1}^n|X_i|$ 是完备的充分统计量。 ∎

9. 设 $X_1,\cdots,X_n$ 为 *i.i.d.* 样本，X_1 服从 Pareto 分布 $f(x_1;\alpha,\theta)=\alpha\theta^\alpha x_1^{-(\alpha+1)}I\{x_1\geq\theta\}$，在以下情形下，求相应的完备充分统计量：(1) θ 已知但 α 未知；(2) α 已知但 θ 未知；(3) θ 和 α 都未知。

解. (1) $X=(X_1,\cdots,X_n)^T$ 的密度函数为

$$\begin{aligned}f(x;\alpha,\theta) &= \alpha^n\theta^{n\alpha}(\prod_{i=1}^n x_i)^{-(\alpha+1)}I\{x_{(1)}\geq\theta\}\\ &= \alpha^n\exp\{\alpha(\log(\prod_{i=1}^n x_i)-n\log\theta)\}\cdot I\{x_{(1)}\geq\theta\},\end{aligned}$$

由因子分解定理知 $T=\log\ (\prod_{i=1}^n X_i)-n\ \log\theta=\sum_{i=1}^n(\log X_i-\log\theta)$ 是充分统计量。

令 $Y_i=\log X_i,\ i=1,2,\cdots,n$ ，则 $Y_1,Y_2,\cdots,Y_n$ 为 $i.i.d.$ 样本。 Y_1 的密度函数为

$$f(y_1;\alpha,\theta)=\alpha\theta^\alpha e^{-(\alpha+1)y_1}e^{y_1}I\{y_1\geq\log\ \theta\}=\alpha e^{-\alpha(y_1-\log\theta)}I\{y_1\geq\log\theta\}.$$

因此 $Y_1\sim\log\theta+\Gamma(\alpha,1)$ ，从而 $Y_1-\log\theta\sim\Gamma(\alpha,1)$ 。又因为 $Y_1,Y_2,\cdots,Y_n$ 为 $i.i.d.$ 样本，所以 $Y_1-\log\theta,\ Y_2-\log\ \theta,\ \cdots,\ Y_n-\log\ \theta$ 为 $i.i.d.$ 样本。由 Γ 分布的可加性知 $T=\sum_{i=1}^n(Y_i-\log\theta)\ \sim\ \Gamma(\alpha,n)$ ，又由 Γ 分布族的完备性知 $T=\sum_{i=1}^n(\log X_i-\log\theta)=\log\ (\prod_{i=1}^n X_i)-n\ \log\theta$ 是完备充分统计量。

(2) 记 $\mu=\log\theta$, 则 $Y_1\sim\mu+\Gamma(\alpha,1)$, 其中 μ 未知。由 (1) 中 X 的密度函数知 $T=X_{(1)}$ 是充分统计量，从而 $Y_{(1)}=\log X_{(1)}$ 也是充分统计量. 又因为 $Y_{(1)}\sim\mu+\Gamma(n\alpha,1)$ ，所以由带有位置参数的指数分布族的完备性 (见原书例 2.2.5, p.62) 知 $Y_{(1)}$ 是完备统计量，从而 $T=X_{(1)}$ 也是完备的充分统计量。

(3) 由于 $Y_1\sim\mu+\Gamma(\alpha,1)$ ，所以由原书例 2.2.9 (p.63) 知 $T=\big(Y_{(1)},\ \sum_{i=1}^n(Y_i-Y_{(1)})\big)$ 是完备的充分统计量。 ∎

10. (1) 设 $f(x;\theta)=C(\theta)\phi(x)I\{\theta_1\leq x\leq\theta_2\}$ ，其中 $\theta=(\theta_1,\theta_2)\in R^2$ 是未知参数，$C(\theta)=[\int_{\theta_1}^{\theta_2}\phi(x)dx]^{-1}<+\infty$ 为正则化因子。若 $X_1,\cdots,X_n$ 是来自 $f(x;\theta)$ 的 $i.i.d.$ 样本。求其极小充分统计量；若 θ_1 (或 θ_2) 已知，证明相应极小充分统计量的完备性。

(2) 设 $g(x;\theta)=D(\theta)\psi(x)I\{x\geq\theta\},\ \forall\ \theta\in R$ ，其中 $D(\theta)=[\int_\theta^{+\infty}\psi(x)dx]^{-1}<+\infty$ 为正则化因子。若 $X_1,\cdots,X_n$ 是来自 $g(x;\theta)$ 的 $i.i.d.$ 样本。求极小充分统计量；并证明其完备性。

解. (1) $X=(X_1,\cdots,X_n)^T$ 的密度函数为

$$\begin{aligned}f^*(x;\theta_1,\theta_2)&=\prod_{i=1}^n\{C(\theta)\cdot\phi(x_i)\cdot I\{\theta_1\leq x_i\leq\theta_2\}\}\\&=C^n(\theta)\cdot I\{\theta_1\leq x_{(1)}\leq x_{(n)}\leq\theta_2\}\cdot\prod_{i=1}^n\phi(x_i).\end{aligned}$$

由因子分解定理知 $T(X)=(X_{(1)}\ ,X_{(n)})$ 是充分统计量。

又因为似然比

$$\frac{f^*(x;\theta_1,\theta_2)}{f^*(y;\theta_1,\theta_2)}=\frac{I\{\theta_1\leq x_{(1)}\}\cdot I\{x_{(n)}\leq\theta_2\}}{I\{\theta_1\leq y_{(1)}\}\cdot I\{y_{(n)}\leq\theta_2\}}\cdot\prod_{i=1}^n\frac{\phi(x_i)}{\phi(y_i)}.$$

与参数 $\theta=(\theta_1,\theta_2)$ 无关等价于 $T(x)=T(y)$. 所以 $T=(X_{(1)}\ ,X_{(n)})$ 是极小充分统计量。

不妨设 θ_1 已知， θ_2 未知，则易知 $T=X_{(n)}$ 是极小充分统计量。此时， X_1 的分布函数为

$$F(x_1)=\int_{\theta_1}^{x_1}C(\theta)\phi(t)dt=C(\theta)\int_{\theta_1}^{x_1}\phi(t)dt.$$

其中 $\int_{\theta_1}^{x_1}\phi(t)dt$ 与 θ_2 无关。 $T=X_{(n)}$ 的密度函数为

$$\begin{aligned}f(t)&=n\ [F(t)]^{n-1}\ f(t;\theta)\ I\{\theta_1\leq t\leq\theta_2\}\\&=n\cdot C^n(\theta)\cdot\left(\int_{\theta_1}^t\phi(x)dx\right)^{n-1}\phi(t)I\{\theta_1\leq t\leq\theta_2\}.\end{aligned}$$

若 $\mathrm{E}_\theta[h(T)]=0,\ \forall\ \theta_2$ ，则有 $\int_{\theta_1}^{\theta_2} h(t)f(t)dt=0,\ \forall\ \theta_2$ ，即

$$\int_{\theta_1}^{\theta_2} h(t)\left(\int_{\theta_1}^{t}\phi(x)dx\right)^{n-1}\phi(t)dt=0,\ \forall\ \theta_2.$$

上式两边对 θ_2 求导得

$$h(\theta_2)\cdot\left(\int_{\theta_1}^{\theta_2}\phi(x)dx\right)^{n-1}\cdot\phi(\theta_2)=0,\ \forall\ \theta_2.$$

而 $\left(\int_{\theta_1}^{\theta_2}\phi(x)dx\right)^{n-1}\cdot\phi(\theta_2)\neq 0$ ，所以 $h(\theta_2)=0,\ \forall\ \theta_2$ ，因此 $T=X_{(n)}$ 是完备充分统计量。

(2) $X=(X_1,\cdots,X_n)^T$ 的密度函数为

$$g^*(x;\theta)=D^n(\theta)\cdot\prod_{i=1}^{n}\psi(x_i)\cdot I\{x_{(1)}\geq\theta\}.$$

由因子分解定理知 $T=X_{(1)}$ 是充分统计量。

又因为似然比

$$\frac{g^*(x;\theta)}{g^*(y;\theta)}=\prod_{i=1}^{n}\left(\frac{\psi(x_i)}{\psi(y_i)}\right)\cdot\frac{I\{x_{(1)}\geq\theta\}}{I\{y_{(1)}\geq\theta\}}.$$

与参数 θ 无关等价于 $x_{(1)}=y_{(1)}$ ，所以 $T=X_{(1)}$ 是极小充分统计量。

因为 X_1 的分布函数为 $F(x_1)=\int_\theta^{x_1}D(\theta)\psi(t)dt$ ，所以

$$1-F(x_1)=\int_{x_1}^{+\infty}D(\theta)\psi(t)dt=D(\theta)\int_{x_1}^{+\infty}\psi(t)dt,$$

其中 $\int_{x_1}^{+\infty}\psi(t)dt$ 与 θ 无关。 $T=X_{(1)}$ 的密度函数为

$$f(t)=n\cdot g(t;\theta)\cdot[1-F(t)]^{n-1}=n\cdot D^n(\theta)\cdot\left(\int_t^{+\infty}\psi(u)du\right)^{n-1}\psi(t).$$

若 $\mathrm{E}_\theta[h(T)]=0,\ \forall\ \theta$ ，则有 $\int_\theta^{+\infty}h(t)f(t)dt=0,\ \forall\ \theta$, 即

$$\int_\theta^{+\infty}h(t)\left(\int_t^{+\infty}\psi(u)du\right)^{n-1}\psi(t)dt=0,\ \forall\ \theta.$$

上式两边对 θ 求导得

$$-h(\theta)\cdot\left(\int_\theta^{+\infty}\psi(u)du\right)^{n-1}\cdot\psi(\theta)=0,\ \forall\ \theta.$$

而 $\left(\int_\theta^{+\infty}\psi(u)du\right)^{n-1}\cdot\psi(\theta)\neq 0$ ，所以 $h(\theta)=0,\ \forall\ \theta$ ，因此 $T=X_{(1)}$ 是完备充分统计量。 ∎

11. 证明分布族或统计量的完备性有以下性质：

(1) 若 $\mathcal{F}_X$ 完备，则 $\mathcal{F}_T$ 完备，但反之不真，其中 $\mathcal{F}_X$ 和 $\mathcal{F}_T$ 分别为 X 和 $T=T(X)$ 的分布族；

(2) 若 $T=T(X)$ 完备，则 $S(X)=\psi(T(X))$ 完备，但反之不真;

(3) 若 (S,T) 完备，则 T 完备，但反之不真。

证明. (1) 对任意的 $h(t)$ ，若有 $\mathrm{E}_\theta[h(T)]=0,\ \forall\ \theta$ ，即 $\mathrm{E}_\theta[h(T(X))]=0,\ \forall\ \theta$. 令 $\widetilde{h}(\cdot)=h(T(\cdot))$ ，则有 $\mathrm{E}_\theta[\widetilde{h}(X)]=0,\ \forall\ \theta$ 。由 X 的完备性知 $\widetilde{h}(\cdot)=0$ ，从而 $h(T(\cdot))=0$ ，即 $h(t)=0$ ，故 $T(X)$ 完备。但反之不真，例如原书例 2.2.7 (p.62) 即是。

(2) 对任意的 $h(s)$ ，若有 $\mathrm{E}_\theta[h(S(X))]=0,\ \forall\ \theta$ ，即 $\mathrm{E}_\theta[h(\psi(T(X)))]=0,\ \forall\ \theta$. 令 $\widetilde{h}(\cdot)=h(\psi(\cdot))$ ，则有 $\mathrm{E}_\theta[\widetilde{h}(T)]=0,\ \forall\ \theta$ 。由 T 的完备性知 $\widetilde{h}(\cdot)=0$ ，从而 $h(\psi(\cdot))=0$ ，即 $h(s)=0$ ，故 $S(X)$ 完备。但反之不真，例如原书例 2.2.7 (p.62) 即是。

(3) 设 $(S,\ T)$ 的联合密度函数为 $f(s,t)$,则 T 的边缘密度函数为 $g(t)=\int_{-\infty}^{+\infty}f(s,t)ds$ 。若 $\mathrm{E}[h(T)]=\int_{-\infty}^{+\infty}h(t)g(t)dt=0$ ，则有

$$\int_{-\infty}^{+\infty}\int_{-\infty}^{+\infty}h(t)f(s,t)ds\ dt=0.$$

记 $\widetilde{h}(s,t)=h(t)$ ，则由 $(S,\ T)$ 的完备性知 $\widetilde{h}(s,t)=0$ ，从而 $h(t)=0$ ，故 T 也完备。

反例：设 X_1,X_2 为 $i.i.d.$ ， $X_1\sim N(\mu,\sigma^2)$ 。 X_1 完备 (见原书例 2.2.2, p.62) ，但 (X_1,X_2) 不完备，因为若取 $h(X_1,X_2)=X_1-X_2$ ，显然有 $\mathrm{E}[h(X_1,X_2)]=0$ ，但是 $h(X_1,X_2)=X_1-X_2\neq 0$ 。 ∎

12.* 判断下列三个命题的正误，正确的请证明，错误的给出反例。

(1) 当极小充分统计量存在时，完备的充分统计量一定是极小充分统计量;

(2) 极小充分统计量一定是完备的充分统计量;

(3) 当完备的充分统计量存在时，极小充分统计量一定是完备的充分统计量 (提示：设 U 是完备充分统计量， T 是极小充分统计量，则存在一函数 $h(.)$ 使得 $T=h(U)$) 。

解. (1) 此命题正确，证明如下：

设 U 是完备充分统计量，T 是极小充分统计量，则存在一函数 $h(\cdot)$ 使得 $T=h(U)$ 。令 $\varphi(u)=u-\mathrm{E}(U|T)$ ，则 $\varphi(u)$ 是 u 的函数. 因为 $\mathrm{E}[\varphi(U)]=\mathrm{E}(U)-\mathrm{E}(U)=0$ ，所以由 U 的完备性知 $\varphi(u)=0$ ，从而 $U=\mathrm{E}(U|T)=g(T)$ ，因此 U 也是极小充分统计量。

(2) 此命题不正确。反例见原书例 2.2.11 (p.64) 。

(3) 此命题正确，证明如下：

设 S 是极小充分统计量，T 是完备充分统计量，则存在一函数 $\psi(\cdot)$ 使得 $S=\psi(T)$ 。由第 11 题的 (2) 可知， S 是完备充分统计量。 ∎

13. 证明 β 分布族 $\{BE(a,b):a>0,b>0\}$ 的完备性。

证明. 对任意的 $b=b_0>0$ 和 $\mathcal{B}_X$ 上的可测函数 $h(x)$ ，若

$$\begin{aligned}\mathrm{E}_a[h(X)] &= \int_0^1 h(x)\frac{1}{\beta(a,b_0)}x^{a-1}(1-x)^{b_0-1}dx\\ &= \int_\infty^0 h(e^{-t})\frac{-1}{\beta(a,b_0)}(1-e^{-t})^{b_0-1}e^{-at}dt\\ &= \int_0^\infty \frac{1}{\beta(a,b_0)}h(e^{-t})(1-e^{-t})^{b_0-1}e^{-at}dt=0\end{aligned}$$

其中第二个等式用到了变换 $t=-\log x$ ，则

$$\int_0^\infty h(e^{-t})(1-e^{-t})^{b_0-1}e^{-at}dt=0.$$

由 Laplace 变换的唯一性可知 $h(e^{-t})(1-e^{-t})^{b_0-1}=0,\ 0<t<\infty\ (a.e.)$ ，由此可得 $h(x)\ (1-x)^{b_0-1}=0,\ 0<x<1\ (a.e.)$ ，从而有 $h(x)=0,\ 0<x<1\ (a.e.)$ 。因此分布族 $\mathcal{F}_0=\{BE(a,b_0):\ a>0$ 任意, $b_0>0$ 已知$\}$ 完备，而 $\{BE(a,b):a>0,b>0\}$ 的参数空间包含 $\mathcal{F}_0$ 的参数空间，因此由原书 p.61 推论可知 β 分布族完备。 ∎

14. 设 $X_1,X_2,\cdots,X_n$ 为相互独立的样本， $X_j\sim N(0,\sigma^2)$ 一切 $j\neq 1,n$ ，而 $X_1\sim N(\gamma,\sigma^2)$ ，$X_n\sim N(0,\ \omega^{-1}\sigma^2)$ 。求该分布族完备的极小充分统计量, 其中 $\gamma\in R,\ \omega>0,\ \sigma^2$ 都是未知参数。

解. $X=(X_1,X_2,\cdots,X_n)^T$ 的密度函数为

$$\begin{aligned}f(x;\gamma,\omega,\sigma^2) &= \left(\frac{1}{\sqrt{2\pi}\ \sigma}\right)^n\cdot\omega^{1/2}\cdot\exp\left\{-\frac{1}{2\sigma^2}\sum_{i=2}^{n-1}x_i^2-\frac{(x_1-\gamma)^2}{2\sigma^2}-\frac{x_n^2}{2\omega^{-1}\sigma^2}\right\}\\ &= \left(\frac{1}{\sqrt{2\pi}\ \sigma}\right)^n\cdot\omega^{1/2}\cdot\exp\left\{-\frac{1}{2\sigma^2}\sum_{i=1}^{n-1}x_i^2+\frac{\gamma}{\sigma^2}x_1-\frac{\omega {x_n}^2}{2\sigma^2}-\frac{\gamma^2}{2\sigma^2}\right\},\end{aligned}$$

易见,这可看做一个指数族分布,其中 $\theta_1=-(2\sigma^2)^{-1},T_1(x)=\sum_{i=1}^{n-1}x_i^2;\ \theta_2=\gamma/\sigma^2,T_2(x)=x_1;\theta_3=-\omega(2\sigma^2)^{-1},T_3(x)={x_n}^2$ 。所以由指数族分布的性质可知 $T=(\sum_{i=1}^{n-1}X_i^2,\ X_1,\ X_n^2)$ 是完备的极小充分统计量。另外, $T^*=(\sum_{i=2}^{n-1}X_i^2,\ X_1,\ X_n^2)\triangleq(T_1^*,T_2,T_3)$ 与 T 等价, 所以它也是完备的极小充分统计量。并且有 $T_1^*=\sum_{i=2}^{n-1}X_i^2\sim\sigma^2\chi^2(n-2)$, $T_2=X_1\sim N(\gamma,\sigma^2)$ ， $T_3=X_n^2\sim\omega^{-1}\sigma^2\chi^2(1)$ ，且三者独立。 ∎

15.★ (1) 试证 Poisson 分布族 $\{P(\lambda):\lambda\in(0,+\infty)\}$ 的完备性 (提示：利用函数项级数的性质) 。

(2) 设 $X_1,\cdots,X_n$ 独立， $X_i\sim P(\alpha_i\lambda),\ \alpha_i>0\ (i=1,\cdots,n)$ 已知，求完备的极小充分统计量。

(1) 对 $\mathcal{B}_X$ 上任意的可测函数 $h(x)$,若对任意 $0<\lambda<\infty$ 有 $\mathrm{E}_\lambda[h(X)]=\sum_{x=0}^\infty h(x)e^{-\lambda}\cdot\frac{\lambda^x}{x!}=0$ ，即函数项级数 $\sum_{x=0}^\infty\frac{h(x)}{x!}\lambda^x$ 在 $\lambda\in(0,\ \infty)$ 上收敛，则 $\sum_{x=0}^\infty\frac{h(x)}{x!}\lambda^x$ 在 $(-\infty,\ \infty)$ 上绝对收敛，所以级数 $\sum_{x=0}^\infty\frac{h(x)}{x!}\lambda^x$ 的收敛半径是 $R=\infty$ ，从而级数 $\sum_{x=0}^\infty\frac{h(x)}{x!}\lambda^x$ 在 $(-\infty,\ \infty)$ 上可逐项求导。再令 $\lambda=0$ ，依次可得 $h(x)=0,\ \ x=0,1,2,\cdots$ ，所以泊松分布族完备。

(2) $X=(X_1,X_2,\cdots,X_n)^T$ 的密度函数为

$$f(x;\lambda)=\prod_{i=1}^n e^{-\alpha_i\lambda}\cdot\frac{(\alpha_i\lambda)^{x_i}}{x_i!}=e^{-\sum_{i=1}^n\alpha_i\lambda}\cdot\lambda^{\sum_{i=1}^n x_i}\cdot\frac{\prod_{i=1}^n\alpha_i^{x_i}}{\prod_{i=1}^n x_i!},$$

由因子分解定理知 $T=\sum_{i=1}^n X_i$ 是充分统计量。

因为似然比

$$\frac{f(x;\lambda)}{f(y;\lambda)}=\lambda^{\sum_{i=1}^n x_i-\sum_{i=1}^n y_i}\cdot\frac{\prod_{i=1}^n\alpha_i^{x_i}y_i!}{\prod_{i=1}^n\alpha_i^{y_i}x_i!}$$

与 λ 无关等价于 $T(x)=T(y)$ ，所以 $T=\sum_{i=1}^n X_i$ 是极小充分统计量。

又因为 $T \sim P(\lambda \sum_{i=1}^n \alpha_i)$，所以由泊松分布族的完备性即知 T 是完备的。所以 T 是完备的极小充分统计量。 ∎

16. 设 $X_1, \cdots, X_n$ 为 $i.i.d.$ 样本， $X_1 \sim N(\theta, \theta^2),\ \theta > 0$，求极小充分统计量，并判别其完备性。

解. $X = (X_1, X_2, \cdots, X_n)^T$ 的密度函数为

$$f(x;\theta) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi}\theta} e^{-\frac{(x_i-\theta)^2}{2\theta^2}} = (2\pi e)^{-\frac{n}{2}} \cdot \frac{1}{\theta^n} \exp\{-\frac{1}{2\theta^2}\sum_{i=1}^n x_i^2 + \frac{n}{\theta}\overline{x}\}$$

由因子分解定理知 $T = (\overline{X},\ \sum_{i=1}^n X_i^2)$ 是充分统计量。

因为似然比

$$\frac{f(x;\theta)}{f(y;\theta)} = \exp\{\frac{1}{2\theta^2}(\sum_{i=1}^n y_i^2 - \sum_{i=1}^n x_i^2) + \frac{n}{\theta}(\overline{x} - \overline{y})\}$$

当且仅当 $T(x) = T(y)$ 时与 θ 无关，所以 $T(X) = (\overline{X},\ \sum_{i=1}^n X_i^2)$ 是极小充分统计量。

若取 $h(T) = \frac{2n^2}{n+1}\ \overline{X}^2 - \sum_{i=1}^n X_i^2$ ，虽然有 $\mathrm{E}_\theta[h(T)] = \frac{2n^2}{n+1}(\theta^2 + \frac{\theta^2}{n}) - 2n\theta^2 = 0$，但 $h(t) \neq 0,\ (a.e.)$，所以 $T(X)$ 不具有完备性。 ∎

17.★ 设 $(X_1, Y_1), \cdots, (X_n, Y_n)$ 为 $i.i.d.$ 样本， $(X_1, Y_1) \sim N(0, 0;\ 1, 1;\ \theta)$，其中 $\theta = \mathrm{Cov}(X_1, Y_1)$， $-1 < \theta < 1$ 。

(1) 求极小充分统计量，并判别其完备性;

(2) 证明： $T_1 = \sum_{i=1}^n {X_i}^2$ 和 $T_2 = \sum_{i=1}^n {Y_i}^2$ 都是辅助统计量，但 (T_1, T_2) 不是辅助统计量。

解. (1) $(X, Y) = ((X_1, Y_1), \cdots, (X_n, Y_n))$ 的联合密度函数为

$$\begin{aligned} f(x, y;\theta) &= \prod_{i=1}^n \frac{1}{2\pi\sqrt{1-\theta^2}} \exp\{-\frac{1}{2(1-\theta^2)}(x_i^2 + y_i^2 - 2\theta x_i y_i)\} \\ &= (2\pi)^{-n} \cdot (1-\theta^2)^{-\frac{n}{2}} \cdot \exp\{-\frac{1}{2(1-\theta^2)}\sum_{i=1}^n (x_i^2 + y_i^2) + \frac{\theta}{1-\theta^2}\sum_{i=1}^n x_i y_i\}, \end{aligned}$$

由因子分解定理知 $T = (\sum_{i=1}^n (X_i^2 + Y_i^2),\ \sum_{i=1}^n X_i Y_i)$ 是充分统计量。

因为似然比

$$\frac{f(x, y;\theta)}{f(u, v;\theta)} = \exp\left\{\frac{1}{2(1-\theta)^2}(\sum_{i=1}^n (u_i^2 + v_i^2) - \sum_{i=1}^n (x_i^2 + y_i^2) + \frac{\theta}{1-\theta^2}(\sum_{i=1}^n x_i y_i - \sum_{i=1}^n u_i v_i)\right\}$$

当且仅当 $T(x, y) = T(u, v)$ 时与 θ 无关，所以 T 是极小充分统计量。

(2) T 不完备。事实上，若取 $h(T) = \sum_{i=1}^n (X_i^2 + Y_i^2) - 2n$ ，虽然有 $\mathrm{E}_\theta[h(T)] = 2n - 2n = 0$，但 $h(t) \neq 0,\ (a.e.)$，所以 T 不具有完备性。

因为 (X_1, Y_1) ， $\cdots$， (X_n, Y_n) 为 $i.i.d.$ 样本，所以 X_1 ， $\cdots$， X_n 为 $i.i.d.$ 样本，且 $X_1 \sim N(0, 1)$，所以 $T_1 = \sum_{i=1}^n X_i^2 \sim \chi^2(n)$ 与 θ 无关，从而 T_1 是辅助统计量。同理可得 T_2 也是辅助统计量。但是，因为 $(X_i,\ Y_i)$ 的分布与 θ 有关，从而 X_i 与 Y_i 不独立且与 θ 有关，所以 X_i^2 与 Y_i^2 也不独立且与 θ 有关，从而 (T_1, T_2) 的分布也与 θ 有关，所以 (T_1, T_2) 不是辅助统计量。 ∎

18. 设 $X_1,\cdots,X_n$ 为 *i.i.d.* 样本； $Y_1,\cdots,Y_m$ 为 *i.i.d.* 样本，且两总体独立。在以下情形下，求相应的完备充分统计量：

(1) $X_1\sim\mu_1+\Gamma({\sigma_1}^{-1},1)$ ， $Y_1\sim\mu_2+\Gamma({\sigma_2}^{-1},1)$ ；

(2) $X_1\sim R(0,\theta_1)$ ， $Y_1\sim R(0,\theta_2)$ ；

(3) $X_1\sim N(\mu,{\sigma_1}^2)$ ， $Y_1\sim N(\mu,{\sigma_2}^2)$ ，但 ${\sigma_1}^2/{\sigma_2}^2=\rho$ 已知。

解. (1) $(X,Y)=(X_1,\cdots,X_n,Y_1,\cdots,Y_m)^T$ 的密度函数为

$$\begin{aligned} f(x,y;\mu_1,\mu_2,\sigma_1,\sigma_2) &= \sigma_1^{-n}\exp\left\{-\frac{1}{\sigma_1}\sum_{i=1}^n x_i+\frac{n\mu_1}{\sigma_1}\right\}I\{x_{(1)}\geq\mu_1\} \\ &\quad\cdot\sigma_2^{-m}\exp\left\{-\frac{1}{\sigma_2}\sum_{j=1}^m y_j+\frac{m\mu_2}{\sigma_2}\right\}I\{y_{(1)}\geq\mu_2\}, \end{aligned}$$

由因子分解定理知 $T=(\sum_{i=1}^n X_i,\ X_{(1)},\ \sum_{j=1}^m Y_j,\ Y_{(1)})$ 是充分统计量。

因为 $T^*=(T_1,T_2,T_3,T_4)=(\sum_{i=1}^n(X_i-X_{(1)}),\ X_{(1)},\ \sum_{j=1}^m(Y_j-Y_{(1)}),\ Y_{(1)})$ 与 T 等价，所以它也是充分统计量。其中

$$T_1\sim\Gamma(\frac{1}{\sigma_1},n-1),\quad T_2\sim\mu_1+\Gamma(\frac{n}{\sigma_1},1),\quad T_3\sim\Gamma(\frac{1}{\sigma_2},m-1),\quad T_4\sim\mu_2+\Gamma(\frac{m}{\sigma_2},1).$$

且四者相互独立。利用例 2.2.9 的方法易证 T^* 完备，所以 T^* 是完备充分统计量。

(2) $(X,Y)=(X_1,\cdots,X_n,Y_1,\cdots,Y_m)^T$ 的密度函数为

$$f(x,y;\theta_1,\theta_2)=(\frac{1}{\theta_1})^n\cdot I\{x_{(n)}\leq\theta_1\}\cdot I\{x_{(1)}\geq 0\}\cdot(\frac{1}{\theta_2})^m\cdot I\{y_{(m)}\leq\theta_2\}\cdot I\{y_{(1)}\geq 0\},$$

由因子分解定理知 $T=(T_1,T_2)=(X_{(n)},\ Y_{(m)})$ 是充分统计量。

由于 $X_{(n)}/\theta_1=T_1/\theta_1\ \sim\ BE(n,1)$ 与 $Y_{(m)}/\theta_2=T_2/\theta_2\ \sim\ BE(m,1)$ 独立，所以 (T_1,T_2) 的联合分布密度函数为

$$f(t_1,t_2)=n\cdot\theta_1^{-n}\cdot t_1^{n-1}\cdot m\cdot\theta_2^{-m}\cdot t_2^{m-1}\cdot I\{0\leq t_1\leq\theta_1\}\cdot I\{0\leq t_2\leq\theta_2\}.$$

若 $\mathrm{E}_{(\theta_1,\theta_2)}[h(T_1,T_2)]=0\ \ (\forall\ \theta_1,\theta_2)$ ，则

$$\int_0^{\theta_1}\int_0^{\theta_2}h(t_1,t_2)t_1^{n-1}t_2^{m-1}\ dt_1\ dt_2=0.$$

上式两边先对 θ_1 再对 θ_2 求导，易得 $h(\theta_1,\theta_2)\theta_1^{n-1}\theta_2^{m-1}=0$ ，从而 $h(\theta_1,\theta_2)=0$ ，即 $h(t_1,t_2)=0\ (a.e.)$ 。所以 T 完备，即 T 是完备充分统计量。

(3)) $(X,Y)=(X_1,\cdots,X_n,Y_1,\cdots,Y_m)^T$ 的密度函数为

$$\begin{aligned} & f(x,y;\mu,\sigma_1^2) \\ = & (\frac{1}{\sqrt{2\pi}\sigma_1})^n\exp\{-\frac{\sum_{i=1}^n(x_i-\mu)^2}{2\sigma_1^2}\}\cdot(\frac{1}{\sqrt{2\pi}\sigma_1})^m\cdot\rho^{\frac{m}{2}}\cdot\exp\{-\frac{\rho}{2\sigma_1^2}\sum_{j=1}^m(y_j-\mu)^2\} \\ = & (\frac{1}{\sqrt{2\pi}\sigma_1})^{n+m}\cdot\rho^{\frac{m}{2}}\cdot\exp\{-\frac{1}{2\sigma_1^2}(\sum_{i=1}^n x_i^2+\rho\sum_{j=1}^m y_j^2)+\frac{\mu}{\sigma_1^2}(n\overline{x}+\rho m\overline{y})-\frac{1}{2\sigma_1^2}(m\rho\mu^2+n\mu^2)\}, \end{aligned}$$

由指数族分布的性质知 $T=(\sum_{i=1}^n X_i^2+\rho\sum_{j=1}^m Y_j^2,\ n\overline{X}+\rho m\overline{Y})$ 是完备充分统计量。 ∎

19.★ 设 $X_1,\cdots,X_n$ 为 $i.i.d.$ 样本，$X_1\sim R(0,\theta)$，若参数空间为 $\Theta=[a,+\infty)$ $(a>0)$，证明 $T=X_{(n)}$ 是极小充分统计量，但不是完备的充分统计量（提示：取 $h(t)=(\frac{1}{a^n}-\frac{(n+1)t}{na^{n+1}})I\{0\le t<a\}$，然后证 $E_\theta[h(T)]=0$）。

证明. 易证 $T=X_{(n)}$ 是极小充分统计量。但当参数空间 $\Theta=[a,+\infty)$ $(a>0)$ 时，$T=X_{(n)}$ 不完备。因为 $X_{(n)}\sim n\theta^{-n}t^{n-1}\cdot I\{0\le t\le\theta\}$，并且必须有 $\theta>a>0$，所以我们可设法取 $h(t)\ne 0$，而使之在 $(0,a)$ 上关于 T 的密度函数的积分为零：

$$h(t)=\begin{cases}\frac{1}{a^n}-\frac{(n+1)t}{na^{n+1}} & ,\quad 0\le t<a\\ 0 & ,\quad t\ge a\end{cases}$$

则有

$$\begin{aligned}\mathrm{E}_\theta[h(T)] &= \int_0^\theta h(t)\cdot n\theta^{-n}t^{n-1}dt\\ &= \int_0^a(\frac{1}{a^n}-\frac{(n+1)t}{na^{n+1}})nt^{n-1}\theta^{-n}dt+\int_a^\theta 0\cdot nt^{n-1}\theta^{-n}dt\\ &= \theta^{-n}\left[(\frac{t^n}{a^n}-\frac{t^{n+1}}{a^{n+1}})|_0^a\right]+0=0,\qquad(\forall\ a\le\theta<+\infty)\end{aligned}$$

但是由定义可知 $h(t)\ne 0$ $(a.e.\ t\ge 0)$，所以 $T=X_{(n)}$ 不完备。 ∎

20.★ 设 $X_1,\cdots,X_n$ 为 $i.i.d.$ 样本，$X_1\sim R(\theta,3\theta),-\infty<\theta<+\infty$。证明 $T=(X_{(1)},X_{(n)})$ 是极小充分统计量，但不是完备的充分统计量（提示：证明 $Z=X_{(1)}/X_{(n)}$ 的分布与 θ 无关）。

证明. $X=(X_1,X_2,\cdots,X_n)^T$ 的密度函数为

$$f(x;\theta)=\prod_{i=1}^n\frac{1}{2\theta}\ I\{\theta\le x_i\le 3\theta\}=(2\theta)^{-n}\ I\{X_{(1)}\ge\theta\}\ I\{X_{(n)}\le 3\theta\},$$

由因子分解定理知 $T=(X_{(1)},\ X_{(n)})$ 是充分统计量。

因为似然比

$$\frac{f(x;\theta)}{f(y;\theta)}=\frac{I\{x_{(1)}\ge\theta\}\cdot I\{x_{(n)}\le 3\theta\}}{I\{y_{(1)}\ge\theta\}\cdot I\{y_{(n)}\le 3\theta\}}$$

与 θ 无关等价于 $T(x)=T(y)$，所以 T 是极小充分统计量。

令 $Y_i=X_i/\theta$，则 $Y_1,\cdots,Y_n$ $i.i.d.$，且 $Y_1\ \sim\ R(1,3)$，所以 $(U,V)\triangleq(Y_{(1)},Y_{(n)})$ 的联合密度函数为

$$f(u,v)=n(n-1)(v-u)^{n-2}\cdot 2^{-n}I\{1\le u<v\le 3\}.$$

再令 $Z=U/V$，则 (Z,V) 的联合密度函数为

$$f(z,v)=n(n-1)v^{n-1}(1-z)^{n-2}\cdot 2^{-n}\ I\{\frac{1}{3}<z<1\}I\{\frac{1}{z}<v<3\}.$$

所以 Z 的边缘密度函数为

$$f(z)=\int_{\frac{1}{z}}^3 f(z,v)dv=2^{-n}(n-1)(1-z)^{n-2}(3^n-z^{-n})I\{\frac{1}{3}<z<1\}.$$

因为 $Z=Y_{(1)}/Y_{(n)}=X_{(1)}/X_{(n)}$ 的分布与 θ 无关，所以 $\mathrm{E}[Z]\triangleq m$ 是一个与 θ 无关的常数。因此若取 $h(T)=Z-m=X_{(1)}/X_{(n)}-m$ ，则 $\mathrm{E}_\theta[h(T)]=0$ 对任意的 θ 成立，但是 $h(t)\neq 0,\ (a.e.)$ ，所以 T 不是完备的充分统计量。 ∎

21. 设 $X_1,\cdots,X_n$ 为 $i.i.d.$ 样本，证明以下独立性：

(1) 若 $X_1\sim R(\theta_1,\theta_2)$ ， $-\infty<\theta_1<\theta_2<+\infty$ ，则 $(X_{(i)}-X_{(1)})/(X_{(n)}-X_{(1)})$ $i=2,\cdots,n-1$ 与 $(X_{(1)},X_{(n)})$ 独立；

(2) 若 $X_1\sim\Gamma(\lambda,\nu)$, λ,ν 在参数空间中任意,则 $T=\sum_{i=1}^n X_i$ 与 $\sum_{i=1}^n[\log X_i-\log X_{(1)}]$ 独立；

(3) 若 $X_1\sim\mu+\Gamma(\lambda,1)$, 则 $Z_i^*=\frac{X_{(n)}-X_{(i)}}{X_{(n)}-X_{(n-1)}}$, $i=1,\cdots,n-2$ 与 $(X_{(1)},\sum\limits_{i=1}^n(X_i-X_{(1)}))$ 独立。

证明. (1) 令 $Y_i=\frac{X_i-\theta_1}{\theta_2-\theta_1}$ ，则 $Y_i\sim R(0,1)$ ，从而 $Y_{(1)},\cdots,Y_{(n)}$ 是 $R(0,1)$ 上的次序统计量，由原书第一章的定理 1.6.1 (p.38) 知 $Y_{(i)}-Y_{(1)}\sim BE(i-1,n-i+2)$ ，$Y_{(n)}-Y_{(1)}\sim BE(n-1,2)$ ，因此 $(Y_{(i)}-Y_{(1)})/(Y_{(n)}-Y_{(1)})$ 的分布与 θ_1 ， θ_2 无关。而

$$\frac{Y_{(i)}-Y_{(1)}}{Y_{(n)}-Y_{(1)}}=\frac{\frac{X_{(i)}-\theta_1}{\theta_2-\theta_1}-\frac{X_{(1)}-\theta_1}{\theta_2-\theta_1}}{\frac{X_{(n)}-\theta_1}{\theta_2-\theta_1}-\frac{X_{(1)}-\theta_1}{\theta_2-\theta_1}}=\frac{X_{(i)}-X_{(1)}}{X_{(n)}-X_{(1)}},$$

所以 $[X_{(i)}-X_{(1)}]/[X_{(n)}-X_{(1)}]$ 的分布也与 θ_1,θ_2 无关，从而是辅助统计量。又已知 $(X_{(1)},\ X_{(n)})$ 是完备的充分统计量，所以由 Basu 定理知 $[X_{(i)}-X_{(1)}]/[X_{(n)}-X_{(1)}]$, $i=2,3,\cdots,n-1$ 与 $(X_{(1)},\ X_{(n)})$ 独立。

(2) 对任意的 $\nu=\nu_0$ ，由

$$f(x;\lambda,\nu_0)=\prod_{i=1}^n\frac{\lambda^{\nu_0}}{\Gamma(\nu_0)}e^{-\lambda x_i}x_i^{\nu_0-1}=(\prod_{i=1}^n x_i)^{\nu_0-1}[\Gamma(\nu_0)]^{-n}\cdot\lambda^{n\nu_0}e^{-\lambda\sum_{i=1}^n x_i}$$

可知 $T=\sum_{i=1}^n X_i$ 是充分统计量。

因为 $T=\sum_{i=1}^n X_i\sim\Gamma(\lambda,n\nu_0)$ ，所以由 Γ 分布族的完备性知 $T=\sum_{i=1}^n X_i$ 是完备的充分统计量。

又因为 $X_i\sim\Gamma(\lambda,\nu_0)$ ，所以 $2\lambda X_i\sim\Gamma(\frac{1}{2},\nu_0)=\chi^2(2\nu_0)$ 与 λ 无关。所以 $\sum\limits_{i=1}^n[\log X_i-\log X_{(1)}]=\sum\limits_{i=1}^n\log\frac{X_i}{X_{(1)}}=\sum\limits_{i=1}^n\log\frac{2\lambda X_i}{2\lambda X_{(1)}}$ 的分布与 λ 无关，从而是辅助统计量。由 Basu 定理即知 T 与 $\sum_{i=1}^n[\log X_i-\log X_{(1)}]$ 独立。

由 ν_0 的任意性即知结论对任意 (λ,ν) 成立。

(3) 令 $Y_i=X_i-\mu$, $i=1,2,\cdots,n$ ，则 $Y_i\sim\Gamma(\lambda,1)$ ；再令 $Z_i=2\lambda Y_i$, $i=1,2,\cdots,n$ ，则 $Z_i\sim\Gamma(\frac{1}{2},1)=\chi^2(2)$ 。所以 $Z_{(1)},\cdots,Z_{(n)}$ 是来自 $\chi^2(2)$ 的次序统计量，他们与参数 λ,μ 无关。

因为

$$\frac{Z_{(n)}-Z_{(i)}}{Z_{(n)}-Z_{(n-1)}}=\frac{2\lambda(X_{(n)}-\mu)-2\lambda(X_{(i)}-\mu)}{2\lambda(X_{(n)}-\mu)-2\lambda(X_{(n-1)}-\mu)}=\frac{X_{(n)}-X_{(i)}}{X_{(n)}-X_{(n-1)}}=Z_i^*,$$

所以 Z_i^*, $i=1,\cdots,n-2$ 也与参数 λ,μ 无关，从而是辅助统计量。

又因为 $(X_{(1)}, \sum\limits_{i=1}^{n}(X_i - X_{(1)}))$ 是完备的充分统计量，所以由 Basu 定理知 Z_i^*，$i = 1, 2, \cdots, n-2$ 与 $(X_{(1)}, \sum\limits_{i=1}^{n}(X_i - X_{(1)}))$ 独立。 ∎

22. 设 $X_1, \cdots, X_n$ 为 *i.i.d.* 样本， $S^2 = \sum_{i=1}^n (X_i - \overline{X})^2/(n-1)$ ， $T = \sum_{i=1}^n X_i^2$ 。证明

(1) 若 $X_1 \sim N(0, \sigma^2)$ ，则 $W(X) = n^{\frac{1}{2}}\overline{X}/S$ 与 T 独立;

(2) 若 $X_1 \sim N(\mu, \sigma^2)$ ，则 $(\overline{X}, S)$ 与 $|\overline{X} - M_e|/S$ 独立，其中 M_e 为样本中位数。

证明. (1) 当 $X_1 \sim N(0, \sigma^2)$ 时， $T = \sum_{i=1}^n X_i^2$ 是完备的极小充分统计量。由于 $\overline{X} \sim N(0, \sigma^2/n)$ ，所以 $n^{\frac{1}{2}}\overline{X}/\sigma \sim N(0,1)$ ，其分布与 σ^2 无关。又因为 S^2/σ^2 的分布也与 σ^2 无关，所以 $W(X) = n^{\frac{1}{2}}\overline{X}/S = (n^{\frac{1}{2}}\overline{X}/\sigma)/(S/\sigma)$ 的分布与 σ^2 无关，从而 $W(X)$ 是辅助统计量。所以由 Basu 定理知 $W(X)$ 与 T 独立。

(2) 当 $X_1 \sim N(\mu, \sigma^2)$ 时, $(\overline{X}, S)$ 是完备的极小充分统计量.因为 $\frac{|\overline{X}-M_e|}{\sigma} = \frac{|\overline{X}-\mu-(M_e-\mu)|}{\sigma}$ 的分布以及 S^2/σ^2 的分布都与 μ, σ^2 无关，所以 $\frac{|\overline{X}-M_e|}{S}$ 的分布也与 μ, σ^2 无关，从而为辅助统计量。所以由 Basu 定理可知 $(\overline{X}, S)$ 与 $|\overline{X} - M_e|/S$ 独立。 ∎

23. 设 $X_1, \cdots, X_n$ 为 *i.i.d.* 样本， $X_1 \sim N(\mu_1, \sigma_1^2)$ ； $Y_1, \cdots, Y_m$ 为 *i.i.d.* 样本， $Y_1 \sim N(\mu_2, \sigma_2^2)$ ，且两总体独立。记 $T = (\sum_{i=1}^n X_i^2 + \sum_{j=1}^m Y_j^2,\ \overline{X},\ \overline{Y})$ 。当 $\sigma_1 = \sigma_2$ 时，证明：

(1) $F(X,Y) = [\sum_{j=1}^m (Y_j - \overline{Y})^2/(m-1)]/[\sum_{i=1}^n (X_i - \overline{X})^2/(n-1)]$ 与 T 独立;

(2) $W(X,Y) = \frac{F(X,Y)}{F(X,Y)+\frac{n-1}{m-1}}$ 与 T 独立。

证明. (1) $X = (X_1, \cdots, X_n)^T$ 和 $Y = (Y_1, \cdots, Y_m)^T$ 的联合密度函数为

$$\begin{aligned} f(x, y; \widetilde{\theta}) &= \prod_{i=1}^{n} \frac{1}{\sqrt{2\pi}\sigma_1} e^{-\frac{1}{2\sigma_1^2}(x_i-\mu_1)^2} \cdot \prod_{j=1}^{m} \frac{1}{\sqrt{2\pi}\sigma_2} e^{-\frac{1}{2\sigma_2^2}(y_j-\mu_2)^2} \\ &= c(\widetilde{\theta}) \cdot \exp\{\theta U + \varphi T^T\}, \end{aligned}$$

其中 $\widetilde{\theta} = (\mu_1, \mu_2, {\sigma_1}^2, {\sigma_2}^2)$ ， $\theta = \frac{1}{2\sigma_1^2} - \frac{1}{2\sigma_2^2}$ ， $U = \sum_{j=1}^m Y_j^2$ ， $\varphi = (-\frac{1}{2\sigma_1^2},\ \frac{n\mu_1}{\sigma_1^2},\ \frac{n\mu_2}{\sigma_2^2})$ ，由原书定理 2.2.1 (p.64) 知：当 $\sigma_1 = \sigma_2$ 时， T 是关于 φ 的完备充分统计量，且 $F(X,Y) \sim F(m-1, n-1)$ 与 φ 无关，为辅助统计量，所以由 Basu 定理知 $F(X,Y)$ 与 T 独立。

(2) 当 $\sigma_1 = \sigma_2$ 时，因为 $F(X,Y) \sim F(m-1, n-1)$ ，所以 $W(X,Y) \sim BE(\frac{m-1}{2}, \frac{n-1}{2})$ (见原书定理 1.3.1 的推论 2, p.18) 其分布与 φ 无关，为辅助统计量，所以由 Basu 定理知 $W(X,Y)$ 与 T 独立。 ∎

24. 设 $X_1, \cdots, X_n$ 为 *i.i.d.* 样本， $X_1 \sim f(x_1; \theta) = \frac{1}{\sigma} g(\frac{x_1-\mu}{\sigma})$ (位置尺度参数族) ，其中 $g(x) > 0$ 且 $g'(x)$ 存在 $(\forall x \in R)$, $\theta = (\mu, \sigma) \in R \times (0, +\infty)$ 。证明：其 Fisher 信息阵为

$$I(\theta) = \frac{n}{\sigma^2} \begin{pmatrix} \int \frac{[g'(x)]^2}{g(x)} dx & \int x \frac{[g'(x)]^2}{g(x)} dx \\ \int x \frac{[g'(x)]^2}{g(x)} dx & \int \frac{[xg'(x)+g(x)]^2}{g(x)} dx \end{pmatrix}.$$

证明. 我们先求 X_1 的 Fisher 信息阵。 X_1 的对数似然函数及其关于 μ, σ 的一阶偏导数分别为

$$L(\theta, X_1) = \log f(x_1; \theta) = -\log\sigma + \log g(\frac{x_1 - \mu}{\sigma}),$$

$$\begin{aligned}\frac{\partial L(\theta,X_1)}{\partial\mu} &= -g'(\frac{x_1-\mu}{\sigma})/[\sigma g(\frac{x_1-\mu}{\sigma})],\\ \frac{\partial L(\theta,X_1)}{\partial\sigma} &= -\frac{1}{\sigma}-g'(\frac{x_1-\mu}{\sigma})(x_1-\mu)/[\sigma^2 g(\frac{x_1-\mu}{\sigma})].\end{aligned}$$

由此可得

$$\mathrm{E}_\theta\left[\frac{\partial L(\theta,X_1)}{\partial\mu}\right]^2=\int\frac{1}{\sigma^2}\ \frac{[g'(\frac{x_1-\mu}{\sigma})]^2}{[g(\frac{x_1-\mu}{\sigma})]^2}\cdot\frac{1}{\sigma}g(\frac{x_1-\mu}{\sigma})dx_1=\frac{1}{\sigma^2}\int\frac{[g'(t)]^2}{g(t)}dt.$$

在上面计算过程的第二步用到了变换 $t=\frac{x_1-\mu}{\sigma}$ ，而 $T=\frac{X_1-\mu}{\sigma}\sim g(t)$ 对应于 $\mu=0,\sigma=1$ 时的标准分布。同理可得

$$\begin{aligned}\mathrm{E}_\theta\left[\frac{\partial L(\theta,X_1)}{\partial\sigma}\right]^2 &= \int\left(\frac{1}{\sigma^2}+\frac{[g'(\frac{x_1-\mu}{\sigma})]^2(x_1-\mu)^2}{\sigma^4[g(\frac{x_1-\mu}{\sigma})]^2}+\frac{2(x_1-\mu)g'(\frac{x_1-\mu}{\sigma})}{\sigma^3 g(\frac{x_1-\mu}{\sigma})}\right)\frac{1}{\sigma}g(\frac{x_1-\mu}{\sigma})dx_1\\ &= \frac{1}{\sigma^2}+\frac{1}{\sigma^2}\int\frac{[g'(t)]^2}{g(t)}t^2dt+\frac{2}{\sigma^2}\int g'(t)tdt\\ &= \frac{1}{\sigma^2}\int\frac{[tg'(t)+g(t)]^2}{g(t)}\ dt,\end{aligned}$$

$$\begin{aligned}&\mathrm{E}_\theta\left[\frac{\partial L(\theta,X_1)}{\partial\mu}\cdot\frac{\partial L(\theta,X_1)}{\partial\sigma}\right]\\ =&\int\frac{1}{\sigma^2}\ \frac{g'(\frac{x_1-\mu}{\sigma})}{g(\frac{x_1-\mu}{\sigma})}\cdot\frac{1}{\sigma}\ g(\frac{x_1-\mu}{\sigma})dx_1+\int\frac{[g'(\frac{x_1-\mu}{\sigma})]^2(x_1-\mu)}{\sigma^3[g(\frac{x_1-\mu}{\sigma})]^2}\cdot\frac{1}{\sigma}g(\frac{x_1-\mu}{\sigma})dx_1\\ =&\frac{1}{\sigma^2}\int g'(t)dt+\int\frac{[g'(t)]^2t}{\sigma^2 g(t)}dt=0++\frac{1}{\sigma^2}\int\frac{t}{g(t)}[g'(t)]^2\ dt\\ =&\frac{1}{\sigma^2}\int\frac{t[g'(t)]^2}{g(t)}dt.\end{aligned}$$

其中 $\int g'(t)dt=0$ ，其原因如下：由于 Fisher 信息阵是在正则分布族中定义的，因此可在积分下求导数。对 $\sigma=1$ 有 $\int g(x-\mu)dx=1$ ，该式对 μ 求导可得 $\int g'(x-\mu)dx=0$ ，从而有 $\int g'(t)dt=0$ 。所以 X_1 的 Fisher 信息阵为

$$I_{X_1}(\theta)=\frac{1}{\sigma^2}\begin{pmatrix}\int[g'(x)]^2/g(x)\ dx & \int x[g'(x)]^2/g(x)\ dx\\ \int x[g'(x)]^2/g(x)\ dx & \int[xg'(x)+g(x)]^2/g(x)\ dx\end{pmatrix}$$

因此由 Fisher 信息阵的性质即可得到本题结论。 ∎

25. 设 $X_1,\cdots,X_n$ 为 *i.i.d.* 样本， $X_1\sim$Poisson 分布 $P(\lambda)$ 。

(1) 求样本关于参数 λ 和 λ^{-1} 的 Fisher 信息；

(2) 求 $\eta=g(\lambda)$ ，使 $I(\eta)$ 与参数无关。

解. (1) 由于 $X_i\sim e^{-\lambda}\lambda^{x_i}/x_i!$ ，因此 $X=(X_1,\cdots,X_n)^T$ 的对数似然函数及其关于 λ 的一阶和二阶导数分别为

$$\begin{aligned}L(\lambda;x) &= -n\lambda+\log\lambda\cdot\sum_{i=1}^n x_i-\sum_{i=1}^n(\log x_i!),\\ \frac{\partial L}{\partial\lambda} &= -n+\frac{1}{\lambda}\sum_{i=1}^n x_i,\quad \frac{\partial^2 L}{\partial\lambda^2}=-\frac{1}{\lambda^2}\cdot\sum_{i=1}^n x_i.\end{aligned}$$

所以样本关于参数 λ 的 Fisher 信息为

$$I(\lambda)=\mathrm{E}(-\frac{\partial^2 L}{\partial\lambda^2})=\frac{1}{\lambda^2}\cdot\mathrm{E}(\sum_{i=1}^n X_i)=\frac{n}{\lambda}.$$

因为 $\lambda=(\lambda^{-1})^{-1}=\eta^{-1}$ ，其中 $\eta=\lambda^{-1}$ ，所以样本关于参数 λ^{-1} 的 Fisher 信息为

$$I(\eta)=I(\lambda^{-1})=(-\frac{1}{\eta^2})I(\lambda)(-\frac{1}{\eta^2})=\lambda^2\cdot\frac{n}{\lambda}\cdot\lambda^2=n\lambda^3=\frac{n}{\eta^3}.$$

(2) 要使 $I(\eta)=g'(\lambda)I(\lambda)g'(\lambda)=(n/\lambda)[g'(\lambda)]^2$ 与 λ 无关，则须 $[g'(\lambda)]^2=\lambda$ ，即 $g'(\lambda)=\lambda^{1/2}$ 。所以 $g(\lambda)=\frac{2}{3}\lambda^{\frac{3}{2}}+c$ ，其中 c 是任意常数. ∎

26. 设 $X_1,X_2,\cdots,X_n$ 为相互独立的样本，在下列情形下求样本关于相应参数的 Fisher 信息阵：

(1) $X_j\sim P(\lambda)$, 一切 $j\neq i$ ，而 $X_i\sim P(\gamma\lambda)$;

(2) $X_j\sim\Gamma(1/\sigma,\ 1)$, 一切 $j\neq i$ ，而 $X_i\sim\Gamma(\gamma/\sigma,\ 1)$ 。

其中 $\gamma>0,\ \lambda>0,\ \sigma>0$ 都是未知参数。

解. (1) 由于 $X_i\sim e^{-\gamma\lambda}(\gamma\lambda)^{x_i}/x_i!$ ， $X_j\sim e^{-\lambda}\lambda^{x_j}/x_j!$ ，因此 $X=(X_1,\cdots,X_n)^T$ 的对数似然函数及其关于 $\lambda,\ \gamma$ 的一阶和二阶偏导数分别为

$$\begin{aligned}
L(\lambda,\gamma) &= -(n-1)\lambda-\gamma\lambda+\sum_{j=1}^n x_j\cdot\log\lambda+x_i\cdot\log\gamma-\sum_{j=1}^n(\log x_j!),\\
\frac{\partial L}{\partial\lambda} &= -(n-1)-\gamma+\frac{1}{\lambda}\sum_{j=1}^n x_j,\quad \frac{\partial^2 L}{\partial\lambda^2}=-\frac{1}{\lambda^2}\sum_{j=1}^n x_j,\\
\frac{\partial L}{\partial\gamma} &= -\lambda+\frac{1}{\gamma}x_i,\quad \frac{\partial^2 L}{\partial\gamma^2}=-\frac{1}{\gamma^2}x_i,\quad \frac{\partial^2 L}{\partial\lambda\partial\gamma}=-1
\end{aligned}$$

所以样本关于参数 $\theta=(\lambda,\gamma)$ 的 Fisher 信息为

$$I(\theta)=\mathrm{E}[-\ddot{l}(\lambda,\gamma)]=\begin{pmatrix}\frac{n-1+\gamma}{\lambda} & 1\\ 1 & \lambda/\gamma\end{pmatrix}.$$

(2) 由于 $X_i\sim(\gamma/\sigma)e^{-\gamma x_i/\sigma}$ ， $X_j\sim(1/\sigma)e^{-x_j/\sigma}$ ，因此 $X=(X_1,\cdots,X_n)^T$ 的对数似然函数及其关于 $\sigma,\ \gamma$ 的一阶和二阶偏导数分别为

$$\begin{aligned}
L(\sigma,\gamma) &= -n\log\sigma+\log\gamma-\frac{1}{\sigma}(\sum_{j\neq i}x_j+\gamma x_i),\\
\frac{\partial L}{\partial\sigma} &= -\frac{n}{\sigma}+\frac{1}{\sigma^2}(\sum_{j\neq i}x_j+\gamma x_i),\quad \frac{\partial^2 L}{\partial\sigma^2}=\frac{n}{\sigma^2}-\frac{2}{\sigma^3}(\sum_{j\neq i}x_j+\gamma x_i),\\
\frac{\partial L}{\partial\gamma} &= \frac{1}{\gamma}-\frac{x_i}{\sigma},\quad \frac{\partial^2 L}{\partial\gamma^2}=-\frac{1}{\gamma^2},\quad \frac{\partial^2 L}{\partial\sigma\partial\gamma}=\frac{1}{\sigma^2}x_i.
\end{aligned}$$

所以样本关于参数 $\theta=(\sigma,\gamma)$ 的 Fisher 信息为

$$I(\theta)=\mathrm{E}[-\ddot{l}(\sigma,\gamma)]=\begin{pmatrix}n/\sigma^2 & 1/\gamma\sigma\\ 1/\gamma\sigma & 1/\gamma^2\end{pmatrix}$$ ∎

27. 设 $X_1, X_2, \cdots, X_n$ 为相互独立的样本，在下列情形下求样本关于相应参数的 Fisher 信息阵：

(1) $X_j \sim N(0, \sigma^2)$, 一切 $j \neq i$ ，而 $X_i \sim N(0,\ \omega^{-1}\sigma^2)$;

(2) $X_j \sim N(0, \sigma^2)$, 一切 $j \neq i$ ，而 $X_i \sim N(\gamma,\ \sigma^2)$;

(3) $X_j \sim N(0, \sigma^2)$, 一切 $j \neq 1, n$ ，而 $X_1 \sim N(\gamma, \sigma^2)$ ； $X_n \sim N(0, \omega^{-1}\sigma^2)$ 。

其中 $\gamma \in R,\ \omega > 0,\ \sigma^2$ 都是未知参数。

解. (1)$X = (X_1, \cdots, X_n)^T$ 的对数似然函数及其关于 $\sigma^2,\ \omega$ 的一阶和二阶偏导数分别为

$$\begin{aligned}
L(\omega, \sigma^2) &= -\frac{n}{2}\log\sigma^2 + \frac{1}{2}\log\omega - \frac{1}{2\sigma^2}\sum_{j\neq i} x_j^2 - \frac{\omega}{2\sigma^2}x_i^2 - \frac{n}{2}\log(2\pi), \\
\frac{\partial L}{\partial \sigma^2} &= -\frac{n}{2}\cdot\frac{1}{\sigma^2} + \frac{1}{2\sigma^4}\sum_{j\neq i} x_j^2 + \frac{\omega}{2\sigma^4}x_i^2, \quad \frac{\partial^2 L}{\partial(\sigma^2)^2} = \frac{n}{2}\cdot\frac{1}{\sigma^4} - \frac{1}{\sigma^6}\sum_{j\neq i} x_j^2 - \frac{\omega}{\sigma^2}x_i^2, \\
\frac{\partial L}{\partial \omega} &= \frac{1}{2\omega} - \frac{1}{2\sigma^2}x_i^2, \quad \frac{\partial^2 L}{\partial \omega^2} = -\frac{1}{2\omega^2}, \quad \frac{\partial^2 L}{\partial\sigma^2\partial\omega} = \frac{1}{2\sigma^4}x_i^2
\end{aligned}$$

所以样本关于参数 $\theta = (\sigma^2, \omega)$ 的 Fisher 信息为

$$I(\theta) = \mathrm{E}[-\ddot{l}(\sigma^2, \omega)] = \begin{pmatrix} n/(2\sigma^4) & -1/(2\omega\sigma^2) \\ -1/(2\omega\sigma^2) & 1/(2\omega^2) \end{pmatrix}.$$

(2) $X = (X_1, \cdots, X_n)^T$ 的对数似然函数及其关于 $\sigma^2,\ \gamma$ 的一阶和二阶偏导数分别为

$$\begin{aligned}
L(\sigma^2, \gamma) &= -\frac{n}{2}\log\sigma^2 - \frac{1}{2\sigma^2}\sum_{j=1}^{n} x_j^2 + \frac{\gamma}{\sigma^2}x_i - \frac{\gamma^2}{2\sigma^2} - \frac{n}{2}\log(2\pi), \\
\frac{\partial L}{\partial \sigma^2} &= -\frac{n}{2}\frac{1}{\sigma^2} + \frac{1}{2\sigma^4}\sum_{j=1}^{n} x_j^2 - \frac{\gamma}{\sigma^4}x_i + \frac{\gamma^2}{2\sigma^4}, \quad \frac{\partial^2 L}{\partial(\sigma^2)^2} = \frac{n}{2}\frac{1}{\sigma^4} - \frac{1}{\sigma^6}\sum_{j=1}^{n} {x_j}^2 + \frac{2\gamma}{\sigma^6}x_i - \frac{\gamma^2}{\sigma^6}, \\
\frac{\partial L}{\partial \gamma} &= \frac{1}{\sigma^2}x_i - \frac{\gamma}{\sigma^2}, \quad \frac{\partial^2 L}{\partial \gamma^2} = -\frac{1}{\sigma^2}, \quad \frac{\partial^2 L}{\partial\sigma^2\partial\gamma} = -\frac{1}{\sigma^4}x_i + \frac{2\gamma}{2\sigma^4}
\end{aligned}$$

因为 $\mathrm{E}X_j^2 = \sigma^2,\ j \neq i$ ； $\mathrm{E}X_i^2 = \gamma^2 + \sigma^2,\ \mathrm{E}X_i = \gamma$ ，所以样本关于参数 $\theta = (\sigma^2, \gamma)$ 的 Fisher 信息为

$$I(\theta) = \mathrm{E}[-\ddot{l}(\sigma^2, \gamma)] = \begin{pmatrix} n/(2\sigma^4) & 0 \\ 0 & 1/\sigma^2 \end{pmatrix}.$$

(3) $X = (X_1, \cdots, X_n)^T$ 的对数似然函数及其关于 $\sigma^2,\ \gamma,\ \omega$ 的一阶和二阶偏导数分别为

$$\begin{aligned}
L(\sigma^2, \gamma, \omega) &= -\frac{n}{2}\log\sigma^2 + \frac{1}{2}\log\omega - \frac{n}{2}\log(2\pi) - \frac{1}{2\sigma^2}\sum_{j=2}^{n-1} x_j^2 - \frac{1}{2\sigma^2}(x_1 - \gamma)^2 - \frac{\omega}{2\sigma^2}x_n^2, \\
\frac{\partial L}{\partial \sigma^2} &= -\frac{n}{2}\frac{1}{\sigma^2} + \frac{1}{2\sigma^4}\sum_{j=2}^{n-1} x_j^2 + \frac{1}{2\sigma^4}(x_1 - \gamma)^2 + \frac{\omega}{2\sigma^4}x_n^2, \\
\frac{\partial^2 L}{\partial(\sigma^2)^2} &= \frac{n}{2}\frac{1}{\sigma^4} - \frac{1}{\sigma^6}\sum_{j=2}^{n-1} x_j^2 - \frac{1}{\sigma^6}(x_1 - \gamma)^2 - \frac{\omega}{\sigma^6}x_n^2,
\end{aligned}$$

$$
\begin{aligned}
\frac{\partial L}{\partial \gamma} &= \frac{1}{\sigma^2}(x_1-\gamma), \quad \frac{\partial^2 L}{\partial \gamma^2} = -\frac{1}{\sigma^2}, \\
\frac{\partial L}{\partial \omega} &= \frac{1}{2\omega} - \frac{x_n^2}{2\sigma^2}, \quad \frac{\partial^2 L}{\partial \omega^2} = -\frac{1}{2\omega^2}, \\
\frac{\partial^2 L}{\partial \sigma^2 \partial \gamma} &= -\frac{1}{\sigma^4}(x_1-\gamma), \quad \frac{\partial^2 L}{\partial \sigma^2 \partial \omega} = \frac{1}{2\sigma^4}x_n^2, \quad \frac{\partial^2 L}{\partial \gamma \partial \omega} = 0
\end{aligned}
$$

所以样本关于参数 $\theta = (\sigma^2, \gamma, \omega)$ 的 Fisher 信息为

$$
I(\sigma^2,\gamma,\omega) = \mathrm{E}[-\ddot{l}(\sigma^2,\gamma,\omega)] = \begin{pmatrix} \frac{n}{2\sigma^4} & 0 & -\frac{1}{2\omega\sigma^2} \\ 0 & \frac{1}{\sigma^2} & 0 \\ -\frac{1}{2\omega\sigma^2} & 0 & \frac{1}{2\omega^2} \end{pmatrix}. \qquad \blacksquare
$$

28.* 设 $X \sim f(x,\theta)$, $\theta \in \Theta$ ，假设 $\int_{-\infty}^{\infty} f(x,\theta)dx = 1$ 和 $\mathrm{E}(X) = a(\theta)$ 可在积分号下关于 θ 求导数，并记为 $\dot{a}(\theta)$ ；又记 $\mathrm{Var}(X) = \sigma^2(\theta)$ 。证明：其 Fisher 信息 $I(\theta)$ 满足不等式 $I(\theta) \geq \dot{a}^2(\theta)/\sigma^2(\theta)$ ；并且等号成立的充要条件为 X 服从指数族分布，即 $f(x,\theta) = h(x)\exp\{xQ(\theta) - b(\theta)\}$ (提示：利用 Schwarz 不等式和 score 函数 $S(\theta,x)$ 与密度函数 $f(x,\theta)$ 的关系，即 $S(\theta,x) = \partial \log f(x,\theta)/\partial\theta$) 。

证明. (1) 令 $S(\theta,x) = \partial \ln f(x;\theta)/\partial\theta = f'(x;\theta)/f(x;\theta)$ 。因为

$$
\begin{aligned}
\mathrm{E}[S(\theta,X)] &= \int_{-\infty}^{\infty} S(\theta,x)\cdot f(x;\theta)dx \\
&= \int_{-\infty}^{\infty} f'(x;\theta)\ dx = \frac{\partial}{\partial\theta}\int_{-\infty}^{\infty} f(x;\theta)dx = 0,
\end{aligned}
$$

所以

$$
\begin{aligned}
\mathrm{Cov}(X,S) &= \mathrm{E}[(X-\mathrm{E}X)(S-\mathrm{E}S)] \\
&= \mathrm{E}[(X-\mathrm{E}X)S] = \mathrm{E}[XS] \\
&= \int_{-\infty}^{\infty} x\cdot S(\theta,x)\cdot f(x;\theta)dx = \int_{-\infty}^{\infty} x\cdot f'(x;\theta)dx \\
&= \frac{\partial}{\partial\theta}\int_{-\infty}^{\infty} x\cdot f(x;\theta)\ dx = \dot{a}(\theta).
\end{aligned}
$$

由 Schwarz 不等式可得 $\mathrm{Cov}_\theta^2(X,S) \leq \mathrm{Var}_\theta(X)\ \mathrm{Var}_\theta(S)$ ，又因为 $\mathrm{Var}_\theta(S) = I(\theta)$ ，所以

$$
I(\theta) \geq \mathrm{cov}_\theta^2(X,S)\ /\ \mathrm{Var}_\theta(X) = \dot{a}^2(\theta)/\sigma^2(\theta) \tag{1}
$$

(2) 由 Schwarz 不等式可知，(1) 式等号成立的充要条件为

$$
S(\theta;X) = d(\theta)X + c(\theta)
$$

上式两边取期望得 $0 = d(\theta)\ a(\theta) + c(\theta)$ ，从而 $c(\theta) = -d(\theta)\ a(\theta)$ 。把 $c(\theta)$ 代入上式得

$$
S(\theta;X) = d(\theta)(X - a(\theta)) \tag{2}
$$

下面证明 (2) 式等价于

$$f(x;\theta) = h(x)\ \exp\{Q(\theta)\cdot x - d(\theta)\} \tag{3}$$

若 (2) 式成立，则对于任意的 $x_1 \neq x_2$ ，有 $S(\theta;x_1) - S(\theta;x_2) = d(\theta)(x_1 - x_2)$ ，由 $S(\theta;x)$ 的定义知，上式左端可关于 θ 积分，从而 $d(\theta)$ 可积。再由 (2) 知， $d(\theta)a(\theta)$ 可积，所以可对 (2) 式两边关于 θ 积分，从而得到 $\log f(x;\theta) = Q(\theta)x - d(\theta) + u(x)$ ，因此有 $f(x;\theta) = \exp\{Q(\theta)x - d(\theta)\}\cdot h(x)$ ，其中 $h(x) = e^{u(x)}$ ，由此即得 (3) 式。

反之，若 (3) 式成立，则对于任意的 $x_1 \neq x_2$ 有

$$\log f(x_1;\theta) - \log f(x_2;\theta) = Q(\theta)(x_1 - x_2) + \log h(x_1) - \log h(x_2).$$

由 $S(\theta,x)$ 定义可知，上式左边可导，因此 $Q(\theta)$ 可导，从而 $d(\theta)$ 也可导。对 $\log f(x;\theta) = Q(\theta) - d(\theta) + \log h(x)$ 关于 θ 求导得

$$S(\theta,x) = Q'(\theta)\ x - d'(\theta)$$

上式两边取期望得 $0 = Q'(\theta)\ a(\theta) - d'(\theta)$ ，从而 $d'(\theta) = Q'(\theta)\ a(\theta)$ 。再把 $d'(\theta)$ 代入上式可得 $S(\theta,x) = Q'(\theta)\ [x - a(\theta)]$ ，由此即得 (2) 式。所以综上所述， (1) 式中等号成立的充要条件为 X 服从指数族分布。 ∎

第三章　点估计基本方法

1. 设 $X_1,\cdots,X_n$ 为 *i.i.d.* 样本，当 X_1 服从以下分布时，求参数 θ 的 UMRUE ，其中 $\theta>0$ 。

(1) X_1 服从 Rayleigh 分布 $f(x_1,\theta)=2\theta^{-1}x_1e^{-x_1^2/\theta}I\{x_1>0\}$ ；

(2) $X_1\sim f(x_1,\theta)=2x_1\theta^{-2}I\{0\le x_1\le\theta\}$ ；

(3) $X_1\sim f(x_1,\theta)=\theta x_1^{-2}I\{x_1\ge\theta\}$ 。

解. (1) $T=\sum_{i=1}^n X_i^2$ 是完备的充分统计量, 且有 $X_1^2\sim\Gamma(1/\theta,1)$ 。因此 $\mathrm{E}_\theta(X_1^2)=\theta$ ，从而有 $\mathrm{E}_\theta(T/n)=\theta$ ，所以 $T^*(X)=n^{-1}\sum_{i=1}^n X_i^2$ 是 θ 的 UMRUE 。

(2) $T=X_{(n)}$ 是完备的充分统计量。因为 X_1 的分布函数为

$$F(x_1)=\int_0^{x_1}f(t;\theta)dt=\frac{x_1^2}{\theta^2}\cdot I\{0\le x_1\le\theta\},$$

所以 $T=X_{(n)}$ 的密度函数为

$$g(t;\theta)=\frac{2n}{\theta^{2n}}t^{2n-1}I\{0\le t\le\theta\}.$$

由此可得

$$E_\theta(T)=\int_0^\theta g(t;\theta)dt=\frac{2n}{2n+1}\theta,$$

所以 $E_\theta(\frac{2n+1}{2n}T)=\theta$ 。从而可知 $T^*(X)=\frac{2n+1}{2n}X_{(n)}$ 是 θ 的 UMRUE 。

(3) $T=X_{(1)}$ 是完备的充分统计量。其密度函数为

$$g(t;\theta)=n\theta^n t^{-(n+1)}I\{t\ge\theta\},$$

由此可得

$$\mathrm{E}_\theta(T)=\int_\theta^\infty n\theta^n t^{-n}dt=\frac{n}{n-1}\theta,$$

所以 $\mathrm{E}_\theta(\frac{n-1}{n}T)=\theta$ 。从而可知 $T^*(X)=\frac{n-1}{n}X_{(1)}$ 是 θ 的 UMRUE 。 ∎

2. 设 $X_1,\cdots,X_n$ 为 *i.i.d.* 样本， X_1 服从 Poisson 分布 $P(\lambda)$ ，求 λ^2 的 UMRUE 。

解. $T=\sum_{i=1}^n X_i$ 是完备的充分统计量，且 $T\sim P(n\lambda)$ 。由 $\mathrm{E}_\lambda T=n\lambda$; $\mathrm{E}_\lambda T^2=n^2\lambda^2+n\lambda$ 可得 $\mathrm{E}_\lambda[(T^2-T)/n^2]=\lambda^2$ 。所以 $T^*(X)=T(T-1)/n^2$ 是 λ^2 的 UMRUE 。 ∎

3. 设 $X_1,\cdots,X_n$ 为 *i.i.d.* 样本,

(1) $X_1\sim R(\mu-\sigma/2,\ \mu+\sigma/2)$ ，求 μ 和 σ 的 UMRUE;

(2) $X_1\sim R(\theta_1,\theta_2)$, 求 X_1 的均值 $(\theta_1+\theta_2)/2$ 的 UMRUE 。

解. (1) 记 $\theta_1=\mu-\sigma/2,\ \theta_2=\mu+\sigma/2$ ，则有 $\mu=(\theta_1+\theta_2)/2$ ， $\sigma=\theta_2-\theta_1$ ；$X_i\sim R(\theta_1,\theta_2)$ ， $i=1,2,\cdots,n$ ，并且 $T=(X_{(1)},X_{(n)})$ 为完备的充分统计量。再令 $Y_i=(X_i-\theta_1)/(\theta_2-\theta_1)$ ，则 $Y_i\sim R(0,1),\ i=1,2,\cdots,n$ ，所以

$$Y_{(1)}=\frac{X_{(1)}-\theta_1}{\theta_2-\theta_1}\sim BE(1,n),\quad Y_{(n)}=\frac{X_{(n)}-\theta_1}{\theta_2-\theta_1}\sim BE(n,1).$$

由此可得

$$\begin{aligned}\mathrm{E}(X_{(1)}) &= \theta_1+\frac{1}{n+1}(\theta_2-\theta_1)=\mu-\frac{\sigma}{2}+\frac{1}{n+1}\sigma\\ \mathrm{E}(X_{(n)}) &= \theta_1+\frac{n}{n+1}(\theta_2-\theta_1)=\mu-\frac{\sigma}{2}+\frac{n}{n+1}\sigma.\end{aligned}$$

因此有

$$\mathrm{E}(X_{(1)}+X_{(n)})=\theta_1+\theta_2=2\mu;\quad \mathrm{E}(X_{(n)}-X_{(1)})=\frac{n-1}{n+1}(\theta_2-\theta_1)=\frac{n-1}{n+1}\sigma.$$

所以 μ 和 σ 的 UMRUE 分别为

$$\hat{\mu}(X)=\frac{1}{2}(X_{(1)}+X_{(n)});\quad \hat{\sigma}(X)=\frac{n+1}{n-1}(X_{(n)}-X_{(1)}).$$

(2) 由 (1) 可得 $\mu=(\theta_1+\theta_2)/2$ 的 UMRUE 就是 $(X_{(1)}+X_{(n)})/2$ 。 ∎

4. 设 $X_1,\cdots,X_n$ 为 *i.i.d.* 样本， X_1 服从 Γ 分布 $\Gamma(\lambda,\nu)$ ， ν 为已知，求 λ, λ^{-1}, λ^2 的 UMRUE 。

解. 因为 $T=\sum_{i=1}^n X_i$ 是完备的充分统计量，且 $T\sim\Gamma(\lambda,n\nu)$ 。由 $\mathrm{E}(T)=n\nu\lambda^{-1}$ 可知 λ^{-1} 的 UMRUE 是 $T/(n\nu)$ ；又由于

$$\mathrm{E}(T^{-1})=\frac{\lambda}{n\nu-1};\quad \mathrm{E}(T^{-2})=\frac{1}{(n\nu-1)(n\nu-2)}\lambda^2.$$

所以 λ 的 UMRUE 是 $(n\nu-1)T^{-1}$ ； λ^2 的 UMRUE 是 $(n\nu-1)(n\nu-2)T^{-2}$ 。 ∎

5. 设 $X_1,\cdots,X_n$ 为 *i.i.d.* 样本， X_1 服从 Laplace 分布，即 $X_1\sim LA(0,\sigma)\sim\frac{1}{2\sigma}e^{-\frac{|x|}{\sigma}}$, 其中 $\sigma>0$ ，求 σ, σ^{-1}, σ^r 的 UMRUE 。

解. 由因子分解定理可知 $T=\sum_{i=1}^n|X_i|$ 是充分统计量。令 $Y_i=|X_i|$, $i=1,2,\cdots,n$ ，则 $Y_i\sim\Gamma(1/\sigma,1)$ ，所以 $T=\sum_{i=1}^n|X_i|=\sum_{i=1}^n Y_i\sim\Gamma(1/\sigma,n)$ 。由 Γ 分布的完备性可知 T 是完备的充分统计量。所以由 $\mathrm{E}(T)=n\sigma$ 可知 T/n 是 σ 的 UMRUE ；由 $\mathrm{E}(T^{-1})=\sigma^{-1}/(n-1)$ 可知 $(n-1)T^{-1}$ 是 σ^{-1} 的 UMRUE ；又由直接计算可知 $\mathrm{E}(T^r)=[\Gamma(n+r)/\Gamma(n)]\sigma^r$ ，因此 σ^r 的 UMRUE 为 $[\Gamma(n)/\Gamma(n+r)]T^r$ 。 ∎

6. 设 $X_1,\cdots,X_n$ 为 *i.i.d.* 样本，X_1 服从指数分布 $\mu+\Gamma(1/\sigma,1)$, 求 μ, σ, σ^2 的 UMRUE 。

解. $T=(X_{(1)},S)$ 是完备的充分统计量，其中 $S=\sum_{i=1}^n(X_i-X_{(1)})$ ，且 $X_{(1)}\sim\mu+\Gamma(n/\sigma,1)$ 与 $S\sim\Gamma(1/\sigma,n-1)$ 相互独立。由此可算得

$$\mathrm{E}(X_{(1)})=\mu+\frac{\sigma}{n},\quad \mathrm{E}(S)=(n-1)\sigma,\quad \mathrm{E}(S^2)=n(n-1)\sigma^2,$$

从而

$$\mathrm{E}(X_{(1)}-\frac{1}{n(n-1)}S)=\mu+\frac{\sigma}{n}-\frac{\sigma}{n}=\mu;\quad \mathrm{E}[S/(n-1)]=\sigma;\quad \mathrm{E}[S^2/n(n-1)]=\sigma^2.$$

所以有

$$\hat{\mu}(X)=X_{(1)}-\frac{1}{n(n-1)}S;\quad \hat{\sigma}(X)=\frac{S}{n-1};\quad \widehat{\sigma^2}(X)=\frac{S^2}{n(n-1)}.$$ ∎

7. 设 X 服从截尾二项分布，其密度函数为 $p(x,\theta)=C(\theta)\binom{n}{x}\theta^x(1-\theta)^{n-x}$，$C(\theta)=[1-(1-\theta)^n]^{-1}$，$x=1,2,\cdots,n$ 。 (1) 证明： $T=X$ 关于 θ 为完备的充分统计量； (2) 求 $\theta[1-(1-\theta)^n]^{-1}$ 的 UMVUE 。

解. (1) 因为

$$p(x,\theta)=C(\theta)\binom{n}{x}\theta^x(1-\theta)^{n-x}=\binom{n}{x}\cdot C(\theta)(1-\theta)^n\left(\frac{\theta}{1-\theta}\right)^x$$

所以由因子分解定理可知 $T=X$ 是充分统计量。

另外，若对任意的 θ 有 $\varphi(\theta)=\mathrm{E}_\theta[h(T)]=\mathrm{E}_\theta[h(X)]=0$ ，即

$$\varphi(\theta)=\sum_{x=1}^{n}h(x)\cdot C(\theta)\binom{n}{x}\theta^x(1-\theta)^{n-x}=0,$$

由此可推出

$$\sum_{x=1}^{n}h(x)\binom{n}{x}\left(\frac{\theta}{1-\theta}\right)^x=0,$$

该式为 $y=\theta/(1-\theta)$ 的 n 次多项式，它对一切的 $y>0$ 为零，则其系数必为零，即 $h(x)\binom{n}{x}=0,\ x=1,2,\cdots,n$ ，所以 $h(x)=0,\ x=1,2,\cdots,n$ 。所以 $T=X$ 是完备的充分统计量。

(2) 因为 $T=X$ 是完备的充分统计量，且

$$\begin{aligned}\mathrm{E}(X) &= \sum_{x=1}^{n}x\cdot p(x;\theta)\\ &= C(\theta)\cdot\left[\sum_{x=0}^{n}x\cdot\binom{n}{x}\theta^x(1-\theta)^{n-x}-0\cdot\binom{n}{0}\theta^0(1-\theta)^{n-0}\right]\\ &= C(\theta)\cdot n\theta=\frac{n\theta}{1-(1-\theta)^n}\ ,\end{aligned}$$

所以 $T=X/n$ 是 $\theta[1-(1-\theta)^n]^{-1}$ 的 UMVUE 。 ∎

8. 设 $X_1,\cdots,X_n$ 为 *i.i.d.* 样本， X_1 服从两点分布，即 $P(X_1=1)=\theta,\ 0<\theta<1$ 。

(1) 求 $a=\theta^m$ 的 UMRUE ，其中 $m\le n$ ， m 为正数；

(2) 求 $b=P(X_1+X_2+\cdots+X_m=k)$ 的 UMRUE ，其中 $0\le m\le n,\ 0\le k\le m$ ；

(3) 求 $c=P(X_1+X_2+\cdots+X_{n-1}>X_n)$ 的 UMRUE 。

解. (1) 取 $\tilde{a}(X)=I\{X:X_1=X_2=\cdots=X_m=1\}$ ，则由 $\mathrm{E}[\tilde{a}(X)]=P(X_1=X_2=\cdots=X_m=1)=\theta^m$ 可知 $\tilde{a}(X)$ 是 θ^m 的无偏估计。因为 $T=\sum_{i=1}^{n}X_i\sim b(n;\theta)$ 是完备的充分统计量，所以根据 Lehmann-Scheffe 定理， θ^m 的 UMRUE 可表示为

$$\begin{aligned}\hat{a}(X) &= \mathrm{E}[\tilde{a}(X)]=\mathrm{E}(I\{X:X_1=X_2=\cdots=X_m=1\}|T)\\ &= P(X_1=X_2=\cdots=X_m=1|T)\\ &= \frac{P(X_1=X_2=\cdots=X_m=1;\sum\limits_{i=m+1}^{n}X_i=T-m)}{P(\sum\limits_{i=1}^{n}X_i=T)}\\ &= \frac{\theta^m\binom{n-m}{T-m}\theta^{T-m}(1-\theta)^{n-T}}{\binom{n}{T}\theta^T(1-\theta)^{n-T}}=\frac{\binom{n-m}{T-m}}{\binom{n}{T}}.\end{aligned}$$

(2) 取 $\tilde{b}(X)=I\{X:X_1+\cdots+X_m=k\}$ ，则由 $\mathrm{E}[\tilde{b}(X)]=P(X_1+\cdots+X_m=k)$ 可知 $\tilde{b}(X)$ 是 $P(X_1+\cdots+X_m=k)$ 的无偏估计。因为 $T=\sum_{i=1}^n X_i\sim b(n;\theta)$ 是完备的充分统计量，所以 $P(X_1+\cdots+X_m=k)$ 的 UMRUE 可表示为

$$\begin{aligned}\hat{b}(X) &= \mathrm{E}[\tilde{b}(X)]=\mathrm{E}(I\{X:X_1+\cdots+X_m=k\}|T)\\ &= \frac{P(X_1+\cdots+X_m=k;\ X_{m+1}+\cdots+X_n=T-k)}{P(X_1+\cdots+X_n=T)}\\ &= \frac{\binom{m}{k}\cdot\binom{n-m}{T-k}}{\binom{n}{T}}.\end{aligned}$$

(3) 首先， c 可表示为 $c=P(X_1+\cdots+X_{n-1}>X_n)=P(T>2X_n)$ 。我们来求后一等式的概率。取 $\tilde{c}(X)=I\{X:T>2X_n\}$ ，则由 $\mathrm{E}[\tilde{c}(X)]=P(T>2X_n)$ 可知 $\tilde{c}(X)$ 是 $P(X_1+\cdots+X_{n-1}>X_n)$ 的无偏估计。因为 $T=\sum_{i=1}^n X_i\sim b(n;\theta)$ 是完备的充分统计量，所以 $P(X_1+\cdots+X_{n-1}>X_n)$ 的 UMVUE 可表示为

$$\hat{c}(X)=\mathrm{E}(I\{X:T>2X_n\}|T)=\frac{P(T>2X_n;\ X_1+\cdots+X_n=T)}{P(X_1+\cdots+X_n=T)}.$$

当 $T=0$ 时，显然有 $\hat{c}(X)=0$ ；当 $T=1,2$ 时， X_n 只能取 0 ，这时有

$$\begin{aligned}\hat{c}(X) &= \frac{P(X_1+\cdots+X_{n-1}>0,\ X_1+\cdots+X_{n-1}=T)P(X_n=0)}{P(X_1+\cdots+X_n=T)}\\ &= \frac{\binom{n-1}{T}\theta^T(1-\theta)^{n-1-T}(1-\theta)}{\binom{n}{T}\theta^T(1-\theta)^{n-T}}\\ &= \frac{\binom{n-1}{T}}{\binom{n}{T}}=\frac{n-T}{n}.\end{aligned}$$

当 $T=3,\cdots,n$ 时， X_n 可取 0 或 1 ，这时有

$$\begin{aligned}&\hat{c}(X)=\mathrm{E}(I\{X:T>2X_n\}|T)\\ =\ &\frac{1}{P(X_1+\cdots+X_n=T)}[P(X_1+\cdots+X_{n-1}>0,\ X_1+\cdots+X_{n-1}=T)P(X_n=0)\\ &+P(X_1+\cdots+X_{n-1}>1,\ X_1+\cdots+X_{n-1}=T-1)P(X_n=1)]\\ =\ &\frac{\binom{n-1}{T}+\binom{n-1}{T-1}}{\binom{n}{T}}=1.\end{aligned}$$

∎

9. 设 $X_1,\cdots,X_n$ 为 *i.i.d.* 样本， X_1 服从指数分布 $\Gamma(\lambda,1)$ ，求 $e^{-\lambda}$ 的 UMRUE 。

解. 取 $\tilde{p}(X)=I\{X:X_1>1\}$ ，则由 $\mathrm{E}[\tilde{p}(X)]=P(X_1>1)=\int_1^\infty \lambda e^{-\lambda x_1}dx_1=e^{-\lambda}$ 可知 $\tilde{p}(X)$ 是 $p=e^{-\lambda}$ 的无偏估计。因为 $T=\sum_{i=1}^n X_i\sim\Gamma(\lambda,n)$ 是完备的充分统计量，所以 $p=e^{-\lambda}$ 的 UMRUE 可表示为

$$\hat{p}(X)=\mathrm{E}(\tilde{p}(X)|T)=\mathrm{E}[I\{X:X_1>1\}|T]=P(X_1>1|T).$$

当 $T<1$ 时，显然有 $\hat{p}(X)=0$ ；当 $T\geq 1$ 时， $\hat{p}(X)=P(X_1/T>1/T|T)$ 。由 Beta 分布定理知 $X_1/T\sim BE(1,n-1)$ ，且 X_1/T 与 T 独立，所以此时

$$\hat{p}(X)=P(\frac{X_1}{T}>\frac{1}{T})=\int_{1/T}^1(n-1)(1-y)^{n-2}dy=(1-\frac{1}{T})^{n-1}.$$

所以 $p=e^{-\lambda}$ 的 UMRUE 为

$$\hat{p}(X)=\begin{cases}0, & T<1\\ (1-\frac{1}{T})^{n-1}, & T\geq 1\end{cases}=(1-\frac{1}{T})^{+(n-1)}.$$ ∎

10. 设 $X_1,\cdots,X_n$ 为 $i.i.d.$ 样本， X_1 服从几何分布，即 $P(X_1=x_1)=\theta(1-\theta)^{x_1-1}$, $0<\theta<1$ ， $x_1=1,\ 2,\ \cdots$ 。

(1) 求 θ^{-1}, θ^{-2} 的 UMRUE ；

(2) 求 θ 的 UMRUE 。

解. (1) $X=(X_1,\cdots,X_n)^T$ 的联合密度函数为

$$f(x;\theta)=\theta^n(1-\theta)^{\sum_{i=1}^n x_i-n}=\theta^n(1-\theta)^{-n}\cdot(1-\theta)^{\sum_{i=1}^n x_i}.$$

由因子分解定理知 $T=\sum_{i=1}^n X_i$ 是充分统计量。又由 Pascal 分布的可加性知 $T=\sum_{i=1}^n X_i\sim PA(n;\theta)$ 。因为 Pascal 分布是指数族分布，所以由指数族分布的性质可知 $T=\sum_{i=1}^n X_i$ 是完备的充分统计量。由

$$\mathrm{E}(T)=n\theta^{-1},\quad \mathrm{E}(T^2)=n(n+1)\theta^{-2}-n\theta^{-1}.$$

易得

$$\mathrm{E}(T/n)=\theta^{-1},\quad \mathrm{E}\left(\frac{1}{n(n+1)}(T^2+T)\right)=\theta^{-2}.$$

所以 T/n 和 $T(T+1)/[n(n+1)]$ 分别是 θ^{-1} 和 θ^{-2} 的 UMRUE 。

(2) 取 $\tilde{\theta}(X)=I\{X:X_1=1\}$ ，则由 $\mathrm{E}[\tilde{\theta}(X)]=P(X_1=1)=\theta$ 可知 $\tilde{\theta}(X)$ 是 θ 的无偏估计。因为 $T=\sum_{i=1}^n X_i$ 是完备的充分统计量，所以

$$\begin{aligned}\hat{\theta}(X) &= \mathrm{E}(\tilde{\theta}(X)|T)=P(X_1=1|T)\\ &= P(X_1=1,\ \sum_{i=2}^n X_i=T-1)/P(\sum_{i=1}^n X_i=T)\\ &= \frac{\theta\binom{T-1-1}{n-1-1}\theta^{n-1}(1-\theta)^{T-1-(n-1)}}{\binom{T-1}{n-1}\theta^n(1-\theta)^{T-n}}\\ &= \frac{n-1}{T-1}.\end{aligned}$$

因此 θ 的 UMRUE 为 $\hat{\theta}(X)=(n-1)/(T-1)$ 。 ∎

11. 设 $X_1,\cdots,X_n$ 相互独立， $X_j\sim N(0,\sigma^2)$, 一切 $j\neq 1,n$ ，而 $X_1\sim N(\gamma,\sigma^2)$ ； $X_n\sim N(0,\omega\sigma^2)$ 求参数 γ, ω, σ^2 的 UMRUE 。

解. 由第二章第 14 题可知， $T=(\sum_{i=2}^{n-1}X_i^2,X_1,X_n^2)$ 为完备的充分统计量。因为

$$T_1=\sum_{i=2}^{n-1}X_i^2\sim\sigma^2\chi^2(n-2),\ T_2=X_1\sim N(\gamma,\sigma^2),\ T_3=X_n^2\sim\omega\sigma^2\chi^2(1).$$

并且三者相互独立。所以有

$$\mathrm{E}(T_1)=(n-2)\sigma^2,\quad \mathrm{E}(T_2)=\gamma,\quad \mathrm{E}(T_3)=\omega\sigma^2.$$

由此可得

$$\mathrm{E}(T_1^{-1}) = \frac{1}{(n-4)\sigma^2}, \quad \mathrm{E}(T_1^{-1}T_3) = \frac{\omega}{n-4}.$$

所以 γ, σ^2 ω 的 UMRUE 分别为

$$\hat{\gamma}(X) = T_2 = X_1; \quad \widehat{\sigma^2}(X) = \frac{T_1}{n-2} = \frac{1}{n-2}\sum_{i=2}^{n-1} X_i^2;$$

$$\hat{\omega}(X) = (n-4)T_3/T_1 = (n-4)X_n^2/\sum_{i=2}^{n-1} X_i^2. \qquad \blacksquare$$

12. 设 $X_1, X_2, \cdots, X_n$ 相互独立, $X_j \sim \Gamma(1/\sigma, 1)$, 一切 $j \neq i$, 而 $X_i \sim \Gamma(1/\gamma\sigma,\ 1)$, $\gamma > 0$, 求 γ, σ 的 UMRUE 。

解. $X = (X_1, \cdots, X_n)^T$ 的联合密度函数为

$$\begin{aligned} f(x;\gamma,\sigma) &= (\frac{1}{\sigma})^{n-1} \cdot \exp\{-\frac{1}{\sigma}\sum_{j\neq i} x_j\} \cdot \frac{1}{\sigma\gamma} e^{-\frac{x_i}{\sigma\gamma}} \\ &= \frac{1}{\gamma\sigma^n}\exp\{-\frac{1}{\sigma}\sum_{j\neq i} x_j - x_i/(\sigma\gamma)\}. \end{aligned}$$

这是一个指数族分布，其中 $\theta_1 = -1/\sigma$, $T_1(x) = \sum_{j\neq i} x_j$, $\theta_2 = -1/(\sigma\gamma)$, $T_2(x) = x_i$ 。所以由指数族分布的性质可知 $T = (S, X_i)$ 是完备的极小充分统计量，其中 $S = \sum_{j\neq i} X_j$ 。由于 $S \sim \Gamma(1/\sigma, n-1)$ ， $X_i \sim \Gamma(1/(\sigma\gamma), 1)$ ，且二者独立， 所以由 $\mathrm{E}(S) = (n-1)\sigma$ 可知 $S/(n-1) = (n-1)^{-1}\sum_{j\neq i} X_j$ 是 σ 的 UMRUE 。又由 $\mathrm{E}(X_i) = \sigma\gamma$ 以及 $\mathrm{E}S^{-1} = \sigma^{-1}/(n-2)$ 可得 $\mathrm{E}[(n-2)X_iS^{-1}] = \gamma$ ，因此 $(n-2)X_i(\sum_{j\neq i} X_j)^{-1}$ 是 γ 的 UMRUE 。 $\blacksquare$

13.* 设 $X_1, \cdots, X_n$ 为 *i.i.d.* 样本， X_1 服从 Pareto 分布 $PR(\alpha, \theta)$ ，即 X_1 的密度函数为 $f(x_1;\alpha,\theta) = \alpha\theta^\alpha {x_1}^{-(\alpha+1)} I\{x_1 \geq \theta\}$ ，

(1) 若 θ 已知，求 α 的 UMRUE ；

(2) 若 α 已知，求 θ 的 UMRUE ；

(3) 若 α, θ 都未知，求 α 和 θ 的 UMRUE (提示：作变换 $Y_i = \log X_i$ ，$i = 1, 2, \cdots, n$ ，并利用指数分布的性质) 。

解. $X = (X_1, \cdots, X_n)^T$ 的联合密度函数为

$$f(x;\alpha,\theta) = \alpha^n\theta^{n\alpha}(\prod_{i=1}^n x_i)^{-(\alpha+1)} I\{x_{(1)} \geq \theta\}.$$

(1) 当 θ 已知时，由第二章的第 9 题可知， $T = \prod_{i=1}^n X_i$ 是完备的充分统计量。由第一章的第 23 题可知， $2\alpha(\log T - n\log\theta) \sim \chi^2(2n)$ ，所以由 $\mathrm{E}[2\alpha(\log T - n\log\theta)] = 2n$ 可知 α 的 UMVUE 为 $\hat{\alpha}(X) = n/(\log T - n\log\theta)$ 。

(2) 当 α 已知时，由第二章的第 9 题可知， $T = X_{(1)}$ 是完备的充分统计量。由第一章的第 23 题可知 $X_{(1)} \sim PR(n\alpha, \theta)$ ，即

$$T = X_{(1)} \sim n\alpha\theta^{n\alpha} t^{-(n\alpha+1)} I\{t \geq \theta\},$$

所以由 $\mathrm{E}(X_{(1)}) = n\alpha\theta/(n\alpha-1)$ ，可知 θ 的 UMVUE 为 $\hat{\theta}(X) = (n\alpha-1)X_{(1)}/(n\alpha)$ 。

(3) 当 θ, α 都未知时，做变换 $Y_i = \log X_i$ ，则有 $Y_i \sim \alpha e^{-\alpha(y_i - \log\theta)} I\{y_i \geq \log\theta\}$ ，即 $Y_i \sim \log\theta + \Gamma(\alpha, 1),\ i = 1, 2, \cdots, n$ ，由第二章的第 9 题可知从而可知 $(S_Y, Y_{(1)})$ 是完备的充分统计量，其中 $S_Y = \sum_{i=1}^n Y_i - nY_{(1)}$ 。

$$Y_{(1)} \sim \log\theta + \Gamma(n\alpha, 1),\ S_Y \sim \Gamma(\alpha, n-1).$$

且 S_Y 与 $Y_{(1)}$ 独立。因为 $X_{(1)} = e^{Y_{(1)}}$ ，所以 S_Y 与 $X_{(1)}$ 也独立。由 $\mathrm{E}(S_Y^{-1}) = \alpha/(n-2)$ 可知， α 的 UMVUE 为 $\hat{\alpha}(X) = (n-2)S_Y^{-1}$ 。因为 $\mathrm{E}(S_Y) = (n-1)/\alpha$, $\mathrm{E}(X_{(1)}) = n\alpha\theta/(n\alpha-1)$ ，利用 S_Y 与 $X_{(1)}$ 的独立性，通过直接计算可得

$$\mathrm{E}[X_{(1)}(1 - \frac{1}{n(n-1)}S_Y)] = \theta; \quad \hat{\alpha}(X) = [X_{(1)}(1 - \frac{1}{n(n-1)}S_Y)].$$ ∎

14. 设 $X_1, \cdots, X_n$ 为 *i.i.d.* 样本， $g(\cdot)$ 为 $(0, +\infty)$ 上的可微函数。

(1) $X_1 \sim \mu + \Gamma(1, 1)$ ，求 $g(\mu)$ 的 UMRUE; 并由此求 μ^{-1}, μ^{-2} 的 UMRUE ；

(2) $X_1 \sim \frac{2x_1}{\theta^2} I\{0 \leq x_1 \leq \theta\}$ ，求 $g(\theta)$ 的 UMRUE ；并由此求 θ, θ^{-1} 的 UMRUE ；

(3) $X_1 \sim \frac{\theta}{x_1^2} I\{x_1 \geq \theta\}$ ，求 $g(\theta)$ 的 UMRUE ；并由此求 θ, θ^{-1} 的 UMRUE (提示：参见例 3.2.5) 。

解. (1) $T = X_{(1)}$ 是完备的充分统计量且 $T \sim \mu + \Gamma(n, 1)$ 。若存在一函数 $h(t)$ 使得 $\mathrm{E}_\mu[h(T)] = g(\mu)\ \ (\forall\mu)$,则 $h(T)$ 就是 $g(\mu)$ 的 UMRUE 。下面, 我们由 $\mathrm{E}_\mu[h(T)] = g(\mu)\ \ (\forall\mu)$ 来求 $h(t)$ 。因为

$$\mathrm{E}_\mu[h(T)] = \int_\mu^\infty h(t) \cdot ne^{-n(t-\mu)} dt = g(\mu), \quad \forall\mu,$$

即

$$n\int_\mu^\infty h(t) \cdot e^{-nt} dt = g(\mu)e^{-n\mu}, \quad \forall\mu,$$

上式两边对 μ 求导得

$$-nh(\mu)e^{-n\mu} = g'(\mu)e^{-n\mu} - ne^{-n\mu}g(\mu).$$

因此 $h(\mu) = g(\mu) - n^{-1}g'(\mu)$ ，即 $h(t) = g(t) - n^{-1}g'(t)$ 。所以 $h(T) = g(T) - n^{-1}g'(T)$ 是 $g(\mu)$ 的 UMRUE 。

当 $g(\mu) = \mu^{-1}$ 时，易知 $h(T) = T^{-1} + n^{-1}T^{-2}$ 是 μ 的 UMRUE 。

当 $g(\mu) = \mu^{-2}$ 时，易知 $h(T) = T^{-2} + 2n^{-1}T^{-3}$ 是 μ^{-2} 的 UMRUE 。

(2) 由第二章的第 8 题可知， $T = X_{(n)}$ 是完备的充分统计量，且有

$$T \sim f(t;\theta) = \frac{2n}{\theta^{2n}} t^{2n-1} I\{0 \leq t \leq \theta\}.$$

与 (1) 类似,若存在一函数 $h(t)$ 使得 $\mathrm{E}_\theta[h(T)] = g(\theta)\ \ (\forall\theta)$,则 $h(T)$ 就是 $g(\theta)$ 的 UMRUE 。下面，我们由 $\mathrm{E}_\theta(h(T)) = g(\theta)\ \ (\forall\theta)$ 来求 $h(t)$ 。因为

$$\mathrm{E}_\theta[h(T)] = \int_0^\theta h(t)\frac{2n}{\theta^{2n}} t^{2n-1} dt = g(\theta).$$

即

$$2n\int_0^{\theta} h(t)\cdot t^{2n-1}dt = g(\theta)\theta^{2n}.$$

上式两边对 θ 求导得

$$2nh(\theta)\theta^{2n-1} = g'(\theta)\theta^{2n} + 2n\theta^{2n-1}g(\theta).$$

从而得 $h(\theta) = g(\theta) + \theta g'(\theta)/(2n)$ ，所以 $h(T) = g(T) + Tg'(T)/(2n)$ 是 $g(\theta)$ 的 UMRUE 。

当 $g(\theta) = \theta$ 时， θ 的 UMRUE 为 $h(T) = (2n+1)T/(2n)$ 。

当 $g(\theta) = \theta^{-1}$ 时， θ^{-1} 的 UMRUE 为 $h(T) = (2n-1)T^{-1}/(2n)$ 。

(3) 由第二章的第 8 题可知， $T = X_{(1)}$ 是完备的充分统计量，且有

$$T \sim f(t;\theta) = n\theta^n t^{-(n+1)} I\{t \geq \theta\}.$$

因为由 $\mathrm{E}_\theta[h(T)] = g(\theta)$ $(\forall\ \theta)$ 可得

$$\int_{\theta}^{+\infty} h(t)\cdot n\theta^n t^{-(n+1)}dt = g(\theta), \quad \forall\ \theta.$$

即

$$n\int_{\theta}^{\infty} h(t)t^{-(n+1)}dt = g(\theta)\theta^{-n}, \quad \forall\ \theta.$$

上式两边对 θ 求导得

$$-nh(\theta)\theta^{-(n+1)} = g'(\theta)\theta^{-n} - ng(\theta)\theta^{-(n+1)}.$$

从而得 $h(\theta) = g(\theta) - \theta g'(\theta)/n$ ，所以 $h(T) = g(T) - Tg'(T)/n$ 是 $g(\theta)$ 的 UMRUE 。

当 $g(\theta) = \theta$ 时， $h(T) = (n-1)T/n$ 是 θ 的 UMRUE 。

当 $g(\theta) = \theta^{-1}$ 时， $h(T) = (n+1)T^{-1}/n$ 是 θ^{-1} 的 UMRUE 。 ∎

15.★ 设 $X_1, \cdots, X_n$ 为 *i.i.d.* 样本， $X_1 \sim N(\mu, 1)$， $-\infty < \mu < \infty$ ， $\Phi(x)$ 是标准正态分布的分布函数。求 $\lambda(n)$, 使 $\Phi(\lambda(n)\bar{X})$ 为 $\Phi(\mu)$ 的 UMRUE 。并由此求 $P_\mu(X_1 < a)$ 的 UMRUE ，其中 a 为给定常数 (提示：利用第一章习题 16 的结果) 。

解. (1) $T = \bar{X}$ 是完备的充分统计量。由第一章习题 16 可知，当 $\lambda(n) = \sqrt{n/(n-1)}$ 时，$\mathrm{E}[\Phi(\lambda(n)\bar{X})] = \Phi(\mu)$, 所以当 $\lambda(n) = \sqrt{n/(n-1)}$ 时，$\Phi(\lambda(n)\bar{X})$ 是 $\Phi(\mu)$ 的 UMRUE 。

(2) 因为

$$P_\mu(X_1 < a) = P_\mu(X_1 - \mu < a - \mu) = \Phi(a - \mu).$$

令 $Y_i = (a - X_i)$; $i = 1, \cdots, n$ ，则 $Y_1, \cdots, Y_n$ 为 *i.i.d.* 样本，且 $Y_1 \sim N((a-\mu), 1)$ 。所以由 (1) 的结论有 $\mathrm{E}[\Phi(\lambda(n)\bar{Y})] = \Phi(a-\mu)$ ，因此 $P_\mu(X_1 < a) = \Phi(a-\mu)$ 的 UMRUE 为 $\Phi(\sqrt{n/(n-1)}(a - \bar{X}))$ 。 ∎

16.★ 设 $X_1, X_2, \cdots, X_n$ 为 *i.i.d.* 样本，X_1 服从幂级数分布，即 $P(X_1 = x_1) = \nu(x_1)\theta^{x_1}/c(\theta)$, $x_1 = 0, 1, 2\cdots$ ，其中 $\nu(x_1)$ 为正则化系数，是已知的， $\theta > 0$ 为未知参数。求 $\theta^r/[c(\theta)]^p$ 的 UMRUE (提示：记 $P(T = t) = \nu_n(t)\theta^t/[c(\theta)]^n$ ，其中 $T = \sum_{i=1}^n X_i$, $\nu_n(t)$ 是正则化系数，由以下方程决定 $\sum_{t=0}^{\infty} P(T = t) = 1$ 可得 $[c(\theta)]^n = \sum_{t=0}^{\infty} \nu_n(t)\theta^t$ ，利用此级数展开式) 。

解. $X_1,\cdots,X_n$ 分布密度可表示为

$$f(x,\theta)=\prod_{i=1}^{n}\nu(x_i)\exp\{\log\theta\sum_{i=1}^{n}x_i-n\log c(\theta)\}.$$

这是一个指数族分布。由指数族分布的性质可知 $T=\sum_{i=1}^{n}X_i$ 是完备的充分统计量，并且其分布可表示为

$$f(t,\theta)=P(T=t)=\nu_n(t)\theta^t[c(\theta)]^{-n},\quad t=0,1,2,\cdots.$$

其中 $\nu_n(t)$ 是正则化系数，由以下方程决定

$$\sum_{t=0}^{\infty}p(T=t)=1\Longleftrightarrow\sum_{t=0}^{\infty}\nu_n(t)\theta^t=[c(\theta)]^n,\quad \forall n=1,2,\cdots.$$

即 $\nu_n(t)$ 是 $[c(\theta)]^n$ 的展开式中 θ^t 的系数。

今设 $h(T)$ 为 $\theta^r/[c(\theta)]^p$ 的无偏估计，则 $h(T)$ 应满足以下方程

$$\mathrm{E}_\theta[h(T)]=\sum_{t=0}^{\infty}h(t)\nu_n(t)\theta^t[c(\theta)]^{-n}=[c(\theta)]^{-p}\theta^r.$$

$$\sum_{t=0}^{\infty}h(t)\nu_n(t)\theta^t=[c(\theta)]^{n-p}\theta^r.$$

由正则化系数的方程可得 $[c(\theta)]^{n-p}=\sum_{s=0}^{\infty}\nu_{n-p}(s)\theta^s$ ，该式代入上式可得

$$\sum_{t=0}^{\infty}h(t)\nu_n(t)\theta^t=\sum_{s=0}^{\infty}\nu_{n-p}(s)\theta^{s+r}=\sum_{t=r}^{\infty}\nu_{n-p}(t-r)\theta^t.$$

比较两边 θ^t 前的系数可得 $h(t)\nu_n(t)=\nu_{n-p}(t-r);\ t\geq r$ (若 $t<r$ ，则 $h(t)=0$) 。因此 $\theta^r/[c(\theta)]^p$ 的 UMRUE 为

$$h(T)=\begin{cases}0, & T<r,\\ \frac{\nu_{n-p}(T-r)}{\nu_n(T)}, & T\geq r.\end{cases}$$ ∎

17. 设 $(X_1,Y_1),\cdots,(X_n,Y_n)$ 为 *i.i.d.* 样本， (X_1,Y_1) 的分布密度为

$$f(x_1,y_1)=(\pi\gamma^2)^{-1}I\{\sqrt{x_1^2+y_1^2}\leq\gamma\},$$

其中 $(x_1,y_1)\in R^2,\ \gamma\in(0,\infty)$ 。(1) 求关于 γ 的完备的充分统计量；(2) 求 γ 的 UMRUE (提示：作变换 $x_i=r_i\cos\phi_i,\ \ y_i=r_i\sin\phi_i;\ \ i=1,2,\cdots,n$) 。

解. (1) 作变换 $\begin{cases}x_i=r_icos(\phi_i)\\ y_i=r_isin(\phi_i)\end{cases}$ ， $i=1,2,\cdots,n$ ，则该变换的 Jacobi 行列式为 $J=r_i,\ i=1,2,\cdots,n$ 。所以

$$f(r_i,\phi_i)=(\pi\gamma^2)^{-1}r_iI\{0\leq r_i\leq\gamma\},\ i=1,2,\cdots,n.$$

由此可算得 $R_i,\ i=1,2,\cdots,n$ 的边缘分布密度函数为

$$f(r_i)=\int_0^{2\pi}f(r_i,\phi_i)d\phi_i=\frac{2r_i}{\gamma^2}I\{0\leq r_i\leq\gamma\}.$$

因为 $R_i = \sqrt{X_i^2+Y_i^2}$, $i = 1,2,\cdots,n$ ，且 $(X_1,Y_1),\cdots,(X_n,Y_n)$ 为 $i.i.d.$ 样本，所以 $R_1,\cdots,R_n$ 也独立同分布。由此可得 $(R_1,\cdots,R_n)^T$ 的联合分布密度函数为

$$f(r_1,\cdots,r_n) = (\frac{2}{\gamma^2})^n \prod_{i=1}^n r_i \cdot I\{0 \le r_{(1)}\} I\{r_{(n)} \le \gamma\}.$$

所以 $R_{(n)} = \max\limits_{1\le i\le n}\{\sqrt{X_i^2+Y_i^2}\}$ 是关于参数 γ 的充分统计量。又因为

$$T = R_{(n)} \sim f(t) = 2n\frac{t^{2n-1}}{\gamma^{2n}} I\{0 \le t \le \gamma\}.$$

所以由 $\mathrm{E}[h(T)] = 0$ ，即 $\int_0^\gamma h(t)t^{2n-1}dt = 0 \ \ (\forall\gamma)$ ，可知 $h(\gamma) = 0$, $(a.e.)$ 所以 $R_{(n)}$ 关于 γ 完备，即 $R_{(n)}$ 为完备的充分统计量。

(2) 由于

$$\mathrm{E}(R_{(n)}) = \int_0^\gamma t \cdot 2n\frac{t^{2n-1}}{\gamma^{2n}}dt = \frac{2n}{2n+1}\gamma,$$

因此 γ 的 UMRUE 为

$$\hat{\gamma} = \frac{2n+1}{2n}R_{(n)} = \frac{2n+1}{2n}\max_{1\le i\le n}\{\sqrt{X_i^2+Y_i^2}\}.$$

注. 作变换以后， R_i 的分布实际上就是第 14 题 (2) 的分布。 ∎

18. 设 $X_1,X_2,\cdots,X_m$, 为 $i.i.d.$ 样本， $X_1 \sim \mu_x + \mathrm{E}(\sigma_x^{-1}) \sim {\sigma_x}^{-1}\exp\{-\frac{x_1-\mu_x}{\sigma_x}\}I\{x_1 > \mu_x\}$ ； $Y_1,\cdots,Y_n$ 为 $i.i.d.$ 样本， $Y_1 \sim \mu_y + \mathrm{E}(\sigma_y^{-1})$ ； 其中 $\sigma_x > 0$, $\sigma_y > 0$, 且 X_i, Y_j 相互独立， $i = 1,\cdots,m$, $j = 1,\cdots,n$ 。

(1) 求 $\mu_x - \mu_y$ 和 σ_x/σ_y 的 UMRUE ；

(2) 当 $\sigma_x = \sigma_y$ 时，求 σ_x 和 $(\mu_x-\mu_y)/\sigma_x$ 的 UMRUE 。

解. (1) $T = (S_x, S_y, X_{(1)}, Y_{(1)})$ 为完备的充分统计量，其中

$$S_x = \sum_{i=1}^m X_i - mX_{(1)} \sim \Gamma(\frac{1}{\sigma_x}, m-1), \quad S_y = \sum_{i=1}^n Y_i - nY_{(1)} \sim \Gamma(\frac{1}{\sigma_y}, n-1).$$

$$X_{(1)} \sim \mu_x + \Gamma(\frac{m}{\sigma_x}, 1), \quad Y_{(1)} \sim \mu_y + \Gamma(\frac{n}{\sigma_y}, 1).$$

且 $X_{(1)}, Y_{(1)}, S_x, S_y$ 相互独立。由于

$$\mathrm{E}(X_{(1)}) = \mu_x + \frac{\sigma_x}{m}, \quad \mathrm{E}(S_x) = (m-1)\sigma_x,$$

$$\mathrm{E}(Y_{(1)}) = \mu_y + \frac{\sigma_y}{n}, \quad \mathrm{E}(S_y) = (n-1)\sigma_y, \quad \mathrm{E}(S_y^{-1}) = \frac{1}{(n-2)\sigma_y}.$$

因此有

$$\mathrm{E}[(X_{(1)} - \frac{1}{m(m-1)}S_x) - (Y_{(1)} - \frac{1}{n(n-1)}S_y)] = \mu_x - \mu_y, \quad \mathrm{E}(\frac{n-2}{m-1}\frac{S_x}{S_y}) = \frac{\sigma_x}{\sigma_y}.$$

所以 $\mu_x - \mu_y$ 和 σ_x/σ_y 的 UMRUE 分别为

$$(X_{(1)} - \frac{1}{m(m-1)}S_x) - (Y_{(1)} - \frac{1}{n(n-1)}S_y) \quad 和 \quad \frac{n-2}{m-1}\frac{S_x}{S_y}.$$

(2) 当 $\sigma_x=\sigma_y$ 时，容易验证， $T=(S_x+S_y,X_{(1)},Y_{(1)})$ 为完备的充分统计量，且有 $S_x+S_y\sim\Gamma(1/\sigma_x,\ m+n-2)$ 。所以由 $\mathrm{E}(S_x+S_y)=(m+n-2)\sigma_x$ 可知 σ_x 的 UMRUE 为 $(S_x+S_y)/(m+n-2)$ 。同时有

$$\mathrm{E}(X_{(1)})=\mu_x+\frac{\sigma_x}{m},\quad \mathrm{E}(Y_{(1)})=\mu_y+\frac{\sigma_x}{n},\quad \mathrm{E}(\frac{m+n-3}{S_x+S_y})=\frac{1}{\sigma_x}.$$

由于 S_x+S_y 与 $X_{(1)},\ Y_{(1)}$ 独立，所以有

$$\mathrm{E}[(m+n-3)\frac{X_{(1)}-Y_{(1)}}{S_x+S_y}-(\frac{1}{m}-\frac{1}{n})]=\frac{\mu_x-\mu_y}{\sigma_x},$$

所以 $(\mu_x-\mu_y)/\sigma_x$ 的 UMRUE 为

$$(m+n-3)\frac{X_{(1)}-Y_{(1)}}{S_x+S_y}+\frac{m-n}{mn}.$$

∎

19. 设 $X_1,\cdots,X_m$ 为 $i.i.d.$ 样本，X_1 服从均匀分布 $R(0,\theta_x)$; $Y_1,\cdots,Y_n$ 为 $i.i.d.$ 样本，Y_1 服从均匀分布 $R(0,\theta_y)$；其中 $\theta_x>0,\ \theta_y>0$, 且 X_i,Y_j 相互独立，$i=1,\cdots,m;\ j=1,\cdots,n$ 。当 $n>1$ 时，试求 θ_x/θ_y 的 UMRUE 。

解. 由第二章习题 18 知 $T=(X_{(m)},Y_{(n)})^T$ 是关于参数 $(\theta_x,\ \theta_y)^T$ 的完备的充分统计量。因为

$$\frac{X_{(m)}}{\theta_x}\sim BE(m,1),\quad \frac{Y_{(n)}}{\theta_y}\sim BE(n,1),$$

所以

$$\mathrm{E}[\frac{X_{(m)}}{\theta_x}]=\frac{m}{m+1},\quad \mathrm{E}[(\frac{Y_{(n)}}{\theta_y})^{-1}]=\frac{n}{n-1}.$$

又因为 $X_{(m)}$ 与 $Y_{(n)}$ 独立，所以

$$\mathrm{E}(\frac{m+1}{m}\cdot\frac{n-1}{n}\cdot\frac{X_{(m)}}{Y_{(n)}})=\frac{\theta_x}{\theta_y}.$$

从而 θ_x/θ_y 的 UMRUE 为 $[(m+1)(n-1)X_{(m)}]/[mnY_{(n)}]$ 。 ∎

20. 设 $X_1,\cdots,X_m$ 为 $i.i.d.$ 样本， $X_1\sim N(\mu_x,\sigma_x^2)$; $Y_1,\cdots,Y_n$ 为 $i.i.d.$ 样本， $Y_1\sim N(\mu_y,\sigma_y^2)$ ，且 X_i 与 Y_j 独立， $i=1,2,\cdots,m,j=1,2,\cdots,n$ 。假设 $\mu_x\in R,\ \mu_y\in R,\ \sigma_x^2>0,\ \sigma_y^2>0$ ；并记 $a=\mu_x-\mu_y,\ \rho=\sigma_x/\sigma_y$ 。

(1) 求 $a,\ \rho^2$, 以及 $\rho,\ \rho^r$ 的 UMRUE, 其中 $r>0$ ；

(2) 设 $\sigma_x^2=\sigma_y^2$ ，求 σ_x^2 和 $(\mu_x-\mu_y)/\sigma_x$ 的 UMRUE ；

(3) 设 $\mu_x=\mu_y$ ，且 ρ 已知，求 μ_x 和 σ_x^2 的 UMRUE 。

解. $(X,Y)^T=(X_1,\cdots,X_m,\ Y_1,\cdots,Y_n)^T$ 的联合分布密度函数为

$$\begin{aligned}
&f(x_1,\cdots,x_m,y_1,\cdots,y_n;\mu_x,\sigma_x^2,\mu_y,\sigma_y^2)\\
=\ &(\prod_{i=1}^m\frac{1}{\sqrt{2\pi}\sigma_x}\exp\{-\frac{(x_i-\mu_x)^2}{2\sigma_x^2}\})\cdot(\prod_{j=1}^n\frac{1}{\sqrt{2\pi}\sigma_y}\exp\{-\frac{(y_i-\mu_y)^2}{2\sigma_y^2}\})\\
=\ &(\frac{1}{2\pi})^{\frac{m+n}{2}}\sigma_x^{-m}\sigma_y^{-n}\exp\{-\frac{1}{2\sigma_x^2}[\sum_{i=1}^m x_i^2-2m\bar{x}\mu_x+m\mu_x^2]-\frac{1}{2\sigma_y^2}[\sum_{j=1}^n y_j^2-2n\bar{y}\mu_y+n\mu_y^2]\}
\end{aligned}$$

(1) 显然 $f(x,y)$ 是指数族分布，所以 $T=(\sum_{i=1}^m X_i^2,\ \sum_{j=1}^n Y_j^2,\ \bar{X},\ \bar{Y})$ 是完备的充分统计量。从而由 $\mathrm{E}(\bar{X}-\bar{Y})=\mu_x-\mu_y$ 可知 $a=\mu_x-\mu_y$ 的 UMRUE 为 $\bar{X}-\bar{Y}$ 。令 $S_x^2=(m-1)^{-1}\sum_{i=1}^m(X_i-\bar{X})^2,\ \ S_y^2=(n-1)^{-1}\sum_{j=1}^n(Y_j-\bar{Y})^2$ ，则

$$(m-1)S_x^2/\sigma_x^2\sim\chi^2(m-1),\ \ (n-1)S_y^2/\sigma_y^2\sim\chi^2(n-1).$$

所以

$$\begin{aligned}\mathrm{E}\left[\frac{(m-1)S_x^2}{\sigma_x^2}\right]^{r/2} &= \int_0^\infty x^{r/2}\frac{2^{-(m-1)/2}}{\Gamma[(m-1)/2]}e^{-x/2}x^{\frac{m-1}{2}-1}dx\\ &= 2^{r/2}\frac{\Gamma(\frac{m+r-1}{2})}{\Gamma(\frac{m-1}{2})}\triangleq A_{m-1,r},\\ \mathrm{E}\left[\frac{(n-1)S_y^2}{\sigma_y^2}\right]^{-r/2} &= 2^{-r/2}\frac{\Gamma(\frac{n-r-1}{2})}{\Gamma(\frac{n-1}{2})}\triangleq A_{n-1,-r}.\end{aligned}$$

又因为 S_x^2 与 S_y^2 独立，所以

$$\frac{1}{A_{m-1,r}\cdot A_{n-1,-r}}\mathrm{E}[(\frac{(m-1)S_x^2}{(n-1)S_y^2})^{r/2}]=(\frac{\sigma_x}{\sigma_y})^r=\rho^r.$$

所以 ρ^r 的 UMRUE 为 $[(m-1)/(n-1)\ S_x^2/S_y^2]^{r/2}[A_{m-1,r}\cdot A_{n-1,-r}]^{-1}$ ；特别，$\rho^2={\sigma_x}^2/{\sigma_y}^2$ 的 UMRUE 为 $[(n-3)/(n-1)][S_x^2/S_y^2]$ 。

(2) 当 $\sigma_x^2=\sigma_y^2$ 时， $T=(\sum_{i=1}^m X_i^2+\sum_{j=1}^n Y_j^2,\ \bar{X},\ \bar{Y})$ 为完备的充分统计量。令

$$S^2=\sum_{i=1}^m(X_i-\bar{X})^2+\sum_{j=1}^n(Y_j-\bar{Y})^2,$$

则

$$S^2=(\sum_{i=1}^m X_i^2+\sum_{j=1}^n Y_j^2)-m\bar{X}^2-n\bar{Y}^2.$$

是 T 的函数。因为 $S^2/\sigma_x^2\sim\chi^2(m+n-2)$ ，所以 $\mathrm{E}[S^2/(m+n-2)]=\sigma_x^2$ ，从而 σ_x^2 的 UMVUE 为 $S^2/(m+n-2)$ 。同时由 (1) 的公式可得

$$\mathrm{E}(\frac{S^2}{\sigma_x^2})^{-\frac{1}{2}}=(\frac{1}{2})^{\frac{1}{2}}\frac{\Gamma(\frac{m+n-3}{2})}{\Gamma(\frac{m+n-2}{2})}.$$

又因为 $\bar{X}-\bar{Y}$ 与 S^2 独立，所以有

$$\mathrm{E}[\sqrt{2}\Gamma(\frac{m+n-2}{2})[\Gamma(\frac{m+n-3}{2})]^{-1}(\bar{X}-\bar{Y})(S^2)^{\frac{1}{2}}]=\frac{\mu_x-\mu_y}{\sigma_x}.$$

所以 $\frac{\mu_x-\mu_y}{\sigma_x}$ 的 UMRUE 是 $\sqrt{2}\Gamma(\frac{m+n-2}{2})[\Gamma(\frac{m+n-3}{2})]^{-1}(\bar{X}-\bar{Y})S$ 。

(3) 这时， $(X_1,\cdots,X_m,\ Y_1,\cdots,Y_n)^T$ 的联合分布密度函数为

$$\begin{aligned}&f(x_1,\cdots,x_m,y_1,\cdots,y_n;\mu_x,\sigma_x^2)\\ =\ &(\frac{1}{\sqrt{2\pi}\sigma_x})^m\exp\{-\frac{1}{2\sigma_x^2}\sum_{i=1}^m(x_i-\mu_x)^2\}\cdot(\frac{1}{\sqrt{2\pi}\sigma_x})^n\rho^n\exp\{-\frac{\rho^2}{2\sigma_x^2}\sum_{j=1}^n(y_j-\mu_x)^2\}\\ =\ &(\frac{1}{\sqrt{2\pi}\sigma_x})^{m+n}\rho^n\exp\{-\frac{1}{2\sigma_x^2}(\sum_{i=1}^m x_i^2+\rho^2\sum_{j=1}^n y_j^2)+\frac{\mu_x}{\sigma_x^2}(m\bar{x}+n\rho^2\bar{y})-\frac{1}{2\sigma_x^2}(m\mu_x^2+n\rho^2\mu_x^2)\}\end{aligned}$$

由指数分布族的性质易可知，完备的充分统计量为

$$T=(T_1,T_2)=(\sum_{i=1}^{m}X_i^2+\rho^2\sum_{j=1}^{n}Y_j^2,\ m\bar{X}+n\rho^2\bar{Y}).$$

所以由 $\mathrm{E}(m\bar{X}+n\rho^2\bar{Y})=(m+n\rho^2)\mu_x$ 可知，μ_x 的 UMRUE 为 $(m\bar{X}+n\rho^2\bar{Y})/(m+n\rho^2)$ 。由于

$$\bar{X}\sim N(\mu_x,\sigma_x^2/m),\quad \bar{Y}\sim N(\mu_x,\sigma_y^2/n)$$

因此有

$$m\bar{X}\sim N(m\mu_x,m\sigma_x^2),\quad n\rho^2\bar{Y}\sim N(n\rho^2\mu_x,n\rho^2\sigma_x^2),$$

又因为 $\bar{X}$ 与 $\bar{Y}$ 独立，所以

$$m\bar{X}+n\rho^2\bar{Y}\sim N((m+n\rho^2)\mu_x,\ (m+n\rho^2)\sigma_x^2).$$

令

$$T^*=\sum_{i=1}^{m}X_i^2+\rho^2\sum_{j=1}^{n}Y_j^2-\frac{1}{m+n\rho^2}(m\bar{X}+n\rho^2\bar{Y})^2,$$

则由

$$\begin{aligned}\mathrm{E}[\sum_{i=1}^{m}X_i^2+\rho^2\sum_{j=1}^{n}Y_j^2] &= (m+n)\sigma_x^2+(m+n\rho^2)\mu_x^2,\\ \mathrm{E}(m\bar{X}+n\rho^2\bar{Y})^2 &= (m+n\rho^2)^2\mu_x^2+(m+n\rho^2)\sigma_x^2\end{aligned}$$

可算得 $\mathrm{E}(T^*)=(m+n-1)\sigma_x^2$ ，所以 $(m+n-1)^1T^*$ 是 σ_x^2 的 UMRUE 。 ∎

21. 设 $X_1,\cdots,X_n$ 为 *i.i.d.* 样本，$\mathrm{E}(X_1)=\mu$ ，记 μ 的线性估计类为 $L_\mu=\{T(X):\ T(X)=\sum_{i=1}^{n}c_iX_i\}$

(1) 证明： T(X) 为 μ 的无偏估计的充要条件是 $\sum_{i=1}^{n}c_i=1$ ；

(2) 在线性无偏估计类 L_μ 中求 μ 的 UMVUE 。

解. (1) 根据定义

$$\mathrm{E}[T(X)]=\sum_{i=1}^{n}\mathrm{E}(c_iX_i)=(\sum_{i=1}^{n}c_i)\mu.$$

所以 T(X) 为 μ 的无偏估计的充要条件是 $\sum_{i=1}^{n}c_i=1$ 。

(2) 因为 $\mathrm{Var}[T(X)]=(\sum_{i=1}^{n}c_i^2)\mathrm{Var}(X_1)$ ，所以本题化为在约束条件 $\sum_{i=1}^{n}c_i=1$ 下，求函数 $\sum_{i=1}^{n}c_i^2$ 的极小值问题。这可由 Lagrange 乘数法得到。经简单计算可知，当 $c_i=1/n,\ i=1,2,\cdots,n$ 时， $\sum_{i=1}^{n}c_i^2$ 达到最小值，其最小值为 $1/n$ 。所以在线性无偏估计类 L_μ 中， μ 的 UMVUE 为 $T(X)=\sum_{i=1}^{n}n^{-1}X_i=\bar{X}$ 。 ∎

22. 设 $\tilde{g}(X)$ 是参数 $g(\theta)$ 的一个无偏估计，证明： $g(\theta)$ 的任一无偏估计 $\hat{g}(X)$ 可表示为 $\hat{g}(X)=\tilde{g}(X)-\phi(X)$ ，其中 $\phi(X)$ 是 0 的某一无偏估计。

证明. 对于 $g(\theta)$ 的任一无偏估计 $\hat{g}(X)$ ，令 $\phi(X)=\tilde{g}(X)-\hat{g}(X)$ ，则 $\hat{g}(X)=\tilde{g}(X)-\phi(X)$ 。因为 $\tilde{g}(X)$ 和 $\hat{g}(X)$ 都是 $g(\theta)$ 的无偏估计，所以

$$\mathrm{E}(\phi(X))=\mathrm{E}_\theta[\tilde{g}(X)-\hat{g}(X)]=0;\ \ \forall\,\theta.$$

即 $\phi(X)$ 是 0 的无偏估计。所以 $g(\theta)$ 的任一无偏估计 $\hat{g}(X)$ 都可以表示为 $\hat{g}(X)=\tilde{g}(X)-\phi(X)$ ，其中 $\phi(X)$ 是 0 的某一无偏估计。 ∎

23.★ 设 $\Phi=\{\phi(X):\ \mathrm{E}_\theta\phi(X)=0,\ \mathrm{Var}_\theta\phi(X)<+\infty,$ 对一切 $\theta\in\Theta\}$, $\hat{g}(X)$ 为 $g(\theta)$ 的无偏估计.

(1) 证明： $\hat{g}(X)$ 为 $g(\theta)$ 的 UMVUE 的充要条件是 $\mathrm{E}_\theta[\hat{g}(X)\phi(X)]=0,\ \forall\ \phi(X)\in\Phi,\ \theta\in\Theta$ (提示：用反证法) ；

(2) 若 $\hat{g}(X)$ 为 $g(\theta)$ 的 UMVUE , $\tilde{g}(X)$ 为 $g(\theta)$ 的任一无偏估计, 则必有 $\rho_\theta(\hat{g}(X),\ \tilde{g}(X))\geq 0$ ，其中 $\rho_\theta(.,.)$ 表示相关系数;

(3) 若 T_i 分别为 $g_i(\theta)$ 的 UMVUE, $i=1,2,\cdots,n$, 则 $\sum_{i=1}^n c_iT_i$ 是 $\sum_{i=1}^n c_ig_i(\theta)$ 的 UMVUE, 其中 c_i 为常数， $i=1,2,\cdots,n$ 。

证明. (1) 必要性. 若 $\hat{g}(X)$ 是 $g(\theta)$ 的 UMVUE , 要证 $\mathrm{E}_\theta[\hat{g}(X)\phi(X)]=0,\ \forall\ \phi(X)\in\Phi$, $\theta\in\Theta$ 。令 $\tilde{g}_c(X)=\hat{g}(X)+c\phi(X)$ ，其中 $\phi(X)\in\Phi,\ c$ 是任意常数。由于 $\mathrm{E}_\theta\phi(X)=0$ ，则有 $\mathrm{E}_\theta(\tilde{g}_c(X))=\mathrm{E}_\theta[\hat{g}(X)+c\phi(X)]=g(\theta)$ ，即 $\tilde{g}_c(X)$ 是 $g(\theta)$ 的无偏估计。则有

$$\begin{aligned}\mathrm{Var}_\theta(\tilde{g}_c(X)) &= \mathrm{Var}_\theta[\hat{g}(X)+c\phi(X)]\\ &= \mathrm{Var}_\theta(\hat{g}(X))+c^2\mathrm{Var}_\theta(\phi(X))+2c\mathrm{Cov}_\theta[\hat{g}(X),\ \phi(X)].\end{aligned}$$

如果 $\hat{g}(X)$ 是 $g(\theta)$ 的 UMVUE , 即 $\mathrm{Var}_\theta(\tilde{g}_c(X))\geq\mathrm{Var}_\theta(\hat{g}(X))$, 则必有 $\mathrm{Cov}_\theta[\hat{g}(X),\ \phi(X)]=\mathrm{E}_\theta[\hat{g}(X)\phi(X)]=0$ ，因为若不为零，则可取 $c=-\mathrm{Cov}_\theta[\hat{g}(X),\ \phi(X)]/\mathrm{Var}_\theta(\phi(X))$ ，代入上式可得

$$\mathrm{Var}_\theta(\tilde{g}_c(X))=\mathrm{Var}_\theta(\hat{g}(X))-\mathrm{Cov}_\theta^2[\hat{g}(X),\ \phi(X)]/\mathrm{Var}_\theta(\phi(X))<\mathrm{Var}_\theta(\hat{g}(X)).$$

这与 $\hat{g}(X)$ 是 $g(\theta)$ 的 UMVUE 矛盾。因此必有 $\mathrm{E}_\theta[\hat{g}(X)\phi(X)]=0,\ \forall\ \phi(X)\in\Phi$ ， $\theta\in\Theta$ 。

充分性. 若 $\mathrm{E}_\theta[\hat{g}(X)\phi(X)]=0,\ \forall\ \phi(X)\in\Phi,\ \theta\in\Theta$, 要证 $\hat{g}(X)$ 是 $g(\theta)$ 的 UMVUE 。对于 $g(\theta)$ 的任一方差有界的无偏估计 $\tilde{g}(X)$ ，我们有

$$\begin{aligned}\mathrm{Var}_\theta(\tilde{g}(X)) &= \mathrm{Var}_\theta[\hat{g}(X)+\tilde{g}(X)-\hat{g}(X)]\\ &= \mathrm{Var}_\theta(\hat{g}(X))+2\mathrm{Cov}_\theta[\hat{g}(X),\ \tilde{g}(X)-\hat{g}(X)]+\mathrm{Var}_\theta[\tilde{g}(X)-\hat{g}(X)]\\ &= \mathrm{Var}_\theta(\hat{g}(X))+\mathrm{Var}_\theta[\tilde{g}(X)-\hat{g}(X)]\geq\mathrm{Var}_\theta(\hat{g}(X)).\end{aligned}$$

以上第二等式中的协方差 $\mathrm{Cov}_\theta[\hat{g}(X),\ \tilde{g}(X)-\hat{g}(X)]=0$ 。这是因为 $\mathrm{E}_\theta(\tilde{g}(X)-\hat{g}(X))=0$, $\mathrm{Var}_\theta(\tilde{g}(X)-\hat{g}(X))<\infty$ ，所以 $\tilde{g}(X)-\hat{g}(X)\in\Phi$ 。从而由假设可知

$$\mathrm{Cov}_\theta[\hat{g}(X),\ \tilde{g}(X)-\hat{g}(X)]=\mathrm{E}_\theta[\hat{g}(X)(\tilde{g}(X)-\hat{g}(X))]-g(\theta)\cdot\mathrm{E}_\theta[\tilde{g}(X)-\hat{g}(X)]=0.$$

所以 $\mathrm{Var}_\theta(\tilde{g}(X))\geq\mathrm{Var}_\theta(\hat{g}(X))$ ，即 $\hat{g}(X)$ 为 $g(\theta)$ 的 UMVUE 。

(2) 由 $\mathrm{E}_\theta(\hat{g}(X))=g(\theta),\ \ \mathrm{E}_\theta(\tilde{g}(X))=g(\theta)$ 可得 $\mathrm{E}_\theta[\hat{g}(X)-\tilde{g}(X)]=0$ ，所以 $\hat{g}(X)-\tilde{g}(X)\in\Phi$ 。因为 $\hat{g}(X)$ 为 $g(\theta)$ 的 UMVUE , 所以由 (1) 可得 $\mathrm{E}_\theta[\hat{g}(X)(\hat{g}(X)-\tilde{g}(X))]=0$, 即 $\mathrm{E}_\theta[\hat{g}(X)^2]=\mathrm{E}_\theta[\hat{g}(X)\tilde{g}(X)]$ 。又因为

$$\begin{aligned}\mathrm{Cov}_\theta(\hat{g}(X),\ \tilde{g}(X)) &= \mathrm{E}_\theta(\hat{g}(X)\tilde{g}(X))-\mathrm{E}_\theta(\hat{g}(X))\mathrm{E}_\theta(\tilde{g}(X))\\ &= \mathrm{E}_\theta(\hat{g}(X)^2)-g^2(\theta)=\mathrm{Var}(\hat{g}(X))\geq 0,\end{aligned}$$

所以 $\rho_\theta(\hat{g}(X),\ \tilde{g}(X)) \geq 0$ 。

(3) 因为 T_i 分别为 $g_i(\theta)$ 的 UMVUE ，$i=1,2,\cdots,n$ ，所以由 (1) 可得 $\mathrm{E}_\theta(T_i\phi(X))=0,\ \ \forall\ \phi(X)\in\Phi,\ \theta\in\Theta,\ i=1,2,\cdots,n$ ，从而

$$\mathrm{E}_\theta[(\sum_{i=1}^n c_iT_i)\phi(X)]=\sum_{i=1}^n c_i\mathrm{E}_\theta(T_i\phi(X))=0,\ \ \forall\ \phi(X)\in\Phi,\ \theta\in\Theta.$$

又因为

$$\mathrm{E}_\theta(\sum_{i=1}^n c_iT_i)=\sum_{i=1}^n c_i\mathrm{E}_\theta(T_i)=\sum_{i=1}^n c_ig_i(\theta),$$

即 $\sum_{i=1}^n c_iT_i$ 是 $\sum_{i=1}^n c_ig_i(\theta)$ 的无偏估计，所以由 (1) 可得 $\sum_{i=1}^n c_iT_i$ 是 $\sum_{i=1}^n c_ig_i(\theta)$ 的 UMVUE 。 ∎

24. 设 $X_1,X_2,\cdots,X_n$ 为 *i.i.d.* 样本，当 X_1 的密度函数 $f(x_1,\theta)$ 为下列各种情况时，分别求 θ 的 MLE 。

(1) $f(x_1,\theta)=\theta(1-x_1)^{\theta-1}I\{0\leq x_1\leq 1\}$, 其中 $\theta>1$ ；

(2) $f(x_1,\theta)=\theta x_1^{-2}I\{x_1\geq\theta\}$, 其中 $\theta>0$ ；

(3) $f(x_1,\theta)=\beta^{-\alpha}\alpha x_1^{\alpha-1}I\{0\leq x_1\leq\beta\}$ ，其中 $\theta=(\alpha,\beta)$, $\alpha>0,\ \beta>0$ ；

(4) $f(x_1,\theta)=\alpha\mu^\alpha {x_1}^{-(\alpha+1)}I\{x_1\geq\mu\}$ ，其中 $\theta=(\alpha,\ \mu)$ ；

解. (1) $X=(X_1,\cdots,X_n)^T$ 的密度函数为

$$f(x;\theta)=\theta^n(\prod_{i=1}^n(1-x_i))^{\theta-1}I\{0\leq x_{(1)}\}I\{x_{(n)}\leq 1\},$$

由 $\partial\log f/\partial\theta=0$ 可得 $\theta=-n/\sum_{i=1}^n\log(1-x_i)$ 。因为 $\partial^2\log f/\partial\theta^2=-n/\theta^2<0$ ，所以 $\hat{\theta}(X)=-n/\sum_{i=1}^n\log(1-X_i)$ 为 θ 的 MLE 。

(2) $X=(X_1,\cdots,X_n)^T$ 的密度函数为

$$f(x;\theta)=\theta^n\prod_{i=1}^n x_i^{-2}I\{\theta\leq x_{(1)}\},$$

由此易得 θ 的 MLE 为 $\hat{\theta}=X_{(1)}$ 。

(3) $X=(X_1,\cdots,X_n)^T$ 的密度函数为

$$f(x;\theta)=\beta^{-n\alpha}\alpha^n(\prod_{i=1}^n x_i)^{\alpha-1}I\{0\leq x_{(1)}\}I\{x_{(n)}\leq\beta\},$$

由此易得 β 的 MLE 为 $\hat{\beta}=X_{(n)}$ 。把 $\hat{\beta}$ 代入上式可得关于 α 的对数似然函数为

$$L(\alpha,\hat{\beta})=-n\alpha\log\hat{\beta}+n\log\alpha+(\alpha-1)\sum_{i=1}^n\log x_i,$$

由 $\partial L(\alpha,\hat{\beta})/\partial\alpha=0$ 可得 $\alpha=n[\sum_{i=1}^n(\log\hat{\beta}-\log x_i)]^{-1}$ 。因为 $\partial^2L(\alpha,\hat{\beta})/\partial\alpha^2=-n/\alpha^2<0$ ，所以 $\hat{\alpha}=n[\sum_{i=1}^n(\log X_{(n)}-\log X_i)]^{-1}$ 为 α 的 MLE 。

(4) $X=(X_1,\cdots,X_n)^T$ 的密度函数为

$$f(x;\theta)=\alpha^n\mu^{n\alpha}(\prod_{i=1}^n x_i)^{-(\alpha+1)}I\{x_{(1)}\geq\mu\},$$

由此易得 μ 的 MLE 为 $\hat{\mu}=X_{(1)}$ 。把 $\hat{\mu}$ 代入上式可得关于 α 的对数似然函数为

$$L(\hat{\mu},\alpha)=n\log\alpha+n\alpha\log\hat{\mu}-(\alpha+1)\sum_{i=1}^n\log x_i,$$

由 $\partial L(\hat{\mu},\alpha)/\partial\alpha=0$ 可得 $\alpha=n[\sum_{i=1}^n(\log x_i-\log x_{(1)})]^{-1}$ 。因为 $\partial^2L(\hat{\mu},\alpha)/\partial\alpha^2=-n/\alpha^2<0$ ，所以 $\hat{\alpha}=n[\sum_{i=1}^n(\log X_i-\log X_{(1)})]^{-1}$ 为 α 的 MLE 。 ∎

25. 设 $X_1,X_2,\cdots,X_n$ 为 *i.i.d.* 样本，当 X_1 的密度函数 $f(x_1,\theta)$ 为下列各种情况时，分别求 θ 的 MLE 。

(1) $f(x_1,\theta)=\theta^{x_1}(1-\theta)^{1-x_1}$ ，其中 $x_1=0$ 或 1 ； $\theta\in[\frac{1}{2},\frac{3}{4}]$ ；

(2) $f(x_1,\theta)=\frac{\theta}{1-\theta}x_1^{\frac{2\theta-1}{1-\theta}}I\{0\leq x_1\leq 1\}$ ，其中 $\theta\in(\frac{1}{2},1)$ ；

(3) $f(x_1,\theta)=\begin{cases} I\{0\leq x_1\leq 1\}, & \theta=0\\ \frac{1}{2\sqrt{x_1}}I\{0<x_1\leq 1\}, & \theta=1.\end{cases}$

解. (1) $X=(X_1,\cdots,X_n)^T$ 的密度函数和对数似然函数分别为

$$f(x;\theta)=\theta^{\sum_{i=1}^n x_i}(1-\theta)^{n-\sum_{i=1}^n x_i};\quad L(\theta)=T\log\theta+(n-T)\log(1-\theta).$$

其中 $T=\sum_{i=1}^n x_i$ 。由 $\partial L(\theta)/\partial\theta=0$ 可得 $\theta=T/n=\bar{x}$ 。又由 $\partial^2L(\theta)/\partial\theta^2=-T/\theta^2-(n-T)/(1-\theta)^2<0$ 可知 $L(\theta)$ 为 θ 的上凸单峰函数。即 $\theta<\bar{x}$ 时 $L(\theta)$ 为增函数； $\theta>\bar{x}$ 时 $L(\theta)$ 为减函数。所以 θ 的 MLE 为 (见图)

$$\hat{\theta}(X)=\begin{cases}\bar{X}, & 当\quad \bar{X}\in[1/2,3/4]\\ 1/2, & 当\quad \bar{X}<1/2,\\ 3/4, & 当\quad \bar{X}>3/4.\end{cases}$$

(2) $X=(X_1,\cdots,X_n)^T$ 的密度函数为和对数似然函数分别为

$$f(x;\theta)=\theta^n(1-\theta)^{-n}(\prod_{i=1}^n x_i)^{(2\theta-1)/(1-\theta)},$$

$$L(\theta)=n\log\frac{\theta}{1-\theta}+\frac{2\theta-1}{1-\theta}T.$$

其中 $T=\sum_{i=1}^n\log x_i\leq 0$ 。而 $L(\theta)$ 的一阶导数为

$$\frac{\partial L(\theta)}{\partial\theta}=\frac{n-(n-T)\theta}{\theta(1-\theta)^2}.$$

由 $\partial L(\theta)/\partial\theta=0$ 可得 $\hat{\theta}=n/(n-T)\leq 1$ 。而且当 $\theta<n/(n-T)$ 时， $\partial L(\theta)/\partial\theta>0$ ， $L(\theta)$ 为增函数；当 $\theta>n/(n-T)$ 时， $\partial L(\theta)/\partial\theta<0$ ， $L(\theta)$ 为减函数。因此 $L(\theta)$ 为单峰函数，并且当 $\theta=\hat{\theta}=n/(n-T)$ 时达到最大值。容易验证， $\hat{\theta}=n/(n-T)\in(1/2,1)$

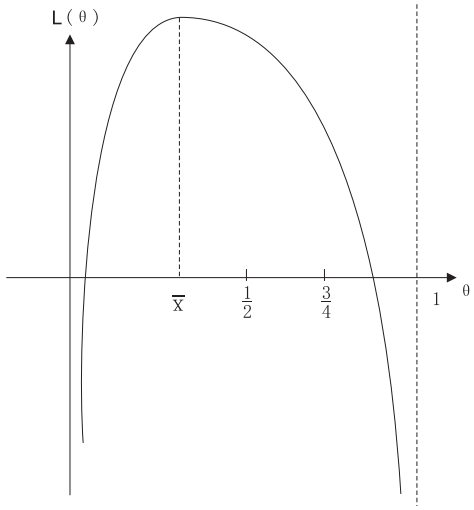

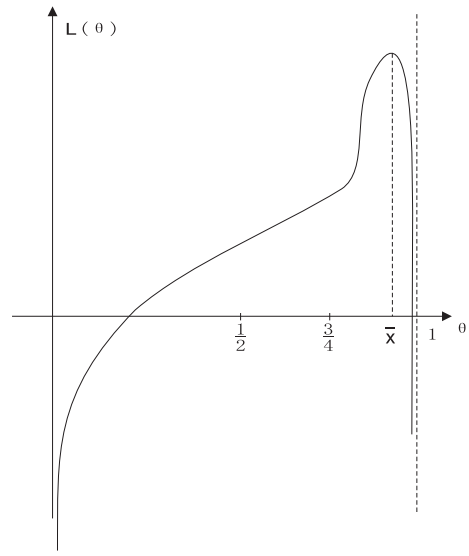

等同于 $0 < -T < n$ 。因此，当 $0 < -T < n$ 时， θ 的 MLE 为 $\hat{\theta}(X) = n/(n-T)$ 。当 $-T = 0$ 时 ($-T$ 不可能 < 0) ， $\partial L(\theta)/\partial\theta > 0$ ， $L(\theta)$ 为增函数，因而 θ 在开区间 $(1/2, 1)$ 上的 MLE 不存在；同理，当 $-T \geq n$ 时，在 $(1/2, 1)$ 上 $\partial L(\theta)/\partial\theta < 0$ ， $L(\theta)$ 为减函数，因而 θ 在开区间 $(1/2, 1)$ 上的 MLE 也不存在。

注. 如果 θ 的定义域为半开区间 $[1/2, 1)$ (这是可以的) ，则当 $-T \geq n$ 时， $L(\theta)$ 为减函数，因而在 $\theta = 1/2$ 时达到最大值，所以 $\hat{\theta}(X) = 1/2$ 为其 MLE 。类似的讨论可参见第 35 题。

(3) $X = (X_1, \cdots, X_n)^T$ 的密度函数为

$$f(x;\theta) = \begin{cases} \prod\limits_{i=1}^{n} I\{0 \leq x_i \leq 1\}, & \text{当} \quad \theta = 0 \\ 2^{-n}(\prod\limits_{i=1}^{n} \sqrt{x_i})^{-1} I\{0 < x_i \leq 1\}, & \text{当} \quad \theta = 1 \end{cases}$$

由此可知，当 $X_1, \cdots, X_n$ 中有一个为 0 时，θ 的 MLE 为 $\hat{\theta}(X) = 0$；当 $X_i \neq 0$, $i = 1, 2, \cdots, n$ 时， θ 的 MLE 为

$$\hat{\theta}(X) = \begin{cases} 0, & \text{当} \quad 2^n \prod\limits_{i=1}^{n} \sqrt{X_i} > 1 \\ 1, & \text{当} \quad 2^n \prod\limits_{i=1}^{n} \sqrt{X_i} \leq 1 \end{cases}$$

∎

26. 设 $X_1, X_2, \cdots, X_n$ 为 *i.i.d.* 样本，应用正文中定理 3.3.1 关于指数族分布 MLE 的结果求以下分布中相应参数的 MLE 。

(1) X_1 服从正态分布 $N(\mu, \sigma^2)$ ；

(2) X_1 服从 Pascal 分布 $PA(r, \theta)$ ，但 r 已知；

(3) X_1 服从负二项分布 $NB(r, \theta)$ ，但 r 已知；

(4) X_1 服从 Γ 分布 $\Gamma(\lambda, \nu)$ ，但 ν 已知。

解. (1) $X=(X_1,\cdots,X_n)^T$ 的联合分布密度函数为

$$\begin{aligned} f(x_1,\cdots,x_n;\mu,\sigma^2) &= (\frac{1}{\sqrt{2\pi}\sigma})^n \exp\{-\frac{1}{2\sigma^2}\sum_{i=1}^n (x_i-\mu)^2\} \\ &= (\frac{1}{\sqrt{2\pi}})^n \exp\{-\frac{1}{2\sigma^2}\sum_{i=1}^n x_i^2 + \frac{n\mu}{\sigma^2}\bar{x} - (\frac{n\mu^2}{2\sigma^2}+\frac{n}{2}\log\sigma^2)\}. \end{aligned}$$

它显然是指数族分布，其中

$$\theta_1 = -\frac{1}{2\sigma^2},\quad T_1(x)=\sum_{i=1}^n x_i^2,\quad \theta_2=\frac{n\mu}{\sigma^2},\quad T_2(x)=\bar{x},$$

$$b(\theta)=\frac{n\mu^2}{2\sigma^2}+\frac{n}{2}\log\sigma^2 = -\frac{\theta_2^2}{4n\theta_1}-\frac{n}{2}\log(-2\theta_1),$$

由 $T(X)=\mathrm{E}(T(X))=\dot{b}(\theta)$ ，即

$$\begin{aligned} T_1(X) &= \frac{\partial b(\theta)}{\partial\theta_1} = \frac{\theta_2^2}{4n\theta_1^2}-\frac{n}{2\theta_1}, \\ T_2(X) &= \frac{\partial b(\theta)}{\partial\theta_2} = -\frac{\theta_2}{2n\theta_1}. \end{aligned}$$

可得

$$\begin{aligned} T_1(X)-nT_2^2(X) &= -\frac{n}{2\theta_1} = n\sigma^2, \\ T_2(X) &= \mu. \end{aligned}$$

所以 μ 和 σ^2 的 MLE 分别为 $\bar{X}$ 和 $n^{-1}\sum_{i=1}^n (X_i-\bar{X})^2$ 。

(2) $X=(X_1,\cdots,X_n)^T$ 的联合分布密度函数为

$$\begin{aligned} f(x;\theta) &= \prod_{i=1}^n \left[\binom{x_i-1}{r-1}\theta^r(1-\theta)^{x_i-r}\right] \\ &= \prod_{i=1}^n \binom{x_i-1}{r-1}\cdot\exp\{\log(1-\theta)\sum_{i=1}^n x_i - nr\log(\frac{1-\theta}{\theta})\}. \end{aligned}$$

它是指数族分布，其中

$$T_1(x)=\sum_{i=1}^n x_i,\ \theta_1=\log(1-\theta),\ b(\theta_1)=nr\log(\frac{e^{\theta_1}}{1-e^{\theta_1}}).$$

由

$$T_1(X)=\sum_{i=1}^n X_i = \mathrm{E}(T_1(X)) = \frac{\partial b(\theta_1)}{\partial\theta_1} = nr(1-e^{\theta_1})^{-1} = nr\theta^{-1}.$$

可知 θ 的 MLE 为 $\hat{\theta}=nrT^{-1}$ ， $T=\sum_{i=1}^n X_i$ 。

(3) $X=(X_1,\cdots,X_n)^T$ 的联合分布密度函数为

$$\begin{aligned} f(x;\theta) &= \prod_{i=1}^n \left[\binom{x_i+r-1}{x_i}\theta^r(1-\theta)^{x_i}\right] = \prod_{i=1}^n \binom{x_i+r-1}{x_i}\cdot\theta^{nr}(1-\theta)^{\sum_{i=1}^n x_i} \\ &= \prod_{i=1}^n \binom{x_i+r-1}{x_i}\cdot\exp\{\sum_{i=1}^n x_i\log(1-\theta)-(-nr\log\theta)\}. \end{aligned}$$

它是指数族分布，其中

$$T_1(x)=\sum_{i=1}^n x_i,\ \theta_1=\log(1-\theta),\ b(\theta_1)=-nr\log(1-e^{\theta_1}).$$

由

$$T_1(X)=\sum_{i=1}^n X_i=\mathrm{E}(T_1(X))=\frac{\partial b(\theta_1)}{\partial\theta_1}=\frac{nre^{\theta_1}}{1-e^{\theta_1}}=\frac{nr}{\theta}-nr.$$

可知 θ 的 MLE 为 $\hat\theta=nr/(T+nr)$ ， $T=\sum_{i=1}^n X_i$ 。

(4) $X=(X_1,\cdots,X_n)^T$ 的联合分布密度函数为

$$\begin{aligned} f(x;\lambda) &= \prod_{i=1}^n\left[\frac{\lambda^\nu}{\Gamma(\nu)}e^{-\lambda x_i}x_i^{\nu-1}\right] \\ &= (\prod_{i=1}^n x_i)^{\nu-1}\Gamma^{-n}(\nu)\exp\{-\lambda\sum_{i=1}^n x_i-(-n\nu\log\lambda)\}. \end{aligned}$$

它是指数族分布，其中

$$T(x)=\sum_{i=1}^n x_i,\ \theta=-\lambda,\ b(\theta)=-n\nu\log(-\theta).$$

由

$$T(X)=\mathrm{E}(T(X))=\frac{\partial b(\theta)}{\partial\theta}=-n\nu/\theta=n\nu/\lambda.$$

可知 λ 的 MLE 为 $\hat\lambda=n\nu/T$ ， $T=\sum_{i=1}^n X_i$ 。 ∎

27. 设 $X_1,X_2,\cdots,X_n$ 相互独立，在下列情形下求相应参数的 MLE ：

(1) $X_j\sim N(0,\sigma^2)$ 一切 $j\neq i$ ，而 $X_i\sim N(\gamma,\sigma^2)$ ；

(2) $X_j\sim N(0,\sigma^2)$ 一切 $j\neq i$ ，而 $X_i\sim N(0,\omega^{-1}\sigma^2)$ ；

(3) $X_j\sim N(0,\sigma^2)$ 一切 $j\neq 1,n$ ，而 $X_1\sim N(\gamma,\sigma^2)$ ； $X_n\sim N(0,\omega^{-1}\sigma^2)$ 。

其中 $\gamma\in R,\ \omega>0,\ \sigma^2$ 都是未知参数。

解. (1) $X=(X_1,\cdots,X_n)^T$ 的对数似然函数为

$$L(\gamma,\sigma^2)=-\frac{n}{2}\log\sigma^2-\frac{1}{2\sigma^2}\sum_{j\neq i}x_j^2-\frac{1}{2\sigma^2}(x_i-\gamma)^2-\frac{n}{2}\log(2\pi),$$

由

$$\begin{aligned} \frac{\partial L(\gamma,\sigma^2)}{\partial\gamma} &= \frac{1}{\sigma^2}(x_i-\gamma)=0, \\ \frac{\partial L(\gamma,\sigma^2)}{\partial\sigma^2} &= -\frac{n}{2\sigma^2}+\frac{1}{2\sigma^4}\sum_{j\neq i}x_j^2+\frac{1}{2\sigma^4}(x_i-\gamma)^2=0. \end{aligned}$$

可解得

$$\gamma=x_i,\quad \sigma^2=\frac{1}{n}\sum_{j\neq i}x_j^2.$$

所以 γ, σ^2 的极大似然估计分别为

$$\hat{\gamma} = X_i, \quad \hat{\sigma}^2 = \frac{1}{n}\sum_{j\neq i} X_j^2.$$

(2) $X = (X_1, \cdots, X_n)^T$ 的对数似然函数为

$$L(\omega, \sigma^2) = -\frac{n}{2}\log\sigma^2 + \frac{1}{2}\log\omega - \frac{1}{2\sigma^2}\sum_{j\neq i} x_j^2 - \frac{\omega}{2\sigma^2}x_i^2 - \frac{n}{2}\log(2\pi).$$

由

$$\begin{aligned}
\frac{\partial L(\omega,\sigma^2)}{\partial\omega} &= \frac{1}{2\omega} - \frac{1}{2\sigma^2}x_i^2 = 0 \\
\frac{\partial L(\omega,\sigma^2)}{\partial\sigma^2} &= -\frac{n}{2\sigma^2} + \frac{1}{2\sigma^4}\sum_{j\neq i} x_j^2 + \frac{\omega}{2\sigma^4}x_i^2 = 0
\end{aligned}$$

可解得

$$\omega = \frac{\sum_{j\neq i} x_j^2}{(n-1)x_i^2}, \quad \sigma^2 = \frac{1}{n-1}\sum_{j\neq i} x_j^2.$$

所以 ω, σ^2 的极大似然估计分别为

$$\hat{\omega} = \frac{\sum_{j\neq i} X_j^2}{(n-1)X_i^2}, \quad \hat{\sigma}^2 = \frac{1}{n-1}\sum_{j\neq i} X_j^2.$$

(3) $X = (X_1, \cdots, X_n)^T$ 的对数似然函数为

$$L(\gamma, \omega, \sigma^2) = -\frac{n}{2}\log\sigma^2 + \frac{1}{2}\log\omega - \frac{1}{2\sigma^2}\sum_{j=2}^{n-1} x_j^2 - \frac{1}{2\sigma^2}(x_1-\gamma)^2 - \frac{\omega}{2\sigma^2}x_n^2 - \frac{n}{2}\log(2\pi).$$

由

$$\begin{aligned}
\frac{\partial L(\gamma,\omega,\sigma^2)}{\partial\gamma} &= \frac{1}{\sigma^2}(x_1-\gamma) = 0, \\
\frac{\partial L(\gamma,\omega,\sigma^2)}{\partial\omega} &= \frac{1}{2\omega} - \frac{1}{2\sigma^2}x_n^2 = 0, \\
\frac{\partial L(\gamma,\omega,\sigma^2)}{\partial\sigma^2} &= -\frac{n}{2\sigma^2} + \frac{1}{2\sigma^4}\sum_{j=2}^{n-1} x_j^2 + \frac{1}{2\sigma^4}(x_1-\gamma)^2 + \frac{\omega}{2\sigma^4}x_n^2 = 0.
\end{aligned}$$

可解得

$$\gamma = x_1, \quad \omega = \frac{\sum_{j=2}^{n-1} x_j^2}{(n-1)x_n^2}, \quad \sigma^2 = \frac{1}{n-1}\sum_{j=2}^{n-1} x_j^2.$$

所以 γ, ω, σ^2 的极大似然估计分别为

$$\hat{\gamma} = X_1, \quad \hat{\omega} = \frac{\sum_{j=2}^{n-1} X_j^2}{(n-1)X_n^2}, \quad \hat{\sigma}^2 = \frac{1}{n-1}\sum_{j=2}^{n-1} X_j^2.$$

注. 本题亦可应用第 26 题的方法求解。 ∎

28. 设 $X_1, X_2, \cdots, X_n$ 相互独立，在下列情形下求相应参数的 MLE：

(1) $X_j \sim \Gamma(\lambda, 1)$ 一切 $j \neq i$，而 $X_i \sim \Gamma(\gamma\lambda,\ 1)$；

(2) $X_j \sim P(\lambda)$ 一切 $j \neq i$，而 $X_i \sim P(\gamma\lambda)$；

(3) $X_j \sim b(1, \theta)$ 一切 $j \neq i$，而 $X_i \sim b(1, \gamma\theta)$；

其中 $\gamma > 0,\ \lambda > 0,\ 0 < \theta < 1$ 为未知参数。

解. (1) $X = (X_1, \cdots, X_n)^T$ 的对数似然函数为

$$L(\lambda, \gamma) = n \log \lambda + \log \gamma - \lambda \sum_{j \neq i} x_j - \gamma\lambda x_i,$$

由

$$\begin{aligned} \frac{\partial L(\lambda, \gamma)}{\partial \lambda} &= \frac{n}{\lambda} - \sum_{j \neq i} x_j - \gamma x_i = 0, \\ \frac{\partial L(\lambda, \gamma)}{\partial \gamma} &= \frac{1}{\gamma} - \lambda x_i = 0. \end{aligned}$$

可得

$$\gamma = \frac{\sum_{j \neq i} x_j}{(n-1)x_i}, \quad \lambda = \frac{n-1}{\sum_{j \neq i} x_j}.$$

所以 $\lambda,\ \gamma$ 的极大似然估计分别为

$$\hat{\gamma} = \frac{\sum_{j \neq i} X_j}{(n-1)X_i}, \quad \hat{\lambda} = \frac{n-1}{\sum_{j \neq i} X_j}.$$

(2) $X = (X_1, \cdots, X_n)^T$ 的对数似然函数为

$$L(\lambda, \gamma) = -(n-1)\lambda - \gamma\lambda + \log \lambda \sum_{j=1}^{n} x_j + x_i \log \gamma - \sum_{j=1}^{n} \log(x_i!),$$

由

$$\begin{aligned} \frac{\partial L(\lambda, \gamma)}{\partial \lambda} &= -(n-1) - \gamma + \frac{1}{\lambda} \sum_{j=1}^{n} x_j = 0, \\ \frac{\partial L(\lambda, \gamma)}{\partial \gamma} &= -\lambda + \frac{1}{\gamma} x_i = 0. \end{aligned}$$

可得

$$\lambda = \frac{\sum_{j \neq i} x_j}{(n-1)}, \quad \gamma = \frac{(n-1)x_i}{\sum_{j \neq i} x_j}.$$

所以 $\lambda,\ \gamma$ 的极大似然估计分别为

$$\hat{\lambda} = \frac{\sum_{j \neq i} X_j}{(n-1)}, \quad \hat{\gamma} = \frac{(n-1)X_i}{\sum_{j \neq i} X_j}.$$

(3) $X = (X_1, \cdots, X_n)^T$ 的对数似然函数为

$$L(\gamma, \theta) = x_i \log \gamma + \log \theta \sum_{j=1}^{n} x_j + [(n-1) - \sum_{j \neq i} x_j] \log(1-\theta) + (1 - x_i) \log(1 - \gamma\theta).$$

由

$$\begin{aligned}\frac{\partial L(\gamma,\theta)}{\partial\gamma} &= \frac{x_i}{\gamma}-\frac{\theta(1-x_i)}{1-\gamma\theta}=0,\\ \frac{\partial L(\gamma,\theta)}{\partial\theta} &= \frac{\sum_{j=1}^n x_j}{\theta}-\frac{(n-1)-\sum_{j\neq i}x_j}{1-\theta}-\frac{\gamma(1-x_i)}{1-\gamma\theta}=0.\end{aligned}$$

可得

$$\theta=\frac{\sum_{j\neq i}x_j}{n-1},\quad \gamma=\frac{(n-1)x_i}{\sum_{j\neq i}x_j}.$$

所以 θ, γ 的极大似然估计分别为

$$\hat\theta=\frac{\sum_{j\neq i}X_j}{n-1},\quad \hat\gamma=\frac{(n-1)X_i}{\sum_{j\neq i}X_j}.$$

注. 本题亦可应用第 26 题的方法求解。 ∎

29. 设随机变量 X 只能取 4 个值，每种取值出现的概率分别为 $\frac{1}{2}+\frac{\theta}{4},\frac{1-\theta}{4},\frac{1-\theta}{4},\frac{\theta}{4}$ ，其中 $0<\theta<1$ 。若观察到 n 个样本， 4 个值出现的次数分别为 N_1,N_2,N_3,N_4 ，其中 $N_1+N_2+N_3+N_4=n$ ；求 θ 的 MLE 。

解. $(N_1,N_2,N_3,N_4)^T$ 的联合分布密度函数为

$$f(n_1,n_2,n_3,n_4;\theta)=\frac{n!}{n_1!n_2!n_3!n_4!}(\frac{2+\theta}{4})^{n_1}(\frac{1-\theta}{4})^{n_2}(\frac{1-\theta}{4})^{n_3}(\frac{\theta}{4})^{n_4}.$$

其对数似然函数的一阶导数为

$$\frac{\partial L}{\partial\theta}=\frac{n_1}{2+\theta}-\frac{n_1+n_2}{1-\theta}+\frac{n_4}{\theta}.$$

由 $\partial L/\partial\theta=0$ 可得

$$n\theta^2+[2(n_2+n_3)+n_4-n_1]\theta-2n_4=0.$$

因为 $\theta\in(0,1)$ ，所以解方程 $(*)$ 可得

$$\theta=\frac{1}{2n}[(n_1-2n_2-2n_3-n_4)+\sqrt{(2n_2+2n_3+n_4-n_1)^2+8nn_4}\ ].$$

又因为

$$\frac{\partial^2 L}{\partial\theta^2}=-\frac{n_1}{(\theta+2)^2}-\frac{n_2+n_3}{(1-\theta)^2}-\frac{n_4}{\theta^2}<0.$$

所以 θ 的 MLE 为

$$\hat\theta=\frac{1}{2n}[(N_1-2N_2-2N_3-N_4)+\sqrt{(2N_2+2N_3+N_4-N_1)^2+8nN_4}\ ].$$ ∎

30. 设 $X=(X_1,X_2,X_3,X_4)^T$ 服从 4 项分布，即 $X\sim MN(n,\pi)$ ，其中 n 已知，$\pi=(a,b,b,c)^T$ ，求 a,b,c 的 MLE 。

解. X 的密度函数为

$$f(x;a,b,c)=\frac{n!}{x_1!x_2!x_3!x_4!}a^{x_1}b^{x_2+x_3}c^{x_4},$$

其对数似然函数为

$$L(a,b,c)=x_1\log a+(x_2+x_3)\log b+x_4\log c+\log n!-\log(x_1!x_2!x_3!x_4!).$$

其中 $a+2b+c=1$ 。下面用 Lagrange 乘数法求 $a,\ b,\ c$ 的极大似然估计。令

$$l^*(a,b,c)=x_1\log a+(x_2+x_3)\log b+x_4\log c-\lambda(a+2b+c-1)+\text{常数项},$$

则由

$$\begin{aligned}\frac{\partial L^*(a,b,c)}{\partial a} &= \frac{x_1}{a}-\lambda=0, \quad \frac{\partial L^*(a,b,c)}{\partial b}=\frac{x_2+x_3}{b}-2\lambda=0,\\ \frac{\partial L^*(a,b,c)}{\partial c} &= \frac{x_4}{c}-\lambda=0, \quad \frac{\partial L^*(a,b,c)}{\partial \lambda}=-(a+2b+c-1)=0.\end{aligned}$$

可得 $\lambda=n,\ a=x_1/n,\ b=(x_2+x_3)/(2n),\ c=x_4/n$ 。所以 a,b,c 的极大似然估计分别为 $\hat{a}=X_1/n,\ \hat{b}=(X_2+X_3)/(2n),\ \hat{c}=X_4/n$ 。 ∎

31. 设做了三个相互独立的试验，每个试验都服从两点分布，第一个试验共做了 n_1 次，成功的次数为 X_1 ；第二个试验共做了 n_2 次，成功的次数为 X_2 ；第三个试验共做了 n_3 次，成功的次数为 X_3 。设三次试验中成功的概率分别为 $\alpha,\ \alpha+\beta,\ \alpha$ ，求 α,β 的 MLE 。

解. $X=(X_1,X_2,X_3)^T$ 的联合密度函数为

$$f(x;\alpha,\beta)=\binom{n_1}{x_1}\binom{n_2}{x_2}\binom{n_3}{x_3}\alpha^{x_1}(1-\alpha)^{n_1-x_1}(\alpha+\beta)^{x_2}(1-\alpha-\beta)^{n_2-x_2}\alpha^{x_3}(1-\alpha)^{n_3-x_3},$$

其对数似然函数为

$$\begin{aligned}L(\alpha,\beta) &= (x_1+x_3)\log\alpha+(n_1-x_1+n_3-x_3)\log(1-\alpha)\\ &\quad +x_2\log(\alpha+\beta)+(n_2-x_2)\log(1-\alpha-\beta)+\text{常数项},\end{aligned}$$

其似然方程为

$$\begin{aligned}\frac{\partial L(\alpha,\beta)}{\partial\alpha} &= \frac{x_1+x_3}{\alpha}-\frac{n_1-x_1+n_3-x_3}{1-\alpha}+\frac{x_2}{\alpha+\beta}-\frac{n_2-x_2}{1-\alpha-\beta}=0,\\ \frac{\partial L(\alpha,\beta)}{\partial\beta} &= \frac{x_2}{\alpha+\beta}-\frac{n_2-x_2}{1-\alpha-\beta}=0.\end{aligned}$$

由此可得

$$\alpha=\frac{x_1+x_3}{n_1+n_3},\quad \beta=\frac{x_2}{n_2}-\frac{x_1+x_3}{n_1+n_3}.$$

所以 α,β 的极大似然估计分别为

$$\hat{\alpha}=\frac{X_1+X_3}{n_1+n_3},\quad \hat{\beta}=\frac{X_2}{n_2}-\frac{X_1+X_3}{n_1+n_3}.$$

注. 本题亦可应用第 26 题的方法求解。 ∎

32. 设 $N=(N_{ij})$ 服从多项分布 $MN(n,\pi);\ \pi=(\pi_{ij}),\ i=1,\cdots,r;\ j=1,\cdots,s$ 。并满足关系： $\pi_{ij}=\pi_{i\cdot}\pi_{\cdot j},\ i=1,\cdots,r;\ j=1,\cdots,s$ ，其中 $\pi_{i\cdot}=\sum_{j=1}^s\pi_{ij};\ \pi_{\cdot j}=\sum_{i=1}^r\pi_{ij}$ 。求 $\pi=(\pi_{ij})$ 的 MLE 。

解. 由假设可知，$\pi_{ij}=\pi_{i\cdot}\pi_{\cdot j},\ i=1,\cdots,r;\ j=1,\cdots,s$。并且满足关系式 $\sum_{j=1}^{s}\pi_{\cdot j}=\sum_{i=1}^{r}\pi_{i\cdot}=\sum_{j=1}^{s}\sum_{i=1}^{r}\pi_{ij}=1$，所以本题实际上只有 $r+s-2$ 个独立参数。不妨记 $\theta=(\pi_{1\cdot},\pi_{2\cdot},\cdots,\pi_{(r-1)\cdot};\pi_{\cdot 1},\pi_{\cdot 2},\cdots,\pi_{\cdot(s-1)})$，则

$$\begin{aligned}\pi_{i\cdot} &= \theta_i,\ \pi_{\cdot j}=\theta_{r-1+j},\quad 1\le i\le r-1,\ 1\le j\le s-1,\\ \pi_{r\cdot} &= 1-\theta_1-\cdots-\theta_{r-1},\quad \pi_{\cdot s}=1-\theta_r-\cdots-\theta_{r+s-2},\\ \pi_{ij} &= \pi_{i\cdot}\pi_{\cdot j}=\theta_i\theta_{r-1+j}.\end{aligned}$$

根据不变原理，我们仅需求出 θ 的极大似然估计即可得到 $\pi=(\pi_{ij})$ 的极大似然估计。令 $M=(N_{1\cdot},\cdots,N_{r\cdot})$，其中 $N_{i\cdot}=\sum_{j=1}^{s}N_{ij}$，则显然有 $M\sim MN(n,(\pi_{1\cdot},\cdots,\pi_{r\cdot})^T)$，所以由多项分布的极大似然估计知 $\hat{\pi}_{i\cdot}=N_{i\cdot}/n,\ i=1,\cdots,r$。同理，$\hat{\pi}_{\cdot j}=N_{\cdot j}/n,\quad j=1,\cdots,s$，其中 $N_{\cdot j}=\sum_{i=1}^{r}N_{ij},j=1,\cdots,s$。所以

$$\hat{\pi}_{ij}=\hat{\pi}_{i\cdot}\hat{\pi}_{\cdot j},\quad i=1,\cdots,r;\ j=1,\cdots,s.$$

∎

33. 设 $X_1,\cdots,X_n$ 为 *i.i.d.* 样本，X_1 的概率密度函数为 $f(x_1;\theta)=2x_1/\theta^2 I\{0\le x_1\le\theta\}$。

(1) 试求具有上述概率密度函数的分布函数的中位数的 MLE；

(2) 证明 (1) 中的估计是极小充分统计量。

解. (1) 设 $x_{0.5}$ 是题中概率密度函数的分布函数的中位数，则由

$$\int_0^{x_{0.5}}\frac{2x}{\theta^2}dx=\frac{1}{\theta^2}x_{0.5}^2=\frac{1}{2},$$

可知 $x_{0.5}=\theta/\sqrt{2}$。 $X=(X_1,\cdots,X_n)$ 的概率密度函数为

$$f(x;\theta)=\prod_{i=1}^{n}f(x_i;\theta)=(\frac{2^n}{\theta^{2n}}\prod_{i=1}^{n}x_i)I\{x_{(1)}\ge 0\}I\{x_{(n)}\le\theta\},$$

由此易得 θ 的极大似然估计为 $\hat{\theta}=X_{(n)}$。根据极大似然估计的不变原理可知，中位数 $x_{0.5}$ 的 MLE 为 $\hat{x}_{0.5}=X_{(n)}/\sqrt{2}$。

(2) 由第二章的第 4 题可知，$T=X_{(n)}$ 是极小充分统计量，所以 $\hat{x}_{0.5}=X_{(n)}/\sqrt{2}$ 也是极小充分统计量。 ∎

34. 设 $X_1,\cdots,X_n$ 为 *i.i.d.* 样本，X_1 服从指数分布 $\mu+\Gamma(\lambda,1)$，$P(X_1\le x_\alpha)=\alpha$。

(1) 若 α 已知求 x_α 的 MLE；

(2) 若 x_α 已知求 α 的 MLE。

解. μ 和 λ 的极大似然估计分别为 $\hat{\mu}=X_{(1)},\ \hat{\lambda}=n/S$，其中 $S=\sum_{i=1}^{n}(X_i-X_{(1)})$。由于 $X_1\sim\mu+\Gamma(\lambda,1)$，因此有 $2\lambda(X_1-\mu)\sim\Gamma(1/2,1)\sim\chi^2(2)$。所以

$$P(X_1\le x_\alpha)=P(2\lambda(X_1-\mu)\le 2\lambda(x_\alpha-\mu))=\alpha.$$

从而 $2\lambda(x_\alpha-\mu)=\chi^2(2,\alpha)$，其中 $\chi^2(2,\alpha)$ 是 $\chi^2(2)$ 的 α 分位点。

(1) 若 α 已知，则 $\chi^2(2,\alpha)$ 已知，且 $x_\alpha=\mu+\chi^2(2,\alpha)/(2\lambda)$，因此由极大似然估计的不变性可得

$$\hat{x}_\alpha=\hat{\mu}+\frac{\chi^2(2,\alpha)}{2\hat{\lambda}}=X_{(1)}+\frac{S}{2n}\chi^2(2,\alpha).$$

(2) 若 x_α 已知，则 $\alpha = \Psi(2\lambda(x_\alpha - \mu))$ ，其中 $\Psi(\cdot)$ 是 $\chi^2(2)$ 的分布函数，由极大似然估计的不变性可得

$$\hat{\alpha} = \Psi(\frac{2n}{S}(x_\alpha - X_{(1)}).$$

∎

35. (1) 设 $X \sim N(\mu, \sigma^2)$ ，其中 $\mu \in [a, b]$ ， a 和 b 已知，求 (μ, σ^2) 的 MLE ；

(2) 设 $X_1, X_2, \cdots, X_n$ 为 $i.i.d.$ 样本， $X_1 \sim N(\mu, 1)$ ，当 $\mu \in [0, +\infty)$ 时，求 μ 的 MLE ；当 $\mu \in (0, +\infty)$ 时，求 μ 的 MLE (提示：对 $\bar{X}$ 的取值分情况进行讨论) 。

解. (1) X 的密度函数，对数似然函数及其导数分别为

$$L(\mu, \sigma^2) = -\frac{(x-\mu)^2}{2\sigma^2} - \frac{1}{2}\log(2\pi\sigma^2);$$

$$\frac{\partial L}{\partial \mu} = \frac{1}{\sigma^2}(x-\mu); \quad \frac{\partial L}{\partial \sigma^2} = \frac{(x-\mu)^2}{2\sigma^4} - \frac{1}{2\sigma^2}.$$

由上式可知，对于任意固定的 σ ， $L(\mu, \sigma^2)$ 为 μ 的上凸单峰函数，且在 $\mu = x$ 时达到峰值； $\mu < x$ 时 $L(\mu, \sigma^2)$ 为增函数； $\mu > x$ 时 $L(\mu, \sigma^2)$ 为减函数。

当 $a \le x \le b$ 时， $\mu = x$ 为 $L(\mu, \sigma^2)$ 的峰值点；但是这时 $L(x, \sigma^2) = -\frac{1}{2}\log(2\pi\sigma^2)$ 将会随着 σ 趋于 0 而趋于 $+\infty$ ，所以 (μ, σ^2) 的极大似然估计不存在。

当 $x < a$ 时，$L(\mu, \sigma^2)$ 在 $[a, b]$ 上是 μ 的减函数，所以 μ 的极大似然估计为 $\hat{\mu}(X) = a$ 。再由 $L(\hat{\mu}, \sigma^2)$ 可得 σ^2 的极大似然估计为 $\hat{\sigma}^2(X) = (X-a)^2$ 。

当 $x > b$ 时， $L(\mu, \sigma^2)$ 在 $[a, b]$ 上是 μ 的增函数，所以 μ, σ^2 的极大似然估计分别为 $\hat{\mu}(X) = b$, $\hat{\sigma}^2(X) = (X-b)^2$ (见图) 。

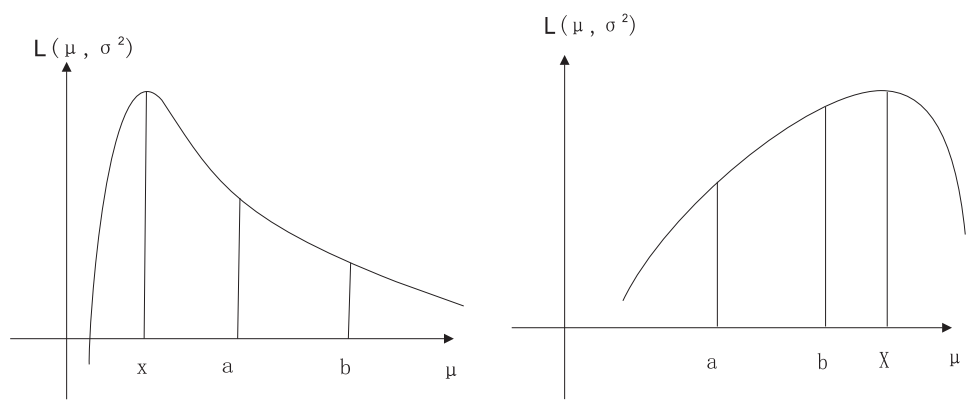

(2) $X = (X_1, \cdots, X_n)^T$ 密度函数和对数似然函数分别为

$$f(x; \mu) = (\frac{1}{\sqrt{2\pi}})^n \exp\{-\frac{1}{2}[\sum_{i=1}^n (x_i - \bar{x})^2 + n(\bar{x} - \mu)^2]\},$$

$$L(\mu) = -\frac{n}{2}(\bar{x} - \mu)^2 - \frac{1}{2}\sum_{i=1}^n (x_i - \bar{x})^2 - \frac{n}{2}\log(2\pi).$$

由 $\partial L(\mu)/\partial \mu = n(\bar{x} - \mu) = 0$ 可得 $\mu = \bar{x}$ 。因此与 (1) 类似， $L(\mu)$ 为 μ 的上凸单峰函数，且在 $\mu = \bar{x}$ 时达到峰值； $\mu < \bar{x}$ 时 $L(\mu)$ 为增函数； $\mu > \bar{x}$ 时 $L(\mu)$ 为减函数。

当 $\mu \in [0,+\infty)$ 时，若 $\bar{x} \geq 0$ ，则 μ 的 MLE 为 $\hat{\mu} = \bar{X}$ ；若 $\bar{x} < 0$ ，则 $L(\mu)$ 在 $[0,+\infty)$ 上是 μ 的减函数，所以 μ 的 MLE 为 $\hat{\mu} = 0$ 。

当 $\mu \in (0,\infty)$ 时，若 $\bar{x} > 0$ ，则 μ 的 MLE 为 $\hat{\mu} = \bar{X}$ ；若 $\bar{x} \leq 0$ ，则 $L(\mu)$ 在 $(0,+\infty)$ 上是 μ 的减函数， $L(\mu)$ 在开区间 $(0,+\infty)$ 上的最大值不存在，因此 μ 的极大似然估计不存在。 ∎

36. 设 $X_1, X_2, \cdots, X_n$ 为 *i.i.d.* 样本， X_1 服从 Cauchy 分布，即 $f(x_1,\theta) = \frac{1}{\pi}\frac{1}{1+(x_1-\theta)^2}$ 。

(1) 当 $n=1$ 时，证明 θ 的 MLE 为 X_1 ；

(2) 当 $n=2$ 时，证明 θ 的极大似然估计存在且唯一，但似然方程有多个根。

证明. (1) 当 $n=1$ 时， θ 的极大似然估计显然为 X_1 。

(2) 当 $n=2$ 时， $X=(X_1,X_2)^T$ 的联合密度函数为

$$f(x;\theta) = \frac{1}{\pi^2}\cdot\frac{1}{1+(x_1-\theta)^2}\cdot\frac{1}{1+(x_2-\theta)^2}.$$

似然方程为

$$\frac{x_1-\theta}{1+(x_1-\theta)^2} + \frac{x_2-\theta}{1+(x_2-\theta)^2} = 0.$$

由此可得

$$(x_1+x_2-2\theta)[\theta^2-(x_1+x_2)\theta+x_1x_2+1] = 0.$$

由以上二次方程可知，当 $(x_1-x_2)^2 < 4$ 时，该似然方程只有一个实根 $\theta_1 = (x_1+x_2)/2$ 和两个复根。另外有

$$\frac{\partial^2 \log f}{\partial\theta^2}|_{\theta=\theta_1} = \left[\frac{-2+(x_1-\theta)^2}{(1+(x_1-\theta)^2)^2} + \frac{-2+(x_2-\theta)^2}{(1+(x_2-\theta)^2)^2}\right]|_{\theta=\theta_1} < 0.$$

所以当 $(x_1-x_2)^2 < 4$ 时， θ 的极大似然估计为 $\hat{\theta} = (X_1+X_2)/2$ 。

当 $(x_1-x_2)^2 \geq 4$ 时，该似然方程有三个实数根，分别为

$$\theta_1 = \frac{x_1+x_2}{2}, \quad \theta_2 = \frac{x_1+x_2+\sqrt{(x_1-x_2)^2-4}}{2},$$

$$\theta_3 = \frac{x_1+x_2-\sqrt{(x_1-x_2)^2-4}}{2}.$$

易证 θ_1 为极大值点，而 θ_2, θ_3 为拐点，所以当 $(x_1-x_2)^2 \geq 4$ 时， θ 的极大似然估计仍然为 $\hat{\theta} = (X_1+X_2)/2$ 。所以当 $n=2$ 时， θ 的极大似然估计存在且唯一，但似然方程有多个根。 ∎

37. 设 $Y_1, Y_2, \cdots, Y_n$ 为 *i.i.d.* 样本， Y_1 的密度函数为

$$P(Y_1=y_1) = \begin{cases} (\frac{\theta}{1+\theta})^{y_1}\frac{1}{1+\theta}, & y_1 = 0,1,\cdots \\ 0, & \text{其他}. \end{cases}$$

设 $X_1, \cdots, X_m$ 为 *i.i.d.* 样本， X_1 服从 Poisson 分布 $P(\theta)$, 且 X_i 和 Y_j 相互独立， $i = 1,\cdots,m, j=1,\cdots,n$, 其中未知参数 $\theta > 0$ 。

(1) 利用题中所给的 $n+m$ 个样本写出 θ 的似然方程;

(2) 证明 (1) 中的方程有且只有一个允许解。

解. (1) $(X,Y)^T=(X_1,\cdots,X_m,Y_1,Y_2,\cdots,Y_n)^T$ 的联合密度函数为

$$f(x,y)=\theta^{\sum_{j=1}^n y_j}(1+\theta)^{-\sum_{j=1}^n y_j-n}e^{-m\theta}\theta^{\sum_{i=1}^m x_i}/(\prod_{i=1}^m x_i!).$$

由 $\partial\log f/\partial\theta=0$ 可得 θ 的似然方程为

$$\frac{\sum_{i=1}^m x_i+\sum_{j=1}^n y_j}{\theta}-\frac{n+\sum_{j=1}^n y_j}{1+\theta}-m=0.$$

(2) 化简上式可得

$$m\theta^2+(m+n-\sum_{i=1}^m x_i)\theta-(\sum_{i=1}^m x_i+\sum_{j=1}^n y_j)=0,$$

令 $\Delta=(m+n-\sum_{i=1}^m x_i)^2+4m(\sum_{i=1}^m x_i+\sum_{j=1}^n y_j)$ ，则方程的解为

$$\begin{aligned}\theta_1 &= \frac{1}{2m}[-(m+n-\sum_{i=1}^m x_i)+\sqrt{\Delta}],\\ \theta_2 &= \frac{1}{2m}[-(m+n-\sum_{i=1}^m x_i)-\sqrt{\Delta}].\end{aligned}$$

由于 $\sqrt{\Delta}>|(m+n-\sum_{i=1}^m x_i)|$ ，所以 $\theta_1>0$ ， $\theta_2<0$ 。由于要求 $\theta>0$ ，因此 θ_1 为允许解，即该方程有且只有一个允许解。 ∎

38.* 设 $X_1,X_2,\cdots,X_n$ 为 *i.i.d.* 样本， X_1 的分布密度函数为 $f(x_1,\theta)=\frac{9}{10}\frac{1}{\sigma}\varphi(\frac{x_1-\mu}{\sigma})+\frac{1}{10}\varphi(x_1-\mu)$, 其中 $\varphi(.)$ 是标准正态的密度函数， $\mu\in R,\sigma^2>0$ 。证明： (μ,σ^2) 的极大似然估计不存在 (提示：证当 $\mu=x_k$, $k=1,2,\cdots,n$ 且 $\sigma^2\longrightarrow 0$ 时，似然函数 $L(\mu,\sigma^2)\longrightarrow\infty$) 。

证明. $X=(X_1,\cdots,X_n)^T$ 的似然函数为

$$L(x;\mu,\sigma^2)=\prod_{i=1}^n f(x_i;\mu,\sigma^2),$$

其中

$$f(x_i;\mu,\sigma^2)=\frac{9}{10}\{\frac{1}{\sqrt{2\pi}\sigma}\exp[-\frac{(x_i-\mu)^2}{2\sigma^2}]\}+\frac{1}{10}\{\frac{1}{\sqrt{2\pi}}\exp[-\frac{(x_i-\mu)^2}{2}]\},\quad i=1,2,\cdots,n.$$

设 X_k 的观察值为 x_k $(1\le k\le n)$ ，今取 $\mu=x_k$ ，则当 $\sigma^2\to 0$ 时有

$$f(x_k;x_k,\sigma^2)=\frac{9}{10}\frac{1}{\sqrt{2\pi}\sigma}+\frac{1}{10}\frac{1}{\sqrt{2\pi}}\to\infty.$$

对于 $i\ne k$ ，我们有

$$f(x_i;x_k,\sigma^2)=\frac{9}{10}\frac{1}{\sqrt{2\pi}\sigma}\exp\{-\frac{(x_i-x_k)^2}{2\sigma^2}\}+\frac{1}{10}\frac{1}{\sqrt{2\pi}}\exp\{-\frac{(x_i-x_k)^2}{2}\}\ne 0,$$

所以当 $\mu=x_k$ 且 $\sigma^2\to 0$ 时， $L(x;\mu,\sigma^2)\to\infty$ 。所以 (μ,σ^2) 的 MLE 不存在。 ∎

39. 设 $X_{i1},\cdots,X_{ir}$ 为 *i.i.d.* 样本， $X_{i1}\sim N(\mu_i,\sigma^2),i=1,2,\cdots,n$ ，且当 $i\ne j$ 时 X_{is} 与 X_{jt} 相互独立。求 $(\mu_1,\cdots,\mu_n;\sigma^2)$ 的 MLE 。

解. 因为 $X_{i1},\cdots,X_{ir}$ 为 *i.i.d.* 样本，且 $X_{i1}\sim N(\mu_i,\sigma^2)$ ，所以易得 μ_i 的极大似然估计为 $\hat{\mu}_i=(1/r)\sum_{j=1}^r X_{ij}$ ，并记为 $\bar{X}_{i\cdot}$ 。又因为

$$f(x_{11},\cdots,x_{nr})=(\frac{1}{\sqrt{2\pi}\sigma})^{nr}\exp\{-\frac{1}{2\sigma^2}\sum_{i=1}^n\sum_{j=1}^r(x_{ij}-\mu_i)^2\},$$

将 $\hat{\mu}_i=(1/r)\sum_{j=1}^r x_{ij}=\bar{x}_{i\cdot},\ i=1,2,\cdots,n$ 代入上式，则由 $\partial\log f/\partial\sigma^2=0$ 可得

$$\sigma^2=\frac{1}{rn}\sum_{i=1}^n\sum_{j=1}^r(x_{ij}-\bar{x}_{i\cdot})^2.$$

所以 $(\mu_1,\cdots,\mu_n,\sigma^2)$ 的极大似然估计为

$$(\bar{X}_{1\cdot},\cdots,\bar{X}_{n\cdot};\ \ \frac{1}{rn}\sum_{i=1}^n\sum_{j=1}^r(X_{ij}-\bar{X}_{i\cdot})^2)\ \ \text{其中}\ \ \bar{X}_{i\cdot}=\frac{1}{r}\sum_{j=1}^r X_{ij}.$$

40. 设 $X_1,X_2,\cdots,X_n$ 为 *i.i.d.* 样本， $X_1\sim N(\mu_1,\sigma_1^2)$; $Y_1,\cdots,Y_m$ 为 *i.i.d.* 样本， $Y_1\sim N(\mu_2,\sigma_2^2)$ 。求 $c=\mu_1-\mu_2$ 的 MLE ；若样本容量之和 $n+m$ 固定， σ_1 和 σ_2 已知，如何调整 n 和 m 的比例，使 c 的 MLE 的均方误差最小？

解. $(X,Y)^T=(X_1,\cdots,X_n,Y_1,\cdots,Y_m)^T$ 的对数似然函数为

$$L(\mu_1,\mu_2,\sigma_1^2,\sigma_2^2)=-\frac{1}{2\sigma_1^2}\sum_{i=1}^n(x_i-\mu_1)^2-\frac{1}{2\sigma_2^2}\sum_{j=1}^m(y_j-\mu_2)^2-\frac{n}{2}\log(2\pi\sigma_1^2)-\frac{m}{2}\log(2\pi\sigma_2^2),$$

由

$$\frac{\partial L}{\partial\mu_1}=\frac{1}{\sigma_1^2}\sum_{i=1}^n(x_i-\mu_1)=0,\ \ \frac{\partial L}{\partial\mu_2}=\frac{1}{\sigma_2^2}\sum_{j=1}^m(y_j-\mu_2)=0,$$

可得 $\mu_1=\bar{x},\ \mu_2=\bar{y}$ 。所以 $\mu_1,\ \mu_2$ 的极大似然估计为 $\mu_1=\bar{X},\ \mu_2=\bar{Y}$ 。由极大似然估计的不变原理可知， $c=\mu_2-\mu_1$ 的极大似然估计为 $\hat{c}=\hat{\mu}_2-\hat{\mu}_1=\bar{X}-\bar{Y}$ 。由假设可知 $\bar{X}-\bar{Y}\sim N(\mu_1-\mu_2,\ \sigma_1^2/n+\sigma_2^2/m)$ ，且 $\mathrm{E}(\hat{c})=c$ ，所以均方误差 $\mathrm{MSE}(\hat{c})=\mathrm{Var}(\hat{c})=\sigma_1^2/n+\sigma_2^2/m$ 。记 $g(m,n)=\sigma_1^2/n+\sigma_2^2/m$ ，其中 $m+n=N$ 为常数。要求 $g(m,n)$ 在 $m+n=N$ 条件下的极小值，即求

$$g^*(m,n,\lambda)=\frac{1}{n}\sigma_1^2+\frac{1}{m}\sigma_2^2-\lambda(n+m-N)$$

的极小值。由于

$$\frac{\partial g^*}{\partial m}=-\frac{1}{m^2}\sigma_2^2-\lambda=0,\ \ \frac{\partial g^*}{\partial n}=-\frac{1}{n^2}\sigma_1^2-\lambda=0,\ \ \frac{\partial g^*}{\partial\lambda}=N-(m+n)=0,$$

因此有

$$m=\frac{\sigma_2}{\sqrt{-\lambda}},\ \ n=\frac{\sigma_1}{\sqrt{-\lambda}}.$$

所以当 $n/m=\sigma_1/\sigma_2$ 时， c 的极大似然估计的均方误差最小。 ∎

41. 设观察样本 $X_1,X_2,\cdots,X_n$ 满足关系 $X_i=X_{i-1}\theta+u_i,\ i=1,\cdots,n$ ， $X_0=0$ 。其中 $u_1,u_2,\cdots,u_n$ 为 *i.i.d.* 未知随机变量， $u_1\sim N(0,\sigma^2)$ ，求 θ 和 σ^2 的 MLE 。

解. 由题意可知

$$U \triangleq \begin{pmatrix} u_1 \\ \vdots \\ u_n \end{pmatrix} = \begin{pmatrix} 1 & 0 & 0 & \cdots & 0 & 0 \\ -\theta & 1 & 0 & \cdots & 0 & 0 \\ 0 & -\theta & 1 & \cdots & 0 & 0 \\ \cdots & \cdots & \cdots & \cdots & \cdots & \cdots \\ 0 & 0 & 0 & \cdots & -\theta & 1 \end{pmatrix} \begin{pmatrix} X_1 \\ \vdots \\ X_n \end{pmatrix} \triangleq MX.$$

其中 $X = (X_1, \cdots, X_n)^T$,则 $X = M^{-1}U$ 。因为 $U \sim N(0, \sigma^2 I_n)$,所以 $X \sim N(0, \sigma^2 M^{-2})$ 。所以 X 的密度函数为

$$\begin{aligned} f(x;\theta,\sigma^2) &= (\frac{1}{\sqrt{2\pi}})^n |\sigma^2 M^{-2}|^{-\frac{1}{2}} \exp\{-\frac{1}{2}x^T(\sigma^2 M^{-2})^{-1}x\} \\ &= (\frac{1}{\sqrt{2\pi}})^n \sigma^{-n} \exp\{-\frac{1}{2\sigma^2}x^T M^2 x\}. \end{aligned}$$

又因为 $Mx = (x_1, x_2 - \theta x_1, \cdots, x_n - \theta x_{n-1})^T$ ，所以 $x^T M^2 x = \sum_{i=1}^n (x_i - \theta x_{i-1})^2$ (其中 $x_0 = 0$) 。所以 X 的对数似然函数为

$$L(\theta, \sigma^2) = -\frac{n}{2}\log(\sigma^2) - \frac{1}{2\sigma^2}\sum_{i=1}^n (x_i - \theta x_{i-1})^2 - \frac{n}{2}\log(2\pi).$$

由于

$$\begin{aligned} \frac{\partial L(\theta,\sigma^2)}{\partial \theta} &= \frac{1}{\sigma^2}\sum_{i=1}^n (x_i - \theta x_{i-1})x_{i-1} = 0, \\ \frac{\partial L(\theta,\sigma^2)}{\partial \sigma^2} &= -\frac{n}{2}\frac{1}{\sigma^2} + \frac{1}{2\sigma^4}\sum_{i=1}^n (x_i - \theta x_{i-1})^2 = 0. \end{aligned}$$

因此有

$$\theta = \frac{\sum_{i=1}^n x_i x_{i-1}}{\sum_{i=1}^n x_{i-1}^2}, \quad \sigma^2 = \frac{1}{n}\sum_{i=1}^n (x_i - \theta x_{i-1})^2 = \frac{1}{n}\sum_{i=1}^n (x_i - \frac{\sum_{i=1}^n x_i x_{i-1}}{\sum_{i=1}^n x_{i-1}^2} x_{i-1})^2.$$

所以 θ 和 σ^2 的极大似然估计分别为

$$\hat{\theta}(X) = \frac{\sum_{i=1}^n X_i X_{i-1}}{\sum_{i=1}^n X_{i-1}^2}, \quad \hat{\sigma}^2(X) = \frac{1}{n}\sum_{i=1}^n (X_i - \frac{\sum_{i=1}^n X_i X_{i-1}}{\sum_{i=1}^n X_{i-1}^2} X_{i-1})^2. \qquad \blacksquare$$

42. 设 $X_1, X_2, \cdots, X_N$ 为 *i.i.d.* 样本， X_1 服从 Poisson 分布 $P(\lambda)$, $\lambda > 0$ 。若仅观察到 $X_1, X_2, \cdots, X_N$ 中前 n 个样本 $X_1, X_2, \cdots, X_n$ 的值，以及后面 $N - n$ 个样本的和 $\sum_{i=n+1}^N X_i = T$ ，求 λ 的 MLE 。

解. 因为 $X_1, \cdots, X_n \sim P(\lambda)$ 与 $T = \sum_{i=n+1}^N X_i \sim P((N-n)\lambda)$ 独立，所以 $X_1, \cdots, X_n, T$ 的联合密度函数为

$$\begin{aligned} f(x_1, \cdots, x_n, t; \lambda) &= \prod_{i=1}^n [e^{-\lambda}\lambda^{x_i}/x_i!] e^{-(N-n)\lambda} \cdot \frac{[(N-n)\lambda]^t}{t!} \\ &= e^{-N\lambda} \cdot \lambda^{t+\sum_{i=1}^n x_i} \cdot (N-n)^t / (t! \prod_{i=1}^n x_i!). \end{aligned}$$

由 $\partial \log f(x_1,\cdots,x_n,t;\lambda)/\partial\lambda = 0$ 可得 $\lambda = (\sum_{i=1}^n x_i + t)/N$ 。所以 λ 的极大似然估计为 $\hat{\lambda} = (\sum_{i=1}^n X_i + T)/N$ 。 ∎

43. 设某种家禽生下的蛋的数目是一个随机变量 N ，其中 $N \sim P(\lambda)$, λ 未知。若每个蛋能发育成小动物的概率是 p ，且各个蛋能否发育成小动物是彼此独立的；若记 M 为发育成小动物的个数。

(1) 求 (N,M) 的联合分布；

(2) 设 $(N_1,M_1),\cdots,(N_s,M_s)$ 是来自 (1) 中分布的 s 个随机样本，求参数 $\theta=(\lambda,p)$ 的 MLE 。

解. (1) 易见 $M|N$ 服从二项分布，所以

$$f(n,m;\theta) = f(m|n;p)f(n;\lambda), \quad \theta=(\lambda,p),$$

其中 $f(n;\lambda) = e^{-\lambda}\lambda^n/n!$, $f(m|n;p) = \binom{n}{m}p^m(1-p)^{n-m}$ ，所以

$$f(n,m;\theta) = \binom{n}{m}p^m(1-p)^{n-m}e^{-\lambda}\frac{\lambda^n}{n!}.$$

(2) 样本 $(N_1,M_1),\cdots,(N_s,M_s)$ 的对数似然函数为

$$L(\theta) = -s\lambda + \sum_{i=1}^s n_i\log\lambda + \sum_{i=1}^s m_i\log p + (\sum_{i=1}^s n_i - \sum_{i=1}^s m_i)\log(1-p) + \text{常数项},$$

由于

$$\begin{aligned}\frac{\partial L(\theta)}{\partial\lambda} &= -s + \frac{1}{\lambda}\sum_{i=1}^s n_i = 0,\\ \frac{\partial L(\theta)}{\partial p} &= \frac{1}{p}\sum_{i=1}^s m_i - \frac{1}{1-p}(\sum_{i=1}^s n_i - \sum_{i=1}^s m_i) = 0.\end{aligned}$$

因此有 $\lambda = \bar{n}$, $p = \bar{m}/\bar{n}$ ，其中 $\bar{n} = (1/s)\sum_{i=1}^s n_i$; $\bar{m} = (1/s)\sum_{i=1}^s m_i$ 。所以 λ, p 的极大似然估计分别为

$$\hat{\lambda} = \bar{N}, \quad \hat{p} = \frac{\bar{M}}{\bar{N}}.$$ ∎

44. 设 $X_1,X_2,\cdots,X_n$ 为 *i.i.d.* 样本， $X_1 \sim \theta e^{-\theta x_1}I\{x_1>0\}$ ，其中未知参数 $\theta>0$ 。若仅观察到 $X_1,X_2,\cdots,X_m$ 的值，以及 $X_i \ge \tau, i=m+1,\cdots,n,(m<n)$ ；试求 θ 的 MLE 。

解. $X=(X_1,X_2,\cdots,X_n)$ 的联合密度函数为

$$f(x;\theta) = \prod_{i=1}^m f(x_i)\cdot\prod_{i=m+1}^n[1-F(\tau)].$$

其中 $f(x_i)$ 是 X_i 的密度函数， $i=1,\cdots,m$ ； $F(\tau)=P(X_1\le\tau)$ 是 X_1 的分布函数。因为 $1-F(\tau)=e^{-\theta\tau}$ ，所以

$$\begin{aligned}f(x;\theta) &= \theta^m e^{-\theta\sum_{i=1}^m x_i}e^{-(n-m)\theta\tau},\\ L(\theta) &= m\log\theta - [\sum_{i=1}^m x_i + (n-m)\tau]\theta.\end{aligned}$$

由 $\partial L(\theta)/\partial\theta = 0$ 可得 $\theta = m[(n-m)\tau + \sum_{i=1}^{m} x_i]^{-1}$ 。又因为 $\partial^2 L(\theta)/\partial\theta^2 = -m/\theta^2 < 0$ ，所以 θ 的极大似然估计为 $\hat{\theta} = m[(n-m)\tau + \sum_{i=1}^{m} X_i]^{-1}$ 。 ∎

45.* 设随机变量 X 服从超几何分布 $HG(b,N,n)$ ，即 $P(X=x) = \binom{b}{x}\binom{N-b}{n-x}/\binom{N}{n}$ ，其中 N, n 均为非负整数。求证：当 N, n 固定时，参数 b 具有以下极大似然估计

$$b(X) = \begin{cases} [\frac{X}{n}(N+1)], & \frac{X}{n}(N+1) \bar{\in} N \\ \frac{X}{n}(N+1) \quad 或 \quad \frac{X}{n}(N+1)-1, & \frac{X}{n}(N+1) \in N \end{cases}$$

其中 $[\cdot]$ 表示整数部分 (提示：求 $L(b+1,\ x)/L(b,\ x)$ ，其中 $L(b,\ x)$ 为关于 b 的似然函数) 。

解. 在超几何分布中， $\max(b,n) \le N,\ \ 0 \le \min(b,n)$ 。记 $P(X=k) = p(k)$ ，在给定了参数 N 和 n 时，视 b 为未知，则超几何分布的密度函数为

$$p(k) = \binom{b}{k}\binom{N-b}{n-k}\binom{N}{n}^{-1}, \quad k = 0,1,\cdots,\min(N,b).$$

似然函数为 $L(b,x) = \binom{b}{x}\binom{N-b}{n-x}\binom{N}{n}^{-1}$ ，因为

$$\begin{aligned} \frac{L(b+1,x)}{L(b,x)} &= \binom{b+1}{x}\binom{N-b-1}{n-x}\left[\binom{b}{x}\binom{N-b}{n-x}\right]^{-1} \\ &= \frac{b+1}{b+1-x}\cdot\frac{N-b-n+x}{N-b}. \end{aligned}$$

若令 $\frac{L(b+1,x)}{L(b,x)} > 1$ ，则有 $b < (x/n)(N+1)-1$ 。因此，若 $b < (x/n)(N+1)-1$ ，则 $L(b,x)$ 为 b 的增函数；反之，若 $b > (x/n)(N+1)-1$ ，则 $L(b,x)$ 为 b 的减函数。并且，若 $b = (x/n)(N+1)-1$ ，则 $L(b,x) = L(b+1,x)$ 。所以当 $(x/n)(N+1)$ 为整数时， b 的 MLE 为 $\hat{b} = (X/n)(N+1)-1$ 或 $(X/n)(N+1)$ ；当 $(x/n)(N+1)$ 不是整数时，可令 $\hat{b} = [(x/n)(N+1)]$ ，则在此时 $L(\hat{b})$ 达到 $L(b)$ 的最大值。所以

$$b(X) = \begin{cases} [\frac{X}{n}(N+1)], & 当\ \ \frac{X}{n}(N+1)\ \ 不是整数, \\ \frac{X}{n}(N+1)\ 或\ \frac{X}{n}(N+1)-1 & 当\ \ \frac{X}{n}(N+1)\ \ 是整数. \end{cases}$$ ∎

46. 设 $X_1, X_2, \cdots, X_n$ 为 *i.i.d.* 样本， X_1 服从几何分布，即 $P(X_1 = k) = \theta^{k-1}(1-\theta), k = 1,2,\cdots$ 。若仅观察到满足以下条件的样本 $Y_1, Y_2, \cdots, Y_n$ ：当 $X_i \le r$ 时， $Y_i = X_i$ ；当 $X_i \ge r+1$ 时，则 $Y_i = r+1$ ， $i = 1,2,\cdots,n$ 。若 r 为某个固定的正整数，且共有 m 个样本 (可设最后 m 个样本) 的值为 $r+1,\ m \le n$ ，求 θ 的 MLE 。

解. 不妨设前 $n-m$ 个样本的值小于 $r+1$ ，则 $X_1, X_2, \cdots, X_n$ 的联合分布密度函数为

$$f(x_1,\cdots,x_n) = [\prod_{i=1}^{n-m}\theta^{x_i-1}(1-\theta)]\prod_{j=n-m+1}^{n} P(X_j \ge r+1).$$

而 $P(X_j \ge r+1) = \sum_{k=r+1}^{+\infty}\theta^{k-1}(1-\theta) = \theta^r$ ，因此有

$$f(x_1,\cdots,x_n) = \theta^{\sum_{i=1}^{n-m} x_i-(n-m)}(1-\theta)^{n-m}\theta^{mr}.$$

由于

$$\frac{\partial \log f}{\partial\theta} = \frac{\sum_{i=1}^{n-m} x_i - (n-m) + mr}{\theta} - \frac{n-m}{1-\theta} = 0$$

所以有 $\theta=(\sum_{i=1}^{n-m}x_i-(n-m)+mr)/(\sum_{i=1}^{n-m}x_i+mr)$ ，因此 θ 的极大似然估计为

$$\hat{\theta}(X)=\frac{\sum_{i=1}^{n-m}X_i-(n-m)+mr}{\sum_{i=1}^{n-m}X_i+mr}.$$

∎

47.★ 设 $(Y_1,Z_1),\cdots,(Y_n,Z_n)$ 为 $i.i.d.$ 样本， (Y_1,Z_1) 的密度函数为 $\lambda^{-1}\mu^{-1}e^{-y_1/\lambda}e^{-z_1/\mu}$. $I\{y_1>0\}I\{z_1>0\}$ ，其中 $\lambda>0,\mu>0$ ，求 (λ,μ) 的 MLE ，若

(1) 观测到的样本为 $(Y_1,Z_1),\cdots,(Y_n,Z_n)$ ；

(2) 观测到的样本不是 $(Y_1,Z_1),\cdots,(Y_n,Z_n)$ ，而是 $(X_1,\Delta_1),\cdots,(X_n,\Delta_n)$ ，其中 $X_i=\min(Y_i,Z_i)$ ； $\Delta_i=1$ 若 $X_i=Y_i$, $\Delta_i=0$ 若 $X_i=Z_i$, $i=1,2,\cdots,n$ (提示：密度函数可表示为 $f(x,\Delta;\lambda,\mu)=\frac{1}{\lambda^{\sum_{i=1}^n\Delta_i}}\frac{1}{\mu^{n-\sum_{i=1}^n\Delta_i}}\exp\{-(\frac{1}{\mu}+\frac{1}{\lambda})\sum_{i=1}^n x_i\}$ 。

解. (1) 样本的对数似然函数为

$$L(\mu,\lambda)=-n\log\lambda-n\log\mu-\sum_{i=1}^n y_i/\lambda-\sum_{i=1}^n z_i/\mu,$$

由

$$\frac{\partial L(\mu,\lambda)}{\partial\lambda}=-\frac{n}{\lambda}+\frac{\sum_{i=1}^n y_i}{\lambda^2}=0,\quad \frac{\partial L(\mu,\lambda)}{\partial\mu}=-\frac{n}{\mu}+\frac{\sum_{i=1}^n z_i}{\mu^2}0$$

可得 $\lambda=\sum_{i=1}^n y_i/n=\bar{y}$, $\mu=\sum_{i=1}^n z_i/n=\bar{z}$ 。所以 λ,μ 的极大似然估计分别为 $\hat{\lambda}=\bar{Y}$, $\hat{\mu}=\bar{Z}$.

(2) 我们先求 (X_1,Δ_1) 的联合分布密度函数。由 (X_1,Δ_1) 的定义易知：

当 $\Delta_1=0$ 时 $X_1=Z_1$ ，因此有

$$\begin{aligned}P(X_1\le x_1,\Delta_1=0) &= P(\min(Y_1,Z_1)\le x_1,Z_1\le Y_1)\\ &= P(Z_1\le x_1,Z_1\le Y_1)\\ &= \int_0^{x_1}\int_{z_1}^{\infty}\lambda^{-1}\mu^{-1}e^{-y_1/\lambda}e^{-z_1/\mu}dy_1dz_1\\ &= \frac{\lambda}{\mu+\lambda}\left[1-\exp\{-(\frac{1}{\mu}+\frac{1}{\lambda})x_1\}\right]\end{aligned}$$

该式对 x_1 求导可得

$$f_0(x_1,\Delta_1;\lambda,\mu)=\frac{1}{\mu}\exp\{-(\frac{1}{\mu}+\frac{1}{\lambda})x_1\}.$$

当 $\Delta_1=1$ 时 $X_1=Y_1$ ，类似地可得

$$P(X_1\le x_1,\Delta_1=1)=\frac{\mu}{\mu+\lambda}\left[1-\exp\{-(\frac{1}{\mu}+\frac{1}{\lambda})x_1\}\right].$$

该式对 x_1 求导可得

$$f_1(x_1,\Delta_1;\lambda,\mu)=\frac{1}{\lambda}\exp\{-(\frac{1}{\mu}+\frac{1}{\lambda})x_1\}.$$

因此 (X_1,Δ_1) 的联合密度函数可表示为

$$f(x_1,\Delta_1;\lambda,\mu) = \begin{cases}\frac{1}{\mu}\exp\{-(\frac{1}{\mu}+\frac{1}{\lambda})x_1\} & \Delta_1=0\\ \frac{1}{\lambda}\exp\{-(\frac{1}{\mu}+\frac{1}{\lambda})x_1\}, & \Delta_1=1\end{cases}$$

该式可进一步表示为

$$f(x_1,\Delta_1;\lambda,\mu)=\frac{1}{\lambda^{\Delta_1}}\frac{1}{\mu^{1-\Delta_1}}\exp\{-(\frac{1}{\mu}+\frac{1}{\lambda})x_1\}$$

从而观测样本 $(X_1,\Delta_1),\cdots,(X_n,\Delta_n)$ 的联合密度函数为

$$f(x,\Delta;\lambda,\mu)=\frac{1}{\lambda^{\sum_{i=1}^n\Delta_i}}\frac{1}{\mu^{n-\sum_{i=1}^n\Delta_i}}\exp\{-(\frac{1}{\mu}+\frac{1}{\lambda})\sum_{i=1}^n x_i\}$$

对数似然函数为

$$L(\lambda,\mu)=-n_1\log\lambda-(n-n_1)\log\mu-(\frac{1}{\mu}+\frac{1}{\lambda})\sum_{i=1}^n x_i$$

其中 $n_1=\sum_{i=1}^n\Delta_i$ 。由

$$\frac{\partial L(\lambda,\mu)}{\partial\lambda}=-\frac{n_1}{\lambda}+\frac{\sum_{i=1}^n x_i}{\lambda^2},\quad \frac{\partial L(\lambda,\mu)}{\partial\mu}=-\frac{n-n_1}{\mu}+\frac{\sum_{i=1}^n x_i}{\mu^2}$$

可得 λ 和 μ 的极大似然估计分别为

$$\hat\lambda=\sum_{i=1}^n X_i/n_1,\quad \hat\mu=\sum_{i=1}^n X_i/(n-n_1).$$ ∎

48. 设 Y 服从幂级数分布，即 $P(Y=y)=a_y\theta^y/c(\theta),\ y=0,1,2,\cdots$, 其中 $\theta>0,\{a_y\}$ 为非负序列且与 θ 无关。设 $Y_1,\cdots,Y_n$ 为 *i.i.d.* 样本， Y_1 服从上述幂级数分布。证明： θ 的极大似然估计 $\hat\theta$ 满足 $\bar Y=\hat\theta c'(\hat\theta)/c(\hat\theta)$ 。

证明. $Y=(Y_1,\cdots,Y_n)$ 的联合分布密度函数为

$$f(y;\theta)=\theta^{\sum_{i=1}^n y_i}\prod_{i=1}^n a_{y_i}\cdot c^{-n}(\theta)=\prod_{i=1}^n a_{y_i}\cdot[\frac{\theta^{\bar y}}{c(\theta)}]^n.$$

易见，求 θ 使 $f(y;\theta)$ 达到最大值等价于求 θ 使 $g(\theta)\triangleq\theta^{\bar y}/c(\theta)$ 达到最大值。由于

$$\frac{\partial\log g(\theta)}{\partial\theta}=\frac{\bar y}{\theta}-\frac{c'(\theta)}{c(\theta)}=0.$$

因此有 $\bar y=\theta c'(\theta)/c(\theta)$ 。所以 θ 的极大似然估计 $\hat\theta$ 满足方程 $\bar Y=\hat\theta c'(\hat\theta)/c(\hat\theta)$ 。 ∎

49. 设 $Y_1,\cdots,Y_n$ 为 *i.i.d.* 样本， Y_1 的密度函数为 $f(y_1,\theta)=K(\theta)g(y_1)I\{y_1\ge\theta\}$ ，其中 $\theta>0,\ g(\cdot)$ 为非负可积实函数。

(1) 证明 $K(\theta)$ 为 θ 的增函数;

(2) 试求参数 θ 的 MLE ;

(3) 若 Y_1 的密度函数为 $f(y_1,\theta)=L(\theta)g(y_1)I\{a\le y_1\le\theta\}$ ，其中 a 为常数，研究类似的问题。

解. (1) 由 $\int_\theta^\infty f(y_1;\theta)dy_1=\int_\theta^\infty K(\theta)g(y_1)dy_1=1$ 可得 $K(\theta)=[\int_\theta^\infty g(y_1)dy_1]^{-1}$ 。由于 $g(\cdot)$ 为非负可积实函数，所以对任意的 $\theta_2>\theta_1$ ，我们有

$$K(\theta_2)=[\int_{\theta_2}^\infty g(y_1)dy_1]^{-1}\ge[\int_{\theta_1}^\infty g(y_1)dy_1]^{-1}=K(\theta_1).$$

所以 $K(\theta)$ 为 θ 的增函数。

(2) $Y=(Y_1,\cdots,Y_n)$ 的联合分布密度函数为

$$f(y;\theta)=K^n(\theta)\prod_{i=1}^n g(y_i)\cdot I\{y_{(1)}\geq\theta\}.$$

易见, 求 θ 使 $f(y;\theta)$ 最大等价于求 θ 使 $K(\theta)$ 最大, 而 $K(\theta)$ 为 θ 的增函数且有 $\theta\leq y_{(1)}$ 。因此 $\theta=y_{(1)}$ 时 $K(\theta)$ 最大，所以 θ 的 MLE 为 $\hat{\theta}=Y_{(1)}$ 。

(3) 由 $\int_a^\theta f(y_1;\theta)dy_1=\int_a^\theta L(\theta)g(y_1)dy_1=1$ 可得 $L(\theta)=[\int_a^\theta g(y_1)dy_1]^{-1}$ 。由于 $g(\cdot)$ 为非负可积实函数，所以对任意的 $\theta_2>\theta_1$ ，我们有

$$L(\theta_2)=[\int_a^{\theta_2}g(y_1)dy_1]^{-1}\leq[\int_a^{\theta_1}g(y_1)dy_1]^{-1}=L(\theta_1).$$

所以 $L(\theta)$ 为 θ 的减函数。

$Y=(Y_1,\cdots,Y_n)$ 的联合分布密度函数为

$$f(y;\theta)=L^n(\theta)\prod_{i=1}^n g(y_i)I\{a\leq y_{(1)}\leq y_{(n)}\leq\theta\}.$$

易见, 求 θ 使 $f(y;\theta)$ 最大等价于求 θ 使 $L(\theta)$ 最大, 而 $L(\theta)$ 为 θ 的减函数且有 $\theta\geq y_{(n)}$ 。因此 $\theta=y_{(n)}$ 时 $L(\theta)$ 最大，所以 θ 的 MLE 为 $\hat{\theta}=Y_{(n)}$ 。 ∎

50. 设 $X_1,\cdots,X_n$ 为 *i.i.d.* 样本，当 X_1 的密度函数为下列各种情况时，求相应参数的矩估计

(1) $X_1\sim 2(\theta-x_1)/\theta^2 I\{0\leq x_1\leq\theta\};\quad\theta>0;$
(2) $X_1\sim\theta(\theta+1)x_1^{\theta-1}(1-x_1)I\{0\leq x_1\leq 1\};$
(3) $X_1\sim\frac{1}{2}(\theta x_1+1)I\{-1\leq x_1\leq 1\};$
(4) $X_1\sim\theta^{-1}x_1^{-(1+1/\theta)};\ x_1>1;\quad 0<\theta<1;$
(5) $X_1\sim 2\theta^2/(x_1+\theta)^3 I\{x_1\geq 0\}$ 。

解. (1) 因为

$$\mathrm{E}X_1=\int_0^\theta x_1\cdot 2(\theta-x_1)\theta^{-2}dx_1=\frac{1}{3}\theta.$$

所以由 $\hat{\theta}/3=\bar{X}$ 可得 θ 的矩估计为 $\hat{\theta}(X)=3\bar{X}$ 。

(2) 因为

$$\mathrm{E}X_1=\int_0^1 x_1\cdot\theta(\theta+1)x_1^{\theta-1}(1-x_1)dx_1=\frac{\theta}{\theta+2}.$$

所以由 $\hat{\theta}/(\hat{\theta}+2)=\bar{X}$ 可得 θ 的矩估计为 $\hat{\theta}(X)=2\bar{X}/(1-\bar{X})$ 。

(3) 因为

$$\mathrm{E}(X_1)=\int_{-1}^1 x_1\cdot\frac{1}{2}(\theta x_1+1)dx_1=\int_{-1}^1(\frac{\theta}{2}x_1^2+\frac{1}{2}x_1)dx_1=\frac{\theta}{3}.$$

所以由 $\hat{\theta}/3=\bar{X}$ 可得 θ 的矩估计为 $\hat{\theta}(X)=3\bar{X}$ 。

(4) 因为

$$\mathrm{E}X_1=\int_1^{\infty}x_1\theta^{-1}x_1^{-(1+\theta^{-1})}dx_1=\frac{1}{1-\theta}.$$

所以由 $(1-\hat{\theta})^{-1}=\bar{X}$ 可得 θ 的矩估计为 $\hat{\theta}(X)=1-1/\bar{X}$ 。

(5) 因为

$$\mathrm{E}X_1=\int_0^{\infty}x_1\cdot 2\theta^2/(x_1+\theta)^3dx_1=\theta.$$

所以 θ 的矩估计为 $\hat{\theta}(X)=\bar{X}$ 。 ∎

51. 设 $X_1,\cdots,X_n$ 为 $i.i.d.$ 样本，当 X_1 的密度函数为下列各种情况时，求相应双参数的矩估计

(1) $X_1\sim$ 指数分布 $\mu+\Gamma(\sigma^{-1},1)$ ；

(2) $X_1\sim\beta$ 分布 $BE(p,q)$ ；

(3) $X_1\sim$ 对数正态分布 $LN(\mu,\sigma^2)$: $\frac{1}{\sqrt{2\pi}\sigma}x_1^{-1}\exp\{-\frac{(\log x_1-\mu)^2}{2\sigma^2}\}I\{x_1\geq 0\}$ ；

(4) $X_1\sim$ Pareto 分布 $PR(\lambda,\theta)$: $\lambda\theta^{\lambda}/(x_1+\theta)^{\lambda+1}I\{x_1>0\}$ ；

(5) $X_1\sim$ Pascal 分布 $PA(\theta,r)$: $\binom{x_1-1}{r-1}\theta^r(1-\theta)^{x_1-r},x_1=r,r+1,\cdots,\theta\in(0,1),r$ 为正整数时。

解. 记 $\bar{X}=n^{-1}\sum_{i=1}^n X_i$, $S^2=n^{-1}\sum_{i=1}^n(X_i-\bar{X})^2$, $Q=n^{-1}\sum_{i=1}^n X_i^2$ 。

(1) 因为

$$\mathrm{E}(X_1)=\mu+\sigma,\quad \mathrm{Var}(X_1)=\sigma^2$$

所以有 $\bar{X}=\hat{\mu}+\hat{\sigma}$ ， $S^2=\hat{\sigma}^2$ ，因此 μ,σ 的矩估计分别为

$$\hat{\mu}=\bar{X}-S,\quad \hat{\sigma}=S.$$

(2) 因为

$$\mathrm{E}(X_1)=\frac{p}{p+q},\quad \mathrm{E}(X_1^2)=\frac{p(p+1)}{(p+q)(p+q+1)},$$

经简单计算可得 p, q 的矩估计分别为

$$\hat{p}=\frac{Q\bar{X}-\bar{X}^2}{\bar{X}^2-Q},\quad \hat{q}=\frac{(Q-\bar{X})(1-\bar{X})}{\bar{X}^2-Q}.$$

(3) 因为

$$\mathrm{E}(X_1)=e^{\mu+\frac{\sigma^2}{2}},\quad \mathrm{var}(X_1)=e^{2\mu+\sigma^2}(e^{\sigma^2}-1),$$

经简单计算可得 μ,σ^2 的矩估计分别为

$$\hat{\mu}=\log\bar{X}-\frac{1}{2}\log(\frac{S^2}{\bar{X}^2}+1)=\log\frac{\bar{X}^2}{\sqrt{\bar{X}^2+S^2}},\quad \hat{\sigma}^2=\log(\frac{S^2}{\bar{X}^2}+1).$$

(4) 因为

$$\mathrm{E}(X_1)=\frac{\theta}{\lambda-1},\quad \mathrm{E}(X_1^2)=\frac{2\theta^2}{(\lambda-1)(\lambda-2)},$$

经简单计算可得 λ, θ 的矩估计分别为

$$\hat{\lambda}=\frac{2(Q-\bar{X}^2)}{Q-2\bar{X}^2},\quad \hat{\theta}=\frac{\bar{X}Q}{Q-2\bar{X}^2}.$$

(5) 因为

$$\mathrm{E}(X_1)=\frac{r}{\theta},\quad \mathrm{Var}(X_1)=\frac{r(1-\theta)}{\theta^2},$$

经简单计算可得 $r,\ \theta$ 的矩估计分别为

$$\hat{r}=\mathrm{E}(X_1)=\frac{\bar{X}^2}{S^2+\bar{X}},\quad \hat{\theta}=\frac{\bar{X}}{S^2+\bar{X}}.$$

52. 设 $X_1,,\cdots,X_n$ 为 $i.i.d.$ 样本, X_1 的密度函数为 $P(X_1=k)=\frac{-1}{\log(1-p)}\frac{p^k}{k}, k=1,2,\cdots$, 其中 $0<p<1$ ，证明： p 的矩估计为 $\hat{p}=1-\frac{\bar{X}}{S^2+(\bar{X})^2}$, 其中

$$\bar{X}=\frac{1}{n}\sum_{i=1}^{n}X_i, S^2=\frac{1}{n}\sum_{i=1}^{n}(X_i-\bar{X})^2.$$

解. 因为

$$\mathrm{E}(X_1)=\frac{-1}{\log(1-p)}\cdot\frac{p}{1-p},\quad \mathrm{E}(X_1^2)=\frac{-1}{\log(1-p)}\cdot\frac{p}{(1-p)^2},$$

由此可得矩估计方程为

$$\bar{X}=\frac{-1}{\log(1-\hat{p})}\cdot\frac{\hat{p}}{1-\hat{p}},\quad S^2+\bar{X}^2=\frac{-1}{\log(1-\hat{p})}\cdot\frac{\hat{p}}{(1-\hat{p})^2}.$$

因此 p 的矩估计为 $\hat{p}=1-\bar{X}/(S^2+\bar{X}^2)$ 。 ∎

第四章　同变估计

1. 设 X_1, X_2, X_3 为 $i.i.d.$ 样本， X_1 服从位置参数分布族 $f(x_1-\theta)$ 。令

$$\delta(X_1,X_2,X_3)=\begin{cases} X_1, & X_3>0 \\ X_2, & X_3\le 0 \end{cases}$$

将 $\delta(X_1,X_2,X_3)$ 作为 θ 的一个估计，证明：当损失函数为 $L(\delta-\theta)$ 时， $\delta(X_1,X_2,X_3)$ 的风险函数与 θ 无关；但 $\delta(X_1,X_2,X_3)$ 不是 θ 的同变估计。

证明. $(X_1,X_2,X_3)^T$ 的联合分布密度函数为 $f(x_1,x_2,x_3;\theta)=\prod_{i=1}^3 f(x_i-\theta)$ 。因为损失函数

$$L(\delta-\theta)=L(X_1-\theta)\cdot I\{X_3>0\}+L(X_2-\theta)\cdot I\{X_3\le 0\},$$

其中 $I\{\cdot\}$ 是示性函数，所以 $\delta(X_1,X_2,X_3)$ 的风险函数为

$$\begin{aligned} R(\theta,\delta) &= \mathrm{E}_\theta[L(\delta-\theta)]=\int\int\int L(\delta-\theta)f(x_1,x_2,x_3;\theta)dx_1dx_2dx_3 \\ &= \int L(x_1-\theta)f(x_1-\theta)dx_1\cdot P(X_3>0) \\ &\quad +\int L(x_2-\theta)f(x_2-\theta)dx_2\cdot P(X_3\le 0), \end{aligned}$$

令 $y_1=x_1-\theta,\ y_2=x_2-\theta$ ，则风险函数

$$\begin{aligned} R(\theta,\delta) &= \int L(y_1)f(y_1)dy_1\cdot P(X_3>0)+\int L(y_2)f(y_2)dy_2\cdot P(X_3\le 0) \\ &= \int L(y_1)f(y_1)dy_1. \end{aligned}$$

该式与 θ 无关。另外，当 $X_3>0$ 时，取 $\theta=-2X_3$ 则有 $\delta(X_1-2X_3,X_2-2X_3,X_3-2X_3)=X_2-2X_3$ (因为 $X_3-2X_3<0$) ；但是 $\delta(X_1,X_2,X_3)-2X_3=X_1-2X_3\ne X_2-2X_3$ ，所以 $\delta(X_1,X_2,X_3)$ 不是 θ 的同变估计。 ∎

2. 设样本 $X=(X_1,\cdots,X_n)^T$ 服从位置参数分布族 $f(x_1-\theta,\cdots,x_n-\theta)$ 。 $T(X)$ 为 θ 的同变估计，取损失函数为 $L(\theta,d)=L(d-\theta)$ 。证明： $T(X)$ 的偏差、方差以及 $T(X)$ 的风险函数都与 θ 无关。

证明. 记样本 X 的分布密度函数为 $f(x-\theta\mathbf{1})=f(x_1-\theta,\cdots,x_n-\theta)$ ，其中 $\mathbf{1}=(1,\cdots,1)$ 。则 $T(X)$ 的偏差、方差以及 $T(X)$ 的风险函数分别为

$$\begin{aligned} \mathrm{bias}[T(X)] &= \mathrm{E}[T(X)]-\theta=\mathrm{E}[T(X)-\theta]=\mathrm{E}[T(X-\theta\mathbf{1})] \\ &= \int T(x-\theta\mathbf{1})f(x-\theta\mathbf{1})dx=\int T(y)f(y)dy, \\ \mathrm{Var}[T(X)] &= \mathrm{Var}[T(X)-\theta]=\mathrm{Var}[T(X-\theta\mathbf{1})] \\ &= \mathrm{E}T^2(X-\theta\mathbf{1})-[\mathrm{E}T(X-\theta\mathbf{1})]^2 \\ &= \int T^2(x-\theta\mathbf{1})f(x-\theta\mathbf{1})dx-\mathrm{bias}^2[T(X)] \end{aligned}$$

$$
\begin{aligned}
&= \int T^2(y)f(y)dy - \text{bias}^2(T), \\
R(\theta, T(X)) &= \mathrm{E}[L(T(X)-\theta)] = \mathrm{E}[L(T(X-\theta\mathbf{1}))] \\
&= \int L(T(x-\theta\mathbf{1}))f(x-\theta\mathbf{1})dx = \int L(T(y))f(y)dy.
\end{aligned}
$$

在上面的推导中，最后一步都用到了变换 $y_i = x_i - \theta,\ i = 1, 2, \cdots, n$ 。显然， $T(X)$ 的偏差、方差以及 $T(X)$ 的风险函数都与 θ 无关。 ∎

3. 设样本 $X = (X_1, \cdots, X_n)^T$ 服从位置参数分布族 $f(x_1-\theta, \cdots, x_n-\theta)$ 。若 $T(X)$ 为关于 θ 的充分统计量， $\hat{\theta}^*(X)$ 为 θ 的 Pitman 估计，证明： $\hat{\theta}^*(X)$ 是 $T(X)$ 的函数。

证明. 因为 $T(X)$ 是充分统计量，所以由因子分解定理知 $f(x_1-\theta, \cdots, x_n-\theta) = h(x)\cdot g(T(x), \theta)$ 。又因为 $\hat{\theta}^*(X)$ 为 θ 的 Pitman 估计，所以由 Pitman 公式可得

$$
\begin{aligned}
\hat{\theta}^*(x) &= \frac{\int_{-\infty}^{\infty} \theta f(x_1-\theta, \cdots, x_n-\theta)d\theta}{\int_{-\infty}^{\infty} f(x_1-\theta, \cdots, x_n-\theta)d\theta} \\
&= \frac{\int_{-\infty}^{\infty} \theta h(x)\cdot g(T(x), \theta)d\theta}{\int_{-\infty}^{\infty} h(x)\cdot g(T(x), \theta)d\theta} \\
&= \frac{\int_{-\infty}^{\infty} \theta \cdot g(T(x), \theta)d\theta}{\int_{-\infty}^{\infty} g(T(x), \theta)d\theta}.
\end{aligned}
$$

因此由上式可知 $\hat{\theta}^*(X)$ 为 $T(X)$ 的函数。 ∎

4. 设 $X_1, \cdots, X_n$ 为 *i.i.d.* 样本， X_1 服从均匀分布 $R(\theta-\frac{1}{2}, \theta+\frac{1}{2})$ ，其中 $\theta \in R$ 未知。在均方损失下，求 θ 的 MREE 。

解. 因为 $X = (X_1, \cdots, X_n)^T$ 服从位置参数分布族，并且其密度函数为

$$
f(x;\theta) = I\{\theta - \frac{1}{2} \le x_{(1)} \le x_{(n)} \le \theta + \frac{1}{2}\} = I\{x_{(n)} - \frac{1}{2} \le \theta \le x_{(1)} + \frac{1}{2}\},
$$

所以由 Pitman 积分公式可得 θ 的 MREE 为

$$
\hat{\theta} = \frac{\int_{X_{(n)}-\frac{1}{2}}^{X_{(1)}+\frac{1}{2}} \theta d\theta}{\int_{X_{(n)}-\frac{1}{2}}^{X_{(1)}+\frac{1}{2}} d\theta} = \frac{X_{(1)} + X_{(n)}}{2}.
$$

∎

5. 设 $X_1, \cdots, X_n$ 为 *i.i.d.* 样本， X_1 的密度函数为 $f(x_1, \theta) = \sqrt{\frac{2}{\pi}} e^{-\frac{(x_1-\theta)^2}{2}} I\{x_1 \ge \theta\}$ ，在均方损失下，求 θ 的 MREE 。

解. 因为 $X = (X_1, \cdots, X_n)^T$ 服从位置参数分布族，并且其密度函数为

$$
f(x_1, \cdots, x_n; \theta) = (\sqrt{\frac{2}{\pi}})^n \exp\{-\frac{\sum_{i=1}^n (x_i-\theta)^2}{2}\} I\{x_{(1)} \ge \theta\},
$$

所以由 Pitman 积分公式可得 θ 的 MREE 为

$$
\hat{\theta}(X) = \frac{\int_{-\infty}^{\infty} \theta \cdot \exp\{-\frac{\sum_{i=1}^n (X_i-\theta)^2}{2}\} I\{X_{(1)} \ge \theta\} d\theta}{\int_{-\infty}^{\infty} \exp\{-\frac{\sum_{i=1}^n (X_i-\theta)^2}{2}\} I\{X_{(1)} \ge \theta\} d\theta}
$$

$$
\begin{aligned}
&= \frac{\int_{-\infty}^{X_{(1)}} \theta \cdot \exp\{n\overline{X}\theta - \frac{n}{2}\theta^2\} d\theta}{\int_{-\infty}^{X_{(1)}} \exp\{n\overline{X}\theta - \frac{n}{2}\theta^2\} d\theta} \\
&= \overline{X} - \frac{\exp\{-\frac{n}{2}(X_{(1)} - \overline{X})^2\}}{\sqrt{n}\Phi(\sqrt{n}(X_{(1)} - \overline{X}))}
\end{aligned}
$$

其中 $\Phi(\cdot)$ 为标准正态分布的分布函数。 ∎

6. 设 $X_1, \cdots, X_n$ 为相互独立的样本， $X_i \sim N(\mu, \omega_i^{-1}\sigma^2)$ ， $i = 1, \cdots, n$ ，其中 ω_i, σ 已知。在均方损失下，求 μ 的 MREE 。

解. $X = (X_1, \cdots, X_n)^T$ 的密度函数为

$$
f(x;\mu) = (\frac{1}{\sqrt{2\pi}\sigma})^n (\prod_{i=1}^n \sqrt{\omega_i}) \cdot \exp\{-\frac{1}{2\sigma^2}\sum_{i=1}^n \omega_i x_i^2 + \frac{\mu}{\sigma^2}\sum_{i=1}^n \omega_i x_i - \frac{\mu^2}{2\sigma^2}\sum_{i=1}^n \omega_i\}.
$$

由指数族的性质可知, $T(X) = \sum_{i=1}^n \omega_i X_i$ 是完备的充分统计量。因为 $X_i \sim N(\mu, \omega_i^{-1}\sigma^2)$ ，且 $X_1, \cdots, X_n$ 相互独立，所以

$$
T = \sum_{i=1}^n \omega_i X_i \sim N(\sum_{i=1}^n \omega_i \mu, \sum_{i=1}^n \omega_i \sigma^2).
$$

今记 $M = \sum_{i=1}^n \omega_i$ ，则 $T^*(X) = M^{-1}T(X) = M^{-1}\sum_{i=1}^n \omega_i X_i$ 也是完备的充分统计量。容易验证， $T^*(x + \mathbf{1}\theta) = T^*(x) + \theta$ ，因而它是 μ 的同变估计；且有 $T^* \sim N(\mu, \sigma^2/M)$ ，所以 μ 的 MREE 为 $\hat{\mu}(X) = T^*(X) - \mathrm{E}_0(T^*) = T^*(X)$ 。

注. 本题亦可根据 Pitman 积分公式求解。因为 $X = (X_1, \cdots, X_n)^T$ 服从位置参数分布族，并且其密度函数可表示为

$$
f(x;\mu) = (\frac{1}{\sqrt{2\pi}\sigma})^n (\prod_{i=1}^n \sqrt{\omega_i}) \cdot \exp\{-\frac{1}{2\sigma^2}M(\mu - \frac{1}{M}\sum_{i=1}^n \omega_i x_i)^2 + \frac{1}{2\sigma^2}[\frac{1}{M}(\sum_{i=1}^n \omega_i x_i)^2 - \sum_{i=1}^n \omega_i x_i^2]\}.
$$

所以由 Pitman 积分公式可得 μ 的 MREE 为

$$
\hat{\mu} = \frac{\int_{-\infty}^{\infty} \mu f(X;\mu) d\mu}{\int_{-\infty}^{\infty} f(X;\mu) d\mu} = \frac{\int_{-\infty}^{\infty} \mu \cdot \exp\{-\frac{1}{2\sigma^2}M(\mu - T^*)^2\} d\mu}{\int_{-\infty}^{\infty} \exp\{-\frac{1}{2\sigma^2}M(\mu - T^*)^2\} d\mu},
$$

令 $u = \mu - T^*$ ，则

$$
\hat{\mu}(X) = \frac{\int_{-\infty}^{\infty} (u + T^*) \exp\{-\frac{1}{2\sigma^2}Mu^2\} du}{\int_{-\infty}^{\infty} \exp\{-\frac{1}{2\sigma^2}Mu^2\} du} = T^*(X).
$$

∎

7. 设 $X_1, \cdots, X_n$ 为 *i.i.d.* 样本， $X_1 \sim N(\mu, \sigma^2)$ ； $Y_1, \cdots, Y_m$ 为 *i.i.d.* 样本， $Y_1 \sim N(c\mu, \sigma^2)$ ；并且合样本独立， $c \neq 0, \sigma > 0$ 已知。在均方损失下，求 μ 的 MREE 。

解. 本题可应用上题的结果求解。令

$$
Z_i = \begin{cases} X_i, & i = 1, \cdots, n, \\ Y_{i-n}/c, & i = n+1, \cdots, m+n. \end{cases}
$$

则可认为 $Z_i \sim N(\mu, \omega_i^{-1}\sigma^2)$ ，且诸 Z_i 独立，其中当 $i = 1, \cdots, n$ 时， $\omega_i = 1$ ；当 $i = n+1, \cdots, n+m$ 时， $\omega_i = c^2$ 。因此由第 6 题的结论知

$$T = (\sum_{i=1}^{m+n} \omega_i)^{-1} \sum_{i=1}^{m+n} \omega_i Z_i = (n + mc^2)^{-1}(\sum_{i=1}^{n} X_i + c\sum_{j=1}^{m} Y_j)$$

是 μ 的 MREE 。 ∎

8. 设 $X_1, \cdots, X_n$ 为 *i.i.d.* 样本， X_1 的密度函数为 $f(x_1;\mu) = \frac{1}{2}e^{-|x_1-\mu|}$ ，其中 $\mu \in R$ 未知，在均方损失下，试求 μ 的 MREE 。

解. 由 Pitman 积分公式可知 μ 的 MREE 可表示为

$$\hat{\mu}(X) = \frac{\int_{-\infty}^{\infty} \mu \cdot e^{-\sum_{i=1}^{n}|X_i-\mu|} d\mu}{\int_{-\infty}^{\infty} e^{-\sum_{i=1}^{n}|X_i-\mu|} d\mu}.$$

我们分别计算上式分子和分母的积分。为了便于计算绝对值的积分，设样本的次序统计量为 $X_{(1)} < X_{(2)} < \cdots < X_{(n)}$ ，则分母的积分可表示为

$$A = \int_{-\infty}^{\infty} e^{-\sum_{i=1}^{n}|X_i-\mu|} d\mu = \sum_{k=0}^{n} \int_{X_{(k)}}^{X_{(k+1)}} e^{-\sum_{i=1}^{n}|X_{(i)}-\mu|} d\mu.$$

其中 $X_{(0)} = -\infty$ ， $X_{(n+1)} = \infty$ 。今计算积分 $A_k = \int_{X_{(k)}}^{X_{(k+1)}} e^{-\sum_{i=1}^{n}|X_{(i)}-\mu|} d\mu$ 。这时 $X_{(k)} < \mu < X_{(k+1)}$ ，因此有 $\sum\limits_{i=1}^{n}|X_{(i)}-\mu| = \sum\limits_{i=1}^{k}(\mu - X_{(i)}) + \sum\limits_{i=k+1}^{n}(X_{(i)}-\mu) = \sum\limits_{i=k+1}^{n} X_{(i)} - \sum\limits_{i=1}^{k} X_{(i)} + (2k-n)\mu$

$$\begin{aligned}
A_k &= \int_{X_{(k)}}^{X_{(k+1)}} \exp\{-\sum_{i=1}^{n}|X_{(i)}-\mu|\} d\mu \\
&= \int_{X_{(k)}}^{X_{(k+1)}} \exp\left\{-\left[\sum_{i=1}^{k}(\mu - X_{(i)}) + \sum_{i=k+1}^{n}(X_{(i)}-\mu)\right]\right\} d\mu \\
&= \int_{X_{(k)}}^{X_{(k+1)}} \exp\left\{-\left[\sum_{i=k+1}^{n} X_{(i)} - \sum_{i=1}^{k} X_{(i)} + (2k-n)\mu\right]\right\} d\mu \\
&= \frac{-1}{2k-n} \exp\left\{-\left[\sum_{i=1}^{k}(X_{(k+1)} - X_{(i)}) + \sum_{i=k+1}^{n}(X_{(i)} - X_{(k+1)})\right]\right\} \\
&+ \frac{1}{2k-n} \exp\left\{-\left[\sum_{i=1}^{k}(X_{(k)} - X_{(i)}) + \sum_{i=k+1}^{n}(X_{(i)} - X_{(k)})\right]\right\} \\
&= \frac{-1}{2k-n} \exp\left\{-\left[\sum_{i=1}^{k}(X_{(k+1)} - X_{(i)}) + \sum_{i=k+2}^{n}(X_{(i)} - X_{(k+1)})\right]\right\} \\
&+ \frac{1}{2k-n} \exp\left\{-\left[\sum_{i=1}^{k-1}(X_{(k)} - X_{(i)}) + \sum_{i=k+1}^{n}(X_{(i)} - X_{(k)})\right]\right\}.
\end{aligned}$$

注意，当 $k = n$ 时， $X_{(n+1)} = \infty$ ，所以上式第一项为零；而当 $k = 0$ 时， $X_{(0)} = -\infty$ ，

所以上式第二项为零，因此积分 A 可表示为

$$
\begin{aligned}
A &= \sum_{k=0}^{n-1}\frac{-1}{2k-n}\exp\left\{-\left[\sum_{i=1}^{k}(X_{(k+1)}-X_{(i)})+\sum_{i=k+2}^{n}(X_{(i)}-X_{(k+1)})\right]\right\}\\
&+ \sum_{k=1}^{n}\frac{1}{2k-n}\exp\left\{-\left[\sum_{i=1}^{k-1}(X_{(k)}-X_{(i)})+\sum_{i=k+1}^{n}(X_{(i)}-X_{(k)})\right]\right\}\\
&= \sum_{k=1}^{n}\frac{-1}{2k-2-n}\exp\left\{-\left[\sum_{i=1}^{k-1}(X_{(k)}-X_{(i)})+\sum_{i=k+1}^{n}(X_{(i)}-X_{(k)})\right]\right\}\\
&+ \sum_{k=1}^{n}\frac{1}{2k-n}\exp\left\{-\left[\sum_{i=1}^{k-1}(X_{(k)}-X_{(i)})+\sum_{i=k+1}^{n}(X_{(i)}-X_{(k)})\right]\right\}\\
&= \sum_{k=1}^{n}\frac{-2}{(n-2k)(n-2k+2)}\exp\left\{-\left[\sum_{i=1}^{k-1}(X_{(k)}-X_{(i)})+\sum_{i=k+1}^{n}(X_{(i)}-X_{(k)})\right]\right\}.
\end{aligned}
$$

同理，$\hat{\mu}(X)$ 分子的积分可表示为

$$
B=\int_{-\infty}^{\infty}\mu e^{-\sum_{i=1}^{n}|X_i-\mu|}d\mu=\sum_{k=0}^{n}\int_{X_{(k)}}^{X_{(k+1)}}\mu e^{-\sum_{i=1}^{n}|X_{(i)}-\mu|}d\mu.
$$

$$
\begin{aligned}
B_k &= \int_{X_{(k)}}^{X_{(k+1)}}\mu\exp\{-\sum_{i=1}^{n}|X_{(i)}-\mu|\}d\mu\\
&= \int_{X_{(k)}}^{X_{(k+1)}}\mu\exp\left\{-\left[\sum_{i=1}^{k}(\mu-X_{(i)})+\sum_{i=k+1}^{n}(X_{(i)}-\mu)\right]\right\}d\mu\\
&= \int_{X_{(k)}}^{X_{(k+1)}}\mu\exp\left\{-\left[\sum_{i=k+1}^{n}X_{(i)}-\sum_{i=1}^{k}X_{(i)}+(2k-n)\mu\right]\right\}d\mu\\
&= \frac{-1}{(2k-n)^2}\exp\left\{-\left[\sum_{i=1}^{k}(X_{(k+1)}-X_{(i)})+\sum_{i=k+1}^{n}(X_{(i)}-X_{(k+1)})\right]\right\}\\
&+ \frac{1}{(2k-n)^2}\exp\left\{-\left[\sum_{i=1}^{k}(X_{(k)}-X_{(i)})+\sum_{i=k+1}^{n}(X_{(i)}-X_{(k)})\right]\right\}\\
&+ \frac{-X_{(k+1)}}{(2k-n)}\exp\left\{-\left[\sum_{i=1}^{k}(X_{(k+1)}-X_{(i)})+\sum_{i=k+1}^{n}(X_{(i)}-X_{(k+1)})\right]\right\}\\
&+ \frac{X_{(k)}}{(2k-n)}\exp\left\{-\left[\sum_{i=1}^{k}(X_{(k)}-X_{(i)})+\sum_{i=k+1}^{n}(X_{(i)}-X_{(k)})\right]\right\}\\
&= \frac{-1}{(2k-n)^2}\exp\left\{-\left[\sum_{i=1}^{k}(X_{(k+1)}-X_{(i)})+\sum_{i=k+2}^{n}(X_{(i)}-X_{(k+1)})\right]\right\}\\
&+ \frac{1}{(2k-n)^2}\exp\left\{-\left[\sum_{i=1}^{k-1}(X_{(k)}-X_{(i)})+\sum_{i=k+1}^{n}(X_{(i)}-X_{(k)})\right]\right\}\\
&+ \frac{-X_{(k+1)}}{(2k-n)}\exp\left\{-\left[\sum_{i=1}^{k}(X_{(k+1)}-X_{(i)})+\sum_{i=k+2}^{n}(X_{(i)}-X_{(k+1)})\right]\right\}
\end{aligned}
$$

$$+ \quad \frac{X_{(k)}}{(2k-n)} \exp\left\{-\left[\sum_{i=1}^{k-1}(X_{(k)}-X_{(i)})+\sum_{i=k+1}^{n}(X_{(i)}-X_{(k)})\right]\right\}.$$

$$\begin{aligned}
B &= \sum_{k=0}^{n-1}\frac{-1}{(2k-n)^2}\exp\left\{-\left[\sum_{i=1}^{k}(X_{(k+1)}-X_{(i)})+\sum_{i=k+2}^{n}(X_{(i)}-X_{(k+1)})\right]\right\} \\
&+ \sum_{k=1}^{n}\frac{1}{(2k-n)^2}\exp\left\{-\left[\sum_{i=1}^{k-1}(X_{(k)}-X_{(i)})+\sum_{i=k+1}^{n}(X_{(i)}-X_{(k)})\right]\right\} \\
&+ \sum_{k=0}^{n-1}\frac{-X_{(k+1)}}{(2k-n)}\exp\left\{-\left[\sum_{i=1}^{k}(X_{(k+1)}-X_{(i)})+\sum_{i=k+2}^{n}(X_{(i)}-X_{(k+1)})\right]\right\} \\
&+ \sum_{k=1}^{n}\frac{X_{(k)}}{(2k-n)}\exp\left\{-\left[\sum_{i=1}^{k-1}(X_{(k)}-X_{(i)})+\sum_{i=k+1}^{n}(X_{(i)}-X_{(k)})\right]\right\} \\
&= \sum_{k=1}^{n}\frac{-1}{(2k-2-n)^2}\exp\left\{-\left[\sum_{i=1}^{k-1}(X_{(k)}-X_{(i)})+\sum_{i=k+1}^{n}(X_{(i)}-X_{(k)})\right]\right\} \\
&+ \sum_{k=1}^{n}\frac{1}{(2k-n)^2}\exp\left\{-\left[\sum_{i=1}^{k-1}(X_{(k)}-X_{(i)})+\sum_{i=k+1}^{n}(X_{(i)}-X_{(k)})\right]\right\} \\
&+ \sum_{k=1}^{n}\frac{-X_{(k)}}{(2k-2-n)}\exp\left\{-\left[\sum_{i=1}^{k-1}(X_{(k)}-X_{(i)})+\sum_{i=k+1}^{n}(X_{(i)}-X_{(k)})\right]\right\} \\
&+ \sum_{k=1}^{n}\frac{X_{(k)}}{(2k-n)}\exp\left\{-\left[\sum_{i=1}^{k-1}(X_{(k)}-X_{(i)})+\sum_{i=k+1}^{n}(X_{(i)}-X_{(k)})\right]\right\} \\
&= \sum_{k=1}^{n}\alpha_k\exp\left\{-\left[\sum_{i=1}^{k-1}(X_{(k)}-X_{(i)})+\sum_{i=k+1}^{n}(X_{(i)}-X_{(k)})\right]\right\}.
\end{aligned}$$

其中

$$\alpha_k = \frac{-2X_k}{(n-2k)(n-2k+2)} + \frac{4(n-2k+1)}{(n-2k)^2(n-2k+2)^2}. \qquad \blacksquare$$

9.* 设 $X_1,\cdots,X_n$ 为 *i.i.d.* 样本， X_1 服从指数分布 $f(x_1;\lambda,\mu)=\lambda e^{-\lambda(x_1-\mu)}I\{x_1\ge\mu\}$ ，其中 λ 已知， μ 为未知的位置参数。

(1) 在均方损失 $L(\mu,d)=(d-\mu)^2$ 下，求 μ 的 MREE ；

(2) 在绝对损失 $L(\mu,d)=|d-\mu|$ 下，证明： μ 的 MREE 为 $X_{(1)}-\ln 2/(n\lambda)$ (提示：直接用 MREE 的定义，求 d 使 $E_\mu[L(\mu,\ d)]$ 最小， (3) 和第 10 题亦类似) ；

(3) 若损失函数为 $L(\mu,d)=I\{|d-\mu|>A\}$ ，其中 A 为已知正数。证明： μ 的 MREE 为 $X_{(1)}-A$ 。

解. (1) 因为 $X_{(1)}$ 是完备的充分统计量，且 $X_{(1)}$ 为 μ 的同变估计，所以 μ 的 MREE 为 $\hat{\mu}(X)=X_{(1)}-\mathrm{E}_0(X_{(1)})=X_{(1)}-1/(n\lambda)$ 。

(2) 仿照原书定理 4.2.1 的证明方法。要求 μ 在绝对损失下的 MREE , 可设 $T^*=X_{(1)}-\varphi(Y)$, 并求 $\varphi(\cdot)$, 使得 T^* 在绝对损失下的风险函数最小, 其中 $Y=(X_2-X_1,\cdots,X_n-X_1)$

为最大不变量。这时，风险函数为

$$\begin{aligned} R(\mu, T^*) &= \mathrm{E}_\mu(L(\mu, T^*)) = \mathrm{E}_\mu|T^* - \mu| = \mathrm{E}_\mu|X_{(1)} - \varphi(Y) - \mu| \\ &= \mathrm{E}_0|X_{(1)} - \varphi(Y)| = \mathrm{E}_0\{\mathrm{E}_0[|X_{(1)} - \varphi(Y)| \mid Y]\}, \end{aligned}$$

在风险函数的条件期望中， Y 为已知，从而可将 $\varphi(Y)$ 视为常数。所以要求风险函数最小，只须在条件期望的内层期望中求常数 $\varphi(Y)$ (不妨记其为 a) ，使 $\mathrm{E}_0[|X_{(1)} - a| \ |Y]$ 达到最小。由于 $T = X_{(1)}$ 与 Y 独立，所以当 $\mu = 0$ 时 $T = X_{(1)}|Y$ 的条件密度函数为其无条件密度函数，即 $T \sim \Gamma(n\lambda, 1)$:

$$f(t) = n\lambda e^{-n\lambda t} I\{t \geq 0\},$$

所以

$$\begin{aligned} \mathrm{E}_0[|X_{(1)} - a| \ |Y] &= \int_0^a (a-t) n\lambda e^{-n\lambda t} dt + \int_a^\infty (t-a) n\lambda e^{-n\lambda t} dt \\ &= \mathrm{E}(a - T) + 2\int_a^\infty (t-a) n\lambda e^{-n\lambda t} dt = G(a). \end{aligned}$$

对上式关于 a 求导并令其为 0 ，即由 $G'(a) = 0$ 可得 $a = \ln 2/(n\lambda)$ 。又因为

$$G''(a) = \frac{d^2 \mathrm{E}_0[|X_{(1)} - a| \ |Y]}{da^2} = 2n\lambda e^{-n\lambda a} > 0,$$

所以 $\mathrm{E}_0[|X_{(1)} - a| \ |Y]$ 在 $a = \ln 2/(n\lambda)$ 处达到最小，从而 $R(\mu, T^*)$ 在 $\varphi(Y) = \ln 2/(n\lambda)$ 处达到最小，所以 μ 在绝对损失下的 MREE 为 $T^* = X_{(1)} - \ln 2/(n\lambda)$ 。

(3) 证明方法与 (2) 类似，要求 μ 的 MREE ，即要求 $\varphi(\cdot)$ ，使得 $T^* = X_{(1)} - \varphi(Y)$ 在损失函数 $L(\mu, d) = I\{|d - \mu| > A\}$ 下的风险函数最小。这时风险函数为

$$\begin{aligned} R(\mu, T^*) &= \mathrm{E}_\mu(L(\mu, T^*)) = \mathrm{E}_\mu[I\{|T^* - \mu| > A\}] \\ &= \mathrm{E}_\mu[I\{|X_{(1)} - \varphi(Y) - \mu| > A\}] \\ &= \mathrm{E}_0[I\{|X_{(1)} - \varphi(Y)| > A\}] \\ &= \mathrm{E}_0\{\mathrm{E}_0[I\{|X_{(1)} - \varphi(Y)| > A\} \mid Y]\}, \end{aligned}$$

同 (2) 一样，只须在条件期望的内层期望中求常数 $\varphi(Y)$ (不妨记其为 a) ，使 $\mathrm{E}_0[I\{|X_{(1)} - \varphi(Y)| > A\} \mid Y]$ 达到最小。而且由于 $T = X_{(1)}$ 与 Y 独立，所以当 $\mu = 0$ 时关于 $T = X_{(1)}|Y$ 的条件期望即为相应的无条件期望。因此有

$$\begin{aligned} & \mathrm{E}_0[I\{|X_{(1)} - \varphi(Y)| > A\} \mid Y] \\ = \ & P_0(|X_{(1)} - a| > A) = 1 - P(|X_{(1)} - a| \leq A) \\ = \ & 1 - P(a - A \leq X_{(1)} \leq a + A) = 1 - \int_{a-A}^{a+A} f(t) dt \end{aligned}$$

可知求 a 使 $\mathrm{E}_0[I\{|X_{(1)} - \varphi(Y)| > A\} \mid Y]$ 达到最小即求 a 使 $\int_{a-A}^{a+A} f(t)dt$ 最大。 因为 $T = X_{(1)} \sim \Gamma(n\lambda, 1)$ 的密度函数 $f(t)$ 是 $[0, \infty)$ 上的减函数，所以要使 $f(t)$ 在 $[a-A, a+A]$ 这个长度为 2A 的区间上积分最大，这个积分区间必为 $[0, 2A]$ ， 从而 $a - A = 0$ ，即 $a = A$ 。因此当 $a = A$ 时 $R(\mu, T^*)$ 达到最小，所以 μ 的 MREE 为 $T^* = X_{(1)} - A$ 。

注. 在 (2) 中，也可根据原书定理 1.1.1 求解 $\mathrm{E}_0[|X_{(1)}-a|\ |Y]=\mathrm{E}_0|X_{(1)}-a|$ 的最小值。这时 a 等于 $X_{(1)}$ 的分布 $\Gamma(n\lambda,1)$ 的中位数，即 $\int_0^a n\lambda e^{-n\lambda t}dt=1/2$ ，由此亦可得到 $a=\ln 2/(n\lambda)$ 。 ∎

10.★ 设 $X_1,\cdots,X_n$ 为 *i.i.d.* 样本， $X_1\sim N(\mu,\sigma^2)$ ，其中 $\mu\in R$ 未知， $\sigma^2>0$ 已知。若损失函数为

$$L(\mu,d)=L(\mu-d)=\begin{cases}-\alpha(\mu-d), & \mu<d\\ \beta(\mu-d), & \mu\geq d\end{cases}$$

其中 α, β 为正常数，求 μ 的 MREE 。

解. 因为 $T=\overline{X}$ 是完备的充分统计量且为 μ 的同变估计，所以要求 μ 的 MREE ，即求 $\varphi(\cdot)$ ，使得 μ 的同变估计 $T^*=\overline{X}-\varphi(Y)$ 在损失函数 $L(\mu,d)$ 下的风险函数最小。这时，风险函数为

$$\begin{aligned}R(\mu,T^*) &= \mathrm{E}_\mu(L(\mu,T^*))=\mathrm{E}_\mu[L(\mu-T^*)]\\ &= \mathrm{E}_\mu[L(\mu-(\overline{X}-\varphi(Y)))]=\mathrm{E}_0[L(\varphi(Y)-\overline{X})]\\ &= \mathrm{E}_0\{\mathrm{E}_0[L(\varphi(Y)-\overline{X})|Y]\}\end{aligned}$$

其中 $Y=(X_2-X_1,\cdots,X_n-X_1)$ 为最大不变量。在风险函数的条件期望中， Y 为已知，从而可将 $\varphi(Y)$ 视为常数。所以要求风险函数最小，只须在条件期望的内层期望中求常数 $\varphi(Y)$ (不妨记其为 a) ，使 $\mathrm{E}_0[L(\varphi(Y)-\overline{X})|Y]$ 达到最小。因为 $\overline{X}$ 与最大不变量 Y 独立，所以当 $\mu=0$ 时 $T=\overline{X}|Y$ 的条件密度函数为其无条件密度函数 $f(t)$ ，即 $\overline{X}\sim f(t)\sim N(0,\sigma^2/n)$ ，所以

$$\begin{aligned}\mathrm{E}_0[L(\varphi(Y)-\overline{X})|Y] &= \mathrm{E}_0[L(a-T)]=\int_{-\infty}^{\infty}L(a-t)f(t)dt\\ &= \int_{-\infty}^{a}\beta(a-t)f(t)dt+\int_{a}^{\infty}-\alpha(a-t)f(t)dt=G(a).\end{aligned}$$

对上式关于 a 求导并令其为 0 ，即由 $G'(a)=0$ 可得 $\Psi(a)=\alpha/(\alpha+\beta)$ 。其中 $\Psi(\cdot)$ 为 $N(0,\sigma^2/n)$ 的分布函数，而 $\Psi(x)=\Phi(\sqrt{n}x/\sigma)$ ， $\Phi(\cdot)$ 为标准正态分布的的分布函数分布函数。又因为 $G''(a)=(\alpha+\beta)f(a)>0$ ，所以当 $a=\Phi^{-1}(\sqrt{n}\alpha/(\alpha+\beta)\sigma)$ 时，$\mathrm{E}_0[L(\varphi(Y)-\overline{X})|Y]$ 达到最小值，从而 $R(\mu,T^*)$ 也达到最小值。所以 μ 的 MREE 为 $T^*=\overline{X}-\Phi^{-1}(\sqrt{n}\alpha/(\alpha+\beta)\sigma)$ 。 ∎

11.★ (1) 定义函数 $\phi(a)=\mathrm{E}[\rho(X-a)]$ ，其中 ρ 为 $(-\infty,+\infty)$ 上的凸函数。证明：若 ρ 为偶函数，且 X 的密度函数关于 $X=\mu$ 对称，则 $\phi(a)$ 在 $a=\mu$ 处达到最小值 (提示：对任意实数 c ， 先证 $\phi(\mu+c)=\phi(\mu-c)$ ，然后用 ρ 的凸性证 $\phi(\mu)\leq\phi(\mu+c)$) ；

(2) 设样本 $X=(X_1,\cdots,X_n)^T$ 服从位置参数分布族 $f(x_1-\mu,\cdots,x_n-\mu)$ 。取损失函数为 $L(\mu,d)=L(d-\mu)$ ，其中 $L(\cdot)$ 为凸的偶函数。若 $T_0(X)$ 为 μ 的同变估计，其密度函数关于 $\mu=0$ 对称，并假设 $T_0(X)$ 与 Y 独立，其中 $Y=(X_2-X_1,\cdots,X_n-X_1)$ ，则 $T_0(X)$ 为 μ 的 MREE 。

证明. (1) 设 X 的密度函数为 $g(x)$ ，则

$$\phi(\mu+c)=\int\rho(x-(\mu+c))g(x)dx=\int\rho(x-\mu-c)g(x)dx$$

令 $t=x-\mu$ ，则有

$$\phi(\mu+c)=\int\rho(t-c)g(t+\mu)dt=\int\rho(c-t)g(\mu-t)dt$$

其中上式用到了 $\rho(\cdot)$ 为偶函数以及 X 的密度函数关于 μ 的对称性, 即 $g(\mu+t)=g(\mu-t)$ 。在以上积分中，再令 $w=\mu-t$ ，则有

$$\phi(\mu+c)=\int\rho(c-\mu+w)g(w)dw=\int\rho(w-(\mu-c))g(w)dw=\phi(\mu-c)$$

因为 ρ 为凸函数，所以

$$\begin{aligned}\rho(x-\mu) &= \rho(\frac{1}{2}[x-(\mu-c)]+\frac{1}{2}[x-(\mu+c)])\\ &\le \frac{1}{2}\rho(x-(\mu-c))+\frac{1}{2}\rho(x-(\mu+c)).\end{aligned}$$

上式两边取积分可得 $\phi(\mu)\le\frac{1}{2}\phi(\mu-c)+\frac{1}{2}\phi(\mu+c)=\phi(\mu+c)$ 。 由 c 的任意性可知 $\phi(\mu)$ 是一切 $\phi(a)$ 的最小值，即 $a=\mu$ 时 $\phi(a)$ 达到最小值。

(2) 因为 $T_0(X)$ 为 μ 的同变估计, 所以可设 μ 的 MREE 为 $T^*(X)=T_0(X)-\varphi(Y)$ ，其中 $\varphi(\cdot)$ 为某一函数。 要求 μ 在损失函数 $L(\mu,d)$ 下的 MREE ，即求 $\varphi(\cdot)$ 使得 μ 的同变估计 $T^*(X)$ 在该损失函数下的风险最小。其中风险函数为

$$\begin{aligned}R(\mu,T^*) &= \mathrm{E}_\mu(L(\mu,T^*))=\mathrm{E}_\mu[L(T^*-\mu)]=\mathrm{E}_\mu[L(T_0-\varphi(Y)-\mu)]\\ &= \mathrm{E}_\mu[L(T_0(X-\mu)-\varphi(Y))]=\mathrm{E}_0[L(T_0(X)-\varphi(Y))]\\ &= \mathrm{E}_0\{\mathrm{E}_0[L(T_0(X)-\varphi(Y))|Y]\}\end{aligned}$$

在风险函数的条件期望中，Y 为已知, 从而可将 $\varphi(Y)$ 视为常数, 不妨记其为 a 。在内层期望 $\mathrm{E}_0[L(T_0(X)-\varphi(Y))|Y]=\mathrm{E}_0[L(T_0(X)-a)|Y]=\phi(a)$ 中，由于 $T_0(X)$ 与 Y 独立, 因此 $T_0(X)|Y$ 的分布就是 $T_0(X)$ 的分布, 而由假设 $T_0(X)$ 的分布关于 $\mu=0$ 对称, 又因为 $L(\cdot)$ 为凸的偶函数，所以由 (1) 的结论可知，当 $a=\mu=0$ 时 $\phi(a)=\mathrm{E}_0[L(T_0(X)-\varphi(Y))|Y]$ 达到最小，从而 $R(\mu,T^*)$ 达到最小。所以 $T^*=T_0$ 为 μ 的 MREE 。 ∎

12.★ 设样本 $X=(X_1,\cdots,X_n)^T$ 服从位置参数分布族 $f(x_1-\theta,\cdots,x_n-\theta)$ 。$T(X)$ 为位置参数 θ 的同变估计。证明: 在均方损失下，$T(X)$ 为 θ 的 MREE 的充要条件为 $T(X)$ 是 θ 的无偏估计, 并且满足 $\mathrm{E}_\theta[T(X)U(X)]=0,\ \forall\, U\in W$,其中 $W=\{U(X)|U(X)=U(X+c\mathbf{1}),\forall\, c,$ 且 $\mathrm{E}_\theta[U(X)]=0,\ \forall\ \theta\}$ 。

证明. 必要性. 设 $T_0(X)$ 为 θ 的某一同变估计, 则在均方损失之下，$T(X)=T_0(X)-\mathrm{E}_0(T_0|Y)$ 为 θ 的 MREE ，其中 $Y=(X_2-X_1,\cdots,X_n-X_1)$ 。所以

$$\mathrm{E}_\theta(T-\theta)=\mathrm{E}_\theta[T_0-\mathrm{E}_0(T_0|Y)-\theta]=\mathrm{E}_0[T_0-\mathrm{E}_0(T_0|Y)]=0.$$

即 T 是 θ 的无偏估计。另一方面，若 $U(X)\in W$ ，则有

$$\begin{aligned}\mathrm{E}_\theta[T(X)U(X)] &= \mathrm{E}_\theta\{[T_0-\mathrm{E}_0(T_0|Y)]U(X)\}\\ &= \mathrm{E}_\theta\{[T_0-\theta-\mathrm{E}_0(T_0|Y)+\theta]U(X)\}\\ &= \mathrm{E}_\theta\{[T_0-\theta-\mathrm{E}_0(T_0|Y)]U(X-\theta\mathbf{1})\}+\theta\mathrm{E}_\theta[U(X)]\\ &= \mathrm{E}_0\{[T_0-\mathrm{E}_0(T_0|Y)]U(X)\}+0\\ &= \mathrm{E}_0(T_0U)-\mathrm{E}_0[\mathrm{E}_0(T_0|Y)U(X)].\end{aligned}$$

由于 $U(X)\in W$,则对任意的 c ,有 $U(X_1,\cdots,X_n)=U(X_1+c,\cdots,X_n+c)$,所以取 $c=-X_1$ 可得 $U(X_1,\cdots,X_n)=U(0,X_2-X_1,\cdots,X_n-X_1)=U(Y)$ ，所以 $\mathrm{E}_0[T_0(X)|Y]U(Y)=\mathrm{E}_0[T_0(X)U(Y)|Y]$ ，这一结果代入上式可得

$$\begin{aligned}\mathrm{E}_\theta[T(X)U(X)] &= \mathrm{E}_0(T_0U)-\mathrm{E}_0\{\mathrm{E}_0[T_0(X)|Y]U(Y)\}\\ &= \mathrm{E}_0(T_0U)-\mathrm{E}_0\{\mathrm{E}_0[T_0(X)U(Y)|Y]\\ &= \mathrm{E}_0(T_0U)-\mathrm{E}_0[T_0(X)U(Y)].\end{aligned}$$

所以 $\mathrm{E}_\theta[T(X)U(Y)]=0,\ \forall\, U\in W$ 。

充分性. 若 $T(X)$ 是 θ 的无偏估计，且满足 $\mathrm{E}_\theta[T(X)U(X)]=0,\ \forall U\in W$ ，要证 $T(X)$ 是 θ 的 MREE 。今设 $T_1(X)$ 为 θ 的任一同变估计，则有

$$\begin{aligned}\mathrm{E}_\theta(T_1-\theta)^2 &= \mathrm{E}_\theta(T_1-T+T-\theta)^2\\ &= \mathrm{E}_\theta(T_1-T)^2+\mathrm{E}_\theta(T-\theta)^2+2\mathrm{E}_\theta[(T_1-T)(T-\theta)].\end{aligned}$$

下面证明 $\mathrm{E}_\theta[(T_1-T)(T-\theta)]=0$ 。由于 $T(X)-\theta=T(X-\theta\mathbf{1})$ ， $X-\theta\mathbf{1}\sim P_0$ 。同时由于 $T(X)$ 是 θ 的无偏估计，因此由 $\mathrm{E}_\theta[T(X)]=\theta$ 可知 $\theta=0$ 时有 $\mathrm{E}_0T=0$ 。因此有

$$\begin{aligned}\mathrm{E}_\theta[(T_1-T)(T-\theta)] &= \mathrm{E}_\theta[(T_1-\theta-(T-\theta))(T-\theta)]=\mathrm{E}_0[(T_1-T)T]\\ &= \mathrm{E}_0[(T_1-\mathrm{E}_0T_1-T+\mathrm{E}_0T_1)T]\\ &= \mathrm{E}_0[(T_1-\mathrm{E}_0T_1-T)T]+\mathrm{E}_0T_1\cdot\mathrm{E}_0T\\ &= \mathrm{E}_0[(T_1-\mathrm{E}_0T_1-T)T]=\mathrm{E}_0[U(X)T(X)]\end{aligned}$$

其中 $U(X)=T_1-\mathrm{E}_0T_1-T$ 。由同变性容易验证， $U(X+c\mathbf{1})=U(X),\ \forall\, c$ ，同时有 $\mathrm{E}_\theta[U(X)]=0,\ \forall\,\theta$ ，这是因为

$$\begin{aligned}\mathrm{E}_\theta[U(X)] &= \mathrm{E}_\theta[T_1-\theta-\mathrm{E}_0T_1-(T-\theta)]\\ &= \mathrm{E}_0[T_1-\mathrm{E}_0T_1-T]=\mathrm{E}_0T=0,\ \ \forall\,\theta.\end{aligned}$$

所以 $\mathrm{E}_\theta[U(X)]=0,\ \forall\,\theta$ ；因此 $U\in W$ 。从而由假设条件可知 $\mathrm{E}_\theta[(T_1-T)(T-\theta)]=\mathrm{E}_0[U(X)T(X)]=0$ ，因此有

$$\mathrm{E}_\theta(T_1-\theta)^2=\mathrm{E}_\theta(T_1-T)^2+\mathrm{E}_\theta(T-\theta)^2\geq\mathrm{E}_\theta(T-\theta)^2.$$

即对任意的 θ 都有 $R(\theta,T_1)\geq R(\theta,T)$ ，其中 $R(\theta,T)$ 是 $T(X)$ 在均方损失下的风险函数。所以 $T(X)$ 为 θ 的 MREE 。 ∎

13. 设 $X_1,\cdots,X_n$ 为 *i.i.d.* 样本，在均方损失下求 σ 的 MREE ： (1) $X_1\sim\Gamma(\frac{1}{\sigma},\nu)$, ν 已知； (2) X_1 服从 Weibull 分布，即 $f(x_1,\sigma)=\alpha\sigma^{-\alpha}x_1^{\alpha-1}\exp\{-x_1^\alpha/\sigma^\alpha\}$ ，其中 α 是已知的正整数。

解. (1) 由

$$X_1\sim\frac{1}{\Gamma(\nu)}\frac{1}{\sigma}\cdot(\frac{x_1}{\sigma})^{\nu-1}e^{-\frac{x_1}{\sigma}}I\{\frac{x_1}{\sigma}\geq 0\}$$

可知 X_1 服从尺度参数分布族。因为 $T=\sum_{i=1}^n X_i$ 为完备的充分统计量且为 σ 的同变估计，当 $\sigma=1$ 时， $T\sim\Gamma(1,n\nu)$ ，所以 σ 的 MREE 为 $\hat\sigma=\mathrm{E}_1(T)T/\mathrm{E}_1(T^2)=T/(n\nu+1)$ 。

(2) 由

$$X_1 \sim \frac{\alpha}{\sigma} \cdot (\frac{x_1}{\sigma})^{\alpha-1} e^{-(\frac{x_1}{\sigma})^\alpha} I\{\frac{x_1}{\sigma} \geq 0\}$$

可知 X_1 服从尺度参数分布族。因为 $\sigma = 1$ 时， $X_1^\alpha \sim \Gamma(1,1)$ ，所以 $T = \sum_{i=1}^n X_i^\alpha \sim \Gamma(1,n)$ 。又因为 T 为完备的充分统计量且 $T^{1/\alpha}$ 为 σ 的同变估计，所以 σ 的 MREE 为

$$\hat{\sigma} = \mathrm{E}_1(T^{\frac{1}{\alpha}})T^{\frac{1}{\alpha}}/\mathrm{E}_1(T^{\frac{2}{\alpha}}) = \frac{\Gamma(n+\frac{1}{\alpha})}{\Gamma(n+\frac{2}{\alpha})}T^{\frac{1}{\alpha}}. \qquad \blacksquare$$

14. 设 $X_1, \cdots, X_n$ 为相互独立的样本， $X_i \sim N(0, \omega_i^{-1}\sigma^2)$ ， $i = 1, \cdots, n$ ，其中 $\omega_i > 0$ 已知。在均方损失下，求 σ^2 的 MREE 。

解. $X = (X_1, \cdots, X_n)^T$ 的密度函数为

$$f(x;\sigma^2) = (\frac{1}{\sqrt{2\pi}\sigma})^n \prod_{i=1}^n \omega_i^{\frac{1}{2}} \times \exp\{-\frac{1}{2\sigma^2}\sum_{i=1}^n \omega_i x_i^2\}.,$$

由指数族的性质可知 $T = \sum_{i=1}^n \omega_i X_i^2$ 是完备的充分统计量。令 $Y_i = \omega_i^{\frac{1}{2}} X_i$, 则 $Y_1, \cdots, Y_n$ 为 *i.i.d.* 样本，且 $Y_1 \sim N(0, \sigma^2)$ ，所以 $T = \sum\limits_{i=1}^n \omega_i X_i^2 = \sum\limits_{i=1}^n Y_i^2 \sim \sigma^2\chi^2(n)$ 。又因为 T 是 σ^2 的相似同变估计，所以 σ^2 的 MREE 为 $\widehat{\sigma^2} = \mathrm{E}_1(T)T/\mathrm{E}_1(T^2) = T/(n+2)$ 。 $\blacksquare$

15. 设 $X_1, \cdots, X_n$ 为 *i.i.d.* 样本， $X_1 \sim R(\theta, k\theta)$, $k > 1$ 已知， $\theta > 0$ 未知，在均方损失下求 θ, θ^r 的 MREE 。

解. 由

$$X_1 \sim R(\theta, k\theta) \sim \frac{1}{\theta}\frac{1}{k-1} I\{1 \leq \frac{x_1}{\theta} \leq k\}$$

可知 X_1 服从尺度参数分布族。 $X = (X_1, \cdots, X_n)^T$ 的密度函数为

$$p(x;\theta) = \frac{1}{\theta^n} \cdot \frac{1}{(k-1)^n} I\{\theta \leq x_{(1)} \leq x_{(n)} \leq k\theta\}.$$

所以由 Pitman 积分公式可得 θ^r 的 MREE 为

$$\begin{aligned}
\widehat{\theta^r} &= \frac{\int_0^\infty \theta^{-(r+1)} p(X;\theta)d\theta}{\int_0^\infty \theta^{-(2r+1)} p(X;\theta)d\theta} = \frac{\int_{X_{(n)}/k}^{X_{(1)}} \theta^{-(n+r+1)}d\theta}{\int_{X_{(n)}/k}^{X_{(1)}} \theta^{-(n+2r+1)}d\theta} \\
&= \frac{n+2r}{n+r} \cdot \frac{X_{(1)}^{-(n+r)} - (X_{(n)}/k)^{-(n+r)}}{X_{(1)}^{-(n+2r)} - (X_{(n)}/k)^{-(n+2r)}}.
\end{aligned}$$

当 $r = 1$ 时有

$$\hat{\theta} = \frac{n+2}{n+1} \cdot \frac{X_{(1)}^{-(n+1)} - (X_{(n)}/k)^{-(n+1)}}{X_{(1)}^{-(n+2)} - (X_{(n)}/k)^{-(n+2)}}. \qquad \blacksquare$$

16. 设 $X_1, \cdots, X_n$ 为 *i.i.d.* 样本，在均方损失下求 θ 的 MREE ： (1) $X_1 \sim 3\theta^3/x_1^4 I\{x_1 \geq \theta > 0\}$ ； (2) $X_1 \sim 4x_1^3/\theta^4 I\{0 \leq x_1 \leq \theta\}$ 。

解. (1) 由

$$X_1 \sim f(x_1;\theta) = \frac{3}{\theta}\cdot(\frac{x_1}{\theta})^{-4} I\{\frac{x_1}{\theta} \geq 1\}$$

可知 X_1 服从尺度参数分布族。所以由 Pitman 积分公式可得 θ 的 MREE 为

$$\hat{\theta} = \frac{\int_0^\infty \theta^{-2}\prod_{i=1}^n f(X_i,\theta)d\theta}{\int_0^\infty \theta^{-3}\prod_{i=1}^n f(X_i,\theta)d\theta} = \frac{\int_0^{X_{(1)}} \theta^{3n-2}d\theta}{\int_0^{X_{(1)}} \theta^{3n-3}d\theta} = \frac{3n-2}{3n-1}X_{(1)}.$$

(2) 由

$$X_1 \sim f(x_1;\theta) = \frac{4}{\theta}\cdot(\frac{x_1}{\theta})^{3} I\{0 \leq \frac{x_1}{\theta} \leq 1\}$$

可知 X_1 服从尺度参数分布族。所以由 Pitman 积分公式可得 θ 的 MREE 为

$$\hat{\theta} = \frac{\int_0^\infty \theta^{-2}\prod_{i=1}^n f(X_i,\theta)d\theta}{\int_0^\infty \theta^{-3}\prod_{i=1}^n f(X_i,\theta)d\theta} = \frac{\int_{X_{(n)}}^\infty \theta^{-(4n+2)}d\theta}{\int_{X_{(n)}}^\infty \theta^{-(4n+3)}d\theta} = \frac{4n+2}{4n+1}X_{(n)}.$$

∎

17.★ 设样本 $X=(X_1,\cdots,X_n)^T$ 服从尺度参数分布族 $\frac{1}{\sigma^n}f(\frac{x_1}{\sigma},\cdots,\frac{x_n}{\sigma})$，其中 $\sigma>0$ 是未知的尺度参数。设 $T=T(X)$ 为 σ^r 的某一同变估计，损失函数取为 $L(\sigma,d)=|\frac{d}{\sigma^r}-1|$，其中 r 为某一正整数。假设 $T=T(X)|Z$ 的条件分布记为 $f(t|Z)$，其中 $Z=(\frac{X_1}{|X_1|},\frac{X_2}{X_1},\cdots,\frac{X_n}{X_1})$ 为最大不变量。证明：σ^r 的 MREE 为 $T^*(X)=T(X)/\varphi(Z)$，其中 $\varphi(Z)$ 满足以下关系式：$\int_0^{\varphi(Z)} tf(t|Z)dt = \int_{\varphi(Z)}^{+\infty} tf(t|Z)dt$ (提示：直接用 MREE 的定义证明)。

证明. 由假设，σ^r 的 MREE 记为 $T^*(X)=T(X)/\varphi(Z)$，要求 $\varphi(Z)$，使其风险函数 $R(\sigma^r,T^*)$ 达到最小，这时

$$\begin{aligned} R(\sigma^r,T^*) &= \mathrm{E}_\sigma[L(\sigma,T^*)] = \mathrm{E}_\sigma|\frac{T}{\sigma^r}\frac{1}{\varphi(Z)}-1| \\ &= \mathrm{E}_1|\frac{T}{\varphi(Z)}-1| = \mathrm{E}_1\{\mathrm{E}_1[|\frac{T}{\varphi(Z)}-1|\ |Z]\} \end{aligned}$$

在条件期望中，Z 为已知，所以可视 $\varphi(Z)$ 为“常数” a。内层期望为

$$\mathrm{E}_1[|\frac{t}{\varphi(Z)}-1||Z] = \int_0^{\varphi(Z)}(1-\frac{t}{\varphi(Z)})f(t|Z)dt + \int_{\varphi(Z)}^\infty(\frac{t}{\varphi(Z)}-1)f(t|Z)dt.$$

上式关于 $a=\varphi(Z)$ 求导并令其为 0，则有

$$\int_0^{\varphi(Z)}\frac{t}{\varphi^2(Z)}f(t|Z)dt - \int_{\varphi(Z)}^\infty \frac{t}{\varphi^2(Z)}f(t|Z)dt = 0.$$

所以 $\varphi(Z)$ 满足等式

$$\int_0^{\varphi(Z)} tf(t|Z)dt = \int_{\varphi(Z)}^\infty tf(t|Z)dt.$$

这就是要证的关系式。又因为 $\sigma>0$，必有 $\varphi(Z)>0$，所以

$$\frac{d^2\mathrm{E}_1[|\frac{t}{\varphi(Z)}-1||Z]}{d(\varphi(Z))^2} = \frac{2f(\varphi(Z)|Z)}{\varphi(Z)} > 0.$$

所以当 $\varphi(Z)$ 满足以上关系式时，$\mathrm{E}_\sigma[L(\sigma,T^*)]$ 达到最小值。 ∎

18. 设 $X_1,\cdots,X_n$ 为 $i.i.d.$ 样本，当损失函数取为 $L(\sigma,d)=|\frac{d}{\sigma}-1|$ 时，求 σ 的 MREE：(1) X_1 服从均匀分布 $R(0,\sigma)$； (2) $X_1\sim\frac{1}{\sigma}e^{-\frac{x_1}{\sigma}}I\{x_1\geq 0\}$ 。

解. (1) 利用第 17 题的结论。取 $T=X_{(n)}$ 。因为 $X_{(n)}$ 为完备的充分统计量，所以 $X_{(n)}$ 与 $Z=(\frac{X_1}{|X_1|},\frac{X_2}{X_1},\cdots,\frac{X_n}{X_1})$ 独立。所以 $T(X)|Z$ 的条件密度函数为 T 的无条件密度函数，即

$$f(t|Z)=f(t)=n\sigma^{-n}t^{n-1}\cdot I\{0<t<\sigma\}$$

$\varphi(Z)$ 可视为常数，记其为 a ，则它满足下式

$$\int_0^a tf(t)dt=\int_a^1 tf(t)dt.$$

其中 $f(t)$ 是 $\sigma=1$ 时 T 的密度函数。由上式易得 $a=2^{-\frac{1}{n+1}}$ ，所以 $T^*=T/a=2^{\frac{1}{n+1}}X_{(n)}$ 为 σ 的 MREE 。

(2) 因为 $T=\sum_{i=1}^n X_i$ 为完备的充分统计量，并且 $T\sim f(t)\sim\Gamma(1/\sigma,n)$ 。所以由第 17 题的结论和 (1) 的解法可知 σ 的 MREE 为 $\hat{\sigma}=T/a$ ，其中 a 为常数，且满足关系式

$$\int_0^a t\frac{1}{\Gamma(n)}e^{-t}t^{n-1}dt=\int_a^\infty t\frac{1}{\Gamma(n)}e^{-t}t^{n-1}dt.$$

其中 $f(t)=e^{-t}t^{n-1}/\Gamma(n)$ 是 $\sigma=1$ 时 T 的密度函数。由上式易得 $F(a)=\frac{1}{2}$ ，其中 $F(t)$ 为 $\Gamma(1,n+1)$ 的分布函数，即 a 为 $\Gamma(1,n+1)$ 的中位数。所以 σ 的 MREE 为 $\hat{\sigma}=\sum_{i=1}^n X_i/F^{-1}(0.5)$ 。 ∎

19.* 设样本 $X=(X_1,\cdots,X_n)^T$ 服从尺度参数分布族 $\frac{1}{\sigma^n}f(\frac{x_1}{\sigma},\cdots,\frac{x_n}{\sigma})$ ，其中 $\sigma>0$ 是未知的尺度参数。设 $\hat{\sigma}(X)$ 为 σ 的某一同变估计， $Z=(\frac{X_1}{|X_1|},\frac{X_2}{X_1},\cdots,\frac{X_n}{X_1})$ 为最大不变量，损失函数取为 $L(\sigma,d)=\frac{d}{\sigma}-\log\frac{d}{\sigma}-1$ ；求 σ 的 MREE ；并证明其唯一性，即 MREE 与 $\hat{\sigma}(X)$ 的选取无关 (提示：仿照定理 4.3.1 的证明) 。

解. 由引理 4.3.3 知， σ 的任一同变估计都可表示为 $\hat{\sigma}^*(X)=\hat{\sigma}(X)\varphi(Z)$ 。要求 $\varphi(Z)$ ，使 $\hat{\sigma}^*$ 的风险函数 $R(\sigma,\hat{\sigma}^*)=\mathrm{E}_\sigma[L(\sigma,\hat{\sigma}^*)]$ 最小，这时有

$$\begin{aligned}
R(\sigma,\hat{\sigma}^*) &= \mathrm{E}_\sigma[L(\sigma,\hat{\sigma}^*)]=\mathrm{E}_\sigma[\frac{\hat{\sigma}^*(X)}{\sigma}-\log\frac{\hat{\sigma}^*(X)}{\sigma}-1]\\
&= \mathrm{E}_\sigma[\hat{\sigma}(\frac{X}{\sigma})\varphi(Z)-\log[\hat{\sigma}(\frac{X}{\sigma})\varphi(Z)]-1]\\
&= \mathrm{E}_1[\hat{\sigma}(X)\varphi(Z)-\log\hat{\sigma}(X)-\log\varphi(Z)-1]\\
&= \mathrm{E}_1\{\mathrm{E}_1\{[\hat{\sigma}(X)\varphi(Z)-\log\hat{\sigma}(X)-\log\varphi(Z)-1]|Z\}\}
\end{aligned}$$

最小，其中第三个等式用到了 $X/\sigma\sim P_1$ 。在条件期望中， Z 为已知，所以可视 $\varphi(Z)$ 为“常数”。令 $\varphi(Z)=\lambda$ ，即求 λ 使

$$\begin{aligned}
f(\lambda) &= \mathrm{E}_1\{[\hat{\sigma}(X)\lambda-\log\hat{\sigma}(X)-\log\lambda-1]|Z\}\\
&= \mathrm{E}_1[\hat{\sigma}(X)|Z]\lambda-\mathrm{E}_1[\log\hat{\sigma}(X)|Z]-\log\lambda-1
\end{aligned}$$

最小。由 $\partial f/\partial\lambda=\mathrm{E}_1[\hat{\sigma}(X)|Z]-1/\lambda=0$ 可得 $\lambda=1/\mathrm{E}_1[\hat{\sigma}(X)|Z]$ ，且有 $\partial^2 f/\partial\lambda^2=1/\lambda^2>0$ ，所以 $f(\lambda)$ 在 $\lambda=1/\mathrm{E}_1[\hat{\sigma}(X)|Z]$ 处达到最小值，从而 $R(\sigma,\hat{\sigma}^*)$ 在 $\varphi(Z)=1/\mathrm{E}_1[\hat{\sigma}(X)|Z]$ 处达到最小值。所以 $\hat{\sigma}^*(X)=\hat{\sigma}(X)/\mathrm{E}_1[\hat{\sigma}(X)|Z]$ 是 σ 的 MREE 。

对 σ 的另一任意同变估计 $\tilde{\sigma}(X)$,与其相应的 σ 的 MREE 为 $\tilde{\sigma}^*(X)=\tilde{\sigma}(X)/\mathrm{E}_1[\tilde{\sigma}(X)|Z]$ 。根据同变估计的性质，必存在 $\psi(Z)$ ，使得 $\tilde{\sigma}(X)=\hat{\sigma}(X)\psi(Z)$ 。因而有

$$\tilde{\sigma}^*(X)=\frac{\hat{\sigma}(X)\psi(Z)}{\mathrm{E}_1[\hat{\sigma}(X)\psi(Z)|Z]}=\frac{\hat{\sigma}(X)}{\mathrm{E}_1[\hat{\sigma}(X)|Z]}=\hat{\sigma}^*(X).$$

所以 σ 的 MREE 与 $\hat{\sigma}(X)$ 的选取无关，即唯一性成立。 ∎

20. 设 $X_1,\cdots,X_n$ 为 *i.i.d.* 样本， $X_1\sim N(\mu,\ \sigma^2)$ ，在均方损失下求 σ 的 MREE ： (1) $\mu=0$ ； (2) μ 未知。

解. (1) $T=\sum_{i=1}^n X_i^2$ 是完备的充分统计量，并且 $\varphi(T)=\sqrt{T}$ 是 σ 的同变估计。当 $\sigma=1$ 时， $T\sim\chi^2(n)\sim\Gamma(\frac{1}{2},\frac{n}{2})$ ，所以在均方损失下 σ 的 MREE 为

$$\hat{\sigma}(X)=\frac{\mathrm{E}_1(\varphi(T))}{\mathrm{E}_1(\varphi^2(T))}\varphi(T)=\frac{\Gamma(\frac{n+1}{2})}{\Gamma(\frac{n+2}{2})}\cdot\sqrt{\frac{T}{2}}.$$

(2) 因为 $T=(\overline{X},S^2)$ 为完备的充分统计量，且 $\overline{X}$ 与 S^2 独立， $S=(\sum\limits_{i=1}^n(X_i-\overline{X})^2)^{1/2}$ 是 σ 的同变估计，所以在均方损失下 σ 的 MREE 为

$$\hat{\sigma}(X)=S\cdot\frac{\mathrm{E}_{(0,1)}[S]}{\mathrm{E}_{(0,1)}[S^2]}.$$

又因为 $\mu=0,\sigma=1$ 时， $W=S^2\sim\chi^2(n-1)$ ，所以 $\mathrm{E}_{(0,1)}[S^2]=n-1$ ，

$$\mathrm{E}_{(0,1)}[S]=\int_0^\infty\sqrt{w}\cdot\frac{2^{-\frac{n-1}{2}}}{\Gamma(\frac{n-1}{2})}e^{-\frac{1}{2}w}w^{\frac{n-1}{2}-1}dw=\frac{\Gamma(\frac{n}{2})\sqrt{2}}{\Gamma(\frac{n-1}{2})}.$$

因此在均方损失下 σ 的 MREE 为 $\hat{\sigma}(X)=[\Gamma(\frac{n}{2})\sqrt{2}S]/[\Gamma(\frac{n-1}{2})(n-1)]$ 。 ∎

21. 设 $X_1,\cdots,X_n$ 为 *i.i.d.* 样本，X_1 服从均匀分布 $R(\mu-\frac{1}{2}\sigma,\ \mu+\frac{1}{2}\sigma)$,其中 $\mu\in R,\ \sigma>0$ 是未知参数, 在均方损失下, 求 μ 和 σ 的 MREE (提示：$\hat{\mu}=\frac{1}{2}(X_{(1)}+X_{(n)})$ 和 $\hat{\sigma}=\frac{1}{2}(X_{(n)}-X_{(1)})$ 分别是 μ 和 σ 的同变估计，且有 $E_{(0,1)}(X_{(n)}^2-X_{(1)}^2)=0$) 。

解. 先求 σ 的 MREE 。因为 $(X_{(1)},X_{(n)})$ 为完备的充分统计量， 并且 $X_{(n)}-X_{(1)}$ 是 σ 的同变估计，所以 σ 的 MREE 为

$$\hat{\sigma}^*(X)=(X_{(n)}-X_{(1)})\frac{\mathrm{E}_{(0,1)}(X_{(n)}-X_{(1)})}{\mathrm{E}_{(0,1)}(X_{(n)}-X_{(1)})^2}=\frac{n+2}{n}(X_{(n)}-X_{(1)}).$$

其中当 $\mu=0,\sigma=1$ 时， $X_{(n)}-X_{(1)}\sim BE(n-1,2)$ 。

下面求 μ 的 MREE 。因为 $\hat{\mu}(X)=\frac{X_{(n)}+X_{(1)}}{2}$ 为 μ 的同变估计， $\hat{\sigma}(X)=\frac{X_{(n)}-X_{(1)}}{2}$ 为 σ 的同变估计，所以 μ 的 MREE 为

$$\begin{aligned}\hat{\mu}^*(X) &= \hat{\mu}(X)-\hat{\sigma}(X)\frac{\mathrm{E}_{(0,1)}[\hat{\mu}(X)\hat{\sigma}(X)]}{\mathrm{E}_{(0,1)}[\hat{\sigma}^2(X)]}\\ &= \frac{X_{(n)}+X_{(1)}}{2}-\frac{X_{(n)}-X_{(1)}}{2}\cdot\frac{\mathrm{E}_{(0,1)}[\frac{X_{(n)}^2-X_{(1)}^2}{4}]}{\mathrm{E}_{(0,1)}[(\frac{X_{(n)}-X_{(1)}}{2})^2]}\\ &= \frac{X_{(n)}+X_{(1)}}{2}-\frac{X_{(n)}-X_{(1)}}{2}\cdot\frac{\mathrm{E}_{(0,1)}[X_{(n)}^2-X_{(1)}^2]}{\mathrm{E}_{(0,1)}[(X_{(n)}-X_{(1)})^2]}\end{aligned}$$

下面通过计算来证明 $\mathrm{E}_{(0,1)}[X_{(n)}^2 - X_{(1)}^2] = 0$ 。令 $Y_{(1)} = X_{(1)} + \frac{1}{2}, Y_{(n)} = X_{(n)} + \frac{1}{2}$ ，则有 $Y_{(1)} \sim BE(1,n), Y_{(n)} \sim BE(n,1)$ 。所以可得

$$\begin{aligned}
\mathrm{E}_{(0,1)}[X_{(n)}^2] &= \mathrm{E}_{(0,1)}(Y_{(n)} - \frac{1}{2})^2 = \mathrm{E}_{(0,1)}(Y_{(n)} - \frac{n}{n+1} + \frac{n}{n+1} - \frac{1}{2})^2 \\
&= \mathrm{E}_{(0,1)}(Y_{(n)} - \frac{n}{n+1})^2 + (\frac{n}{n+1} - \frac{1}{2})^2 \\
&= \frac{n}{(n+1)^2(n+2)} + \frac{(n-1)^2}{4(n+1)^2}.
\end{aligned}$$

$$\begin{aligned}
\mathrm{E}_{(0,1)}[X_{(1)}^2] &= \mathrm{E}_{(0,1)}(Y_{(1)} - \frac{1}{2})^2 = \mathrm{E}_{(0,1)}(Y_{(1)} - \frac{1}{n+1} + \frac{1}{n+1} - \frac{1}{2})^2 \\
&= \mathrm{E}_{(0,1)}(Y_{(1)} - \frac{1}{n+1})^2 + (\frac{1}{n+1} - \frac{1}{2})^2 \\
&= \frac{n}{(n+1)^2(n+2)} + \frac{(n-1)^2}{4(n+1)^2}.
\end{aligned}$$

所以 $\mathrm{E}_{(0,1)}[X_{(n)}^2 - X_{(1)}^2] = 0$ ，从而 $\hat{\mu}^*(X) = \frac{X_{(n)}+X_{(1)}}{2}$ 。 ∎

22. 设 $X_1, \cdots, X_n$ 为 *i.i.d.* 样本， $X_1 \sim \mu + \Gamma(\frac{1}{\sigma},\ 1)$ ，若仅观测到 $(Y_1, \cdots, Y_r) = (X_{(1)}, \cdots, X_{(r)})$ ，其中 $X_{(1)} \le \cdots \le X_{(r)}$ 。

(1) 当 σ 已知时，求均方损失下 μ 的 MREE ；

(2) 当 μ 已知时，求均方损失下 σ 的 MREE ；

(3) 当 $\mu,\ \sigma$ 都未知时，求均方损失下 $(\mu,\ \sigma)$ 的 MREE ；

(4) 分别求各个估计值的风险函数。

解. (1) $X = (X_1, \cdots, X_n)$ 的密度函数为

$$f(x;\mu) = \frac{n!}{(n-r)!}\sigma^{-r}\exp\{-\frac{1}{\sigma}[\sum_{i=1}^{r} x_{(i)} + (n-r)x_{(r)} - n\mu]\}I\{x_{(1)} \ge \mu\},$$

记 $T_{n,r} = \sum\limits_{i=1}^{r} X_{(i)} + (n-r)X_{(r)}$ 。

当 σ 已知时，因为 $X_{(1)}$ 是完备的充分统计量且为 μ 的同变估计， $X_{(1)} \sim \mu + \Gamma(n/\sigma, 1)$ ，所以 μ 的 MREE 为 $\hat{\mu}(X) = X_{(1)} - \mathrm{E}_0(X_{(1)}) = X_{(1)} - \sigma/n$ 。

注. 由 Pitman 积分公式亦可得到 μ 的 MREE 为

$$\begin{aligned}
\hat{\mu}(X) &= \frac{\int_{-\infty}^{X_{(1)}} \mu\exp\{-(T_{n,r} - n\mu)/\sigma\}d\mu}{\int_{-\infty}^{X_{(1)}} \exp\{-(T_{n,r} - n\mu)/\sigma\}d\mu} = \frac{\int_{-\infty}^{X_{(1)}} \mu\exp\{\frac{n\mu}{\sigma}\}d\mu}{\int_{-\infty}^{X_{(1)}} \exp\{\frac{n\mu}{\sigma}\}d\mu} \\
&= X_{(1)} - \frac{\sigma}{n}
\end{aligned}$$

(2) 当 μ 已知时，因为 $X_i \sim \mu + \Gamma(1/\sigma, 1)$ ，则 $X_i - \mu \sim \Gamma(1/\sigma, 1),\ i = 1, 2, \cdots, n$ 。所以 $T = \sum_{i=1}^{n}(X_{(i)} - \mu) + (n-r)(X_{(r)} - \mu) = \sum_{i=1}^{r} X_{(i)} + (n-r)X_{(r)} - n\mu$ 是 σ 的同变估计。由指数族的性质可知 T 也是完备的充分统计量。所以 σ 的 MREE 为

$$\hat{\sigma}(X) = \frac{\mathrm{E}_1 T}{\mathrm{E}_1 T^2} \cdot T = \frac{T_{n,r} - n\mu}{r+1}.$$

注. 由 Pitman 积分公式亦可得到 σ 的 MREE 为

$$\hat{\sigma}(X)=\frac{\int_0^\infty \sigma^{-(r+2)}\exp\{-(T_{n,r}-n\mu)/\sigma\}d\sigma}{\int_0^\infty \sigma^{-(r+3)}\exp\{-(T_{n,r}-n\mu)/\sigma\}d\sigma}.$$

令 $u=1/\sigma$，则有

$$\hat{\sigma}(X)=\frac{\int_0^\infty u^r\exp\{-u(T_{n,r}-n\mu)\}du}{\int_0^\infty u^{r+1}\exp\{-u(T_{n,r}-n\mu)\}du}=\frac{T_{n,r}-n\mu}{r+1}.$$

(3) 因为 $(X_{(1)},S_1)$ 是完备的充分统计量, 其中 $S_1=\sum_{i=1}^r[X_{(i)}-X_{(1)}]+(n-r)[X_{(r)}-X_{(1)}]=T_{n,r}-nX_{(1)}$；且 $X_{(1)},S_1$ 分别为 μ 和 σ 的同变估计，$X_{(1)}\sim\mu+\Gamma(n/\sigma,1)$, $S_1\sim\Gamma(1/\sigma,r-1)$，并且两者独立，所以 μ 和 σ 的 MREE 分别为

$$\begin{aligned}\hat{\mu}(X) &= X_{(1)}-S_1\cdot\frac{\mathrm{E}_{(0,1)}[X_{(1)}S_1]}{\mathrm{E}_{(0,1)}[S_1^2]}=X_{(1)}-\frac{1}{nr}S_1;\\ \hat{\sigma}(X) &= S_1\frac{\mathrm{E}_{(0,1)}[S_1]}{\mathrm{E}_{(0,1)}[S_1^2]}=\frac{S_1}{r}.\end{aligned}$$

注. 由 Pitman 积分公式亦可得到 μ 和 σ 的 MREE 分别为

$$\begin{aligned}\hat{\mu}(X) &= \frac{\int_0^\infty\int_{-\infty}^{X_{(1)}}\sigma^{-(r+3)}\mu\cdot\exp\{-(T_{n,r}-n\mu)/\sigma\}d\mu d\sigma}{\int_0^\infty\int_{-\infty}^{X_{(1)}}\sigma^{-(r+3)}\cdot\exp\{-(T_{n,r}-n\mu)/\sigma\}d\mu d\sigma}\\ &= \frac{\int_0^\infty\sigma^{-(r+3)}(\frac{\sigma}{n}X_{(1)}-\frac{\sigma^2}{n^2})\cdot\exp\{-(T_{n,r}-nX_{(1)})/\sigma\}d\sigma}{\int_0^\infty\frac{1}{n}\sigma^{-(r+2)}\cdot\exp\{-(T_{n,r}-nX_{(1)})/\sigma\}d\sigma}\\ &= X_{(1)}-\frac{1}{nr}S_1\end{aligned}$$

$$\begin{aligned}\hat{\sigma}(X) &= \frac{\int_0^\infty\int_{-\infty}^{X_{(1)}}\sigma^{-(r+2)}\cdot\exp\{-(T_{n,r}-n\mu)/\sigma\}d\mu d\sigma}{\int_0^\infty\int_{-\infty}^{X_{(1)}}\sigma^{-(r+3)}\cdot\exp\{-(T_{n,r}-n\mu)/\sigma\}d\mu d\sigma}\\ &= \frac{\int_0^\infty\sigma^{-(r+1)}\cdot\exp\{-(T_{n,r}-nX_{(1)})/\sigma\}d\sigma}{\int_0^\infty\sigma^{-(r+2)}\cdot\exp\{-(T_{n,r}-nX_{(1)})/\sigma\}d\sigma}=\frac{S_1}{r}\end{aligned}$$

(4) 在 (1) 中，因为 $X_{(1)}\sim\mu+\Gamma(n/\sigma,1)$，所以 $\mathrm{E}(X_{(1)})=\sigma/n+\mu$，从而

$$\mathrm{E}_\mu(\hat{\mu}-\mu)^2=\mathrm{E}_\mu(X_{(1)}-\frac{\sigma}{n}-\mu)^2=\mathrm{Var}(X_{(1)})=\frac{\sigma^2}{n^2}.$$

在 (2) 中，因为 $2(T_{n,r}-n\mu)/\sigma\sim\chi^2(2r)$，所以 $2(r+1)\hat{\sigma}(X)/\sigma\sim\chi^2(2r)$，从而

$$\mathrm{E}(\hat{\sigma}-\sigma)^2=[\mathrm{E}(\hat{\sigma}^2)-2\sigma\mathrm{E}(\hat{\sigma})+\sigma^2]=\frac{\sigma^2}{r+1}.$$

在 (3) 中，因为 $X_{(1)}\sim\mu+\Gamma(n/\sigma,1),S_1\sim\Gamma(1/\sigma,r-1)$，且两者独立。所以

$$\begin{aligned}\mathrm{E}(\hat{\mu}-\mu)^2 &= \mathrm{E}(X_{(1)}-\frac{1}{nr}S_1-\mu)^2\\ &= \mathrm{E}[X_{(1)}-\mu]^2+\frac{1}{(nr)^2}\mathrm{E}(S_1^2)-\frac{2}{nr}\mathrm{E}[S_1(X_{(1)}-\mu)]=\frac{r+1}{rn^2}\sigma^2.\\ \mathrm{E}(\hat{\sigma}-\sigma)^2 &= [\mathrm{E}(\hat{\sigma}^2)-2\sigma\mathrm{E}(\hat{\sigma})+\sigma^2]=\frac{\sigma^2}{r}.\end{aligned}$$

∎

第五章　点估计的性质

1. 设 $X_1,\cdots,X_n$ 为 $i.i.d.$ 样本， X_1 的密度函数为 $f(x_1,\theta)=e^{-(x_1-\theta)}\exp(-e^{-(x_1-\theta)})$ ，其中 $x_1\in R$ 。求 θ 的 C-R 下界。

解.　X_1 的对数似然函数为

$$L(\theta,x_1)=\log f(x_1,\theta)=\theta-x_1-e^{-(x_1-\theta)}.$$

由 $\partial^2L(\theta,x_1)/\partial\theta^2=-e^{\theta-x_1}$ 可知， X_1 的 Fisher 信息为

$$I_{X_1}(\theta)=-\mathrm{E}(-e^{\theta-x_1})=\int_{-\infty}^{+\infty}e^{2(\theta-x_1)}\exp(-e^{-(x_1-\theta)})dx_1.$$

令 $e^{\theta-x_1}=t$ ，则 $dx_1=-dt/t$ ，所以

$$I_{X_1}(\theta)=\int_{+\infty}^{0}t^2e^{-t}(-\frac{1}{t})dt=\int_0^{+\infty}te^{-t}dt=\Gamma(2)=1.$$

又因为 $I(\theta)=nI_{X_1}(\theta)=n$ ，所以 θ 的 C-R 下界为 $1/n$ 。 ∎

2. 设 $X_1,\cdots,X_n$ 为 $i.i.d.$ 样本, $X_1\sim$ Rayleigh 分布: $f(x_1,\sigma)=(x_1/\sigma^2)\exp\{-x_1^2/(2\sigma^2)\}$ ，$x_1\geq 0$ 。

(1) 求 σ,σ^2 的 C-R 下界;

(2) 判断 σ,σ^2 是否存在有效的无偏估计。

解.　(1) X_1 的对数似然函数为

$$L(\sigma,x_1)=\log f(x_1,\sigma)=\log x_1-2\log\sigma-x_1^2/(2\sigma^2).$$

其前二阶导数为

$$\frac{\partial L(\sigma,x_1)}{\partial\sigma}=-\frac{2}{\sigma}+\frac{x_1^2}{\sigma^3};\quad \frac{\partial^2L(\sigma,x_1)}{\partial\sigma^2}=\frac{2}{\sigma^2}-\frac{3x_1^2}{\sigma^4}.$$

由于 $X_1\sim\Gamma(1/(2\sigma^2),1)$ ，因此样本的 Fisher 信息为

$$I(\sigma)=nI_{X_1}(\sigma)=-n\mathrm{E}(\frac{2}{\sigma^2}-\frac{3X_1^2}{\sigma^4})=\frac{4n}{\sigma^2}.$$

所以 σ 的 C-R 下界为 $\sigma^2/(4n)$ ， σ^2 的 C-R 下界为 $(2\sigma)^2/I(\sigma)=(2\sigma)^2\cdot\sigma^2/(4n)=\sigma^4/n$ 。

(2) $X=(X_1,\cdots,X_n)^T$ 的联合分布密度函数为

$$f(x,\sigma)=\frac{\prod_{i=1}^n x_i}{\sigma^{2n}}\exp\{-\frac{\sum_{i=1}^n x_i^2}{2\sigma^2}\}=(\prod_{i=1}^n x_i)\exp\{-\frac{1}{\sigma^2}\frac{\sum_{i=1}^n x_i^2}{2}-2n\log\sigma\}.$$

这是一个指数族分布，其中 $Q(\theta)=-1/\sigma^2$ ， $T(x)=\sum_{i=1}^n x_i^2/2$ ， $b(\theta)=2n\log\sigma$ (这里 θ 就是 σ) 。根据原书定理 5.1.3 ， $\hat{g}(X)$ 为$g(\theta)$ 的有效无偏估计 的充要条件为

$$\begin{aligned}\hat{g}(X) &= \alpha\cdot(\sum_{i=1}^{n}X_i^2/2)+\beta;\\ g(\theta) &= \alpha\cdot\frac{b'(\theta)}{Q'(\theta)}+\beta=\alpha(\frac{2n\sigma^{-1}}{2\sigma^{-3}})+\beta=(\alpha n)\cdot\sigma^2+\beta.\end{aligned}$$

其中 α,β 为常数。所以 σ 不存在有效无偏估计，但是 σ^2 存在有效无偏估计，并且由上式可知， σ^2 的有效无偏估计为 $\widehat{\sigma^2}=\sum_{i=1}^{n}X_i^2/(2n)$ 。 ∎

3. 设 $X_1,\cdots,X_n$ 为 *i.i.d.* 样本， X_1 的密度函数为

$$f(x_1,\lambda)=\begin{cases}\dfrac{\lambda^3x_1(x_1+1)}{\lambda+2}\exp\{-\lambda x_1\}, & x_1\geq 0\\ 0, & x_1<0\end{cases}$$

(1) 求 λ 的 Fisher 信息 $I(\lambda)$ ；

(2) 求 $h(\lambda)$, 使 $h(\lambda)$ 存在有效无偏估计。

解. (1) X_1 的对数似然函数为

$$L(\lambda;x_1)=\log f(x_1,\lambda)=\log[x_1(x_1+1)]+3\log\lambda-\log(\lambda+2)-\lambda x_1.$$

其前二阶导数为

$$\frac{\partial L(\lambda;x_1)}{\partial\lambda}=\frac{3}{\lambda}-\frac{1}{\lambda+2}-x_1;\quad \frac{\partial^2L(\lambda;x_1)}{\partial\lambda^2}=-\frac{3}{\lambda^2}+\frac{1}{(\lambda+2)^2}$$

该式与 X_1 无关，因此样本的 Fisher 信息为

$$I(\lambda)=nI_{X_1}(\lambda)=\frac{3n}{\lambda^2}-\frac{n}{(\lambda+2)^2}=\frac{2n(\lambda^2+6\lambda+6)}{\lambda^2(\lambda+2)^2}.$$

(2) 因为 $X=(X_1,\cdots,X_n)^T$ 的联合分布密度函数为

$$f(x,\lambda)=[\prod_{i=1}^{n}x_i(x_i+1)]\exp\{-\lambda\sum_{i=1}^{n}x_i-[n\log(\lambda+2)-3n\log\lambda]\}I\{x_{(1)}\geq 0\}.$$

这是一个指数族分布，其中 $Q(\theta)=-\lambda$ ， $T(x)=\sum_{i=1}^{n}x_i$ ， $b(\theta)=n\log(\lambda+2)-3n\log\lambda$ (这里 θ 就是 λ) 。根据原书定理 5.1.3 ， $\hat{g}(X)$ 为 $g(\theta)$ 的有效无偏估计的充要条件为

$$\begin{aligned}\hat{g}(X) &= \alpha\cdot\sum_{i=1}^{n}X_i+\beta;\\ g(\theta) &= \alpha\cdot\frac{b'(\theta)}{Q'(\theta)}+\beta=\alpha\cdot\frac{n/(\lambda+2)-3n/\lambda}{-1}+\beta=\alpha n(\frac{3}{\lambda}-\frac{1}{\lambda+2})+\beta.\end{aligned}$$

其中 α,β 为常数。因此 $h(\lambda)=3/\lambda-1/(\lambda+2)$ 存在有效的无偏估计，并且由上式可知， $h(\lambda)$ 的有效无偏估计为 $\widehat{h(\lambda)}=\sum_{i=1}^{n}X_i/n$ 。 ∎

4. 设 $X_1,\cdots,X_n$ 为 *i.i.d.* 样本， $X_1\sim\Gamma(\lambda,\nu)$ ，其中 ν 已知。分别求 λ 和 $1/\lambda$ 的 MLE ，并判断其方差是否能达到 C-R 下界。

解. λ 的极大似然估计为 $\hat{\lambda}=n\nu T^{-1}$ ，其中 $T=\sum_{i=1}^{n}X_i\sim\Gamma(\lambda,n\nu)$ 。因为

$$\mathrm{E}(\hat{\lambda})=n\nu\mathrm{E}(T^{-1})=\lambda\cdot\frac{n\nu}{n\nu-1}=\lambda+\frac{\lambda}{n\nu-1},$$

所以 $\hat{\lambda}$ 为 λ 的有偏估计。 λ 的 Fisher 信息为 $I(\lambda)=n\nu/\lambda^2$ ，且有

$$\mathrm{Var}(\hat{\lambda})=n^2\nu^2[\mathrm{E}(T^{-2})-\mathrm{E}^2(T^{-1})]=\frac{n^2\nu^2\lambda^2}{(n\nu-1)^2(n\nu-2)}.$$

所以 $\hat{\lambda}$ 的 C-R 下界

$$CRLB=[1+\frac{1}{n\nu-1}]^2\frac{\lambda^2}{n\nu}=\frac{n\nu\lambda^2}{(n\nu-1)^2}<\frac{n^2\nu^2\lambda^2}{(n\nu-1)^2(n\nu-2)}=\mathrm{Var}(\hat{\lambda}).$$

即 λ 的极大似然估计达不到其 C-R 下界。

$1/\lambda$ 的极大似然估计为 $\widehat{1/\lambda}=T/(n\nu)$ ，其中 $T=\sum_{i=1}^{n}X_i\sim\Gamma(\lambda,n\nu)$ 。由此可知 $\mathrm{E}(\widehat{1/\lambda})=\mathrm{E}(T)/(n\nu)=1/\lambda$ ，因此 $\widehat{1/\lambda}$ 为 $1/\lambda$ 的无偏估计。 λ 的 Fisher 信息为 $I(\lambda)=n\nu/\lambda^2$ ， 且有

$$\mathrm{Var}(\widehat{1/\lambda})=\frac{1}{n^2\nu^2}\mathrm{Var}(T)=\frac{1}{n\nu\lambda^2},$$

所以 $\widehat{1/\lambda}$ 的 C-R 下界

$$CRLB=(-1/\lambda^2)^2I^{-1}(\lambda)=\frac{1}{n\nu\lambda^2}=\mathrm{Var}(\widehat{1/\lambda}).$$

因此 $1/\lambda$ 的极大似然估计能够达到其 C-R 下界。 ∎

5. 设随机变量 X 的密度函数为 $f(x)=(2\theta)^{-1}\exp\{-|x|/\theta\}$ ，其中 $\theta>0$ 。分别求 $\theta,\theta^r(r>1),(1+\theta)^{-1}$ 的 UMVUE ，并检验它们能否达到各自的 C-R 下界 (提示： $T=|X|$ 是关于 θ 的完备充分统计量) 。

解. 令 $T=|X|$ ，则其密度函数为 $f(t)=\theta^{-1}e^{-\frac{t}{\theta}}I\{t\geq 0\}\sim\Gamma(\theta^{-1},1)$ ，由 Γ 分布族的性质知 $T=|X|$ 是完备充分统计量。

由 $\mathrm{E}(T)=\theta$ 知 T 是 θ 的 UMVUE 。因为 X 的对数似然函数及其关于 θ 的二阶导数分别为

$$L(\theta)=-\log\theta-\frac{|x|}{\theta}-\log 2,\quad \frac{\partial^2L(\theta)}{\partial\theta^2}=\frac{1}{\theta^2}-\frac{2|x|}{\theta^3}.$$

所以 X 的 Fisher 信息为 $I(\theta)=\mathrm{E}(2|x|/\theta^3-1/\theta^2)=1/\theta^2$ 。 θ 的 C-R 下界为 CRLB= $I^{-1}(\theta)=\theta^2$ ，而 $\mathrm{Var}(T)=\theta^2$ ，所以 θ 的 UMVUE 能达到其 C-R 下界。

$\theta^r(r>1)$ 的 C-R 下界为 CRLB= $[(\theta^r)']^2\theta^2=r^2\theta^{2r}$ 。由 $\mathrm{E}(T^r)=\Gamma(r+1)\theta^r$ 知 $T^r/\Gamma(r+1)$ 是 θ^r 的 UMVUE 。因为

$$\mathrm{Var}(T^r)=\mathrm{E}(T^{2r})-[\mathrm{E}(T^r)]^2=\Gamma(2r+1)\theta^{2r}-\Gamma^2(r+1)\theta^{2r},$$

所以

$$\mathrm{Var}(T^r/\Gamma(r+1))=[\Gamma(2r+1)/\Gamma^2(r+1)-1]\theta^{2r}>r^2\theta^{2r}=CRLB.$$

即 θ^r 的 UMVUE 达不到 θ^r 的 C-R 下界。

由于

$$\mathrm{E}(e^{-T}) = \int_0^\infty \theta^{-1} e^{-(1+\theta^{-1})t} dt = \theta^{-1}(1+\theta^{-1})^{-1} = (1+\theta)^{-1},$$

所以 e^{-T} 是 $(1+\theta)^{-1}$ 的 UMVUE 。又因为

$$\mathrm{Var}(e^{-T}) = \mathrm{E}(e^{-2T}) - [\mathrm{E}(e^{-T})]^2 = \frac{1}{1+2\theta} - \frac{1}{(1+\theta)^2} = \frac{\theta^2}{(1+2\theta)(1+\theta)^2},$$

所以 $(1+\theta)^{-1}$ 的 C-R 下界

$$CRLB = \{[(1+\theta)^{-1}]'\}^2 I^{-1}(\theta) = \frac{\theta^2}{(1+\theta)^4} < \mathrm{Var}(e^{-T}).$$

即 $(1+\theta)^{-1}$ 的 UMVUE 达不到其 C-R 下界。 ∎

6. 设 $X_1, \cdots, X_n$ 为 *i.i.d.* 样本， X_1 服从两点分布，即 $P(X_1 = 1) = p$ ，其中 $p \in (0,1)$ 。证明： $p(1-p)$ 的 UMVUE 为 $S_n = \frac{n}{n-1}\bar{X}(1-\bar{X})$ ，并且方差 $\mathrm{Var}(S_n)$ 达不到 $p(1-p)$ 的 C-R 下界。

证明. 根据原书例 3.2.6 ，可用待定系数法得到 $p(1-p)$ 的 UMVUE 为 $S_n = \frac{n}{n-1}\bar{X}(1-\bar{X})$ 。根据原书例 2.3.2. 可得 p 的 Fisher 信息为 $I(p) = n[p(1-p)]^{-1}$ ，所以 $p(1-p)$ 的无偏估计的 C-R 下界为

$$CRLB = (1-2p)^2 I^{-1}(p) = \frac{p(1-p)(1-2p)^2}{n};$$

经直接计算， S_n 的方差可表示为

$$\begin{aligned}
\mathrm{Var}(S_n) &= \mathrm{E}(S_n^2) - [\mathrm{E}(S_n)]^2 \\
&= \frac{1}{n^2(n-1)^2}[\sum_{t=0}^{n}\binom{n}{t}p^t(1-p)^{n-t}t^2(n-t)^2] - p^2(1-p)^2 \\
&= \frac{n(n-1)(n-2)(n-3)p^2(1-p)^2 + n(n-1)^2 p(1-p)}{n^2(n-1)^2} - p^2(1-p)^2 \\
&= \frac{(n-2)(n-3)}{n(n-1)}p^2(1-p)^2 + \frac{p(1-p)}{n} - p^2(1-p)^2 \\
&= \frac{p(1-p)}{n} + \frac{-4n+6}{n(n-1)}p^2(1-p)^2 \\
&> \frac{p(1-p)}{n} + \frac{-4}{n}p^2(1-p)^2 \\
&= (1-2p)^2\frac{p(1-p)}{n} = CRLB
\end{aligned}$$

所以方差 $\mathrm{Var}(S_n)$ 达不到 $p(1-p)$ 的 C-R 下界。

注. 我们亦可直接根据完备的充分统计量 $T = \sum_{i=1}^n X_i \sim b(n,p)$ 求出 $p(1-p)$ 的 UMVUE ，今记为 $h(T)$ 。则由 $\mathrm{E}[h(T)] = p(1-p), \ \forall\, p \in (0,1)$ 可得

$$\sum_{t=0}^{n}\binom{n}{t}h(t)p^t(1-p)^{n-t} = p(1-p), \ \ \forall\, p \in (0,1)$$

令 $\rho = \frac{p}{1-p}$ ，则 $p = \frac{\rho}{1+\rho}$, $1-p = \frac{1}{1+\rho}$ 。代入上式可得

$$\sum_{t=0}^{n}\binom{n}{t}h(t)\rho^t = \rho(1+\rho)^{n-2} = \sum_{t=1}^{n-1}\binom{n-2}{t-1}\rho^t, \ \ \forall\, p \in (0,1).$$

比较两边系数可得

$$h(t)=\frac{t(n-t)}{n(n-1)}=\frac{n\bar{x}(1-\bar{x})}{n-1},\ t=0,1,\cdots,n.$$

所以 $p(1-p)$ 的 UMVUE 为 $=h(T)=\frac{n}{n-1}\bar{X}(1-\bar{X})$ ， ∎

7. 设 $X_1,\cdots,X_n$ 为 *i.i.d.* 样本， $X_1\sim N(0,\ \sigma^2)$ 。试求 σ 的 UMVUE ，问其能否达到 σ 的无偏估计的 C-R 下界。

解. 因为 $S^2=\sum_{i=1}^n X_i^2$ 是完备的充分统计量, 且 $S^2/\sigma^2\sim\chi^2(n)$ 。所以由 $\mathrm{E}(S/\sigma)=\sqrt{2}\Gamma(\frac{n+1}{2})/\Gamma(\frac{n}{2})$ 知 $T=\Gamma(\frac{n}{2})S/[\sqrt{2}\Gamma(\frac{n+1}{2})]$ 是 σ 的 UMVUE 。易求 σ 的 Fisher 信息为 $I(\sigma)=2n/\sigma^2$ ，且

$$\mathrm{Var}(T)=\mathrm{E}(T^2)-[\mathrm{E}(T)]^2=C_n^2\mathrm{E}(S^2)-\sigma^2=(nC_n^2-1)\sigma^2,$$

其中 $C_n=\Gamma(\frac{n}{2})/[\sqrt{2}\Gamma(\frac{n+1}{2})]$ 。由 $nC_n^2-1>1/(2n)$ 可知 σ 的 UMVUE 达不到 σ 的无偏估计的 C-R 下界。 ∎

8. 设 $X_1,\cdots,X_n$ 为 *i.i.d.* 样本， $X_1\sim N(\mu,\sigma^2)$ ，其中 $\mu\in R$ 是未知参数， σ^2 是已知参数。

(1) 求 $e^{a\mu}$ 的 UMVUE ，其中 a 为固定的正数;

(2) 验证 (1) 中所求的 $e^{a\mu}$ 的 UMVUE 是否能达到 $e^{a\mu}$ 的 C-R 下界。

解. (1) $T=\bar{X}$ 为完备的充分统计量，且 $T\sim N(\mu,\sigma^2/n)$ 。由于

$$\mathrm{E}_\mu(e^{aT})=\exp\{a\mu+\frac{1}{2}a^2\frac{\sigma^2}{n}\},\quad \mathrm{E}_\mu[\exp\{aT-\frac{a^2\sigma^2}{2n}\}]=e^{a\mu}.$$

所以 $e^{a\mu}$ 的 UMVUE 为 $e^{aT-a^2\sigma^2/2n}$ 。

(2) 因为 μ 的 Fisher 信息为 $I(\mu)=n/\sigma^2$ ，且

$$\mathrm{Var}(e^{aT-\frac{a^2\sigma^2}{2n}})=\mathrm{E}[e^{aT-\frac{a^2\sigma^2}{2n}}]^2-e^{2a\mu}=e^{2a\mu}(e^{\frac{a^2\sigma^2}{n}}-1).$$

所以 $e^{a\mu}$ 的 C-R 下界

$$CRLB=(ae^{a\mu})^2\frac{\sigma^2}{n}=e^{2a\mu}\frac{a^2\sigma^2}{n}<e^{2a\mu}(e^{\frac{a^2\sigma^2}{n}}-1)=\mathrm{Var}(e^{aT-\frac{a^2\sigma^2}{2n}}).$$

因此 $e^{a\mu}$ 的 UMVUE 达不到其 C-R 下界。 ∎

9. 设 $\{f(x;\theta),\ \theta\in\Theta\}$ 为 C-R 分布族， $g(\theta)$ 在 Θ 上可微， $T(X)$ 是 $g(\theta)$ 的估计，则有

$$\mathrm{E}_\theta\{T(X)-g(\theta)\}^2\geq b^2(\theta)+[g'(\theta)+b'(\theta)]^2I^{-1}(\theta).$$

其中 $b(\theta)=\mathrm{E}_\theta[T(X)]-g(\theta)$ 。

证明. 因为 $\mathrm{bias}[T(X)]=b(\theta)=\mathrm{E}_\theta[T(X)]-g(\theta)$ 是 $T(X)$ 的偏差，所以由原书第 5 章定理 5.1.1 推论 3 知 $\mathrm{Var}_\theta[T(X)]\geq[g'(\theta)+b'(\theta)]^2I^{-1}(\theta)$ 。又因为

$$MSE[T(X)]=\mathrm{E}_\theta[T(X)-g(\theta)]^2=\mathrm{Var}_\theta[T(X)]+\mathrm{bias}^2[T(X)],$$

所以

$$\mathrm{E}_\theta\{T(X)-g(\theta)\}^2 \geq b^2(\theta)+[g'(\theta)+b'(\theta)]^2 I^{-1}(\theta). \qquad \blacksquare$$

10. 设 $X_1,\cdots,X_n$ 为 *i.i.d.* 样本， X_1 的密度函数为 $f(x_1,\theta)$ 且对 $\forall x_1,\ f(x_1,\theta)>0$, 又设 $\delta(X)$ 为 $g(\theta)$ 的任意一个无偏估计，证明：

$$\mathrm{Var}[\delta(X)] \geq \frac{[g(\theta)-g(\theta_0)]^2}{[\int_{-\infty}^{\infty}\frac{[f(x_1,\theta)]^2}{f(x_1,\theta_0)}dx_1]^n-1} \quad , \quad \forall\theta\neq\theta_0.$$

证明. 类似于原书 5.2 节，可取 $S(x)$ 为

$$S(x)=\prod_{i=1}^n f(x_i;\theta)/\prod_{i=1}^n f(x_i;\theta_0) \triangleq \frac{f(x;\theta)}{f(x;\theta_0)}.$$

则有

$$\begin{aligned}
\mathrm{E}_{\theta_0}(S) &= \int_{R^n} S(x)\cdot f(x;\theta_0)dx = 1\\
\mathrm{E}_{\theta_0}[\delta(X)S] &= \int_{R^n} \delta(x)\cdot S(x)\cdot f(x;\theta_0)dx\\
&= \int_{R^n} \delta(x)\cdot f(x;\theta)dx = \mathrm{E}_\theta[\delta(X)] = g(\theta).
\end{aligned}$$

所以

$$\mathrm{Cov}(\delta(X),S)=\mathrm{E}_{\theta_0}[\delta(X)\cdot S]-\mathrm{E}_{\theta_0}(\delta(X))\cdot\mathrm{E}_{\theta_0}(S)=g(\theta)-g(\theta_0).$$

又因

$$\begin{aligned}
\mathrm{Var}_{\theta_0}(S) &= \mathrm{E}_{\theta_0}(S^2)-[\mathrm{E}_{\theta_0}(S)]^2\\
&= \int_{R^n}[f(x;\theta)/f(x;\theta_0)]^2\cdot f(x;\theta_0)dx-1\\
&= \int_{R^n}\prod_{i=1}^n[f^2(x_i;\theta)/f(x_i;\theta_0)]dx-1\\
&= \prod_{i=1}^n\int_R[f^2(x_i;\theta)/f(x_i;\theta_0)]dx_i-1\\
&= [\int_{-\infty}^{\infty}[f^2(x_1;\theta)/f(x_1;\theta_0)]dx_1]^n-1.
\end{aligned}$$

由 Schwarz 不等式 $\mathrm{Var}_{\theta_0}(\delta(X))\cdot\mathrm{Var}_{\theta_0}(S)\geq\mathrm{Cov}^2_{\theta_0}(\delta(X),S)$ 可得

$$\mathrm{Var}_{\theta_0}[\delta(X)]\geq\mathrm{Cov}^2_{\theta_0}(\delta(X),S)\cdot\mathrm{Var}^{-1}_{\theta_0}(S)=\frac{[g(\theta)-g(\theta_0)]^2}{[\int_{-\infty}^{\infty}\frac{[f(x_1,\theta)]^2}{f(x_1,\theta_0)}dx_1]^n-1} \quad , \quad \forall\theta\neq\theta_0. \qquad \blacksquare$$

11. 设 $X_1,\cdots,X_n$ 为 *i.i.d.* 样本， $X_1\sim\Gamma(1/\theta,\nu)$ ，其中 $\theta>0$ 未知， ν 已知。证明： θ 的 MLE 是 θ 的无偏的相合估计。

证明. θ 的极大似然估计为 $\hat{\theta}=T/(n\nu)$ ，其中 $T=\sum_{i=1}^{n}X_i\sim\Gamma(1/\theta,n\nu)$ 。因为

$$\begin{aligned}\mathrm{E}(\hat{\theta}) &= \frac{\mathrm{E}T}{n\nu}=\frac{1}{n\nu}\cdot\frac{n\nu}{1/\theta}=\theta,\\ \mathrm{Var}(\hat{\theta}) &= \frac{1}{(n\nu)^2}\mathrm{Var}(T)=\frac{\theta^2}{n\nu}\to 0\ \ (n\to\infty).\end{aligned}$$

所以 $\hat{\theta}\xrightarrow{P}\mathrm{E}(\hat{\theta})=\theta\ \ (n\to\infty)$ ，即 $T/(n\nu)$ 是 θ 的无偏的相合估计。 ∎

12. 设 $X_1,\cdots,X_n$ 为 *i.i.d.* 样本， X_1 的密度函数为 $f(x_1,\theta)=\frac{1+\theta x_1}{2}I\{-1\le x_1\le 1\}$ ，其中 $\theta\in(-1,1)$ 为未知参数，试找 θ 的一个相合估计。

解. 因为 $\mathrm{E}X_1=\int_{-1}^{1}x_1(1+\theta x_1)/2dx_1=\theta/3$ ，所以 $\mathrm{E}(3\bar{X})=3\mathrm{E}\bar{X}=\theta$ 。又因为

$$\mathrm{Var}(3\bar{X})=(\frac{3}{n})^2\cdot n\mathrm{Var}(X_1)=\frac{9}{n}(\frac{1}{3}-\frac{\theta^2}{9})\to 0\ \ (n\to\infty).$$

所以 $3\bar{X}$ 是 θ 的相合估计。 ∎

13. 设 $X_1,\cdots,X_n$ 为 *i.i.d.* 样本， X_1 的密度函数为 $f(x_1,\theta)=\frac{1}{\theta}e^{-\frac{x_1}{\theta}}I\{x_1\ge 0\}$ ，其中 $\theta>0$ 未知。考虑 θ 的三个估计： $T_1=\frac{1}{n}\sum_{i=1}^{n}X_i$, $T_2=\frac{1}{n+1}\sum_{i=1}^{n}X_i$, $T_3=nX_{(1)}$ 。试判断哪些是 θ 的无偏估计，哪些是 θ 的相合估计，并证明你的结论。

解. 由指数分布次序统计量的性质知 $X_{(1)}\sim\Gamma(\frac{n}{\theta},1)$ 。因为

$$\mathrm{E}T_1=\frac{1}{n}\cdot n\mathrm{E}X_1=\theta,\ \ \mathrm{E}T_2=\frac{1}{n+1}\cdot n\mathrm{E}X_1=\frac{n}{n+1}\theta,\ \ \mathrm{E}T_3=n\mathrm{E}X_{(1)}=\theta.$$

所以 T_1, T_3 是 θ 的无偏估计，但 T_2 不是 θ 的无偏估计，又因为

$$\mathrm{Var}(T_1)=\frac{1}{n^2}n\mathrm{Var}(X_1)=\frac{\theta^2}{n}\to 0\ \ (n\to\infty).$$

所以 $T_1\xrightarrow{P}\theta$ ，从而 T_1 是 θ 的相合估计。对于 T_2 ，因为

$$\mathrm{Var}(T_2)=\frac{1}{(n+1)^2}n\mathrm{Var}(X_1)=\frac{n}{(n+1)^2}\theta^2\to 0\ \ (n\to\infty).$$

并且 $\mathrm{E}T_2\to\theta$ ，所以 $T_2\xrightarrow{P}\theta$ ，因而 T_2 也是 θ 的相合估计。对于 T_3 ，因为对任意的 $\varepsilon>0$ ，

$$\begin{aligned}P\{|T_3-\theta|>\varepsilon\} &= P\{|nX_{(1)}-\theta|>\varepsilon\}\\ &= \int_{|nt-\theta|>\varepsilon}\frac{n}{\theta}e^{-\frac{n}{\theta}t}dt\ge\int_{\frac{\theta}{n}+\frac{\varepsilon}{n}}^{+\infty}\frac{n}{\theta}e^{-\frac{n}{\theta}t}dt\\ &= e^{-1-\frac{\varepsilon}{\theta}}\ge e^{-1}\end{aligned}$$

所以 T_3 不是 θ 的相合估计。 ∎

14. 设 $X_1,\cdots,X_n$ 相互独立，其中 $X_1,\cdots,X_{n_1}$ 为 *i.i.d.* ， $\mathrm{E}(X_1)=\mu$ ， $\mathrm{Var}(X_1)=\sigma^2$ ；$X_{n_1+1},\cdots,X_n$ 为 *i.i.d.* ， $\mathrm{E}(X_n)=\mu$ ， $\mathrm{Var}(X_n)=\tau^2$ 。证明： $\bar{X}$ 是 μ 的相合估计。

证明. 若 $\mathrm{E}(\xi)=a$, $\mathrm{Var}(\xi)=b$ ，则记为 $\xi\sim(a,\ b)$ 。则有

$$\sum_{i=1}^{n_1}\frac{X_i}{n}\sim(\frac{n_1}{n}\mu,\ \frac{n_1}{n^2}\sigma^2),\qquad\sum_{j=n_1+1}^{n}\frac{X_j}{n}\sim(\frac{n-n_1}{n}\mu,\ \frac{n-n_1}{n^2}\tau^2),$$

所以

$$\bar{X}=\sum_{i=1}^{n_1}\frac{X_i}{n}+\sum_{j=n_1+1}^{n}\frac{X_j}{n}\sim(\mu,\ \frac{n_1\sigma^2+(n-n_1)\tau^2}{n^2}).$$

即

$$\mathrm{E}(\bar{X})=\mu,\quad \mathrm{Var}(\bar{X})=\frac{1}{n}(\frac{n_1}{n}\sigma^2+(1-\frac{n_1}{n})\tau^2)\to 0\ \ (n\to\infty).$$

所以 $\bar{X}$ 是 μ 的相合估计。 ∎

15. 设 $X_1,\cdots,X_n$ 为 *i.i.d.* 样本， $X_1\sim N(0,\sigma^2)$ ，证明： $\delta_n=(k/n)\sum_{i=1}^n|X_i|$ 是 σ 的相合估计的充要条件为 $k=\sqrt{\pi/2}$ 。

证明. 因为

$$\begin{aligned}\mathrm{E}\delta_n &= \frac{k}{n}\mathrm{E}(\sum_{i=1}^n|X_1|)=\frac{k}{n}\cdot n\mathrm{E}|X_1|=k\cdot\sqrt{\frac{2}{\pi}}\cdot\sigma\\ \mathrm{Var}(\delta_n) &= \frac{k^2}{n^2}\mathrm{Var}(\sum_{i=1}^n|X_i|)=\frac{k^2}{n}\mathrm{Var}(|X_1|)\to 0\ \ (n\to\infty).\end{aligned}$$

所以必有 $\delta_n-\mathrm{E}\delta_n\xrightarrow{P}0\ \ (n\to\infty)$ 。而 $\mathrm{E}\delta_n$ 等于常数 $c=k\cdot\sqrt{2/\pi}\sigma$ 。因此， δ_n 以概率收敛到常数 c ，而这一常数 $c=\sigma$ 的充要条件为 $k=\sqrt{\pi/2}$ 。 所以 $\delta_n=(k/n)\sum_{i=1}^n|X_i|$ 是 σ 的相合估计的充要条件为 $k=\sqrt{\pi/2}$ 。 ∎

16. 设 $Y_n,\ n=1,2,\cdots$ 为正态随机变量序列， $Y_n\sim N(a,\tau_n^2)$ ， $n=1,2,\cdots$ 证明： Y_n 是 a 的相合估计的充要条件为 $\tau_n\to 0$ 。

证明. 因为 $Y_n\sim N(a,\tau_n^2)$ ，所以 $Y_n-a\sim N(0,\tau_n^2)$ 。因此对任意的 $\varepsilon>0$ ，我们有

$$\begin{aligned}P\{|Y_n-a|\geq\varepsilon\} &= 1-P\{|Y_n-a|<\varepsilon\}\\ &= 1-\int_{-\varepsilon}^{\varepsilon}\frac{1}{\sqrt{2\pi}\tau_n}\exp\{-\frac{t^2}{2\tau_n^2}\}dt.\end{aligned}$$

令 $u=t/\tau_n$ ，则

$$\begin{aligned}P\{|Y_n-a|\geq\varepsilon\} &= 1-\int_{-\varepsilon/\tau_n}^{\varepsilon/\tau_n}\frac{1}{\sqrt{2\pi}}e^{-u^2/2}du\\ &= 1-[\Phi(\frac{\varepsilon}{\tau_n})-\Phi(-\frac{\varepsilon}{\tau_n})]=2[1-\Phi(\frac{\varepsilon}{\tau_n})].\end{aligned}$$

而 $[1-\Phi(\varepsilon/\tau_n)]\to 0\ \ (n\to\infty)$ 等价于

$$\Phi(\frac{\varepsilon}{\tau_n})\to 1\ \ (n\to\infty)\ \ \text{等价于}\ \ \tau_n\to 0\ \ (n\to\infty).$$

所以 Y_n 是 a 的相合估计的充要条件为 $\tau_n\to 0$ 。 ∎

17. 设 $X_1,\cdots,X_n$ 为 *i.i.d.* 样本， $X_1\sim R(0,\ \theta)$ ，证明： $T(X)=X_{(n)}$ 是 θ 的相合与强相合估计。

证明. 因为 $T=X_{(n)}$ 的密度函数为

$$f(t;\theta)=nt^{n-1}\theta^{-n}I\{0\leq t\leq\theta\}.$$

所以对任意的 $0<\varepsilon<\theta$ ，我们有

$$\begin{aligned} P_\theta\{|X_{(n)}-\theta|\geq\varepsilon\} &= P_\theta\{X_{(n)}\leq\theta-\varepsilon\}=\int_0^{\theta-\varepsilon} nt^{n-1}\theta^{-n}dt \\ &= (1-\frac{\varepsilon}{\theta})^n\to 0 \quad (n\to\infty). \end{aligned}$$

由此可知 $X_{(n)}\xrightarrow{P}\theta$ ，即 $T=X_{(n)}$ 是 θ 的相合估计。

因为 $\sum_{n=1}^{\infty}P_\theta\{|X_{(n)}-\theta|\geq\varepsilon\}=\sum_{n=1}^{\infty}(1-\varepsilon/\theta)^n$ 收敛，所以由 Borel-Cantell 引理知 $T=X_{(n)}\to\theta\ (a.e.P_\theta)$ ，即 $T=X_{(n)}$ 是 θ 的强相合估计。 ∎

18. ★ 设 $X_1,\cdots,X_n$ 为 $i.i.d.$ 样本， $X_1\sim f(x_1,\theta)$ 。证明： $X_{(1)}$ 是 θ 的强相合估计，其中

(1) $f(x_1,\theta)=I\{\theta<x_1<\theta+1\}$ ；

(2) $f(x_1,\theta)=2(x_1-\theta)I\{\theta<x_1<\theta+1\}$;

(3) $f(x_1,\theta)=g(x_1,\theta)I\{x_1\geq\theta\}$ ，其分布函数 $F_\theta(x_1)>0,\ \forall\ x_1>\theta$ (提示：参考例 5.3.5) 。

证明. (1) 因为

$$T=X_{(1)}\sim f(t;\theta)=n(1+\theta-t)^{n-1}I\{\theta<t<\theta+1\}.$$

所以对任意的 $0<\varepsilon<1$ ，由于

$$\begin{aligned} P\{|X_{(1)}-\theta|\geq\varepsilon\} &= \int_{\theta+\varepsilon}^{\theta+1} n(1+\theta-t)^{n-1}dt \\ &= -(1+\theta-t)^n|_{\theta+\varepsilon}^{\theta+1}=(1-\varepsilon)^n\to 0 \quad (n\to\infty). \end{aligned}$$

因此 $X_{(1)}\xrightarrow{P}\theta$ 。

又因为

$$\sum_{n=1}^{\infty}P\{|X_{(1)}-\theta|\geq\varepsilon\}=\sum_{n=1}^{\infty}(1-\varepsilon)^n$$

收敛，所以由 Borel-Cantell 引理知 $X_{(1)}\to\theta\ (a.e.)$ ，即 $X_{(1)}$ 是 θ 的强相合估计。

(2) 因为 X_1 的分布函数为

$$F(x_1)=\int_\theta^{x_1}2(t-\theta)dt=(x_1-\theta)^2I\{\theta<x_1<\theta+1\}.$$

所以 $T=X_{(1)}$ 的密度函数为

$$f(t;\theta)=n[1-(t-\theta)^2]^{n-1}\cdot 2(t-\theta)I\{\theta<t<\theta+1\}.$$

从而对任意的 $0<\varepsilon<1$ ，由于

$$\begin{aligned} P\{|X_{(1)}-\theta|\geq\varepsilon\} &= \int_{\theta+\varepsilon}^{\theta+1} 2n(t-\theta)[1-(t-\theta)^2]^{n-1}dt \\ &= (1-\varepsilon^2)^n\to 0 \quad (n\to\infty) \end{aligned}$$

因此 $X_{(1)}\xrightarrow{P}\theta$ 。

又因为

$$\sum_{n=1}^{\infty} P\{|X_{(1)}-\theta| \geq \varepsilon\} = \sum_{n=1}^{\infty}(1-\varepsilon^2)^n$$

收敛，所以由 Borel-Cantell 引理知 $X_{(1)} \to \theta$ $(a.e.)$ ，即 $X_{(1)}$ 是 θ 的强相合估计。

(3) 因为 $T = X_{(1)}$ 的密度函数为

$$f(t;\theta) = ng(x_1;\theta)[1-F_\theta(t)]^{n-1} I\{t \geq \theta\}.$$

所以对任意的 $0 < \varepsilon < 1$ ，由

$$\begin{aligned} P\{|X_{(1)}-\theta| \geq \varepsilon\} &= \int_{\theta+\varepsilon}^{\infty} ng(x_1;\theta)[1-F_\theta(t)]^{n-1}dt = -[1-F_\theta(t)]^n|_{\theta+\varepsilon}^{\infty} \\ &= [1-F_\theta(\theta+\varepsilon)]^n \to 0 \quad (n \to \infty). \end{aligned}$$

在上式中，由假设可知 $F_\theta(\theta+\varepsilon) > 0,\ \forall\ \varepsilon > 0$ ，因此 $1-F_\theta(\theta+\varepsilon) < 1$ ，所以上式成立。从而 $X_{(1)} \xrightarrow{P} \theta$ 。

又因为

$$\sum_{n=1}^{\infty} P\{|X_{(1)}-\theta| \geq \varepsilon\} = \sum_{n=1}^{\infty}[1-F_\theta(\theta+\varepsilon)]^n$$

收敛，所以由 Borel-Cantell 引理知 $X_{(1)} \to \theta$ $(a.e.)$ ，即 $X_{(1)}$ 是 θ 的强相合估计。 ∎

19. ★ 设 $X_1, \cdots, X_n$ 为 $i.i.d.$ 样本， X_1 的分布函数 $F_\theta(x_1)$ 为连续函数，并且有 $F_\theta(\theta) = 1,\ F_\theta(x_1) < 1,\ \forall\ x_1 < \theta$ 。证明：

(1) $X_{(n)}$ 为 θ 的强相合估计;

(2) 若 $F_\theta^{'}(\theta) \neq 0$ ，则 $nF_\theta^{'}(\theta)(X_{(n)}-\theta) \xrightarrow{L} Y$ ，其中 Y 的分布函数为 $F(y) = e^y I\{y \leq 0\}$ (提示： $F_\theta(X_{(n)}) = F_\theta(\theta) + F_\theta'(\theta)(X_{(n)}-\theta) + O(|\theta - X_{(n)}|^2)$ ，并证 $n|\theta - X_{(n)}|^2 \xrightarrow{P} 0$) 。

证明. (1) 因为对任意的 $\varepsilon > 0$ ，有 $F_\theta(\theta-\varepsilon) < 1$ ，且

$$P(|X_{(n)}-\theta| \geq \varepsilon) = P(X_{(n)} \leq \theta-\varepsilon) = [F_\theta(\theta-\varepsilon)]^n.$$

所以 $\sum_{n=1}^{\infty}[F_\theta(\theta-\varepsilon)]^n$ 收敛，从而 $X_{(n)} \to \theta$ $(a.e.)$ ，即 $X_{(n)}$ 为 θ 的强相合估计。

(2) 因为 $F_\theta(X_{(n)})$ 在 θ 处的一阶 Taylor 展开为

$$F_\theta(X_{(n)}) = F_\theta(\theta) + F_\theta^{'}(\theta)(X_{(n)}-\theta) + O(|\theta - X_{(n)}|^2).$$

所以

$$nF_\theta'(\theta)(X_{(n)}-\theta) = -n[1-F_\theta(X_{(n)})] + O(n|\theta - X_{(n)}|^2).$$

下面证明 $n|\theta - X_{(n)}|^2 \xrightarrow{P} 0$ 。对任意的 $\varepsilon > 0$ ，我们有

$$\begin{aligned} P\{n|\theta - X_{(n)}|^2 \geq \varepsilon\} &= P\{|\theta - X_{(n)}| \geq \sqrt{\varepsilon/n}\} \\ &= P\{X_{(n)} \leq \theta - \sqrt{\varepsilon/n}\} \\ &= [F_\theta(\theta - \sqrt{\varepsilon/n})]^n. \end{aligned}$$

$F_\theta(\theta - \sqrt{\varepsilon/n})$ 可展开为

$$F_\theta(\theta - \sqrt{\varepsilon/n}) = F_\theta(\theta) - [F_\theta'(\theta) + \alpha_n]\sqrt{\varepsilon/n} = 1 - b_n/\sqrt{n}.$$

其中 $\alpha_n \to 0$ $(n \to +\infty)$ ， $b_n = [F'_\theta(\theta) + \alpha_n]\sqrt{\varepsilon} \to b = F'_\theta(\theta)\sqrt{\varepsilon} > 0$. 在上式中，令 $b_n/\sqrt{n} = 1/K_n$ ，则 $K_n = b_n^{-1}\sqrt{n} \to +\infty$ $(n \to +\infty)$ ，且有 $n = K_n^2 b_n^2$ ，因此有

$$\begin{aligned}
[F_\theta(\theta - \sqrt{\varepsilon/n})]^n &= (1 - b_n/\sqrt{n})^n = (1 - 1/K_n)^n \\
&= (1 - 1/K_n)^{K_n^2 b_n^2} \\
&= [(1 - 1/K_n)^{K_n}]^{K_n b_n^2}.
\end{aligned}$$

当 $n \to +\infty$ 时， $K_n \to +\infty$ ， $(1 - 1/K_n)^{K_n} \to e^{-1}$ ； $b_n \to b$ ， $K_n b_n^2 \to +\infty$ ，因此上式右端极限为 0 ，所以必有 $[F_\theta(\theta - \sqrt{\varepsilon/n})]^n \to 0$ ， 即 $n|\theta - X_{(n)}|^2 \xrightarrow{P} 0$ 。从而由 Slutsky 定理可知， $nF'_\theta(\theta)(X_{(n)} - \theta)$ 与 $-n[1 - F_\theta(X_{(n)})]$ 有相同的渐近分布。因为 $Z_i = F_\theta(X_i) \sim R(0,1),\ i = 1, 2, \cdots, n$ ，所以 $Z_{(n)} = F_\theta(X_{(n)})$ 是均匀分布 $R(0,1)$ 上的最大次序统计量， $F_\theta(X_{(n)}) \sim BE(n,1)$ 。所以对于任意的 $t < 0$ ，我们有

$$\begin{aligned}
\lim_{n\to\infty} P\{nF'_\theta(\theta)(X_{(n)} - \theta) \le t\} &= \lim_{n\to\infty} P\{-n[1 - F_\theta(X_{(n)})] \le t\} \\
&= \lim_{n\to\infty} P\{F_\theta(X_{(n)}) \le 1 + \frac{t}{n}\} \\
&= \lim_{n\to\infty} (1 + \frac{t}{n})^n = e^t
\end{aligned}$$

所以 $nF'_\theta(\theta)(X_{(n)} - \theta) \xrightarrow{L} Y$ ，其中 Y 的分布函数为 $F(y) = e^y I\{y \le 0\}$ 。 ∎

20. ★ 设 $X_1, \cdots, X_n$ 为 *i.i.d.* 样本， X_1 服从均匀分布 $R(\theta - \frac{1}{2}, \theta + \frac{1}{2})$ ，其中 $\theta \in R$ 未知。证明： $\frac{1}{2}(X_{(1)} + X_{(n)})$ 为 θ 的强相合估计 (提示：证明 $\sum_{n=1}^{\infty} \mathrm{Var}(\frac{X_{(1)}+X_{(n)}}{2})$ 收敛) 。

证明. 首先求 $\mathrm{Var}(\frac{X_{(1)}+X_{(n)}}{2})$ 的一个上界，然后证 $\sum_{n=1}^{\infty} \mathrm{Var}(\frac{X_{(1)}+X_{(n)}}{2})$ 收敛，从而得到 $\frac{1}{2}(X_{(1)} + X_{(n)})$ 为 θ 的强相合估计。

令 $Y_i = X_i - (\theta - \frac{1}{2}),\ i = 1, 2, \cdots, n$ ，则

$$Y_{(1)} = X_{(1)} - (\theta - \frac{1}{2}) \sim BE(1,n), \quad Y_{(n)} = X_{(n)} - (\theta - \frac{1}{2}) \sim BE(n,1).$$

由此易得

$$\begin{aligned}
&\mathrm{E}(\frac{X_{(1)} + X_{(n)}}{2}) = \theta, \\
&\mathrm{Var}(X_{(1)}) = \mathrm{Var}[X_{(1)} - (\theta - \frac{1}{2})] = \mathrm{Var}(Y_{(1)}) = \frac{n}{(n+1)^2(n+2)}, \\
&\mathrm{Var}(X_{(n)}) = \mathrm{Var}[X_{(n)} - (\theta - \frac{1}{2})] = \mathrm{Var}(Y_{(n)}) = \frac{n}{(n+1)^2(n+2)}.
\end{aligned}$$

因为

$$\begin{aligned}
\mathrm{Var}(\frac{X_{(1)} + X_{(n)}}{2}) &= \frac{1}{4}[\mathrm{Var}(X_{(1)}) + \mathrm{Var}(X_{(n)}) + 2\mathrm{Cov}(X_{(1)}, X_{(n)})], \\
\mathrm{Cov}(X_{(1)}, X_{(n)}) &\le [\mathrm{Var}(X_{(1)}) \cdot \mathrm{Var}(X_{(n)})]^{\frac{1}{2}} \le \frac{n}{(n+1)^2(n+2)}.
\end{aligned}$$

所以有

$$\mathrm{Var}(\frac{X_{(1)} + X_{(n)}}{2}) \le \frac{1}{4}\frac{4n}{(n+1)^2(n+2)} = \frac{n}{(n+1)^2(n+2)} \to 0 \quad (n \to \infty).$$

因此首先可知 $\frac{1}{2}(X_{(1)}+X_{(n)})$ 为 θ 的相合估计。同时有

$$\sum_{n=1}^{\infty}\mathrm{Var}(\frac{X_{(1)}+X_{(n)}}{2})\le\sum_{n=1}^{\infty}\frac{n}{(n+1)^2(n+2)}<\infty.$$

因此 $\sum_{n=1}^{\infty}\mathrm{Var}(\frac{X_{(1)}+X_{(n)}}{2})$ 收敛，所以由 Borel-Cantell 引理知 $\frac{1}{2}(X_{(1)}+X_{(n)})$ 为 θ 的强相合估计。 ∎

21. ★ 设 $X_1,\cdots,X_n$ 为 *i.i.d.* 样本， X_1 服从 Cauchy 分布，即 $f(x_1,\theta)=\frac{1}{\pi[1+(x_1-\theta)^2]}$ ，其中 $\theta\in R$ 未知。证明： $\bar{X}$ 不是 θ 的相合估计，其中 $\bar{X}=\frac{1}{n}\sum_{i=1}^{n}X_i$ 。

证明. 因为 X_j 的特征函数为

$$\phi_j(t)=\exp\{it\theta-|t|\},\ j=1,2,\cdots,n,$$

所以 $\bar{X}$ 的特征函数为

$$\phi(t)=\prod_{j=1}^{n}\phi_j(\frac{t}{n})=\exp\{it\theta-|t|\}.$$

所以 $\bar{X}$ 与 X_1 同分布。因此对任意的 n 和 $\varepsilon>0$ 都有

$$P\{|\bar{X}-\theta|>\varepsilon\}=P\{|X_1-\theta|>\varepsilon\}=a(\varepsilon).$$

其中 $a(\varepsilon)$ 与 n 无关，当 $n\to\infty$ 时不可能有 $a(\varepsilon)\to 0$ ，所以 $\bar{X}$ 不是 θ 的相合估计。 ∎

22. 设 $S_n\sim\chi_n^2$ ，证明： $\sqrt{S_n}-\sqrt{n}$ 的渐近分布为 $N(0,\frac{1}{2})$ 。

证明. 由原书第一章第 22 题 (2) 可知 $(S_n-n)/\sqrt{2n}\xrightarrow{L}N(0,1)$ ，即

$$\frac{S_n-n}{\sqrt{n}}=\sqrt{n}(\frac{S_n}{n}-1)\xrightarrow{L}N(0,2).$$

若取 $\phi(x)=\sqrt{x}$ ，则有

$$\sqrt{n}\ [\phi(\frac{S_n}{n})-\phi(1)]=\sqrt{n}\ [\sqrt{\frac{S_n}{n}}-1]=\sqrt{S_n}-\sqrt{n}.$$

另一方面，由原书引理 5.3.3 可知

$$\sqrt{S_n}-\sqrt{n}=\sqrt{n}\ [\phi(\frac{S_n}{n})-\phi(1)]\xrightarrow{L}N(0,[\phi'(1)]^2\cdot 2).$$

即 $\sqrt{S_n}-\sqrt{n}\xrightarrow{L}N(0,\frac{1}{2})$ 。 ∎

23. 设 $X_1,\cdots,X_n$ 独立同分布，并设 $EX_1=\mu,\ \mathrm{Var}(X_1)=\sigma^2,\ \mathrm{Var}(X_1^2)=\tau^2$ ， $S^2=n^{-1}\sum_{i=1}^{n}(X_i-\bar{X})^2$ 。求 $\mu^2,\ \mu^k$ 以及 $\sigma,\ \sigma^k$ 的 CAN ，并求它们的渐近分布。

解. 可应用原书引理 5.3.3 求解。由于 $\bar{X}$ 是 μ 的 CAN ，即 $\sqrt{n}(\bar{X}-\mu)\xrightarrow{L}N(0,\sigma^2)$ 。若取 $\phi(\mu)=\mu^k$ ，则有 $\phi'(\mu)=k\mu^{k-1}$ ，因此由引理 5.3.3 可得

$$\sqrt{n}(\bar{X}^k-\mu^k)\xrightarrow{L}N(0,\ k^2\mu^{2k-2}\sigma^2).$$

特别，若 $k=2$ ，则有 $\sqrt{n}(\bar{X}^2-\mu^2)\xrightarrow{L}N(0,\ 4\mu^2\sigma^2)$ 。

由原书例 5.3.7 可知， $T=S^2$ 为 $\delta=\sigma^2$ 的 CAN ，且有 $\sqrt{n}(T-\delta)\xrightarrow{L}N(0,\tau^2)$ 。对于 $\sigma^k=\delta^{k/2}$ ，可取 $\phi(\delta)=\delta^{k/2}$ ，则有 $\phi'(\delta)=(k/2)\delta^{k/2-1}$ ，因此由引理 5.3.3 可知，$\phi(T)=T^{k/2}=S^k$ 是 $\phi(\delta)=\delta^{k/2}=\sigma^k$ 的 CAN ，且有

$$\sqrt{n}(S^k-\sigma^k)=\sqrt{n}[\phi(T)-\phi(\delta)]\xrightarrow{L}N(0,\ [(k/2)\delta^{k/2-1}]^2\tau^2)=N(0,\ (k^2/4)\sigma^{2k-4}\tau^2).$$

特别，若 $k=1$ ，则有 $\sqrt{n}(S-\sigma)\xrightarrow{L}N(0,\ \sigma^{-2}\tau^2/4)$ 。 ∎

24. 设 $X_1,\cdots,X_n$ 为 *i.i.d.* 样本， $X_1\sim b(1,\ \theta),\ 0<\theta<1$ 。

(1) 试基于 $\bar{X}$ 求 $g(\theta)=\theta/(1-\theta)$ 的一个矩估计 $\hat{g}_n(X)$ ；

(2) 求 $\sqrt{n}(\hat{g}_n(X)-g(\theta))$ 的渐近分布，并证明 $\hat{g}_n(X)$ 是 $g(\theta)$ 的 BAN 估计。

解. (1) 因为 $g(\theta)$ 在 $(0,1)$ 上连续，且 $\bar{X}$ 是 θ 的矩估计，所以 $\hat{g}_n(X)=g(\bar{X})=\bar{X}/(1-\bar{X})$ 是 $g(\theta)$ 的一个矩估计。

(2) 由中心极限定理知

$$\sqrt{n}(\bar{X}-\theta)\xrightarrow{L}N(0,\theta(1-\theta)).$$

因此 $\hat{g}(X)$ 是 $g(\theta)$ 的 CAN ，且有

$$\sqrt{n}(g(\bar{X})-g(\theta))\xrightarrow{L}N(0,[g'(\theta)]^2\theta(1-\theta)).$$

即 $\sqrt{n}(\hat{g}_n(X)-g(\theta))\xrightarrow{L}N(0,\theta(1-\theta)^{-3})$ 。

而 X_1 的 Fisher 信息为 $i(\theta)=[\theta(1-\theta)]^{-1}$ ，所以 $[g'(\theta)]^2i^{-1}(\theta)=\theta(1-\theta)^{-3}$ ，从而可知 $\hat{g}_n(X)$ 是 $g(\theta)$ 的 BAN 估计。 ∎

25. 设 $X_1,\cdots,X_n$ 为 *i.i.d.* 样本。

(1) 若 $X_1\sim R(0,\ \theta),\ \theta>0$ ，证明： $n(\theta-X_{(n)})$ 的分布收敛于指数分布 $E(1/\theta)$ ；

(2) 若 $X_1\sim R(0,\ n\theta),\ \theta>0$ ，证明： $n\theta-X_{(n)}$ 的分布收敛于指数分布 $E(1/\theta)$ ，并由此给出 θ 的一个相合估计；

(3) 若 $X_1\sim R(0,\ \theta),\ \theta>0$ ，证明： $LR(\theta_0)$ 的分布为 $\chi^2(2)$ ，而不是收敛到 $\chi^2(1)$ 。

证明. (1) $T=X_{(n)}$ 的密度函数为

$$f(t;\theta)=nt^{n-1}\theta^{-n}I\{0\le t\le\theta\}.$$

令 $Y=n(\theta-X_{(n)})=n(\theta-T)$ ，则 $t=\theta-y/n$ ， Y 的密度函数为

$$\begin{aligned}f(y;\theta)&=n(\theta-\frac{y}{n})^{n-1}\theta^{-n}\frac{1}{n}I\{0\le y\le n\theta\}\\&=\frac{1}{\theta}[(1-\frac{y}{n\theta})^{-\frac{n\theta}{y}}]^{-\frac{y}{n\theta}(n-1)}I\{0\le y\le n\theta\}\\&\to\frac{1}{\theta}e^{-\frac{y}{\theta}}I\{y\ge 0\}\quad(n\to\infty).\end{aligned}$$

所以 $n(\theta-X_{(n)})$ 的分布收敛于指数分布 $E(1/\theta)$ 。

(2) $T=X_{(n)}$ 的分布密度函数为

$$f(t;\theta)=nt^{n-1}(n\theta)^{-n}I\{0\le t\le n\theta\}.$$

令 $Y = n\theta - X_{(n)}$ ，则 Y 的密度函数为

$$g_n(y;\theta) = n(n\theta - y)^{n-1}(n\theta)^{-n} I\{0 \le y \le n\theta\}.$$

当 $n \to \infty$ 时，我们有

$$\begin{aligned} g_n(y;\theta) &= n(n\theta - y)^{n-1}(n\theta)^{-n} = \frac{1}{\theta}\left[(1-\frac{y}{n\theta})^{-\frac{n\theta}{y}}\right]^{-\frac{y}{n\theta}(n-1)} \\ &\to \frac{1}{\theta}e^{-\frac{1}{\theta}y} \quad (n \to \infty). \end{aligned}$$

所以 $Y = n\theta - X_{(n)}$ 的分布收敛于指数分布 $E(1/\theta)$ 。

下面，我们证明 $\hat{\theta}_n = n^{-1}X_{(n)}$ 是 θ 的一个相合估计。 对任意的 $\varepsilon > 0$ 有

$$\begin{aligned} P\{|\hat{\theta}_n - \theta| \ge \varepsilon\} &= P\{|n\theta - X_{(n)}| \ge n\varepsilon\} \\ &= P\{n\theta - X_{(n)} \ge n\varepsilon\} \\ &= \int_{n\varepsilon}^{+\infty} g_n(y;\theta)dy \to 0 \quad (n \to \infty). \end{aligned}$$

所以 $\hat{\theta}_n = n^{-1}X_{(n)}$ 是 θ 的一个相合估计。

注. 本题亦可直接根据 $X_{(n)}$ 的分布来证明 $n^{-1}X_{(n)}$ 的相合性。

(3) 由假设可知, $f(x,\theta) = \theta^{-n}I\{0 \le x_n \le \theta\}$, $L(\theta) = -n\log\theta + \log[I\{0 \le x_n \le \theta\}]$, 同时有 $\hat{\theta} = X_{(n)}$ ，因此

$$LR(\theta) = 2[-n\log X_{(n)} + n\log\theta] = 2n\log\frac{\theta}{X_{(n)}} = 2n\log\frac{\theta}{T} \quad (T \le \theta).$$

其中 $T = X_{(n)}$ 。令 $U = LR(\theta) = 2n\log(\theta/T)$ ，则 $T = \theta e^{-U/(2n)}$ ，所以 U 的密度函数为

$$\begin{aligned} f(u;\theta) &= n[\theta e^{-u/(2n)}]^{n-1}\theta^{-n} \cdot \theta e^{-u/(2n)} \cdot \frac{1}{2n} I\{u \ge 0\} \\ &= \frac{1}{2}e^{-u/2}I\{u \ge 0\} \sim \Gamma(\frac{1}{2}, 1) \sim \chi^2(2) \end{aligned}$$

所以对某一固定的 θ_0 ，我们有 $LR(\theta_0) \sim \chi^2(2)$ ，而不是 $\chi^2(1)$ 。

注. 由于均匀分布 $\{R(0,\ \theta),\ \theta > 0\}$ 不属于 CR 分布族，它不满足原书定理 5.3.6 的条件，因此定理 5.3.8 不一定成立，本题也可视为一个反例。 ∎

26. 设 $X_1, \cdots, X_n$ 为 *i.i.d.* 样本,

(1) 若 $X_1 \sim R(0,1)$ ，令 $Y_n = (\prod_{i=1}^n X_i)^{-\frac{1}{n}}$ ，证明： $\sqrt{n}(Y_n - e) \xrightarrow{L} N(0, e^2)$ ，其中 e 是自然对数的底数 (提示：令 $Z = \ln Y_n = -n^{-1}\sum_{i=1}^n \ln X_i$ ，然后用中心极限定理) ；

(2) 若 $X_1 \sim R(0,\theta)$ ，推导相应的结果，并据此给出 θ 的一个相合估计。

证明. (1) 令 $Z_n = \log Y_n = -\frac{1}{n}\sum_{i=1}^n \log X_i$ 。因为 $X_1, \cdots, X_n$ 为 *i.i.d.* 样本，所以 $\log X_1, \cdots, \log X_n$ 亦独立同分布，且有 $-\log X_1 \sim E(1)$ 指数分布。从而由中心极限定理可得

$$\frac{\sum_{i=1}^n -\log X_i - n\mathrm{E}(-\log X_1)}{\sqrt{n\mathrm{Var}(-\log X_1)}} \xrightarrow{L} N(0,1),$$

又因为 $\mathrm{E}(-\log X_1)=1,\ \mathrm{Var}(-\log X_1)=1$ ，所以

$$\frac{-\sum_{i=1}^n \log X_i - n}{\sqrt{n}} \xrightarrow{L} N(0,1).$$

即

$$\sqrt{n}(-\frac{1}{n}\sum_{i=1}^n \log X_i - 1) = \sqrt{n}(Z_n - 1) \xrightarrow{L} N(0,1).$$

若取 $\phi(x)=e^x$ ，则有 $\phi'(x)=e^x$ ， $\phi(Z_n)=e^{Z_n}=Y_n$ ，因此由原书引理 5.3.3 以及上式可得

$$\sqrt{n}\ [\phi(Z_n)-\phi(1)] = \sqrt{n}(Y_n - e) \xrightarrow{L} N(0,\ \phi'(1)^2) \sim N(0, e^2).$$

(2) 令 $W_i = X_{(i)}/\theta$ ，则 $W_1,\cdots,W_n$ 为 *i.i.d.* 样本，且有 $W_1 \sim R(0,1)$ 。因此由 (1) 的结果可得

$$\sqrt{n}(Y_n - e) \xrightarrow{L} N(0,e^2); \quad Y_n = (\prod_{i=1}^n W_i)^{-\frac{1}{n}}.$$

今记 $T_n(X) = (\prod_{i=1}^n X_i)^{-\frac{1}{n}}$ ，则有

$$T_n = (\prod_{i=1}^n X_i)^{-\frac{1}{n}} = (\prod_{i=1}^n \theta W_i)^{-\frac{1}{n}} = \theta^{-1} Y_n.$$

则由以上结果可得

$$\sqrt{n}(T_n - \theta^{-1}e) = \sqrt{n}(\theta^{-1}Y_n - \theta^{-1}e) \to N(0, \theta^{-2}e^2).$$

因此 T_n 是 $\theta^{-1}e$ 的 CAN ，当 $n\to\infty$ 时有 $T_n \xrightarrow{P} \theta^{-1}e$ ， $eT_n^{-1} \xrightarrow{P} \theta$ 。所以 $e(\prod_{i=1}^n X_i)^{\frac{1}{n}}$ 是 θ 的一个相合估计。 ∎

27. 设 $X_1,\cdots,X_n$ 为 *i.i.d.* 样本， $X_1 \sim f(x_1,\theta) = \theta(\theta+1)x_1^{\theta-1}(1-x_1)I\{0<x_1<1\}$ ，其中 $0<x_1<1,\ \theta>0$ 。

(1) 证明： $T_n = \frac{2\bar{X}}{1-\bar{X}}$ 是 θ 的一个矩估计；

(2) 证明： $\sqrt{n}(T_n - \mu_n(\theta))/\sigma_n(\theta) \xrightarrow{L} N(0,1)$ ，其中 $\mu_n(\theta)=\theta,\ \sigma_n^2(\theta) = \frac{\theta(\theta+2)^2}{2(\theta+3)}$ 。

证明. (1) 因为 X_1 服从 β 分布，即 $X_1 \sim BE(\theta,2)$ ，因此有

$$\mathrm{E}(X_1) = a = \frac{\theta}{\theta+2}, \quad \mathrm{Var}(X_1) = \sigma^2 = \frac{2\theta}{(\theta+2)^2(\theta+3)}.$$

所以由 $\bar{X} \xrightarrow{P} \mathrm{E}(X_1) = \frac{\theta}{\theta+2}$ 可知 $T_n = \frac{2\bar{X}}{1-\bar{X}}$ 是 θ 的一个矩估计。

(2) 基于以上符号，由中心极限定理可知

$$\sqrt{n}(\bar{X} - a) \xrightarrow{L} N(0,\sigma^2).$$

令 $\phi(x) = \frac{2x}{1-x}$ ， $\phi(a) = \frac{2a}{1-a}$ ，则有 $\phi(a)=\theta$ ， $\phi'(a) = \frac{2}{(1-a)^2} = (\theta+2)^2/2$ 。因此由原书引理 5.3.3 以及上式可得

$$\sqrt{n}[\phi(\bar{X}) - \phi(a)] \xrightarrow{L} N(0,\ [\phi'(a)]^2\sigma^2).$$

其中

$$\phi(\bar{X}) = \frac{2\bar{X}}{1-\bar{X}} = T_n, \quad \phi(a) = \frac{2a}{1-a} = \theta = \mu_n(\theta),$$
$$[\phi'(a)]^2\sigma^2 = \frac{(\theta+2)^4}{4}\sigma^2 = \frac{\theta(\theta+2)^2}{2(\theta+3)} = \sigma_n^2(\theta).$$

所以有

$$\sqrt{n}(T_n - \mu_n(\theta))/\sigma_n(\theta) \xrightarrow{L} N(0,1).$$

∎

28. 设 $X_1, \cdots, X_n$ 为 *i.i.d.* 样本， $X_1 \sim (\mu, \sigma^2)$ ，即 $\mathrm{E}(X_1) = \mu$, $\mathrm{Var}(X_1) = \sigma^2 < \infty$ 。设函数 $h(t)$ 的二阶导数 $h''(t)$ 在 $t = \mu$ 处连续，且 $h'(\mu) = 0$ 。

(1) 证明： $\sqrt{n}[h(\bar{X}) - h(\mu)] \xrightarrow{P} 0$ ，且 $n[h(\bar{X}) - h(\mu)]$ 的渐近分布为 $\frac{1}{2}h''(\mu)\sigma^2 V$ ，其中 $V \sim \chi_1^2$ ；

(2) 证明：当 $\mu = \frac{1}{2}$ 时， $n[\bar{X}(1-\bar{X})] - n[\mu(1-\mu)] \xrightarrow{L} -\sigma^2 V$ ，其中 $V \sim \chi_1^2$ 。

证明. (1) 由中心极限定理可知，当 $n \to \infty$ 时有

$$Z_n = \sqrt{n}(\bar{X} - \mu) \xrightarrow{L} N(0, \sigma^2).$$

即 $Z_n \xrightarrow{L} Z$; $Z \sim N(0, \sigma^2)$ ，且有 $\bar{X} \xrightarrow{P} \mu$ 。 $h(\bar{X})$ 在 μ 处的二阶 Taylor 展开式为

$$h(\bar{X}) = h(\mu) + h'(\mu)(\bar{X} - \mu) + \frac{1}{2}h''(\xi)(\bar{X} - \mu)^2.$$

其中 ξ 为 $\bar{X}$ 与 μ 之间的一点，且有 $\xi \xrightarrow{P} \mu$ 。因为 $h(x)$ 的一阶导数 $h'(\mu) = 0$ ，并在 μ 有连续的二阶导数，所以

$$\sqrt{n}[h(\bar{X}) - h(\mu)] = \frac{1}{2}h''(\xi)(\bar{X} - \mu)\sqrt{n}(\bar{X} - \mu) = \frac{1}{2}h''(\xi)(\bar{X} - \mu)Z_n.$$

由于 $h''(\xi) \xrightarrow{P} h''(\mu)$ ， $(\bar{X} - \mu) \xrightarrow{P} 0$ ， $Z_n \xrightarrow{L} Z$ ，所以由 Slutsky 定理可得 $\sqrt{n}(h(\bar{X}) - h(\mu)) \xrightarrow{L} 0$ ，从而也有 $\sqrt{n}(h(\bar{X}) - h(\mu)) \xrightarrow{P} 0$ 。类似的展开可得

$$n[h(\bar{X}) - h(\mu)] = \frac{1}{2}h''(\xi)Z_n^2 = \frac{1}{2}h''(\xi)\sigma^2[Z_n/\sigma]^2.$$

由于 $h''(\xi) \xrightarrow{P} h''(\mu)$ ， $Z_n/\sigma \xrightarrow{L} N(0,1)$ ， $[Z_n/\sigma]^2 \xrightarrow{L} V \sim \chi_1^2$ 。因此由 Slutsky 定理可知， $n[h(\bar{X}) - h(\mu)]$ 的渐近分布为 $\frac{1}{2}h''(\mu)\sigma^2 V$ ，其中 $V \sim \chi_1^2$ 。

(2) 令 $h(x) = x(1-x)$ ，则有 $h'(x) = 1 - 2x$ ， $h''(x) = -2$ ，以及 $h'(1/2) = 0$, $h''(1/2) = -2$ 。所以当 $\mu = 1/2$ 时，由 (1) 可得 $n[\bar{X}(1-\bar{X})] - n[\mu(1-\mu)] \xrightarrow{L} -\sigma^2 V$ ，其中 $V \sim \chi_1^2$ 。 ∎

29. ★ 设 $X_1, \cdots, X_n$ 为 *i.i.d.* 样本, $X_1 \sim N(\theta, \sigma^2)$ 。现有 θ^2 的四个估计 δ_{1n}, δ_{2n}, δ_{3n}, δ_{4n} ，其中 $\delta_{1n} = \bar{X}^2 - \sigma^2/n$ 为 σ^2 已知条件下， θ^2 的 UMVUE ； $\delta_{2n} = \bar{X}^2 - \frac{T^2}{n(n-1)}$, $(T^2 = \sum_{i=1}^n (X_i - \bar{X})^2)$ 为 σ^2 未知条件下， θ^2 的 UMVUE ； $\delta_{3n} = \bar{X}^2$ 为 θ^2 的 MLE ； $\delta_{4n} = \max\{0, \delta_{1n}\}$ 为 δ_{1n} 的改进。证明：当 $\theta \neq 0$ 时， δ_{1n}, δ_{2n}, δ_{3n}, δ_{4n} 有相同的渐近分布，并且都是 θ^2 的 BAN 估计。

证明. 因为 $\sqrt{n}(\bar{X}-\theta)\xrightarrow{L}N(0,\sigma^2)$,取 $\phi(x)=x^2$,则 $\sqrt{n}[\phi(\bar{X})-\phi(\theta)]\xrightarrow{L}N(0,[\phi'(\theta)]^2\sigma^2)$, 即 $\sqrt{n}(\bar{X}^2-\theta^2)\xrightarrow{L}N(0,4\theta^2\sigma^2)$ 。因此对 δ_{3n} 有

$$\sqrt{n}(\delta_{3n}-\theta^2)\xrightarrow{L}N(0,4\theta^2\sigma^2).$$

因为 $n\to\infty$ 时， $\sigma^2/\sqrt{n}\to 0$ ，且 $\sqrt{n}(\delta_{1n}-\theta^2)=\sqrt{n}(\delta_{3n}-\theta^2)-\sigma^2/\sqrt{n}$ ，所以由 Slutsky 定理可知， $\sqrt{n}(\delta_{1n}-\theta^2)$ 与 $\sqrt{n}(\delta_{3n}-\theta^2)$ 有相同的渐近分布，即

$$\sqrt{n}(\delta_{1n}-\theta^2)\xrightarrow{L}N(0,4\theta^2\sigma^2).$$

类似地，在 δ_{2n} 中，由于 $T^2/(n-1)\xrightarrow{P}\sigma^2$ ，因此有

$$\sqrt{n}(\delta_{2n}-\theta^2)=\sqrt{n}(\bar{X}^2-\theta^2)-\frac{1}{\sqrt{n}}\frac{T^2}{n-1};\quad \frac{1}{\sqrt{n}}\frac{T^2}{n-1}\xrightarrow{P}0.$$

所以由 Slutsky 定理也有

$$\sqrt{n}(\delta_{2n}-\theta^2)\xrightarrow{L}N(0,4\theta^2\sigma^2).$$

对于 δ_{4n} ，由于

$$\sqrt{n}(\delta_{4n}-\theta^2)=\sqrt{n}(\delta_{1n}-\theta^2)+\sqrt{n}(\delta_{4n}-\delta_{1n}).$$

下面我们证明 $\sqrt{n}(\delta_{4n}-\delta_{1n})\xrightarrow{P}0$ 。由 δ_{4n} 的定义可知，当 $\delta_{1n}\geq 0$ 时 $\delta_{4n}=\delta_{1n}$ ，因此 $\sqrt{n}(\delta_{4n}-\delta_{1n})=0$ ；当 $\delta_{1n}<0$ 时 $\delta_{4n}=0$ ，这时 $\sqrt{n}(\delta_{4n}-\delta_{1n})=-\sqrt{n}\delta_{1n}$ 。所以对任意的 $\varepsilon>0$ ，我们有

$$P\{\sqrt{n}|\delta_{4n}-\delta_{1n}|>\varepsilon\}=P\{-\sqrt{n}\delta_{1n}>\varepsilon,\ \ \delta_{1n}<0\}\leq P\{\delta_{1n}<0\}.$$

而在 $\delta_{1n}=\bar{X}^2-\sigma^2/n$ 中，由于 $\theta\neq 0$ ，当 $n\to\infty$ 时， $\bar{X}^2\xrightarrow{P}\theta^2>0$ ， $\sigma^2/n\to 0$ 。因此 $\delta_{1n}=\bar{X}^2-\sigma^2/n\xrightarrow{P}\theta^2>0$ ，所以必有 $P\{\delta_{1n}<0\}\to 0$ ， $P\{\sqrt{n}|\delta_{4n}-\delta_{1n}|>\varepsilon\}\to 0$ ，即 $\sqrt{n}(\delta_{4n}-\delta_{1n})\xrightarrow{P}0\ (n\to\infty)$ ，因此 $\sqrt{n}(\delta_{4n}-\theta^2)$ 与 $\sqrt{n}(\delta_{1n}-\theta^2)$ 有相同的渐近分布：

$$\sqrt{n}(\delta_{4n}-\theta^2)\xrightarrow{L}N(0,4\theta^2\sigma^2).$$

另外， X_1 关于 θ 的 Fisher 信息为 $i(\theta)=1/\sigma^2$ ，因此 θ^2 的 C-R 下界为 CRLB= $[(\theta^2)']^2(1/\sigma^2)^{-1}=4\theta^2\sigma^2$ ，所以这四个估计都是 θ^2 的 BAN 估计。 ∎

30. 设 $X_1,\cdots,X_n$ 为 *i.i.d.* 样本, X_1 存在前 4 阶矩。求下列统计量的渐近分布：(1) $\hat{g}_1(X)=(\bar{X},\ \frac{1}{n}\sum_{i=1}^n X_i^2)$ ； (2) $\hat{g}_2(X)=(\bar{X},\ S^2)$ ， $S^2=\frac{1}{n}\sum_{i=1}^n(X_i-\bar{X})^2$ 。

证明. (1) 记 $Y_1=\bar{X},\ Y_2=n^{-1}\sum_{i=1}^n X_i^2$ ，则 $\hat{g}_1(X)=(Y_1,\ Y_2)$ ，由矩估计的性质可知

$$\sqrt{n}\left(\begin{pmatrix}\frac{1}{n}\sum_{i=1}^n X_i\\ \frac{1}{n}\sum_{i=1}^n X_i^2\end{pmatrix}-\begin{pmatrix}\mu_1\\ \mu_2\end{pmatrix}\right)\xrightarrow{L}N(0,V(\mu)).$$

即 $\sqrt{n}((Y_1,\ Y_2)^T-(\mu_1,\ \mu_2)^T)\xrightarrow{L}N(0,V(\mu))$ ，其中

$$V(\mu)=\begin{pmatrix}\sigma^2 & \mu_3-\mu_1\mu_2\\ \mu_3-\mu_1\mu_2 & \mu_4-\mu_2^2\end{pmatrix}.$$

μ_i $(i=1,2,3,4)$ 是 X_1 的 i 阶原点矩。

(2) 由于 $S^2 = Y_2 - Y_1^2$ ，因此 $\hat{g}_2(X) = (\bar{X},\ S^2)$ 可表示为 $(Y_1,\ Y_2)$ 的函数。令 $\phi_1(\mu_1,\mu_2)=\mu_1,\ \phi_2(\mu_1,\mu_2)=\mu_2-\mu_1^2$, 则有 $\phi_1(Y_1,Y_2)=Y_1=\bar{X}$ ， $\phi_2(Y_1,Y_2)=Y_2-Y_1^2=S^2$ 。因此有 $\hat{g}_2(X)=(\phi_1(Y_1,Y_2),\ \phi_2(Y_1,Y_2))^T$ 。函数 $\phi_1,\ \phi_2$ 关于 (μ_1,μ_2) 的导数为

$$F(\mu)=\left(\frac{\partial\phi_i}{\partial\mu_j}\right)=\begin{pmatrix} 1 & 0 \\ -2\mu_1 & 1 \end{pmatrix}.$$

所以根据原书引理 5.3.3 的推论，即 (5.3.8) 式可得

$$\sqrt{n}[\hat{g}_2(X)-(\phi_1,\phi_1)]\xrightarrow{L}N(0,\ FVF^T);\quad \phi_1=\mu_1,\ \phi_2=\mu_2-\mu_1^2.$$

经直接计算可得

$$\sqrt{n}[\hat{g}_2(X)-(\phi_1,\phi_1)]\xrightarrow{L}N(0,\Omega).$$

其中 $\Omega=\begin{pmatrix} \sigma^2 & \nu_3 \\ \nu_3 & \nu_4-\sigma^4 \end{pmatrix}$, $\sigma^2=\mu_2-\mu_1^2,\ \nu_3=\mathrm{E}(X_1-\mu_1)^3,\ \nu_4=\mathrm{E}(X_1-\mu_1)^4$ 。 ∎

31. 设 $X_1,\cdots,X_n$ 为 *i.i.d.* 样本， $X_1\sim N(\mu,\sigma^2)$ ， σ^2 已知。设 $p=P(X_1>a)$ 的极大似然估计为 $\hat{p}$ ，求 $\sqrt{n}(\hat{p}-p)$ 的渐近分布。

解. 由定义可得

$$\begin{aligned} p &= P(X_1>a)=1-P(X_1\le a) \\ &= 1-P(\frac{X_1-\mu}{\sigma}\le\frac{a-\mu}{\sigma}) \\ &= 1-\Phi(\frac{a-\mu}{\sigma}). \end{aligned}$$

其中 $\Phi(\cdot)$ 是标准正态分布 $N(0,1)$ 的分布函数,所以 p 的极大似然估计为 $\hat{p}=1-\Phi(\frac{a-\hat{\mu}}{\sigma})$, $\hat{\mu}=\bar{X}$ 。又因为 $\sqrt{n}(\hat{\mu}-\mu)\to N(0,\sigma^2)$ ，所以令 $g(x)=1-\Phi(\frac{a-x}{\sigma})$ ，则有 $g(\mu)=p$, $g(\hat{\mu})=\hat{p}$ ，因此

$$\sqrt{n}(\hat{p}-p)=\sqrt{n}[g(\hat{\mu})-g(\mu)]\to N(0,\ \sigma^2\cdot[g'(\mu)]^2).$$

即

$$\sqrt{n}(\hat{p}-p)\sim N(0,\ \phi^2(\frac{a-\mu}{\sigma})).$$

其中 $\phi(\cdot)$ 是标准正态分布 $N(0,1)$ 的密度函数。 ∎

32. 设 $X_1,\cdots,X_n$ 为 *i.i.d.* 样本, X_1 服从两点分布,即 $X_1\sim b(1,\theta)$,证明: $\sqrt{n}\{\arcsin\sqrt{\bar{X}}-\arcsin\sqrt{\theta}\}$ 具有渐近正态分布，并且其方差与参数无关。

证明. 由矩估计的性质知

$$\sqrt{n}(\bar{X}-\theta)\to N(0,\theta(1-\theta)).$$

令 $g(x)=\arcsin\sqrt{x}$ ，则 $g(\theta)=\arcsin\sqrt{\theta}$ ， $g(\bar{X})=\arcsin\sqrt{\bar{X}}$ 的渐近方差为

$$\theta(1-\theta)[g'(\theta)]^2=\theta(1-\theta)[\arcsin'\sqrt{\theta}]^2=\theta(1-\theta)[\frac{1}{\sqrt{1-\theta}}\cdot\frac{1}{2\sqrt{\theta}}]^2=\frac{1}{4}.$$

所以

$$\sqrt{n}(\arcsin\sqrt{\bar{X}} - \arcsin\sqrt{\theta}) \to N(0, \frac{1}{4}).$$

显然，其方差与参数无关。 ∎

第六章　参数假设检验

1. 在以下假设检验问题中，求检验 $\phi(x)$ 的第一、第二类错误以及在 H_1 情形下的功效：

(1) 设 X_1, X_2, X_3 为 $i.i.d.$ 样本， X_1 服从两点分布 $b(1,\theta)$ 。考虑假设检验问题 $H_0: \theta = \frac{1}{2} \longleftrightarrow H_1: \theta = \frac{3}{4}$ 。检验 $\phi(x)$ 的否定域为 $R^+ = \{X_1 + X_2 + X_3 \geq 1\}$ ；

(2) 设 X_1, X_2 相互独立，都服从 Poisson 分布 $P(\lambda)$ 。考虑假设检验问题 $H_0: \lambda = \frac{1}{2} \longleftrightarrow H_1: \lambda = 2$ 。检验 $\phi(x)$ 的否定域为 $R^+ = \{X_1 + X_2 \geq 3\}$ 。

解. (1) 因为 $T(X) = X_1 + X_2 + X_3 \sim b(3;\theta)$ ，所以检验函数 $\phi(x)$ 的第一类错误为

$$I(\theta) = P_{\theta=\frac{1}{2}}\{X \in R^+\} = P_{\theta=\frac{1}{2}}\{T \geq 1\} = 1 - P_{\theta=\frac{1}{2}}(T = 0) = 1 - \frac{1}{8} = \frac{7}{8}.$$

第二类错误为

$$II(\theta) = 1 - P_{\theta=\frac{3}{4}}(T \geq 1) = P_{\theta=\frac{3}{4}}(T = 0) = \frac{1}{64}.$$

在 H_1 情形下的功效为

$$\beta_\phi(\frac{3}{4}) = P_{\theta=\frac{3}{4}}(T \geq 1) = 1 - II(\theta) = \frac{63}{64}.$$

(2) 因为 $T(X) = X_1 + X_2 \sim P(2\lambda)$ ，所以检验函数 $\phi(x)$ 的第一类错误为

$$I(\lambda) = P_{\lambda=\frac{1}{2}}\{X \in R^+\} = P_{\lambda=\frac{1}{2}}(T \geq 3) = 1 - P_{\lambda=\frac{1}{2}}(T \leq 2) = 1 - \frac{5}{2}e^{-1}.$$

第二类错误为

$$II(\theta) = 1 - P_{\lambda=2}(T \geq 3) = P_{\lambda=2}(T \leq 2) = 13e^{-4}.$$

在 H_1 情形下的功效为

$$\beta_\phi(2) = P_{\lambda=2}(T \geq 3) = 1 - II(\theta) = 1 - 13e^{-4}.$$

∎

2. 考虑简单假设检验问题 $H_0: \theta = \theta_0 \longleftrightarrow H_1: \theta = \theta_1$ 。对于以下分布密度 $f(x;\theta)$ ，在一样本情况下，求检验问题水平为 α $(0 < \alpha < 1)$ 的 MPT ：

(1) $f(x;\theta) = 2\theta^{-2}(\theta - x)I\{0 \leq x \leq \theta\}$， $\theta_0 < \theta_1$ ；

(2) $f(x;\theta) = 2[\theta x + (1-\theta)(1-x)]I\{0 \leq x \leq 1\}$， $0 \leq \theta_1 < \theta_0 \leq 1$ 。

解. (1) 因为似然比

$$\begin{aligned}
\lambda(x) &= \frac{f(x;\theta_1)}{f(x;\theta_0)} = \frac{2{\theta_1}^{-2}(\theta_1 - x)\ I\{0 \leq x \leq \theta_1\}}{2{\theta_0}^{-2}(\theta_0 - x)\ I\{0 \leq x \leq \theta_0\}} \\
&= (\frac{\theta_0}{\theta_1})^2 \cdot \frac{\theta_1 - x}{\theta_0 - x} \cdot \frac{I\{x \leq \theta_1\}}{I\{x \leq \theta_0\}} \\
&= \begin{cases} (\frac{\theta_0}{\theta_1})^2 \cdot \frac{\theta_1 - x}{\theta_0 - x} & , \quad 0 \leq x < \theta_0 \\ +\infty & , \quad \theta_0 \leq x \leq \theta_1 \\ 0 & , \quad \text{其它} \end{cases}
\end{aligned}$$

根据 N-P 引理， $R^+=\{x:\ \lambda(x)>c\}$ 。在 $[\theta_0,\ \theta_1]$ 上 $\lambda(x)=\infty$ ，因此 $[\theta_0,\ \theta_1]\subset R^+$ ；而在 $[0\ ,\theta_0]$ 上 $\lambda(x)$ 为 x 的严增函数，因此 $\{x:\ \lambda(x)>c\}=\{x:\ x>k\}$ ， k 由 $\mathrm{E}_{\theta_0}[\phi(X)]=P_{\theta_0}(R^+)=\alpha$ 决定，由于 $f(x;\theta_0)$ 在 $[\theta_0,\ \theta_1]$ 上为 0 ，所以有

$$\phi(X)=\begin{cases}1 & , \quad k<X\le\theta_1\\ 0 & , \quad 0\le X\le k.\end{cases}$$

$$\mathrm{E}_{\theta_0}[\phi(X)]=\int_k^{\theta_0}2{\theta_0}^{-2}(\theta_0-x)\ dx=\alpha.$$

由此可得 $k\triangleq k_0=(1-\sqrt{\alpha})\theta_0$ ， 因此假设检验问题的 MPT 为

$$\phi(X)=\begin{cases}1 & , \quad k_0<X\le\theta_1\\ 0 & , \quad 0\le X\le k_0.\end{cases}$$

注. 由 $\lambda(x)$ 的表达式可知，分布族 $\{f(x;\theta)\}$ 关于 $T=X$ 为 MLR 分布族。所以由原书定理 6.3.1 可直接得到假设检验问题的 MPT 。

(2) 我们分两种情况来讨论假设检验问题的 MPT 。

i) 当 $\theta_0=\frac{1}{2}$ 时， $f(x;\theta_0)=1$ ，所以似然比为

$$\lambda(x)=f(x;\theta_1)/f(x;\theta_0)=f(x;\theta_1)=2(2\theta_1-1)x+2(1-\theta_1).$$

因为 $\theta_1<\theta_0=\frac{1}{2}$, 所以 $\lambda(x)$ 是 x 的严格递减函数，$R^+=\{x:\ \lambda(x)>c\}=\{x:\ x<k\}$ ，从而假设检验问题的 MPT 为

$$\phi(X)=\begin{cases}1 & , \quad 0\le X\le k\\ 0 & , \quad k<X\le 1.\end{cases}$$

其中 k 由 $\mathrm{E}_{\theta_0}[\phi(X)]=\alpha$ 决定。由于 $f(x;\theta_0)=1$ ，所以由 $\mathrm{P}_{\theta_0}\{0\le X\le k\}=\alpha$ 可得 $k=\alpha$ 。所以假设检验问题的 MPT 为

$$\phi(X)=\begin{cases}1 & , \quad 0\le X\le \alpha\\ 0 & , \quad \alpha<X\le 1.\end{cases}$$

ii) 当 $\theta_0\ne\frac{1}{2}$ 时，似然比为

$$\begin{aligned}\lambda(x) &= \frac{f(x;\theta_1)}{f(x;\theta_0)}=\frac{(2\theta_1-1)x+(1-\theta_1)}{(2\theta_0-1)x+(1-\theta_0)}=\frac{\frac{2\theta_1-1}{2\theta_0-1}x+\frac{1-\theta_1}{2\theta_0-1}}{x+\frac{1-\theta_0}{2\theta_0-1}}\\ &= \frac{2\theta_1-1}{2\theta_0-1}+(\frac{1-\theta_1}{2\theta_0-1}-\frac{1-\theta_0}{2\theta_0-1}\cdot\frac{2\theta_1-1}{2\theta_0-1})/(x+\frac{1-\theta_0}{2\theta_0-1})\\ &= \frac{2\theta_1-1}{2\theta_0-1}+\frac{\theta_0-\theta_1}{(2\theta_0-1)^2}/(x+\frac{1-\theta_0}{2\theta_0-1}).\end{aligned}$$

这是 x 的严格递减函数，所以假设检验问题的 MPT 为

$$\phi(X)=\begin{cases}1 & , \quad 0\le X\le k\\ 0 & , \quad k<X\le 1.\end{cases}$$

其中 k 由定解条件 $\mathrm{E}_{\theta_0}[\phi(X)]=\alpha$ 决定。 ∎

3. 考虑简单假设检验问题 $H_0: f(x)=f_0(x) \longleftrightarrow H_1: f(x)=f_1(x)$ 。对于以下分布密度 $f_0(x)$ 和 $f_1(x)$ ，在一样本情况下，求检验问题水平为 α $(0<\alpha<1)$ 的 MPT ：

(1) $f_0(x)=I\{0\le x\le 1\}$, $f_1(x)=2xI\{0\le x\le 1\}$ ；

(2) $f_0(x)=I\{0\le x\le 1\}$, $f_1(x)=4xI\{0\le x\le 1/2\}+(4-4x)I\{1/2\le x\le 1\}$ ；

解. (1) 似然比

$$\lambda(x)=\frac{f_1(x)}{f_0(x)}=\frac{2x\ I\{0\le x\le 1\}}{I\{0\le x\le 1\}}=2x\ I\{0\le x\le 1\}$$

在区间 $[0,\ 1]$ 上是 x 的严格递增函数，所以假设检验问题的 MPT 的否定域为 $R^+=\{x:\ \lambda(x)>c\}=\{x:\ x>k\}$ 。由定解条件 $\mathrm{E}_{f_0}[\phi(X)]=P_{f_0}\{X\in R^+\}=P_{f_0}\{X>k\}=\int_k^1 dx=\alpha$ 可算得 $k=1-\alpha$ 。所以该检验问题的水平为 α 的 MPT 为

$$\phi(X)=\begin{cases}1 & ,\quad 1-\alpha\le X\le 1\\ 0 & ,\quad 0\le X<1-\alpha\end{cases}$$

(2) 似然比为

$$\lambda(x)=\frac{f_1(x)}{f_0(x)}=\frac{4x\ I\{0\le x\le \frac{1}{2}\}+(4-4x)\ I\{\frac{1}{2}\le x\le 1\}}{I\{0\le x\le 1\}}$$

$$=\begin{cases}4x & ,\quad 0\le x\le \frac{1}{2}\\ 4(1-x) & ,\quad \frac{1}{2}<x\le 1\end{cases}$$

因为其图像关于 $x=\frac{1}{2}$ 对称，所以假设检验问题的 MPT 的否定域为 $R^+=\{x:\lambda(x)>c\}=\{|x-\frac{1}{2}|<k\}$ (见图) 。

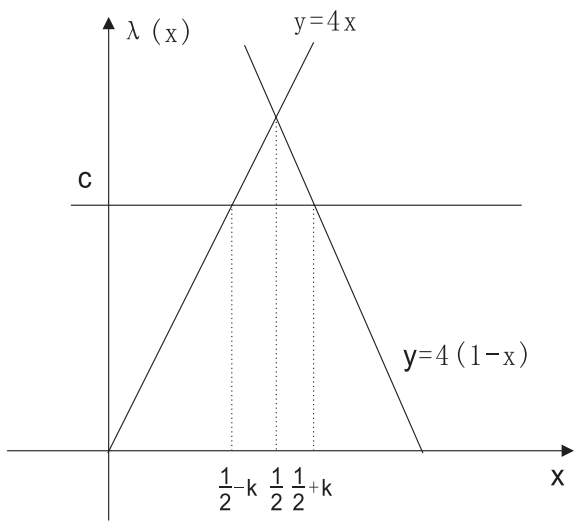

由定解条件 $\mathrm{E}_{f_0}[\phi(X)]=P_{f_0}\{X\in R^+\}=P_{f_0}\{|X-\frac{1}{2}|<k\}=\int_{\frac{1}{2}-k}^{\frac{1}{2}+k}dx=2k=\alpha$ 可算得 $k=\frac{\alpha}{2}$ ，所以该检验问题的水平为 α 的 MPT 为

$$\phi(X)=\begin{cases}1 & ,\quad |X-\frac{1}{2}|<\frac{\alpha}{2}\\ 0 & ,\quad \text{其它}.\end{cases}$$

∎

4. 设 $X_1,\cdots,X_n$ 为 $i.i.d.$ 样本，求以下假设检验问题水平为 α $(0<\alpha<1)$ 的 MPT：$H_0:\theta=1\longleftrightarrow H_1:\theta=2$ 。

(1) X_1 服从均匀分布 $R(0,\theta)$；

(2) X_1 服从 β 分布 $BE(\theta,1)$ 。

解. (1) 在原书例 6.2.2 中取 $\theta_0=1,\ \theta_2=2$ 即可。

(2) 分布族的密度函数和似然比分别为

$$f(x;\theta)=\theta^n(\prod_{i=1}^n x_i)^{\theta-1},\quad \lambda(x)=\frac{f(x;2)}{f(x;1)}=2^n\prod_{i=1}^n x_i.$$

易见 $\lambda(x)$ 是 $T(x)=\prod_{i=1}^n x_i$ 的严增函数，并且 $T(X)$ 的分布连续，所以假设检验问题的 MPT 的否定域为 $R^+=\{x:\ \lambda(x)>c\}=\{x:\ x>k\}$ ，检验函数为

$$\phi(x)=\begin{cases}1 & ,\quad T>k\\ 0 & ,\quad T<k\end{cases}$$

其中 k 由 $\mathrm{E}_{\theta=1}[\phi(X)]=\alpha$ 决定。事实上，由于 $X_i\sim f(x_i,\theta)=\theta {x_i}^{\theta-1}\ I\{0\le x_i\le 1\}$ ，所以 $-\log X_i\sim\Gamma(\theta,1)$ ，从而 $-\log T=\sum_{i=1}^n(-\log X_i)\sim\Gamma(\theta,n)$ 。由此可知当 $\theta=1$ 时，$-2\log T=2\sum_{i=1}^n(-\log X_i)\sim\Gamma(\frac{1}{2},n)\sim\chi^2(2n)$ 。所以由

$$\mathrm{E}_{\theta=1}[\phi(X)]=P_{\theta=1}(T>k)=P_{\theta=1}(-2\log T<-2\log k)=\alpha$$

可得 $-2\log k=\chi^2(2n,\alpha)$ ，即 $k=\exp\{-\frac{1}{2}\chi^2(2n,\alpha)\}$ 。 ∎

注. 本题亦可视为本章习题 12 (2) 的特例。 ∎

5. 设 $X_1,\cdots,X_n$ 为 $i.i.d.$ 样本，考虑以下假设检验问题 $H_0:\theta=\theta_0\longleftrightarrow H_1:\theta=\theta_1$ 。求检验问题水平为 α $(0<\alpha<1)$ 的 MPT：

(1) $f(x_1;\theta)=e^{-(x_1-\theta)}I\{x_1\ge\theta\},\quad \theta_1<\theta_0$；

(2) $f(x_1;\theta)=2\theta^2x_1^{-3}I\{x_1\ge\theta\},\quad \theta_1<\theta_0$ 。

解. 我们依照原书例 6.2.2 的方法来求本题假设检验问题的 MPT 。

(1) 似然比为

$$\begin{aligned}\lambda(x) &= \frac{e^{-\sum(x_i-\theta_1)}I\{x_{(1)}\ge\theta_1\}}{e^{-\sum(x_i-\theta_0)}I\{x_{(1)}\ge\theta_0\}}=e^{n(\theta_1-\theta_0)}\cdot\frac{I\{x_{(1)}\ge\theta_1\}}{I\{x_{(1)}\ge\theta_0\}}\\ &= \begin{cases}e^{n(\theta_1-\theta_0)} & ,\quad x_{(1)}\ge\theta_0\\ +\infty & ,\quad \theta_1\le x_{(1)}<\theta_0\\ 0 & ,\quad \text{其他}\end{cases}\end{aligned}$$

易见，虽然 X_1 的分布连续，但是 $\lambda(X)$ 的分布为离散型，仅取值 0，$\Delta=e^{n(\theta_1-\theta_0)}$ 和 $+\infty$ 这三个值。记 $R^+=\{x:\lambda(x)>c\}$ ， $R^0=\{x:\lambda(x)=c\}$ ，下面求合适的 c 和 γ ，使

$$\mathrm{E}_{\theta_0}[\phi(X)]=P_{\theta_0}(R^+)+\gamma P_{\theta_0}(R^0)=\alpha.$$

以下证明：当 $0<\alpha<1$ 时， c 只能取 Δ 。

i) 当 $c > \Delta$ 时， $R^+ = \{x : \lambda(x) > c\} = \{x : \lambda(x) = \infty\} = \{x : \theta_1 \le x_{(1)} < \theta_0\}$ ，$R^0 =$ 空集。此时 $P_{\theta_0}(R^+) + \gamma P_{\theta_0}(R^0) = 0 + \gamma \cdot 0 = 0$ ，与 $\alpha > 0$ 矛盾。

ii) 当 $c < \Delta$ 时， $R^+ = \{x : \lambda(x) > c\} = \{x : x_{(1)} \ge \theta_0\}$ ， $R^0 =$ 空集。此时 $P_{\theta_0}(R^+) + \gamma P_{\theta_0}(R^0) = 1 + \gamma \cdot 0 = 1$ ，与 $\alpha < 1$ 矛盾。

因此 c 只能取 Δ 。这时 $R^+ = \{x : \lambda(x) > c\} = \{x : \theta_1 \le x_{(1)} < \theta_0\}$ ， $R^0 = \{x : \lambda(x) = c\} = \{x : x_{(1)} \ge \theta_0\}$ ，由 $P_{\theta_0}(R^+) + \gamma P_{\theta_0}(R^0) = 0 + \gamma \cdot 1 = \alpha$ 可得 $\gamma = \alpha$ 。所以该假设检验问题的水平为 α 的 MPT 为

$$\phi(X) = \begin{cases} 1 & , \quad \theta_1 \le X_{(1)} < \theta_0 \\ \alpha & , \quad X_{(1)} \ge \theta_0 \\ 0 & , \quad \text{其它} \end{cases}$$

(2) 似然比为

$$\begin{aligned} \lambda(x) &= \frac{f(x,\theta_1)}{f(x,\theta_0)} = \frac{2^n \theta_1^{2n} (\prod x_i)^{-3}\ I\{x_{(1)} \ge \theta_1\}}{2^n \theta_0^{2n} (\prod x_i)^{-3}\ I\{x_{(1)} \ge \theta_0\}} = (\frac{\theta_1}{\theta_0})^{2n} \cdot \frac{I\{x_{(1)} \ge \theta_1\}}{I\{x_{(1)} \ge \theta_0\}} \\ &= \begin{cases} (\frac{\theta_1}{\theta_0})^{2n} & , \quad x_{(1)} \ge \theta_0 \\ +\infty & , \quad \theta_1 \le x_{(1)} < \theta_0 \\ 0 & , \quad \text{其他} \end{cases} \end{aligned}$$

易见，虽然 X_1 的分布连续，但是 $\lambda(X)$ 的分布为离散型，仅取值 0, $\Delta = (\frac{\theta_1}{\theta_0})^{2n}$ 和 $+\infty$ 这三个值。记 $R^+ = \{x : \lambda(x) > c\}$ ， $R^0 = \{x : \lambda(x) = c\}$ ，下面求合适的 c 和 γ ，使

$$\mathrm{E}_{\theta_0}[\phi(X)] = P_{\theta_0}(R^+) + \gamma P_{\theta_0}(R^0) = \alpha.$$

以下证明：当 $0 < \alpha < 1$ 时， c 只能取 Δ 。

i) 当 $c > \Delta$ 时， $R^+ = \{x : \lambda(x) > c\} = \{x : \lambda(x) = \infty\} = \{x : \theta_1 \le x_{(1)} < \theta_0\}$ ，$R^0 = \{x : \lambda(x) = c\} =$ 空集，此时 $P_{\theta_0}(R^+) + \gamma P_{\theta_0}(R^0) = 0 + \gamma \cdot 0 = 0$ ，与 $\alpha > 0$ 矛盾。

ii) 当 $c < \Delta$ 时， $R^+ = \{x : \lambda(x) > c\} = \{x : x_{(1)} \ge \theta_1\}$ ， $R^0 =$ 空集，此时 $P_{\theta_0}(R^+) + \gamma P_{\theta_0}(R^0) = 1 + \gamma \cdot 0 = 1$ ，与 $\alpha < 1$ 矛盾。

因此 c 只能取 Δ 。这时 $R^+ = \{x : \lambda(x) > c\} = \{x : \theta_1 \le x_{(1)} < \theta_0\}$ ， $R^0 = \{x : \lambda(x) = c\} = \{x : x_{(1)} \ge \theta_0\}$ 。由 $P_{\theta_0}(R^+) + \gamma P_{\theta_0}(R^0) = 0 + \gamma \cdot 1 = \alpha$ 可得 $\gamma = \alpha$ ，所以该假设检验问题的水平为 α 的 MPT 为

$$\phi(X) = \begin{cases} 1 & , \quad \theta_1 \le X_{(1)} < \theta_0 \\ \alpha & , \quad X_{(1)} \ge \theta_0 \\ 0 & , \quad \text{其它} \end{cases} \qquad \blacksquare$$

6. 设 $X_1, \cdots, X_n$ 为 *i.i.d.* 样本， $X_1 \sim \Gamma(\lambda, p)$ ，其中 $p > 0$ 已知， $\lambda > 0$ 未知。

(1) 求假设检验问题 $H_0 : \lambda = \lambda_0 \longleftrightarrow H_1 : \lambda = \lambda_1\ (\lambda_1 > \lambda_0)$ 的一个水平为 α 的 MPT ；

(2) 求 (1) 中的检验函数 $\phi(X)$ 的功效函数 $\beta_\phi(\lambda)$ ，并证明其为 λ 的增函数;

(3) 证明 (1) 中所得的 MPT 是以下假设检验问题的 $UMPT$: (a) $H_0 : \lambda = \lambda_0 \longleftrightarrow H_1 : \lambda > \lambda_0$; (b) $H_0 : \lambda \le \lambda_0 \longleftrightarrow H_1 : \lambda > \lambda_0$ 。

解. 下面我们依照原书例 6.2.3 的方法来求解本题。

(1) 在 $\lambda_1 > \lambda_0$ 的条件下，似然比

$$\lambda(x) = \frac{f(x;\lambda_1)}{f(x;\lambda_0)} = \frac{\prod_{i=1}^n [\lambda_1^p/\Gamma(p)\cdot e^{-\lambda_1 x_i}\ x_i^{p-1}]}{\prod_{i=1}^n [\lambda_0^p/\Gamma(p)\cdot e^{-\lambda_0 x_i}\ x_i^{p-1}]} = (\frac{\lambda_1}{\lambda_0})^{np}\ e^{(\lambda_0-\lambda_1)\sum_{i=1}^n x_i}$$

为 $T(X) = \sum_{i=1}^n X_i$ 的严减函数，因此有

$$R^+ = \{x : \lambda(x) > c\} = \{x : T(x) < k\}.$$

其中 k 由水平条件 $\mathrm{E}_{\lambda_0}[\phi(X)] = \alpha$ 决定。当 H_0 成立时， $2\lambda_0 T \sim \chi^2(2np)$ 为连续型分布，所以由

$$\mathrm{E}_{\lambda_0}[\phi(X)] = P_{\lambda_0}(R^+) = P_{\lambda_0}\{T < k\} = P_{\lambda_0}\{2\lambda_0 T < 2\lambda_0 k\} = \alpha$$

可得 $2\lambda_0 k = \chi^2(2np,\alpha)$ ，即 $k = k_0 = \frac{1}{2\lambda_0}\chi^2(2np,\alpha)$ 。因此该假设检验问题的水平为 α 的 MPT 为

$$\phi(X) = \begin{cases} 1 & , \quad T < \frac{1}{2\lambda_0}\chi^2(2np,\alpha) \\ 0 & , \quad T > \frac{1}{2\lambda_0}\chi^2(2np,\alpha) \end{cases}$$

(2) 根据定义，功效函数可表示为

$$\begin{aligned} \beta_\phi(\lambda) &= \mathrm{E}_\lambda[\phi(X)] = P_\lambda\{T < k_0\} = P_\lambda\{2\lambda T < 2\lambda k_0\} \\ &= P_\lambda\{2\lambda T < \frac{\lambda}{\lambda_0}\chi^2(2np,\alpha)\} \end{aligned}$$

由于 $2\lambda T \sim \chi^2(2np)$ ，所以由上式可知， $\beta_\phi(\lambda)$ 是 λ 的严格递增函数。

(3) 对于假设检验问题 (a) ，由于 (1) 中所得的 $\phi(X)$ 为 MPT ，且与 λ_1 的具体取值无关，只与 $\lambda_1 > \lambda_0$ 有关，所以由原书引理 6.2.1 可知， $\phi(X)$ 也是假设检验问题 (a) $H_0 : \lambda = \lambda_0 \longleftrightarrow H_1 : \lambda > \lambda_0$ 的水平为 α 的 UMPT 。

对于假设检验问题 (b) ，由于

$$\mathrm{E}_\lambda[\phi(X)] = \beta_\phi(\lambda) \begin{cases} < \alpha & , \quad \lambda < \lambda_0 \\ = \alpha & , \quad \lambda = \lambda_0 \\ > \alpha & , \quad \lambda > \lambda_0 \end{cases}$$

所以 (1) 中的 $\phi(X)$ 也是也是假设检验问题 (b) $H_0 : \lambda \le \lambda_0 \longleftrightarrow H_1 : \lambda > \lambda_0$ 的水平为 α 的检验。 所以根据原书引理 6.2.1 ，由 (1) 和 (2) 可知， $\phi(X)$ 也是假设检验问题 (b) 的水平为 α 的 UMPT 。 ∎

7. 考虑简单假设检验问题 $H_0 : f(x) = f_0(x) \longleftrightarrow H_1 : f(x) = f_1(x)$ 。

(1) 证明：以下 $\phi_1(x)$ 为上述检验问题水平为 $\alpha = 0$ 的 MPT ，并且在 $R^+ \cup R^-$ 上唯一。

$$\phi_1(x) = \begin{cases} 1, & x \in R^+ = \{x : f_0(x) = 0,\ f_1(x) \ne 0\} \\ \gamma, & x \in R^0 = \{x : f_0(x) = 0,\ f_1(x) = 0\}, \quad 0 < \gamma < 1 \\ 0, & x \in R^- = \{x : f_0(x) \ne 0\} \end{cases}$$

(2) 证明：以下 $\phi_2(x)$ 为上述检验问题水平为 $\alpha=1$ 的 MPT ，并且在 $R^+\cup R^-$ 上唯一。

$$\phi_2(x)=\begin{cases}1, & x\in R^+=A\cup B\\ \gamma, & x\in\overline{R^+}\end{cases}$$

其中 $A=\{x:f_0(x)\neq 0\},\ B=\{x:f_1(x)\neq 0\},\ 0<\gamma<1$ 。

证明. (1) 显然有 $\mathrm{E}_{f_0}[\phi_1(X)]=0$ ，即 $\phi_1(X)$ 是假设检验问题的水平为 $\alpha=0$ 的检验。设 $\tilde{\phi}(X)$ 是假设检验问题的任一水平为 $\alpha=0$ 的检验，则由 $\mathrm{E}_{f_0}[\tilde{\phi}(X)]=0$ 得 $\int_{R^-}\tilde{\phi}(x)f_0(x)\ dx=0$ 。因为 $\tilde{\phi}(x)f_0(x)\geq 0$ ，所以在 R^- 上 $\tilde{\phi}(x)f_0(x)=0$ 。由于在 R^- 上 $f_0(x)\neq 0$ ，所以 $\tilde{\phi}(x)=0$ ，$x\in R^-$ 。从而

$$\begin{aligned}\mathrm{E}_{f_1}[\phi_1(X)] &= \int_{R^+}f_1(x)\ dx\geq\int_{R^+}\tilde{\phi}(x)f_1(x)\ dx\\ &= \int_{R^+\bigcup R^0\bigcup R^-}\tilde{\phi}(x)f_1(x)\ dx=\mathrm{E}_{f_1}[\tilde{\phi}(X)]\end{aligned}$$

以上第二个等式成立的原因是： $f_1(x)$ 在 R^0 上为零；而 $\tilde{\phi}(x)$ 在 R^- 上为零。由此可知 $\phi_1(X)$ 是假设检验问题的水平为 $\alpha=0$ 的 MPT 。

若 $\phi^*(X)$ 是另一水平为 $\alpha=0$ 的 MPT ，则由水平条件可知 (见以上 $\tilde{\phi}(x)$ 的推导) ，$\phi^*(x)=\phi_1(x)=0,\ x\in R^-$ 。又由 $\mathrm{E}_{f_1}[\phi_1(X)]=\mathrm{E}_{f_1}[\phi^*(X)]$ 可得

$$\int_{\mathcal{X}}[\phi_1(x)-\phi^*(x)]f_1(x)\ dx=\int_{R^+}[\phi_1(x)-\phi^*(x)]f_1(x)dx=0.$$

因为在 R^+ 上 $[\phi_1(x)-\phi^*(x)]f_1(x)\geq 0$ ，所以 $[\phi_1(x)-\phi^*(x)]f_1(x)=0,\ x\in R^+$ 。又因 $f_1(x)\neq 0$, $x\in R^+$, 所以 $\phi_1(x)=\phi^*(x)$, $x\in R^+$, 从而有 $\phi_1(x)=\phi^*(x),\ x\in R^+\bigcup R^-$ ，即假设检验问题的水平为 $\alpha=0$ 的 MPT 在 $R^+\bigcup R^-$ 上唯一。

(2) 显然有 $\mathrm{E}_{f_0}[\phi_2(X)]=1$ (也有 $\mathrm{E}_{f_1}[\phi_2(X)]=1$) ，即 $\phi_2(X)$ 是假设检验问题的水平为 $\alpha=1$ 的检验。设 $\tilde{\phi}(X)$ 是假设检验问题的任一水平为 $\alpha=1$ 的检验。由于 $\mathrm{E}_{f_1}[\tilde{\phi}(X)]\leq 1=\mathrm{E}_{f_1}[\phi_2(X)]$ ，所以 $\phi_2(x)$ 是假设检验问题的水平为 $\alpha=1$ 的 MPT 。

若 $\phi^*(X)$ 是另一水平为 $\alpha=1$ 的 MPT ，则由 $\mathrm{E}_{f_0}[\phi^*(X)]=\int_A\phi^*(x)f_0(x)dx=1$ 可知， $\int_A[1-\phi^*(x)]f_0(x)dx=0$ ，因此 $\phi^*(x)=1,\ x\in A$ 。由最优性知 $\mathrm{E}_{f_1}[\phi^*(X)]=1$ ，因此也有 $\phi^*(x)=1,\ x\in B$ 。所以有 $\phi^*(x)=\phi_2(x)=1,\ x\in A\bigcup B=R^+$ ，即假设检验问题的水平为 $\alpha=1$ 的 MPT 在 $R^+\cup R^-$ 上唯一。 ∎

8. 设 $\phi(x)$ 为 N-P 基本引理导出的 MPT (见定理 6.2.1 的 (6.2.2) 式) , 其水平为 α 的否定域为 $R^+=\{\lambda(X)>c\}$ ，且满足 $P_{\theta_0}\{\lambda(X)>c\}=\alpha$ ；其中 c 可看作 α 的函数 $c=c(\alpha)$ 。

(1) 证明： $c(\alpha)$ 为 α 的非增函数，即若 $\alpha_1<\alpha_2$ ，则 $c(\alpha_1)\geq c(\alpha_2)$ ；

(2) 若 $\lambda(x)$ 的分布函数连续，且 $\alpha_1<\alpha_2$ 。证明：当水平 $\alpha=\alpha_1$ 时， $\phi(x)$ 犯第二类错误的概率不小于水平 $\alpha=\alpha_2$ 时 $\phi(x)$ 犯第二类错误的概率。

证明. (1) 由定理 6.2.1 的证明过程可知， $c=c(\alpha)$ 是似然比 $\lambda(X)$ 的分布函数 $F(u)$ 的 $1-\alpha$ 分位点 $u_{1-\alpha}$ ，因此，由分位点的性质可知当 $\alpha_1<\alpha_2$ 即 $1-\alpha_1>1-\alpha_2$ 时，$c(\alpha_1)=u_{1-\alpha_1}\geq u_{1-\alpha_2}=c(\alpha_2)$ 。

(2) 因为似然比 $\lambda(X)$ 的分布函数 $F(u)$ 连续，所以 N-P 基本引理导出的 MPT 为

$$\phi(x)=\begin{cases}1 & , \quad f(x,\theta_1)>c\ f(x,\theta_0)\\ 0 & , \quad f(x,\theta_1)<c\ f(x,\theta_0)\end{cases}$$

由分位点的性质知 $c(\alpha_1)=u_{1-\alpha_1}>u_{1-\alpha_2}=c(\alpha_2)$ ，因此若记 $R_1=\{x:\ f(x,\theta_1)>c(\alpha_1)\ f(x,\theta_0)\}$ ， $R_2=\{x:\ f(x,\theta_1)>c(\alpha_2)\ f(x,\theta_0)\}$ ，则若 $x\in R_1$ ，必有 $x\in R_2$ ，因此有 $R_1\subset R_2$ 。由概率的性质知 $1-P_{\theta_1}(R_1)\geq 1-P_{\theta_1}(R_2)$ ，所以当水平 $\alpha=\alpha_1$ 时， $\phi(x)$ 犯第二类错误的概率不小于水平 $\alpha=\alpha_2$ 时 $\phi(x)$ 犯第二类错误的概率。 ∎

注. 以上性质 (2) 说明，由 N-P 基本引理导出的 MPT ，犯第一类错误的概率越小，则犯第二类错误的概率越大。 ∎

9. 对于简单假设检验问题 $H_0:\theta=\theta_0\longleftrightarrow H_1:\theta=\theta_1$ 以及水平 α $(0<\alpha<1)$ 。设 $\phi(x)$ 为上述检验问题水平为 α 的 MPT ，且 $\beta=\mathrm{E}_{\theta_1}[\phi(X)]<1$ 。证明：检验 $1-\phi(x)$ 是假设检验问题 $H_0:\theta=\theta_1\longleftrightarrow H_1:\theta=\theta_0$ 的一个水平为 $1-\beta$ 的 MPT 。

证明. 记 $\lambda(x)=f(x,\theta_1)/f(x,\theta_0)$ ，则由定理 6.2.1 可知

$$\phi(x)=\begin{cases}1 & , \quad x\in R^+=\{x:\lambda(x)>c\}\\ \gamma & , \quad x\in R^0=\{x:\lambda(x)=c\}\\ 0 & , \quad x\in R^-=\{x:\lambda(x)<c\}\end{cases}$$

其中 $c\geq 0,\ 0\leq\gamma\leq 1$ 使得 $\mathrm{E}_{\theta_0}[\phi(X)]=\alpha$ 。

下面，我们先用反证法证明 $c>0$ 。

若 $c=0$ ，则 $R^+=\{x:\lambda(x)=f(x,\theta_1)/f(x,\theta_0)>0\}=\{x:f(x,\theta_1)>0\}$ ，所以

$$\begin{aligned}\mathrm{E}_{\theta_1}[\phi(X)] &= \int_{\mathcal{X}}\phi(x)f(x,\theta_1)\ dx=\int_{R^+}\phi(x)f(x,\theta_1)\ dx\\ &= \int_{R^+}f(x,\theta_1)\ dx=\int_{\mathcal{X}}f(x,\theta_1)\ dx=1.\end{aligned}$$

这与 $\beta=\mathrm{E}_{\theta_1}[\phi(X)]<1$ 相矛盾，所以 $c\neq 0$ 。由 $c\geq 0$ 可知 $c>0$ 。因此

$$1-\phi(x)=\begin{cases}0 & , \quad \lambda(x)>c\\ 1-\gamma & , \quad \lambda(x)=c\\ 1 & , \quad \lambda(x)<c\end{cases}\triangleq\begin{cases}1 & , \quad \lambda^*(x)>c^*\\ \gamma^* & , \quad \lambda^*(x)=c^*\\ 0 & , \quad \lambda^*(x)<c^*\end{cases}$$

其中 $\gamma^*=1-\gamma,\ \lambda^*(x)=1/\lambda(x)=f(x,\theta_0)/f(x,\theta_1),\ c^*=\frac{1}{c}$ 。易见， $1-\phi(x)$ 具有 N-P 引理中所得 MPT 的一般形式，且 $\mathrm{E}_{\theta_1}[1-\phi(X)]=1-\mathrm{E}_{\theta_1}[\phi(X)]=1-\beta$ 。因此，由 N-P 引理中 MPT 的最优性可知 $1-\phi(X)$ 是假设检验问题 $H_0:\theta=\theta_1\longleftrightarrow H_1:\theta=\theta_0$ 的一个水平为 $1-\beta$ 的 MPT ，且由 N-P 引理中 MPT 的唯一性可知它在 $R^{*+}\bigcup R^{*-}$ 上唯一，其中 $R^{*+}=\{x:\lambda^*(x)>c^*\}=\{x:\lambda(x)<c\}$ ， $R^{*-}=\{x:\lambda^*(x)<c^*\}=\{x:\lambda(x)>c\}$ 。这等价于 $\phi(x)$ 在 R^+ 与 R^- 上的唯一性。 ∎

10. 证明以下分布族为单调似然比分布族：

(1) $f(x,\mu)=\frac{1}{2\theta}e^{-\frac{1}{\theta}|x-\mu|}:\mu\in R$ 未知， $\theta>0$ 已知；

(2) $U(\theta,\theta+1):\theta\in R$;

(3) $\{f_\theta(x):\ \theta\in R\}$，其中 $f_\theta(x)=c(\theta)h(x)I\{a(\theta)\le x\le b(\theta)\}$ 且 $h(x)$ 和 $c(\theta)$ 都是正函数， $a(\theta)$ 和 $b(\theta)$ 都是 θ 的非降函数。

证明. (1) 当 $\mu_0<\mu_1$ 时，似然比

$$\begin{aligned}\lambda(x) &= \frac{f(x;\mu_1)}{f(x;\mu_0)}=\frac{\frac{1}{2\theta}\ e^{|x-\mu_1|/\theta}}{\frac{1}{2\theta}\ e^{-|x-\mu_0|/\theta}}=\exp\{(|x-\mu_0|-|x-\mu_1|)/\theta\}\\ &= \begin{cases}\exp\{\frac{1}{\theta}(\mu_0-\mu_1)\} & ,\quad x\le\mu_0\\ \exp\{\frac{1}{\theta}(2x-\mu_0-\mu_1)\} & ,\quad \mu_0<x<\mu_1\\ \exp\{\frac{1}{\theta}(\mu_1-\mu_0)\} & ,\quad x\ge\mu_1\end{cases}\end{aligned}$$

显然 $\lambda(x)$ 是 x 的非减函数，并且 $\mu\{f(x;\mu_1)\ne f(x;\mu_2)\ ,\ \mu_1\ne\mu_2\}>0$，所以分布族是关于 $T(x)=x$ 的 MLR 分布族。

(2) 下面我们分两种情况来讨论。

i) 当 $\theta_0+1<\theta_1<\theta_1+1$ 时，似然比

$$\begin{aligned}\lambda(x) &= \frac{f(x;\theta_1)}{f(x;\theta_0)}=\frac{I\{\theta_1\le x\le\theta_1+1\}}{I\{\theta_0\le x\le\theta_0+1\}}\\ &= \begin{cases}0 & ,\quad \theta_0\le x<\theta_0+1\\ +\infty & ,\quad \theta_1\le x\le\theta_1+1.\end{cases}\end{aligned}$$

当 $\theta_0+1<x<\theta_1$ 时 $f(x;\theta_0)$ 与 $f(x;\theta_1)$ 都为零，这时亦可取 $\lambda(x)=0$，因此 $\lambda(x)$ 是 x 的非减函数。

ii) 当 $\theta_0<\theta_1\le\theta_0+1<\theta_1+1$ 时，似然比

$$\begin{aligned}\lambda(x) &= \frac{f(x;\theta_1)}{f(x;\theta_0)}=\frac{I\{\theta_1\le x\le\theta_1+1\}}{I\{\theta_0\le x\le\theta_0+1\}}\\ &= \begin{cases}0 & ,\quad \theta_0\le x<\theta_1\\ 1 & ,\quad \theta_1\le x\le\theta_0+1\\ +\infty & ,\quad \theta_0+1<x\le\theta_1+1.\end{cases}\end{aligned}$$

$\lambda(x)$ 亦是 x 的非减函数，并且 $\mu\{f(x;\theta_1)\ne f(x;\theta_2)\ ,\ \theta_1\ne\theta_2\}>0$，所以分布族是关于 $T(x)=x$ 的 MLR 分布族。

(3) 在 $\theta_0<\theta_1$ 的条件下，我们分两种情况来讨论。

i) 当 $b(\theta_0)<a(\theta_1)$ 时，似然比

$$\begin{aligned}\lambda(x) &= \frac{f(x;\theta_1)}{f(x;\theta_0)}=\frac{c(\theta_1)\ h(x)\ I\{a(\theta_1)\le x\le b(\theta_1)\}}{c(\theta_0)\ h(x)\ I\{a(\theta_0)\le x\le b(\theta_0)\}}\\ &= \begin{cases}0 & ,\quad a(\theta_0)\le x<a(\theta_1)\\ +\infty & ,\quad a(\theta_1)\le x\le b(\theta_1)\end{cases}\end{aligned}$$

因此 $\lambda(x)$ 是 x 的非减函数。

ii) 当 $a(\theta_1)<b(\theta_0)$ 时 (见图)，

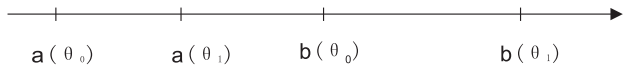

$$\lambda(x)=\frac{f(x;\theta_1)}{f(x;\theta_0)}=\begin{cases}0 & , \quad a(\theta_0)\le x<a(\theta_1)\\ \frac{c(\theta_1)}{c(\theta_0)} & , \quad a(\theta_1)\le x\le b(\theta_0)\\ +\infty & , \quad b(\theta_0)<x\le b(\theta_1)\end{cases}$$

$\lambda(x)$ 亦是 x 的非减函数，并且 $\mu\{f(x;\theta_1)\ne f(x;\theta_2)\ ,\ \theta_1\ne\theta_2\}>0$ ，所以分布族是关于 $T(x)=x$ 的 MLR 分布族。 ∎

11. 对习题 5 中的两个小题的分布族：

(1) 证明其分布族为单调似然比分布族;

(2) 对于简单假设检验问题 $H_0:\theta=\theta_0\longleftrightarrow H_1:\theta=\theta_1\ (\theta_1<\theta_0)$ ，求一个水平为 α 的非随机化的 MPT;

(3) 对于假设检验问题 $H_0:\theta\le\theta_0\longleftrightarrow H_1:\theta>\theta_0$ ，求一个水平为 α 的 $UMPT$ 。

解. 对于 (1) 中的分布族：

i) 当 $\theta_1>\theta_0$ 时，似然比

$$\begin{aligned}\lambda(x) &= \frac{f(x,\theta_1)}{f(x,\theta_0)}=\frac{e^{-\sum(x_i-\theta_1)}\ I\{x_{(1)}\ge\theta_1\}}{e^{-\sum(x_i-\theta_0)}\ I\{x_{(1)}\ge\theta_0\}}=e^{n(\theta_1-\theta_0)}\ \frac{I\{x_{(1)}\ge\theta_1\}}{I\{x_{(1)}\ge\theta_0\}}\\ &= \begin{cases}e^{n(\theta_1-\theta_0)} & , \quad x_{(1)}\ge\theta_1\\ 0 & , \quad \theta_0\le x_{(1)}<\theta_1.\end{cases}\end{aligned}$$

因此似然比 $\lambda(x)$ 是 $T(x)=x_{(1)}$ 的非减函数，并且 $\mu\{f(x;\theta_1)\ne f(x;\theta_2)\ ,\ \theta_1\ne\theta_2\}>0$ ，所以 $X=(X_1,\cdots,X_n)^T$ 的分布关于 $T(X)=X_{(1)}$ 为 MLR 分布族，其中 $T(X)$ 服从连续型分布。

ii) 由定理 6.3.3 可知，简单假设检验问题 $H_0:\theta=\theta_0\longleftrightarrow H_1:\theta=\theta_1\ (\theta_1<\theta_0)$ 的水平为 α 的非随机化的 MPT 可表示为

$$\phi(x)=\begin{cases}1 & , \quad T(x)<k\\ 0 & , \quad \text{其他}.\end{cases}$$

其中 k 由 $\mathrm{E}_{\theta_0}[\phi(X)]=\alpha$ 决定。事实上，由于当 $\theta=\theta_0$ 时， $X_{(1)}\ \sim\ \theta_0+\Gamma(n,1)$ ，即 $2n(X_{(1)}-\theta_0)\ \sim\ \chi^2(2)$ ，所以有

$$\mathrm{E}_{\theta_0}[\phi(X)]=P_{\theta_0}(X_{(1)}<k)=P_{\theta_0}(2n(X_{(1)}-\theta_0)<2n(k-\theta_0))=\alpha.$$

因此 $2n(k-\theta_0)=\chi^2(2,\alpha)$ ，即 $k=\frac{1}{2n}\chi^2(2,\alpha)+\theta_0$ 。

iii) 由定理 6.3.1 知假设检验问题 $H_0:\theta\le\theta_0\longleftrightarrow H_1:\theta>\theta_0$ 的水平为 α 的 UMPT 可表示为

$$\phi(x)=\begin{cases}1 & , \quad T(x)>k\\ 0 & , \quad T(x)<k.\end{cases}$$

其中 k 由 $\mathrm{E}_{\theta_0}[\phi(X)]=\alpha$ 决定。事实上，由于当 $\theta=\theta_0$ 时， $2n(X_{(1)}-\theta_0)\ \sim\ \chi^2(2)$ ，所以有

$$\mathrm{E}_{\theta_0}[\phi(X)]=P_{\theta_0}(X_{(1)}>k)=P_{\theta_0}(2n(X_{(1)}-\theta_0)>2n(k-\theta_0))=\alpha.$$

因此 $2n(k-\theta_0)=\chi^2(2,1-\alpha)$ ，即 $k=\frac{1}{2n}\chi^2(2,1-\alpha)+\theta_0$ 。

对于 (2) 中的分布族：

i) 当 $\theta_1>\theta_0$ 时，似然比

$$\lambda(x)=\frac{f(x,\theta_1)}{f(x,\theta_0)}=(\frac{\theta_1}{\theta_0})^{2n}\ \frac{I\{x_{(1)}\geq\theta_1\}}{I\{x_{(1)}\geq\theta_0\}}=\begin{cases}(\frac{\theta_1}{\theta_0})^{2n} & , \quad x_{(1)}\geq\theta_1\\ 0 & , \quad \theta_0\leq x_{(1)}<\theta_1\end{cases}$$

因此似然比 $\lambda(x)$ 是 $T(x)=x_{(1)}$ 的非减函数，并且 $\mu\{f(x;\theta_1)\neq f(x;\theta_2)\ ,\ \theta_1\neq\theta_2\}>0$ ，所以 $X=(X_1,\cdots,X_n)^T$ 的分布关于 $T(X)=X_{(1)}$ 为 MLR 分布族，其中 $T(X)$ 服从连续型分布。

ii) 由定理 6.3.3 可知，简单假设检验问题 $H_0:\theta=\theta_0\longleftrightarrow H_1:\theta=\theta_1\ (\theta_1<\theta_0)$ 的水平为 α 的非随机化的 MPT 可表示为

$$\phi(x)=\begin{cases}1 & , \quad T(x)<k\\ 0 & , \quad \text{其他}\end{cases}$$

其中 k 由 $\mathrm{E}_{\theta_0}[\phi(X)]=\alpha$ 决定。事实上，由于 $X_{(1)}\ \sim\ f(t)=2n\ \theta^{2n}\ t^{-2n-1}\ I\{t\geq\theta\}$ ，所以当 $\theta=\theta_0$ 时有

$$\mathrm{E}_{\theta_0}[\phi(X)]=P_{\theta_0}(X_{(1)}<k)=\int_{\theta_0}^{k}f(t)\ dt=\alpha.$$

由此可得 $k=\theta_0(1-\alpha)^{-1/(2n)}$ 。

iii) 由定理 6.3.1 知假设检验问题 $H_0:\theta\leq\theta_0\longleftrightarrow H_1:\theta>\theta_0$ 的水平为 α 的 UMPT 可表示为

$$\phi(x)=\begin{cases}1 & , \quad T(x)>k\\ 0 & , \quad T(x)<k\end{cases}$$

其中 k 由 $\mathrm{E}_{\theta_0}[\phi(X)]=\alpha$ 决定。事实上，由于 $X_{(1)}\ \sim\ f(t)=2n\ \theta^{2n}\ t^{-2n-1}\ I\{t\geq\theta\}$ ，类似于以上计算可得 $k=\theta_0\alpha^{-1/(2n)}$ 。 ∎

12. 设 $X_1,\cdots,X_n$ 为 *i.i.d.* 样本， $X_1\sim f(x_1;\theta),\ \theta\in\Theta\subset R$ 。在下列情况下，基于 χ^2 分布 (见第一章习题) ，求假设检验问题 $H_0:\theta\leq\theta_0\longleftrightarrow H_1:\theta>\theta_0$ 水平为 α 的 $UMPT$:

(1) $f(x_1;\theta)=\theta^{-1}e^{-\frac{x_1}{\theta}}I\{x_1\geq 0\},\ \ \theta>0;$

(2) $f(x_1;\theta)=\theta x_1^{\theta-1}I\{0\leq x_1\leq 1\},\ \ \theta>0;$

(3) $f(x_1;\theta)=c\theta^{-c}x_1^{c-1}\exp\{-(\frac{x_1}{\theta}^c)\}I\{x_1\geq 0\}$ ，其中 $\theta>0$ 未知， $c>0$ 已知。

解. (1) 当 $\theta_0<\theta_1$ ，即 $\frac{1}{\theta_0}-\frac{1}{\theta_1}>0$ 时，似然比为

$$\lambda(x)=\frac{f(x;\theta_1)}{f(x;\theta_0)}=\frac{{\theta_1}^{-n}\exp\{-\sum_{i=1}^n x_i/\theta_1\}}{{\theta_0}^{-n}\exp\{-\sum_{i=1}^n x_i/\theta_0\}}=(\frac{\theta_0}{\theta_1})^n\exp\{(\frac{1}{\theta_0}-\frac{1}{\theta_1})\sum_{i=1}^n x_i\}$$

因此 $\lambda(x)$ 是 $T(x)=\sum_{i=1}^n x_i$ 的严增函数，并且 $\mu\{f(x;\theta_1)\neq f(x;\theta_2)\ ,\ \theta_1\neq\theta_2\}>0$ ，所以 $X=(X_1,\cdots,X_n)^T$ 的分布关于 $T(X)=\sum_{i=1}^n X_i$ 为 MLR 分布族，其中 $T(X)$ 服从连续型分布。

由定理 6.3.1 知假设检验问题 $H_0:\theta\le\theta_0 \longleftrightarrow H_1:\theta>\theta_0$ 的水平为 α 的 UMPT 可表示为

$$\phi(x)=\begin{cases}1 & , \quad T(x)>k\\ 0 & , \quad T(x)<k.\end{cases}$$

其中 k 由 $\mathrm{E}_{\theta_0}[\phi(X)]=\alpha$ 决定。事实上，当 $\theta=\theta_0$ 时， $T=\sum\limits_{i=1}^{n}X_i \sim \Gamma(\frac{1}{\theta_0},n)$ ，从而 $2T/\theta_0 \sim \chi^2(2n)$ ，所以有

$$\mathrm{E}_{\theta_0}[\phi(X)]=P_{\theta_0}(T>k)=P_{\theta_0}(2T/\theta_0>2k/\theta_0)=\alpha$$

由此可得 $2k/\theta_0=\chi^2(2n,1-\alpha)$ ，即 $k=\frac{\theta_0}{2}\chi^2(2n,1-\alpha)$ 。

(2) 当 $\theta_0<\theta_1$ 时，似然比为

$$\lambda(x)=\frac{f(x;\theta_1)}{f(x;\theta_0)}=\frac{{\theta_1}^n\ (\prod_{i=1}^n x_i)^{\theta_1-1}}{{\theta_0}^n\ (\prod_{i=1}^n x_i)^{\theta_0-1}}=(\frac{\theta_1}{\theta_0})^n\ (\prod_{i=1}^n x_i)^{\theta_1-\theta_0}.$$

因此 $\lambda(x)$ 是 $T(x)=\prod_{i=1}^n x_i$ 的严增函数，并且 $\mu\{f(x;\theta_1)\ne f(x;\theta_2)\ ,\ \theta_1\ne\theta_2\}>0$ ，所以 $X=(X_1,\cdots,X_n)^T$ 的分布关于 $T(X)=\prod_{i=1}^n X_i$ 为 MLR 分布族，其中 $T(X)$ 服从连续型分布。

由定理 6.3.1 知假设检验问题 $H_0:\theta\le\theta_0 \longleftrightarrow H_1:\theta>\theta_0$ 的水平为 α 的 UMPT 可表示为

$$\phi(x)=\begin{cases}1 & , \quad T(x)>k\\ 0 & , \quad T(x)<k.\end{cases}$$

其中 k 由 $\mathrm{E}_{\theta_0}[\phi(X)]=\alpha$ 决定。事实上，由于 $X_i \sim f(x_i,\theta)=\theta {x_i}^{\theta-1}\ I\{0\le x_i\le 1\}$ ，所以 $-\log X_i \sim \Gamma(\theta,1)$ ，从而 $-\log T=\sum_{i=1}^n(-\log X_i) \sim \Gamma(\theta,n)$ 。因此当 $\theta=\theta_0$ 时，$-2\theta_0\log T=2\theta_0\sum_{i=1}^n(-\log X_i) \sim \Gamma(\frac{1}{2},n)\sim\chi^2(2n)$ 。所以有

$$\mathrm{E}_{\theta_0}[\phi(X)]=P_{\theta_0}(T>k)=P_{\theta_0}(-2\theta_0\log T<-2\theta_0\log k)=\alpha.$$

由此可得 $-2\theta_0\log k=\chi^2(2n,\alpha)$ ，即 $k=\exp\{-\frac{1}{2\theta_0}\chi^2(2n,\alpha)\}$ 。

(3) 当 $\theta_1>\theta_0>0$ ，即 $1/\theta_0^c-1/\theta_1^c>0$ 时，似然比为

$$\lambda(x)=\frac{f(x;\theta_1)}{f(x;\theta_0)}=\frac{\prod_{i=1}^n c\ \theta_1^{-c}x_i^{c-1}\exp\{-(\frac{x_i}{\theta_1})^c\}}{\prod_{i=1}^n c\ \theta_0^{-c}x_i^{c-1}\exp\{-(\frac{x_i}{\theta_0})^c\}}=(\frac{\theta_0}{\theta_1})^{nc}\exp\{(\frac{1}{\theta_0^c}-\frac{1}{\theta_1^c})\sum_{i=1}^n x_i^c\}.$$

因此 $\lambda(x)$ 是 $T(x)=\sum\limits_{i=1}^n x_i^c$ 的增函数，并且 $\mu\{f(x;\theta_1)\ne f(x;\theta_0)\ ,\ \theta_1\ne\theta_0\}>0$ ，所以 $X=(X_1,\cdots,X_n)^T$ 的分布关于 $T(X)=\sum\limits_{i=1}^n X_i^c$ 为 MLR 分布族，其中 $T(X)$ 服从连续型分布。

由定理 6.3.1 知假设检验问题 $H_0:\theta\le\theta_0 \longleftrightarrow H_1:\theta>\theta_0$ 的水平为 α 的 UMPT 可表示为

$$\phi(x)=\begin{cases}1 & , \quad T(x)>k\\ 0 & , \quad T(x)<k\end{cases}$$

其中 k 由 $\mathrm{E}_{\theta_0}[\phi(X)]=\alpha$ 决定。由于 $X_i \sim f(x_i,\theta)=c\,\theta^{-c}x_i^{c-1}\exp\{-(\frac{x_i}{\theta_1})^c\}\,I\{x>0\}$ ，所以 $X_i^c \sim \Gamma(\frac{1}{\theta^c},1)$ 。由此可知当 $\theta=\theta_0$ 时， $T=\sum_{i=1}^n X_i^c \sim \Gamma(\frac{1}{\theta_0^c},n)$ ，从而 $2T/\theta_0^c \sim \Gamma(\frac{1}{2},n)\sim\chi^2(2n)$ 。所以由

$$\mathrm{E}_{\theta_0}[\phi(X)]=P_{\theta_0}(T>k)=P_{\theta_0}(2T/\theta_0^c>2k/\theta_0^c)=\alpha$$

可得 $\frac{2k}{\theta_0^c}=\chi^2(2n,1-\alpha)$ ，即 $k=\frac{\theta_0^c}{2}\chi^2(2n,1-\alpha)$ 。 ∎

13. 求以下单边假设检验问题水平为 α 的 $UMPT$:

(1) X 服从超几何分布 $h(x|n;N,M)$ ，求检验 $H_0:M\le M_0 \longleftrightarrow H_1:M>M_0$ 的 $UMPT$;

(2) X 负二项分布 $NB(r,\theta)$ ，求检验 $H_0:\theta\le\theta_0 \longleftrightarrow H_1:\theta>\theta_0$ 的 $UMPT$ 。

解. (1) X 的密度函数为

$$h(x;n,N,M)=\binom{M}{x}\binom{N-M}{n-x}\Big/\binom{N}{n}$$

当 $M_1>M_0$ 时，似然比为

$$\begin{aligned}
\lambda(x) &= \frac{h(x;n,N,M_1)}{h(x;n,N,M_0)}=\frac{\binom{M_1}{x}\binom{N-M_1}{n-x}\Big/\binom{N}{n}}{\binom{M_0}{x}\binom{N-M_0}{n-x}\Big/\binom{N}{n}}\\
&= \frac{M_1!}{M_0!}\cdot\frac{(N-M_1)!}{(N-M_0)!}\cdot\frac{(M_0-x)!}{(M_1-x)!}\cdot\frac{(N-n+x-M_0)!}{(N-n+x-M_1)!}\\
&= \frac{M_1!}{M_0!}\cdot\frac{(N-M_1)!}{(N-M_0)!}\cdot\frac{(N-n+x-M_1+1)\cdots(N-n+x-M_0)}{(M_0-x+1)\cdots(M_1-x)}
\end{aligned}$$

$\lambda(x)$ 是 x 的严增函数，并且 $\mu\{h(x|n;N,M_1)\ne h(x|n;N,M_2),M_1\ne M_2\}>0$ ，所以 X 的分布关于 $T(x)=x$ 是 MLR 分布族。

由定理 6.3.1 知假设检验问题 $H_0:M\le M_0 \longleftrightarrow H_1:M>M_0$ 的水平为 α 的 UMPT 可表示为

$$\phi(x)=\begin{cases}1 & , \quad x>k\\ \gamma & , \quad x=k\\ 0 & , \quad x<k\end{cases}$$

其中 γ,k 由 $\mathrm{E}_{M_0}[\phi(X)]=P_{M_0}(X>k)+\gamma P_{M_0}(X=k)=\alpha$ 决定。具体来说，我们先在 $P_{M_0}(X>k)\le\alpha$ 的条件下取最小的 k ，即 $k=\min\{m:P_{M_0}(X>m)<\alpha\ ,\ m=0,1,2,\cdots,M_0\}$ ，此时 $P_{M_0}(X>k)$ 在小于等于 α 的条件下达到最大，然后即可取 $\gamma=(\alpha-P_{M_0}(X>k))/P_{M_0}(X=k)$ ，从而即可得到 $\phi(x)$ 。

(2) X 的密度函数为

$$p(x;r,\theta)=\binom{x+r-1}{x}\theta^r(1-\theta)^x\ ,\quad x=0,1,2,\cdots$$

当 $\theta_1>\theta_0$ 时，似然比

$$\frac{p(x;r,\theta_1)}{p(x;r,\theta_0)}=\frac{\binom{x+r-1}{x}\theta_1^r(1-\theta_1)^x}{\binom{x+r-1}{x}\theta_0^r(1-\theta_0)^x}=(\frac{\theta_1}{\theta_0})^r(\frac{1-\theta_0}{1-\theta_1})^{-x}$$

是 $-x$ 的严格递增函数，并且 $\mu\{p(x;r,\theta_1)\neq p(x;r,\theta_2),\ \theta_1\neq\theta_2\}>0$ ，所以 X 的分布关于 $T(X)=-X$ 是 MLR 分布族。

由定理 6.3.1 知假设检验问题 $H_0:\theta\le\theta_0\longleftrightarrow H_1:\theta>\theta_0$ 的水平为 α 的 UMPT 可表示为

$$\phi(x)=\begin{cases}1 & , \quad T(x)>k\\ \gamma & , \quad T(x)=k\\ 0 & , \quad T(x)<k\end{cases}\qquad 即\qquad \phi(x)=\begin{cases}1 & , \quad x<-k\triangleq c\\ \gamma & , \quad x=c\\ 0 & , \quad x>c\end{cases}$$

其中 c, γ 由 $\mathrm{E}_{\theta_0}[\phi(X)]=P_{\theta_0}(X<c)+\gamma P_{\theta_0}(X=c)=\alpha$ 决定。具体来说，我们先在 $P_{\theta_0}(X<c)\le\alpha$ 的条件下取最大的 c ，即 $c=\max\{m:P_{\theta_0}(X<m)\le\alpha\ ,\ m=0,1,2,\cdots\}$ ，然后取 $\gamma=(\alpha-P_{\theta_0}(X<c))/P_{\theta_0}(X=c)$ ，从而即可得到 $\phi(x)$ 。 ∎

14. 设 $X_1,\cdots,X_n$ 为 *i.i.d.* 样本， X_1 服从两点分布 $b(1,p)$ 。

(1) 求检验 $H_0:p\le0.02\longleftrightarrow H_1:p>0.02$ 水平为 $\alpha=0.05$ 的 $UMPT$; 若要求这个检验在 $p=0.08$ 时犯第二类错误的概率不超过 0.1 ， n 要取多大？

(2) 某厂生产的轴套出厂标准为次品率不超过 2% ，现从一批产品中随机抽取 400 只轴套，发现次品 12 只。在水平为 $\alpha=0.05$ 的条件下，是否应允许这批产品出厂？

解. (1) 由原书例 6.3.6 可知，假设检验问题 $H_0:p\le0.02\longleftrightarrow H_1:p>0.02$ 的 UMPT 为

$$\phi(x)=\begin{cases}1 & , \quad T>k\\ 0 & , \quad T<k.\end{cases}$$

其中 $T(x)=\sum_{i=1}^n x_i$ ， k 由 $\mathrm{E}_{p_0}[\phi(X)]=P_{p_0}(T>k)=\alpha$ 决定。其渐近正态否定域为 $R^+=\{U_0(x)>z_{1-\alpha}\}$ ，其中 $U_0(x)=\frac{T-np_0}{\sqrt{np_0q_0}}\xrightarrow{L}N(0,1),\ q_0=1-p_0,\ z_{1-\alpha}$ 为标准正态分布 $N(0,1)$ 的 $1-\alpha$ 分位点。由此可得 $k=np_0+\sqrt{np_0q_0}z_{1-\alpha}$ 。

该检验的功效函数为

$$\beta_\phi(p)=P_p(T>k)=P_p\{\frac{T-np}{\sqrt{npq}}>\frac{k_0-np}{\sqrt{npq}}\}.$$

因为 $\frac{T-np}{\sqrt{npq}}\xrightarrow{L}N(0,1)$ ，所以 $\beta_\phi(p)=1-\Phi(\frac{k_0-np}{\sqrt{npq}})$ 。因此当 $p=0.08$ 时，该检验犯第二类错误的概率为

$$\begin{aligned}II(p) &= 1-\beta_\phi(p)=\Phi(\frac{k_0-np}{\sqrt{npq}})\\ &= \Phi(\sqrt{n}\frac{p_0-p}{\sqrt{pq}}+\sqrt{\frac{p_0q_0}{pq}}\ z_{1-\alpha})\end{aligned}$$

其中 $\Phi(.)$ 为标准正态分布的分布函数。由此可得 $II(0.08)=\Phi(-0.2212\sqrt{n}+0.8515)$ 。由于 $\Phi(-1.28)=0.1$ ，因此要使 $II(p)\le0.1$ ，即要使 $-0.2212\sqrt{n}+0.8515\le-1.28$ ，则须 $n\ge93$ 。因此，若使这个检验在 $p=0.08$ 时犯第二类错误的概率不超过 0.1 ， n 应不小于 93 。

(2) 该问题是要根据 (1) 的结果来检验

$$H_0:p\le0.02\quad\longleftrightarrow\quad H_1:p>0.02$$

由于 $n=400$ 比较大，所以可以应用近似正态否定域。这时 $p_0=0.02$ ， $q_0=0.98$ ， $T=12$ ，由此可算得 $U_0(x)=(12-400\cdot 0.02)/\sqrt{400\cdot 0.02\cdot 0.98}=1.4286$ 。因为 $U_0(x)<1.65=z_{1-\alpha}$ ，所以不否定原假设，即允许这批产品出厂。 ∎

15. 设 $X_1,\cdots,X_n$ 为 *i.i.d.* 样本， X_1 表示寿命且服从指数分布 $\Gamma(\frac{1}{\theta},1)$ 。现仅观测到前 r 个寿命的值： $(Y_1,\ldots,Y_r)^T=(X_{(1)},\ldots,X_{(r)})^T$ 。

(1) 对于假设检验问题 $H_0:\theta\le\theta_0\longleftrightarrow H_1:\theta>\theta_0$ ，求其 $UMPT$ 的功效函数;

(2) 设某元件的寿命服从指数分布 $\Gamma(\frac{1}{\theta},1)$ 。今对 12 个元件观测其寿命，仅测得前 6 个元件的失效时间 (小时) 为 1380, 1510, 1650, 1760, 2100, 2320 。在水平为 $\alpha=0.05$ 的条件下检验：元件的平均寿命是否在 2000 小时以上？

解. (1) 在例 6.3.5 的 (2) 中我们已经求出了该假设检验问题的 UMPT ，其功效函数为

$$\beta_\phi(\theta)=\mathrm{E}_\theta[\phi(X)]=P_\theta(T_{n,r}>k_0).$$

其中 $T_{n,r}=\sum_{i=1}^r X_{(i)}+(n-r)X_{(r)}\sim\Gamma(1/\theta,r),\ k_0=\frac{1}{2}\theta_0\chi^2(2r,1-\alpha)$ 。因为 $\frac{2}{\theta}T_{n,r}\sim\chi^2(2r)$ ，所以

$$\beta_\phi(\theta)=P_\theta\{\frac{2}{\theta}T_{n,r}>\frac{\theta_0}{\theta}\chi^2(2r,1-\alpha)\}.$$

易见， $\beta_\phi(\theta)$ 是 θ 的增函数。

(2) 该问题可根据例 6.3.5 中 (2) 的结果进行检验

$$H_0:\theta\le\theta_0=2000\ \longleftrightarrow\ H_1:\theta>\theta_0$$

其中 $n=12$ ， $r=6$ 。经直接计算可得 $\frac{2}{\theta_0}T_{n.r.}=24.64>\chi^2(12,0.95)=21.026$ ，所以应该否定原假设 $H_0:\theta\le\theta_0=2000$ ，即认为元件的平均寿命在 2000 小时以上。 ∎

16. ★ 设 $X_1,\cdots,X_n$ 为 *i.i.d.* 样本， $n\ge 2,\ X_1\sim R(\theta,\theta+1),\ \theta\in R$ 。

(1) 求 $X_{(1)}$ 和 $X_{(n)}$ 的联合分布;

(2) 证明： $\phi^*(X_{(1)},X_{(n)})=\begin{cases}0, & X_{(1)}<1-\alpha^{\frac{1}{n}}\ \text{且}\ X_{(n)}<1\\ 1, & X_{(1)}\ge 1-\alpha^{\frac{1}{n}}\ \text{或}\ X_{(n)}\ge 1\end{cases}$

是假设检验问题 $H_0:\theta\le 0\longleftrightarrow H_1:\theta>0$ 的水平为 α 的 $UMPT$ (提示：仿照例 6.2.3) 。

解. (1) 设 $(X_{(1)},X_{(n)})=(Y,Z)\sim f(y,z)$ ，则由均匀分布次序统计量的分布知

$$f(y,z)=n(n-1)(z-y)^{n-2}\ I\{\theta\le y<z\le\theta+1\}.$$

(2) 仿照例 6.2.3 的方法，我们先考虑简单假设检验问题 (i) $H_0:\theta=\theta_0=0\ \longleftrightarrow\ H_1:\theta=\theta_1>\theta_0$ 。

因为 $y<1-\alpha^{\frac{1}{n}},\ z<1$ 时 $\phi^*=0$ ，所以有

$$\begin{aligned}\mathrm{E}_{\theta_0}[\phi^*(X_{(1)},X_{(n)})] &= \int_0^1\int_0^1\phi^*(y,z)n(n-1)(z-y)^{n-2}I\{0\le y<z\le 1\}\ dzdy\\ &= \int_{1-\alpha^{\frac{1}{n}}}^1\int_y^1 n(n-1)(z-y)^{n-2}\ dzdy\\ &= \int_{1-\alpha^{\frac{1}{n}}}^1 n(1-y)^{n-1}\ dy=-(1-y)^n\,\big|_{1-\alpha^{1/n}}^1=\alpha.\end{aligned}$$

所以 ϕ^* 是假设检验问题 (i) 的水平为 α 的检验。

设 ϕ 是假设检验问题 (i) 的任一水平为 α 的检验,下面我们分两种情况来证明 $\mathrm{E}_{\theta_1}[\phi^*] \geq E_{\theta_1}[\phi]$ 。注意，以下积分只需考虑 $\phi^* = 1$ 的情形即可。

若 $\theta_1 \geq 1-\alpha^{\frac{1}{n}}$ ，这时有 $X_{(1)} \geq 1-\alpha^{\frac{1}{n}}$ ， $\phi^* = 1$ ，因此

$$\mathrm{E}_{\theta_1}[\phi^*] = \int_{\theta_1}^{\theta_1+1}\int_{y}^{\theta_1+1} f(y,z)dzdy = 1.$$

由此可知 $\mathrm{E}_{\theta_1}[\phi^*] \geq E_{\theta_1}[\phi]$ 。

若 $0 < \theta_1 < 1-\alpha^{\frac{1}{n}}$ ，则在 $\mathrm{E}_{\theta_1}[\phi^*]$ 的积分中， $y,\ z$ 必须满足 $\theta \leq y < z \leq \theta+1$ ，并且只有当 $y \geq 1-\alpha^{\frac{1}{n}}$ 或者 $z \geq 1$ (见图) 时才有 $\phi^* = 1$ ，所以我们可以把 $\mathrm{E}_{\theta_1}[\phi^*]$ 表示为

$$\begin{aligned}
\mathrm{E}_{\theta_1}[\phi^*] &= \int_{\theta_1}^{\theta_1+1}\int_{y}^{\theta_1+1} \phi^*(y,z)f(y,z)\ dzdy \\
&= \int_{\theta_1}^{1-\alpha^{\frac{1}{n}}}\int_{1}^{\theta_1+1} n(n-1)(z-y)^{n-2}\ dzdy + \int_{1-\alpha^{\frac{1}{n}}}^{\theta_1+1}\int_{y}^{\theta_1+1} n(n-1)(z-y)^{n-2}\ dzdy \\
&= \int_{\theta_1}^{1-\alpha^{\frac{1}{n}}} n[(1+\theta_1-y)^{n-1}-(1-y)^{n-1}]\ dy + \int_{1-\alpha^{\frac{1}{n}}}^{\theta_1+1} n(1+\theta_1-y)^{n-1}\ dy \\
&= \int_{\theta_1}^{\theta_1+1} n(1+\theta_1-y)^{n-1}\ dy - \int_{\theta_1}^{1-\alpha^{\frac{1}{n}}} (1-y)^{n-1}\ dy \\
&= 1+\alpha-(1-\theta_1)^n.
\end{aligned}$$

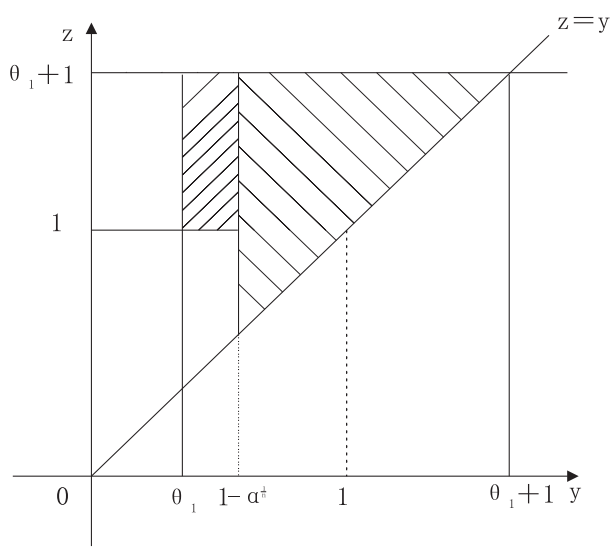

下面再计算 $\mathrm{E}_{\theta_1}[\phi]$ 。因为 $\mathrm{E}_{\theta_0}[\phi] = \int_0^1\int_y^1 \phi f(y,z)dzdy \leq \alpha$ ，而且 $y,\ z$ 满足 $\theta \leq y < z \leq \theta+1$ (见图) ，所以我们可以把 $\mathrm{E}_{\theta_1}[\phi]$ 表示为

$$\begin{aligned}
\mathrm{E}_{\theta_1}[\phi] &= \int_{\theta_1}^{\theta_1+1}\int_{y}^{\theta_1+1} \phi(y,z)f(y,z)\ dzdy \\
&= \int_{\theta_1}^{1}\int_{y}^{1} \phi f(y,z)\ dzdy + \int_{1}^{\theta_1+1}\int_{\theta_1}^{z} \phi f(y,z)\ dydz
\end{aligned}$$

$$
\begin{aligned}
&\leq \int_0^1 \int_y^1 \phi f(y,z)\ dzdy + \int_1^{\theta_1+1} \int_{\theta_1}^z f(y,z)\ dydz \\
&= \mathrm{E}_{\theta_0}[\phi] + \int_1^{\theta_1+1} n(z-\theta_1)^{n-1} dz \\
&\leq \alpha + 1 - (1-\theta_1)^n \\
&= E_{\theta_1}[\phi^*].
\end{aligned}
$$

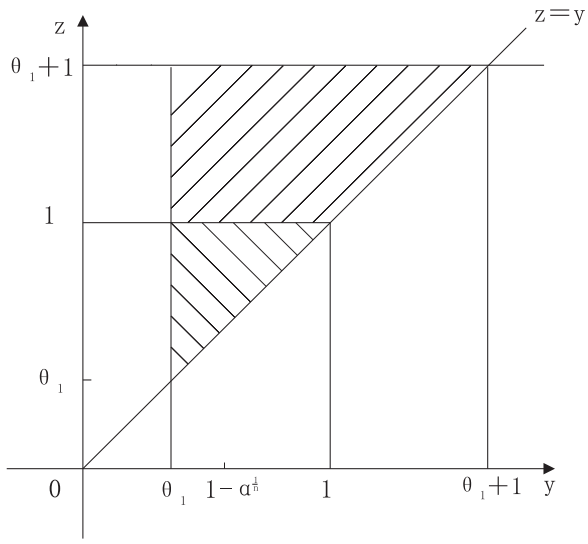

综合以上结合可知， ϕ^* 是假设检验问题 (i) 的水平为 α 的 MPT 。

因为 ϕ^* 与 θ_1 的具体取值无关，只与 $\theta_1 > \theta_0$ 有关，所以由引理 6.2.1 可知， ϕ^* 也是假设检验问题 (ii) $H_0 : \theta = 0 \longleftrightarrow H_1 : \theta > 0$ 的水平为 α 的 UMPT 。

下面我们来证明： ϕ^* 是假设检验问题 (iii) $H_0 : \theta \leq 0 \longleftrightarrow H_1 : \theta > 0$ 的水平为 α 的 UMPT 。为此，根据引理 6.2.1 ，只需证明当 $\theta \leq 0$ 时， $\mathrm{E}_\theta[\phi^*] \leq \alpha$ 即可，这可分两种情况来加以证明。

当 $\theta < -\alpha^{\frac{1}{n}}$ ，即 $1+\theta < 1-\alpha^{\frac{1}{n}}$ 时，我们有 $y < z < 1-\alpha^{\frac{1}{n}}$ ，即 $y < 1-\alpha^{\frac{1}{n}}$ ，并且 $z < 1$ ，这时 $\phi^* = 0$ ，因此 $\mathrm{E}_\theta[\phi^*] = 0 < \alpha$ 。

当 $0 > \theta \geq -\alpha^{\frac{1}{n}}$ ，即 $1 > 1+\theta \geq 1-\alpha^{\frac{1}{n}}$ 时，这时 $y < z \leq 1+\theta < 1$ ，因此只有 $y \geq 1-\alpha^{\frac{1}{n}}$ 时，才有 $\phi^* = 1$ ，所以

$$
\mathrm{E}_\theta[\phi^*] = \int_{1-\alpha^{\frac{1}{n}}}^{\theta+1} \int_y^{\theta+1} f(y,z) dzdy = \int_{1-\alpha^{\frac{1}{n}}}^{\theta+1} n(1+\theta-y)^{n-1} dy = (\theta + \alpha^{\frac{1}{n}})^n.
$$

这表明， $\mathrm{E}_\theta[\phi^*]$ 在区间 $[-\alpha^{\frac{1}{n}}, 0]$ 上是 θ 的严增函数，所以对于满足 $-\alpha^{\frac{1}{n}} \leq \theta < 0$ 的 θ 都有 $\mathrm{E}_\theta[\phi^*] \leq \mathrm{E}_{\theta_0=0}[\phi^*] = \alpha$ 。

综上所述， ϕ^* 是假设检验问题 (iii) 的水平为 α 的检验，因此，由引理 6.2.1 可知， ϕ^* 是假设检验问题 (iii) 的水平为 α 的 UMPT 。 ∎

17. ★ 假设 $\{X \sim f(x,\theta),\ \theta \in \Theta \subset R\}$ 关于 $T = T(X)$ 为单调似然比分布族。考虑假设检验问题 $H_0 : \theta \leq \theta_0 \longleftrightarrow H_1 : \theta > \theta_0$ ，其水平为 α 的 $UMPT$ 的否定域为 $R^+ = \{T(X) >$

$c(\theta_0)\}$，且满足 $P_{\theta_0}\{T(X) > c(\theta_0)\} = \alpha$；该式对任意的 $\theta_0 \in \Theta$ 都成立。若把 $c(\theta)$ 看成 θ 的函数，证明： $c(\theta)$ 是 θ 的增函数 (提示：利用 $UMPT$ 的无偏性) 。

证明. 对任意的 $\theta_1, \theta_2 \in \Theta$， $\theta_1 < \theta_2$， 我们考虑如下简单假设检验问题：

$$H_0 : \theta = \theta_1 \ \longleftrightarrow \ H_1 : \theta = \theta_2.$$

由题意可知，若 $\phi(X)$ 为该检验的其水平为 α 的 MPT，则其否定域为 $R^+ = \{x : T(x) > c(\theta_1)\}$，且满足 $P_{\theta_1}\{T(X) > c(\theta_1)\} = \alpha$。由无偏性定理知

$$\mathrm{E}_{\theta_2}[\phi(X)] = P_{\theta_2}\{T(X) > c(\theta_1)\} \geq \alpha,$$

而由假设可知，在 θ_2 处有 $P_{\theta_2}\{T(X) > c(\theta_2)\} = \alpha$，所以

$$P_{\theta_2}\{T(X) > c(\theta_1)\} \geq P_{\theta_2}\{T(X) > c(\theta_2)\}.$$

因此必有 $c(\theta_1) \leq c(\theta_2)$，即 $c(\theta)$ 是 θ 的增函数。 ∎

18. 设 $X_1, \cdots, X_n$ 为 $i.i.d.$ 样本， $X_1 \sim f(x_1, \theta) = \theta x_1^{\theta-1} I\{0 \leq x_1 \leq 1\}$, $\theta > 0$。

(1) $H_0 : \theta \leq \theta_1$ 或 $\theta \geq \theta_2 \longleftrightarrow H_1 : \theta_1 < \theta < \theta_2$，求其水平为 α 的 $UMPT$:

(2) $H_0 : \theta = \theta_0 \longleftrightarrow H_1 : \theta \neq \theta_0$，求其水平为 α 的 $UMPUT$。

解. (1) $X_1, \cdots, X_n$ 的联合密度函数为

$$f(x;\theta) = \theta^n (\prod_{i=1}^n x_i)^{\theta-1} = \exp\{\theta \sum_{i=1}^n \log x_i - \sum_{i=1}^n \log x_i + n \log \theta\}$$

显然， $f(x;\theta)$ 关于 $T(x) = \sum_{i=1}^n \log x_i$ 是单参数指数族。由于 $T(X)$ 服从连续型分布，所以由定理 6.4.2 可知假设检验问题的水平为 α 的 UMPT 为

$$\phi(T) = \begin{cases} 1 & , \quad c_1 < T < c_2 \\ 0 & , \quad T < c_1 \text{ 或 } T > c_2 \end{cases}$$

其中 c_1, c_2 由 $\mathrm{E}_{\theta_1}[\phi(T)] = \mathrm{E}_{\theta_2}[\phi(T)] = \alpha$ 决定。因为 $-2\theta T \ \sim \ \chi^2(2n)$ (见本章第 12 题)，所以 c_1, c_2 满足

$$\begin{aligned} \mathrm{E}_{\theta_i}[\phi(T)] &= P_{\theta_i}\{c_1 < T < c_2\} \\ &= P_{\theta_i}\{-2\theta_i c_2 < -2\theta_i T < -2\theta_i c_1\} \\ &= \int_{-2\theta_i c_2}^{-2\theta_i c_1} \chi^2(2n; y) dy = \alpha, \quad i = 1,\ 2. \end{aligned}$$

其中 $\chi^2(2n; y)$ 表示自由度为 $2n$ 的 χ^2 分布的密度函数。

(2) 由定理 6.4.4 可知假设检验问题

$$H_0 : \theta = \theta_0 (> 0) \ \longleftrightarrow \ H_1 : \theta \neq \theta_0$$

的水平为 α 的 UMPUT 为

$$\phi(T) = \begin{cases} 1 & , \quad T < k_1 \text{ 或 } T > k_2 \\ 0 & , \quad k_1 < T < k_2 \end{cases}$$

其中 k_1, k_2 由 $\mathrm{E}_{\theta_0}[\phi(T)] = \alpha$ 和 $\mathrm{E}_{\theta_0}[T\phi(T)] = \alpha\mathrm{E}_{\theta_0}[T]$ 决定。因为 $Y = -2\theta_0 T \sim \chi^2(2n)$，所以由 $\mathrm{E}_{\theta_0}[\phi(T)] = \alpha$ 及 $\mathrm{E}_{\theta_0}[1-\phi(T)] = 1-\alpha$ 可得

$$\begin{aligned}\mathrm{E}_{\theta_0}[1-\phi(T)] &= P_{\theta_0}\{k_1 < T < k_2\} \\ &= P_{\theta_0}\{-2\theta_0 k_2 < -2\theta_0 T < -2\theta_0 k_1\} \\ &= \int_{-2\theta_0 k_2}^{-2\theta_0 k_1} \chi^2(2n; y)dy = 1-\alpha.\end{aligned}$$

又由 $\mathrm{E}_{\theta_0}[T] = -\mathrm{E}_{\theta_0}[-2\theta_0 T]/(2\theta_0) = -n/\theta_0$ 及 $\mathrm{E}_{\theta_0}[(1-\phi(T))T] = -n(1-\alpha)/\theta_0$ 可得 $\mathrm{E}_{\theta_0}[(1-\phi(T))(-2\theta_0 T)] = 2n(1-\alpha)$，因此有

$$\begin{aligned}\mathrm{E}_{\theta_0}[(1-\phi(T))(-2\theta_0 T)] &= \int I\{k_1 < T < k_2\} y\chi^2(2n; y)dy \\ &= \int I\{-2\theta_0 k_2 < -2\theta_0 T < -2\theta_0 k_1\} y\chi^2(2n; y)dy \\ &= \int_{-2\theta_0 k_2}^{-2\theta_0 k_1} y\chi^2(2n; y)dy = 2n(1-\alpha).\end{aligned}$$

所以 k_1, k_2 由以上两个关于 χ^2 分布的积分决定。 ∎

19. 设 $X_1, \cdots, X_n$ 为 *i.i.d.* 样本， $X_1 \sim N(\mu, 1)$ 。对于假设检验问题 $H_0: \mu \le -a$ 或 $\mu \ge a \longleftrightarrow H_1: -a < \mu < a;\ a > 0$ 。证明：其水平为 α 的 UMPT 可表示为：

$$\phi^*(x) = \begin{cases} 1, & -k < \bar{x} < k \\ 0, & \text{其他} \end{cases}$$

并给出 k 的定解条件。

证明. 由例 (6.4.2) 或表 (6.5.1) 可知，假设检验问题

$$H_0: \mu \le \mu_1 \text{ 或 } \mu \ge \mu_2 \longleftrightarrow H_1: \mu_1 < \mu < \mu_2$$

的 UMPUT 为

$$\phi(x) = \begin{cases} 1, & k_1 < \bar{x} < k_2 \\ 0, & \text{其他} \end{cases}$$

其中 k_1, k_2 由 $\mathrm{E}_{\mu_i}[\phi(X)] = P_{\mu_i}\{k_1 < \bar{X} < k_2\} = \alpha,\ i = 1, 2$ 决定。因此，我们只需证明，在 $a = \mu_2 = -\mu_1$ 的条件下，上面的 $\phi(x)$ 满足 $k = k_2 = -k_1$ 即可。

k_1, k_2 由以下方程决定：

$$P_{\mu_1}(k_1 - \mu_1 < \bar{X} - \mu_1 < k_2 - \mu_1) = \alpha, \tag{1}$$

$$P_{\mu_2}(k_1 - \mu_2 < \bar{X} - \mu_2 < k_2 - \mu_2) = \alpha. \tag{2}$$

当 $\mu_2 = -\mu_1$ 时， (2) 式等价于

$$P_{\mu_1}(k_1 + \mu_1 < \bar{X} + \mu_1 < k_2 + \mu_1) = \alpha. \tag{3}$$

在 (1) 式中，$\bar{X} - \mu_1 \sim N(0, \frac{1}{n})$，在 (2) 式中，也有 $\bar{X} - \mu_2 = \bar{X} + \mu_1 \sim N(0, \frac{1}{n})$。在 (1)，(3) 两式中，其积分值相同，同时被积函数与积分区间的长度也都相同，但积分限不同。由

正态分布 $N(0,\frac{1}{n})$ 的对称性可知, 区间 $[k_1-\mu_1,\ k_2-\mu_1]$ 与 $[k_1+\mu_1,\ k_2+\mu_1]$ 必然关于原点对称, 因此有 $k_1-\mu_1=-(k_2+\mu_1)$, 因而有 $k_2=-k_1$ 。以上讨论中, 取 $\mu_1=-a,\ \mu_2=a$, 则说明, 假设检验问题 $H_0:\mu\le -a$ 或 $\mu\ge a \longleftrightarrow H_1:-a<\mu<a;\ a>0$ 的水平为 α 的 UMPUT 可表示为

$$\phi^*(x)=\begin{cases}1, & -k<\bar{x}<k\\ 0, & \text{其他}\end{cases}$$

其中 k 由 $\mathrm{E}_{\mu=a}[\phi(X)]=P_{\mu=a}\{-k<\bar{X}<k\}=\alpha$, 即 $\Phi(\sqrt{n}(k-a))-\Phi(-\sqrt{n}(k+a))=\alpha$ 决定, 其中 $\Phi(.)$ 为标准正态分布的分布函数。 ∎

20. 设 $X_1,\cdots,X_n$ 为 $i.i.d.$ 样本, $X_1\sim N(\mu,\sigma^2)$ 。证明以下假设检验问题的 UMPT 不存在:

(1) $H_0:\mu=0\longleftrightarrow H_1:\mu\ne 0$, 已知 $\sigma=1$;

(2) $H_0:\sigma=1\longleftrightarrow H_1:\sigma\ne 1$, 已知 $\mu=0$ (提示: 利用单边检验中功效函数的单调性) 。

证明. (1) 设 $\phi(x)$ 是假设检验问题 (1) $H_0:\mu=0\longleftrightarrow H_1:\mu\ne 0$ 的水平为 α 的 UMPT 。由于 $\phi^*(x)\equiv\alpha$ 是假设检验问题 (1) 的水平为 α 的检验, 所以有

$$\mathrm{E}_\mu[\phi(X)]\ge \mathrm{E}_\mu[\phi^*(X)]=\alpha\ ,\forall\ \mu\ne 0 \tag{1}$$

显然, $\phi(x)$ 也是假设检验问题

$$\text{(i)}'\ H_0:\mu=0\ \longleftrightarrow\ H_1:\mu=\mu_1\ (\mu_1>0).$$

的水平为 α 的 MPT 。由原书例 6.2.3 可知, 假设检验问题 (i)$'$ 的 MPT 的否定域为 $R^+=\{x:\overline{x}>\frac{1}{\sqrt{n}}z_{1-\alpha}\}$, 所以由唯一性可知 $\phi(x)$ 的否定域也为 R^+ 。由此可算得 $\phi(x)$ 的功效函数为

$$\beta_\phi(\mu)=\mathrm{E}_\mu[\phi(X)]=\Phi(\sqrt{n}\mu-z_{1-\alpha})$$

易见, $\beta_\phi(\mu)$ 是 μ 的严增函数。因此在 $\mu<0$ 时, 有 $\mathrm{E}_\mu[\phi(X)]<\mathrm{E}_0[\phi(X)]=\alpha$, 这与 (1) 式相矛盾, 所以假设检验问题 (i) 的 UMPT 不存在。

(2) 设 $\phi(x)$ 是假设检验问题 (2) $H_0:\sigma=1\longleftrightarrow H_1:\sigma\ne 1$ 的水平为 α 的 UMPT 。由于 $\phi^*(x)\equiv\alpha$ 是假设检验问题 (2) 的水平为 α 的检验, 所以有

$$\mathrm{E}_\sigma[\phi(X)]\ge \mathrm{E}_\sigma[\phi^*(X)]=\alpha,\ \ \forall\sigma\ne 1. \tag{2}$$

显然, $\phi(x)$ 也是假设检验问题

$$\text{(ii)}'\ H_0:\sigma=1\ \longleftrightarrow\ H_1:\sigma=\sigma_1(\sigma_1<1)$$

的水平为 α 的 MPT 。由原书例 6.3.8 可知, 假设检验问题 (ii)$'$ 的 MPT 的否定域为 $R^+=\{x:T(x)=\sum\limits_{i=1}^{n}{x_i}^2<\chi^2(n,\alpha)\}$, 所以由唯一性可知 $\phi(x)$ 的否定域也为 R^+ 。由此可算得 $\phi(x)$ 的功效函数为

$$\beta_\phi(\sigma)=\mathrm{E}_\sigma[\phi(X)]=P\{\frac{T}{\sigma^2}<\frac{1}{\sigma^2}\chi^2(n,\alpha)\}.$$

由于 $T/\sigma^2\ \sim\ \chi^2(n)$, 所以 $\beta_\phi(\sigma)$ 是 σ 的严减函数。因此在 $\sigma>1$ 时, 有 $\mathrm{E}_\sigma[\phi(X)]<\mathrm{E}_1[\phi(X)]=\alpha$, 这与 (2) 式相矛盾, 所以假设检验问题 (ii) 的 UMPT 不存在。 ∎

21. 设 $X_1,\cdots,X_n$ 为 *i.i.d.* 样本， $X_1\sim\Gamma(\frac{1}{\theta},1)$ 。求以下假设检验问题 $H_0:\theta=\theta_0\longleftrightarrow H_1:\theta\neq\theta_0$ 水平为 α 的 UMPUT 。

解. $X_1,\cdots,X_n$ 的联合密度函数为

$$f(x;\theta)=\prod_{i=1}^{n}\frac{1}{\theta}\exp\{-\frac{1}{\theta}x_i\}=\frac{1}{\theta^n}\exp\{-\frac{1}{\theta}\sum_{i=1}^{n}x_i\}$$

因为 $Q(\theta)=-\frac{1}{\theta}$ 是 θ 的严增函数，所以 $f(x;\theta)$ 关于 $T(x)=\sum_{i=1}^{n}x_i$ 为单参数指数族分布，其中 $T\sim\Gamma(\frac{1}{\theta},n)$ 。由原书定理 6.4.4 可知假设检验问题 $H_0:\theta=\theta_0\longleftrightarrow H_1:\theta\neq\theta_0$ 的水平为 α 的 UMPUT 是

$$\phi(T)=\begin{cases}1 & , \quad T<k_1 \text{ 或 } T>k_2\\ 0 & , \quad k_1<T<k_2\end{cases}$$

其中 k_1, k_2 由 $\mathrm{E}_{\theta_0}[\phi(T)]=\alpha$ 和 $\mathrm{E}_{\theta_0}[T\phi(T)]=\alpha\mathrm{E}_{\theta_0}[T]$ 决定。事实上，当 $\theta=\theta_0$ 时，$T\sim\Gamma(\frac{1}{\theta_0},n)$ ，即 $\frac{2}{\theta_0}T\sim\Gamma(\frac{1}{2},n)\sim\chi^2(2n)$ ，所以由 $\mathrm{E}_{\theta_0}[\phi(T)]=\alpha$ 可得

$$\mathrm{E}_{\theta_0}[1-\phi(T)]=P_{\theta_0}(\frac{2}{\theta_0}k_1<\frac{2}{\theta_0}T<\frac{2}{\theta_0}k_2)=\int_{2k_1/\theta_0}^{2k_2/\theta_0}\chi^2(2n,y)dy=1-\alpha.$$

由于 $\mathrm{E}_{\theta_0}T=n\theta_0$,因此有 $\mathrm{E}_{\theta_0}[T\phi(T)]=\alpha\mathrm{E}_{\theta_0}[T]=\alpha n\theta_0$ 及 $\mathrm{E}_{\theta_0}[T(1-\phi(T))]=(1-\alpha)n\theta_0$ ，由此可得 $\mathrm{E}_{\theta_0}[(2T/\theta_0)(1-\phi(T))]=2n(1-\alpha)$ 。因此由 $2T/\theta_0\sim\chi^2(2n)$ 可得

$$\begin{aligned}\mathrm{E}_{\theta_0}[(2T/\theta_0)(1-\phi(T))] &= \int I\{k_1<T<k_2\}y\chi^2(2n;y)dy\\ &= \int I\{\frac{2}{\theta_0}k_1<\frac{2}{\theta_0}T<\frac{2}{\theta_0}k_2\}y\chi^2(2n;y)dy\\ &= \int_{2k_1/\theta_0}^{2k_2/\theta_0}y\chi^2(2n;y)dy=2n(1-\alpha).\end{aligned}$$

所以 k_1, k_2 由以上两个关于 χ^2 分布的积分决定。 ∎

22. 对于指数族分布，设 $\phi_1(x)$ 是假设检验问题 $H_0:\theta\leq\theta_1$ 或 $\theta\geq\theta_2\longleftrightarrow H_1:\theta_1<\theta<\theta_2$ 的水平为 α 的 UMPT 。若 $\widetilde{\phi}(x)$ 为一个检验，且 $\mathrm{E}_{\theta_1}\widetilde{\phi}(X)=\mathrm{E}_{\theta_2}\widetilde{\phi}(X)=\alpha$, 则 $\mathrm{E}_{\theta}\phi_1(X)\leq\mathrm{E}_{\theta}\widetilde{\phi}(X)$, 对任意的 $\theta<\theta_1$ 或 $\theta>\theta_2$ 成立。

证明. 考虑假设检验问题 $H_0:\theta=\theta_1$ 或 $\theta=\theta_2\longleftrightarrow H_1:\theta=\theta_4\ (<\theta_1)$ (或 $\theta=\theta_5\ (>\theta_2)$) ，令

$$\phi_2^*=1-\phi_1=\begin{cases}1 & , \quad T<k_1 \text{ 或 } T>k_2\\ 1-\gamma_{1i} & , \quad T=k_i\ ,\ i=1,2\\ 0 & , \quad k_1<T<k_2.\end{cases}$$

则 ϕ_2^* 具有原书引理 6.4.2 中 ϕ_2 的形式，且 $\mathrm{E}_{\theta_1}[\phi_2^*]=\mathrm{E}_{\theta_2}[\phi_2^*]=1-\alpha$ 。因为 $\mathrm{E}_{\theta_1}[1-\widetilde{\phi}]=\mathrm{E}_{\theta_2}[1-\widetilde{\phi}]=1-\alpha$ ，所以由引理 6.4.2 可知 $\mathrm{E}_{\theta_4}[\phi_2^*]\geq\mathrm{E}_{\theta_4}[1-\widetilde{\phi}]$ ， $\forall\ \theta_4<\theta_1$ (或 $\mathrm{E}_{\theta_5}[\phi_2^*]\geq\mathrm{E}_{\theta_5}[1-\widetilde{\phi}]$ ， $\forall\ \theta_5>\theta_2$) ，即对任意 $\theta<\theta_1$ 或 $\theta>\theta_2$ ，有 $\mathrm{E}_{\theta}[\phi_1]\leq\mathrm{E}_{\theta}[\widetilde{\phi}]$ 。 ∎

23. 设 $f(x)$ 和 $g(x)$ 是两个已知的密度函数, 又设 X 的密度函数为 $\theta f(x)+(1-\theta)g(x)$, $\theta\in R$ 。证明： $\phi^*(x)=\alpha$ 是假设检验问题 $H_0:\theta\leq\theta_1$ 或 $\theta\geq\theta_2\longleftrightarrow H_1:\theta_1<\theta<\theta_2$ 的一个水平为 α 的 UMPT 。

证明. 对于任意的 $\theta \in R$ ，检验 $\phi^*(x)$ 的功效函数为

$$\beta_{\phi^*}(\theta) = \mathrm{E}_\theta[\phi^*(X)] = \int_{\mathcal{X}} \alpha[\theta f(x) + (1-\theta)g(x)]\ dx \equiv \alpha.$$

所以 $\phi^*(x)$ 是假设检验问题的一个水平为 α 的检验,并且对于 $\theta_1 < \theta < \theta_2$,有 $\mathrm{E}_\theta[\phi^*(X)] = \beta_{\phi^*}(\theta) = \alpha$ 。今设 $\phi(x)$ 为假设检验问题的一个水平为 α 的检验，并设 $a = \mathrm{E}_f[\phi(X)] = \int_{\mathcal{X}} \phi(x)f(x)\ dx$ ， $b = \mathrm{E}_g[\phi(X)] = \int_{\mathcal{X}} \phi(x)g(x)\ dx$ ，则对任意的 $\theta \le \theta_1$ 或 $\theta \ge \theta_2$ ，由水平条件可知

$$\begin{aligned}
\mathrm{E}_\theta[\phi(X)] &= \int_{\mathcal{X}} \phi(x)[\theta f(x) + (1-\theta)g(x)]\ dx \\
&= \theta \mathrm{E}_f[\phi(X)] + (1-\theta)\mathrm{E}_g[\phi(X)] \\
&= a\theta + b(1-\theta) = (a-b)\theta + b \le \alpha.
\end{aligned}$$

即 $(a-b)\theta \le \alpha - b$ 。由水平条件可知，该式对任意的 $\theta \le \theta_1$ 或 $\theta \ge \theta_2$ 都成立，而 $a-b$ 和 $\alpha - b$ 都是确定的常数，所以必有 $a-b=0$ 及 $b \le \alpha$ 。 所以当 $\theta_1 < \theta < \theta_2$ 时，我们有

$$\begin{aligned}
\mathrm{E}_\theta[\phi(X)] &= \int_{\mathcal{X}} \phi(x)[\theta f(x) + (1-\theta)g(x)]\ dx \\
&= a\theta + b(1-\theta) = (a-b)\theta + b \\
&= b \le \alpha = \mathrm{E}_\theta[\phi^*(X)].
\end{aligned}$$

因此 $\phi^*(x)$ 是假设检验问题的一个水平为 α 的 UMPT 。 ∎

24. ★ 设 $X_1, \cdots, X_n$ 为 *i.i.d.* 样本， X_1 服从均匀分布 $R(0,\theta)$, $\theta > 0$ 。证明：以下 $\phi^*(x)$ 是假设检验问题 $H_0 : \theta = \theta_0\ (>0) \longleftrightarrow H_1 : \theta \ne \theta_0$ 的一个水平为 α 的 UMPT.

$$\phi^* = \begin{cases} 1, & X_{(n)} > \theta_0 \text{ 或 } X_{(n)} \le \theta_0 \alpha^{\frac{1}{n}} \\ 0, & \text{其他} \end{cases}$$

(提示:对 $\forall\, \theta_1 \ne \theta_0$,把 θ_1 分为 $\theta_1 < \theta_0\alpha^{\frac{1}{n}}$; $\theta_0\alpha^{\frac{1}{n}} \le \theta_1 \le \theta_0$ 以及 $\theta_1 > \theta_0$ 等情形证明 $\mathrm{E}_{\theta_1}\phi^* \ge \mathrm{E}_{\theta_1}\phi$).

证明. 因为 $X_{(n)}/\theta \sim BE(n,1)$ ，由此容易验证:

$$\mathrm{E}_{\theta_0}[\phi^*(X)] = \int_0^{\theta_0\alpha^{1/n}} n\theta_0^{-n}x^{n-1}\ dx = \alpha.$$

所以 $\phi^*(x)$ 是假设检验问题的一个水平为 α 的检验。今设 $\phi(x)$ 为假设检验问题的任一水平为 α 的检验，即 $\mathrm{E}_{\theta_0}[\phi(X)] \le \alpha$ ，由充分性准则， ϕ 可取为 $X_{(n)}$ 的函数。下面，我们分三种情况来证明 $\mathrm{E}_{\theta_1}[\phi^*(X)] \ge \mathrm{E}_{\theta_1}[\phi(X)]$ 对任意的 $\theta_1 \ne \theta_0$ 都成立。注意， $\phi^*(x)$ 仅在 $R^+ = \{x_{(n)} > \theta_0\} \cup \{x_{(n)} \le \theta_0\alpha^{1/n}\}$ 上取值为 1 。

i) 当 $\theta_1 < \theta_0\alpha^{1/n}$ 时，对于分布 $R(0,\theta_1)$ 有 $X_{(n)} \le \theta_1 \le \theta_0\alpha^{1/n}$ ，所以 $\phi^*(X) = 1$ ，从而有 $\mathrm{E}_{\theta_1}[\phi^*(X)] = 1$ ，由此可得 $\mathrm{E}_{\theta_1}[\phi^*(X)] = 1 \ge \mathrm{E}_{\theta_1}[\phi(X)]$ 。

ii) 当 $\theta_0\alpha^{1/n} \le \theta_1 \le \theta_0$ 时，我们有

$$\begin{aligned}
\mathrm{E}_{\theta_1}[\phi^*(X)] &= \int_0^{\theta_0\alpha^{1/n}} n\theta_1^{-n}x^{n-1}\ dx = \frac{\theta_0^n}{\theta_1^n}\alpha. \\
\mathrm{E}_{\theta_1}[\phi(X)] &= \int_0^{\theta_1} \phi(x)n\theta_1^{-n}x^{n-1}\ dx \le \int_0^{\theta_0} \phi(x)n\theta_1^{-n}x^{n-1}\ dx
\end{aligned}$$

$$
\begin{aligned}
&= \frac{\theta_0^n}{\theta_1^n}\int_0^{\theta_0}\phi(x)n\theta_0^{-n}x^{n-1}\,dx = \mathrm{E}_{\theta_0}[\phi(X)]\cdot\frac{\theta_0^n}{\theta_1^n}\\
&\le \alpha\frac{\theta_0^n}{\theta_1^n} = \mathrm{E}_{\theta_1}[\phi^*(X)].
\end{aligned}
$$

iii) 当 $\theta_1 > \theta_0$ 时，由于 ϕ^* 在 $(\theta_0\alpha^{1/n},\ \theta_0)$ 上的值为零，因此有

$$
\begin{aligned}
\mathrm{E}_{\theta_1}[\phi^*(X)] &= \int_0^{\theta_0\alpha^{1/n}} n\theta_1^{-n}x^{n-1}\,dx + \int_{\theta_0}^{\theta_1} n\theta_1^{-n}x^{n-1}\,dx\\
&= \frac{\theta_0^n}{\theta_1^n}\alpha + 1 - \frac{\theta_0^n}{\theta_1^n}.\\
\mathrm{E}_{\theta_1}[\phi(X)] &= \int_0^{\theta_1}\phi(x)n\theta_1^{-n}x^{n-1}\,dx\\
&= \int_0^{\theta_0}\phi(x)n\theta_1^{-n}x^{n-1}\,dx + \int_{\theta_0}^{\theta_1}\phi(x)n\theta_1^{-n}x^{n-1}\,dx\\
&= \frac{\theta_0^n}{\theta_1^n}\int_0^{\theta_0}\phi(x)n\theta_0^{-n}x^{n-1}\,dx + \int_{\theta_0}^{\theta_1}\phi(x)n\theta_1^{-n}x^{n-1}\,dx\\
&\le \frac{\theta_0^n}{\theta_1^n}\cdot\mathrm{E}_{\theta_0}[\phi(X)] + \int_{\theta_0}^{\theta_1} n\theta_1^{-n}x^{n-1}\,dx\\
&\le \frac{\theta_0^n}{\theta_1^n}\alpha + 1 - \frac{\theta_0^n}{\theta_1^n} = \mathrm{E}_{\theta_1}[\phi^*(X)].
\end{aligned}
$$

综上所述， $\phi^*(x)$ 是假设检验问题 $H_0:\theta=\theta_0\ (>0) \longleftrightarrow H_1:\theta=\theta_1\ (\theta_1\neq\theta_0)$ 的一个水平为 α 的 MPT 。

由于 $\phi^*(x)$ 仅与 θ_0 有关，与 $\theta_1\ (\neq\theta_0)$ 的具体取值无关，所以由引理 6.2.1 可知，$\phi^*(x)$ 是假设检验问题 $H_0:\theta=\theta_0\ (>0) \longleftrightarrow H_1:\theta\neq\theta_0$ 的一个水平为 α 的 UMPT 。 ∎

25. ★ 设 $X_1,\cdots,X_n$ 为 *i.i.d.* 样本，求假设检验问题 $H_0:\theta=\theta_0 \longleftrightarrow H_1:\theta\neq\theta_0$ 的一个水平为 α 的 UMPT:

(1) $X_1\sim\theta+\Gamma(\frac{1}{\sigma},1)$ ，其中 $\theta\in R$ 未知， $\sigma>0$ 已知;

(2) $X_1\sim PR(c,\theta),\ \theta>0, c>0$ ，即 $f(x_1;\theta,c)=c\theta^c x_1^{-(c+1)}I\{x_1\ge\theta\}$ ， $c>0$ 已知 (提示：参见第 25 题中 UMPT 的形式) 。

解. (1) 基于本章习题 24 中 UMPT 的形式，我们猜测本题假设检验问题的 UMPT 具有如下形式

$$
\phi^*(X)=\begin{cases} 1 & ,\quad X_{(1)}<\theta_0 \text{ 或 } X_{(1)}>\theta^* \quad (\theta^*>\theta_0)\\ 0 & ,\quad \text{其他}\end{cases}
$$

其中 θ^* 由水平条件 $\mathrm{E}_{\theta_0}[\phi^*(X)]=\alpha$ 得到。事实上，因为 $X_{(1)}\ \sim\ \theta+\Gamma(\frac{n}{\sigma},1)$ ，所以有

$$
\mathrm{E}_{\theta_0}[\phi^*(X)] = P_{\theta_0}(X_{(1)}>\theta^*) = \int_{\theta^*}^{\infty}\frac{n}{\sigma}\ \exp\{-\frac{n}{\sigma}(t-\theta_0)\}\,dt = \exp\{-\frac{n}{\sigma}(\theta^*-\theta_0)\} = \alpha
$$

由此可得 $\theta^*=\theta_0-\frac{\sigma}{n}\log\alpha\ge\theta_0$ 。

下面我们证明 $\phi^*(x)$ 的确是假设检验问题的水平为 α 的 UMPT 。

由 θ^* 的确定过程可知 $\phi^*(x)$ 是假设检验问题的水平为 α 的检验。今设 $\phi(x)$ 是假设检验问题的任一水平为 α 的检验，即 $\mathrm{E}_{\theta_0}[\phi(X)]\le\alpha$ ，由充分性准则， $\phi(x)$ 可取为 $X_{(1)}$ 的函数。下面我们仍然分三种情况来证明：对于任意的 $\theta\neq\theta_0$ 有 $\mathrm{E}_\theta[\phi^*(X)]\ge\mathrm{E}_\theta[\phi(X)]$ 。

i) 当 $\theta \geq \theta^*$ 时，我们有 $X_{(1)} \geq \theta \geq \theta^*$ ，因此 $\mathrm{E}_\theta[\phi^*(X)] = 1 \geq \mathrm{E}_\theta[\phi(X)]$ 。

ii) 当 $\theta_0 < \theta < \theta^*$ 时，

$$\begin{aligned}
\mathrm{E}_\theta[\phi^*(X)] &= \int_\theta^\infty \phi^*(x)\frac{n}{\sigma}\ e^{-\frac{n}{\sigma}(t-\theta)}\ dt = \int_{\theta^*}^\infty \frac{n}{\sigma}\ e^{-\frac{n}{\sigma}(t-\theta)}\ dt \\
&= \exp\{-\frac{n}{\sigma}(\theta^*-\theta)\} = \exp\{-\frac{n}{\sigma}(\theta^*-\theta_0+\theta_0-\theta)\} \\
&= \alpha\cdot\exp\{\frac{n}{\sigma}(\theta-\theta_0)\} \\
\mathrm{E}_\theta[\phi(X)] &= \int_\theta^\infty \phi(x)\ \frac{n}{\sigma}\ e^{-\frac{n}{\sigma}(t-\theta)}\ dt \leq \int_{\theta_0}^\infty \phi(x)\ \frac{n}{\sigma}\ e^{-\frac{n}{\sigma}(t-\theta)}\ dt \\
&= e^{\frac{n}{\sigma}(\theta-\theta_0)}\int_{\theta_0}^\infty \phi(x)\frac{n}{\sigma}\cdot e^{-\frac{n}{\sigma}(t-\theta_0)}\ dt \\
&= \mathrm{E}_{\theta_0}[\phi(X)]\cdot e^{\frac{n}{\sigma}(\theta-\theta_0)} \leq \alpha\cdot e^{\frac{n}{\sigma}(\theta-\theta_0)} = \mathrm{E}_\theta[\phi^*(X)].
\end{aligned}$$

iii) 当 $\theta < \theta_0$ 时，由于 ϕ^* 在 $(\theta_0,\ \theta^*)$ 上的值为零，因此有

$$\begin{aligned}
\mathrm{E}_\theta[\phi^*(X)] &= \int_\theta^\infty \phi^*(x)\frac{n}{\sigma}\ e^{-\frac{n}{\sigma}(t-\theta)}\ dt \\
&= \int_\theta^{\theta_0} \frac{n}{\sigma}\ e^{-\frac{n}{\sigma}(t-\theta)}\ dt + \int_{\theta^*}^\infty \frac{n}{\sigma}\ e^{-\frac{n}{\sigma}(t-\theta)}\ dt \\
&= \int_\theta^{\theta_0} \frac{n}{\sigma}\ e^{-\frac{n}{\sigma}(t-\theta)}\ dt + \int_{\theta^*}^\infty \frac{n}{\sigma}\ e^{-\frac{n}{\sigma}(t-\theta_0)}\ dt\cdot e^{\frac{n}{\sigma}(\theta-\theta_0)} \\
&= \int_\theta^{\theta_0} \frac{n}{\sigma}\ e^{-\frac{n}{\sigma}(t-\theta)}\ dt + \alpha\cdot e^{\frac{n}{\sigma}(\theta-\theta_0)} \\
\mathrm{E}_\theta[\phi(X)] &= \int_\theta^\infty \phi(x)\frac{n}{\sigma}\ e^{-\frac{n}{\sigma}(t-\theta)}\ dt \\
&= \int_\theta^{\theta_0} \phi(x)\frac{n}{\sigma}\ e^{-\frac{n}{\sigma}(t-\theta)}\ dt + e^{\frac{n}{\sigma}(\theta-\theta_0)}\int_{\theta_0}^\infty \phi(x)\frac{n}{\sigma}\ e^{-\frac{n}{\sigma}(t-\theta_0)}\ dt \\
&= \int_\theta^{\theta_0} \phi(x)\frac{n}{\sigma}\ e^{-\frac{n}{\sigma}(t-\theta)}\ dt + e^{\frac{n}{\sigma}(\theta-\theta_0)}\mathrm{E}_{\theta_0}[\phi(X)] \\
&\leq \int_\theta^{\theta_0} \frac{n}{\sigma}\ e^{-\frac{n}{\sigma}(t-\theta)}\ dt + \alpha\cdot e^{\frac{n}{\sigma}(\theta-\theta_0)} = \mathrm{E}_\theta[\phi^*(X)].
\end{aligned}$$

综上所述， $\phi^*(X)$ 是假设检验问题的水平为 α 的 UMPT 。

(2) 基于本题 (1) 中的 UMPT 的形式，我们猜测本题假设检验问题的 UMPT 具有与 (1) 完全类似的形式

$$\phi^*(X) = \begin{cases} 1 & , \quad X_{(1)} < \theta_0 \text{ 或 } X_{(1)} > \theta^* \quad (\theta^* > \theta_0) \\ 0 & , \quad \text{其他}. \end{cases}$$

其中 θ^* 由 $\mathrm{E}_{\theta_0}[\phi^*(X)] = \alpha$ 决定。 因为 $T = X_{(1)}$ 的密度函数为

$$g(t) = nc\cdot\theta^{nc}t^{-(nc+1)}\ I\{t \geq \theta\}\ \sim\ PR(nc,\theta).$$

所以有

$$\mathrm{E}_{\theta_0}[\phi^*(X)] = \int_{\theta^*}^\infty nc\cdot{\theta_0}^{nc}t^{-(nc+1)}\ dt = (\theta_0/\theta^*)^{nc}.$$

由此可得 $\theta^* = \theta_0/\alpha^{\frac{1}{nc}} > \theta_0$ 。

下面我们证明 $\phi^*(x)$ 的确是假设检验问题的水平为 α 的 UMPT 。

由 θ^* 的确定过程可知 $\phi^*(x)$ 是假设检验问题的水平为 α 的检验。今设 $\phi(x)$ 是假设检验问题的任一水平为 α 的检验，即 $\mathrm{E}_{\theta_0}[\phi(X)] \le \alpha$ ，由充分性准则， $\phi(x)$ 可取为 $X_{(1)}$ 的函数。下面我们仍然分三种情况来证明：对于任意的 $\theta \ne \theta_0$ 都有 $\mathrm{E}_\theta[\phi^*(X)] \ge \mathrm{E}_\theta[\phi(X)]$ 。

i) 当 $\theta \ge \theta^*$ 时，我们有 $X_{(1)} \ge \theta \ge \theta^*$ ，因此 $\mathrm{E}_\theta[\phi^*(X)] = 1 \ge \mathrm{E}_\theta[\phi(X)]$ 。

ii) 当 $\theta_0 < \theta < \theta_*$ 时，

$$\begin{aligned}
\mathrm{E}_\theta[\phi^*(X)] &= \int_\theta^\infty \phi^*(x)g(t)\ dt = \int_{\theta^*}^\infty nc\cdot\theta^{nc}t^{-(nc+1)}\ dt \\
&= (\frac{\theta}{\theta_0})^{nc}\int_{\theta^*}^\infty nc\cdot{\theta_0}^{nc}t^{-(nc+1)}\ dt = (\frac{\theta}{\theta_0})^{nc}\cdot\alpha. \\
\mathrm{E}_\theta[\phi(X)] &= \int_\theta^\infty \phi(x)g(t)\ dt \le \int_{\theta_0}^\infty \phi(x)g(t)\ dt \\
&= (\frac{\theta}{\theta_0})^{nc}\int_{\theta_0}^\infty \phi(x)nc\cdot{\theta_0}^{nc}x^{-(nc+1)}\ dx \\
&= \mathrm{E}_{\theta_0}[\phi(X)](\frac{\theta}{\theta_0})^{nc} \le \alpha\cdot(\frac{\theta}{\theta_0})^{nc} = \mathrm{E}_\theta[\phi^*(X)].
\end{aligned}$$

iii) 当 $\theta < \theta_0$ 时，由于 ϕ^* 在 $(\theta_0,\ \theta^*)$ 上的值为零，因此有

$$\begin{aligned}
\mathrm{E}_\theta[\phi^*(X)] &= \int_\theta^\infty \phi^*(x)g(t)\ dt = \int_\theta^{\theta_0} g(t)\ dt + \int_{\theta^*}^\infty g(t)\ dt \\
&= \int_\theta^{\theta_0} g(t)\ dt + (\frac{\theta}{\theta_0})^{nc}\cdot\alpha \\
\mathrm{E}_\theta[\phi(X)] &= \int_\theta^\infty \phi(x)g(t)\ dt = \int_\theta^{\theta_0} \phi(x)g(t)\ dt + \int_{\theta_0}^\infty \phi(x)g(t)\ dt \\
&\le \int_\theta^{\theta_0} g(t)\ dt + (\frac{\theta}{\theta_0})^{nc}\int_{\theta_0}^\infty \phi(x)nc\cdot{\theta_0}^{nc}x^{-(nc+1)}\ dx \\
&= \int_\theta^{\theta_0} g(t)\ dt + \mathrm{E}_{\theta_0}[\phi(X)]\cdot(\frac{\theta}{\theta_0})^{nc} \\
&\le \int_\theta^{\theta_0} g(t)\ dt + \alpha\cdot(\frac{\theta}{\theta_0})^{nc} = \mathrm{E}_\theta[\phi^*(X)].
\end{aligned}$$

综上所述， $\phi^*(X)$ 是假设检验问题的水平为 α 的 UMPT 。 ∎

26. 某饮料厂生产的瓶装果汁重量服从正态分布，要求出厂重量的标准差 (即 σ) 在 0.02 公斤之内。今抽取 28 个样本，计算出样本方差为 0.001 公斤，问这批瓶装果汁在水平 $\alpha = 0.05$ 下是否合格？

解. 本题是要检验

$$H_0 : \sigma \le 0.02 \longleftrightarrow H_1 : \sigma > 0.02.$$

这可用 χ^2 检验。根据原书 (6.5.16) 式，检验的否定域为 $R^+ = \{x : S(x) > {\sigma_0}^2\ \chi^2(n-1, 1-\alpha)\}$ ，其中 $S(x) = \sum_{i=1}^n (x_i - \overline{x})^2$ 。对于本题，已知 $n = 28$ ， $\sigma_0 = 0.02$ ，样本方差 $= (n-1)^{-1}S(x) = 0.001$ ，由此可算得 $S(x) = 0.027$ 。而 ${\sigma_0}^2\chi^2(n-1, 1-\alpha) =$

$0.02^2\ \chi^2(27,0.95)=0.0004\cdot 40.113=0.01604<S(x)$，所以应否定原假设 $H_0:\sigma\le 0.02$，即认为这批瓶装果汁不合格。 ∎

27. 某品牌香烟尼古丁含量服从正态分布，合格品要求尼古丁平均含量不超过 17.5 毫克。今对一批产品随机抽取 8 支样品，算出其尼古丁含量的平均值为 18.6 毫克，标准差为 1.4 毫克。在水平 $\alpha=0.01$ 下，检验这批香烟是否合格。

解. 本题是要检验

$$H_0:\mu\le 17.5\ \longleftrightarrow\ H_1:\mu>17.5.$$

可用 t 检验。根据原书 (6.5.23) 式，检验的否定域为 $R^+=\{x:W(x)>t(n-1,1-\alpha)\}$，其中 $W(x)$ 由 (6.5.22) 式给出即为

$$W(x)=\sqrt{n(n-1)}\ (\overline{x}-\mu_0)/\sqrt{S(x)}.$$

对于本题， $n=8,\ \mu_0=17.5$，样本方差 $=(n-1)^{-1}\ S(x)=1.4^2$，由此可算得 $S(x)=13.72$， $W(x)=\sqrt{8\cdot 7}\ (18.6-17.5)/\sqrt{13.72}=2.2225$，而 $t(7,0.99)=2.998>W(x)$，所以没有充分理由否定原假设，即认为这批香烟合格。 ∎

28. 为了比较甲、乙两个砖厂生产砖块的平均强度，在两厂抽取样品，测得强度 (公斤) 分别为 74, 65, 72, 69 和 75, 78, 74, 76, 72。假设两厂砖块强度分别服从正态分布 $N(\mu_1,\sigma^2)$ 和 $N(\mu_2,\sigma^2)$。试检验：两厂生产砖块的平均强度是否有显著性差异 (取 $\alpha=0.05$)。

解. 分别记两厂生产的砖块强度为 X 和 Y，由直接计算可得 $\bar{x}=70$， $\bar{y}=75$。本题可用原书 (6.5.32) 式的 t 检验统计量来检验假设

$$H_0:\mu_1=\mu_2\ \longleftrightarrow\ H_1:\mu_1\ne\mu_2.$$

对于本题，$n=4$，$m=5$，$\sqrt{\sum_{i=1}^n(x_i-\overline{x})^2+\sum_{j=1}^m(y_j-\bar{y})^2}\,\big/\sqrt{n+m-2}=3.0706$，所以 $|t(x,y)|=|\frac{75-70}{3.0706}\cdot\sqrt{\frac{20}{9}}|=2.4274$，而 $t(n+m-2,1-\alpha/2)=t(7,0.975)=2.3646<|t(x,y)|$，因此应否定原假设，即认为两厂生产砖块的平均强度存在显著性差异。 ∎

29. 为了比较温度对于针织品断裂强度的影响，分别在 $70°C$ 和 $80°C$ 下对某针织品测试其断裂强度 (单位为公斤)，具体数据如下：

$70°C$ 时： 20.5, 18.8, 19.8, 20.9, 21.5, 19.5, 21.0, 21.2;

$80°C$ 时： 17.7, 20.3, 20.0, 18.8, 19.0, 20.1, 20.2, 19.1。

在正态性假设下：(1) 通过假设检验说明：可认为两组数据相应分布的方差相等；(2) 在此基础上检验：温度对于针织品断裂强度是否有显著性差异 (取 $\alpha=0.05$)。

解. 设 $70°C$ 和 $80°C$ 时，某针织品的断裂强度分别为 X 和 Y，且 $X\ \sim\ N(\mu_1,{\sigma_1}^2)$，$Y\ \sim\ N(\mu_2,{\sigma_2}^2)$。

(1) 本题相当于两样本正态总体的方差齐性检验

$$H_0:\sigma_1=\sigma_2\ \longleftrightarrow\ H_1:\sigma_1\ne\sigma_2.$$

这可用原书 (6.5.29) 式的 F 检验，本题 $m=n=8$，所以由 (6.5.29) 式可得

$$F(x,y)=\sum_{j=1}^n(y_j-\overline{y})^2/\ \sum_{i=1}^m(x_i-\overline{x})^2=0.9355.$$

近似否定域的两个临界值分别为 $F(7,7,0.025)=0.2002$ 和 $F(7,7,0.975)=4.9949$ 。显然有 $F(7,7,0.025)<F(x,y)<F(7,7,0.975)$ ，因此不否定原假设，即认为 $\sigma_1=\sigma_2$ 。

(2) 本题可用原书 (6.5.32) 式的 t 检验统计量来检验假设

$$H_0:\mu_1=\mu_2 \longleftrightarrow H_1:\mu_1\neq\mu_2.$$

直接计算可得 $\bar{x}=20.4$ ， $\bar{y}=19.4$ ， $\sqrt{\sum_{i=1}^n(x_i-\overline{x})^2+\sum_{j=1}^m(y_j-\overline{y})^2}/\sqrt{n+m-2}=0.9258$ 。由此可得 $|t(x,y)|=|\frac{19.4-20.4}{0.9258}\cdot\sqrt{\frac{64}{8+8}}|=2.1603$ ，而 $t(n+m-2,1-\alpha/2)=t(14,0.975)=2.1448<|t(x,y)|$ ，所以应该否定原假设，即认为温度对于针织品的断裂强度有显著性差异。 ∎

注. 本题 $t(n+m-2,1-\alpha/2)$ 与 $|t(x,y)|$ 相差很小，若取 $\alpha=0.01$ ，则 $t(n+m-2,1-\alpha/2)=t(14,0.995)=2.9768>|t(x,y)|=2.1603$ ，不能否定原假设。这说明，在犯第一类错误概率更小的要求下，我们没有充分理由否定原假设。 ∎

30. 为了比较 A ， B 两种同类药物副作用的大小，对服用 A 种药的 92 人进行调查，其中 7 人有不良反映；对服用 B 种药的 78 人进行调查，其中 5 人有不良反映。试检验：A ， B 两种药物副作用的大小是否有显著性差异 (取 $\alpha=0.01$) 。

解. 设 A ， B 两种药物的副作用发生率分别为 p_1 和 p_2 。本题是典型的等价性检验问题，即求解检验问题 $H_0:p_1=p_2 \longleftrightarrow H_1:p_1\neq p_2$ ，这可用原书 (6.5.36) 式进行检验

$$H_0:\delta=p_1-p_2=0 \longleftrightarrow H_1:\delta\neq 0.$$

检验的渐近正态否定域为 $R^+=\{x:|U(x_1,x_2)|>z_{1-\frac{\alpha}{2}}\}$ ， $U(x_1,x_2)$ 如 (6.5.36) 式所示，其中 $z_{1-\frac{\alpha}{2}}$ 为标准正态分布的 $1-\frac{\alpha}{2}$ 分位点。直接计算可得： $\hat{p}_1=7/92=0.0761$ ， $\hat{p}_2=5/78=0.0641$ ，而当 $\delta=0$ 时，有 $\hat{p}=\frac{7+5}{92+78}=0.0706$ 。代入 (6.5.36) 式可得

$$|U(x_1,x_2)|=|\frac{0.0761-0.0641}{0.0706\cdot 0.9294(92^{-1}+78^{-1})}|=7.7198.$$

而 $z_{0.995}=2.5758<|U(x_1,x_2)|$ ，因此应否定原假设，即认为两种药物副作用的大小有显著性差异。 ∎

31. 设 $X_1,\cdots,X_n$ 为 *i.i.d.* 样本， $X_1\sim N(\mu,\sigma^2)$, μ, σ^2 都未知。求假设检验问题 $H_0:\mu\leq\mu_0\longleftrightarrow H_1:\mu>\mu_0$ 的水平为 α 的 UMPUT 的功效函数。

解. 由原书 (6.5.24) 式可知，上述假设检验问题的水平为 α 的 UMPUT 为

$$\phi^*(W)=\begin{cases}1 & , \quad W(x)>t^*\\ 0 & , \quad W(x)<t^*\end{cases}$$

其中 $W(x)=\sqrt{n}(\bar{x}-\mu_0)/\sqrt{\sum_{i=1}^n(x_i-\bar{x})^2/(n-1)}$, $t^*=t(n-1,1-\alpha)$ 。该检验的势函数为

$$\beta_{\phi^*}(\mu,\sigma) \quad = \quad \mathrm{E}_{(\mu,\sigma)}[\phi^*(W)]=P_{(\mu,\sigma)}(W(X)>t^*)$$

$$
\begin{aligned}
&= P_{(\mu,\sigma)}\left(\frac{\sqrt{n}(\bar{X}-\mu_0)}{\sqrt{\sum_{i=1}^n (X_i-\bar{X})^2/(n-1)}} > t^*\right) \\
&= P_{(\mu,\sigma)}\left(\frac{\sqrt{n}(\bar{X}-\mu)/\sigma+\sqrt{n}(\mu-\mu_0)/\sigma}{\sqrt{\sum_{i=1}^n (X_i-\bar{X})^2/(\sigma^2(n-1))}} > t^*\right)
\end{aligned}
$$

因为 $\sqrt{n}(\bar{X}-\mu)/\sigma \sim N(0,1)$ 与 $\sum_{i=1}^n (X_i-\bar{X})^2/\sigma^2 \sim \chi^2(n-1)$ 独立，所以

$$
W^*(X) \triangleq \frac{\sqrt{n}(\overline{X}-\mu)/\sigma+\sqrt{n}(\mu-\mu_0)/\sigma}{\sqrt{\sum_{i=1}^n (X_i-\overline{X})^2/(\sigma^2(n-1))}}
$$

服从非中心 t 分布 $t(n-1,\sqrt{n}(\mu-\mu_0)/\sigma)$ ，其中非中心参数是 $\sqrt{n}(\mu-\mu_0)/\sigma$ 。因此 $\beta_{\phi^*}(\mu,\sigma)=P_{(\mu,\sigma)}(W^*(X)>t^*)$ 。 ∎

32. 设 $X_1,\cdots,X_n$ 为 *i.i.d.* 样本， $X_1 \sim N(\mu_1,1)$ ； $Y_1,\cdots,Y_m$ 为 *i.i.d.* 样本， $Y_1 \sim N(\mu_2,1)$ ，且两总体独立。求下列假设检验问题水平为 α 的 UMPUT：(i) $H_0:\mu_1\le\mu_2 \longleftrightarrow H_1:\mu_1>\mu_2$ ；(ii) $H_0:\mu_1=\mu_2 \longleftrightarrow H_1:\mu_1\ne\mu_2$ 和 (iii) $H_0:\mu_1\le c\mu_2 \longleftrightarrow H_1:\mu_1>c\mu_2$, c 为已知常数。

解. 类似于原书 (6.5.30) 式， $X=(X_1,\cdots,X_n)^T$ 和 $Y=(Y_1,\cdots,Y_m)^T$ 的联合密度函数可表示为

$$
\begin{aligned}
f(x,y;\mu_1,\mu_2) &= (\frac{1}{\sqrt{2\pi}})^n \exp\{-\frac{1}{2}\sum_{i=1}^n (x_i-\mu_1)^2\}(\frac{1}{\sqrt{2\pi}})^m \exp\{-\frac{1}{2}\sum_{j=1}^m (y_j-\mu_2)^2\} \\
&= (\frac{1}{\sqrt{2\pi}})^{n+m} \exp\{-\frac{1}{2}(\sum_{i=1}^n x_i^2+\sum_{j=1}^m y_j^2)+(n\mu_1\bar{x}+m\mu_2\bar{y})-\frac{1}{2}(n\mu_1^2+m\mu_2^2)\} \\
&= (\frac{1}{\sqrt{2\pi}})^{n+m} \exp\{\theta U(x,y)+\varphi T(x,y)-b(\theta,\varphi)-\frac{1}{2}(\sum_{i=1}^n x_i^2+\sum_{j=m}^n y_j^2)\}.
\end{aligned}
$$

其中 $\theta=mn(\mu_2-\mu_1)/(m+n)$ ， $U(x,y)=\bar{y}-\bar{x}$ ， $\varphi=(n\mu_1+m\mu_2)/(m+n)$ ， $T(x,y)=n\bar{x}+m\bar{y}$ ，易见， $f(x,y;\mu_1,\mu_2)$ 服从双参数指数族分布。

(i) 该检验等价于

$$
H_0:\theta\ge\theta_0=0 \longleftrightarrow H_1:\theta<\theta_0.
$$

取 $W(x,y)=(\bar{y}-\bar{x})\sqrt{\frac{mn}{m+n}}$ ，则 $U(x,y)$ 是 W 的严增函数 (实际上仅相差一个正的常数)，且当 $\theta=\theta_0=0$ 时， $W(X,Y)\sim N(0,1)$ 与 φ 无关。而此时， T 关于 φ 为完备充分统计量，所以 W 与 T 独立。与定理 6.5.3 类似，上述假设检验问题的 UMPUT 的否定域为 $R^+=\{W(x,y)<k\}$ 。 由 $P_{\theta_0}\{R^+\}=P_{\theta_0}\{W<k\}=\alpha$ 可得 $k=z_\alpha$ 。所以假设检验问题 (i) 的水平为 α 的 UMPUT 可表示为

$$
\phi(W)=\begin{cases} 1 & , \quad W(x,y)<z_\alpha \\ 0 & , \quad W(x,y)>z_\alpha. \end{cases}
$$

(ii) 该检验等价于

$$
H_0:\theta=\theta_0=0 \longleftrightarrow H_1:\theta\ne 0.
$$

由于 $U(x,y)=\sqrt{\frac{m+n}{mn}}W(x,y)$ ，即 $U(x,y)$ 为 $W(x,y)$ 的线性严增函数，并且 W 的分布关于 $\theta_0=0$ 对称，所以由定理 6.5.4 可知，上述假设检验问题的 UMPUT 的否定域为 $R^+=\{|W(x,y)|>k\}$ 。由 $P_{\theta_0}\{|W|>k\}=\alpha$ 可得 $k=z_{1-\alpha/2}$ 。所以假设检验问题 (ii) 的水平为 α 的 UMPUT 为

$$\phi(W)=\begin{cases}1 & , \quad |W(x,y)|>z_{1-\alpha/2}\\ 0 & , \quad |W(x,y)|<z_{1-\alpha/2}\end{cases}$$

(iii) 令 $Z_j=cY_j$ ， $j=1,\cdots,m$ ， $\mu_3=c\mu_2$ ，则 $Z_j\sim N(\mu_3,c^2)$ 。$X=(X_1,\cdots,X_n)^T$ 和 $Z=(Z_1,\cdots,Z_m)^T$ 的联合密度函数为

$$\begin{aligned}f(x,z;\mu_1,\mu_3) &= (\frac{1}{\sqrt{2\pi}})^{n+m}(\frac{1}{c^2})^{m/2}\exp\{-\frac{1}{2}(\sum_{i=1}^n x_i^2+\frac{1}{c^2}\sum_{j=1}^m z_j^2)\\ &\quad -\frac{1}{2}(n\mu_1^2+m\mu_3^2/c^2)+\theta U(x,z)+\varphi T(x,z)\}.\end{aligned}$$

其中 $\theta=mn(\mu_3-\mu_1)/(m+nc^2)$ ， $U(x,z)=\bar{z}-\bar{x}$ ， $\varphi=(nc^2\mu_1+m\mu_3)/(m+nc^2)$ ， $T(x,z)=n\bar{x}+m\bar{z}/c^2$ 。假设检验问题 (iii) 等价于

$$H_0:\theta\geq\theta_0=0 \longleftrightarrow H_1:\theta<\theta_0$$

取 $W(x,z)=(\bar{z}-\bar{x})\sqrt{\frac{1}{n}+\frac{c^2}{m}}$ ，则 U 是 W 的严增函数。且当 $\theta=\theta_0=0$ 时， $W(X,Y)\sim N(0,1)$ 与 φ 无关，而此时， T 关于 φ 为完备充分统计量，所以 W 与 T 独立。 所以由定理 6.5.3 可知，上述假设检验问题的 UMPUT 的否定域为 $R^+=\{W(x,y)<k\}$ 。由 $P_{\theta_0}\{R^+\}=P_{\theta_0}\{W<k\}=\alpha$ 可得 $k=z_\alpha$ 。 所以假设检验问题 (iii) 的水平为 α 的 UMPUT 为

$$\phi(W)=\begin{cases}1 & , \quad W(x,z)<z_\alpha\\ 0 & , \quad W(x,z)>z_\alpha\end{cases}$$

∎

33. 设 $X_1,\cdots,X_n$ 为 *i.i.d.* 样本， $X_1\sim N(\mu_1,\sigma_1^2)$ ； $Y_1,\cdots,Y_m$ 为 *i.i.d.* 样本， $Y_1\sim N(\mu_2,\sigma_2^2)$ ，且两总体独立。若 μ_1 已知但 μ_2 未知，求下列假设检验问题水平为 α 的 UMPUT ： (i) $H_0:\sigma_1\leq\sigma_2\longleftrightarrow H_1:\sigma_1>\sigma_2$ 和 (ii) $H_0:\sigma_1=\sigma_2\longleftrightarrow H_1:\sigma_1\neq\sigma_2$ 。

解. 类似于 (6.5.27) 式， $X=(X_1,\cdots,X_n)^T$ 和 $Y=(Y_1,\cdots,Y_m)^T$ 的联合密度函数可表示为

$$f(x,y)=(\frac{1}{\sqrt{2\pi}\sigma_1})^n(\frac{1}{\sqrt{2\pi}\sigma_2})^m\exp\{\theta U(y)+\varphi_1T_1(x,y)+\varphi_2T_2(y)-\frac{n\mu_1^2}{2\sigma_1^2}-\frac{m\mu_2^2}{2\sigma_2^2}\}.$$

其中 $\theta=\frac{1}{2\sigma_1^2}-\frac{1}{2\sigma_2^2}$ ， $U(y)=Q_y=\sum_{j=1}^m y_j^2$ ， $\varphi_1=-\frac{1}{2\sigma_1^2}$ ， $T_1(x,y)=Q_x+Q_y-2n\mu_1\bar{x}=\sum_{i=1}^n x_i^2+\sum_{j=1}^m y_j^2-2n\mu_1\bar{x}$ ， $\varphi_2=\frac{m\mu_2}{\sigma_2^2}$ ， $T_2(y)=\bar{y}$ 。易见， $f(x,y)$ 服从多参数指数族分布。

(i) 该检验等价于

$$H_0:\theta\geq\theta_0=0 \longleftrightarrow H_1:\theta<\theta_0.$$

由于 μ_1 已知，可取检验函数为

$$F(x,y)=\frac{\sum_{j=1}^m(y_j-\bar{y})^2/(m-1)}{\sum_{i=1}^n(x_i-\mu_1)^2/n}=\frac{(Q_y-m\bar{y}^2)/(m-1)}{(Q_x-2n\mu_1\bar{x}+n\mu_1^2)/n}=\frac{(U-mT_2^2)/(m-1)}{(T_1-U+n\mu_1^2)/n}.$$

易见， F 是 U 的严增函数，且在 $\theta=\theta_0=0$ 时， $F(X,Y)\sim F(m-1,n)$ 为连续型分布，与参数 (φ_1,φ_2) 无关。此时， (T_1,T_2) 是关于 (φ_1,φ_2) 的完备充分统计量，所以 (T_1,T_2) 与 F 独立。由定理 6.5.3 可知， 上述假设检验问题的否定域为 $R^+=\{F(x,y)<k\}$ 。由于

$$P_{\theta_0}\{R^+\}=P_{\theta_0}\{F<k\}=\alpha,$$

因此有 $k=F(m-1,n,\alpha)$ 。所以假设检验问题 (i) 的水平为 α 的 UMPUT 为

$$\phi(F)=\begin{cases}1 & , \quad F<F(m-1,n,\alpha)\\ 0 & , \quad F>F(m-1,n,\alpha)\end{cases}$$

(ii) 该检验等价于

$$H_0:\theta=\theta_0=0 \longleftrightarrow H_1:\theta\neq\theta_0.$$

由 (i) 的讨论可知, 上述假设检验问题的否定域为 $R^+=\{F>k_1$ 或 $F<k_2\}$, 其中 k_1 ， k_2 的精确值的确定较为复杂 通常取近似值 $k_1=F(m-1,n,1-\alpha/2)$, $k_2=F(m-1,n,\alpha/2)$(见原书 p.266 页的表 6.5.2) 。所以假设检验问题 (ii) 的水平为 α 的 UMPUT 为

$$\phi(F)=\begin{cases}1 & , \quad F>k_1 \text{ 或 } F<k_2\\ 0 & , \quad k_1<F<k_2\end{cases}$$

∎

34.★ 设 $X_1,\cdots,X_n$ 为 *i.i.d.* 样本， $X_1\sim N(\mu_1,\sigma_1^2)$ ； $Y_1,\cdots,Y_m$ 为 *i.i.d.* 样本， $Y_1\sim N(\mu_2,\sigma_2^2)$ ，且两总体独立。记 $\theta=\sigma_2^2/\sigma_1^2$ 。

(1) 求下列假设检验问题水平为 α 的 UMPUT ： (i) $H_0:\theta\le\theta_0\longleftrightarrow H_1:\theta>\theta_0$ 和 (ii) $H_0:\theta=\theta_0\longleftrightarrow H_1:\theta\neq\theta_0$ ；

(2) 当 $m=n$ 时, 对假设检验问题 (ii) 即 $H_0:\sigma_2^2=\theta_0\sigma_1^2\longleftrightarrow H_1:\sigma_2^2\neq\theta_0\sigma_1^2$ ，证明：其一个水平为 α 的 UMPUT 的否定域为 $R^+=\{x:\max[S_2^2/(\theta_0S_1^2),\ (\theta_0S_1^2)/S_2^2]>\frac{1-c}{c}\}$ ，其中 c 由 $\int\limits_0^c f(\nu;\ \frac{n-1}{2},\frac{n-1}{2})d\nu=\alpha/2$ 来决定， $f(\nu;p,q)$ 为 β 分布 $BE(p,q)$ 的密度函数，

$S_1^2=\sum\limits_{i=1}^n(X_i-\overline{X})^2,\ S_2^2=\sum\limits_{j=1}^m(Y_j-\overline{Y})^2$

(提示：利用 F 分布和 β 分布的关系) 。

解. (1) 今记 $\widetilde{\theta}=(\mu_1,\mu_2,\sigma_1^2,\sigma_2^2)$ ，则 $X=(X_1,\cdots,X_n)^T$ 和 $Y=(Y_1,\cdots,Y_m)^T$ 的联合密度函数可表示为

$$\begin{aligned}f(x,y;\widetilde{\theta}) &= c(x,y)\exp\{-\frac{1}{2\sigma_1^2}\sum_{i=1}^n(x_i-\mu_1)^2-\frac{1}{2\sigma_2^2}\sum_{j=1}^m(y_j-\mu_2)^2\}\\ &= c(x,y)\exp\{\Delta U+\varphi T-b(\widetilde{\theta})\}\end{aligned}$$

其中 $\Delta=\frac{1}{2\theta_0\sigma_1^2}-\frac{1}{2\sigma_2^2}$ ， $U=\sum_{j=1}^m y_j^2$ ， $\varphi=(-\frac{1}{2\sigma_1^2},\ \frac{n\mu_1}{\sigma_1^2},\ \frac{m\mu_2}{\sigma_2^2})$ ， $T=(\sum_{i=1}^n x_i^2+\frac{1}{\theta_0}\sum_{j=1}^m y_j^2,\ \bar{x},\ \bar{y})^T$ 。易见，当 $\Delta=0$ 时 $\theta=\theta_0$ ，所以假设检验问题 (i) 等价于

$$H_0:\Delta\le\Delta_0=0 \longleftrightarrow H_1:\Delta>\Delta_0.$$

这时仍然可取 F 分布为检验函数

$$F=\frac{S_2^2/(m-1)}{\theta_0 S_1^2/(n-1)}=\frac{(U-mT_3^2)/(m-1)}{\theta_0(T_1-nT_2^2-\frac{1}{\theta_0}U)/(n-1)}.$$

则 F 是 U 的严增函数。当 $\theta=\theta_0$ ，即 $\Delta=0$ ， $\theta_0=\sigma_2^2/\sigma_1^2$ 时， $F\sim F(m-1,n-1)$ ，其分布与 φ 无关，而 T 关于 φ 为完备充分统计量，所以由 Basu 定理知 F 和 T 独立。则由定理 6.5.3 可知，假设检验问题 (i) 的水平为 α 的 UMPUT 为

$$\phi_1(F)=\begin{cases}1 & , \quad F>F(m-1,n-1,1-\alpha)\\ 0 & , \quad F<F(m-1,n-1,1-\alpha)\end{cases}$$

关于假设检验问题 (ii) ，它等价于

$$H_0:\Delta=\Delta_0=0 \longleftrightarrow H_1:\Delta\neq\Delta_0$$

所以 (ii) 的水平为 α 的 UMPUT 的否定域为 $R^+=\{x:F<k_1 \text{ 或 } F>k_2\}$ ，即 假设检验问题 (ii) 的水平为 α 的 UMPUT 可表示为

$$\phi_2(F)=\begin{cases}1 & , \quad F<k_1 \text{ 或 } F>k_2\\ 0 & , \quad k_1<F<k_2\end{cases}$$

其中 k_1 ， k_2 由 $\mathrm{E}_{\Delta_0}[\phi_2(F)]=\alpha$ 和 $\mathrm{E}_{\Delta_0}[F\phi_2(F)]=\alpha\mathrm{E}_{\Delta_0}[F]$ 决定。一般还是取近似值 $k_1=F(m-1,n-1,\alpha/2)$, $k_2=F(m-1,n-1,1-\alpha/2)$ 。

(2) 在 $m=n$ 的条件下，由 (1) 中的结果可知 $F=S_2^2/(\theta_0 S_1^2)$ ，并且当 $\Delta=0$ 时， $F\sim F(n-1,n-1)$ 。这时我们亦可应用 F 分布和 β 分布的关系，取

$$W=\frac{F}{F+1}=\frac{S_2^2/\theta_0}{S_1^2+S_2^2/\theta_0}\sim BE(\frac{n-1}{2},\frac{n-1}{2}).$$

因为 W 是 F 的严增函数，所以假设检验问题 (ii) 的一个水平为 α 的 UMPUT 亦可由 W 表示为

$$\phi_3(W)=\begin{cases}1 & , \quad W<k_1 \text{ 或 } W>k_2\\ 0 & , \quad k_1<W<k_2\end{cases}$$

其中 k_1 ， k_2 由 $\mathrm{E}_{\Delta_0}[\phi_3(W)]=\alpha$ 和 $\mathrm{E}_{\Delta_0}[W\phi_3(W)]=\alpha\mathrm{E}_{\Delta_0}[W]$ 决定。这时通常也是取近似值 k_1 ， k_2 ，使之满足

$$\int_0^{k_1} f(\frac{n-1}{2},\frac{n-1}{2},z)\,dz=\alpha/2,\quad \int_{k_2}^1 f(\frac{n-1}{2},\frac{n-1}{2},z)\,dz=\alpha/2.$$

其中 $f(\frac{n-1}{2},\frac{n-1}{2},z)$ 为 $BE(\frac{n-1}{2},\frac{n-1}{2})$ 的密度函数。 由 β 分布 $BE(\frac{n-1}{2},\frac{n-1}{2})$ 的性质可知， $k_2=1-k_1$ 。令 $c=k_1$ ，则以上积分等价于

$$\int_0^c f(\frac{n-1}{2},\frac{n-1}{2},z)\,dz=\alpha/2.$$

而 $\phi_3(W)$ 的否定域可表示为

$$R^+ \quad = \quad \{x:\ W<k_1 \text{ 或 } W>k_2\}$$

$$
\begin{aligned}
&= \{x: \frac{F}{F+1} < c \text{ 或 } \frac{F}{F+1} > 1-c\} \\
&= \{x: \frac{1}{F} > \frac{1-c}{c} \text{ 或 } F > \frac{1-c}{c}\} \\
&= \{x: \max(\frac{S_2^2}{\theta_0 S_1^2}, \frac{\theta_0 S_1^2}{S_2^2}) > \frac{1-c}{c}\}.
\end{aligned}
$$

∎

35.★ 设 $X_1, \cdots, X_n$ 相互独立， $X_i \sim N(\mu_i, \sigma^2)$, $i = 1, \cdots, m$ ； $X_j \sim N(0, \sigma^2)$, $j = m+1, \cdots, n$ 。设 μ_0 已知，求下列假设检验问题水平为 α 的 UMPUT ： (i) $H_0: \mu_1 \le \mu_0 \longleftrightarrow H_1: \mu_1 > \mu_0$ 和 (ii) $H_0: \mu_1 = \mu_0 \longleftrightarrow H_1: \mu_1 \ne \mu_0$ ；并求 (ii) 的似然比检验 (提示：仿照一样本正态总体中关于 μ 的单边和双边检验的处理方法) 。

解. $X = (X_1, \cdots, X_n)^T$ 的密度函数可表示为

$$
\begin{aligned}
f(x; \mu_1, \cdots, \mu_m, \sigma^2) &= (\frac{1}{\sqrt{2\pi}\sigma})^n \exp\{-\frac{1}{2\sigma^2}\sum_{i=1}^m (x_i - \mu_i)^2 - \frac{1}{2\sigma^2}\sum_{i=m+1}^n x_i^2\} \\
&= (\frac{1}{\sqrt{2\pi}\sigma})^n \exp\{\frac{\mu_1}{\sigma^2}x_1 + \sum_{i=2}^m \frac{\mu_i}{\sigma^2}x_i - \frac{1}{2\sigma^2}\sum_{i=1}^n x_i^2 - \frac{1}{2\sigma^2}\sum_{i=1}^m \mu_i^2\} \\
&= (\frac{1}{\sqrt{2\pi}\sigma})^n \exp\{\theta U(x) + \varphi_1 T_1(x) + \sum_{i=2}^m \varphi_i T_i(x) - b(\theta, \varphi)\}
\end{aligned}
$$

其中 $\theta = \frac{\mu_1 - \mu_0}{\sigma^2}$ ， $U(x) = x_1$ ， $\varphi_1 = -\frac{1}{2\sigma^2}$ ， $T_1(x) = \sum_{i=1}^n x_i^2 - 2\mu_0 x_1$ ， $\varphi_i = \frac{\mu_i}{\sigma^2}$ ， $T_i(x) = x_i$ ， $i = 2, \cdots, m$ ， $b(\theta, \varphi) = -\frac{1}{2\sigma^2}\sum_{i=1}^m \mu_i^2$ 。易见， $f(x; \mu_1, \cdots, \mu_m, \sigma^2)$ 服从多参数指数族分布。假设检验问题 (i) 等价于

$$H_0: \theta \le \theta_0 = 0 \longleftrightarrow H_1: \theta > \theta_0.$$

上述假设检验问题 UMPUT 的否定域为 $R^+ = \{U > k(t)\}$ ，其中 $k(t)$ 由 $P_{\theta_0}(U > k(T)|T) = \alpha$ 决定。取

$$
\begin{aligned}
W(X) &= (U - \mu_0) \Big/ \sqrt{\sum_{i=m+1}^n X_i^2/(n-m)} \\
&= (U - \mu_0) \Big/ \sqrt{[T_1 - \sum_{i=2}^m T_i^2 - (U - \mu_0)^2 + \mu_0^2]/(n-m)}
\end{aligned}
$$

易见， W 是 U 的严增函数 (一般地，因 $f(z) = \frac{z}{M - z^2}$ 是 z 的严增函数， $z(x) = x - \mu_0$ 是 x 的严增函数，因此 $f(z(x))$ 是 x 的严增函数，其中 M 是一大于 z^2 的常数) 。当 $\theta = \theta_0 = 0$ ，即 $\mu_1 = \mu_0$ 时， $W \sim t(n-m)$ 与 φ 无关，而此时， $T = (T_1, \cdots, T_m)^T$ 关于 $\varphi = (\varphi_1, \cdots, \varphi_m)^T$ 是完备充分统计量，所以当 $\theta = \theta_0$ 时，由 Basu 定理可知 W 与 T 独立。由

$$P_{\theta_0}(U > k(T)|T) = P_{\theta_0}(W > c(T)|T) = P_{\theta_0}(W > c) = \alpha$$

可得 $c = t(n-m, 1-\alpha)$ 。因此假设检验问题 (i) 的水平为 α 的 UMPUT 为

$$\phi(W) = \begin{cases} 1 & , \quad W(x) > t(n-m, 1-\alpha) \\ 0 & , \quad W(x) < t(n-m, 1-\alpha) \end{cases}$$

类似地，假设检验问题 (ii) 等价于 $H_0:\theta=\theta_0=0 \longleftrightarrow H_1:\theta\neq\theta_0$ 。其否定域可由 $R^+=\{U<k_1(t)$ 或 $U>k_2(t)\}$ 化简为 $R^+=\{W<c_1$ 或 $W>c_2\}$ 。又由于当 $\theta_0=0$ 即 $\mu_1=\mu_0$ 时 $W\sim t(n-m)$ ，其分布关于原点对称，因此其否定域可进一步化简为 $R^+=\{|W(x)|>c\}$ ， c 由 $P_{\theta_0}\{|W(X)|>c\}=\alpha$ 决定，因此有 $c=t(n-m,1-\alpha/2)$ 。所以假设检验问题 (ii) 的水平为 α 的 UMPUT 为

$$\phi(W)=\begin{cases}1 & , \quad |W(x)|>t(n-m,1-\alpha/2)\\ 0 & , \quad |W(x)|<t(n-m,1-\alpha/2)\end{cases}$$

下面继续求假设检验问题 (ii) 的水平为 α 的似然比检验。

记 $\theta=(\mu_1,\cdots,\mu_m,\sigma^2)^T$ ，则样本的似然函数为

$$L(\theta)=-\frac{1}{2\sigma^2}\sum_{i=1}^{m}(x_i-\mu_i)^2-\frac{1}{2\sigma^2}\sum_{i=m+1}^{n}x_i^2-\frac{n}{2}\log\sigma^2-\frac{n}{2}\log(2\pi)$$

在 H_1 条件下，我们有

$$\hat{\mu}_i=x_i,\quad i=1,\cdots,m,\quad \hat{\sigma}^2=\frac{1}{n}\sum_{i=m+1}^{n}x_i^2,$$

在 H_0 条件下，我们有

$$\hat{\mu}_{10}=\mu_0,\quad \hat{\mu}_{i0}=x_i,\quad i=2,\cdots,m,\quad \hat{\sigma}_0^2=\frac{1}{n}[(x_1-\mu_0)^2+\sum_{i=m+1}^{n}x_i^2].$$

所以

$$\begin{aligned}LR &= 2[L(\hat{\mu}_1,\cdots,\hat{\mu}_m,\hat{\sigma}^2)-L(\hat{\mu}_{10},\cdots,\hat{\mu}_{m0},\hat{\sigma}_0^2)]=n\log(\hat{\sigma}_0^2/\hat{\sigma}^2)\\ &= n\log[1+(x_1-\mu_0)^2/\sum_{i=m+1}^{n}x_i^2]=n\log(1+W^2\cdot\frac{1}{n-m}).\end{aligned}$$

其中 $W=(x_1-\mu_0)/\sqrt{\sum_{i=m+1}^{n}x_i^2/(n-m)}$ 。易见，LR 是 W^2 的严增函数，所以似然比检验的否定域为 $R^+=\{LR>c\}=\{|W|>k\}$ 。当 H_0 成立，即 $\mu_1=\mu_0$ 时，$W\sim t(n-m)$ ，所以由 $P_{\theta_0}(|W|>k)=\alpha$ 可得 $k=t(n-m,1-\alpha/2)$ 。因此假设检验问题 (ii) 的水平为 α 的似然比检验为

$$\phi(W)=\begin{cases}1 & , \quad |W|>t(n-m,1-\alpha/2)\\ 0 & , \quad |W|<t(n-m,1-\alpha/2)\end{cases}$$

这与前面得到的水平为 α 的 UMPUT 完全一致 ∎

36. 设 $X_1,\cdots,X_n$ 为 *i.i.d.* 样本，$X_1\sim\Gamma(\frac{1}{\sigma},p)$, 即 $f(x_1;\sigma,p)=\frac{\sigma^{-p}}{\Gamma(p)}e^{-\frac{x_1}{\sigma}}x_1^{p-1}I\{x_1\geq 0\}$ ，其中 σ, p 都未知。

(1) 对于假设检验问题 $H_0:\sigma\leq\sigma_0\longleftrightarrow H_1:\sigma>\sigma_0$ ，证明：存在一个否定域为 $\{x:\sum_{i=1}^{n}x_i>g(\prod_{i=1}^{n}x_i)\}$ 的 UMPUT ，其中 g 为某一函数;

(2) 对于假设检验问题 (i) $H_0:p\leq p_0\longleftrightarrow H_1:p>p_0$ 和 (ii) $H_0:p=p_0\longleftrightarrow H_1:p\neq p_0$ ，试证： 存在否定域与 $\nu=\prod_{i=1}^{n}(X_i/\overline{X})$ 有关的 UMPUT 。

证明. (1) $X=(X_1,\cdots,X_n)^T$ 的密度函数为

$$\begin{aligned} f(x;\sigma,p) &= \frac{1}{\sigma^{np}\ \Gamma^n(p)}\exp\{-\frac{1}{\sigma}\sum_{i=1}^n x_i\}\cdot(\prod_{i=1}^n x_i)^{p-1} \\ &= h(x)\exp\{-\frac{1}{\sigma}\sum_{i=1}^n x_i+p\log(\prod_{i=1}^n x_i)\}. \end{aligned}$$

令 $\theta=-\frac{1}{\sigma}$ ， $U(x)=\sum_{i=1}^n x_i$ ， $\varphi=p$ ， $T(x)=\log(\prod_{i=1}^n x_i)$ ，则 $f(x;\sigma,p)$ 服从多参数指数族分布。假设检验问题 $H_0:\sigma\le\sigma_0\longleftrightarrow H_1:\sigma>\sigma_0$ 等价于

$$H_0:\theta\le\theta_0=-\frac{1}{\sigma_0}\ \longleftrightarrow\ H_1:\theta>\theta_0.$$

因此，由多参数指数族的检验理论可知，上述假设检验问题的 UMPUT 存在，其否定域可表示为

$$R^+=\{x:U>k(t)\}=\{x:\sum_{i=1}^n x_i>g(\prod_{i=1}^n x_i)\},$$

其中 g 为某一函数。

(2) 在 $f(x;\sigma,p)$ 中，取 $\theta=p$ ， $U(x)=\log(\prod_{i=1}^n x_i)$ ， $\varphi=-\frac{1}{\sigma}$ ， $T(x)=\sum_{i=1}^n x_i$ ，则 $f(x;\sigma,p)$ 也服从多参数指数族分布。由多参数指数族的检验理论知，假设检验问题 (i) 和 (ii) 的 UMPUT 存在。对假设检验问题 (i) ，其 UMPUT 的否定域为

$$\begin{aligned} R^+ &= \{x:\log(\prod_{i=1}^n x_i)>k(\sum_{i=1}^n x_i)\} \\ &= \{x:\sum_{i=1}^n\log x_i-n\log\bar{x}>k(\sum_{i=1}^n x_i)-n\log\frac{\sum_{i=1}^n x_i}{n}\} \\ &= \{x:\log\prod_{i=1}^n\frac{x_i}{\bar{x}}>c(\sum_{i=1}^n x_i)\}=\{x:\nu>\exp\{c(t)\}\} \end{aligned}$$

该式可由 ν 表出。

对假设检验问题 (ii) ，其 UMPUT 的否定域为

$$R^+=\{x:U<k_1(t)\ \text{或}\ U>k_2(t)\}=\{x:\nu<\exp\{c_1(t)\}\ \text{或}\ \nu>\exp\{c_2(t)\}\}$$

该式亦可由 ν 表出。 ∎

37. 设 $X_1\sim P(\lambda_1)$, $X_2\sim P(\lambda_2)$, X_1 和 X_2 独立。求假设检验问题 $H_0:\lambda_1\ge\lambda_2\longleftrightarrow H_1:\lambda_1<\lambda_2$ 的一个水平为 α 的 UMPUT.

解. X_1 和 X_2 的联合密度函数可表示为

$$\begin{aligned} f(x_1,x_2;\lambda_1,\lambda_2) &= e^{-\lambda_1}\cdot\frac{{\lambda_1}^{x_1}}{x_1!}\cdot e^{-\lambda_2}\cdot\frac{{\lambda_2}^{x_2}}{x_2!} \\ &= \frac{1}{x_1!\ x_2!}\exp\{x_1\log\lambda_1+x_2\log\lambda_2-(\lambda_1+\lambda_2)\} \\ &= \frac{1}{x_1!\ x_2!}\exp\{x_1\log\frac{\lambda_1}{\lambda_2}+(x_1+x_2)\log\lambda_2-(\lambda_1+\lambda_2)\} \\ &= \frac{1}{x_1!\ x_2!}\exp\{\theta U(x)+\varphi T(x)-(\lambda_1+\lambda_2)\} \end{aligned}$$

其中 $\theta = \log\frac{\lambda_1}{\lambda_2}$ ， $U(x) = x_1$ ， $\varphi = \log\lambda_2$ ， $T(x) = x_1 + x_2$ 。易见， $f(x_1, x_2; \lambda_1, \lambda_2)$ 服从多参数指数族分布。假设检验问题 (i) $H_0 : \lambda_1 \geq \lambda_2 \longleftrightarrow H_1 : \lambda_1 < \lambda_2$ 等价于 $H_0 : \theta \geq 0 \longleftrightarrow H_1 : \theta < 0$ ，其否定域为 $R^+ = \{x_1 < k(t)\}$ 。而在给定 $X_1 + X_2 = t$ 的条件下， X_1 的条件分布为

$$P(x_1|x_1 + x_2 = t) = \binom{t}{x_1} p^{x_1}(1-p)^{t-x_1}; \quad x_1 = 1, \cdots, t.$$

其中 $p = \frac{\lambda_1}{\lambda_1+\lambda_2} = \frac{e^\theta}{1+e^\theta}$ 为 θ 的严增函数， $\theta = 0$ 时 $p = 1/2$ 。所以假设检验问题 (i) 又可转化为关于二项分布的参数 p 的假设检验问题

$$H_0 : p \geq p_0 = 1/2 \longleftrightarrow H_1 : p < p_0.$$

所以假设检验问题 (i) 的 UMPUT 为

$$\phi(x_1) = \begin{cases} 1 & , \quad x_1 < c \\ \gamma & , \quad x_1 = c \\ 0 & , \quad x_1 > c \end{cases}$$

其中 c, γ 由以下水平条件决定

$$\mathrm{E}_{p_0}[\phi(X_1)|T] = P_{p_0}(X_1 < c|T) + \gamma P_{p_0}(X_1 = c|T) = \alpha.$$

其中 $X_1|T \sim b(T, p)$ ， $p_0 = 1/2$ 。 ∎

38. 设 $X_i \sim P(\lambda_i)$, $i = 1, 2, 3$, X_1, X_2, X_3 相互独立。对于假设检验问题 $H_0 : \lambda_1\lambda_2 \leq \lambda_3^2 \longleftrightarrow H_1 : \lambda_1\lambda_2 \geq \lambda_3^2$ ，证明：存在一个水平为 α 的 UMPUT 。

解. $X = (X_1, X_2, X_3)^T$ 的密度函数可表示为

$$\begin{aligned} f(x; \lambda_1, \lambda_2, \lambda_3) &= \frac{1}{x_1!\ x_2!\ x_3!} \exp\{\sum_{i=1}^{3} x_i \log\lambda_i - (\lambda_1 + \lambda_2 + \lambda_3)\} \\ &= h(x) \exp\{x_1 \log\frac{\lambda_1\lambda_2}{\lambda_3^2} + (x_2 - x_1)\log\lambda_2 + (x_3 + 2x_1)\log\lambda_3 - (\lambda_1 + \lambda_2 + \lambda_3)\} \\ &= h(x) \exp\{\theta U(x) + \varphi_1 T_1(x) + \varphi_2 T_2(x) - (\lambda_1 + \lambda_2 + \lambda_3)\}. \end{aligned}$$

其中 $\theta = \log\frac{\lambda_1\lambda_2}{\lambda_3^2}$ ， $U(x) = x_1$ ， $\varphi_1 = \log\lambda_2$ ， $T_1(x) = x_2 - x_1$ ， $\varphi_2 = \log\lambda_3$ ， $T_2(x) = x_3 + 2x_1$ 。易见， $f(x; \lambda_1, \lambda_2, \lambda_3)$ 服从多参数指数族分布。而假设检验问题

$$H_0 : \lambda_1\lambda_2 \leq \lambda_3^2 \longleftrightarrow H_1 : \lambda_1\lambda_2 \geq \lambda_3^2$$

等价与

$$H_0 : \theta \leq \theta_0 = 0 \longleftrightarrow H_1 : \theta > \theta_0.$$

所以由多参数指数族的检验理论可知, 上述假设检验问题存在一个水平为 α 的 UMPUT ，其具体形式为

$$\phi(x) = \begin{cases} 1 & , \quad U(x) > k(t) \\ \gamma(t) & , \quad U(x) = k(t) \\ 0 & , \quad U(x) < k(t). \end{cases}$$

其中 $k(t)$, $\gamma(t)$ 由 $\mathrm{E}_{\theta_0}[\phi(X)|T]=\alpha$ 决定。 ∎

39.* 设 $X_1,\cdots,X_n$ 为 *i.i.d.* 样本， $X_1\sim\Gamma(\frac{1}{\sigma_1},p_1)$ ， $Y_1,\cdots,Y_m$ 为 *i.i.d.* 样本， $Y_1\sim\Gamma(\frac{1}{\sigma_2},p_2)$ ，且两总体独立。

(1) 设 p_1, p_2 已知，对于假设检验问题 (i) $H_0:\sigma_1\le\sigma_2\longleftrightarrow H_1:\sigma_1>\sigma_2$ 和 (ii) $H_0:\sigma_1=\sigma_2\longleftrightarrow H_1:\sigma_1\ne\sigma_2$ ，试证：存在 UMPUT ，且其否定域可用 β 分布确定；

(2) 如果在 (1) 中，p_1, p_2 都未知, 对假设检验问题 (i) 和 (ii) , 证明：存在 UMPUT , 并描述它们的一般形式；

(3) 假设 $\sigma_1=\sigma_2$ ，但未知，对假设检验问题 (i) $H_0:p_1\le p_2\longleftrightarrow H_1:p_1>p_2$ 和 (ii) $H_0:p_1=p_2\longleftrightarrow H_1:p_1\ne p_2$ ，证明：存在 UMPUT ，并描述它们的一般形式。

证明. (1) $X=(X_1,\cdots,X_n)^T$ 和 $Y=(Y_1,\cdots,Y_m)^T$ 的联合密度函数可表示为

$$\begin{aligned}
f(x,y;\sigma_1,\sigma_2) &= \prod_{i=1}^n\left[\frac{1}{\sigma_1^{p_1}\Gamma(p_1)}\ e^{-\frac{x_i}{\sigma_1}}\ x_i^{p_1-1}\right]\cdot\prod_{j=1}^m\left[\frac{1}{\sigma_2^{p_2}\Gamma(p_2)}\ e^{-\frac{y_j}{\sigma_2}}\ y_j^{p_2-1}\right]\\
&= h(x,y)\exp\{-\frac{1}{\sigma_1}\sum_{i=1}^n x_i-\frac{1}{\sigma_2}\sum_{j=1}^m y_j-np_1\log\sigma_1-mp_2\log\sigma_2\}\\
&= h(x,y)\exp\{(\frac{1}{\sigma_2}-\frac{1}{\sigma_1})\sum_{i=1}^n x_i-\frac{1}{\sigma_2}(\sum_{i=1}^n x_i+\sum_{j=1}^m y_j)-np_1\log\sigma_1-mp_2\log\sigma_2\}\\
&= h(x,y)\exp\{\theta U(x,y)+\varphi T(x,y)-np_1\log\sigma_1-mp_2\log\sigma_2\}.
\end{aligned}$$

其中 $\theta=\frac{1}{\sigma_2}-\frac{1}{\sigma_1}$ ， $U(x,y)=\sum_{i=1}^n x_i$ ， $\varphi=-\frac{1}{\sigma_2}$ ， $T(x,y)=\sum_{i=1}^n x_i+\sum_{j=1}^m y_j$ 。易见， $f(x,y;\sigma_1,\sigma_2)$ 服从多参数指数族分布，因此假设检验问题 (i) 等价于

$$\text{(i)}'\quad H_0:\theta\le\theta_0=0\ \longleftrightarrow\ H_1:\theta>\theta_0.$$

当 $\theta=\theta_0$ ，即 $\sigma_1=\sigma_2$ 时，

$$W\triangleq U/T=\sum_{i=1}^n X_i/(\sum_{i=1}^n X_i+\sum_{j=1}^m Y_j)\sim BE(np_1,mp_2)$$

与 φ 无关，并且为 U 的严增函数，而此时 T 为关于 φ 的完备充分统计量，所以由 Basu 定理知，当 $\theta=\theta_0$ 时 W 和 T 独立。因此，由定理 6.5.3 可知，假设检验问题 (i)$'$ ，即假设检验问题 (i) 的 UMPUT 为

$$\phi(W)=\begin{cases}1 & , \quad W>c\\ 0 & , \quad W<c\end{cases}$$

其中 c 由 $\mathrm{E}_{\theta_0}[\phi(W)]=P_{\theta_0}(W>c)=\alpha$ 决定。

同理，假设检验问题 (ii) 等价于

$$H_0:\theta=\theta_0=0\ \longleftrightarrow\ H_1:\theta\ne\theta_0.$$

并且 W 为 U 的严增函数，所以由定理 6.5.4 可知，假设检验问题 (ii) 的一个水平为 α 的 UMPUT 为

$$\phi'(W)=\begin{cases}1 & , \quad W<c_1\ \text{或}\ W>c_2\\ 0 & , \quad c_1<W<c_2.\end{cases}$$

其中 c_1 ， c_2 由 $\mathrm{E}_{\theta_0}[\phi'(W)]=\alpha$ 和 $\mathrm{E}_{\theta_0}[W\phi'(W)]=\alpha\mathrm{E}_{\theta_0}[W]$ 共同决定。

(2) 记 $\tilde{\theta}=(\sigma_1,\sigma_2,p_1,p_2)$ ，则 X 和 Y 的联合密度函数可表示为

$$\begin{aligned}
f(x,y;\tilde{\theta}) &= c(x,y)\exp\{(\frac{1}{\sigma_2}-\frac{1}{\sigma_1})\sum_{i=1}^n x_i-\frac{1}{\sigma_2}(\sum_{i=1}^n x_i+\sum_{j=1}^m y_j)\\
&\quad +p_1\log\prod_{i=1}^n x_i+p_2\log\prod_{j=1}^m y_j-b(\tilde{\theta})\}\\
&= c(x,y)\exp\{\theta U(x,y)+\varphi_1T_1(x,y)+\varphi_2T_2(x,y)+\varphi_3T_3(x,y)-b(\tilde{\theta}).\}
\end{aligned}$$

其中 $\theta=\frac{1}{\sigma_2}-\frac{1}{\sigma_1}$ ， $U(x,y)=\sum_{i=1}^n x_i$ ， $\varphi_1=-\frac{1}{\sigma_2}$ ， $T_1(x,y)=\sum_{i=1}^n x_i+\sum_{j=1}^m y_j$ ， $\varphi_2=p_1$ ， $T_2(x,y)=\log\prod_{i=1}^n x_i=\sum_{i=1}^n\log x_i$ ， $\varphi_3=p_2$ ， $T_3(x,y)=\log\prod_{j=1}^m y_j=\sum_{j=1}^m\log y_j$ 。易见， $f(x,y;\tilde{\theta})$ 服从多参数指数族分布，因此假设检验问题 (i) 等价于

$$H_0:\theta\le\theta_0=0\ \longleftrightarrow\ H_1:\theta>\theta_0.$$

由多参数指数族的检验理论可知，假设检验问题 (i) 的水平为 α 的 UMPUT 为

$$\phi(U,T)=\begin{cases}1 & ,\ U(x,y)>k(t)\\ \gamma(t) & ,\ U(x,y)=k(t)\\ 0 & ,\ U(x,y)<k(t)\end{cases}$$

其中 $k(t),\gamma(t)$ 由 $\mathrm{E}_{\theta_0}[\phi(U,T)|T]=\alpha$ 决定。

同理，假设检验问题 (ii) 的水平为 α 的 UMPUT 为

$$\phi'(U,T)=\begin{cases}1 & ,\ U(x,y)<k_1(t)\text{ 或 }U(x,y)>k_2(t)\\ \gamma_i(t) & ,\ U(x,y)=k_i(t),\ i=1,2\\ 0 & ,\ k_1(t)<U(x,y)<k_2(t).\end{cases}$$

其中 $k_i(t),\ \gamma_i(t),\ i=1,2$ 由 $\mathrm{E}_{\theta_0}[\phi'(U,T)|T]=\alpha$ 和 $\mathrm{E}_{\theta_0}[U\phi'(U,T)|T]=\alpha\mathrm{E}_{\theta_0}[U|T]$ 决定。

(3) 记 $\tilde{\theta}=(\sigma_1,p_1,p_2)$ ，则 X 和 Y 的联合密度函数可表示为

$$\begin{aligned}
f(x,y;\tilde{\theta}) &= c(x,y)\exp\{-\frac{1}{\sigma_1}(\sum_{i=1}^n x_i+\sum_{j=1}^m y_j)+p_1\log\prod_{i=1}^n x_i+p_2\log\prod_{j=1}^m y_j-b(\tilde{\theta})\}\\
&= c(x,y)\exp\{(p_1-p_2)\log\prod_{i=1}^n x_i+p_2(\log\prod_{i=1}^n x_i+\log\prod_{j=1}^m y_j)\\
&\quad -\frac{1}{\sigma_1}(\sum_{i=1}^n x_i+\sum_{j=1}^m y_j)-b(\tilde{\theta})\}\\
&= c(x,y)\exp\{\theta U(x,y)+\varphi_1T_1(x,y)+\varphi_2T_2(x,y)-b(\tilde{\theta})\}
\end{aligned}$$

其中 $\theta=p_1-p_2$ ， $U(x,y)=\log\prod_{i=1}^n x_i$ ， $\varphi_1=p_2$ ， $T_1(x,y)=\log\prod_{i=1}^n x_i+\log\prod_{j=1}^m y_j$ ， $\varphi_2=-\frac{1}{\sigma_1}$ ， $T_2(x,y)=\sum_{i=1}^n x_i+\sum_{j=1}^m y_j$ 。易见， $f(x,y;\tilde{\theta})$ 服从多参数指数族分布，因此假设检验问题 (i) 等价于

$$H_0:\theta\le\theta_0=0\ \longleftrightarrow\ H_1:\theta>\theta_0$$

由多参数指数族的检验理论知，假设检验问题 (i) 的水平为 α 的 UMPUT 为

$$\phi(U,T)=\begin{cases}1 & , \quad U(x,y)>k(t)\\ \gamma(t) & , \quad U(x,y)=k(t)\\ 0 & , \quad U(x,y)<k(t)\end{cases}$$

其中 $k(t)$, $\gamma(t)$ 由 $\mathrm{E}_{\theta_0}[\phi(U,T)|T]=\alpha$ 决定。

同理，假设检验问题 (ii) 的水平为 α 的 UMPUT 为

$$\phi'(U,T)=\begin{cases}1 & , \quad U(x,y)<k_1(t) \text{ 或 } U(x,y)>k_2(t)\\ \gamma_i(t) & , \quad U(x,y)=k_i(t),\ i=1,2\\ 0 & , \quad k_1(t)<U(x,y)<k_2(t)\end{cases}$$

其中 $k_i(t)$, $\gamma_i(t)$, $i=1,2$ 由 $\mathrm{E}_{\theta_0}[\phi'(U,T)|T]=\alpha$ 和 $\mathrm{E}_{\theta_0}[U\phi'(U,T)|T]=\alpha\mathrm{E}_{\theta_0}[U|T]$ 决定。 ▮

40. 设 $X_1,\cdots,X_n$ 为 *i.i.d.* 样本， $X_1\sim\mu+\Gamma(\frac{1}{\sigma},1)$ 。求以下假设检验问题水平为 α 的似然比检验：

(1) 当 $\mu=0$ 时， $H_0:\sigma=\sigma_0\longleftrightarrow H_1:\sigma\neq\sigma_0$ ；

(2) 当 μ 未知时， $H_0:\sigma=\sigma_0\longleftrightarrow H_1:\sigma\neq\sigma_0$ ；

(3) 当 σ 已知时， $H_0:\mu=\mu_0\longleftrightarrow H_1:\mu\neq\mu_0$ ；

(4) 当 σ 未知时,； $H_0:\mu=\mu_0\longleftrightarrow H_1:\mu\neq\mu_0$ 。

解. (1) 样本的密度函数和对数似然函数分别为

$$f(x;\sigma)=\frac{1}{\sigma^n}\exp\{-\frac{1}{\sigma}\sum_{i=1}^n x_i\},\qquad L(\sigma)=-n\log\sigma-\frac{1}{\sigma}\sum_{i=1}^n x_i.$$

在 H_1 成立的条件下， σ 的极大似然估计为 $\hat\sigma=\bar X$ ，所以 $L(\hat\sigma)=-n\log\bar x-n$ ；在 H_0 成立的条件下， σ 的极大似然估计为 $\hat\sigma_0=\sigma_0$ ，所以 $L(\hat\sigma_0)=-n\log\sigma_0-\frac{1}{\sigma_0}\sum_{i=1}^n x_i$ 。因此

$$\begin{aligned}LR(\sigma_0) &= 2[L(\hat\sigma)-L(\hat\sigma_0)]=2[-n\log\bar x-n+n\log\sigma_0+\frac{1}{\sigma_0}\sum_{i=1}^n x_i]\\ &= -2n\log(\sum_{i=1}^n x_i/\sigma_0)+2\sum_{i=1}^n x_i/\sigma_0-2n+2n\log n\\ &= -2n\log T(x)+2T(x)-2n+2n\log n.\end{aligned}$$

其中 $T(x)=\sum_{i=1}^n x_i/\sigma_0$ ，且当 H_0 成立时，

$$2T(X)=2\sum_{i=1}^n X_i/\sigma_0\ \sim\ \Gamma(1/2,n)\sim\chi^2(2n).$$

令

$$g(T)=LR(\sigma_0)=-2n\log T+2T-2n+2n\log n,$$

则 $g''(T)=2n/T^2>0$ ，所以 $g(T)$ 是凸函数。因此假设检验问题的否定域为

$$R^+=\{LR(\sigma_0)>c\}=\{T<k_1 \text{ 或 } T>k_2\}.$$

其中 $g(k_1)=g(k_2)=c$ 。从而假设检验问题的水平为 α 的似然比检验为

$$\phi(T)=\begin{cases}1 & , \quad T<k_1 \text{ 或 } T>k_2\\ 0 & , \quad k_1<T<k_2\end{cases}$$

其中 k_1 ， k_2 由 $\mathrm{E}_{\sigma_0}[\phi(T)]=\alpha$ 和 $g(k_1)=g(k_2)$ 决定，这等价于 $\int_{2k_1}^{2k_2}\chi^2(2n,x)\,dx=1-\alpha$ 和 $(k_1/k_2)^n=e^{k_1}/e^{k_2}$ ，其中 $\chi^2(2n,x)$ 表示自由度为 $2n$ 的 χ^2 分布的密度函数。但通常可取 $k_1=\frac{1}{2}\chi^2(2n,\alpha/2)$ ， $k_2=\frac{1}{2}\chi^2(2n,1-\alpha/2)$ 。

(2) 样本的密度函数为

$$f(x;\mu,\sigma)=\frac{1}{\sigma^n}\exp\{-\frac{1}{\sigma}\sum_{i=1}^n(x_i-\mu)\}\ I\{x_{(1)}\geq\mu\}$$

在 H_1 成立的条件下, μ 和 σ 的极大似然估计分别为 $\hat{\mu}_1=X_{(1)}$, $\hat{\sigma}_1=\frac{1}{n}\sum_{i=1}^n(X_i-X_{(1)})$; 在 H_0 成立的条件下， μ 和 σ 的极大似然估计分别为 $\hat{\mu}_0=X_{(1)}$ ， $\hat{\sigma}_0=\sigma_0$ 。所以

$$\begin{aligned}\Lambda(x) &= \frac{f(x;\hat{\mu}_1,\hat{\sigma}_1)}{f(x;\hat{\mu}_0,\hat{\sigma}_0)}=\frac{\hat{\sigma}_1^{-n}\ e^{-n}\ I\{x_{(1)}\geq\hat{\mu}_1\}}{\sigma_0^{-n}\exp\{-\frac{1}{\sigma_0}\sum_{i=1}^n(x_i-x_{(1)})\}\ I\{x_{(1)}\geq\hat{\mu}_0\}}\\ &= e^{-n}\cdot n^n\cdot(\sum_{i=1}^n(x_i-x_{(1)})/\sigma_0)^{-n}\cdot\exp\{\frac{1}{\sigma_0}\sum_{i=1}^n(x_i-x_{(1)})\}\end{aligned}$$

由此可得

$$\begin{aligned}LR &= 2\log\Lambda(x)=-2n\log(\sum_{i=1}^n(x_i-x_{(1)})/\sigma_0)+\frac{2}{\sigma_0}\sum_{i=1}^n(x_i-x_{(1)})-2n+2n\log n\\ &= -2n\log T(x)+2T(x)-2n+2n\log n\end{aligned}$$

其中 $T(x)=\sum_{i=1}^n(x_i-x_{(1)})/\sigma_0$ 。可以看出，此处 LR 的公式与 (1) 十分类似，只是当 H_0 成立时， $T(x)$ 的分布略有不同，这时

$$2T(X)=2\sum_{i=1}^n(X_i-X_{(1)})/\sigma_0\sim\Gamma(1/2,n-1)\sim\chi^2(2n-2).$$

由此根据与 (1) 类似的讨论可知，假设检验问题的水平为 α 的似然比检验为

$$\phi(T)=\begin{cases}1 & , \quad T<k_1 \text{ 或 } T>k_2\\ 0 & , \quad k_1<T<k_2\end{cases}$$

其中 k_1 ， k_2 由 $\mathrm{E}_{\sigma_0}[\phi(T)]=\alpha$ 和 $g(k_1)=g(k_2)$ 决定, 这等价于 $\int_{2k_1}^{2k_2}\chi^2(2n-2,x)\,dx=1-\alpha$ 和 $(k_1/k_2)^n=e^{k_1}/e^{k_2}$ ，其中 $\chi^2(2n-2,x)$ 表示自由度为 $2n-2$ 的 χ^2 分布的密度函数。但通常可取 $k_1=\frac{1}{2}\chi^2(2n-2,\alpha/2)$ ， $k_2=\frac{1}{2}\chi^2(2n-2,1-\alpha/2)$ 。

(3) 样本的密度函数为

$$f(x;\mu)=\frac{1}{\sigma^n}\exp\{-\frac{1}{\sigma}\sum_{i=1}^n(x_i-\mu)\}\ I\{x_{(1)}\geq\mu\}.$$

在 H_1 成立的条件下， μ 的极大似然估计为 $\hat{\mu}=X_{(1)}$ ；在 H_0 成立的条件下， μ 的极大似然估计为 $\hat{\mu}_0=\mu_0$ ，所以

$$\begin{aligned}\Lambda(x) &= \frac{f(x;\hat{\mu})}{f(x;\hat{\mu}_0)}=\frac{\sigma^{-n}\exp\{-\frac{1}{\sigma}\sum_{i=1}^n(x_i-x_{(1)})\}\ I\{x_{(1)}\geq x_{(1)}\}}{\sigma^{-n}\exp\{-\frac{1}{\sigma}\sum_{i=1}^n(x_i-\mu_0)\}\ I\{x_{(1)}\geq \mu_0\}}\\ &= \begin{cases}\exp\{\frac{n}{\sigma}(x_{(1)}-\mu_0)\} & , \quad x_{(1)}\geq\mu_0\\ +\infty & , \quad x_{(1)}<\mu_0.\end{cases}\end{aligned}$$

由此可知似然比检验的否定域为

$$\begin{aligned}R^+ &= \{x:\Lambda(x)>c\}=\{x:x_{(1)}<\mu_0\}\cup\{x:\exp\{\frac{n}{\sigma}(x_{(1)}-\mu_0)\}>c,\ \text{且}\ x_{(1)}\geq\mu_0\}\\ &= \{x:x_{(1)}<\mu_0\}\cup\{x:\frac{2n}{\sigma}(x_{(1)}-\mu_0)>2\log c\triangleq k\}.\end{aligned}$$

当 H_0 成立时， $\frac{2n}{\sigma}(X_{(1)}-\mu_0)\ \sim\ \chi^2(2)$ ，所以由 $\mathrm{E}_{\mu_0}[\phi(X)]=\alpha$ 可得 $k=\chi^2(2,1-\alpha)$ 。因此假设检验问题的水平为 α 的似然比检验为

$$\phi(x)=\begin{cases}1 & , \quad x_{(1)}<\mu_0\ \text{或}\ x_{(1)}>\mu_0+\frac{\sigma}{2n}\chi^2(2,1-\alpha)\\ 0 & , \quad \text{其他}.\end{cases}$$

本题的似然比检验与本章习题 25 (1) 中的 UMPT 基本一致。

(4) 样本的密度函数为

$$f(x;\mu,\sigma)=\frac{1}{\sigma^n}\exp\{-\frac{1}{\sigma}\sum_{i=1}^n(x_i-\mu)\}\ I\{x_{(1)}\geq\mu\}.$$

在 H_1 成立的条件下, μ 和 σ 的极大似然估计分别为 $\hat{\mu}_1=X_{(1)}$, $\hat{\sigma}_1=\frac{1}{n}\sum_{i=1}^n(X_i-X_{(1)})$ ；在 H_0 成立的条件下， μ 和 σ 的极大似然估计分别为 $\hat{\mu}_0=\mu_0$ ， $\hat{\sigma}_0=\frac{1}{n}\sum_{i=1}^n(X_i-\mu_0)$ ，所以似然比为

$$\begin{aligned}\Lambda(x) &= \frac{f(x;\hat{\mu}_1,\hat{\sigma}_1)}{f(x;\hat{\mu}_0,\hat{\sigma}_0)}=\frac{\hat{\sigma}_1^{-n}\exp\{-\frac{1}{\hat{\sigma}_1}\sum_{i=1}^n(x_i-\hat{\mu}_1)\}\ I\{x_{(1)}\geq\hat{\mu}_1\}}{\hat{\sigma}_0^{-n}\exp\{-\frac{1}{\hat{\sigma}_0}\sum_{i=1}^n(x_i-\mu_0)\}\ I\{x_{(1)}\geq\mu_0\}}\\ &= \{\sum_{i=1}^n(x_i-\mu_0)/\sum_{i=1}^n(x_i-x_{(1)})\}^n\cdot\frac{1}{I\{x_{(1)}\geq\mu_0\}}\\ &= \begin{cases}\{\sum_{i=1}^n(x_i-\mu_0)/\sum_{i=1}^n(x_i-x_{(1)})\}^n & , \quad x_{(1)}\geq\mu_0\\ +\infty & , \quad x_{(1)}<\mu_0.\end{cases}\end{aligned}$$

由此可知似然比检验的否定域为

$$\begin{aligned}R^+ &= \{x:\Lambda(x)>c\}\\ &= \{x:x_{(1)}<\mu_0\}\cup\left\{x:\{\sum_{i=1}^n(x_i-\mu_0)/\sum_{i=1}^n(x_i-x_{(1)})\}^n>c,\ \text{且}\ x_{(1)}\geq\mu_0\right\}\\ &= \{x:x_{(1)}<\mu_0\}\cup\left\{x:\frac{\sum_{i=1}^n(x_i-x_{(1)})+n(x_{(1)}-\mu_0)}{\sum_{i=1}^n(x_i-x_{(1)})}>\sqrt[n]{c},\ \text{且}\ x_{(1)}\geq\mu_0\right\}\\ &= \{x:x_{(1)}<\mu_0\}\cup\{x:2n(x_{(1)}-\mu_0)/\sum_{i=1}^n(x_i-x_{(1)})>k\}\end{aligned}$$

其中 $k=2(\sqrt[n]{c}-1)\geq 0$ 。 在 H_0 成立的条件下， $X_{(1)}-\mu_0 \sim \Gamma(\frac{n}{\sigma},1)$ 与 $\sum_{i=1}^n(X_i-X_{(1)}) \sim \Gamma(\frac{1}{\sigma},n-1)$ 独立，所以

$$T=\frac{2n(X_{(1)}-\mu_0)}{2\sum_{i=1}^n(X_i-X_{(1)})}\cdot\frac{2n-2}{2}=\frac{n(n-1)(X_{(1)}-\mu_0)}{\sum_{i=1}^n(X_i-X_{(1)})} \sim F(2,2n-2).$$

由 $\mathrm{E}_{\mu_0}[\phi(X)]=\alpha$ 可得 $k=\frac{2}{n-1}F(2,2n-2,1-\alpha)$ 。所以，假设检验问题的水平为 α 的似然比检验为

$$\phi(x)=\begin{cases}1 & , \quad x_{(1)}<\mu_0 \text{ 或 } T>F(2,2n-2,1-\alpha)\\ 0 & , \quad \text{其他}.\end{cases}$$

∎

41. 设 $X_1,\cdots,X_n$ 为 *i.i.d.* 样本， X_1 服从均匀分布 $R(0,\theta)$ ， $\theta>0$ 。求假设检验问题 $H_0:\theta=\theta_0 \longleftrightarrow H_1:\theta\neq\theta_0$ 水平为 α 的似然比检验。

解. θ 的极大似然估计为 $\hat{\theta}=X_{(n)}$ ，所以

$$\begin{aligned}\Lambda(x) &= =\frac{f(x;\hat{\theta})}{f(x;\theta_0)}\\ &= \frac{(x_{(n)})^{-n}\ I\{x_{(n)}\leq x_{(n)}\}}{\theta_0^{-n}\ I\{x_{(n)}\leq\theta_0\}}=(\frac{x_{(n)}}{\theta_0})^{-n}\cdot\frac{1}{I\{x_{(n)}\leq\theta_0\}}\\ &= \begin{cases}(\frac{x_{(n)}}{\theta_0})^{-n} & , \quad x_{(n)}\leq\theta_0\\ +\infty & , \quad x_{(n)}>\theta_0\end{cases}\end{aligned}$$

由此可知似然比检验的否定域为

$$\begin{aligned}R^+=\{x:\Lambda(x)>c\} &= \{x:x_{(n)}>\theta_0\}\cup\{x:(\frac{x_{(n)}}{\theta_0})^{-n}>c\}\\ &= \{x:x_{(n)}>\theta_0\}\cup\{x:\frac{x_{(n)}}{\theta_0}<k\}.\end{aligned}$$

由于 $X_{(n)}/\theta_0\sim BE(n,1)$ ，所以 k 由 $P_{\theta_0}(R^+)=\alpha$ 决定，易得 $k=1/\alpha$ 。所以假设检验问题的水平为 α 的似然比检验为

$$\phi(x)=\begin{cases}1 & , \quad x_{(n)}>\theta_0 \text{ 或 } x_{(n)}<\theta_0\alpha^{1/n}\\ 0 & , \quad \text{其他}\end{cases}$$

这与本章 24 题中所得的 UMPT 相一致。 ∎

42. 设 $X_1,\cdots,X_n$ 为 *i.i.d.* 样本，$X_1\sim PR(\alpha,\theta)$, 即 $f(x_1;\alpha,\theta)=\alpha\theta^\alpha x_1^{-(\alpha+1)}I\{x_1\geq\theta\}$ ，其中 α,θ 都未知。求假设检验问题 $H_0:\alpha=1\longleftrightarrow H_1:\alpha\neq 1$ 的一个水平为 α 的似然比检验。

解. 样本的密度函数和对数似然函数分别为

$$\begin{aligned}f(x;\theta,\alpha) &= \alpha^n\theta^{n\alpha}(\prod_{i=1}^n x_i)^{-(\alpha+1)}\ I\{x_{(1)}\geq\theta\}\\ L(\theta,\alpha) &= n\log\alpha-\alpha\sum_{i=1}^n\log\frac{x_i}{\theta}-\log\prod_{i=1}^n x_i+\log I\{x_{(1)}\geq\theta\}.\end{aligned}$$

在 H_1 成立的条件下，θ 和 α 的极大似然估计分别为 $\hat{\theta}_1 = X_{(1)}$ ， $\hat{\alpha}_1 = n/\sum_{i=1}^n \log\frac{x_i}{\theta}$ ，
在 H_0 成立的条件下， θ 和 α 的极大似然估计分别为 $\hat{\theta}_0 = X_{(1)}$ ， $\hat{\alpha}_0 = 1$ ，所以有

$$\begin{aligned} L(\hat{\theta}_1, \hat{\alpha}_1) &= n\log n - n\log(\sum_{i=1}^n \log\frac{x_i}{x_{(1)}}) - n - \log\prod_{i=1}^n x_i \\ L(\hat{\theta}_0, \hat{\alpha}_0) &= -\sum_{i=1}^n \log\frac{x_i}{x_{(1)}} - \log\prod_{i=1}^n x_i. \end{aligned}$$

令 $T(x) = \sum_{i=1}^n \log\frac{x_i}{x_{(1)}}$ ，则似然比为

$$LR = 2[L(\hat{\theta}_1, \hat{\alpha}_1) - L(\hat{\theta}_0, \hat{\alpha}_0)] = -2n\log T + 2T - 2n + 2n\log n.$$

该式在形式上与本章第 40 题 (1),(2) 中 LR 完全一样，但 $T(X)$ 得分布要另行决定。令 $g(T) = LR = -2n\log T + 2T - 2n + 2n\log n$ ，则 $g''(T) = 2n/T^2 > 0$ ，所以 $g(T)$ 是凸函数 (见图) 。因此假设检验问题的否定域为

$$R^+ = \{LR > c\} = \{T < k_1 \text{ 或 } T > k_2\}.$$

其中 $g(k_1) = g(k_2) = c$ (见图) 。从而假设检验问题的水平为 α 的似然比检验为

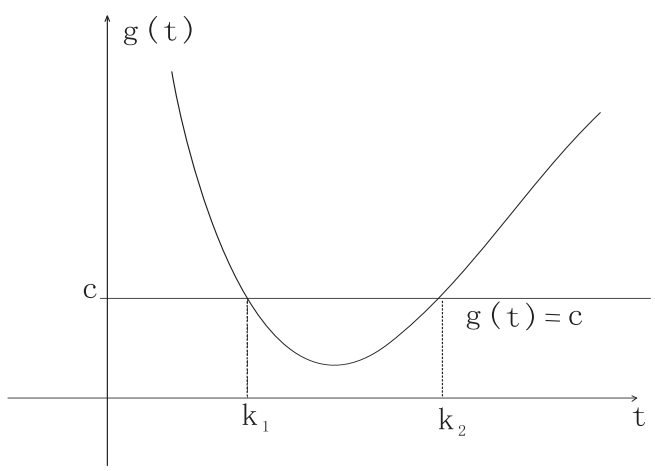

$$\phi(T) = \begin{cases} 1 & , \quad T < k_1 \text{ 或 } T > k_2 \\ 0 & , \quad k_1 < T < k_2 \end{cases}$$

为确定 $T(X)$ 的分布，令 $Y_i = \log\frac{X_i}{\theta}$ ，易得 $Y_i \sim \Gamma(\alpha, 1)$ ，所以有

$$\begin{aligned} \sum_{i=1}^n (Y_i - Y_{(1)}) &= \sum_{i=1}^n (\log\frac{X_i}{\theta} - \log\frac{X_{(1)}}{\theta}) \\ &= \sum_{i=1}^n (\log X_i - \log\theta - \log X_{(1)} + \log\theta) \\ &= \sum_{i=1}^n \log\frac{X_i}{X_{(1)}} = T(X) \sim \Gamma(\alpha, n-1). \end{aligned}$$

在 H_0 成立的条件下, 即 $\alpha=1$ 时, $T\sim\Gamma(1,n-1)$, 所以 $2T\sim\Gamma(1/2,n-1)\sim\chi^2(2n-2)$ 。因此 k_1 ， k_2 由 $\mathrm{E}_{H_0}[\phi(T)]=\alpha$ 和 $g(k_1)=g(k_2)$ 决定, 这等价于 $\int_{2k_1}^{2k_2}\chi^2(2n,x)\,dx=1-\alpha$ 和 $(k_1/k_2)^n=e^{k_1}/e^{k_2}$ ，其中 $\chi^2(2n-2,x)$ 表示自由度为 $2n-2$ 的 χ^2 分布的密度函数。但通常可取 $k_1=\frac{1}{2}\chi^2(2n-2,\alpha/2)$ ， $k_2=\frac{1}{2}\chi^2(2n-2,1-\alpha/2)$ 。 ∎

43. 设 X 是来自密度函数为 $f(x)=2\theta^{-2}(\theta-x)I\{0\le x\le\theta\}$ 的总体的一个容量为 1 的样本，其中 $\theta>0$ 未知。求假设检验问题 $H_0:\theta=\theta_0\longleftrightarrow H_1:\theta\ne\theta_0$ 的一个水平为 α 的似然比检验。

解. X 的对数似然函数为

$$L(\theta)=\log 2-2\log\theta+\log(\theta-x)+\log I\{0\le x\le\theta\}.$$

则有

$$\frac{\partial L(\theta)}{\partial\theta}=-\frac{2}{\theta}+\frac{1}{\theta-x}=0.$$

因此 θ 的极大似然估计为 $\hat\theta=2X\ (\ge X)$ ，所以似然比为

$$\begin{aligned}\Lambda(x)&=\frac{f(x;\hat\theta)}{f(x;\theta_0)}=\frac{2(2x)^{-2}(2x-x)\ I\{0\le x\le 2x\}}{2{\theta_0}^{-2}(\theta_0-x)\ I\{0\le x\le\theta_0\}}\\&=\begin{cases}\frac{{\theta_0}^2}{4x(\theta_0-x)} & ,\quad 0\le x\le\theta_0\\ +\infty & ,\quad x>\theta_0\end{cases}\end{aligned}$$

因此似然比检验的否定域为

$$\begin{aligned}R^+&=\{x:\Lambda(x)>c\}\ (c\ge 1)\\&=\{x:x>\theta_0\}\cup\{x:\frac{{\theta_0}^2}{4x(\theta_0-x)}>c,\ \text{且}\ 0\le x\le\theta_0\}\\&=\{x:x>\theta_0\}\cup\{x:4cx^2-4c\theta_0x+{\theta_0}^2>0,\ \text{且}\ 0\le x\le\theta_0\}\\&=\{x:x>\theta_0\}\cup\{x:x<\frac{\theta_0}{2}(1-\sqrt{1-1/c})\}\cup\{x:\frac{\theta_0}{2}(1+\sqrt{1-1/c})<x\le\theta_0\}\end{aligned}$$

记 $k_1=(1-\sqrt{1-1/c})/2$ ， $k_2=(1+\sqrt{1-1/c})/2$ ，则 $0<k_1\le 1/2$ ， $1/2\le k_2<1$ ，且有 $k_1+k_2=1$ 。所以否定域为

$$R^+=\{x:x>\theta_0\}\cup\{x:x<k_1\theta_0\}\cup\{x:k_2\theta_0<x\le\theta_0\}.$$

因此，假设检验问题的水平为 α 的似然比检验为

$$\phi(x)=\begin{cases}1 & ,\quad x>\theta_0\ \text{或}\ x<k_1\theta_0\ \text{或}\ k_2\theta_0<x\le\theta_0\\ 0 & ,\quad \text{其他}\end{cases}$$

其中 k_1 和 k_2 由 $\mathrm{E}_{\theta_0}[\phi(X)]=\alpha$ 决定，并满足约束条件 $k_1+k_2=1$ 。因此有

$$\mathrm{E}_{\theta_0}[\phi(X)]=\int_0^{k_1\theta_0}f(x;\theta_0)\ dx+\int_{k_2\theta_0}^{\theta_0}f(x;\theta_0)\ dx=\alpha.$$

$f(x;\theta_0)=2\theta_0^{-2}(\theta_0-x)I\{0\le x\le\theta_0\}$ 代入上式可得 $1-(1-k_1)^2+(1-k_2)^2=\alpha$ ，即 $(k_1-k_2)(k_1+k_2-2)=1-\alpha$ 。 $k_1+k_2=1$ 代入上式求解可得 $k_2=1-\alpha/2,\ k_1=\alpha/2$ 。

最后可得假设检验问题的水平为 α 的似然比检验为

$$\phi(x)=\begin{cases}1 & , \quad x>\theta_0 \text{ 或 } x<\frac{\alpha}{2}\theta_0 \text{ 或 } (1-\frac{\alpha}{2})\theta_0<x\le\theta_0\\ 0 & , \quad \text{其他}\end{cases}$$ ∎

44. 设 $X_1,X_2,\cdots,X_n$ 为相互独立的样本， $X_j\sim N(0,\sigma^2)$, $j\neq i$ ，求以下假设检验问题水平为 α 的似然比检验统计量：

(1) $X_i\sim N(\gamma,\sigma^2)$ ， $H_0:\gamma=0\longleftrightarrow H_1:\gamma\neq 0$;

(2) $X_i\sim N(0,\omega^{-1}\sigma^2)$ ， $H_0:\omega=1\longleftrightarrow H_1:\omega\neq 1$ (提示：利用 F 分布与 β 分布的关系，由 β 分布确定否定域，第 45 题的 (2) 、第 48 题和第 49 题的 (3) 也类似) 。

解. (1) 样本的密度函数和对数似然函数分别为

$$\begin{aligned}f(x;\gamma,\sigma^2) &= (\frac{1}{\sqrt{2\pi}\sigma})^n\exp\{-(\sum_{j\neq i}x_j^2+(x_i-\gamma)^2)/(2\sigma^2)\}\\ L(\gamma,\sigma^2) &= -\frac{n}{2}\log\sigma^2-\frac{1}{2\sigma^2}\{\sum_{j\neq i}x_j^2+(x_i-\gamma)^2\}-\frac{n}{2}\log(2\pi)\end{aligned}$$

由第三章习题 27 (1) 可知, 在 H_1 成立的条件下, γ 和 σ^2 的极大似然估计分别为 $\hat\gamma=X_i$, $\hat\sigma^2=\frac{1}{n}\sum_{j\neq i}X_j^2$ 。在 H_0 成立的条件下， γ 和 σ^2 的极大似然估计分别为 $\hat\gamma_0=\gamma_0=0$, $\hat\sigma_0^2=\frac{1}{n}\sum_{j=1}^n {X_j}^2$ ，所以

$$\begin{aligned}LR &= 2[L(\hat\gamma,\hat\sigma^2)-L(\hat\gamma_0,\hat\sigma_0^2)]\\ &= 2[-\frac{n}{2}\log(\frac{1}{n}\sum_{j\neq i}x_j^2)-n(\sum_{j\neq i}x_j^2+0)/(2\sum_{j\neq i}x_j^2)-\frac{n}{2}\log(2\pi)\\ &\quad +\frac{n}{2}\log(\frac{1}{n}\sum_{j=1}^n x_j^2)+n(\sum_{j\neq i}x_j^2+x_i^2)/(2\sum_{j=1}^n x_j^2)+\frac{n}{2}\log(2\pi)]\\ &= n\log(\sum_{j=1}^n x_j^2/\sum_{j\neq i}x_j^2)=n\log(1+x_i^2/\sum_{j\neq i}x_j^2)\\ &= n\log(1+\frac{1}{n-1}W^2)\end{aligned}$$

其中 $W=X_i/\sqrt{\sum_{j\neq i}X_j^2/(n-1)}$ 。易见， LR 是 $|W|$ 的严增函数，所以似然比检验的否定域为 $R^+=\{x:LR>c\}=\{x:|W|>k\}$ 。在 H_0 成立的条件下， $W\sim t(n-1)$ ，因此由 $P_{H_0}\{|W|>k\}=\alpha$ 可得 $k=t(n-1,1-\alpha/2)$ 。所以假设检验问题 (1) 的水平为 α 的似然比检验为

$$\phi(W)=\begin{cases}1 & , \quad |W|>t(n-1,1-\alpha/2)\\ 0 & , \quad |W|<t(n-1,1-\alpha/2)\end{cases}$$

注. 亦可取 $W=X_i^2/(\sum_{j\neq i}X_j^2/(n-1))\sim F(1,n-1)$ 。

(2) 样本的对数似然函数为

$$L(\omega,\sigma^2)=-\frac{n}{2}\log(2\pi)-\frac{n}{2}\log\sigma^2+\frac{1}{2}\log\omega-\sum_{j\neq i}x_j^2/(2\sigma^2)-\omega x_i^2/(2\sigma^2).$$

由第三章的习题 27 (2) 可知，在 H_1 成立的条件下， ω 和 σ^2 的极大似然估计分别为 $\hat{\omega}=\sum_{j\neq i}X_j^2/[(n-1)X_i^2]$ ， $\hat{\sigma}^2=\frac{1}{n-1}\sum_{j\neq i}X_j^2$ 。在 H_0 成立的条件下， ω 和 σ^2 的极大似然估计分别为 $\hat{\omega}_0=1$ ， $\hat{\sigma}_0^2=\frac{1}{n}\sum_{j=1}^n {X_j}^2$ 。所以

$$\begin{aligned}
LR &= 2[L(\hat{\omega},\hat{\sigma}^2)-L(\hat{\omega}_0,\hat{\sigma}_0^2)] \\
&= 2[-\frac{n}{2}\log\hat{\sigma}^2+\frac{1}{2}\log\hat{\omega}-\frac{n-1}{2}-\frac{1}{2}+\frac{n}{2}\log\hat{\sigma}_0^2-\frac{1}{2}\log 1+\frac{n}{2}] \\
&= n\log(\hat{\sigma}_0^2/\hat{\sigma}^2)+\log\hat{\omega}=n\log[\frac{n-1}{n}(1+x_i^2/\sum_{j\neq i}x_j^2)]+\log(\sum_{j\neq i}x_j^2/[(n-1)x_i^2]) \\
&= n\log\frac{n-1}{n}+n\log(1+\frac{1}{n-1}W)+\log(W^{-1}) \\
&\triangleq g(W)=n\log\frac{n-1}{n}+n\log(1+\frac{1}{n-1}W)-\log W
\end{aligned}$$

易见, 在 H_0 成立的条件下, $W=X_i^2/[\sum_{j\neq i}X_j^2/(n-1)]\sim F(1,n-1)$ 。由于 $g(W)$ 在 $W>0$ 时, 其函数性态比较复杂, 不易确定似然比检验的否定域, 因此, 我们令 $B=\frac{W}{W+(n-1)}$ ，由第一章的 β 分布定理可知 $B\sim BE(\frac{1}{2},\frac{n-1}{2})$ 。把 $W=\frac{(n-1)B}{1-B}$ 代入 $g(W)$ 可得

$$h(B)\triangleq g(W)=-(n-1)\log(1-B)-\log B+\text{常数项}.$$

对任意的 $0<B<1$ ，由于 $h''(B)=1/B^2+(n-1)/(1-B)^2>0$ ，所以 $h(B)$ 是 B 的严凸函数 (可参见本章 42 题的图) 。因此，似然比检验的否定域为 $R^+=\{x:LR>c\}=\{x:B<k_1 \text{ 或 } B>k_2\}$ 。由此可得假设检验问题 (2) 的水平为 α 的似然比检验为

$$\phi(B)=\begin{cases}1 & , \quad B<k_1 \text{ 或 } B>k_2 \\ 0 & , \quad k_1<B<k_2\end{cases}$$

其中 k_1 ， k_2 由 $\mathrm{E}_{H_0}[\phi(B)]=\alpha$ 和 $h(k_1)=h(k_2)$ 决定，这等价于

$$\int_{k_1}^{k_2}f(1/2,(n-1)/2,u)\,du=1-\alpha \quad \text{和} \quad (\frac{1-k_1}{1-k_2})^{n-1}=\frac{k_1}{k_2}.$$

其中 $f(p,q;u)$ 表示 β 分布 $BE(p,q)$ 的密度函数。 ∎

45. 设 $X_1,X_2,\cdots,X_n$ 为相互独立的样本， $X_j\sim N(0,\sigma^2),\ j\neq 1,n$ ，而 $X_1\sim N(\gamma,\sigma^2)$ ； $X_n\sim N(0,\omega^{-1}\sigma^2)$ 。求以下假设检验问题水平为 α 的似然比检验和 score 检验统计量:

(1) $H_0:\gamma=0\longleftrightarrow H_1:\gamma\neq 0$;

(2) $H_0:\omega=1\longleftrightarrow H_1:\omega\neq 1$;

(3) $H_0:\gamma=0,\ \omega=1\longleftrightarrow H_1:\gamma\neq 0,$ 或 $\omega\neq 1$ 。

解. 样本的对数似然函数为

$$L(\gamma,\omega,\sigma^2)=-\frac{n}{2}\log\sigma^2+\frac{1}{2}\log\omega-\frac{1}{2\sigma^2}\sum_{j=2}^{n-1}x_j^2-\frac{1}{2\sigma^2}(x_1-\gamma)^2-\frac{\omega}{2\sigma^2}x_n^2-\frac{n}{2}\log(2\pi). \quad (1)$$

由第三章习题 27 (3) 知，在 H_1 成立的条件下， γ,ω 和 σ^2 的极大似然估计分别为

$$\hat{\gamma}=X_1,\quad \hat{\omega}=\sum_{j=2}^{n-1}X_j^2/[(n-1)X_n^2],\quad \hat{\sigma}^2=\frac{1}{n-1}\sum_{j=2}^{n-1}X_j^2.$$

由第二章习题 27 (3) 知，样本关于 σ^2 ， γ 和 ω 的 Fisher 信息阵为

$$I(\sigma^2,\gamma,\omega)=\begin{pmatrix} \frac{n}{2\sigma^4} & 0 & -\frac{1}{2\omega\sigma^2} \\ 0 & \frac{1}{\sigma^2} & 0 \\ -\frac{1}{2\omega\sigma^2} & 0 & \frac{1}{2\omega^2}. \end{pmatrix} \tag{2}$$

并记 $I(\sigma^2,\gamma,\omega)=(I_{ij})$ ， $I^{-1}(\sigma^2,\gamma,\omega)=(I^{ij})$ ， $i,j=1,2,3$ 。

(1) 在 H_0 成立的条件下， γ,ω 和 σ^2 的极大似然估计分别为

$$\hat{\gamma}_0=0,\ \ \hat{\omega}_0=\sum_{j=1}^{n-1}X_j^2/\ [(n-1)X_n^2],\ \ \hat{\sigma}_0^2=\frac{1}{n-1}\sum_{j=1}^{n-1}X_j^2.$$

所以有

$$\begin{aligned} LR &= 2[L(\hat{\gamma},\hat{\omega},\hat{\sigma}^2)-L(\hat{\gamma}_0,\hat{\omega}_0,\hat{\sigma}_0^2)]=n\log(\hat{\sigma}_0^2/\hat{\sigma}^2)-\log(\hat{\omega}_0/\hat{\omega}) \\ &= n\log(\sum_{j=1}^{n-1}x_j^2/\sum_{j=2}^{n-1}x_j^2)-\log(\sum_{j=1}^{n-1}x_j^2/\sum_{j=2}^{n-1}x_j^2) \\ &= (n-1)\log(\sum_{j=1}^{n-1}x_j^2/\sum_{j=2}^{n-1}x_j^2)\triangleq(n-1)\log(1+\frac{T^2}{n-2}). \end{aligned}$$

其中 $T=x_1/\sqrt{\sum_{j=2}^{n-1}x_j^2/(n-2)}$ 。易知， LR 是 T^2 的严增函数，并且在 H_0 成立的条件下， $T\sim t(n-2)$ 。因此似然比检验的否定域为 $R^+=\{x:|T_1|>k\}$ ，由定解条件易得 $k=t(n-2,1-\alpha/2)$ 。由此可得假设检验问题 (1) 的似然比检验为

$$\phi(T)=\begin{cases} 1 & , \quad |T|>t(n-2,1-\alpha/2) \\ 0 & , \quad |T|<t(n-2,1-\alpha/2). \end{cases}$$

注. 也可令 $LR=(n-1)\log(1+\frac{1}{n-2}T_1)$ ，其中 $T_1=x_1^2/[\sum_{j=2}^{n-1}x_j^2/(n-2)]$ ，并且在 H_0 成立的条件下， $T_1\sim F(1,n-2)$ 。由此可得基于 F 分布的似然比检验。

为求 score 检验统计量，由 (1) 和 (2) 式经直接计算可得

$$\frac{\partial L}{\partial\gamma}=\frac{1}{\sigma^2}(x_1-\gamma),\ \ I^{22}=\sigma^2.$$

所以在 H_0 成立的条件下，假设检验问题 (1) 的 score 检验统计量为

$$SC_\gamma=\frac{1}{\sigma^2}(X_1-\gamma)^2\ |_{\hat{\theta}_0}=X_1^2/[\sum_{j=1}^{n-1}X_j^2/(n-1)]\xrightarrow{L}\chi^2(1).$$

其中 $\hat{\theta}_0=(0,\hat{\omega}_0,\hat{\sigma}_0^2)$ ，其水平为 α 的 score 检验的否定域为 $R^+=\{SC_\gamma>\chi^2(1,1-\alpha)\}$ 。所以假设检验问题 (1) 的水平为 α 的 score 检验为

$$\phi(x)=\begin{cases} 1 & , \quad SC_\gamma>\chi^2(1,1-\alpha) \\ 0 & , \quad SC_\gamma<\chi^2(1,1-\alpha). \end{cases}$$

(2) 在 H_0 成立的条件下， γ,ω 和 σ^2 的极大似然估计分别为

$$\hat{\omega}_0=1,\ \ \hat{\gamma}_0=X_1,\ \ \hat{\sigma}_0^2=\frac{1}{n}\sum_{j=2}^{n}X_j^2.$$

所以有

$$\begin{aligned}
LR &= 2[L(\hat{\gamma},\hat{\omega},\hat{\sigma}^2)-L(\hat{\gamma}_0,\hat{\omega}_0,\hat{\sigma}_0^2)] = n\log(\hat{\sigma}_0^2/\hat{\sigma}^2)+\log\hat{\omega} \\
&= n\log(\frac{n-1}{n}\sum_{j=2}^{n}x_j^2/\sum_{j=2}^{n-1}x_j^2)+\log(\sum_{j=2}^{n-1}x_j^2/[(n-1)x_n^2]) \\
&= n\log\frac{n-1}{n}+n\log(1+\frac{T}{n-2})-\log\frac{n-1}{n-2}-\log T \\
&\triangleq g(T)=n\log(1+\frac{T}{n-2})-\log T+\text{常数项}.
\end{aligned}$$

其中 $T=x_n^2/[\sum_{j=2}^{n-1}x_j^2/(n-2)]$ 。在 H_0 成立的条件下， $T\sim F(1,n-2)$ 。为了更精确地表示检验问题的否定域，可采用本章习题 44 (2) 的处理方法。令 $B=\frac{T}{T+(n-2)}$ ，则在 H_0 成立的条件下， $B\sim BE(\frac{1}{2},\frac{n-2}{2})$ 。把 $T=\frac{(n-2)B}{1-B}$ 代入 $g(T)$ 的表达式可得

$$h(B)\triangleq g(T)=-(n-1)\log(1-B)-\log B+\text{常数项}.$$

对于任意的 $0<B<1$ ，由于 $h''(B)=1/B^2+(n-1)/(1-B)^2>0$ ，所以 $h(B)$ 是 B 的严凸函数。因此假设检验问题 (2) 的似然比检验的否定域为 $R^+=\{x:LR>c\}=\{x:B<k_1$ 或 $B>k_2\}$ 。由此可得假设检验问题 (2) 的水平为 α 的似然比检验为

$$\phi(B)=\begin{cases}1 & , \quad B<k_1 \text{ 或 } B>k_2 \\ 0 & , \quad k_1<B<k_2.\end{cases}$$

其中 k_1 ， k_2 由 $\mathrm{E}_{H_0}[\phi(B)]=\alpha$ 和 $h(k_1)=h(k_2)$ 决定，这等价于

$$\int_{k_1}^{k_2}f(1/2,(n-2)/2,u)\,du=1-\alpha \quad \text{和} \quad (\frac{1-k_1}{1-k_2})^{n-1}=\frac{k_1}{k_2}.$$

其中 $f(p,q;u)$ 表示 β 分布 $BE(p,q)$ 的密度函数。

为求 score 检验统计量，由 (1) 和 (2) 式经直接计算可得

$$\frac{\partial L}{\partial\omega}=\frac{1}{2\omega}-\frac{1}{2\sigma^2}x_n^2, \quad I^{33}=\frac{2n\omega^2}{n-1}.$$

所以假设检验问题 (2) 的 score 检验统计量为

$$SC_\omega=(\frac{1}{2}-\frac{nX_n^2}{2\sum_{j=2}^{n}X_j^2})^2\cdot\frac{2n}{n-1}=\frac{n}{2(n-1)}(1-nX_n^2/\sum_{j=2}^{n}X_j^2)^2 \xrightarrow{L} \chi^2(1).$$

因此假设检验问题 (2) 的水平为 α 的 score 检验为

$$\phi(x)=\begin{cases}1 & , \quad SC_\omega>\chi^2(1,1-\alpha) \\ 0 & , \quad SC_\omega<\chi^2(1,1-\alpha).\end{cases}$$

(3) 在 H_0 成立的条件下， γ,ω 和 σ^2 的极大似然估计分别为

$$\hat{\gamma}_0=0, \quad \hat{\omega}_0=1, \quad \hat{\sigma}_0^2=\frac{1}{n}\sum_{j=1}^{n}X_j^2.$$

所以有

$$\begin{aligned} LR &= 2[L(\hat{\gamma},\hat{\omega},\hat{\sigma}^2)-L(\hat{\gamma}_0,\hat{\omega}_0,\hat{\sigma}_0^2)] = n\log(\hat{\sigma}_0^2/\hat{\sigma}^2)+\log\hat{\omega} \\ &= n\log(\frac{n-1}{n})+n\log(\sum_{j=1}^{n}x_j^2/\sum_{j=2}^{n-1}x_j^2)+\log(\sum_{j=2}^{n-1}x_j^2/[(n-1)x_n^2]) \xrightarrow{L} \chi^2(2) \end{aligned}$$

因此假设检验问题 (3) 的水平为 α 的似然比检验为

$$\phi(x)=\begin{cases} 1 & , \quad LR>\chi^2(2,1-\alpha) \\ 0 & , \quad LR<\chi^2(2,1-\alpha) \end{cases}$$

为求 score 检验统计量，由 (1) 和 (2) 式经直接计算可得

$$\begin{pmatrix} \frac{\partial L}{\partial\gamma} \\ \frac{\partial L}{\partial\omega} \end{pmatrix} = \begin{pmatrix} \frac{1}{\sigma^2}(x_1-\gamma) \\ \frac{1}{2\omega}-\frac{x_n^2}{2\sigma^2} \end{pmatrix}, \quad \begin{pmatrix} I^{22} & I^{23} \\ I^{32} & I^{33} \end{pmatrix} = \begin{pmatrix} \sigma^2 & 0 \\ 0 & 2n\omega^2/(n-1) \end{pmatrix}.$$

由于后者为对角阵，所以由 (1)， (2) 可知，假设检验问题 (3) 的 score 检验统计量为

$$SC = SC_\gamma + SC_\omega \xrightarrow{L} \chi^2(2).$$

因此假设检验问题 (3) 的水平为 α 的 score 检验为

$$\phi(x)=\begin{cases} 1 & , \quad SC>\chi^2(2,1-\alpha) \\ 0 & , \quad SC<\chi^2(2,1-\alpha). \end{cases}$$

∎

46. 设 $X_1,X_2,\cdots,X_n$ 为相互独立的样本，并考虑假设检验问题 $H_0:\gamma=1 \longleftrightarrow H_1:\gamma\neq 1$ 。在以下情形下求假设检验问题的 score 检验统计量

(1) $X_j\sim\Gamma(\lambda,1),\ j\neq i$ ，但 $X_i\sim\Gamma(\gamma\lambda,\ 1)$ ；

(2) $X_j\sim P(\lambda),\ j\neq i$ ，但 $X_i\sim P(\gamma\lambda)$ 。

解. (1) 样本的对数似然函数为

$$L(\lambda,\gamma)=n\log\lambda+\log\gamma-\lambda(\sum_{j\neq i}x_j+\gamma x_i).$$

由此可得

$$\frac{\partial L}{\partial\lambda}=n/\lambda-(\sum_{j\neq i}x_j+\gamma x_i), \quad \frac{\partial L}{\partial\gamma}=1/\gamma-\lambda x_i;$$

$$\frac{\partial^2 L}{\partial\lambda^2}=-\frac{n}{\lambda^2}, \quad \frac{\partial^2 L}{\partial\gamma^2}=-1/\gamma^2, \quad \frac{\partial^2 L}{\partial\lambda\partial\gamma}=-x_i.$$

所以 (λ,γ) 的 Fisher 信息阵 $I(\lambda,\gamma)$ 以及相应 $I^{-1}(\lambda,\gamma)$ 的分量为

$$I(\lambda,\gamma)=\begin{pmatrix} n/\lambda^2 & 1/(\lambda\gamma) \\ 1/(\lambda\gamma) & 1/\gamma^2 \end{pmatrix}; \quad I^{22}=(\frac{1}{\gamma^2}-\frac{1}{\lambda\gamma}\cdot\frac{\lambda^2}{n}\cdot\frac{1}{\lambda\gamma})^{-1}=\frac{n\gamma^2}{n-1}.$$

因此假设检验问题 (1) 的 score 检验统计量为

$$SC=\frac{n}{n-1}(1-nX_i/\sum_{j=1}^{n}X_j)^2.$$

(2) 由第二章习题 26 (1) 知，(λ,γ) 的 Fisher 信息阵 $I(\lambda,\gamma)$ 以及相应 $I^{-1}(\lambda,\gamma)$ 的分量为

$$I(\lambda,\gamma)=\begin{pmatrix}\frac{n-1+\gamma}{\lambda} & 1\\ 1 & \frac{\lambda}{\gamma}\end{pmatrix};\quad I^{22}=\frac{(n-1+\gamma)\gamma}{(n-1)\lambda}.$$

由于 $\frac{\partial L}{\partial\gamma}=-\lambda+x_i/\gamma$，而在 H_0 成立的条件下 $\hat\lambda=\bar X$，由此可得假设检验问题 (2) 的 score 检验统计量为

$$SC=(-\bar X+X_i)^2\cdot\frac{n}{(n-1)\bar X}=\frac{n}{(n-1)}\frac{(X_i-\bar X)^2}{\bar X}.$$

∎

47. 证明：在定理 6.6.2 中的 score 检验统计量 $SC'(\theta_{10})$ 可表示为

$$SC'(\theta_{10})=\left\{\dot L_p^T(\theta_1)[-\ddot L_p^{-1}(\theta_1)]\dot L_p(\theta_1)\right\}_{\theta_1=\theta_{10}}.$$

其中 $L_p(\theta_1)=L(\theta_1,\tilde\theta_2(\theta_1))$; $\dot L_p(\theta_1)$ 和 $\ddot L_p(\theta_1)$ 为 $L_p(\theta_1)$ 关于 θ_1 的前二阶导数。

证明. 根据以上符号的定义可得

$$\dot L_p(\theta_1)=\frac{\partial L_p(\theta_1)}{\partial\theta_1}=\frac{\partial L(\theta_1,\tilde\theta_2(\theta_1))}{\partial\theta_1}+\frac{\partial L(\theta_1,\tilde\theta_2(\theta_1))}{\partial\theta_2}\cdot\frac{\partial\tilde\theta_2(\theta_1)}{\partial\theta_1^T}=\frac{\partial L(\theta_1,\tilde\theta_2(\theta_1))}{\partial\theta_1}. \tag{1}$$

这是因为 $\tilde\theta_2(\theta_1)$ 是 θ_1 固定时 θ_2 的 MLE，所以上式第二项为零 (对任意的 θ_1)。上式再次对 θ_1 求导可得

$$\ddot L_p(\theta_1)=\frac{\partial^2 L(\theta_1,\tilde\theta_2(\theta_1))}{\partial\theta_1\partial\theta_1^T}+\frac{\partial L(\theta_1,\tilde\theta_2(\theta_1))}{\partial\theta_1\partial\theta_2^T}\cdot\frac{\partial\tilde\theta_2(\theta_1)}{\partial\theta_1^T}\triangleq L_{11}+L_{12}\frac{\partial\tilde\theta_2(\theta_1)}{\partial\theta_1^T} \tag{2}$$

根据 $\tilde\theta_2(\theta_1)$ 的定义我们可以求出 $\partial\tilde\theta_2(\theta_1)/\partial\theta_1^T$。事实上，由 $\partial L(\theta_1,\tilde\theta_2(\theta_1))/\partial\theta_2=0$ 对 θ_1 求导可得可得

$$0=\frac{\partial^2 L(\theta_1,\tilde\theta_2(\theta_1))}{\partial\theta_2\partial\theta_1^T}+\frac{\partial L(\theta_1,\tilde\theta_2(\theta_1))}{\partial\theta_2\partial\theta_2^T}\cdot\frac{\partial\tilde\theta_2(\theta_1)}{\partial\theta_1^T}\triangleq L_{21}+L_{22}\frac{\partial\tilde\theta_2(\theta_1)}{\partial\theta_1^T}$$

由此可得 $\partial\tilde\theta_2(\theta_1)/\partial\theta_1^T=-L_{22}^{-1}L_{21}$。该式代入 (2) 式可得

$$\ddot L_p(\theta_1)=L_{11}-L_{12}L_{22}^{-1}L_{21}=L^{11}(\theta_1,\tilde\theta_2(\theta_1)) \tag{3}$$

因此根据 (1)，(3) 两式可得

$$\left\{\dot L_p^T(\theta_1)[-\ddot L_p^{-1}(\theta_1)]\dot L_p(\theta_1)\right\}_{\theta_1=\theta_{10}}=\left\{(\frac{\partial L(\theta)}{\partial\theta_1})^T[-L^{11}(\theta)]\frac{\partial L(\theta)}{\partial\theta_1}\right\}_{\theta=(\theta_{10},\ \tilde\theta_2(\theta_{10}))}.$$

因此根据原书 (6.6.15) 式可知上式即为 $SC'(\theta_{10})$。 ∎

48. 设 $X_1,\cdots,X_n$ 为 *i.i.d.* 样本，$X_1\sim\Gamma(\frac{1}{\sigma_1},1)$；设 $Y_1,\cdots,Y_m$ 为 *i.i.d.* 样本，$Y_1\sim\Gamma(\frac{1}{\sigma_2},1)$；且两样本独立。求以下假设检验问题水平为 α 的似然比检验：$H_0:\sigma_1=\sigma_2\longleftrightarrow H_1:\sigma_1\neq\sigma_2$。

解. 令 $\theta=\sigma_1/\sigma_2$，则假设检验问题 (i) $H_0:\sigma_1=\sigma_2\longleftrightarrow H_1:\sigma_1\neq\sigma_2$ 等价于 (ii) $H_0:\theta=1\longleftrightarrow H_1:\theta\neq1$。则由

$$f(x,y;\sigma_1,\sigma_2)=\sigma_1^{-n}\sigma_2^{-m}\exp\{-\sum_{i=1}^n x_i/\sigma_1-\sum_{j=1}^m y_j/\sigma_2\}$$

可得

$$f(x,y;\theta,\sigma_2)=\theta^{-n}\sigma_2^{-(m+n)}\exp\{-\sum_{i=1}^{n}x_i/(\theta\sigma_2)-\sum_{j=1}^{m}y_j/\sigma_2\},$$

其对数似然函数为

$$L(\theta,\sigma_2)=-n\log\theta-(m+n)\log\sigma_2-\sum_{i=1}^{n}x_i/(\theta\sigma_2)-\sum_{j=1}^{m}y_j/\sigma_2.$$

求导可得

$$\begin{aligned}\frac{\partial L}{\partial\theta} &= -\frac{n}{\theta}+\frac{1}{\theta^2}\cdot\frac{1}{\sigma_2}\sum_{i=1}^{n}x_i\\ \frac{\partial L}{\partial\sigma_2} &= -\frac{m+n}{\sigma_2}+\frac{1}{\sigma_2^2}(\sum_{i=1}^{n}x_i/\theta+\sum_{j=1}^{m}y_j)\end{aligned}$$

因此在 H_1 成立的条件下，θ 和 σ_2 的极大似然估计分别为 $\hat\theta=\bar X/\bar Y$ ，$\hat\sigma_2=\bar Y$ ；而在 H_0 成立的条件下，θ 和 σ_2 的极大似然估计分别为 $\hat\theta_0=1$ ，$\hat\sigma_{20}=(\sum_{i=1}^{n}X_i+\sum_{j=1}^{m}Y_j)/(m+n)$ 。所以有

$$\begin{aligned}LR &= 2[L(\hat\theta,\hat\sigma_2)-L(\hat\theta_0,\hat\sigma_{20})]=2(m+n)\log(\hat\sigma_{20}/\hat\sigma_2)-2n\log\hat\theta\\ &= 2(m+n)\log[\frac{n\bar x+m\bar y}{(m+n)\bar y}]-2n\log\frac{\bar x}{\bar y}\\ &= 2(m+n)\log\frac{m}{m+n}+2(m+n)\log(1+\frac{n\bar x}{m\bar y})-2n\log\frac{\bar x}{\bar y}\\ &\triangleq g(T)=2(m+n)\log(1+\frac{n}{m}T)-2n\log T+c.\end{aligned}$$

其中 $T=\bar x/\bar y$ ， c 是常数。在 H_0 成立的条件下，即 $\sigma_1=\sigma_2$ 时，我们有

$$T=\bar X/\bar Y=(\sum_{i=1}^{n}X_i/n)/(\sum_{j=1}^{m}Y_j/m)=\frac{(\frac{1}{2\sigma_1}\sum_{i=1}^{n}X_i)/2n}{(\frac{1}{2\sigma_2}\sum_{j=1}^{m}Y_j)/2m}\sim F(2n,2m).$$

与本章习题 44 (2) 和习题 45 (2) 的方法类似，令 $B=\frac{T}{T+2m/2n}$ ，则在 H_0 成立的条件下， $B\sim BE(\frac{2n}{2},\frac{2m}{2})\sim BE(n,m)$ 。把 $T=2mB/[2n(1-B)]=mB/[n(1-B)]$ 代入 $g(T)$ 的表达式可得

$$\begin{aligned}h(B) &\triangleq g(T)=2(m+n)\log(1+\frac{B}{1-B})-2n\log\frac{mB}{n(1-B)}+c\\ &= 2(m+n)\log\frac{1}{1-B}-2n\log\frac{B}{1-B}+c'\\ &= -2(m+n)\log(1-B)-2n\log B+2n\log(1-B)+c'\\ &= -2n\log B-2m\log(1-B)+c'\end{aligned}$$

对于任意的 $0<B<1$ ，由于 $h''(B)=2n/B^2+2m/(1-B)^2>0$ ，所以 $h(B)$ 为凸函数。因此假设检验问题 (ii) ，即 (i) 的似然比检验的否定域为 $R^+=\{LR>k\}=\{B<k_1$ 或 $k_2<B\}$ 。由此可得假设检验问题 (i) 的水平为 α 的似然比检验为

$$\phi(B)=\begin{cases}1 & ,\quad B<k_1 \text{ 或 } B>k_2\\ 0 & ,\quad \text{其他}\end{cases}$$

其中 k_1， k_2 由 $\mathrm{E}_{H_0}[\phi(B)]=\alpha$ 和 $h(k_1)=h(k_2)$ 决定，这等价于

$$\int_{k_1}^{k_2} f(n,m,u)\ du = 1-\alpha \ \text{ 和 } \ (\frac{k_1}{k_2})^n = (\frac{1-k_2}{1-k_1})^m.$$

其中 $f(n,m;u)$ 表示 β 分布 $BE(n,m)$ 的密度函数。 ∎

49. 设 $X_1,\cdots,X_n$ 为 *i.i.d.* 样本， $X_1\sim N(\mu_1,\sigma_1^2)$ ； $Y_1,\cdots,Y_m$ 为 *i.i.d.* 样本， $Y_1\sim N(\mu_2,\sigma_2^2)$ ；且两样本独立。求以下假设检验问题水平为 α 的似然比检验：

(1) $H_0:\mu_1=\mu_2 \longleftrightarrow H_1:\mu_1\neq\mu_2$ ，但 $\sigma_1,\ \sigma_2$ 已知;

(2) $H_0:\mu_1=\mu_2 \longleftrightarrow H_1:\mu_1\neq\mu_2$ ，其中 $\sigma_1=\sigma_2=\sigma$ 未知;

(3) $H_0:\sigma_1^2=\sigma_2^2 \longleftrightarrow H_1:\sigma_1^2\neq\sigma_2^2$ ，其中 $\mu_1,\ \mu_2$ 未知。

解. (1) 样本的联合密度函数可表示为

$$L(\mu_1,\ \mu_2) = -\frac{1}{2\sigma_1^2}\sum_{i=1}^n (x_i-\mu_1)^2 - \frac{1}{2\sigma_2^2}\sum_{j=1}^m (y_j-\mu_2)^2 - h(\sigma_1^2,\sigma_2^2,x,y).$$

其中 $h(\sigma_1^2,\sigma_2^2,x,y)$ 与 μ_1 和 μ_2 无关。在 H_1 成立的条件下，易得 μ_1 和 μ_2 的极大似然估计分别为 $\hat\mu_1=\bar X$ ， $\hat\mu_2=\bar Y$ 。在 H_0 成立的条件下，记 $\mu\overset{\triangle}{=}\mu_1=\mu_2$ ，则由

$$\frac{\partial L}{\partial\mu} = \frac{1}{\sigma_1^2}(n\bar x - n\mu) + \frac{1}{\sigma_2^2}(m\bar y - m\mu) = 0.$$

可得 μ 的极大似然估计为

$$\hat\mu = \frac{1}{n\sigma_2^2+m\sigma_1^2}(n\sigma_2^2\bar X + m\sigma_1^2\bar Y).$$

由此可得 $n\sigma_2^2\bar X + m\sigma_1^2\bar Y = (n\sigma_2^2+m\sigma_1^2)\hat\mu$ 。所以有

$$\begin{aligned}
LR &= 2[\frac{1}{2\sigma_1^2}\sum_{i=1}^n (x_i-\hat\mu)^2 + \frac{1}{2\sigma_2^2}\sum_{j=1}^m (y_j-\hat\mu)^2 - \frac{1}{2\sigma_1^2}\sum_{i=1}^n (x_i-\bar x)^2 - \frac{1}{2\sigma_2^2}\sum_{j=1}^m (y_j-\bar y)^2] \\
&= \frac{1}{\sigma_1^2}n(\bar x-\hat\mu)^2 + \frac{1}{\sigma_2^2}m(\bar y-\hat\mu)^2 \\
&= \frac{1}{\sigma_1^2\sigma_2^2}[(n\sigma_2^2+m\sigma_1^2)\hat\mu^2 - 2(n\sigma_2^2\bar x + m\sigma_1^2\bar y)\hat\mu + n\sigma_2^2\bar x^2 + m\sigma_1^2\bar y^2] \\
&= \frac{1}{\sigma_1^2\sigma_2^2}(-(n\sigma_2^2+m\sigma_1^2)\hat\mu^2 + n\sigma_2^2\bar x^2 + m\sigma_1^2\bar y^2) = mn(\bar y-\bar x)^2/(n\sigma_2^2+m\sigma_1^2) \\
&= \left[(\bar y-\bar x)\Big/\sqrt{\frac{\sigma_1^2}{n}+\frac{\sigma_2^2}{m}}\right]^2 = W^2
\end{aligned}$$

其中 $W=(\bar y-\bar x)/\sqrt{\frac{\sigma_1^2}{n}+\frac{\sigma_2^2}{m}}$ 。在 H_0 成立的条件下，即 $\mu_1=\mu_2$ 时， $W\sim N(0,1)$ 。所以假设检验问题 (1) 的否定域为 $R^+=\{x:LR>c\}=\{x:W^2>c\}=\{x:|W|>k\}$ 。由定解条件易得 $k=z_{1-\alpha/2}$ 。所以假设检验问题 (1) 的水平为 α 的似然比检验为

$$\phi(W) = \begin{cases} 1 & , \quad |W|>z_{1-\alpha/2} \\ 0 & , \quad |W|<z_{1-\alpha/2} \end{cases}$$

(2) 样本的联合密度函数为

$$f(x,y;\mu_1,\mu_2,\sigma^2)=(\frac{1}{\sqrt{2\pi}})^{n+m}(\sigma^2)^{-\frac{n+m}{2}}\exp\{-\frac{1}{2\sigma^2}[\sum_{i=1}^{n}(x_i-\mu_1)^2+\sum_{j=1}^{m}(y_j-\mu_2)^2]\}$$

其对数似然函数为

$$L(\mu_1,\mu_2,\sigma^2)=-\frac{1}{2\sigma^2}[\sum_{i=1}^{n}(x_i-\mu_1)^2+\sum_{j=1}^{m}(y_j-\mu_2)^2]-\frac{n+m}{2}\log\sigma^2-\frac{n+m}{2}\log(2\pi)$$

在 H_1 成立的条件下，易得 μ_1, μ_2 和 σ^2 的极大似然估计分别为

$$\hat{\mu}_1=\bar{X},\quad \hat{\mu}_2=\bar{Y},\quad \hat{\sigma}^2=\frac{1}{m+n}\left[\sum_{i=1}^{n}(X_i-\bar{X})^2+\sum_{j=1}^{m}(Y_j-\bar{Y})^2\right].$$

在 H_0 成立的条件下，记 $\mu\triangleq\mu_1=\mu_2$，则 μ 和 σ^2 的极大似然估计分别为

$$\hat{\mu}=\frac{n\bar{X}+m\bar{Y}}{m+n},\quad \hat{\sigma}_0^2=\frac{1}{m+n}(\sum_{i=1}^{n}(X_i-\hat{\mu})^2+\sum_{j=1}^{m}(Y_j-\hat{\mu})^2).$$

所以有

$$\begin{aligned}
LR &= 2[L(\hat{\mu}_1,\hat{\mu}_2,\hat{\sigma}^2)-L(\hat{\mu},\hat{\mu},\hat{\sigma}_0^2)]\\
&= 2[-\frac{m+n}{2}-\frac{m+n}{2}\log\hat{\sigma}^2+\frac{m+n}{2}+\frac{m+n}{2}\log\hat{\sigma}_0^2]\\
&= (m+n)\log(\hat{\sigma}_0^2/\hat{\sigma}^2)\\
&= (m+n)\log\left\{[\sum_{i=1}^{n}(x_i-\hat{\mu})^2+\sum_{j=1}^{m}(y_j-\hat{\mu})^2]\Big/[\sum_{i=1}^{n}(x_i-\bar{x})^2+\sum_{j=1}^{m}(y_j-\bar{y})^2]\right\}.
\end{aligned}$$

由于

$$\begin{aligned}
\sum_{i=1}^{n}(x_i-\hat{\mu})^2 &= \sum_{i=1}^{n}(x_i-\bar{x}+\bar{x}-\hat{\mu})^2=\sum_{i=1}^{n}(x_i-\bar{x})^2+n(\bar{x}-\hat{\mu})^2\\
\sum_{j=1}^{m}(y_j-\hat{\mu})^2, &= \sum_{j=1}^{m}(y_j-\bar{y})^2+m(\bar{y}-\hat{\mu})^2.
\end{aligned}$$

并且有

$$n(\bar{x}-\hat{\mu})^2+m(\bar{y}-\hat{\mu})^2=\frac{n(m\bar{x}-m\bar{y})^2}{(m+n)^2}+\frac{m(n\bar{y}-n\bar{x})^2}{(m+n)^2}=\frac{mn}{m+n}(\bar{y}-\bar{x})^2.$$

所以若记

$$W=\sqrt{\frac{mn}{m+n}}(\bar{y}-\bar{x})\Big/\sqrt{[\sum_{i=1}^{n}(x_i-\bar{x})^2+\sum_{j=1}^{m}(y_j-\bar{y})^2]/(m+n-2)}\ ,$$

则有

$$LR=(m+n)\log[1+W^2/(m+n-2)].$$

易见，似然比 LR 是 W^2 的严增函数，并且在 H_0 成立的条件下，即 $\mu_1=\mu_2$ 时，我们有 $W \sim t(n+m-2)$ 。所以假设检验问题 (2) 的似然比检验的否定域为 $R^+=\{x: LR>c\}=\{x:|W|>c\}$ 。由定解条件可得 $c=t(n+m-2,1-\alpha/2)$ 。所以假设检验问题 (2) 的水平为 α 的似然比检验为

$$\phi(W)=\begin{cases} 1 & , \quad |W|>t(n+m-2,1-\alpha/2) \\ 0 & , \quad |W|<t(n+m-2,1-\alpha/2) \end{cases}$$

(3) 对数似然函数为

$$L(\mu_1,\mu_2,\sigma_1^2,\sigma_2^2)=-\frac{1}{2\sigma_1^2}\sum_{i=1}^n(x_i-\mu_1)^2-\frac{1}{2\sigma_2^2}\sum_{j=1}^m(y_j-\mu_2)^2-\frac{n}{2}\log\sigma_1^2-\frac{m}{2}\log\sigma_2^2-\frac{n+m}{2}\log(2\pi)$$

在 H_1 成立的条件下， μ_1, μ_2, σ_1^2 和 σ_2^2 的极大似然估计分别为

$$\hat{\mu}_1=\bar{X},\ \hat{\mu}_2=\bar{Y},\ \hat{\sigma}_1^2=\frac{1}{n}\sum_{i=1}^n(X_i-\bar{X})^2,\ \hat{\sigma}_2^2=\frac{1}{m}\sum_{j=1}^m(Y_j-\bar{Y})^2.$$

在 H_0 成立的条件下，记 $\sigma^2\triangleq\sigma_1^2=\sigma_2^2$ ，则 μ_1, μ_2 和 σ^2 的极大似然估计分别为

$$\hat{\mu}_{10}=\bar{X},\ \hat{\mu}_{20}=\bar{Y},\ \hat{\sigma}^2=\frac{1}{m+n}(\sum_{i=1}^n(X_i-\bar{X})^2+\sum_{j=1}^m(Y_j-\bar{Y})^2).$$

所以有

$$\begin{aligned} LR &= 2[L(\hat{\mu}_1,\hat{\mu}_2,\hat{\sigma}_1^2,\hat{\sigma}_2^2)-L(\hat{\mu}_{10},\hat{\mu}_{20},\hat{\sigma}^2)] \\ &= (m+n)\log\hat{\sigma}^2-m\log\hat{\sigma}_2^2-n\log\hat{\sigma}_1^2 \\ &= m\log\left(\frac{m}{m+n}[1+\sum_{i=1}^n(x_i-\bar{x})^2/\sum_{j=1}^m(y_j-\bar{y})^2]\right) \\ &\quad +n\log\left(\frac{n}{m+n}[1+\sum_{j=1}^m(y_j-\bar{y})^2/\sum_{i=1}^n(x_i-\bar{x})^2]\right) \\ &\triangleq m\log(1+\frac{n-1}{m-1}W)+n\log(1+\frac{m-1}{n-1}W^{-1})+\text{常数}. \end{aligned}$$

其中 $W=[\sum_{i=1}^n(x_i-\bar{x})^2)/(n-1)]/[\sum_{j=1}^m(y_j-\bar{y})^2/(m-1)]$ 。易见，在 H_0 成立的条件下 $W\sim F(n-1,m-1)$ 。根据与本章习题 44 (2) 等的方法完全一样, 令 $B=\frac{W}{W+(m-1)/(n-1)}$ ，则在 H_0 成立的条件下 $B\sim BE(\frac{n-1}{2},\frac{m-1}{2})$ 。把 $W=\frac{(m-1)B}{(n-1)(1-B)}$ 代入 LR 的表达式可得

$$g(B)\triangleq LR=m\log(1+\frac{B}{1-B})+n\log(1+\frac{1-B}{B})=-m\log(1-B)-n\log B.$$

这时对于任意的 $0<B<1$ ，由于 $g''(B)=n/B^2+m/(1-B)^2>0$ ，所以 $g(B)$ 是 B 的严凸函数。因此假设检验问题 (3) 的似然比检验的否定域为 $R^+=\{x: LR>c\}=\{x: B<k_1$ 或 $B>k_2\}$ 。 由此可知，假设检验问题 (3) 的似然比检验为

$$\phi(B)=\begin{cases} 1 & , \quad B<k_1 \text{ 或 } B>k_2 \\ 0 & , \quad \text{其他}. \end{cases}$$

其中 k_1 和 k_2 由 $\mathrm{E}_{H_0}[\phi(B)]=\alpha$ 和 $g(k_1)=g(k_2)$ 决定，这等价于

$$\int_{k_1}^{k_2} f(\frac{n-1}{2},\frac{m-1}{2},u)\ du=1-\alpha \ \text{ 和 } \ (\frac{k_1}{k_2})^n=(\frac{1-k_2}{1-k_1})^m.$$

其中 $f(p,q,u)$ 是 β 分布 $BE(p,q)$ 的密度函数。 ∎

注. 本题 (1) 亦可按以下方法求解。根据原书 (6.5.30) 式，样本的联合密度函数为

$$f=(\frac{1}{\sqrt{2\pi}\sigma_1})^n(\frac{1}{\sqrt{2\pi}\sigma_2})^m\exp\{\theta U(x,y)+\varphi T(x,y)-\frac{1}{2\sigma_1^2}\sum_{i=1}^n x_i^2-\frac{1}{2\sigma_2^2}\sum_{j=1}^m y_j^2-(\frac{n\mu_1^2}{2\sigma_1^2}+\frac{m\mu_2^2}{2\sigma_2^2})\}$$

其中 $\theta=mn(\mu_2-\mu_1)/(n\sigma_2^2+m\sigma_1^2)$ ，$U(x,y)=\bar{y}-\bar{x}$ ，$\varphi=(n\sigma_2^2\mu_1+m\sigma_1^2\mu_2)/(n\sigma_2^2+m\sigma_1^2)$ ，$T(x,y)=n\sigma_1^2/\bar{x}+m\sigma_2^2/\bar{y}$ 。由 θ 和 φ 的表达式可解得

$$\mu_1=\varphi-\frac{\sigma_1^2}{n}\theta,\quad \mu_2=\varphi+\frac{\sigma_2^2}{m}\theta,$$

所以关于 θ 和 φ 的对数似然函数为

$$L(\theta,\varphi)=\theta U(x,y)+\varphi T(x,y)-\frac{n}{2\sigma_1^2}(\varphi-\frac{\sigma_1^2}{n}\theta)^2-\frac{m}{2\sigma_2^2}(\varphi+\frac{\sigma_2^2}{m}\theta)^2+\text{常数}$$

假设检验问题 (1) 等价与 (1)′ $H_0:\theta=\theta_0=0 \longleftrightarrow H_1:\theta\neq 0$ 。似然方程为

$$\frac{\partial L}{\partial\theta}=U(x,y)-(\frac{\sigma_1^2}{n}+\frac{\sigma_2^2}{m})\theta=0,\quad \frac{\partial L}{\partial\varphi}=T(x,y)-(\frac{n}{\sigma_1^2}+\frac{m}{\sigma_2^2})\varphi=0.$$

则 H_1 成立的条件下，θ 和 φ 的极大似然估计分别为 $\hat{\theta}=U/(\frac{\sigma_1^2}{n}+\frac{\sigma_2^2}{m})$ ，$\hat{\varphi}=T/(\frac{n}{\sigma_1^2}+\frac{m}{\sigma_2^2})$ 。当 H_0 成立时，因为 $L(\theta_0,\varphi)=\varphi T(x,y)-\frac{1}{2}(\frac{n}{\sigma_1^2}+\frac{m}{\sigma_2^2})\varphi^2+$ 常数 ，所以 θ 和 φ 的极大似然估计分别为 $\hat{\theta}_0=0$ ， $\hat{\varphi}_0=T/(\frac{n}{\sigma_1^2}+\frac{m}{\sigma_2^2})=\hat{\varphi}$. 所以有

$$\begin{aligned}
LR &= 2[L(\hat{\theta},\hat{\varphi})-L(\hat{\theta}_0,\hat{\varphi}_0)]\\
&= 2[\hat{\theta}U+\hat{\varphi}T-\frac{n}{2\sigma_1^2}(\hat{\varphi}-\frac{\sigma_1^2}{n}\hat{\theta})^2-\frac{m}{2\sigma_2^2}(\hat{\varphi}+\frac{\sigma_2^2}{m}\hat{\theta})^2-\hat{\varphi}_0T+\frac{n}{2\sigma_1^2}\hat{\varphi}_0^2+\frac{m}{2\sigma_2^2}\hat{\varphi}_0^2]\\
&= 2[(\frac{\sigma_1^2}{n}+\frac{\sigma_2^2}{m})\hat{\theta}^2-(\frac{n}{2\sigma_1^2}\hat{\varphi}^2-\hat{\varphi}\hat{\theta}+\frac{\sigma_1^2}{2n}\hat{\theta}^2)-(\frac{m}{2\sigma_1^2}\hat{\varphi}^2+\hat{\varphi}\hat{\theta}+\frac{\sigma_2^2}{2m}\hat{\theta}^2)+(\frac{n}{2\sigma_1^2}+\frac{m}{2\sigma_2^2})\hat{\varphi}^2]\\
&= (\frac{\sigma_1^2}{n}+\frac{\sigma_2^2}{m})\hat{\theta}^2=U^2/(\frac{\sigma_1^2}{n}+\frac{\sigma_2^2}{m})\triangleq W^2
\end{aligned}$$

其中 $W=U/\sqrt{\frac{\sigma_1^2}{n}+\frac{\sigma_2^2}{m}}$ 。当 H_0 成立时，即 $\theta=0$ ， $\mu_1=\mu_2$ 时， $W\sim N(0,1)$ 。所以假设检验问题 (1)′ ，即 (1) 的否定域为 $R^+=\{x:LR>c\}=\{x:W^2>c\}=\{x:|W|>k\}$ 。由定解条件易得 $k=z_{1-\alpha/2}$ 。所以假设检验问题 (1) 的水平为 α 的似然比检验为

$$\phi(W)=\begin{cases}1 & , \quad |W|>z_{1-\alpha/2}\\ 0 & , \quad |W|<z_{1-\alpha/2}\end{cases}$$ ∎

50. 设随机变量 $X_1,X_2,\cdots,X_n$ 满足关系 $X_i=X_{i-1}\theta+u_i,\ i=1,\cdots,n$ ， $X_0=0$ 。其中 $u_1,u_2,\cdots,u_n$ 为 *i.i.d.* 随机变量， $u_1\sim N(0,\sigma^2)$ 。求以下假设检验问题水平为 α 的似然比检验： $H_0:\theta=0\longleftrightarrow H_1:\theta\neq 0$ 。

解. 样本的对数似然函数为

$$L(\theta,\sigma^2)=-\frac{n}{2}\log\sigma^2-\frac{1}{2\sigma^2}\sum_{i=1}^{n}(x_i-\theta x_{i-1})^2-\frac{n}{2}\log 2\pi.$$

由第三章习题 41 知，在 H_1 成立的条件下， θ 和 σ^2 的极大似然估计分别为

$$\hat{\theta}=\frac{\sum_{i=1}^{n}X_iX_{i-1}}{\sum_{i=1}^{n}X_{i-1}^2},\quad \hat{\sigma}^2=\frac{1}{n}\sum_{i=1}^{n}(X_i-\frac{\sum_{i=1}^{n}X_iX_{i-1}}{\sum_{i=1}^{n}X_{i-1}^2}X_{i-1})^2.$$

在 H_0 成立的条件下， θ 和 σ^2 的极大似然估计分别为

$$\hat{\theta}_0=0,\quad \hat{\sigma}_0^2=\frac{1}{n}\sum_{i=1}^{n}X_i^2.$$

所以有

$$LR=2[L(\hat{\theta},\hat{\sigma}^2)-L(\hat{\theta}_0,\hat{\sigma}_0^2)]=n\log(\hat{\sigma}_0^2/\hat{\sigma}^2)\xrightarrow{L}\chi^2(1).$$

因此假设检验问题的水平为 α 的似然比检验为

$$\phi(x)=\begin{cases}1 & , \quad LR>\chi^2(1,1-\alpha)\\ 0 & , \quad LR<\chi^2(1,1-\alpha)\end{cases}.$$ ∎

51. 对某中学学生每周观看电视的小时数进行调查，情况如下表所示：

每周观看时数	<3	$[3,6)$	$[6,9)$	$[9,13)$	≥ 13
去年比例	0.18	0.30	0.26	0.20	0.06
今年人数	10	30	20	30	10

试检验：从今年 100 人的调查结果来看，今年的比例与去年的比例是否相同 ($\alpha=0.05$) ？

解. 根据多项分布，今记 $n=100$ ，$N=(N_1,N_2,N_3,N_4,N_5)^T=(10,30,20,30,10)^T$ ，$\pi=(0.18,0.30,0.26,0.20,0.06)^T$ 。本题是要检验

$$H_0:N\sim MN(n,\pi)\longleftrightarrow H_1:N\text{ 不服从 }MN(n,\pi).$$

把数据代入 Pearson 公式 (见原书 (6.7.9) 式) ，由此可算得 $K_n=12.61$ ，而本题 $k=5$ ，查表可得 $\chi^2(4,0.95)=9.488<K_n$ ，因此，应否定原假设 H_0 。这时 $p-$ 值为 $P\{\chi^2(4)>12.61\}\approx 0.015$ ，因此可认为该校学生每周观看电视小时数的比例与去年有明显不同。 ∎

52. 某工厂近 5 年共发生 63 次事故，若按星期几分类，事故发生在星期 1–6 的次数如下表所示。 判别一下，事故的发生与星期几是否有关 ($\alpha=0.05$) ？

星期	一	二	三	四	五	六
事故次数	9	10	11	8	13	12

解. 本题解法与原书例 6.7.4 类似。今记 $n=63$, $N=(N_1,N_2,N_3,N_4,N_5,N_6)^T=(9,10,11,8,13,12)^T$ 。问题就是要检验

$$H_0:N\sim MN(n;1/6,1/6,1/6,1/6,1/6,1/6)\longleftrightarrow H_1:N\text{ 不服从该分布},$$

其中 $\pi=(1/6,1/6,1/6,1/6,1/6,1/6)^T$, $k=6$ 。代入 Pearson 公式 (6.7.9) 式可得 $K_n=1.6667$, 而 $\chi^2(6,0.95)=11.0705>K_n$, 因此不否定原假设 H_0 。这时 $p-$ 值为 $P\{\chi^2(6)>1.6667\}\approx 0.94$, 所以可认为在该工厂事故的发生与星期几无关。 ∎

53. 为了研究慢性气管炎与吸烟量的关系，共调查了 272 人，结果如下表所示。试检验：慢性气管炎与日吸烟量是否有关 $(\alpha=0.05)$ 。

	吸烟量 (支 / 日)			总人数
	[0, 9]	[10, 19]	≥ 20	
患者人数	22	98	25	145
健康者人数	22	89	16	127
总人数	44	187	41	272

解. 本题是 2×3 列联表的独立性检验。

假设调查者的状态 (用变量 X 表示) 分为患病 (A_1) , 健康 (A_2) 两种; 日吸烟量 (用变量 Y 表示) 分别为 $[0,9]$ (B_1) , $[10,19]$ (B_2) , 大于等于 20 (B_3) 共 3 类, 而 $(X\in A_i, Y\in B_j)$ 的人数为 N_{ij} , 其对应的概率为 π_{ij} , $i=1,2$, $j=1,2,3$ 。因此 $N=(N_{ij})$ 服从多项分布 $MN(272,\pi)$ 。若 X 和 Y 独立，即慢性气管炎与日吸烟量无关，则应有

$$\pi_{ij}=P(X\in A_i,Y\in B_j)=P(X\in A_i)P(Y\in B_j),\quad i=1,2,\ j=1,2,3.$$

由于

$$P(X\in A_i)=\sum_{j=1}^{3}\pi_{ij}=\pi_{i\cdot},\ i=1,2,\quad P(Y\in B_j)=\sum_{i=1}^{2}\pi_{ij}=\pi_{\cdot j}\ ,\ j=1,2,3,$$

所以本题即相当于检验

$$H_0:\pi_{ij}=\pi_{i\cdot}\ \pi_{\cdot j}\ \longleftrightarrow\ H_1:\pi_{ij}\neq\pi_{i\cdot}\ \pi_{\cdot j}.$$

由定理 6.7.4 可算得

$$K_n(\hat{\theta})=n[\sum_{i=1}^{2}\sum_{j=1}^{3}\frac{N_{ij}^2}{N_{i\cdot}N_{\cdot j}}-1]=1.2229$$

而 $t=(2-1)(3-1)=2$, 由此可得 $\chi^2(2,0.95)=5.9915>K_n(\hat{\theta})$, 所以不否定原假设，即认为慢性气管炎与日吸烟量无关。 ∎

54. 某实验室在 2608 个等时间单位内观察了一种放射性物质所释放出来的 $\alpha-$ 粒子 的个数，结果如下表所示，其中频数 n_k 表示在 2608 个时间单位中释放出 k 个粒子的时间单位的个数。试验证：该放射性物质所释放出来的 $\alpha-$ 粒子 的个数服从 Poisson 分布 $(\alpha=0.05)$ 。

粒子数 k	0	1	2	3	4	5	6	7	8	9	10	11	12	13	总数
频数 n_k	57	203	383	525	532	408	273	139	45	27	10	4	2	0	2608

解. 与原书例 6.7.5 类似，本题可化为含参数 λ 的多项分布的检验问题。

可认为该实验室观察了 $X_1, X_2, \cdots, X_{2608}$ 个独立同分布的样本， X_i 表示第 i 个时间单位内 放射性物质所释放出 $\alpha-$粒子 的个数, 取值为 $0, 1, 2, \cdots, 13$, 要检验 X_i 是否服从 Poisson 分布。为此, 把 2608 个观察值分为 12 个组, 记为 $I_i = \{$释放了 i 个 $\alpha-$ 粒子$\}$, $i = 0, 1, 2, \cdots, 10$ ， $I_{11} = \{$释放出的 $\alpha-$ 粒子数 $\geq 11\}$ ，并用 N_i 表示观测值中属于 I_i 的个数，则有 $N_i = n_i$, $i = 0, 1, \cdots, 10$ ， $N_{11} = 4 + 2 + 0 = 6$ 。若 $X_1 \sim P(\lambda)$ ，则有

$$\pi_i(\lambda) = P_\lambda(X_1 = i) = e^{-\lambda} \cdot \frac{\lambda^i}{i!}, \quad i = 0, 1, 2, \cdots, 10, \quad \pi_{11}(\lambda) = 1 - P_\lambda(X_1 \leq 10).$$

记 $N = (N_0, N_1, \cdots, N_{11})^T$ ， $\pi(\lambda) = (\pi_0(\lambda), \pi_1(\lambda), \cdots, \pi_{11}(\lambda))^T$ ，则问题转化为假设检验问题

$$H_0 : N \sim MN(2608, \pi(\lambda)) \longleftrightarrow H_1 : N \text{ 不服从 } MN(2608, \pi(\lambda)).$$

对该检验应用 Fisher 定理, 这时 $n = 2608$; $k = 12$, $p = 1$, 因而自由度 $= k - p - 1 = 10$ 。通常 $\hat{\lambda}$ 用样本均值 $\bar{x} = 3.8704$ 来近似，根据 (6.7.13) 式可算得 $K_n(\hat{\lambda}) = 12.9708$ ，而 $\chi^2(10, 0.95) = 18.3070 > K_n(\hat{\lambda})$ ，所以不否定原假设 H_0 ，即认为该放射性物质所释放出来的 $\alpha-$粒子 的个数服从泊松分布。 ∎

第七章　区间估计

1. 设 $X_1,\cdots,X_n$ 为 $i.i.d.$ 样本， $X_1\sim E(\mu,1)=\mu+\Gamma(1,1)$, 试用枢轴量法求 μ 的一个水平为 $1-\alpha$ 的置信区间。

解. μ 的极大似然估计为 $\hat{\mu}=X_{(1)}$ 。由 $X_{(1)}\sim\mu+\Gamma(n,1)$ 可知 $T=2n(X_{(1)}-\mu)\sim\Gamma(\frac{1}{2},1)\sim\chi^2(2)$ ，所以可取 T 为枢轴量。由

$$P_\mu\{\chi^2(2,\alpha/2)\le 2n(X_{(1)}-\mu)\le\chi^2(2,1-\alpha/2)\}=1-\alpha$$

可知

$$P_\mu\{X_{(1)}-\frac{\chi^2(2,1-\alpha/2)}{2n}\le\mu\le X_{(1)}-\frac{\chi^2(2,\alpha/2)}{2n}\}=1-\alpha.$$

由上式即得 μ 的一个水平为 $1-\alpha$ 的置信区间为

$$\left[X_{(1)}-\frac{\chi^2(2,1-\alpha/2)}{2n},\quad X_{(1)}-\frac{\chi^2(2,\alpha/2)}{2n}\right].$$

∎

2. 设 $X_1,\cdots,X_n$ 为 $i.i.d.$ 样本， $X_1\sim\Gamma(\lambda,\nu)$ ，但 ν 已知。试用枢轴量法求 λ 的一个水平为 $1-\alpha$ 的置信区间和置信上、下限。

解. λ 的极大似然估计为 $\hat{\lambda}=n\nu/\sum_{i=1}^n X_i$ 。由 $T=\sum_{i=1}^n X_i\sim\Gamma(\lambda,n\nu)$ 可知 $2\lambda T\sim\chi^2(2n\nu)$ ，所以可取 $G(X,\lambda)=2\lambda T$ 为枢轴量。 由

$$P_\lambda\{\chi^2(2n\nu,\alpha/2)\le 2\lambda T\le\chi^2(2n\nu,1-\alpha/2)\}=1-\alpha$$

可得 λ 的水平为 $1-\alpha$ 的置信区间为

$$\left[\frac{1}{2T}\chi^2(2n\nu,\alpha/2),\quad\frac{1}{2T}\chi^2(2n\nu,1-\alpha/2)\right].$$

由

$$P_\lambda\{\chi^2(2n\nu,\alpha)\le 2\lambda T\}=1-\alpha$$

可得 λ 的水平为 $1-\alpha$ 的置信下限为 $\underline{\lambda}=\chi^2(2n\nu,\alpha)/(2T)$ 。同理， $\bar{\lambda}=\chi^2(2n\nu,1-\alpha)/2T$ 是 λ 的水平为 $1-\alpha$ 的置信上限。 ∎

3. 设 $X_1,\cdots,X_n$ 为 $i.i.d.$ 样本，试用枢轴量法求以下分布中相应参数水平为 $1-\gamma$ 的置信区间。

(1) 设 X_1 服从 β 分布 $BE(\theta,1)$ ，即 $f(x_1,\theta)=\theta x_1^{\theta-1}\{0\le x_1\le 1\}$ ；

(2) 设 X_1 服从 Weibull 分布，即 $f(x_1,\lambda)=\alpha\lambda x_1^{\alpha-1}\exp\{-\lambda {x_1}^\alpha\}I\{x_1>0\}$ ，但 α 已知;

(3) X_1 服从 Pareto 分布 $PR(\alpha,\theta)$ ，即 $f(x_1,\alpha,\theta)=\alpha\theta^\alpha {x_1}^{-(\alpha+1)}I\{x_1\ge\theta\}$ ， θ 已知或 α 已知。

解. (1) θ 的极大似然估计为 $\hat{\theta}=-n/\sum_{i=1}^n\log X_i$ 。 由第一章习题 21 可知 $T=-\sum_{i=1}^n\log X_i\sim\Gamma(\theta,n)$ ，所以可取 $G(X,\theta)=2\theta T=-2\theta\sum\limits_{i=1}^n\log X_i\sim\chi^2(2n)$ 为枢轴量。

由

$$P_\theta\{\chi^2(2n,\gamma/2)\le 2\theta T\le \chi^2(2n,1-\gamma/2)\}=1-\gamma$$

可得 θ 的水平为 $1-\gamma$ 的置信区间为

$$\left[\frac{1}{2T}\chi^2(2n,\gamma/2),\quad \frac{1}{2T}\chi^2(2n,1-\gamma/2)\right].$$

(2) λ 的极大似然估计为 $\hat{\lambda}=n/\sum_{i=1}^n X_i^\alpha$ 。由第一章习题 21 可知 $T=\sum_{i=1}^n X_i^\alpha\sim\Gamma(\lambda,n)$ ，所以可取 $G(X,\lambda)=2\lambda T=2\lambda\sum_{i=1}^n X_i^\alpha\sim\chi^2(2n)$ 为枢轴量。由

$$P_\lambda\{\chi^2(2n,\gamma/2)\le 2\lambda T\le \chi^2(2n,1-\gamma/2)\}=1-\gamma$$

可得 λ 的一个水平为 $1-\gamma$ 的置信区间为

$$\left[\frac{1}{2T}\chi^2(2n,\gamma/2),\quad \frac{1}{2T}\chi^2(2n,1-\gamma/2)\right].$$

(3) θ 已知时， α 的极大似然估计为 $\hat{\alpha}=n/[\sum_{i=1}^n\log X_i-n\log\theta]$ 。由第一章习题 23 知 $T_1=\sum_{i=1}^n(\log X_i-\log\theta)\sim\Gamma(\alpha,n)$ ，所以可取 $G(X,\alpha)=2\alpha T_1\sim\chi^2(2n)$ 为枢轴量。由

$$P_\alpha\{\chi^2(2n,\gamma/2)\le 2\alpha T_1\le \chi^2(2n,1-\gamma/2)\}=1-\gamma$$

可知 α 的一个水平为 $1-\gamma$ 的置信区间为

$$\left[\frac{1}{2T_1}\chi^2(2n,\gamma/2),\quad \frac{1}{2T_1}\chi^2(2n,1-\gamma/2)\right].$$

α 已知时， θ 的极大似然估计为 $\hat{\theta}=X_{(1)}$ 。由第一章习题 23 知 $T_2=X_{(1)}\sim PR(n\alpha,\theta)$ 。所以可取 $G(X,\theta)=X_{(1)}/\theta\sim PR(n\alpha,1)$ 为枢轴量。由

$$P_\theta\{a\le X_{(1)}/\theta\le b\}=1-\gamma$$

可得 θ 的一个水平为 $1-\gamma$ 的置信区间为

$$\left[X_{(1)}/b,\quad X_{(1)}/a\right].$$

其中 a,b 可取为 $PR(n\alpha,1)$ 的 $\gamma/2$ 和 $1-\gamma/2$ 分位点。

现在我们来求分布 $PR(n\alpha,1)$ 的 β 分位点 c_β 。记 $n\alpha=m$ ，则 $Y\sim PR(n\alpha,1)\sim my^{-(m+1)}I\{y\ge 1\}$ 。 直接积分可得

$$\int_1^{c_\beta} my^{-(m+1)}dy=1-\frac{1}{{c_\beta}^m}=\beta.$$

由此可得 $c_\beta=1/\sqrt[m]{1-\beta}$ 。因此 $a=1/\sqrt[m]{1-\gamma/2}$ ； $b=1/\sqrt[m]{\gamma/2}$ ；所以 θ 的一个水平为 $1-\gamma$ 的置信区间为

$$\left[\sqrt[m]{\gamma/2}\,X_{(1)},\quad \sqrt[m]{1-\gamma/2}\,X_{(1)}\right];\quad m=n\alpha.$$

∎

注. 与原书例 7.1.3 类似，我们亦可在约束条件 $P_\theta\{a \le X_{(1)}/\theta \le b\} = 1-\gamma$ 下求区间长度 $(1/a - 1/b)X_{(1)}$ 最短的解。上述约束条件相当于

$$\int_a^b my^{-(m+1)}dy = \frac{1}{a^m} - \frac{1}{b^m} = 1-\gamma; \quad 1 \le a < b \le +\infty.$$

因而相当于在 $1/a^m - 1/b^m = 1-\gamma$ 的条件下求 $1/a - 1/b$ 达到最小值的解。若记 $1/a = a'$, $1/b = b'$; $b' < a' \le 1$，这就相当于在约束条件 $(a')^m - (b')^m = 1-\gamma$ 下求 $a'-b'$ 达到最小值的解。易见 $a'-b' = a' - \sqrt[m]{(a')^m - (1-\gamma)}$ 为 a' 的减函数，因而当 $a'=1$ 或 $a=1$ 时 $a'-b'$ 达到最小值。这时 $b = 1/\sqrt[m]{\gamma}$，因此区间长度最短的置信区间为

$$\left[\sqrt[m]{\gamma}\, X_{(1)}, \quad X_{(1)}\right]; \qquad m = n\alpha.$$

∎

4. 设 $X_1, \cdots, X_n$ 为 *i.i.d.* 样本。(1) 若 $X_1 \sim N(\theta,\theta), (\theta > 0)$，找一个枢轴量并用此枢轴量构造 θ 的一个水平为 $1-\alpha$ 的置信区间；(2) 若 $X_1 \sim N(\theta,\theta^2), (\theta > 0)$，求 θ 的一个水平为 $1-\alpha$ 的置信区间。

解. (1) 由 $\bar{X} \sim N(\theta, \theta/n)$ 可得 $\sqrt{n}(\bar{X}-\theta)/\sqrt{\theta} \sim N(0,1)$，所以 $T_1 = \sqrt{n}(\bar{X}-\theta)/\sqrt{\theta}$ 为枢轴量。因为

$$\begin{aligned}
& P_\theta\{|\sqrt{n}(\bar{X}-\theta)/\sqrt{\theta}| \le z_{1-\alpha/2}\} = 1-\alpha \\
\Longleftrightarrow\ & P_\theta\{n(\bar{X}-\theta)^2 \le \theta z_{1-\alpha/2}^2\} = 1-\alpha \\
\Longleftrightarrow\ & P_\theta\{\bar{X} + \frac{1}{2n}z_{1-\alpha/2}^2 - \Delta \le \theta \le \bar{X} + \frac{1}{2n}z_{1-\alpha/2}^2 + \Delta\} = 1-\alpha
\end{aligned}$$

其中 $\Delta = \sqrt{4n\bar{X}z_{1-\alpha/2}^2 + z_{1-\alpha/2}^4} = z_{1-\alpha/2}\sqrt{4n\bar{X} + z_{1-\alpha/2}^2}$， $z_{1-\alpha/2}$ 为标准正态分布的 $1-\alpha/2$ 分位点。所以 θ 的一个水平为 $1-\alpha$ 的置信区间为

$$\left[\bar{X} + \frac{1}{2n}z_{1-\alpha/2}^2 - \Delta, \quad \bar{X} + \frac{1}{2n}z_{1-\alpha/2}^2 + \Delta\right]$$

(2) 由 $\bar{X} \sim N(\theta, \theta^2/n)$ 可得 $\sqrt{n}(\bar{X}-\theta)/\theta \sim N(0,1)$，所以 $T_2 = \sqrt{n}(\bar{X}-\theta)/\theta$ 为枢轴量。由

$$P_\theta\{-z_{1-\alpha/2} \le T_2 \le z_{1-\alpha/2}\} = 1-\alpha$$

可得

$$P_\theta\{\frac{1}{\sqrt{n}+z_{1-\alpha/2}}\sqrt{n}\bar{X} \le \theta \le \frac{1}{\sqrt{n}-z_{1-\alpha/2}}\sqrt{n}\bar{X}\} = 1-\alpha,$$

所以 θ 的一个水平为 $1-\alpha$ 的置信区间为

$$[\frac{1}{\sqrt{n}+z_{1-\alpha/2}}\sqrt{n}\bar{X}, \quad \frac{1}{\sqrt{n}-z_{1-\alpha/2}}\sqrt{n}\bar{X}]$$

∎

5. 设 $X_1, \cdots, X_n$ 为 *i.i.d.* 样本，$X_1 \sim f(x_1,\theta) = \frac{a}{\theta}(\frac{x}{\theta})^{a-1}I\{0 \le x \le \theta\}$, 其中 $a \ge 1$ 已知，$\theta > 0$ 未知。试找一个枢轴量，并用此枢轴量构造 θ 的一个水平为 $1-\alpha$ 的置信区间。

解. θ 的极大似然估计为 $\hat{\theta} = X_{(n)}$。下面我们基于 $X_{(n)}$ 来构造枢轴量，并求 θ 的水平为 $1-\alpha$ 置信区间。令 $Y_i = X_i/\theta$, 则 $Y_i \sim f(y_i) = ay_i^{a-1}I\{0 \le y_i \le 1\}$ 服从 β 分布，且 Y_i 的分布函数为 $F(y_i) = \int_0^{y_i} at^{a-1}dt = y_i^a$, 所以 $T = X_{(n)}/\theta = Y_{(n)}$ 的分布密度函数为

$$f(t) = n(t^a)^{n-1}at^{a-1}I\{0 \le t \le 1\} = nat^{na-1}I\{0 \le t \le 1\}.$$

由此即得 T 为枢轴量。由 $P\{c \le T \le 1\} = 1-\alpha$ 直接积分可得 $c = \alpha^{1/(na)}$ ，所以

$$P_\theta\{\alpha^{1/(na)} \le \frac{X_{(n)}}{\theta} \le 1\} = 1-\alpha.$$

从而 θ 的一个水平为 $1-\alpha$ 的置信区间为 $[X_{(n)},\ X_{(n)}/\alpha^{1/(na)}]$ 。 ∎

6. ★ 设 $X_1, \cdots, X_n$ 为 $i.i.d.$ 样本， X_1 服从均匀分布 $R(\theta-\frac{1}{2},\ \theta+\frac{1}{2})$, 试构造 θ 的一个水平为 $1-\alpha$ 的置信区间。 (提示： θ 的同变估计为 $\hat{\theta} = \frac{X_{(1)}+X_{(n)}}{2}$, 求 $T = \hat{\theta}-\theta$ 的密度函数) 。

解. 我们基于 θ 的同变估计 $\hat{\theta} = \frac{X_{(1)}+X_{(n)}}{2}$ 来求 θ 的水平为 $1-\alpha$ 的置信区间。

由于 $X_i - \theta \sim R(-\frac{1}{2},\ \frac{1}{2})$ ， 所以 $(Y,Z) \triangleq (X_{(1)}-\theta,\ X_{(n)}-\theta)$ 的联合密度函数为

$$f(y,z) = n(n-1)(z-y)^{n-2} I\{-\frac{1}{2} \le y < z \le \frac{1}{2}\}.$$

作变换 $T = \frac{Y+Z}{2} = \hat{\theta}-\theta,\ Y = Y$ ，则 $Z = 2T - Y$ 。因而 (Y,T) 的联合密度函数以及 T 的边缘密度函数分别为

$$f(y,t) = 2n(n-1)(2t-2y)^{n-2} \cdot I\{-\frac{1}{2} \le y < 2t-y \le \frac{1}{2}\}.$$

$$f(t) = \int_{-\frac{1}{2}}^{\frac{1}{2}} f(y,t)dy = \int_{-\frac{1}{2}}^{\frac{1}{2}} 2n(n-1)(2t-2y)^{n-2} \cdot I\{-\frac{1}{2} \le y < 2t-y \le \frac{1}{2}\}dy.$$

易见 $-\frac{1}{2} \le t \le \frac{1}{2}$ ，且有 $y \le t$ ， $2t-y \le \frac{1}{2}$ ，由此可得

$$I\{-\frac{1}{2} \le y < 2t-y \le \frac{1}{2}\} = [I\{-\frac{1}{2} \le y < t \le 0\} + I\{t \ge 0,\ 2t-\frac{1}{2} \le y \le t\}].$$

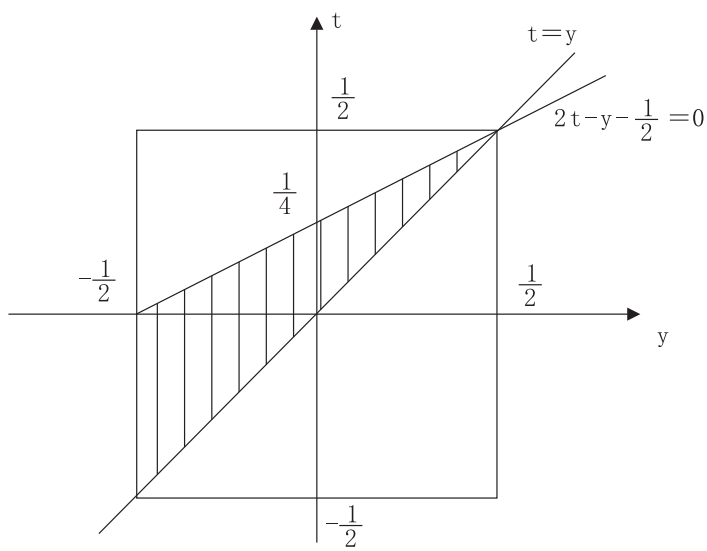

所以 T 的边缘密度函数可表示为分段积分 (见积分区域图)

$$f(t) = \begin{cases} \int_{-\frac{1}{2}}^{t} 2n(n-1)[2t-2y]^{n-2}dy, & -\frac{1}{2} \le t \le 0, \\ \int_{2t-\frac{1}{2}}^{t} 2n(n-1)[2t-2y]^{n-2}dy, & 0 < t \le \frac{1}{2}, \\ 0 & \text{其它}. \end{cases}$$

$$= \begin{cases} n(1+2t)^{n-1}, & -\frac{1}{2} \le t \le 0, \\ n(1-2t)^{n-1}, & 0 < t \le \frac{1}{2}, \\ 0 & \text{其它}. \end{cases}$$

$$= \begin{cases} n(1-2|t|)^{n-1}, & |t| \le \frac{1}{2}, \\ 0 & \text{其它}. \end{cases}$$

由此易见 T 的分布与 θ 无关，所以 T 是枢轴量。取 $-\frac{1}{2} < a < b < \frac{1}{2}$ ，使得 $\int_a^b f(t)dt = 1-\alpha$ 。则由 $P_\theta\{a \le T \le b\} = 1-\alpha$ 可得

$$P_\theta\{\frac{X(1)+X(n)}{2} - b \le \theta \le \frac{X(1)+X(n)}{2} - a\} = 1-\alpha.$$

所以 $\left[\frac{X(1)+X(n)}{2} - b,\ \frac{X(1)+X(n)}{2} - a\right]$ 是 θ 的一个水平为 $1-\alpha$ 的置信区间。例如，由对称性可取 b ，使得 $\int_b^{1/2} f(t)dt = \alpha/2$ ，则 $b = (1-\sqrt[n]{\alpha})/2$ ， $a = -b$ 。 ∎

7. 从某自动车床加工的一批零件中随机抽取 10 个，测得其长度 (单位为毫米) 分别为

12.01, 12.15, 12.08, 12.09, 12.16, 12.03, 12.06, 12.13, 12.07, 12.11

假定长度服从正态分布，置信水平取为 0.95 ， (1) 求平均长度的置信区间； (2) 该自动车床加工的精度 σ 在什么范围内？

解. (1) 由题意可设 $X_1, \cdots, X_{10}$ 为 $i.i.d.$ 样本， $X_1 \sim N(\mu, \sigma^2)$ 。由例 7.1.1 的结论可知平均长度 μ 的水平为 0.95 的置信区间为

$$\left[\bar{X} - \frac{\hat{\sigma}}{\sqrt{10}} t(9, 0.975),\ \ \bar{X} + \frac{\hat{\sigma}}{\sqrt{10}} t(9, 0.975)\right].$$

根据以上数据可得 $\bar{x} = 12.0890,\ \hat{\sigma} = (\frac{1}{9}\sum_{i=1}^n (x_i - \bar{x})^2)^{\frac{1}{2}} = 0.0493,\ t(9, 0.975) = 2.2622$ 。因此平均长度 μ 的置信水平为 0.95 的置信区间为 $[12.0537,\ 12.1243]$ 。

(2) 由例 7.1.2 可知 σ 的水平为 0.95 的置信区间为 $[\underline{\sigma}(X),\ \bar{\sigma}(X)]$ 。其中 $\underline{\sigma}^2(X) = \frac{S(X)}{\chi^2(9,0.975)},\ \bar{\sigma}^2(X) = \frac{S(X)}{\chi^2(9,0.025)},\ S(X) = \sum\limits_{i=1}^n (X_i - \bar{X})^2$ 。根据以上数据可得 σ 的水平为 0.95 的置信区间为 $[0.0339,\ 0.0900]$ 。 ∎

8. 假设某元件的寿命服从指数分布。

(1) 从一批产品中随机抽取 9 个，测得其寿命 (单位为小时) 分别为

150, 450, 500, 530, 600, 650, 700, 830, 910.

问这批产品的平均寿命不低于多少 (置信水平为 0.95) ？又设 p 为这批产品中寿命大于 600 小时的比例，求 p 的置信区间；

(2) 从一批产品中随机抽取 20 个，测得其前 10 个的寿命 (单位为小时) 分别为

500, 920, 1380, 1510, 1650, 1760, 2100, 2320, 2350, 2900.

求这批产品平均寿命的置信区间 (置信水平为 0.95) 。

解. (1) 由题意可设 $X_1, \cdots, X_9$ 为 $i.i.d.$ 样本，$X_1 \sim \Gamma(\frac{1}{\theta}, 1)$, 其中 $\theta > 0$ 为平均寿命。θ 的极大似然估计为 $\hat{\theta} = \frac{T}{n}$ ，其中 $T = \sum_{i=1}^n X_i \sim \Gamma(\frac{1}{\theta}, n)$ 。可取 $G(X, \theta) = \frac{2}{\theta}T \sim \chi^2(2n)$ 为枢轴量。由 $P_\theta\{\dfrac{2T}{\theta} \le \chi^2(2n, 0.95)\} = 0.95$ 可得 $\underline{T} = 2T/\chi^2(2n, 0.95)$ 是 θ 的置信水平为 0.95 的置信下限。代入数据可算得这批产品在置信水平为 0.95 的条件下，其平均寿命不低于 368.5576 。

这批产品中寿命大于 600 小时的比例为 $p=\int_{600}^{\infty}\frac{1}{\theta}e^{-t/\theta}dt=e^{-600/\theta}$ 。因为

$$\begin{aligned}&P_\theta\{\chi^2(2n,0.025)\le\frac{2T}{\theta}\le\chi^2(2n,0.975)\}\\=\;&P_\theta\{2T/\chi^2(2n,0.975)\le\theta\le 2T/\chi^2(2n,0.025)\}\\=\;&P_\theta\{e^{-600\chi^2(2n,0.975)/2T}\le p\le e^{-600\chi^2(2n,0.025)/2T}\}=0.95\end{aligned}$$

所以 $[e^{-600\chi^2(2n,0.975)/2T},\ e^{-600\chi^2(2n,0.025)/2T}]$ 是 p 的一个水平为 0.95 的置信区间。代入数据算得 p 的一个水平为 0.95 的置信区间为 $[0.1690,\ 0.6287]$ 。

(2) 由题意可设 $X_1,\cdots,X_n$ 为 $i.i.d.$ 样本，$n=20$ ，并且 $X_1\sim\Gamma(\frac{1}{\theta},1)$ 。设 $Y_1,\cdots,Y_{10}$ 依次为其前 10 个次序统计量的观察值 (即 $r=10$) 。 θ 的极大似然估计为 $\hat{\theta}=T_{n,r}/r$, 其中 $T_{n,r}=\sum_{i=1}^{10}Y_i+10\cdot Y_{10}$ 。由于 $T_{n,r}\sim\Gamma(\frac{1}{\theta},r)$ ，所以可取 $G(X,\theta)=\frac{2}{\theta}T_{n,r}\sim\chi^2(2r)$ 为枢轴量。由

$$P_\theta\{\chi^2(2r,0.025)\le\frac{2T_{n,r}}{\theta}\le\chi^2(2r,0.975)\}=0.95$$

可得 θ 的一个水平为 0.95 的置信区间为

$$\left[2T_{n,r}/\chi^2(2r,0.975),\quad 2T_{n,r}/\chi^2(2r,0.025)\right].$$

代入数据算得 θ 的一个水平为 0.95 的置信区间为 $[2715.3,\ 9673.9]$ 。 ∎

9. 设 $X_1,\cdots,X_n$ 为 $i.i.d.$ 样本， $X_1\sim N(\mu_1,\sigma_1^2)$ ； $Y_1,\cdots,Y_m$ 为 $i.i.d.$ 样本， $Y_1\sim N(\mu_2,\sigma_2^2)$ ；且两总体独立。

(1) 求 $\rho=\sigma_2^2/\sigma_1^2$ 的置信区间;

(2) 设甲、乙两位化验员独立地对某聚合物的含氮量用相同方法各测量 10 次，其样本方差分别为 0.5419 和 0.6050 。假定测量值服从正态分布，求方差比 $\rho=\sigma_2^2/\sigma_1^2$ 的置信区间 (置信水平为 0.95) 。

解. (1) 因为 $(n-1)S_1^2/\sigma_1^2\sim\chi^2(n-1)$ ， $(m-1)S_2^2/\sigma_2^2\sim\chi^2(m-1)$ 且两者独立，其中 $S_1^2=\sum_{i=1}^{n}(X_i-\bar{X})^2/(n-1)$ ， $S_2^2=\sum_{j=1}^{m}(Y_j-\bar{Y})^2/(m-1)$ ，所以 $T(X,Y;\rho)=\frac{S_2^2}{\rho S_1^2}=\frac{S_2^2/\sigma_2^2}{S_1^2/\sigma_1^2}\sim F(m-1,n-1)$ 。由此易见 $T(X,Y;\rho)$ 的分布与 ρ 无关，所以 T 是枢轴量。记 $F_{\frac{\alpha}{2}}=F(m-1,n-1;\dfrac{\alpha}{2})$, $F_{1-\frac{\alpha}{2}}=F(m-1,n-1;1-\dfrac{\alpha}{2})$ 。由

$$P_\rho\{F_{\frac{\alpha}{2}}\le T(X,Y;\rho)\le F_{1-\frac{\alpha}{2}}\}=1-\alpha$$

可得

$$P_\rho\{\frac{S_2^2}{S_1^2F_{1-\frac{\alpha}{2}}}\le\rho\le\frac{S_2^2}{S_1^2F_{\frac{\alpha}{2}}}\}=1-\alpha$$

所以 ρ 的一个水平为 $1-\alpha$ 的置信区间为

$$\left[S_2^2/(S_1^2F_{1-\frac{\alpha}{2}}),\quad S_2^2/(S_1^2F_{\frac{\alpha}{2}})\right].$$

(2) 由于 $F(9,9;0.975)=4.03$ ， $F(9,9;0.025)=1/4.03$ ， $S_2^2=0.6050$ ， $S_1^2=0.5419$ 。这些结果代入以上公式可得， ρ 的一个水平为 0.95 的置信区间为 $[0.2770,4.4992]$ 。 ∎

10. 设 $X_1,\cdots,X_n$ 为 $i.i.d.$ 样本， $X_1\sim N(\mu_1,\sigma_1^2)$ ； $Y_1,\cdots,Y_m$ 为 $i.i.d.$ 样本， $Y_1\sim N(\mu_2,\sigma_2^2)$ ；且两总体独立。若 $\sigma_2^2/\sigma_1^2=c$ 已知，求 $\delta=\mu_1-\mu_2$ 水平为 $1-\alpha$ 的置信区间。

解. 因为 $\bar{X} \sim N(\mu_1, \frac{\sigma_1^2}{n})$ ， $\bar{Y} \sim N(\mu_2, \frac{\sigma_2^2}{m})$ 且两者独立，所以 $\bar{X} - \bar{Y} \sim N(\mu_1 - \mu_2, \frac{\sigma_1^2}{n} + \frac{\sigma_2^2}{m}) \sim N(\delta, (\frac{1}{n} + \frac{c}{m})\sigma_1^2)$ 。令

$$\begin{aligned} G(X,Y;\delta) &= \frac{(\frac{1}{n}+\frac{c}{m})^{-1}\sigma_1^{-1}(\bar{X}-\bar{Y}-\delta)}{\sqrt{[\sum_{i=1}^n (X_i-\bar{X})^2 + \frac{1}{c}\sum_{j=1}^m (Y_j-\bar{Y})^2]/[(n+m-2)\sigma_1^2]}} \\ &= \frac{(\frac{1}{n}+\frac{c}{m})^{-1}(\bar{X}-\bar{Y}-\delta)}{\sqrt{[\sum_{i=1}^n (X_i-\bar{X})^2 + \frac{1}{c}\sum_{j=1}^m (Y_j-\bar{Y})^2]/(n+m-2)}} \end{aligned}$$

由于 $\bar{X}$ 与 $\sum_{i=1}^n (X_i - \bar{X})^2$ 独立， $\bar{Y}$ 与 $\sum_{j=1}^m (Y_j - \bar{Y})^2$ 独立，且两样本独立，所以上式的分子和分母独立，从而易知 $G(X,Y;\delta) \sim t(n+m-2)$ 。记 $S^2(X,Y) = [\sum_{i=1}^n (X_i - \bar{X})^2 + \frac{1}{c}\sum_{j=1}^m (Y_j - \bar{Y})^2]/(n+m-2)$, $M = (\frac{1}{n} + \frac{c}{m})^{-1}$, $t_{1-\frac{\alpha}{2}} = t(n+m-2, 1-\frac{\alpha}{2})$ ，则由

$$P\{|M(\bar{X}-\bar{Y}-\delta)/S(X,Y)| \le t_{1-\frac{\alpha}{2}}\} = 1-\alpha$$

可得 δ 的一个水平为 $1-\alpha$ 的置信区间为

$$\left[\bar{X}-\bar{Y}-\frac{t_{1-\frac{\alpha}{2}}}{M}S(X,Y),\quad \bar{X}-\bar{Y}+\frac{t_{1-\frac{\alpha}{2}}}{M}S(X,Y)\right]$$

11. 设 $X_1, \cdots, X_n$ 为 *i.i.d.* 样本， $X_1 \sim N(\mu_1, \sigma_1^2)$ ； $Y_1, \cdots, Y_m$ 为 *i.i.d.* 样本， $Y_1 \sim N(\mu_2, \sigma_2^2)$ ；且两总体独立。若 $m = n$ ，求 $\delta = \mu_1 - \mu_2$ 水平为 $1-\alpha$ 的置信区间。若 $m = kn$ (k 为已知正整数)，能否求解同样的问题？

解. 当 $m = n$ 时，令 $Z_i = X_i - Y_i$, 则 $Z_1, \cdots, Z_n$ 为 *i.i.d.* 样本，且 $Z_1 \sim N(\delta, \sigma^2)$ ， $\sigma^2 = \sigma_1^2 + \sigma_2^2$ 。因为

$$\begin{aligned} G(Z,\delta) &= \frac{\sqrt{n}(\bar{Z}-\delta)}{\sqrt{\sum_{i=1}^n (Z_i-\bar{Z})^2/(n-1)}} \\ &= \frac{\sqrt{n(n-1)}(\bar{Z}-\delta)}{\sqrt{\sum_{i=1}^n (Z_i-\bar{Z})^2}} \sim t(n-1) \end{aligned}$$

所以可取 $G(Z,\delta)$ 为枢轴量。由

$$P_\delta\{-t(n-1,1-\frac{\alpha}{2}) \le G(Z,\delta) \le t(n-1,1-\frac{\alpha}{2})\} = 1-\alpha$$

可得 δ 的一个水平为 $1-\alpha$ 的置信区间为

$$\left[\bar{X}-\bar{Y}-\frac{t(n-1,1-\frac{\alpha}{2})}{\sqrt{n(n-1)}}\sqrt{\sum_{i=1}^n (Z_i-\bar{Z})^2},\quad \bar{X}-\bar{Y}+\frac{t(n-1,1-\frac{\alpha}{2})}{\sqrt{n(n-1)}}\sqrt{\sum_{i=1}^n (Z_i-\bar{Z})^2}\right].$$

当 $m = kn$ 时，令 $Z_i = X_i - \frac{1}{k}\sum_{j=1}^k Y_{k(i-1)+j}$ ，则 $Z_1, \cdots, Z_n$ 为 *i.i.d.* 样本，且有 $Z_1 \sim N(\delta, \sigma^2)$ ， $\sigma^2 = \sigma_1^2 + \sigma_2^2/k$ 。 则与同 $m = n$ 时的情形一样，可得 δ 的一个水平为 $1-\alpha$ 的置信区间为

$$\left[\bar{Z}-\frac{t(n-1,1-\frac{\alpha}{2})}{\sqrt{n(n-1)}}\sqrt{\sum_{i=1}^n (Z_i-\bar{Z})^2},\quad \bar{Z}+\frac{t(n-1,1-\frac{\alpha}{2})}{\sqrt{n(n-1)}}\sqrt{\sum_{i=1}^n (Z_i-\bar{Z})^2}\right]. \qquad \blacksquare$$

注. 以上习题说明，对于 Behrens-Fisher 问题 (见原书例 7.1.11)，当 $m = kn$ (k 为已知正整数) 时是有解的。 ∎

12. 某养猪场分别用标准配方饲料和新配方的饲料喂养两组猪，一段时间后，在两组猪中各随机抽取 10 头，测得其体重增加值分别为

新配方： 36.0, 32.7, 39.2, 37.6, 32.0, 40.2, 34.4, 30.7, 36.4, 37.2.

标准配方： 35.2, 30.0, 36.5, 38.1, 29.4, 36.0, 31.3, 31.6, 31.1, 34.0.

假设两组猪体重的增加值都服从正态分布，求体重平均增加值之差的置信区间 (置信水平为 0.95)。

解. 这时可用第 11 题的结果 ($m = n = 10$)。把数据代入以上公式，可算得体重平均增加值之差的置信区间为 $[1.6982, 2.9418]$。 ∎

13. 设 $X_i = (X_{i_1}, X_{i_2}), i = 1, 2, \cdots, n$ 为 $i.i.d.$ 样本， $X_1 \sim N(\mu_1, \mu_2; \sigma_1^2, \sigma_2^2; \rho)$，令 $\theta = \mu_2/\mu_1, (\mu_1 \neq 0)$。求 θ 的一个水平为 $1-\alpha$ 的置信区间 (通常称为 Fieller's 区间) (提示：令 $Y_i(\theta) = X_{i2} - \theta X_{i1},\ i = 1, 2, \cdots, n$，以 $Y_1(\theta), \cdots, Y_n(\theta)$ 为基础构造枢轴量)。

解. 令 $Y_i(\theta) = X_{i2} - \theta X_{i1},\ i = 1, 2, \cdots, n$, 则 $Y_1(\theta), \cdots, Y_n(\theta)$ 为 $i.i.d.$ 样本，且有

$$Y_1 \sim N(0, \sigma^2); \quad \sigma^2 = \sigma_2^2 - 2\theta\rho\sigma_1\sigma_2 + \theta^2\sigma_1^2.$$

令

$$\bar{X}_1 = \frac{1}{n}\sum_{i=1}^n X_{i1},\ \bar{X}_2 = \frac{1}{n}\sum_{i=1}^n X_{i2},\ \bar{Y}(\theta) = \frac{1}{n}\sum_{i=1}^n Y_i(\theta) = \bar{X}_2 - \theta\bar{X}_1.$$

则

$$S^2(\theta) = \frac{1}{n-1}\sum_{i=1}^n [Y_i(\theta) - \bar{Y}(\theta)]^2 = S_2^2 - 2\theta S_{12} + \theta^2 S_1^2,$$

其中

$$S_2^2 = \frac{1}{n-1}\sum_{i=1}^n (X_{i2} - \bar{X}_2)^2, \quad S_1^2 = \frac{1}{n-1}\sum_{i=1}^n (X_{i1} - \bar{X}_1)^2,$$

$$S_{12} = \frac{1}{n-1}\sum_{i=1}^n (X_{i1} - \bar{X}_1)(X_{i2} - \bar{X}_2).$$

显然有 $T(X;\theta) = \sqrt{n}\bar{Y}(\theta)/S(\theta) \sim t_{n-1}$, 所以 $T(X;\theta)$ 是枢轴量. 由

$$P_\theta\{-t(n-1, 1-\frac{\alpha}{2}) \leq T(X;\theta) \leq t(n-1, 1-\frac{\alpha}{2})\} = 1-\alpha$$

可得

$$P_\theta\{n[\bar{Y}(\theta)]^2/S^2(\theta) \leq t^2(n-1, 1-\frac{\alpha}{2})\} = 1-\alpha.$$

由此可以通过 θ 的二次三项式解出其变化范围。由于

$$n[\bar{Y}(\theta)]^2/S^2(\theta) = t^2(n-1, 1-\frac{\alpha}{2}) \tag{1}$$

是一个关于 θ 的一元二次方程，所以可以通过讨论其根的情况得到 θ 的 $1-\alpha$ 置信区间的具体形式. 记 $t = t^2(n-1, 1-\frac{\alpha}{2})$, 则方程 (1) 可化为

$$(n\bar{X}_1^2 - tS_1^2)\theta^2 - (2n\bar{X}_1\bar{X}_2 - 2tS_{12})\theta + (n\bar{X}_2^2 - tS_2^2) = 0. \tag{2}$$

记 $A=n\bar{X}_1^2-tS_1^2$, $B=n\bar{X}_1\bar{X}_2-tS_{12}$, $C=n\bar{X}_2^2-tS_2^2$, 则方程 (2) 的解有以下四种情况，分别对应 θ 的几种不同的置信区间：

a. 当 $A>0$, $B^2-AC>0$ 时，方程 (2) 有两个相异实根，即

$$T_1(X)=\frac{B-\sqrt{B^2-AC}}{A},\quad T_2(X)=\frac{B+\sqrt{B^2-AC}}{A}.$$

此时，θ 的水平为 $1-\alpha$ 的置信区间为 $[T_1(X),\ T_2(X)]$ (当 $B^2-AC=0$ 时置信区间退化为一个点)；

b. 当 $A>0$, $B^2-AC<0$ 时，(2) 式左端恒 >0，置信区间不存在;

c. 当 $A<0$, $B^2-AC>0$ 时，$T_1(X)$, $T_2(X)$ 仍是方程 (2) 的两个实根，但此时 θ 的水平为 $1-\alpha$ 的置信域是 $(-\infty,T_1(X)]\cup[T_2(X),+\infty)$；

d. 当 $A<0$, $B^2-AC<0$ 时，(2) 式左端恒 <0，θ 的水平为 $1-\alpha$ 的置信域是整条实直线。

14.* 设 $X_1,\cdots,X_m$ 为 $i.i.d.$ 样本, $X_1\sim R(0,\theta_1)$；$Y_1,\cdots,Y_n$ 为 $i.i.d.$ 样本, $Y_1\sim R(0,\theta_2)$，且两总体独立。求 θ_1/θ_2 的一个水平为 $1-\alpha$ 的置信区间 (提示：证 $Y_{(n)}\theta_1/(X_{(m)}\theta_2)$ 为枢轴量)。

解. 基于 $X=(X_1,\cdots,X_m)^T$ 和 $Y=(Y_1,\cdots,Y_n)^T$ 的联合分布密度函数，易得 θ_1 和 θ_2 的极大似然估计分别为 $\hat{\theta}_1=X_{(m)}$, $\hat{\theta}_2=Y_{(n)}$. 下面我们基于 $X_{(m)}$ 和 $Y_{(n)}$ 构造枢轴量，进而求得 θ_1/θ_2 的一个水平为 $1-\alpha$ 的置信区间. 考虑

$$G(X,Y;\theta_1,\theta_2)=\frac{Y_{(n)}/\theta_2}{X_{(m)}/\theta_1}=\frac{Y_{(n)}\theta_1}{X_{(m)}\theta_2}.$$

由于

$$\frac{X_{(m)}}{\theta_1}\sim BE(m,1),\quad \frac{Y_{(n)}}{\theta_2}\sim BE(n,1).$$

且两者独立，所以 $(U,V)\triangleq(\frac{X_{(m)}}{\theta_1},\frac{Y_{(n)}}{\theta_2})$ 的联合密度函数为

$$f(u,v)=mu^{m-1}\cdot nv^{n-1}=mnu^{m-1}v^{n-1},\quad 0\le u,v\le 1.$$

作变换 $Z=V/U=\frac{Y_{(n)}\theta_1}{X_{(m)}\theta_2}$, $U=U$, 则 $V=ZU$，而且 (Z,U) 的联合密度函数为

$$f(z,u)=mn\cdot u^{m-1}(zu)^{n-1}\cdot u=mn\cdot u^{m+n-1}z^{n-1};\quad 0\le u\le 1,\ 0\le zu\le 1.$$

注意，在求 Z 的边缘分布密度函数 $f(z)=\int_0^1 f(z,u)du$ 时必须考虑 z 的定义域。由假设可知，$z=v/u$，$0\le u,v\le 1$，因而 $0\le z<+\infty$。但是他们必须满足 $0\le u\le 1$，$0\le uz\le 1$。因此当 $0\le z\le 1$ 时，$0\le u\le 1$；而当 $z>1$ 时有 $0\le u\le\frac{1}{z}$. 所以 Z 的边缘分布密度函数为 (见积分区域图)。

$$f(z)=\begin{cases}\int_0^1 f(z,u)du=\frac{mn}{m+n}z^{n-1}, & 0\le z\le 1,\\ \int_0^{1/z} f(z,u)du=\frac{mn}{m+n}z^{-(m+1)}, & z\ge 1,\\ 0 & z<0.\end{cases}$$

易见 $G(X,Y;\theta_1,\theta_2)=Z$ 的分布与 θ_1/θ_2 无关, 所以 $G(X,Y;\theta_1,\theta_2)$ 是枢轴量. 取 $0<a<b$ 使得 $\int_a^b f(z)dz=1-\alpha$, 由此便得

$$P_{(\theta_1,\theta_2)}\{a\le\frac{Y_{(n)}\theta_1}{X_{(m)}\theta_2}<b\}=1-\alpha$$

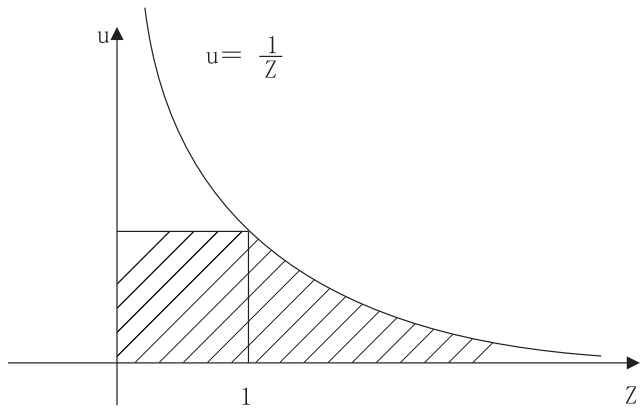

从而

$$P_{(\theta_1,\theta_2)}\{\frac{X_{(m)}}{Y_{(n)}}a \le \frac{\theta_1}{\theta_2} < \frac{X_{(m)}}{Y_{(n)}}b\} = 1-\alpha.$$

所以 θ_1/θ_2 的一个水平为 $1-\alpha$ 的置信区间为 $[\frac{X_{(m)}}{Y_{(n)}}a,\ \frac{X_{(m)}}{Y_{(n)}}b]$ 。例如，若取 $a<1;\ b>1$ ，使得 $\int_0^a f(z)dz = \alpha/2$ ， $\int_b^{+\infty} f(z)dz = \alpha/2$ ，则有 $a^n = \frac{m+n}{m}\frac{\alpha}{2};\ b^{-m} = \frac{m+n}{n}\frac{\alpha}{2}$ 。 ∎

15. 设 $X_i \sim E(\lambda_i) \sim \Gamma(\lambda_i, 1),\ i=1,2$ ，且 $X_1,\ X_2$ 独立。

(1) 令 $\theta = \lambda_1/\lambda_2$ ，证明： $T_1(X_1,X_2;\theta) = \theta X_1/X_2$ 是一个枢轴量，并用它构造 θ 的一个水平为 $1-\alpha$ 的置信区间；

(2) 令 $\theta = (\lambda_1,\lambda_2)$ ，证明： $T_2(X_1,X_2;\theta) = 2\lambda_1 X_1 + 2\lambda_2 X_2$ 是一个枢轴量，并用它构造 θ 的一个水平为 $1-\alpha$ 的置信区域。

证明. (1) 由 $X_i \sim \Gamma(\lambda_i,1)$ 可得 $2\lambda_i X_i \sim \Gamma(\frac{1}{2},1) \sim \chi^2(2),\ i=1,2$. 又由 X_1, X_2 独立可得

$$T_1(X_1,X_2;\theta) = \frac{\theta X_1}{X_2} = \frac{\lambda_1 X_1}{\lambda_2 X_2} \sim F(2,2).$$

易见 $T_1(X_1,X_2;\theta)$ 的分布与 θ 无关, 所以 $T_1(X_1,X_2;\theta)$ 为枢轴量. 记 $F_1 = F(2,2;\frac{\alpha}{2}),\ F_2 = F(2,2;1-\frac{\alpha}{2})$. 由 $P_\theta\{F_1 \le T_1 \le F_2\} = 1-\alpha$ 可得

$$P_\theta\{\frac{X_2}{X_1}F_1 \le \theta \le \frac{X_2}{X_1}F_2\} = 1-\alpha.$$

所以 θ 的一个水平为 $1-\alpha$ 的置信区间为 $[\frac{X_2}{X_1}F_1,\ \frac{X_2}{X_1}F_2]$.

(2) 由于 $2\lambda_i X_i \sim \chi^2(2),\ i=1,2$ 且 X_1 与 X_2 独立，所以

$$T_2(X_1,X_2;\theta) = 2\lambda_1 X_1 + 2\lambda_2 X_2 \sim \chi^2(4).$$

易见 $T_2(X_1,X_2;\theta)$ 的分布与 θ 无关，所以 $T_2(X_1,X_2;\theta)$ 是枢轴量. 根据等式

$$P_\theta\{\chi^2(4,\frac{\alpha}{2}) \le T_2 \le \chi^2(4,1-\frac{\alpha}{2})\} = 1-\alpha,$$

可知 θ 的置信域是 “两直线之间的区域”。 ∎

16. 设 $X_1,\cdots,X_n$ 为 $i.i.d.$ 样本， $X_1 \sim \Gamma(\lambda,1),\ \lambda>0$ ； $Y_1,\cdots,Y_m$ 为 $i.i.d.$ 样本， $Y_1 \sim \Gamma(\eta,1),\ \eta>0$ ，且两总体独立。试基于统计量 $T = \sum_{i=1}^n X_i / \sum_{j=1}^m Y_j$ 构造 $W = (1+\frac{\eta}{\lambda})^{-1}$ 的水平为 $1-\alpha$ 的置信上界。

解. 因为 $2\lambda T_1 \triangleq 2\lambda\sum_{i=1}^n X_i \sim \chi^2(2n)$ 与 $2\eta T_2 \triangleq 2\eta\sum_{j=1}^n Y_j \sim \chi^2(2m)$ 独立，所以

$$\frac{2\lambda T_1/2n}{2\eta T_2/2m} = \frac{\lambda}{\eta}\cdot\frac{m}{n}T = a\cdot\frac{m}{n}T \sim F(2n,2m).$$

其中 $a=\frac{\lambda}{\eta}$ ，则 $W=(1+a^{-1})^{-1}$ 为 a 的严增函数。记 $F_1=F(2n,2m;1-\alpha)$, 则由 $P\{\frac{\lambda}{\eta}\cdot\frac{m}{n}T\le F_1\}=P\{\frac{\lambda}{\eta}\le\frac{nF_1}{mT}\}=1-\alpha$ 可得

$$P\{(1+\frac{\eta}{\lambda})^{-1}\le\frac{nF_1}{nF_1+mT}\}=1-\alpha.$$

所以 $\bar{T}(X)=\frac{nF_1}{nF_1+mT}$ 为 $(1+\frac{\eta}{\lambda})^{-1}$ 的一个水平为 $1-\alpha$ 的置信上界。 ∎

17. 若 $S_i(X)$ 为参数 θ_i 的一个水平为 $1-\alpha_i$ 的置信域 $(i=1,\cdots,k)$, 则 $S(X)=\cap_{i=1}^k S_i(X)$ 为参数 $(\theta_1,\cdots,\theta_k)^T$ 的一个水平为 $1-\alpha$ 的置信域，其中 $\alpha=\sum_{i=1}^k\alpha_i$ 。

证明. 令 $A_i=\{X:\theta_i\in S_i(X)\}$ ， $\bar{A}_i$ 为 A_i 的余集， $i=1,\cdots,k$ 。则 $P(A_i)\ge 1-\alpha_i$, $P(\bar{A}_i)\le\alpha_i$, $i=1,\cdots,k$ 。因为

$$\begin{aligned}
P\{X:\theta\in S(X)\} &= P\{\bigcap_{i=1}^k\{X:\theta_i\in S_i(X)\}\}\\
&= P\{\bigcap_{i=1}^k A_i\}\ge 1-\sum_{i=1}^k P(\bar{A}_i)\\
&\ge 1-\sum_{i=1}^k\alpha_i = 1-\alpha
\end{aligned}$$

其中第一个 "$\ge$" 号用到了 Bonferroni 不等式，所以 $S(X)$ 为参数 $\theta=(\theta_1,\cdots,\theta_k)^T$ 的一个水平为 $1-\alpha$ 的置信域。 ∎

18. (1) 设 $X_1,\cdots,X_n$ 为 *i.i.d.* 样本，$X_1\sim P(\lambda_1)$; $Y_1,\cdots,Y_m$ 为 *i.i.d.* 样本，$Y_1\sim P(\lambda_2)$ 。求 $\delta=\lambda_1-\lambda_2$ 的渐近正态置信区间;

(2) 设 $X_1,\cdots,X_n$ 为 *i.i.d.* 样本， $X_1\sim b(1,p_1)$ ； $Y_1,\cdots,Y_m$ 为 *i.i.d.* 样本， $Y_1\sim b(1,p_2)$ 。求 $\delta=p_1-p_2$ 的渐近正态置信区间;

(3) 某厂对职工出勤率进行调查，甲车间随机抽取 50 人，其中一年全勤的有 40 人；乙车间随机抽取 40 人，其中一年全勤的有 35 人；求甲、乙两车间职工出勤率之差的区间估计 (置信水平为 0.95) 。

解. (1) λ_1 和 λ_2 的极大似然估计分别为 $\hat{\lambda}_1=\bar{X}$, $\hat{\lambda}_2=\bar{Y}$ 。由极大似然估计的渐近正态性可知

$$\frac{\hat{\lambda}_1-\lambda_1}{\sqrt{\lambda_1/n}}\xrightarrow{L}N(0,1),\quad \frac{\hat{\lambda}_2-\lambda_2}{\sqrt{\lambda_2/m}}\xrightarrow{L}N(0,1).$$

且两者独立， 因此有

$$\frac{(\hat{\lambda}_1-\hat{\lambda}_2)-\delta}{\sqrt{\frac{\lambda_1}{n}+\frac{\lambda_2}{m}}}\xrightarrow{L}N(0,1),\quad (m,n\to\infty)$$

由 Slutsky 定理去 1 律以及上式可得

$$\frac{(\hat{\lambda}_1-\hat{\lambda}_2)-\delta}{\sqrt{\frac{\hat{\lambda}_1}{n}+\frac{\hat{\lambda}_2}{m}}}\xrightarrow{L}N(0,1),$$

因此 $\delta=\lambda_1-\lambda_2$ 的渐近正态置信区间为

$$\left[(\bar{X}-\bar{Y})-z_{1-\frac{\alpha}{2}}\sqrt{\frac{\bar{X}}{n}+\frac{\bar{Y}}{m}},\ \ (\bar{X}-\bar{Y})+z_{1-\frac{\alpha}{2}}\sqrt{\frac{\bar{X}}{n}+\frac{\bar{Y}}{m}}\ \right]$$

(2) 由原书 (6.5.35) 式可得

$$\frac{(\bar{X}-\bar{Y})-\delta}{\sqrt{\hat{p}_1\hat{q}_1/n+\hat{p}_2\hat{q}_2/m}}\xrightarrow{L}N(0,1),$$

其中 $\hat{p}_1=\bar{X},\ \hat{q}_1=1-\bar{X},\ \hat{p}_2=\bar{Y},\ \hat{q}_2=1-\bar{Y}$ 。因此 δ 的渐近正态置信区间可表示为

$$\left[(\hat{p}_1-\hat{p}_2)-z_{1-\frac{\alpha}{2}}\sqrt{\frac{\hat{p}_1\hat{q}_1}{n}+\frac{\hat{p}_2\hat{q}_2}{m}},\ \ (\hat{p}_1-\hat{p}_2)+z_{1-\frac{\alpha}{2}}\sqrt{\frac{\hat{p}_1\hat{q}_1}{n}+\frac{\hat{p}_2\hat{q}_2}{m}}\ \right].$$

(3) 本问题可看作两个二项总体，甲乙两车间职工出勤率分别为 p_1 和 p_2 。则由以上数据可得 $\bar{x}=0.8,\ \bar{y}=0.875,\ n=50,\ m=40$ 。代入 (2) 中置信区间的表达式可得甲乙两车间职工出勤率之差的区间估计为 [-0.2260, 0.0760] 。这一结果表明，$\delta=p_1-p_2$ 更接近于负值，即乙车间职工出勤率可能更高一些。 ∎

19. 设 $X_1,\cdots,X_n$ 为 *i.i.d.* 样本， $X_1\sim E(1/\theta)\sim\Gamma(1/\theta,1)$ (指数分布) 。

(1) 证明： $T_1(X;\theta)=\sqrt{n}\frac{\bar{X}-\theta}{\theta}$ 是一渐近枢轴量 (即其渐近分布与 θ 无关) ，并用 T_1 构造 θ 的一个水平为 $1-\alpha$ 的渐近置信区间；

(2) 证明： $T_2(X;\theta)=\sqrt{n}\frac{\bar{X}-\theta}{\bar{X}}$ 是渐近枢轴量，并用 T_2 构造 θ 的一个水平为 $1-\alpha$ 的渐近置信区间；

(3) 求 θ 的基于似然比统计量、 score 统计量以及 Wald 统计量的水平为 $1-\alpha$ 的渐近置信区间。

证明. (1) 由于 $\mathrm{E}X_1=\theta,\ \mathrm{Var}(X_1)=\theta^2$ ，所以由中心极限定理可得

$$T_1(X;\theta)=\frac{\sum_{i=1}^n(X_i-\mathrm{E}X_i)}{\sqrt{\sum_{i=1}^n\mathrm{Var}(X_i)}}=\sqrt{n}\frac{\bar{X}-\theta}{\theta}\xrightarrow{L}N(0,1).\ \ (n\to\infty).$$

易见 $T_1(X;\theta)$ 的渐近分布与 θ 无关，所以 $T_1(X;\theta)$ 是渐近枢轴量。由

$$P_\theta\{-z_{1-\frac{\alpha}{2}}\le T_1(X;\theta)\le z_{1-\frac{\alpha}{2}}\}=1-\alpha$$

可得

$$P_\theta\{\sqrt{n}\bar{X}/(\sqrt{n}+z_{1-\frac{\alpha}{2}})\le\theta\le\sqrt{n}\bar{X}/(\sqrt{n}-z_{1-\frac{\alpha}{2}})\}=1-\alpha,$$

所以 $[\sqrt{n}\bar{X}/(\sqrt{n}+z_{1-\frac{\alpha}{2}}),\ \sqrt{n}\bar{X}/(\sqrt{n}-z_{1-\frac{\alpha}{2}})]$ 即是 θ 的一个水平为 $1-\alpha$ 的渐近置信区间。

(2) 由大数定律可得 $\bar{X} \xrightarrow{P} \mathrm{E}X_1 = \theta$ 。从而由 Slutsky 定理可得

$$T_2(X;\theta) = \sqrt{n}(\bar{X}-\theta)/\bar{X} = \sqrt{n}(\bar{X}-\theta)/\theta \cdot (\bar{X}/\theta)^{-1} \xrightarrow{L} N(0,1), \quad (n \to \infty).$$

易见 $T_2(X;\theta)$ 的渐近分布与 θ 无关，所以 $T_2(X;\theta)$ 是渐近枢轴量。由

$$P_\theta\{-z_{1-\frac{\alpha}{2}} \le T_2(X;\theta) \le z_{1-\frac{\alpha}{2}}\} = 1-\alpha$$

可得

$$P_\theta\{(\sqrt{n}-z_{1-\frac{\alpha}{2}})\bar{X}/\sqrt{n} \le \theta \le (\sqrt{n}+z_{1-\frac{\alpha}{2}})\bar{X}/\sqrt{n}\} = 1-\alpha.$$

所以 $[(\sqrt{n}-z_{1-\frac{\alpha}{2}})\bar{X}/\sqrt{n},\ (\sqrt{n}+z_{1-\frac{\alpha}{2}})\bar{X}/\sqrt{n}]$ 即是 θ 的一个水平为 $1-\alpha$ 的渐近置信区间。

(3) 由假设可知

$$f(x,\theta) = \frac{1}{\theta^n}e^{-T/\theta}; \quad L(\theta) = -\frac{1}{\theta}n\bar{X} - n\log\theta; \quad T = \sum_{i=1}^n X_i = n\bar{X}.$$

i) 根据原书 (7.1.12) 式可知，似然置信域由 $P_\theta\{LR(\theta) \le \chi^2(1,1-\alpha)\} = 1-\alpha$ 决定，其中 $LR(\theta) = 2\{L(\hat{\theta}) - L(\theta)\}$ 。以上公式以及 $\hat{\theta} = \bar{X}$ 代入 $LR(\theta)$ 可得

$$LR(\theta) = 2\{n\log\theta + n\bar{X}/\theta - n\log\bar{X} - n\}.$$

因此 θ 的一个水平为 $1-\alpha$ 的置信域可表示为 $\{\theta:\ n\log\theta + n\bar{X}/\theta \le c\}$ ，其中 $c = n\log\bar{X} + n + \chi^2(1,1-\alpha)/2 > 0$ 。显然这一置信域的求解比较困难，直观上概述如下。记 $g(\theta) = n\log\theta + n\bar{X}/\theta$ ，则有 $g'(\theta) = n(\theta-\bar{X})/\theta^2$ ， $g''(\theta) = n(2\bar{X}-\theta)/\theta^3$ 。因此 $g(\theta)$ 在 $\theta = \bar{X} = \hat{\theta}$ 右面递增，左面递减；而且当 $\theta < 2\hat{\theta}$ 时 (这是合理的) $g''(\theta) > 0$ ，因而 $g(\theta)$ 是凸函数。所以必存在 $\hat{\theta}_1$ 和 $\hat{\theta}_2$ ，使得 $\hat{\theta}_1 < \theta < \hat{\theta}_2$ 时 $g(\theta) < c$ (可参见第六章 42 题的图) 。从而 θ 的一个水平为 $1-\alpha$ 的置信域为 $[\hat{\theta}_1,\ \hat{\theta}_2]$ 。

ii) 基于 score 统计量的置信域由 $P_\theta\{SC(\theta) \le \chi^2(1,1-\alpha)\} = 1-\alpha$ 决定，其中

$$SC = \frac{\partial L(\theta)}{\partial\theta} \cdot I(\theta)^{-1} \cdot \frac{\partial L(\theta)}{\partial\theta}.$$

其中 $I(\theta)$ 为 Fisher 信息。由假设可知

$$\frac{\partial L(\theta)}{\partial\theta} = \frac{n\bar{X}}{\theta^2} - \frac{n}{\theta}, \quad I(\theta) = \frac{n}{\theta^2}.$$

所以 score 统计量为

$$SC = \frac{\theta^2}{n}(\frac{n\bar{X}}{\theta^2} - \frac{n}{\theta})^2 = n(\frac{\bar{X}}{\theta} - 1)^2.$$

因而由 $P_\theta\{SC \le \chi^2(1,1-\alpha)\} = 1-\alpha$ 可得

$$P_\theta\left\{\bar{X}/(1+\sqrt{\chi^2(1,1-\alpha)/n}) \le \theta \le \bar{X}/(1-\sqrt{\chi^2(1,1-\alpha)/n})\right\} = 1-\alpha.$$

所以 θ 的基于 score 统计量的一个水平为 $1-\alpha$ 的置信区间为

$$\left[\bar{X}/(1+\sqrt{\chi^2(1,1-\alpha)/n}),\quad \bar{X}/(1-\sqrt{\chi^2(1,1-\alpha)/n})\right].$$

iii) 基于 Wald 统计量的置信域由 $P_\theta\{WD(\theta) \le \chi^2(1,1-\alpha)\} = 1-\alpha$ 决定，其中

$$WD(\theta) = (\hat\theta - \theta)I(\hat\theta)(\hat\theta - \theta).$$

由于 $\hat\theta = \bar X,\ I(\theta) = n/\theta^2$，所以 Wald 统计量为 $WD(\theta) = n(\bar X - \theta)^2/\bar X^2$。由 $P_\theta\{WD(\theta) \le \chi^2(1,1-\alpha)\} = 1-\alpha$ 可得

$$P_\theta\left\{\bar X - \sqrt{\bar X^2\chi^2(1,1-\alpha)/n} \le \theta \le \bar X + \sqrt{\bar X^2\chi^2(1,1-\alpha)/n}\right\} = 1-\alpha.$$

所以 θ 的基于 Wald 统计量的 $1-\alpha$ 的渐近置信区间为

$$\left[\bar X - \sqrt{\bar X^2\chi^2(1,1-\alpha)/n},\quad \bar X + \sqrt{\bar X^2\chi^2(1,1-\alpha)/n}\right].$$

∎

20. 设 $X_1,\cdots,X_n$ 为 *i.i.d.* 样本， $X_1 \sim b(1,p),\ 0<p<1$. 求 p 的基于似然比统计量、score 统计量以及 Wald 统计量的水平为 $1-\alpha$ 的渐近置信区间。

解. 相应的对数似然函数和 p 的极大似然估计分别为

$$L(p) = \sum_{i=1}^n x_i \log p + (n - \sum_{i=1}^n x_i)\log(1-p),\quad \hat p = \bar X$$

i) 似然置信域由 $P_p\{LR(p) \le \chi^2(1,1-\alpha)\} = 1-\alpha$ 决定，记 $T = \sum_{i=1}^n X_i$，则 $L(p) = T\log p + (n-T)\log(1-p)$， $L(\hat p) = T\log\frac{T}{n} + (n-T)\log(1-\frac{T}{n})$。所以似然比统计量为

$$LR(p) = 2[L(\hat p) - L(p)] = 2\log[(\frac{T}{n})^T(1-\frac{T}{n})^T/(p^T(1-p)^T)].$$

因此 p 的水平为 $1-\alpha$ 的渐近置信区间应满足 $LR(p) \le \chi^2(1,1-\alpha)$，即

$$\{p:\ p^T(1-p)^T \ge (\frac{T}{n})^T(1-\frac{T}{n})^T \cdot \exp\{-\frac{1}{2}\chi^2(1,1-\alpha)\}\}.$$

当 $0<p<1$ 时，由于 $p^T(1-p)^T$ 是 p 的严格上凸函数，所以必存在 $\underline{p}(T),\ \bar p(T)$，使得 $\underline{p}(T) \le p \le \bar p(T)$ 时上式成立。即

$$P_p\{LR(p) \le \chi^2(1,1-\alpha)\} = P_p\{\underline{p}(T) \le p \le \bar p(T)\} = 1-\alpha$$

所以 p 的一个水平为 $1-\alpha$ 的渐近置信区间为 $[\underline{p}(T),\ \bar p(T)]$。

ii) 基于 score 统计量的置信域由 $P_\theta\{SC(\theta) \le \chi^2(1,1-\alpha)\} = 1-\alpha$ 决定，其中

$$SC = \{\frac{\partial L}{\partial p}(I(p))^{-1}\frac{\partial L}{\partial p}\}$$

由于 $\frac{\partial L}{\partial p} = \frac{T}{p} - \frac{n-T}{1-p} = \frac{T-np}{p(1-p)},\ I(p) = \frac{n}{p(1-p)}$，所以 score 统计量为

$$SC(p) = \frac{(T-np)^2}{p^2(1-p)^2}\cdot\frac{p(1-p)}{n} = \frac{(T-np)^2}{np(1-p)}.$$

因此 p 的水平为 $1-\alpha$ 的渐近置信区间应满足 $SC(p) \le \chi^2(1,1-\alpha)$，即

$$\{p:\ (T-np)^2 \le np(1-p)\chi^2(1,1-\alpha)\}.$$

由于

$$P_p\{(T-np)^2 \le np(1-p)\chi^2(1,1-\alpha)\} = 1-\alpha,$$

上式右端为 p 二次式，经反解可得

$$P_p\left\{\frac{2T+\chi^2(1,1-\alpha)-\Delta}{2(n+\chi^2(1,1-\alpha))} \le p \le \frac{2T+\chi^2(1,1-\alpha)+\Delta}{2(n+\chi^2(1,1-\alpha))}\right\} = 1-\alpha.$$

其中 $\Delta = \sqrt{\chi^2(1,1-\alpha)[\chi^2(1,1-\alpha)+4T-4T^2/n]}$. 所以 p 的一个水平为 $1-\alpha$ 的置信区间为

$$\left[\frac{2T+\chi^2(1,1-\alpha)-\Delta}{2(n+\chi^2(1,1-\alpha))},\quad \frac{2T+\chi^2(1,1-\alpha)+\Delta}{2(n+\chi^2(1,1-\alpha))}\right].$$

iii) 基于 Wald 统计量的置信域由 $P_p\{WD(p) \le \chi^2(1,1-\alpha)\} = 1-\alpha$ 决定，其中

$$WD(p) = (\hat{p}-p)I(\hat{p})(\hat{p}-p).$$

由于 $\hat{p} = \bar{X}$, $I(p) = \frac{n}{p(1-p)}$ ，所以 Wald 统计量为 $WD(p) = n(\bar{X}-p)^2/[\bar{X}(1-\bar{X})]$ 。由 $WD(p) \le \chi^2(1,1-\alpha)$ 反解可得

$$\begin{aligned}
& P_p\{WD(p) \le \chi^2(1,1-\alpha)\} \\
= \quad & P_p\left\{\bar{X} - \sqrt{\frac{\bar{X}(1-\bar{X})}{n}\chi^2(1,1-\alpha)} \le p \le \bar{X} + \sqrt{\frac{\bar{X}(1-\bar{X})}{n}\chi^2(1,1-\alpha)}\right\} \\
= \quad & 1-\alpha
\end{aligned}$$

所以 p 的基于 Wald 统计量的水平为 $1-\alpha$ 的渐近置信区间为

$$\left[\bar{X} - \sqrt{\frac{\bar{X}(1-\bar{X})}{n}\chi^2(1,1-\alpha)},\quad \bar{X} + \sqrt{\frac{\bar{X}(1-\bar{X})}{n}\chi^2(1,1-\alpha)}\ \right]. \qquad \blacksquare$$

21. 设 $X_1,\cdots,X_n$ 为 *i.i.d.* 样本， $X_1 \sim N(\mu,\sigma^2)$ 。求 $\theta = (\mu,\sigma^2)^T$ 的基于似然比统计量、 score 统计量以及 Wald 统计量的水平为 $1-\alpha$ 的渐近置信域。

解. 对数似然函数为

$$L(\theta) = -\frac{1}{2\sigma^2}\sum_{i=1}^n (x_i-\mu)^2 - \frac{n}{2}\log\sigma^2 - \frac{n}{2}\log 2\pi.$$

$\theta = (\mu,\sigma^2)^T$ 的极大似然估计为 $\hat{\theta} = (\hat{\mu},\ \hat{\sigma}^2)^T = (\bar{X},\ \frac{1}{n}\sum_{i=1}^n (X_i-\bar{X})^2)^T$ 。

i) 似然置信域由 $P_\theta\{LR(\theta) \le \chi^2(2,1-\alpha)\} = 1-\alpha$ 决定，这时似然比统计量为

$$\begin{aligned}
LR(\theta) &= 2[L(\hat{\theta}) - L(\theta)] \\
&= 2\{-\frac{n}{2} - \frac{n}{2}\log[\frac{1}{n}\sum_{i=1}^n (X_i-\bar{X})^2] + \frac{1}{2\sigma^2}\sum_{i=1}^n (X_i-\mu)^2 + \frac{n}{2}\log\sigma^2\} \\
&= \frac{1}{\sigma^2}\sum_{i=1}^n (X_i-\mu)^2 + n\log[n\sigma^2/\sum_{i=1}^n (X_i-\bar{X})^2] - n
\end{aligned}$$

所以 θ 的基于似然比统计量的水平为 $1-\alpha$ 的渐近置信域为满足以下条件的区域

$$C_1(X) = \{\theta:\ \frac{1}{\sigma^2}\sum_{i=1}^n (X_i-\mu)^2 + n\log[n\sigma^2/\sum_{i=1}^n (X_i-\bar{X})^2] - n \le \chi^2(2,1-\alpha)\}.$$

ii) 基于 score 统计量的置信域由 $P_\theta\{SC(\theta) \le \chi^2(2, 1-\alpha)\} = 1-\alpha$ 决定，其中

$$SC(\theta) = (\frac{\partial L}{\partial \mu}\ \frac{\partial L}{\partial \sigma^2})[I(\theta)]^{-1}(\frac{\partial L}{\partial \mu}\ \frac{\partial L}{\partial \sigma^2})^T.$$

因为

$$\frac{\partial L}{\partial \mu} = \frac{n}{\sigma^2}(\bar{x}-\mu),\quad \frac{\partial L}{\partial \sigma^2} = \frac{1}{2\sigma^4}\sum_{i=1}^n (x_i-\mu)^2 - \frac{n}{2\sigma^2},$$

$$I(\theta) = \begin{pmatrix} \frac{n}{\sigma^2} & 0 \\ 0 & \frac{n}{2\sigma^4} \end{pmatrix}.$$

所以 score 统计量为

$$\begin{aligned} SC(\theta) &= (\frac{\partial L}{\partial \mu}\ \frac{\partial L}{\partial \sigma^2})(I(\theta))^{-1}(\frac{\partial L}{\partial \mu}\ \frac{\partial L}{\partial \sigma^2})^T \\ &= \frac{n}{\sigma^2}(\bar{X}-\mu)^2 + \frac{n}{2\sigma^4}[\frac{1}{n}\sum_{i=1}^n (X_i-\mu)^2 - \sigma^2]^2 \end{aligned}$$

所以 θ 的基于 score 统计量的水平为 $1-\alpha$ 的渐近置信域为满足以下条件的区域

$$C_2(X) = \{\theta:\ \frac{n}{\sigma^2}(\bar{X}-\mu)^2 + \frac{n}{2\sigma^4}[\frac{1}{n}\sum_{i=1}^n (X_i-\mu)^2 - \sigma^2]^2 \le \chi^2(2, 1-\alpha)\}.$$

ii) 基于 Wald 统计量的置信域由 $P_\theta\{WD(\theta) \le \chi^2(2, 1-\alpha)\} = 1-\alpha$ 决定，其中

$$\begin{aligned} WD(\theta) &= (\hat{\theta}-\theta)^T I(\hat{\theta})(\hat{\theta}-\theta) \\ &= \frac{n}{\hat{\sigma}^2}(\bar{X}-\mu)^2 + \frac{n}{2\hat{\sigma}^4}[\frac{1}{n}\sum_{i=1}^n (X_i-\bar{X})^2 - \sigma^2]^2. \end{aligned}$$

所以 θ 的基于 Wald 统计量的水平为 $1-\alpha$ 的渐近置信域为满足以下条件的区域 $C_3(X) = \{\theta:\ WD(\theta) \le \chi^2(2, 1-\alpha)\}$. ∎

22. 设 $X_1, \cdots, X_n$ 为 *i.i.d.* 样本， X_1 服从均匀分布 $R(0, \theta)$, 应用定理 7.1.1 求 θ 的水平为 $1-\alpha$ 的置信区间。

解. 完备充分统计量 $T = X_{(n)}$ 的分布函数为

$$F_T(t;\theta) = \theta^{-n}t^n I\{0 \le t \le \theta\}.$$

显然， $F_T(t;\theta)$ 为 θ 的严格减函数，并且处处连续。由定理 7.1.1 可知， θ 的水平为 α 的置信区间 $[\underline{\theta},\ \bar{\theta}] = [\underline{\theta}(T),\ \bar{\theta}(T)]$ 应满足方程

$$F_T(t;\bar{\theta}) = \alpha/2,\quad F_T(t-0;\underline{\theta}) = 1-\alpha/2.$$

由于 $F_T(t;\theta)$ 是 t 的连续函数，所以

$$F_T(t-0;\underline{\theta}) = F_T(t;\underline{\theta}) = \underline{\theta}^{-n}t^n = 1-\alpha/2.$$

直接求解上面的方程可得 $\underline{\theta} = (1-\alpha/2)^{-\frac{1}{n}}t$ 。同理，解方程 $F_T(t;\bar{\theta}) = \bar{\theta}^{-n}t^n = \alpha/2$ 可得 $\bar{\theta} = (\alpha/2)^{-\frac{1}{n}}t$ 。

所以，θ 的水平为 $1-\alpha$ 的置信区间为 $[(1-\alpha/2)^{-\frac{1}{n}}X_{(n)},\ (\alpha/2)^{-\frac{1}{n}}X_{(n)}]$ 。 ∎

注. 我们亦可根据以下方程求 θ 的水平为 $1-\alpha$ 的置信区间：

$$F_T(t;\bar{\theta})=\alpha_1,\quad F_T(t-0;\underline{\theta})=1-\alpha_2,$$

其中 $\alpha_1\geq 0,\ \alpha_2\geq 0$ ，且 $\alpha_1+\alpha_2=\alpha$ 。由此可根据不同需要选取不同的 $\alpha_1,\ \alpha_2$ 。 ∎

23. ★ 设 $X_1,\cdots,X_n$ 为 *i.i.d.* 样本， $X_1\sim b(1,\theta),\ 0<\theta<1$ 。应用定理 7.1.1 证明： θ 的水平为 $1-\alpha$ 的置信区间可表示为 $[\underline{\theta}\ ,\ \bar{\theta}]$ ，其中

$$\underline{\theta}=\frac{T}{T+(n-T+1)F(2n-2T+2,\ 2T;\ 1-\alpha/2)};$$

$$\bar{\theta}=\frac{(T+1)F(2T+2,\ 2n-2T;\ 1-\alpha/2)}{(n-T)+(T+1)F(2T+2,\ 2n-2T;\ 1-\alpha/2)}.$$

其中 $T=\sum_{i=1}^n X_i$ (提示：参见第一章， T 的分布函数可由不完全 β 函数表示，而 β 分布可由 F 分布表示) 。

证明. $T=\sum_{i=1}^n$ 是关于 θ 的完备充分统计量，且 $T\sim b(n,\theta)$ 。由第一章习题 11 知， T 的分布函数可表示为不完全 β 函数的形式

$$G_T(t,\theta)=I_{1-\theta}(n-t,\ t+1)=\int_0^{1-\theta}\frac{\Gamma(n+1)}{\Gamma(n-t)\Gamma(t+1)}u^{n-t-1}(1-u)^t du,\quad t=0,1,\cdots,n,$$

其中 $I_{1-\theta}(n-t,\ t+1)$ 是不完全 β 函数。易见， $G_T(t,\theta)$ 为 θ 的严格减函数，并且处处连续。由定理 7.1.1 可知， θ 的水平为 $1-\alpha$ 的置信区间 $[\underline{\theta},\ \bar{\theta}]=[\underline{\theta}(T),\ \bar{\theta}(T)]$ 应满足方程

$$G_T(t,\bar{\theta})=\frac{\alpha}{2},\quad G_T(t-0,\underline{\theta})=1-\frac{\alpha}{2}.$$

我们先求解 $G_T(t-0,\underline{\theta})=1-\alpha/2$ 。由于 $T\sim b(n,\theta)$ 为离散型分布，因此当 $t>0$ 时，我们有

$$G_T(t-0,\underline{\theta})=P_{\underline{\theta}}(T<t)=P_{\underline{\theta}}(T\leq t-1)=G_T(t-1,\underline{\theta})=1-\frac{\alpha}{2}.$$

即

$$\begin{aligned}I_{1-\theta}(n-t+1,\ t)&=\int_0^{1-\underline{\theta}}\frac{\Gamma(n+1)}{\Gamma(n-t+1)\Gamma(t)}u^{n-t}(1-u)^{t-1}du\\&=BE(1-\underline{\theta};n-t+1,t)=1-\frac{\alpha}{2}.\end{aligned}\tag{1}$$

其中 $BE(x;m,n)$ 表示 β 分布 $BE(m,n)$ 的分布函数。由第一章 β 分布定理的推论可知，若 $B\sim BE(m,n)$ ，则

$$F=\frac{B}{1-B}\frac{n}{m}\sim \text{F 分布 } F(2m,2n).$$

在 (1) 式中记 $x=1-\underline{\theta};\ m=n-t+1,\ n=t$ ，则 (1) 式等价于

$$F(\frac{1-\underline{\theta}}{1-(1-\underline{\theta})}\frac{t}{n-t+1};\ 2(n-t+1),\ 2t)=1-\frac{\alpha}{2}$$

其中 $F(x;m,n)$ 表示 F 分布 $F(m,n)$ 的分布函数。根据分位数 (即反函数) 的关系，上式等价于方程

$$\frac{1-\underline{\theta}}{\underline{\theta}}\frac{t}{n-t+1}=F(2(n-t+1),\ 2t;\ 1-\frac{\alpha}{2})$$

由此可得

$$\underline{\theta}(T)=\frac{T}{T+(n-T+1)F(2n-2T+2,\ 2T;\ 1-\alpha/2)}.$$

同理，当 $t<n$ 时，由

$$G_T(t,\bar{\theta})=I_{1-\bar{\theta}}(n-t,t+1)=BE(1-\bar{\theta};n-t,t+1)=\frac{\alpha}{2}$$

可得

$$F(\frac{1-\bar{\theta}}{\bar{\theta}}\frac{t+1}{n-t};\ 2(n-t),\ 2(t+1))=\frac{\alpha}{2}.$$

从而可通过解方程

$$\frac{1-\bar{\theta}}{\bar{\theta}}\frac{t+1}{n-t}=F(2(n-t),\ 2(t+1);\ \frac{\alpha}{2})$$

得到

$$\bar{\theta}=\frac{(T+1)F(2T+2,\ 2n-2T;\ 1-\alpha/2)}{(n-T)+(T+1)F(2T+2,\ 2n-2T;\ 1-\alpha/2)},$$

以上推导中用到了 $F(2(n-T),\ 2(T+1);\ \frac{\alpha}{2})=[F(2(T+1),\ 2(n-T);\ 1-\frac{\alpha}{2})]^{-1}$(可参见第一章习题 2) 。

所以，当 $0<T<n$ 时 θ 的水平为 $1-\alpha$ 的置信区间可表示为 $[\underline{\theta}\ ,\ \bar{\theta}]$ ，其中 $\underline{\theta}\ ,\ \bar{\theta}$ 如上所示。

注意，当 $T=0$ 时，我们可取 $\underline{\theta}=0$ ，此时 θ 的水平为 $1-\alpha$ 的置信区间可表示为 $[0,\ \frac{F(2,2n;1-\alpha)}{n+F(2,2n;1-\alpha)}]$ ；而当 $T=n$ 时，可取 $\bar{\theta}=1$ 。此时 θ 的水平为 $1-\alpha$ 的置信区间可表示为 $[\frac{n}{n+F(2,2n;1-\alpha)},\ 1]$ 。 ∎

24. ★ 设 T 服从负二项分布 $NB(\theta,r),\ 0<\theta<1$ ， r 已知。应用定理 7.1.3 证明： θ 的水平为 $1-\alpha$ 的置信区间可表示为 $[\underline{\theta}\ ,\ \bar{\theta}]$ ，其中

$$\underline{\theta}=\frac{r}{r+(T+1)F(2T+2,\ 2r;\ 1-\alpha/2)};$$

$$\bar{\theta}=\frac{rF(2r,\ 2T;\ 1-\alpha/2)}{T+rF(2r,\ 2T;\ 1-\alpha/2)}.$$

证明. 由第一章习题 12 知， T 的分布函数可表示为

$$G_T(t;\theta)=I_\theta(r,t+1)=\int_0^\theta\frac{\Gamma(r+t+1)}{\Gamma(r)\Gamma(t+1)}u^{r-1}(1-u)^t du,\quad t=0,1,2\cdots$$

其中 $I_\theta(r,t+1)$ 是不完全 β 函数。易见， $G_T(t;\theta)$ 是 θ 的严格增函数，并且处处连续，所以由定理 7.1.3 可知， θ 的水平为 $1-\alpha$ 的置信区间 $[\underline{\theta},\ \bar{\theta}]=[\underline{\theta}(T),\ \bar{\theta}(T)]$ 应满足方程

$$G_T(t,\underline{\theta})=\frac{\alpha}{2},\quad G_T(t-0,\bar{\theta})=1-\frac{\alpha}{2}.$$

以下解法与上一题完全类似。我们先求解 $G_T(t,\underline{\theta})=\alpha/2$ 。由 β 分布和 F 分布的关系可得

$$G_T(t,\underline{\theta})=BE(\underline{\theta};r,t+1)=F(\frac{\underline{\theta}}{1-\underline{\theta}}\frac{t+1}{r};\ 2r,\ 2(t+1))=\frac{\alpha}{2},$$

其中 $BE(x;m,n)$ 和 $F(x;m,n)$ 分别表示 β 分布 $BE(m,n)$ 和 F 分布 $F(m,n)$ 的分布函数。所以反解可得

$$\frac{\underline{\theta}}{1-\underline{\theta}}\frac{t+1}{r}=F(2r,\ 2(t+1),\ \frac{\alpha}{2})=[F(2(t+1),2r,1-\frac{\alpha}{2})]^{-1}.$$

由上式可解得

$$\underline{\theta}=\frac{r}{r+(T+1)F(2T+2,\ 2r;\ 1-\alpha/2)};$$

由于 $T\sim NB(\theta,r)$ 为离散型分布，因此

$$\begin{aligned}G_T(t-0,\bar{\theta}) &= P_{\bar{\theta}}(T<t)=P_{\bar{\theta}}(T\le t-1)=G_T(t-1,\bar{\theta})\\ &= BE(\bar{\theta},r,t)=F(\frac{\bar{\theta}}{1-\bar{\theta}}\frac{t}{r};\ 2r,\ 2t)=1-\frac{\alpha}{2}\end{aligned}$$

上述方程等价与

$$\frac{\bar{\theta}}{1-\bar{\theta}}\frac{t}{r}=F(2r,\ 2t;\ 1-\frac{\alpha}{2}),$$

解上面的方程可得

$$\bar{\theta}=\frac{rF(2r,\ 2T;\ 1-\alpha/2)}{T+rF(2r,\ 2T;\ 1-\alpha/2)}.$$

所以 θ 的水平为 $1-\alpha$ 的置信区间可表示为 $[\underline{\theta}\ ,\ \bar{\theta}]$ ，其中 $\underline{\theta}$, $\bar{\theta}$ 如上所示。 ∎

25. 证明定理 7.1.3 的结论。

证明. (1) 因为 $F_T(t;\theta)$ 为 θ 的增函数，所以它为 $\delta=-\theta$ 的减函数。由定理 7.1.1 可知，若 $\bar{\delta}(t)=\sup\{\delta:F_T(t;\theta)\ge\alpha\}$ ，则 $\bar{\delta}(T)$ 为 δ 的水平为 $1-\alpha$ 的置信上限。由上、下确界的性质可知

$$\bar{\delta}(t)=\sup\{\delta:F_T(t;\theta)\ge\alpha\}=\sup\{-\theta:F_T(t;\theta)\ge\alpha\}=-\inf\{\theta:F_T(t;\theta)\ge\alpha\},$$

由于

$$\begin{aligned}P_\theta\{\delta\le\bar{\delta}(T)\} &= P_\theta\{-\theta\le-\inf\{\theta:F_T(T;\theta)\ge\alpha\}\}\\ &= P_\theta\{\theta\ge\inf\{\theta:F_T(T;\theta)\ge\alpha\}\}\\ &= 1-\alpha\end{aligned}$$

所以， θ 的水平为 $1-\alpha$ 的置信下限为 $\underline{\theta}(T)=\inf\{\theta:F_T(T;\theta)\ge\alpha\}$ 。

同理可证 θ 的水平为 $1-\alpha$ 的置信上限为 $\bar{\theta}(T)=\sup\{\theta:F_T(T-0;\theta)\le1-\alpha\}$ 。

(2) 与定理 7.1.1 第 (2) 部分的证明基本一样，此处从略。 ∎

注. 我们完全可以根据分位数的定义与性质，应用证明定理 7.1.1 (1) 的方法来证明本定理的第 (1) 部分。 ∎

26. ★ 设 $f(x)$ 是一密度函数，它在 $[x_-,\ x_+]$ 上非零，在 $[x_-,\ x_+]$ 以外等于零， $-\infty \le x_- < x_+ \le +\infty$ 。

(1) 若 $f(x)$ 在 $[x_-,\ x_+]$ 上严格递减，证明：在所有满足 $\int_a^b f(x)dx = 1-\alpha$ 的区间 [a,b] 中，当取 $a = x_-,\ b$ 使 $\int_{x_-}^b f(x)dx = 1-\alpha$ 的 $a,\ b$ 时，所得区间长度最短;

(2) 当 $f(x)$ 在 $[x_-,\ x_+]$ 上严格递增时，证明与 (1) 类似的结论；并用 (1) 或 (2) 来证明例 7.1.3 中所得的区间 $[X_{(n)}, \alpha^{-\frac{1}{n}}X_{(n)}]$ 在所有满足例 7.1.3 要求的区间中是最短的。

证明. (1) 取 x_0 使 $\int_{x_-}^{x_0} f(x)dx = 1-\alpha$ 。以下分 3 种情形来证明：对一切满足 $\int_a^b f(x)dx = 1-\alpha$ 的 $a,\ b$ ，都有 $x_0 - x_- \le b-a$ 。

i) 若 $a < x_-$ ，则由于 $\int_a^{x_-} f(x)dx = 0$ ，因此由 $\int_a^b f(x)dx = \int_{x_-}^b f(x)dx = 1-\alpha$ 可知 $b = x_0$ 。此时，显然有 $x_0 - x_- < b-a$ 。

ii) 若 $a > x_0$ (见图) ，则由积分中值定理可得

$$\int_{x_-}^{x_0} f(x)dx = f(\xi)(x_0 - x_-) = \int_a^b f(x)dx = f(\eta)(b-a) = 1-\alpha. \tag{1}$$

由于 $f(x)$ 在 $[x_-,\ x_0]$ 上的值必大于 $f(x)$ 在 $[a,\ b]$ 上的值，因此必有 $f(\xi) > f(\eta)$ ，所以由以上等式可得 $x_0 - x_- < b-a$ 。

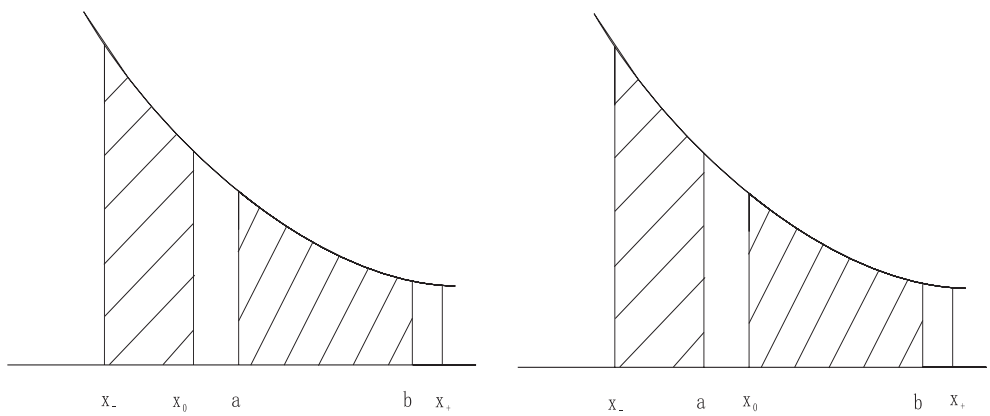

iii) 若 $x_- < a < x_0$ (见图) ，则有

$$\int_{x_-}^{x_0} f(x)dx = \int_{x_-}^{a} f(x)dx + \int_a^{x_0} f(x)dx = 1-\alpha;$$

$$\int_a^b f(x)dx = \int_a^{x_0} f(x)dx + \int_{x_0}^b f(x)dx = 1-\alpha.$$

因此有 $\int_{x_-}^a f(x)dx = \int_{x_0}^b f(x)dx$ ，由于 $f(x)$ 在 $[x_-,\ a]$ 上的值必大于 $f(x)$ 在 $[x_0,\ b]$ 上的值，因此与 ii) 类似，必有 $b - x_0 > a - x_-$ 。所以有 $b-a = (b-x_0)+(x_0-a) > (x_0-a)+(a-x_-) = x_0 - x_-$ 。

(2) 与 (1) 类似的结论如下：若 $f(x)$ 在 $[x_-,\ x_+]$ 上严格递增，则在所有满足 $\int_a^b f(x)dx = 1-\alpha$ 的区间 $[a,\ b]$ 中，当取 $b = x_+,\ a$ 使 $\int_a^{x_+} f(x)dx = 1-\alpha$ 的 $a,\ b$ 时，所得区间长度最短。其证明与 (1) 类似，从略。

下面用 (1) 的结论来证明：在所有满足例 7.1.3 要求的区间中，区间 $[X_{(n)}, \alpha^{-\frac{1}{n}}X_{(n)}]$ 的长度是最短的。 根据例 7.1.3 ， θ 的置信区间可取为 $[X_{(n)}/b,\ X_{(n)}/a]$ ，而 $a,\ b$ 满足

$$P_\theta\{a \le \frac{X_{(n)}}{\theta} \le b\} = \int_a^b ny^{n-1}I\{0 \le y \le 1\}dy = 1-\alpha.$$

其中 $0 \le a < b \le 1$ 。我们要在以上约束条件下，求 $[X_{(n)}/b,\ X_{(n)}/a]$ 的区间长度最短，即求 $1/a - 1/b$ 最小的解。为此，对以上积分做变换： $z = 1/y$ ，则有

$$\int_a^b ny^{n-1}I\{0 \le y \le 1\}dy = \int_{1/b}^{1/a} nz^{-(n+1)}I\{1 \le z < \infty\}dz = 1-\alpha.$$

易见 $f(z) = nz^{-(n+1)}I\{1 \le z < +\infty\}$ 为区间 $[1,\ +\infty)$ 上的严减函数，因此由 (1) 的结论可知， $1/b = 1$ ，并且 $1/a$ 满足以上约束条件时， $1/a - 1/b$ 最小。由此可得

$$\int_1^{1/a} nz^{-(n+1)}dz = 1-\alpha; \quad a = \sqrt[n]{\alpha}.$$

因此， θ 的区间长度最短的置信区间为 $[X_{(n)},\ X_{(n)}/\sqrt[n]{\alpha}]$ 。 ∎

27. 设 $X_1, \cdots, X_n$ 为 *i.i.d.* 样本， $X_1 \sim \mu + \Gamma(1,1)$ 。试在 μ 的水平为 $1-\alpha$ 的置信区间类 $[X_{(1)}+c,\ X_{(1)}+d]$ 中，找一个长度最短的置信区间。

解. 由于 $X_{(1)} \sim \mu + \Gamma(n,1)$, 因此有 $T = 2n(X_{(1)} - \mu) \sim \chi^2(2)$ 。由于 $[X_{(1)}+c,\ X_{(1)}+d]$ 是 μ 的水平为 $1-\alpha$ 的置信区间，所以

$$P_\mu\{X_{(1)} + c \le \mu \le X_{(1)} + d\} = 1-\alpha.$$

由此可得

$$P_\mu\{-2nd \le 2n(X_{(1)} - \mu) \le -2nc\} = 1-\alpha.$$

该式等价于

$$\int_a^b \chi^2(2,x)dx = 1-\alpha; \quad a = -2nd,\ b = -2nc.$$

其中 $\chi^2(2,x)$ 表示自由度为 2 的卡方分布的密度函数。 所以要使区间 $[X_{(1)}+c,\ X_{(1)}+d]$ 的长度 $d-c$ 最短，等价于使 $b-a = 2nd - 2nc$ 最小。由于 $\chi^2(2,x) = \frac{1}{2}e^{-\frac{1}{2}x}$ 在 $[0,+\infty)$ 上为非负严减函数，所以由习题 26 (1) 的结论可知，当取 $a = -2nd = 0$, 即 $d = 0$ 时，所得区间长度最短。此时由 $\int_0^b \chi^2(2,x)dx = 1-\alpha$ 可得 $b = -2nc = \chi^2(2, 1-\alpha)$ ，即 $c = -\frac{1}{2n}\chi^2(2,1-\alpha)$ 。所以在 μ 的水平为 $1-\alpha$ 的置信区间类 $[X_{(1)}+c,\ X_{(1)}+d]$ 中，长度最短的置信区间为 $[X_{(1)} - \frac{1}{2n}\chi^2(2,1-\alpha),\ X_{(1)}]$ 。 ∎

28.* (1) 设 $U(X)$ 是一个取正值的统计量。$\frac{T-\theta}{U}$ 是一个枢轴量。其密度函数 $f(x)$ 在 x_0 是单峰的 (即当 $x \le x_0$ 时， $f(x)$ 不降；当 $x \ge x_0$ 时， $f(x)$ 不增) 。考虑 θ 的如下置信区间类 $\mathcal{C} = \{[T-bU,\ T-aU] : \int_a^b f(x)dx = 1-\alpha\}$, 若 $[T-b_*U,\ T-a_*U] \in \mathcal{C},\ f(a_*) = f(b_*) > 0$, 且 $a_* \le x_0 \le b_*$, 则 $[T-b_*U,\ T-a_*U]$ 是 $\mathcal{C}$ 中长度最短的区间 (提示：因 $\mathcal{C}$ 中任一区间的长度都是 $(b-a)U$ ，所以只需证若 $a < b$ 且 $b-a < b_*-a_*$ ，则有 $\int_a^b f(x)dx < 1-\alpha$) ；

(2) 考虑例 7.1.1 ，即 $X_1, \cdots, X_n$ 为 *i.i.d.* 样本， $X_1 \sim N(\mu, \sigma^2)$ ，其中 μ, σ^2 都未知；试在 μ 的置信区间类： $\{[\bar{X} - bS/\sqrt{n},\ \bar{X} - aS/\sqrt{n}] : \int_a^b f(x)dx = 1-\alpha\ \}$ 中找一个长度最短的置信区间，其中 $S = (n-1)^{-1}\sum_{i=1}^n (X_i - \bar{X})^2$ 。

(1) **证明**. 因为 $\mathcal{C}$ 中任一个区间的长度都是 $(b-a)U$ ，所以由题意我们只须证明：若 $a<b$ 且 $b-a<b_*-a_*$ ，则有 $\int_a^b f(x)dx<1-\alpha$ 。

设 $a<b,\ b-a<b_*-a_*$ ，且不妨设 $a\le a_*$ (当 $a>a_*$ 时，证明类似，从略) 。以下分两种情况来讨论。

i) 若 $b\le a_*$ ，则 $a<b\le a_*\le x_0$ ，而函数 $f(x)$ 在 x_0 左边是非降的，所以

$$\int_a^b f(x)dx\le f(a_*)(b-a)<f(a_*)(b_*-a_*)\le\int_{a_*}^{b_*}f(x)dx=1-\alpha.$$

其中上式的两个 " $\le$ " 号都用到了 $f(x)$ 是单峰的性质。

ii) 若 $b>a_*$ ，因为 $b-a<b_*-a_*$ ，所以必有 $a\le a_*<b<b_*$ 。由 $f(x)$ 的单峰性质可得 $\int_a^{a_*}f(x)dx\le f(a_*)(a_*-a)$ ，且 $\int_b^{b_*}f(x)dx\ge f(b_*)(b_*-b)$ (见图) 。所以

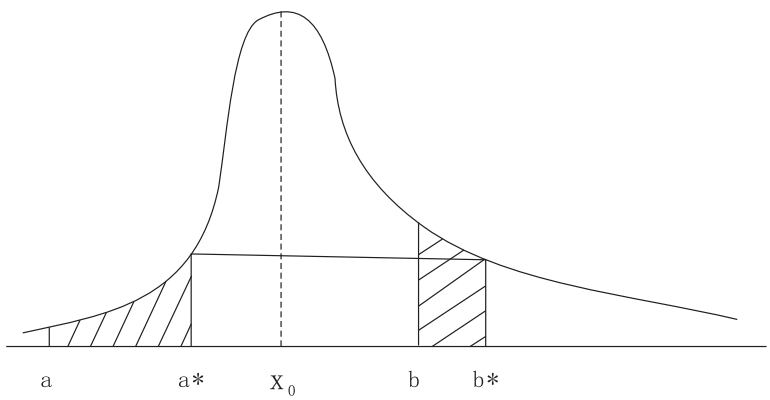

$$\begin{aligned}\int_a^b f(x)dx &= \int_{a_*}^{b_*}f(x)dx+\int_a^{a_*}f(x)dx-\int_b^{b_*}f(x)dx\\ &\le 1-\alpha+f(a_*)(a_*-a)-f(b_*)(b_*-b)\\ &= 1-\alpha+f(a_*)[(a_*-a)-(b_*-b)]\\ &= 1-\alpha+f(a_*)[(b-a)-(b_*-a_*)]\\ &< 1-\alpha.\end{aligned}$$

所以 $[T-b_*U,\ T-a_*U]$ 是 $\mathcal{C}$ 中长度最短的区间。

(2) **解**. 枢轴量 $\sqrt{n}(\bar{X}-\mu)/S$ 的密度函数 $f(x)$ 是自由度为 $n-1$ 的 t 分布，它在 $x_0=0$ 处是单峰的。由于 $f(x)$ 关于 $x=0$ 对称，所以由 $f(a_*)=f(b_*),\ a_*\le x_0\le b_*$ 可得 $a_*=-b_*$ 。显然，当取 $a_*=-t(n-1,1-\frac{\alpha}{2})$ 时，我们有 $[\bar{X}-b_*\cdot\frac{S}{\sqrt{n}},\ \bar{X}-a_*\cdot\frac{S}{\sqrt{n}}]\in\mathcal{C}$ ，且 $f(a_*)=f(b_*)>0,\ a_*<x_0<b_*$ 。所以由 (1) 可知

$$\left[\bar{X}-t(n-1,1-\frac{\alpha}{2})\cdot\frac{S}{\sqrt{n}},\quad \bar{X}+t(n-1,1-\frac{\alpha}{2})\cdot\frac{S}{\sqrt{n}}\right]$$

是 $\mathcal{C}$ 中长度最短的区间。 ∎

注. 我们亦可不用反证法，而用类似于 26 (1) 的方法直接证明本题 (1) 的结论。今概述如下。若 $[T-b_*U,\ T-a_*U]\in\mathcal{C},\ f(a_*)=f(b_*)>0$ ； $[T-bU,\ T-aU]\in\mathcal{C}$ ，要证 $b_*-a_*\le b-a$ 。

i) 首先，若区间 $[a,\ b]$ 与 $[a_*,\ b_*]$ 没有重叠，而位于 a_* 的左边，或位于 b_* 的右边，则由 $f(x)$ 的单峰性可知， $f(x)$ 在 $[a_*,\ b_*]$ 上的值必大于等于 $f(x)$ 在 $[a,\ b]$ 上的值 (见上图)，因此类似于 26 (1) 的证明 (见那里 (1) 式) 可知， $b_* - a_* \le b - a$ 。

ii) 若区间 $[a,\ b]$ 与 $[a,\ b]$ 有重叠，不失一般性，可设 $a_* < a < b_* < b$ (见图，其他情况类似)，则有

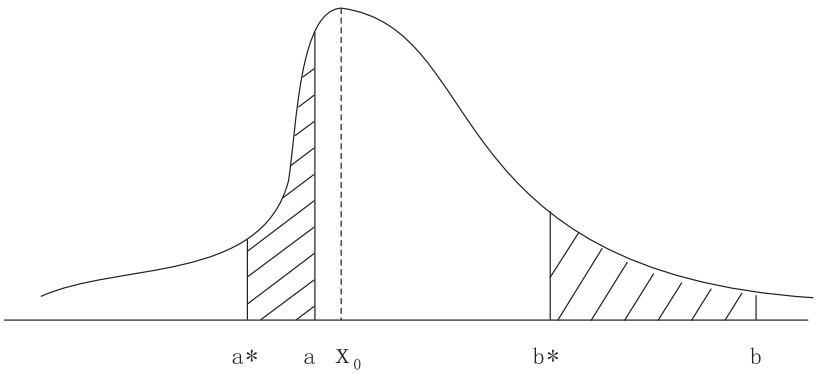

$$\int_{a_*}^{b_*} f(x)dx = \int_{a_*}^{a} f(x)dx + \int_{a}^{b_*} f(x)dx = 1-\alpha;$$
$$\int_{a}^{b} f(x)dx = \int_{a}^{b_*} f(x)dx + \int_{b_*}^{b} f(x)dx = 1-\alpha.$$

因此有 $\int_{a_*}^{a} f(x)dx = \int_{b_*}^{b} f(x)dx$ 。由于 $f(x)$ 在 $[a_*,\ a]$ 上的值大于等于 $f(a_*)$ ；而 $f(x)$ 在 $[b_*,\ b]$ 上的值小于等于 $f(b_*) = f(a_*)$ 的值，因此 $f(x)$ 在 $[a_*,\ a]$ 上的值必大于等于 $f(x)$ 在 $[b_*,\ b]$ 上的值，因此必有 $b - b_* \ge a - a_*$ 。所以有 $b - a = (b - b_*) + (b_* - a) \ge (b_* - a) + (a - a_*) = b_* - a_*$ 。

∎

29. 设 $X_1, \cdots, X_n$ 为 *i.i.d.* 样本， $X_1 \sim N(\mu, \sigma^2)$ ， μ 和 σ^2 都未知。

(1) 求 μ 的水平为 $1-\alpha$ 的 UMAU 置信上、下限以及 UMAU 置信区间;

(2) 证明： (1) 中的置信区间可由反解例 6.6.1 中关于 μ 的似然比检验的接受域而得到;

(3) 求 σ^2 的水平为 $1-\alpha$ 的 UMAU 置信上、下限以及 UMAU 置信区间。

(1) 由原书第六章第 5 节关于 μ 的单边检验可知,

$$\phi(X) = \begin{cases} 1, & W(X) < t(n-1,\alpha) \\ 0, & \text{其它}. \end{cases}$$

是假设检验问题 $H_0 : \mu \ge \mu_0 \longleftrightarrow H_1 : \mu < \mu_0$ 的 UMPUT ，其中 $W(X) = \sqrt{n}(\bar{X} - \mu_0)/\hat{\sigma}$, $\hat{\sigma}^2 = (n-1)^{-1}\sum_{i=1}^{n}(X_i - \bar{X})^2$ 。该检验的否定域为

$$R^+ = \{\sqrt{n}(\bar{X} - \mu_0)/\hat{\sigma} < t(n-1,\alpha)\} = \{\sqrt{n}(\bar{X} - \mu_0)/\hat{\sigma} < -t(n-1,1-\alpha)\}.$$

由此可得其接受域为

$$A(\mu_0) = \overline{R^+} = \{\sqrt{n}(\bar{X} - \mu_0)/\hat{\sigma} \ge -t(n-1,1-\alpha)\}.$$

由于上式对于任意的 μ_0 都成立，所以在上式中换 μ_0 为 μ ，反解 $A(\mu)$ ，即可得到置信域

$$S(X)=\{\mu\le\bar{X}+t(n-1,1-\alpha)\cdot\frac{\hat{\sigma}}{\sqrt{n}}\}=(-\infty,\bar{\mu}].$$

并且 $P_\mu(\mu\in S(X))=P_\mu(X\in A(\mu))=1-\alpha$ 。所以 $\bar{\mu}=\bar{X}+t(n-1,1-\alpha)\cdot(\hat{\sigma}/\sqrt{n})$ 即是 μ 的水平为 $1-\alpha$ 的 UMAU 置信上限。

同理可得 μ 的水平为 $1-\alpha$ 的 UMAU 置信下限为 $\underline{\mu}=\bar{X}-t(n-1,1-\alpha)(\hat{\sigma}/\sqrt{n})$ 。

由第六章第 5 节关于 μ 的双边检验可知

$$\phi(X)=\begin{cases}1, & |W|\triangleq|\sqrt{n}(\bar{X}-\mu_0)/\hat{\sigma}|>t(n-1,1-\frac{\alpha}{2})\\ 0, & \text{其它}.\end{cases}$$

是假设检验问题 $H_0:\mu=\mu_0\longleftrightarrow H_1:\mu\ne\mu_0$ 的 UMPUT 。该检验的否定域为

$$R^+=\{|\sqrt{n}(\bar{X}-\mu_0)/\hat{\sigma}|>t(n-1,1-\frac{\alpha}{2})\}$$

由此可得其接受域为

$$\begin{aligned}A(\mu_0)&=\{|\sqrt{n}(\bar{X}-\mu_0)/\hat{\sigma}|<t(n-1,1-\frac{\alpha}{2})\}\\&=\{-t(n-1,1-\frac{\alpha}{2})\le\sqrt{n}(\bar{X}-\mu_0)/\hat{\sigma}\le t(n-1,1-\frac{\alpha}{2})\}.\end{aligned}$$

上式对于任意的 μ_0 都成立，所以在上式中换 μ_0 为 μ ，反解 $A(\mu)$ ，即可得到置信域

$$S(X)=\{\bar{X}-t(n-1,1-\frac{\alpha}{2})\cdot\frac{\hat{\sigma}}{\sqrt{n}}\le\mu\le\bar{X}+t(n-1,1-\frac{\alpha}{2})\cdot\frac{\hat{\sigma}}{\sqrt{n}}\}=[\underline{\mu},\bar{\mu}].$$

并且 $P_\mu(\mu\in S(X))=P_\mu(X\in A(\mu))=1-\alpha$ 。所以 $[\underline{\mu},\bar{\mu}]$ 是 μ 的水平为 $1-\alpha$ 的 UMAU 置信区间。

(2) 由例 6.6.1 (1) 可知， μ 的双边似然比检验与 N-P 理论的一致最优势检验完一致，所以 (1) 中的置信区间可由反解例 6.6.1 中关于 μ 的似然比检验的接受域而得到。

(3) 由第六章第 5 节关于 σ^2 的单边检验可知，假设检验问题 $H_0:\sigma^2\le\sigma_0^2\longleftrightarrow H_1:\sigma^2>\sigma_0^2$ 的水平为 α 的 UMPUT 的接受域为

$$A(\sigma_0^2)=\{S(X)\le\sigma_0^2\chi^2(n-1,1-\alpha)\}$$

其中 $S(X)=\sum_{i=1}^n(X_i-\bar{X})^2$ 。由

$$P_{\sigma_0^2}\{S(X)\le\sigma_0^2\chi^2(n-1,1-\alpha)\}=1-\alpha$$

可得

$$P_{\sigma_0^2}\{\sigma_0^2\ge S(X)/\chi^2(n-1,1-\alpha)\}=1-\alpha.$$

由于上式对于任意的 σ_0^2 都成立，所以换 σ_0^2 为 σ^2 ，即可得到 σ^2 的水平为 $1-\alpha$ 的 UMAU 置信下限 $\underline{\sigma^2}(X)=S(X))/\chi^2(n-1,1-\alpha)$ 。

同理可得 σ^2 的水平为 $1-\alpha$ 的 UMAU 置信上限为 $\overline{\sigma^2}(X)=S(X)/\chi^2(n-1,\alpha)$ 。

由第六章第 5 节关于 σ^2 的双边检验可知，假设检验问题 $H_0:\sigma^2=\sigma_0^2 \longleftrightarrow H_1:\sigma^2\neq\sigma_0^2$ 的水平为 α 的 UMPUT 的接受域为 $A(\sigma_0^2)=\{k_1\le S(X)/\sigma_0^2\le k_2\}$，其中 k_1，k_2 由

$$\int_{k_1}^{k_2}\chi^2(n-1,y)dy=1-\alpha \text{ 和 } \int_{k_1}^{k_2}y\chi^2(n-1,y)dy=(n-1)(1-\alpha)$$

来决定，$\chi^2(n-1,y)$ 表示自由度为 $n-1$ 的 χ^2 分布的密度函数。由

$$P_{\sigma_0^2}\{k_1\le S(X)/\sigma_0^2\le k_2\}=1-\alpha$$

可得

$$P_{\sigma_0^2}\{\frac{S(X)}{k_2}\le\sigma_0^2\le\frac{S(X)}{k_1}\}=1-\alpha.$$

由于上式对于任意的 σ_0^2 都成立，所以换 σ_0^2 为 σ^2，即可得到 σ^2 的水平为 $1-\alpha$ 的 UMAU 置信区间 $[S(X)/k_2,\ S(X)/k_1]$。 ∎

30. 设 $X_1,\cdots,X_n$ 为 *i.i.d.* 样本，$X_1\sim f(x_1;\theta)=\theta x_1^{\theta-1}I\{0\le x_1\le 1\}$，其中 $\theta>0$ 未知。求 θ 的水平为 $1-\alpha$ 的 UMAU 置信区间。

解. 考虑假设检验问题 $H_0:\theta=\theta_0\longleftrightarrow H_1:\theta\neq\theta_0$，由第六章习题 18 知该假设检验问题的 UMPUT 的否定域为 $R^+=\{X:T<k_1 \text{ 或者 } T>k_2\}$，其中 $T=\sum_{i=1}^n\log X_i$。其接受域为 $A(\theta_0)=\{X:k_1\le T\le k_2\}$。当 $\theta=\theta_0$ 时，$-2\theta_0T\sim\chi^2(2n)$ (见第一章习题 21)，所以有

$$\begin{aligned}A(\theta_0) &= \{X:-2\theta_0k_2\le -2\theta_0T\le -2\theta_0k_1\}\\ &= \{X:c_1\le -2\theta_0T\le c_2\}.\end{aligned}$$

其中 c_1，c_2 由方程 $\int_{c_1}^{c_2}\chi^2(2n,y)dy=1-\alpha$ 和 $\int_{c_1}^{c_2}y\chi^2(2n,y)dy=n(1-\alpha)$ 决定，而与 θ_0 无关。因此由

$$P_{\theta_0}\{x:c_1\le -2\theta_0T\le c_2\}=1-\alpha$$

可得

$$P_{\theta_0}\{x:-\frac{c_2}{2T}\le\theta_0\le-\frac{c_1}{2T}\}=1-\alpha.$$

由于上式对于任意的 θ_0 都成立，所以换 θ_0 为 θ，即可得到 θ 的一个水平为 $1-\alpha$ 的 UMAU 置信区间：$[-c_2/(2T),\ -c_1/(2T)]$ (注意，$T\le 0$)。 ∎

31. 设 $X_1,\cdots,X_n$ 为 *i.i.d.* 样本，$X_1\sim\Gamma(1/\theta,1)$ 为寿命分布。若仅观测到 $(Y_1,\cdots,Y_r)'=(X_{(1)},\cdots,X_{(r)})'$ 这前 r 个寿命的值，求 θ 的水平为 $1-\alpha$ 的 UMA 置信下界和 UMAU 置信区间。

解. 由第六章习题 15 可知，假设检验问题 $H_0:\theta\le\theta_0\longleftrightarrow H_1:\theta>\theta_0$ 的一个水平为 α 的 UMPT 为

$$\phi(X)=\begin{cases}1, & T_{n,r}>\dfrac{\theta_0}{2}\chi^2(2r,1-\alpha)\\ 0, & T_{n,r}<\dfrac{\theta_0}{2}\chi^2(2r,1-\alpha)\end{cases}$$

其中 $T_{n,r}=\sum_{i=1}^{r}Y_i+(n-r)Y_r\sim\Gamma(1/\theta,r)$ 。因此该假设检验问题的接受域可表示为 $A(\theta_0)=\{T_{n,r}\le\frac{\theta_0}{2}\chi^2(2r,1-\alpha)\}$ 。由

$$P_{\theta_0}\{T_{n,r}\le\frac{\theta_0}{2}\chi^2(2r,1-\alpha)\}=1-\alpha$$

可得

$$P_{\theta_0}\{\theta_0\ge 2T_{n,r}/\chi^2(2r,1-\alpha)\}=1-\alpha.$$

由于上式对于任意的 θ_0 都成立，所以在上式中换 θ_0 为 θ 即得 θ 的 UMA 置信下界 $\underline{\theta}(X)=2T_{n,r}/\chi^2(2r,1-\alpha)$ 。

下面求 θ 的水平为 $1-\alpha$ 的 UMAU 置信区间。考虑假设检验问题 (1) $H_0:\theta=\theta_0\longleftrightarrow H_1:\theta\ne\theta_0$ 。由于观察数据的密度函数

$$f(y;\theta)=c\cdot\theta^{-r}\exp\{-\frac{1}{\theta}[\sum_{i=1}^{r}y_i+(n-r)y_r]\}$$

关于 $T_{n,r}=\sum_{i=1}^{r}y_i+(n-r)y_r$ 是指数族分布，所以假设检验问题 (1) 的一个水平为 α 的 UMPUT 的否定域为 $R^+=\{T_{n,r}<k_1$ 或 $T_{n,r}>k_2\}$ ，从而其接受域为 $A(\theta_0)=\{k_1\le T_{n,r}\le k_2\}$ ，其中 k_1，k_2 由 $E_{\theta_0}[\phi(X)]=\alpha$ 和 $E_{\theta_0}[T_{n,r}\phi(X)]=\alpha E_{\theta_0}[T_{n,r}]$ 决定，

$$\phi(X)=\begin{cases}1, & T_{n,r}<k_1 \text{ 或 } T_{n,r}>k_2\\ 0, & k_1\le T_{n,r}\le k_2\end{cases}$$

当 H_0 成立时，因为 $2T_{n,r}/\theta_0\sim\chi^2(2r)$ ，所以可把接受域为 $A(\theta_0)$ 表示为

$$A(\theta_0)=\{\frac{2k_1}{\theta_0}\le\frac{2T_{n,r}}{\theta_0}\le\frac{2k_2}{\theta_0}\}=\{c_1\le\frac{2T_{n,r}}{\theta_0}\le c_2\}.$$

其中 $c_i=2k_i/\theta_0$，$i=1,2$ ，而 c_1，c_2 由以下方程决定

$$\int_{c_1}^{c_2}\chi^2(2r,y)dy=1-\alpha \quad 和 \quad \int_{c_1}^{c_2}y\chi^2(2r,y)dy=2r(1-\alpha).$$

$\chi^2(2r,y)$ 表示自由度为 $2r$ 的 χ^2 分布的密度函数。所以接受域 $A(\theta_0)$ 可反解为

$$S(X)=\{\frac{2T_{n,r}}{c_2}\le\theta_0\le\frac{2T_{n,r}}{c_1}\}.$$

由于上式对于任意的 θ_0 都成立，所以在上式中换 θ_0 为 θ 即可得到 θ 的 UMAU 置信区间为 $[2T_{n,r}/c_2,\ 2T_{n,r}/c_1]$ 。 ∎

32. 设 $X_1,\cdots,X_n$ 为 *i.i.d.* 样本， $X_1\sim R(0,\theta)$，$\theta>0$ 。(1) 求 θ 的水平为 $1-\alpha$ 的 UMA 置信下限； (2) 证明： $[X_{(n)},\alpha^{-\frac{1}{n}}X_{(n)}]$ 为 θ 的水平为 $1-\alpha$ 的 UMA 置信区间。(提示：见第六章 25 题)

(1) 由例 6.3.3 知， $\lambda(x)=f(x,\theta_1)/f(x,\theta_0)$ 关于 $T(X)=X_{(n)}$ 为 MLR 。考虑假设检验问题 $H_0:\theta\le\theta_0\ \ (\theta_0>0)\longleftrightarrow H_1:\theta>\theta_0$ 。由定理 6.3.1 知

$$\phi(X)=\begin{cases}1, & X_{(n)}>c\\ 0, & X_{(n)}\le c\end{cases}$$

是上述假设检验问题的 UMPT，其中 c 由 $E_{\theta_0}\phi(X)=\alpha$ 决定。由于 $\theta=\theta_0$ 时，

$$X_{(n)}\sim f(t)=n\theta_0^{-n}t^{n-1}I\{0\le t\le\theta_0\},$$

所以由 $E_{\theta_0}\phi(X)=\int_c^{\theta_0}f(t)dt=\alpha$ 可得 $c=\theta_0(1-\alpha)^{1/n}$。因此假设检验问题的接受域为 $A(\theta_0)=\{X_{(n)}\le\theta_0(1-\alpha)^{1/n}\}$。由

$$P_{\theta_0}\{X_{(n)}\le\theta_0(1-\alpha)^{1/n}\}=1-\alpha$$

可得

$$P_{\theta_0}\{\theta_0\ge(1-\alpha)^{-\frac{1}{n}}X_{(n)}\}=1-\alpha.$$

由于上式对于任意的 θ_0 都成立，所以在上式中换 θ_0 为 θ，即可得到 θ 的水平为 $1-\alpha$ 的 UMA 置信下限 $\underline{\theta}(X)=(1-\alpha)^{-\frac{1}{n}}X_{(n)}$。

(2) 因为 $S(T)=[X_{(n)},\ \alpha^{-\frac{1}{n}}X_{(n)}]$ 是 θ 的一个水平为 $1-\alpha$ 的置信区间，其中 $T=X_{(n)}$。反解这个区间可得 $A(\theta)=\{\alpha^{\frac{1}{n}}\theta\le T\le\theta\}$。因为 $P_\theta(\theta\in S(T))=1-\alpha$，且该式对于任意的 $\theta=\theta_0$ 都成立，所以有

$$P_{\theta_0}(T\in A(\theta))=P_{\theta_0}(\theta\in S(T))=1-\alpha.$$

因此区域 $\bar{A}(\theta)=\{T:T>\theta_0$ 或 $T<\alpha^{\frac{1}{n}}\theta_0\}$ 是与置信区间 $S(T)=[X_{(n)},\ \alpha^{-\frac{1}{n}}X_{(n)}]$ 相对应的以下假设检验问题的否定域：$H_0:\theta=\theta_0\longleftrightarrow H_1:\theta\ne\theta_0$，因此其相应的检验函数可表示为

$$\phi(X)=\begin{cases}1, & X_{(n)}>\theta_0 \text{ 或 } X_{(n)}<\alpha^{\frac{1}{n}}\theta_0\\ 0, & \text{其它}\end{cases}$$

由第六章习题 25 知，$\phi(X)$ 是上述假设检验问题的水平为 α 的 UMPT。所以由定理 7.3.1 可知，$[X_{(n)},\ \alpha^{-\frac{1}{n}}X_{(n)}]$ 是 θ 的水平为 $1-\alpha$ 的 UMA 置信区间。 ∎

33. 设 $X_1,\cdots,X_n$ 为 *i.i.d.* 样本，$X_1\sim N(\mu,\sigma^2)$，求分布的水平为 $(1-\beta,1-\gamma)$ 的容忍上、下限和容忍区间。(1) 设 μ 未知，$\sigma^2=\sigma_0^2$ 已知；(2) $\mu=\mu_0$ 已知，$\sigma>0$ 未知；(3) 设棉纱的断裂负荷服从正态分布，$\mu,\ \sigma^2$ 未知。现从一批棉纱中随机抽取 12 段测得其断裂负荷 (单位为 100^{-1} Newton) 为

228.6, 232.7, 238.8, 317.2, 315.8, 275.1, 222.2, 236.7, 224.7, 251.2, 210.4, 270.7

设置信水平为 (0.95, 0.95); 已知 $\lambda\ (12,0.95,0.95)=2.74$，求棉纱断裂负荷的容忍下限。

解. (1) 由原书定理 7.3.2 可知，求分布 $N(\mu,\sigma_0^2)$ 的水平为 $(1-\beta,\ 1-\gamma)$ 的容忍下限，等价于求其 β 分位点 $x_\beta(\mu)$ 的水平为 $1-\gamma$ 的置信下限。

由于 $(X_1-\mu)/\sigma_0\sim N(0,1)$，因此有

$$\beta=P\{X_1\le x_\beta(\mu)\}=P\{\frac{X_1-\mu}{\sigma_0}\le\frac{x_\beta(\mu)-\mu}{\sigma_0}\}.$$

所以 $(x_\beta(\mu)-\mu)/\sigma_0=z_\beta$，其中 z_β 为 $N(0,1)$ 的 β 分位点。从而有 $x_\beta(\mu)=\mu+\sigma_0z_\beta$，这与 μ 仅相差一个常数，所以可取枢轴量为

$$G(X,\mu)=\sqrt{n}\frac{\bar{X}-x_\beta(\mu)}{\sigma_0}=\frac{\sqrt{n}(\bar{X}-\mu)}{\sigma_0}-\sqrt{n}z_\beta\sim N(\sqrt{n}z_{1-\beta},1).$$

由于

$$P_\mu\{\sqrt{n}\frac{\bar{X}-x_\beta(\mu)}{\sigma_0}\le m_{1-\gamma}\}=1-\gamma,$$

因此可得

$$P_\mu\{x_\beta(\mu)\ge\bar{X}-\frac{\sigma_0}{\sqrt{n}}m_{1-\gamma}\}=1-\gamma.$$

其中 $m_{1-\gamma}$ 是正态分布 $N(\sqrt{n}z_{1-\beta},1)$ 的 $1-\gamma$ 分位点， $m_{1-\gamma}=\sqrt{n}z_{1-\beta}+z_{1-\gamma}$ (因为 $X\sim N(\mu,\sigma^2)$ 的 β 分位点 $x_\beta=\mu+\sigma z_\beta$) 。由此可知 $\bar{X}-m_{1-\gamma}\sigma_0/\sqrt{n}$ 是 $x_\beta(\mu)$ 的水平为 $1-\gamma$ 的置信下限；所以 $\underline{T}=\bar{X}-m_{1-\gamma}\sigma_0/\sqrt{n}$ 是分布 $N(\mu,\sigma_0^2)$ 的水平为 $(1-\beta,\ 1-\gamma)$ 的容忍下限。

同理可得, 分布 $N(\mu,\sigma_0^2)$ 的水平为 $(1-\beta,\ 1-\gamma)$ 的容忍上限为 $\bar{T}=\bar{X}+m_\gamma\sigma_0/\sqrt{n}$ ，其中 m_γ 是 $N(\sqrt{n}z_{1-\beta},1)$ 的 γ 分位点， $m_\gamma=\sqrt{n}z_{1-\beta}+z_\gamma$ 。

又由定理 7.3.1 可知，分布 $N(\mu,\sigma_0^2)$ 的水平为 $(1-\beta,\ 1-\gamma)$ 的容忍区间为

$$\left[\bar{X}-\frac{\sigma_0}{\sqrt{n}}m_{1-\frac{\gamma}{2}},\quad \bar{X}+\frac{\sigma_0}{\sqrt{n}}m_{1-\frac{\gamma}{2}}\right].$$

其中 $m_{1-\frac{\gamma}{2}}$ 是 $N(\sqrt{n}z_{1-\frac{\beta}{2}},1)$ 的 $1-\dfrac{\gamma}{2}$ 分位点。

(2) 求分布 $N(\mu_0,\sigma^2)$ 的水平为 $(1-\beta,\ 1-\gamma)$ 的容忍上限，等价于求其 $1-\beta$ 分位点 $x_{1-\beta}(\sigma^2)$ 的水平为 $1-\gamma$ 的置信上限。

由于 $(X_1-\mu_0)/\sigma\sim N(0,1)$ 因此有

$$1-\beta=P(X_1\le x_{1-\beta}(\sigma^2))=P(\frac{X_1-\mu_0}{\sigma}\le\frac{x_{1-\beta}(\sigma^2)-\mu_0}{\sigma}).$$

所以 $(x_{1-\beta}(\sigma^2)-\mu_0)/\sigma=z_{1-\beta}$,其中 $z_{1-\beta}$ 是标准正态分布的 $1-\beta$ 分位点。从而 $x_{1-\beta}(\sigma^2)=\mu_0+\sigma z_{1-\beta}$ ，其中 μ_0，$z_{1-\beta}$ 已知，因而求 $x_{1-\beta}(\sigma^2)$ 的置信上限类似于求 σ 的置信上限。

下面我们基于 $S^2=\sum_{i=1}^n(X_i-\mu_0)^2$ 用枢轴量法来求 $x_{1-\beta}(\sigma^2)$ 的水平为 $1-\gamma$ 的置信上限。因为 $\sigma=(x_{1-\beta}(\sigma^2)-\mu_0)/z_{1-\beta}>0$ ，所以有

$$\frac{S^2}{\sigma^2}=\frac{S^2z_{1-\beta}^2}{(x_{1-\beta}(\sigma^2)-\mu_0)^2}\sim\chi^2(n),$$

也有

$$\frac{Sz_{1-\beta}}{x_{1-\beta}(\sigma^2)-\mu_0}\sim\chi(n)\ \ (\text{即为 }\chi\text{ 分布})$$

记 $\chi(n,\gamma)$ 为 $\chi(n)$ 分布的 γ 分位点，则由

$$P_{\sigma^2}\{\frac{Sz_{1-\beta}}{x_{1-\beta}(\sigma^2)-\mu_0}\ge\chi(n,\gamma)\}=1-\gamma$$

可得

$$P_{\sigma^2}\{x_{1-\beta}(\sigma^2)\le\mu_0+\frac{z_{1-\beta}}{\chi(n,\gamma)}\cdot S\}=1-\gamma.$$

所以 $\mu_0+S\cdot z_{1-\beta}/\chi(n,\gamma)$ 是 $x_{1-\beta}(\sigma^2)$ 的水平为 $1-\gamma$ 的置信上限，从而相应分布的一个水平为 $(1-\beta,\ 1-\gamma)$ 的容忍上限为 $\bar{T}=\mu_0+S\cdot z_{1-\beta}/\chi(n,\gamma)$ 。

同理可得，分布 $N(\mu_0,\sigma^2)$ 的水平为 $(1-\beta,\ 1-\gamma)$ 的容忍下限为 $\underline{T}=\mu_0+S\cdot z_\beta/\chi(n,1-\gamma)$ 。由定理 7.3.1 可知分布 $N(\mu_0,\sigma^2)$ 的水平为 $(1-\beta,\ 1-\gamma)$ 的容忍区间为

$$\left[\mu_0+\frac{z_{\beta/2}}{\chi(n,1-\gamma/2)}S,\quad \mu_0+\frac{z_{1-\beta/2}}{\chi(n,\gamma/2)}S\right].$$

其中各符号的意义同上。

(3) 把数据代入例 7.3.4 的结果，可得 $\underline{T}=\bar{x}-\lambda S=252.0083-2.74\cdot 35.5447=154.6158$ ，所以棉纱断裂负荷的容忍下限为 154.6158 。 ∎

注. 以上 (1) ， (2) 中分位点的置信限亦可应用原书引理 7.1.1 (p.306) 以及正态分布置信限的结果直接得到。因为在 (1) 中有 $x_\beta(\mu)=\mu+\sigma_0 z_\beta$ ；而在 (2) 中有 $x_{1-\beta}(\sigma^2)=\mu_0+\sigma z_{1-\beta}$ ，前者为 μ 的线性严增函数; 后者为 σ 的线性严增函数。因此根据引理 7.1.1 ， $x_\beta(\mu)$ 的置信限可由 μ 的置信限得到； $x_{1-\beta}(\sigma^2)$ 的置信限可由 σ 的置信限得到，而 μ 和 σ 的置信限在例题中已有类似的讨论。这在容忍限的问题中常常会出现 (亦可见后面习题) ，因为分位点 $x_\beta(\theta)$ 有可能是 θ 的严增函数或严减函数。 ∎

34. 设 $X_1,\cdots,X_n$ 为 *i.i.d.* 样本， X_1 服从均匀分布 $R(0,\theta)$ ， $\theta>0$, 求该分布水平为 $(1-\beta,1-\gamma)$ 的容忍上、下限和容忍区间。

解. 求分布的水平为 $(1-\beta,\ 1-\gamma)$ 的容忍下限，等价于求其 β 分位点 $x_\beta(\theta)$ 的水平为 $1-\gamma$ 的置信下限。

由于 $X_1/\theta\sim R(0,1)$ 且 $\beta=P_\theta(X_1\le x_\beta(\theta))=P_\theta(\frac{X_1}{\theta}\le\frac{x_\beta(\theta)}{\theta})$ ，所以 $\frac{x_\beta(\theta)}{\theta}=\beta$ ，从而 $x_\beta(\theta)=\beta\theta$ 。 根据引理 7.1.1 ， $x_\beta(\theta)$ 的水平为 $1-\gamma$ 的置信下限就是 $\beta\underline{\theta}_{1-\gamma}(X)$ ，其中 $\underline{\theta}_{1-\gamma}(X)$ 为均匀分布 $R(0,\theta)$ 中 θ 的水平为 $1-\gamma$ 的置信下限。这在习题 32 (1) 中已经得到，即为 $\underline{\theta}_{1-\gamma}(X)=(1-\gamma)^{-\frac{1}{n}}X_{(n)}$ 。所以 $\underline{T}=\beta(1-\gamma)^{-\frac{1}{n}}X_{(n)}$ 是分布的水平为 $(1-\beta,\ 1-\gamma)$ 的容忍下限。

同理，求分布的水平为 $(1-\beta,\ 1-\gamma)$ 的容忍上限，等价于求其 $1-\beta$ 分位点 $x_{1-\beta}(\theta)$ 的水平为 $1-\gamma$ 的置信上限。而由上面的推导可知 $x_{1-\beta}(\theta)=(1-\beta)\theta$ ，同样根据引理 7.1.1 , 其的水平为 $1-\gamma$ 的置信上限为 $(1-\beta)\bar{\theta}_{1-\gamma}(X)$, 其中 $\bar{\theta}_{1-\gamma}(X)$ 为均匀分布 $R(0,\theta)$ 中 θ 的水平为 $1-\gamma$ 的置信上限。 $\bar{\theta}_{1-\gamma}(X)$ 可由习题 32 (1) 的计算结果得到。由习题 32 (1) 的公式可知 $P_\theta\{\theta\ge(1-\alpha)^{-\frac{1}{n}}X_{(n)}\}=1-\alpha$ ，因此 $P_\theta\{\theta\le(1-\alpha)^{-\frac{1}{n}}X_{(n)}\}=\alpha$ ，取 $\alpha=1-\gamma$ 代入上式可得 $P_\theta\{\theta\le\gamma^{-\frac{1}{n}}X_{(n)}\}=1-\gamma$ ，因此 θ 的水平为 $1-\gamma$ 的置信上限为 $\bar{\theta}_{1-\gamma}(X)=\gamma^{-\frac{1}{n}}X_{(n)}$ 。所以 $\bar{T}=(1-\beta)\gamma^{-\frac{1}{n}}X_{(n)}$ 是分布的水平为 $(1-\beta,\ 1-\gamma)$ 的容忍上限。

根据定理 7.3.1 ，分布的一个水平为 $(1-\beta,\ 1-\gamma)$ 的容忍区间可表示为 $[\underline{T}^*,\ \bar{T}^*]$ ，其中 $\underline{T}^*=(\beta/2)(1-\gamma/2)^{-\frac{1}{n}}X_{(n)}$ ， $\bar{T}^*=(1-\beta/2)(\gamma/2)^{-\frac{1}{n}}X_{(n)}$ 。 ∎

35. 设 $X_1,\cdots,X_n$ 为 *i.i.d.* 样本， X_1 服从 Weibull 分布 $W(\frac{1}{\sigma},\alpha_0)$ ，其中 $\alpha_0>0$ 已知，$\sigma>0$ 未知。求该分布水平为 $(1-\beta,1-\gamma)$ 的容忍上、下限和容忍区间。

解. 求分布的水平为 $(1-\beta,\ 1-\gamma)$ 的容忍下限，等价于求其 β 分位点 $x_\beta(\sigma)$ 的水平为 $1-\gamma$ 的置信下限。

由 $X_i\sim W(\frac{1}{\sigma},\alpha_0)$ 可得 $X_i^{\alpha_0}\sim\Gamma(\frac{1}{\sigma},1)$ ，所以 $\frac{2}{\sigma}X_i^{\alpha_0}\sim\Gamma(\frac{1}{2},1)\sim\chi^2(2),\ i=$

$1,2,\cdots,n$ 。由于

$$\beta = P(X_1 \le x_\beta(\sigma)) = P(\frac{2}{\sigma}X_1^{\alpha_0} \le \frac{2}{\sigma}(x_\beta(\sigma))^{\alpha_0}),$$

所以有 $\frac{2}{\sigma}[x_\beta(\sigma)]^{\alpha_0} = \chi^2(2,\beta)$ ，从而 $x_\beta(\sigma) = [(\sigma/2)\chi^2(2,\beta)]^{1/\alpha_0}$ ，这是 σ 的严增函数，因而根据引理 7.1.1 ，问题就化为求解 σ 的水平为 $1-\gamma$ 的置信下限 $\underline{\sigma}_{1-\gamma}(X)$ 。

因为 $T = \sum_{i=1}^n X_i^{\alpha_0}$ 是充分统计量，且有

$$\frac{2}{\sigma}T = \sum_{i=1}^n \frac{2}{\sigma}X_i^{\alpha_0} \sim \chi^2(2n).$$

所以由

$$P\{\frac{2}{\sigma}T \le \chi^2(2n,1-\gamma)\} = 1-\gamma$$

可得

$$P\left\{\sigma \ge \frac{2T}{\chi^2(2n,1-\gamma)}\right\} = 1-\gamma.$$

由此可知 $\underline{\sigma}_{1-\gamma}(X) = 2T/\chi^2(2n,1-\gamma)$ ，该式代入上面 $x_\beta(\sigma)$ 的表达式，即可得到 $x_\beta(\sigma)$ 的水平为 $1-\gamma$ 的置信下限，即 Weibull 分布 $W(\frac{1}{\sigma},\alpha_0)$ 的水平为 $(1-\beta,1-\gamma)$ 的容忍下限为

$$\underline{T} = [\chi^2(2,\beta)T/\chi^2(2n,1-\gamma)]^{1/\alpha_0}$$

根据完全类似的方法，可以得到分布 $W(\frac{1}{\sigma},\alpha_0)$ 的水平为 $(1-\beta,1-\gamma)$ 的容忍上限为 $\overline{T}(X) = [\chi^2(2,1-\beta)T/\chi^2(2n,\gamma)]^{1/\alpha_0}$ 。再由定理 7.3.1 即可得到分布的水平为 $(1-\beta,1-\gamma)$ 的容忍区间为

$$\left[\left(\frac{\chi^2(2,\frac{\beta}{2})}{\chi^2(2n,1-\frac{\gamma}{2})}\right)^{\frac{1}{\alpha_0}}T,\quad \left(\frac{\chi^2(2,1-\frac{\beta}{2})}{\chi^2(2n,\frac{\gamma}{2})}\right)^{\frac{1}{\alpha_0}}T\right].$$ ∎

36. 设 $X_1,\cdots,X_n$ 为 *i.i.d.* 样本， $X_1 \sim BE(\theta,1) \sim \theta x_1^{\theta-1}I\{0 \le x_1 \le 1\}$. 求该分布水平为 $(1-\beta,1-\gamma)$ 的容忍上、下限和容忍区间。

解. 求分布的水平为 $(1-\beta,\ 1-\gamma)$ 的容忍下限，等价于求其 β 分位点 $x_\beta(\theta)$ 的水平为 $1-\gamma$ 的置信下限。

由 $X_i \sim BE(\theta,1)$ 可得 $-\log X_i \sim \Gamma(\theta,1)$ ，所以 $-2\theta\log X_i \sim \Gamma(\frac{1}{2},1) \sim \chi^2(2)$ (见第一章习题 21)， $i=1,2,\cdots,n$ 。由于

$$\beta = P_\theta(X_1 \le x_\beta(\theta)) = P_\theta(-2\theta\log X_1 \ge -2\theta\log x_\beta(\theta)),$$

所以 $-2\theta\log x_\beta(\theta) = \chi^2(2,1-\beta)$ ，从而 $2\theta = -\chi^2(2,1-\beta)/\log x_\beta(\theta)$ 。注意，由于 $x_\beta(\theta) \le 1$ ，因此 $\log x_\beta(\theta) \le 0$ 。因为 $T = \sum_{i=1}^n -\log X_i$ 是充分统计量，且有 $2\theta T \sim \chi^2(2n)$ ，因此

$$-\chi^2(2,1-\beta)/\log x_\beta(\theta)\cdot T = \sum_{i=1}^n(-2\theta\log X_i) \sim \chi^2(2n),$$

所以由

$$P_\theta\{-\chi^2(2,1-\beta)/\log x_\beta(\theta)\cdot T \ge \chi^2(2n,\gamma)\} = 1-\gamma,$$

$$P_\theta\{\chi^2(2,1-\beta)\cdot T/\chi^2(2n,\gamma)\geq \log x_\beta(\theta)^{-1}\}=1-\gamma$$

可得

$$P_\theta\{x_\beta(\theta)\geq \exp[-\chi^2(2,1-\beta)\cdot T/\chi^2(2n,\gamma)]\}=1-\gamma.$$

由此可得 $x_\beta(\theta)$ 的水平为 $1-\gamma$ 的置信下限，即分布 $BE(\theta,1)$ 的水平为 $(1-\beta,\ 1-\gamma)$ 的容忍下限为

$$\underline{T}=\exp\{-[\chi^2(2,1-\beta)/\chi^2(2n,\gamma)]\cdot T\}.$$

同理可得， $BE(\theta,1)$ 分布的水平为 $(1-\beta,1-\gamma)$ 的容忍上限为

$$\overline{T}=\cdot\exp\{[-\chi^2(2,\beta)/\chi^2(2n,1-\gamma)]\cdot T\}.$$

再由定理 7.3.1 可得，分布的水平为 $(1-\beta,1-\gamma)$ 的容忍区间为

$$\left[\exp\left(-\frac{\chi^2(2,1-\frac{\beta}{2})}{\chi^2(2n,\frac{\gamma}{2})}\cdot T\right),\quad \exp\left(-\frac{\chi^2(2,\frac{\beta}{2})}{\chi^2(2n,1-\frac{\gamma}{2})}\cdot T\right)\right].$$ ∎

注. 本题亦可应用类似于 35 题的方法求解。因为由前面推导可知，分位点 $x_\beta(\theta)=\exp\{-\frac{1}{2\theta}\chi^2(2,1-\beta)\}$ 为 θ 的严增函数，因此其置信下限可以由 θ 的置信下限得到。 ∎

第八章　Bayes 统计基础

1. 设 $X_1,\cdots,X_n$ 为 $i.i.d.$ 样本，在给定 X_1 的分布和参数先验分布的情况下，求相应的后验分布：

(1) $X_1\sim N(\theta,1)$ ，并设 θ 的先验分布为指数分布 $\mathrm{E}(a)$ ，但 a 已知，求 θ 的后验分布；

(2) $X_1\sim\Gamma(\lambda;\nu)$, ν 已知。 $\lambda\sim\Gamma(a,p)$, 求 λ 的后验分布；

(3) $X_1\sim f(x_1,\theta)=2x_1\theta^{-2}I\{0\le x_1\le\theta\}$ ，并设 $\theta\sim\mu\theta^{-2}I\{\theta\ge\mu\}$ ，求 θ 的后验分布。

解. (1) θ 的后验分布密度函数为

$$\begin{aligned}\pi(\theta|x) &= c(x)\cdot\exp\{-\frac{1}{2}\sum_{i=1}^n(x_i-\theta)^2\}\cdot e^{-a\theta}\\ &= c(x)\cdot\exp\{-\frac{1}{2}[n\theta^2-2n\bar{x}\theta+2a\theta+\sum_{i=1}^n x_i^2]\}\\ &= c^*(x)\exp\{-\frac{n}{2}(\theta-\frac{n\bar{x}-a}{n})^2\},\end{aligned}$$

所以 $\pi(\theta|x)\sim N(\frac{n\bar{x}-a}{n},\ \frac{1}{n})$ 。

(2) θ 的后验分布密度函数为

$$\pi(\theta|x)=c(x)\cdot\lambda^{n\nu}e^{-\lambda\sum_{i=1}^n x_i}\cdot e^{-a\lambda}\cdot\lambda^{p-1}=c(x)\lambda^{n\nu+p-1}\exp\{-\lambda(a+\sum_{i=1}^n x_i)\},$$

所以 $\pi(\theta|x)\sim\Gamma(a+\sum_{i=1}^n x_i,\ n\nu+p)$ 。

(3) θ 的后验分布密度函数为

$$\pi(\theta|x)=c(x)\cdot\theta^{-2n}I\{\theta\ge x_{(n)}\}\cdot\mu\theta^{-2}I\{\theta\ge\mu\}=c^*(x)\cdot\theta^{-(2n+2)}I\{\theta\ge\theta_0\},$$

其中 $\theta_0=\max\{x_{(n)},\ \mu\}$ 。由 $\int_{\theta_0}^{+\infty}\pi(\theta|x)d\theta=1$ 可得 $c^*(x)=(2n+1)\theta_0^{2n+1}$ ，所以

$$\pi(\theta|x)\sim(2n+1)\theta_0^{2n+1}\theta^{-(2n+2)}I\{\theta\ge\theta_0\}.$$

这是一个 Parato 分布, 即 $\pi(\theta|x)\sim PR((2n+1),\ \theta_0)$ 。实际上, 先验分布 $\theta\sim\mu\theta^{-2}I\{\theta\ge\mu\}$ 也是 Parato 分布，即 $\theta\sim PR(1,\ \mu)$ 是共轭先验分布。 ∎

2. 证明下列先验分布是共轭先验分布

(1) 设 $X_1,\cdots,X_n$ 为 $i.i.d.$ 样本， X_1 服从两点分布 $b(1,\theta)$ ，其中 θ 已知，样本容量 n 未知， n 的先验分布为 $P(\lambda)$ ；

(2) 设 $X_1,\cdots,X_n$ 为 $i.i.d.$ 样本， X_1 服从指数分布 $(1/\sigma)=\Gamma(1/\sigma,1)$ ， σ 的先验分布为逆 Γ 分布 $\Gamma^{-1}(a,p)$ ；

(3) 设 $X_1,\cdots,X_n$ 为 $i.i.d.$ 样本， X_1 服从负二项分布 $NB(\theta,r)$ ， r 已知， θ 未知；其先验分布为 $BE(p,q)$ ；

(4) 设 $X_1,\cdots,X_n$ 为 $i.i.d.$ 样本， $X_1\sim N_k(\theta,I_k)$, $\theta\in R^k$ ，并设 $\theta\sim N_k(\mu_0,\Sigma_0)$, 其中 μ_0 和 Σ_0 已知。

证明. (1) n 的后验分布密度函数为

$$\begin{aligned}\pi(n|x) &= c(x)\cdot\theta^{\sum_{i=1}^n x_i}(1-\theta)^{n-\sum_{i=1}^n x_i}\cdot e^{-\lambda}\frac{\lambda^n}{n!}\\ &= c(x)(\frac{\theta}{1-\theta})^T e^{-\lambda}\cdot\frac{[\lambda(1-\theta)]^n}{n!}\\ &= c^*(x)\exp\{-(1-\theta)\lambda\}\frac{[\lambda(1-\theta)]^n}{n!}\sim P((1-\theta)\lambda).\end{aligned}$$

所以 (1) 中的先验分布是共轭先验。

(2) σ 的后验分布密度函数为

$$\begin{aligned}\pi(\sigma|x) &= c(x)\cdot\frac{1}{\sigma^n}e^{-\frac{T}{\sigma}}\cdot\frac{a^p}{\Gamma(p)}e^{-\frac{a}{\sigma}}(\frac{1}{\sigma})^{p+1}\\ &= c^*(x)e^{-\frac{T+a}{\sigma}}(\frac{1}{\sigma})^{n+p+1}\sim\Gamma^{-1}(T+a,n+p),\end{aligned}$$

其中 $T=\sum_{i=1}^n x_i$ ，所以 (2) 中的先验分布是共轭先验。

(3) θ 的密度函数为

$$f(x,\theta)=\prod_{i=1}^n\binom{x_i+r-1}{x_i}\theta^r(1-\theta)^{x_i}=\left[\prod_{i=1}^n\binom{x_i+r-1}{x_i}\right]\theta^{nr}(1-\theta)^{\sum_{i=1}^n x_i},$$

因此 θ 的后验分布密度函数为

$$\begin{aligned}\pi(\theta|x) &= c(x)\cdot f(x;\theta)\cdot\frac{1}{\beta(p,q)}\theta^p(1-\theta)^q\\ &= c^*(x)\theta^{nr+p}(1-\theta)^{\sum_{i=1}^n x_i+q}\sim BE(nr+p,\sum_{i=1}^n x_i+q).\end{aligned}$$

所以 (3) 中的先验分布是共轭先验。

(4) 在一元正态分布中，均值的共轭先验为正态分布，因此我们猜测在多元正态分布中应有类似的结果，即 $\pi(\theta|x)\sim N_k(\mu,\Sigma)$ (见原书 8.1.4 式)，其中 $\mu=(nI_k+\Sigma_0^{-1})^{-1}(n\bar{x}+\Sigma_0^{-1}\mu_0)$, $\Sigma=(nI_k+\Sigma_0^{-1})^{-1}$ 。下面具体证明， $\pi(\theta|x)$ 确实服从多元正态 $N_k(\mu,\Sigma)$ 。 θ 的后验分布密度函数为

$$\begin{aligned}\pi(\theta|x) &= c(x)\exp\{-\frac{1}{2}\sum_{i=1}^n(x_i-\theta_i)^T(x_i-\theta_i)\}\cdot\exp\{-\frac{1}{2}(\theta-\mu_0)^T\Sigma_0^{-1}(\theta-\mu_0)\}\\ &= c(x)\exp\{-\frac{1}{2}\sum_{i=1}^n(x_i-\bar{x})^T(x_i-\bar{x})-\frac{1}{2}n(\theta-\bar{x})^T(\theta-\bar{x})\}\cdot\\ &\quad\exp\{-\frac{1}{2}(\theta-\mu_0)^T\Sigma_0^{-1}(\theta-\mu_0)\}\\ &= \tilde{c}(x)\exp\{-\frac{1}{2}[n\theta^T\theta-2n\theta^T\bar{x}+\theta^T\Sigma_0^{-1}\theta-2\theta^T\Sigma_0^{-1}\mu_0]\}\\ &= \tilde{c}(x)\exp\{-\frac{1}{2}[\theta^T(nI_k+\Sigma_0^{-1})\theta-2\theta^T(n\bar{x}+\Sigma_0^{-1}\mu_0)]\}\end{aligned}$$

$$
\begin{aligned}
&= \tilde{c}(x)\exp\{-\frac{1}{2}(\theta^T\Sigma^{-1}\theta - 2\theta^T\Sigma^{-1}\mu)\} \\
&= c^*(x)\exp\{-\frac{1}{2}(\theta-\mu)^T\Sigma^{-1}(\theta-\mu)\}.
\end{aligned}
$$

因此 $\pi(\theta|x) \sim N_k(\mu, \Sigma)$ ，所以 (4) 中的先验分布是共轭先验。 ∎

3. 设 $X_1, \cdots, X_n$ 为 *i.i.d.* 样本， X_1 服从幂函数分布 $X_1 \sim PF(c, \theta)$ ，即 $f(x_1; c, \theta) = cx_1^{c-1}\theta^{-c}I\{0 \le x_1 \le \theta\}$ $(c > 0;\ \theta > 0)$. 证明：若 c 已知，则 θ 的共轭先验分布为 Pareto 分布；若 θ 已知，则 c 的共轭先验分布为 Γ 分布。

证明. 当 c 已知时，不妨设 θ 服从 Pareto 分布，即

$$\pi(\theta) = \alpha\mu^\alpha\theta^{-(\alpha+1)}I\{\theta \ge \mu\}.$$

其中 $\alpha \ge 1$ 和 $\mu > 0$ 已知。则 θ 的后验分布密度函数为

$$
\begin{aligned}
\pi(\theta|x) &= c(x)\theta^{-nc}I\{\theta \ge x_{(n)}\} \cdot \alpha\mu^\alpha\theta^{-(\alpha+1)}I\{\theta \ge \mu\} \\
&= c^*(x)\theta^{-(nc+\alpha+1)}I\{\theta \ge \theta_0\}.
\end{aligned}
$$

其中 $\theta_0 = \max\{x_{(n)},\ \mu\}$ 。因此 $\pi(\theta|x) \sim PA(nc+\alpha,\ \theta_0)$ ，所以当 c 已知时 Pareto 分布为 θ 的共轭先验分布。

当 θ 已知时，不妨设 c 服从 Γ 分布 $\Gamma(a, p)$ ，即

$$\pi(c) = \frac{a^p}{\Gamma(p)}e^{-ac} \cdot c^{p-1}I\{c \ge 0\}.$$

其中 $a > 0,\ p > 0$ 已知。则 c 的后验分布密度函数

$$
\begin{aligned}
\pi(c|x) &= c(x)c^n(\prod_{i=1}^n x_i)^{c-1}\theta^{-nc} \cdot e^{-ac}c^{p-1} \\
&= c^*(x)c^{n+p-1}\exp\{-c[a - \sum_{i=1}^n(\log x_i - \log\theta)]\} \\
&\sim \Gamma(a - \sum_{i=1}^n(\log x_i - \log\theta),\ n+p)
\end{aligned}
$$

所以当 θ 已知时 Γ 分布为 c 的共轭先验分布。 ∎

4. 设 $X_1, \cdots, X_n$ 为 *i.i.d.* 样本， $X_1 \sim N(\mu, \sigma^2)$ ， μ 和 σ^2 都未知。又设 $\delta = \frac{1}{2\sigma^2}$ 的先验分布为 $\pi(\delta) \sim \Gamma(\alpha, p)$ ；在 σ^2 给定条件下， μ 的先验分布为 $\pi(\mu|\sigma^2) \sim N(\mu_0, \sigma_0^2/\delta)$ 。

(1) 求 (μ, δ) 的联合后验分布;

(2) 求 δ 的后验边缘分布，以及给定 δ 条件下 μ 的后验边缘分布。

解. (1) 由题意可知 (μ, δ) 的联合先验密度为

$$
\begin{aligned}
\pi(\mu, \delta) &= \pi(\mu|\sigma^2)\pi(\delta) \\
&= \frac{1}{\sqrt{2\pi}\sigma_0/\sqrt{\delta}}\exp\{-\frac{\delta}{2\sigma_0^2}(\mu-\mu_0)^2\} \cdot \frac{\alpha^p}{\Gamma(p)}e^{-\alpha\delta}\delta^{p-1}.
\end{aligned}
$$

所以 (μ,δ) 的联合后验密度函数为

$$\begin{aligned}\pi(\mu,\delta|x) &= c(x)(2\pi\sigma^2)^{-\frac{n}{2}}\exp\{-\delta\sum_{i=1}^{n}(x_i-\mu)^2\}\cdot\pi(\mu,\delta)\\ &= c^*(x)\cdot\delta^{\frac{n+1}{2}+p-1}\exp\{-\delta[\alpha+S^2+n(\mu-\bar{x})^2+\frac{(\mu-\mu_0)^2}{2\sigma_0^2}]\}.\end{aligned}$$

其中 α 及 $S^2=\sum_{i=1}^{n}(x_i-\bar{x})^2$ 与参数无关。又根据原书 p.347 的平方和公式可得

$$\begin{aligned}n(\mu-\bar{x})^2+\frac{(\mu-\mu_0)^2}{2\sigma_0^2} &= (n+\frac{1}{2\sigma_0^2})\mu^2-2(n\bar{x}+\frac{\mu_0}{2\sigma_0^2})\mu+n\bar{x}^2+\frac{\mu_0^2}{2\sigma_0^2}\\ &= (n+\frac{1}{2\sigma_0^2})(\mu-\xi)^2+m(x).\end{aligned}$$

其中

$$\xi=(n+\frac{1}{2\sigma_0^2})^{-1}(n\bar{x}+\frac{\mu_0}{2\sigma_0^2}),\quad m(x)=\frac{(\mu_0-\bar{x})^2}{2\sigma_0^2+1/n}.$$

所以 (μ,δ) 的联合后验密度函数可表示为

$$\pi(\mu,\delta|x)=c^*(x)\cdot\delta^{\frac{n+1}{2}+p-1}\cdot\exp\{-\delta[\alpha+S^2+m(x)+(n+\frac{1}{2\sigma_0^2})(\mu-\xi)^2]\}.$$

(2) 为了对 μ 进行积分，以上联合后验密度可表示为

$$\pi(\mu,\delta|x)=c^*(x)\cdot\delta^{\frac{n}{2}+p-1}\cdot\exp\{-\delta[\alpha+S^2+m(x)]\}\cdot\frac{1}{\sigma}\exp\{-\delta(n+\frac{1}{2\sigma_0^2})(\mu-\xi)^2\}.$$

所以 δ 的后验边缘分布为

$$\begin{aligned}\pi(\delta|x) &= \int_{-\infty}^{+\infty}\pi(\mu,\sigma^2|x)d\mu=c_1(x)\cdot\delta^{\frac{n}{2}+p-1}\exp\{-\delta[\alpha+S^2+m(x)]\}\\ &\sim \Gamma(\alpha+S^2+m(x),\ \ \frac{n}{2}+p).\end{aligned}$$

在给定 δ 的条件下 μ 的后验边缘分布为

$$\pi(\mu|\delta,x)=\frac{\pi(\mu,\delta|x)}{\pi(\delta|x)}=c_2(x)\frac{1}{\sigma}\exp\{-\delta(n+\frac{1}{2\sigma_0^2})(\mu-\xi)^2\}.$$

易见这是一个正态分布 $\pi(\mu|\delta,x)\sim N(\xi,\ \ [(2n+\sigma_0^{-2})\delta]^{-1})$ 。 ∎

5. 设 $X_1,\cdots,X_n$ 为 *i.i.d.* 样本， $X_1\sim N(\mu,\sigma^2)$, 其中 μ 和 $\delta=\sigma^2$ 未知，又设 $\theta=(\mu,\delta)$ 的先验密度 $\pi(\theta)=\delta^{-1}I\{\delta>0\}$ 。证明：

(1) $\theta=(\mu,\delta)$ 的后验密度函数可表示为 $\pi(\theta|X)=\pi_1(\mu|\delta,X)\pi_2(\delta|X)$, 其中：$\pi_1(\mu|\delta,X)\sim N(\overline{X},\delta/n)$, $\pi_2(\delta|X)$ 服从逆 Γ 分布 $\Gamma^{-1}(s,\ n')$ ，其中 $n'=\frac{n-1}{2}$, $s=\frac{1}{2}\sum_{i=1}^{n}(X_i-\overline{X})^2$;

(2) δ 的后验边缘分布服从逆 Γ 分布 $\Gamma^{-1}(s,\ n')$;

(3) μ 的后验边缘密度函数是 $\frac{1}{\tau}f((\mu-\overline{X})/\tau)$, 其中 $\tau^2=\frac{1}{n(n-1)}\sum_{i=1}^{n}(X_i-\overline{X})^2$; $f(\cdot)$ 是自由度为 $n-1$ 的 t 分布的密度函数。

证明. (1) 因为 $(\mu,\delta)^T$ 的后验分布密度函数为

$$\begin{aligned}\pi(\mu,\delta|x) &= c(x)\cdot\delta^{-1}\cdot(2\pi\delta)^{-\frac{n}{2}}\exp\{-\frac{\sum_{i=1}^n(x_i-\mu)^2}{2\delta}\}\\ &= c(x)\cdot(2\pi)^{-\frac{n}{2}}\cdot\delta^{-\frac{n+2}{2}}\exp\{-\frac{1}{2\delta}[\sum_{i=1}^n(x_i-\bar{x})^2+n(\mu-\bar{x})^2]\}\\ &= c^*(x)\cdot(\frac{1}{\delta})^{\frac{n-1}{2}+1}\exp\{-\frac{\sum_{i=1}^n(x_i-\bar{x})^2/2}{\delta}\}\cdot\frac{1}{\sqrt{\delta}}\cdot\exp\{-\frac{(\mu-\bar{x})^2}{2\delta/n}\}\end{aligned}$$

其中 $c^*(x)$ 是正则化因子，满足 $\int_0^\infty\int_{-\infty}^{+\infty}\pi(\mu,\delta|x)d\mu\ d\delta=1$ 。上式最后一项关于 μ 为正态分布，所以 δ 的后验边缘密度函数为

$$\begin{aligned}\pi(\delta|x) &= \int_{-\infty}^{+\infty}\pi(\mu,\delta|X)d\mu\\ &= \tilde{c}(x)\cdot(\frac{1}{\delta})^{\frac{n-1}{2}+1}\exp\{-\frac{1}{\delta}\cdot[\frac{\sum_{i=1}^n(x_i-\bar{x})^2}{2}]\}\\ &\sim \Gamma^{-1}(s,n').\end{aligned}$$

从而有

$$\pi(\mu|\delta,x)=\frac{\pi(\mu,\delta|x)}{\pi(\delta|x)}=c_1\cdot\frac{1}{\sqrt{\delta}}\exp\{-\frac{(\mu-\bar{x})^2}{2\delta/n}\}\sim N(\bar{x},\frac{\delta}{n}).$$

所以 $\theta=(\mu,\delta)$ 的后验密度函数可表示为 $\pi(\theta|x)=\pi_1(\mu|\delta,x)\pi_2(\delta|x)$, 其中： $\pi_1(\mu|\delta,x)\sim N(\overline{x},\delta/n)$, $\pi_2(\delta|x)$ 服从逆 Γ 分布 $\Gamma^{-1}(s,\ n')$ 。

(2) 由 (1) 已经得知 $\pi_2(\delta|x)$ 服从逆 Γ 分布 $\Gamma^{-1}(s,\ n')$ 。

(3) 为求 μ 的后验边缘密度，必须求积分 $\pi(\mu|x)=\int_0^\infty\pi(\mu,\delta|X)d\delta$ 。由 (1) ，该积分可表示为

$$\pi(\mu|x)=\int_0^\infty c^*(x)(\frac{1}{\delta})^{\frac{n}{2}+1}\exp\{-\frac{1}{\delta}\cdot\frac{\sum_{i=1}^n(x_i-\bar{x})^2+n(\mu-\bar{x})^2}{2}\}d\delta.$$

注意，以上积分的被积可看做 $\Delta\sim\Gamma^{-1}(s,\ n/2)$ 的密度函数 (仅相差一个常数) ，其中 $s=\sum_{i=1}^n[(x_i-\bar{x})^2+n(\bar{x}-\mu)^2]/2$ 。因此由其密度函数的积分为 1 可得

$$\int_0^\infty\frac{1}{\Gamma(\frac{n}{2})}[\frac{\sum_{i=1}^n(x_i-\bar{x})^2+n(\bar{x}-\mu)^2}{2}]^{\frac{n}{2}}\cdot(\frac{1}{\delta})^{\frac{n}{2}+1}\exp\{-\frac{1}{\delta}\cdot\frac{\sum_{i=1}^n(x_i-\bar{x})^2+n(\bar{x}-\mu)^2}{2}\}d\delta=1.$$

所以有

$$\begin{aligned}&\int_0^\infty(\frac{1}{\delta})^{\frac{n}{2}+1}\exp\{-\frac{1}{\delta}\cdot\frac{\sum_{i=1}^n(x_i-\bar{x})^2+n(\bar{X}-\mu)^2}{2}\}d\delta\\ =\ &\Gamma(\frac{n}{2})2^{\frac{n}{2}}[\sum_{i=1}^n(x_i-\bar{x})^2+n(\bar{x}-\mu)^2]^{-\frac{n}{2}}\\ =\ &c_1(x)[1+\frac{n(\mu-\bar{x})^2}{\sum_{i=1}^n(x_i-\bar{x})^2}]^{-\frac{n}{2}}.\end{aligned}$$

从而 μ 的后验边缘密度函数为

$$\pi(\mu|x) = \int_0^\infty\pi(\mu,\delta|X)d\delta$$

$$
\begin{aligned}
&= \int_0^{\infty} c^*(x)(\frac{1}{\delta})^{\frac{n}{2}+1}\exp\{-\frac{1}{\delta}\cdot\frac{\sum_{i=1}^n(x_i-\bar{x})^2+n(\mu-\bar{x})^2}{2}\}d\delta \\
&= c(x)[1+\frac{n(\mu-\bar{x})^2}{\sum_{i=1}^n(x_i-\bar{x})^2}]^{-\frac{n}{2}} \\
&= c(x)[1+(\frac{\mu-\bar{x}}{\tau})^2\cdot\frac{1}{n-1}]^{-\frac{(n-1)+1}{2}}.
\end{aligned}
$$

上式即为自由度为 $n-1$ ，自变量为 $\frac{\mu-\bar{x}}{\tau}$ 的 t 分布的核，所以 $\pi(\mu|X)=c_1(x)f(\frac{\mu-\bar{X}}{\tau})$ ，而由 $\int_{-\infty}^{\infty}\pi(\mu|x)d\mu=1$ 可得 $c_1(x)=1/\tau$ ，因此 $\pi(\mu|X)=\frac{1}{\tau}f(\frac{\mu-\bar{X}}{\tau})$ ， ∎

6. 设 $X=(X_1,\cdots,X_k)^T$ 服从多项分布 $MN(n,\theta)$, 即 $f(x;\theta)=\frac{n!}{x_1!\cdots x_k!}\prod_{i=1}^k\theta_i^{x_i}$ ，其中 $\theta=(\theta_1,\cdots,\theta_k)^T$ 为参数， $\sum_{i=1}^k\theta_i=1$, $\sum_{i=1}^k x_i=n$ ， θ 的先验分布为 Dirichlet 分布，即为

$$
\pi(\theta)=\frac{\Gamma(\alpha_0)}{\prod_{i=1}^k\Gamma(\alpha_i)}\prod_{i=1}^k\theta_i^{\alpha_i-1};\quad (0\le\theta_i\le 1,\ \ 1\le i\le k).
$$

其中 $\alpha_i>0,\ i=1,\cdots,k;\ \sum_{i=1}^k\alpha_i=\alpha_0$ 。记 $\alpha=(\alpha_1,\cdots,\alpha_k)^T$ ，并把这一分布记为 $D(\alpha)$ 。证明： θ 的后验分布服从 Dirichlet 分布 $D(\alpha+x)$ 。

证明. 因为 θ 的后验分布密度函数为

$$
\begin{aligned}
\pi(\theta|x) &= c(x)\cdot\frac{n!}{x_1!\cdots x_k!}\prod_{i=1}^k\theta_i^{x_i}\cdot\frac{\Gamma(\alpha_0)}{\prod_{i=1}^k\Gamma(\alpha_i)}\prod_{i=1}^k\theta_i^{\alpha_i-1} \\
&= c^*(x)\prod_{i=1}^k\theta_i^{\alpha_i+x_i-1}
\end{aligned}
$$

所以 θ 的后验分布服从 Dirichlet 分布 $D(\alpha+x)$ 。 ∎

7. 设 $X=(X_1,\cdots,X_n)^T$ 服从指数族分布： $f(x,\theta)=h(x)\exp\{\sum_{i=1}^k Q_i(\theta)T_i(x)-b(\theta)\}$ 。

(1) 证明： $\pi(\theta)=c(\alpha,m)\exp\{\sum_{i=1}^k\alpha_iQ_i(\theta)-mb(\theta)\}$ 为 θ 的共轭先验分布;

(2) 把以上结果用于双参数的 β 分布和 Γ 分布。

证明. (1) 为明确起见， θ 的先验分布记为 $\pi(\theta;\ \alpha,m)$ ，则 θ 的后验分布为

$$
\begin{aligned}
\pi(\theta|x) &= c(x)\cdot\exp\{\sum_{i=1}^k Q_i(\theta)T_i(x)-b(\theta)\}\cdot\exp\{\sum_{i=1}^k\alpha_iQ_i(\theta)-mb(\theta)\} \\
&= c(x)\cdot\exp\{\sum_{i=1}^k Q_i(\theta)[T_i(x)+\alpha_i]-(m+1)b(\theta)\}.
\end{aligned}
$$

它显然与 $\pi(\theta)$ 属于同一分布族，即 $\pi(\theta|x)\sim\pi(\theta;\ \alpha',m')$ ，其中 $\alpha_i'=\alpha_i+T_i(x)$ ， $m'=m+1$ ，所以 $\pi(\theta)$ 为 θ 的共轭先验分布。

(2) 对于双参数的 β 分布 $BE(p,q)$ ，样本 $X=(X_1,\cdots,X_n)^T$ 的密度函数为

$$
\begin{aligned}
f(x,\theta) &= \prod_{i=1}^n[\frac{1}{\beta(p,q)}x_i^{p-1}(1-x_i)^{q-1}]=\beta^{-n}(p,q)(\prod_{i=1}^n x_i)^{p-1}[\prod_{i=1}^n(1-x_i)]^{q-1} \\
&= h(x)\exp\{p\log(\prod_{i=1}^n x_i)+q\log[\prod_{i=1}^n(1-x_i)]-n\log\beta(p,q)\}.
\end{aligned}
$$

记 $\theta=(p,q)^T$ ，则 $f(x,\theta)$ 服从指数族分布，其中

$$Q_1(\theta)=p,\quad T_1(x)=\log(\prod_{i=1}^n x_i)=\sum_{i=1}^n \log x_i,$$

$$Q_2(\theta)=q,\quad T_2(x)=\log[\prod_{i=1}^n(1-x_i)]=\sum_{i=1}^n \log(1-x_i),\quad b(\theta)=n\log\beta(p,q)$$

由 (1) 可知， $\theta=(p,q)^T$ 的共轭先验分布可取为

$$\pi(\theta)=c(\alpha,m)\exp\{p\alpha_1+q\alpha_2-mb(\theta)\}.$$

其后验分布为

$$\begin{aligned}\pi(\theta|x) &= c(x)\cdot\exp\{\sum_{i=1}^k Q_i(\theta)\alpha_i'-m'b(\theta)\}\\ &= c(x)\cdot\exp\{p[\alpha_1+\sum_{i=1}^n\log x_i]+q[\alpha_2+\sum_{i=1}^n\log(1-x_i)]-(m+1)b(\theta)\}.\end{aligned}$$

对于双参数的 Γ 分布 $\Gamma(\lambda,\nu)$ ，样本 $X=(X_1,\cdots,X_n)^T$ 的密度函数为

$$\begin{aligned}f(x,\theta) &= \prod_{i=1}^n[\frac{\lambda^\nu}{\Gamma(\nu)}e^{-\lambda x_i}x_i^{\nu-1}]=\frac{\lambda^{n\nu}}{\Gamma^n(\nu)}e^{-\lambda\sum_{i=1}^n x_i}(\prod_{i=1}^n x_i)^{\nu-1}\\ &= h(x)\exp\{-\lambda\sum_{i=1}^n x_i+\nu\log(\prod_{i=1}^n x_i)-(n\log\Gamma(\nu)-n\nu\log\lambda)\}.\end{aligned}$$

记 $\theta=(\lambda,\nu)^T$ ，则 $f(x,\theta)$ 服从指数族分布，其中

$$Q_1(\theta)=\lambda,\quad T_1(x)=\sum_{i=1}^n x_i,$$

$$Q_2(\theta)=\nu,\quad T_2(x)=\log(\prod_{i=1}^n x_i)=\sum_{i=1}^n\log x_i,\quad b(\theta)=n\log\Gamma(\nu)-n\nu\log\lambda$$

由 (1) 可知， $\theta=(p,q)^T$ 的共轭先验分布可取为

$$\pi(\theta)=c(\alpha,m)\exp\{\lambda\alpha_1+\nu\alpha_2-mb(\theta)\}.$$

其后验分布为

$$\pi(\theta|x)=c(x)\cdot\exp\{\lambda[\alpha_1+\sum_{i=1}^n x_i]+\nu[\alpha_2+\sum_{i=1}^n\log x_i]-(m+1)b(\theta)\}.$$

∎

8. 设 $X_1,\cdots,X_n$ 为 *i.i.d.* 样本，由 Jeffreys 准则确定以下参数的先验分布：

(1) $X_1\sim\Gamma(\lambda;\nu)$ ，但 ν 已知； λ 未知；

(2) $X_1\sim \mathrm{E}(1/\theta)$ 为寿命分布，但只观测到前 r 个寿命的值： $Y_1=X_{(1)},\cdots,Y_r=X_{(r)}$ ；

(3) $X_1\sim NB(\theta,r)$, 但 r 已知， θ 未知;

(4) $X=(X_1,\cdots,X_k)^T$ 服从第 6 题的多项分布 $MN(n,\theta)$ 。

解. (1) 因为 λ 的 Fisher 信息为 $I(\lambda)=n\nu/\lambda^2$ ，所以由 Jeffreys 准则得 λ 的先验分布为

$$\pi(\lambda)=|I(\lambda)|^{\frac{1}{2}}\propto\lambda^{-1}.$$

(2) 因为 θ 的 Fisher 信息为 $I(\theta)=(r-2)/\theta^2$ ，所以由 Jeffreys 准则得 θ 的先验分布为

$$\pi(\theta)=|I(\theta)|^{\frac{1}{2}}\propto\theta^{-1}.$$

(3) 因为 θ 的 Fisher 信息为 $I(\theta)=nr/\theta^2(1-\theta)$ ，所以由 Jeffreys 准则得 θ 的先验分布为

$$\pi(\theta)=|I(\theta)|^{\frac{1}{2}}\propto\theta^{-1}(1-\theta)^{-\frac{1}{2}}.$$

(4) 因为 θ 的 Fisher 信息为

$$I(\theta)=\begin{pmatrix}\frac{n}{\theta_1} & \cdots & 0\\ \vdots & \ddots & \vdots\\ 0 & \cdots & \frac{n}{\theta_k}\end{pmatrix},$$

所以由 Jeffreys 准则得 θ 的先验分布为

$$\pi(\theta)=|I(\theta)|^{\frac{1}{2}}\propto(\prod_{i=1}^{k}\theta_i)^{-\frac{1}{2}}.$$

∎

9. 根据 Jeffreys 准则证明：

(1) 若 $X=(X_1,\cdots,X_n)^T$ 服从位置参数分布 $f(x-\mu\mathbf{1})$ ，则 $\pi(\mu)\propto 1$ ；

(2) 若 $X=(X_1,\cdots,X_n)^T$ 服从尺度参数分布 $\sigma^{-n}f(x/\sigma)$ ，则 $\pi(\sigma)\propto 1/\sigma$;

(3) 若 $X=(X_1,\cdots,X_n)^T$ 服从位置尺度参数分布族 $\sigma^{-n}f((x-\mu\mathbf{1})/\sigma)$ ，则 $\pi(\sigma,\mu)\propto 1/\sigma^2$ 。

证明. 由第二章习题 24 知，对于位置尺度参数分布族

$$\sigma^{-n}f((x-\mu\mathbf{1})/\sigma)=\sigma^{-n}\prod_{i=1}^{n}f(\frac{x_i-\mu}{\sigma}),$$

其 Fisher 信息阵为

$$I(\mu,\sigma)=\frac{n}{\sigma^2}\begin{pmatrix}\int\frac{[f'(x)]^2}{f(x)}dx & \int x\frac{[f'(x)]^2}{f(x)}dx\\ \int x\frac{[f'(x)]^2}{f(x)}dx & \int\frac{[xf'(x)+f(x)]^2}{f(x)}dx\end{pmatrix}.$$

这可用于本题的 3 种情形。

(1) 取 $\sigma=1$ ，则位置参数分布族 $f(x-\mu\mathbf{1})=\prod_{i=1}^{n}f(x_i-\mu)$ 的 Fisher 信息为 $I(\mu)=n\int\frac{[f'(x)]^2}{f(x)}dx$ ，它是常数，与 μ 无关，所以由 Jeffreys 准则可得 μ 的先验分布为 $\pi(\mu)=|I(\mu)|^{\frac{1}{2}}\propto 1$ 。

(2) 取 $\mu=0$ ，则尺度参数分布族 $\sigma^{-n}f(x/\sigma)=\sigma^{-n}\prod_{i=1}^{n}f(\frac{x_i}{\sigma})$ 的 Fisher 信息为

$$I(\sigma)=\frac{n}{\sigma^2}\int\frac{[xf'(x)+f(x)]^2}{f(x)}dx,$$

其中 $\int \frac{[xf'(x)+f(x)]^2}{f(x)}dx$ 是常数，与 σ 无关，所以由 Jeffreys 准则可得 σ 的先验分布为 $\pi(\sigma)=|I(\sigma)|^{\frac{1}{2}} \propto \sigma^{-1}$ 。

(3) 此时 (μ,σ) 的 Fisher 信息阵的行列式为 $|I(\mu,\sigma)| \propto \sigma^{-4}$ ，所以由 Jeffreys 准则可得 (μ,σ) 的联合先验分布为 $\pi(\mu,\sigma)=|I(\mu,\sigma)|^{\frac{1}{2}} \propto \sigma^{-2}$ 。 ∎

注. 以上结果说明，对于位置尺度参数分布族，由 Jeffreys 准则得到的先验分布与无信息先验分布是一致的。 ∎

10. 设 $X_1,\cdots,X_n$ 为 *i.i.d.* 样本，在均方损失下，求相应参数的 Bayes 估计：

(1) $X_1 \sim f(x_1,\theta)=2x_1\theta^{-2}I\{0\le x_1\le\theta\}$ ， θ 服从 Pareto 分布 $PR(\alpha,\mu)$ ；

(2) $X_1 \sim f(x_1,\lambda)=\lambda^2x_1e^{-\lambda x_1}I\{x_1\ge 0\}$ ， λ 服从 Γ 分布 $\Gamma(a,\ p)$ ；

(3) $X_1 \sim \Gamma(1/\sigma;\nu)$, ν 已知， σ 服从逆 Γ 分布 $\Gamma^{-1}(a,\ p)$ ；

(4) $X_1 \sim f(x_1;c)=cx_1^{c-1}I\{0\le x_1\le 1\}$ $(c>0)$ ， c 服从 Γ 分布 $\Gamma(a,p)$ 。

解. (1) 由习题 3 的结论 (取 c=2) 知

$$\pi(\theta|x)=(2n+\alpha)\theta_0^{2n+\alpha}\theta^{-(2n+\alpha+1)}I\{\theta\ge\theta_0\}\sim PA(2n+\alpha,\theta_0),$$

其中 $\theta_0=\max\{X_{(n)},\ \mu\}$ ，所以 θ 的 Bayes 估计为

$$\hat{\theta}=\mathrm{E}[\theta|X]=\frac{2n+\alpha}{2n+\alpha-1}\theta_0.$$

(2) 由于 $X_1\sim\Gamma(\lambda,2)$ ，所以 λ 的后验分布为

$$\begin{aligned}\pi(\lambda|x) &\propto \lambda^{2n}\prod_{i=1}^n x_i\exp\{-\lambda\sum_{i=1}^n x_i\}\cdot\frac{a^p}{\Gamma(p)}e^{-a\lambda}\cdot\lambda^{p-1}\\ &\propto \exp\{-\lambda(\sum_{i=1}^n x_i+a)\}\cdot\lambda^{2n+p-1}\\ &\sim \Gamma(a+\sum_{i=1}^n x_i,\ 2n+p).\end{aligned}$$

因此 λ 的 Bayes 估计为

$$\hat{\lambda}=\mathrm{E}[\lambda|X]=\frac{2n+p}{a+\sum_{i=1}^n X_i}.$$

(3) σ 的后验分布为

$$\begin{aligned}\pi(\sigma|x) &\propto \frac{\sigma^{-n\nu}}{\Gamma^n(\nu)}(\prod_{i=1}^n x_i)^{\nu-1}\exp\{-\frac{1}{\sigma}\sum_{i=1}^n x_i\}\cdot\frac{a^p}{\Gamma(p)}e^{-\frac{a}{\sigma}}\cdot(\frac{1}{\sigma})^{p+1}\\ &\propto \exp\{-\frac{1}{\sigma}(\sum_{i=1}^n x_i+a)\}\cdot(\frac{1}{\sigma})^{n\nu+p+1}\\ &\sim \Gamma^{-1}(\sum_{i=1}^n x_i+a,\ n\nu+p).\end{aligned}$$

所以 σ 的 Bayes 估计为

$$\hat{\sigma}=\mathrm{E}[\sigma|X]=\frac{1}{n\nu+p-1}(\sum_{i=1}^n X_i+a).$$

(4) c 的后验分布为

$$\begin{aligned}\pi(c|x) &\propto c^n(\prod_{i=1}^n x_i)^{c-1}\cdot\frac{a^p}{\Gamma(p)}e^{-ac}\cdot c^{p-1}\\ &\propto c^{n+p-1}\exp\{-c[a-\log\prod_{i=1}^n x_i]\}\\ &\sim \Gamma(a-\sum_{i=1}^n\log x_i,\ n+p),\end{aligned}$$

所以 c 的 Bayes 估计为

$$\hat{c}=\mathrm{E}[c|X]=\frac{n+p}{a-\sum_{i=1}^n\log X_i}.$$

∎

11. 设 $X_1,\cdots,X_n$ 为 *i.i.d.* 样本， $X_1\sim N(\mu,\theta)$ 。

(1) 若 $\theta=1$ ， μ 的先验分布为 $\pi(\mu)=e^{a\mu},\ a>0$ ，在均方损失下，求 $\mu,\ \mu^2$ 的 Bayes 估计；

(2) 若 μ 已知， $\theta\sim\Gamma^{-1}(a,\ p)$ ，求 θ 的后验期望估计；

(3) 条件同 (2) ，在损失函数 $L(\theta,d)=\frac{(d-\theta)^2}{\theta^2}$ 下，求 θ 的 Bayes 估计。

解. (1) μ 的后验分布为

$$\begin{aligned}\pi(\mu|x) &\propto (\frac{1}{\sqrt{2\pi}})^n\exp\{-\frac{\sum_{i=1}^n(x_i-\mu)^2}{2}\}\cdot e^{a\mu}\\ &\propto \exp\{-\frac{n}{2}(\mu-\frac{n\bar{x}+a}{n})^2\}\\ &\sim N(\frac{n\bar{x}+a}{n},\ \frac{1}{n}),\end{aligned}$$

所以 μ 和 μ^2 的 Bayes 估计分别为

$$\hat{\mu}=\mathrm{E}[\mu|X]=\bar{X}+\frac{a}{n},\quad \hat{\mu}^2=\mathrm{E}[\mu^2|X]=\mathrm{Var}(\mu|X)+\mathrm{E}^2(\mu|X)=\frac{1}{n}+(\bar{X}+\frac{a}{n})^2.$$

(2) θ 的后验分布为

$$\begin{aligned}\pi(\theta|x) &\propto (\frac{1}{\sqrt{2\pi\theta}})^n\exp\{-\frac{1}{2\theta}\sum_{i=1}^n(x_i-\mu)^2\}\cdot\frac{a^p}{\Gamma(p)}e^{-\frac{a}{\theta}}(\frac{1}{\theta})^{p+1}\\ &\propto \exp\{-\frac{1}{\theta}(a+\frac{1}{2}\sum_{i=1}^n(x_i-\mu)^2)\}\cdot(\frac{1}{\theta})^{\frac{n}{2}+p+1}\\ &\sim \Gamma^{-1}(a+\frac{1}{2}\sum_{i=1}^n(x_i-\mu)^2,\ \frac{n}{2}+p),\end{aligned}$$

所以 θ 的 Bayes 估计为

$$\hat{\theta}=\mathrm{E}[\theta|X]=\frac{1}{\frac{n}{2}+p-1}(a+\frac{1}{2}\sum_{i=1}^n(X_i-\mu)^2)=\frac{1}{n+2p-2}(2a+\sum_{i=1}^n(X_i-\mu)^2).$$

(3) 这时损失函数为 $L(\theta,d)=\lambda(\theta)(d-\theta)^2$ ， $\lambda(\theta)=\theta^{-2}$ ，所以 θ 的 Bayes 估计为

$$\begin{aligned}\hat{\theta} &= \frac{\mathrm{E}[\theta\lambda(\theta)|X]}{\mathrm{E}[\lambda(\theta)|X]}=\frac{\mathrm{E}[\theta^{-1}|X]}{\mathrm{E}[\theta^{-2}|X]}\\ &= \frac{(\frac{n}{2}+p)/(a+\frac{1}{2}\sum_{i=1}^n(X_i-\mu)^2)}{(\frac{n}{2}+p)(\frac{n}{2}+p+1)/(a+\frac{1}{2}\sum_{i=1}^n(X_i-\mu)^2)^2}\\ &= \frac{2a+\sum_{i=1}^n(X_i-\mu)^2}{n+2p+2}\end{aligned}$$

∎

12. 设 $X_1,\cdots,X_n$ 为 *i.i.d.* 样本， $X_1\sim N(\mu,\sigma^2)$ ， μ 和 σ^2 都未知。又设 $\delta=\frac{1}{2\sigma^2}$ 的先验分布为 $\pi(\delta)\sim\Gamma(a,\ p)$ ；在 σ^2 给定条件下， μ 的先验分布为 $\pi(\mu|\sigma^2)\sim N(\mu_0,\sigma_0^2/\delta)$ 。在均方损失下，求 $\mu,\ \sigma^2$ 的 Bayes 估计。

解. 由习题 4 知 (μ,δ) 的联合后验分布密度函数为

$$\pi(\mu,\delta|x)=c^*(x)\delta^{\frac{n+1}{2}+p-1}\exp\{-\delta[a+S^2+m(x)]\}\cdot\exp\{-\delta(n+\frac{1}{2\sigma_0^2})(\mu-\xi)^2\},$$

其中 $\xi=(n+\frac{1}{2\sigma_0^2})^{-1}(n\bar{x}+\frac{1}{2\sigma_0^2}\mu_0)$, $S^2=\sum_{i=1}^n(x_i-\bar{x})^2$, $m(x)=(2\sigma_0^2+1/n)^{-1}(\mu_0-\bar{x})^2$ 。 δ 的后验边缘分布为 $\pi(\delta|X)\sim\Gamma(a+S^2+m(x),\ \frac{n}{2}+p)$, $\sigma^2=\frac{1}{2\delta}$ ，所以 σ^2 的 Bayes 估计为

$$\hat{\sigma}^2=\frac{1}{2}\int_0^\infty\int_{-\infty}^\infty\delta^{-1}\ \pi(\mu,\delta|X)d\delta d\mu=\frac{1}{2}\int_0^\infty\delta^{-1}\pi(\delta|X)d\delta=\frac{a+S^2+m(X)}{n+2p-2}.$$

μ 的后验边缘分布的计算与第 5 题的 (3) 很类似。为求 μ 的后验边缘密度，必须求积分 $\pi(\mu|x)=\int_0^\infty\pi(\mu,\delta|x)d\delta$ 。由 $\pi(\mu,\delta|x)$ 的公式可知，该积分可表示为

$$\pi(\mu|x)=\int_0^\infty c^*(x)\delta^{\frac{n+1}{2}+p-1}\exp\{-\delta[a+S^2+m(x)+(n+\frac{1}{2\sigma_0^2})(\mu-\xi)^2]\}d\delta.$$

注意，以上积分的被积可看做 $\Delta\sim\Gamma(s,\ \frac{n+1}{2}+p)$ 的密度函数 (仅相差一个常数) ，其中 $s=a+S^2+m(x)+(n+\frac{1}{2\sigma_0^2})(\mu-\xi)^2$ 。因此由其密度函数的积分为 1 可得

$$\int_0^\infty\delta^{\frac{n+1}{2}+p-1}\exp\{-\delta[a+S^2+m(x)+(n+\frac{1}{2\sigma_0^2})(\mu-\xi)^2]\}d\delta=\Gamma(\frac{n+1}{2}+p)/s^{\frac{n+1}{2}+p}.$$

因此 μ 的后验边缘密度可表示为

$$\begin{aligned}\pi(\mu|x) &= \int_0^\infty\pi(\mu,\delta|x)d\delta\\ &= c_1(x)[a+S^2+m(x)+(n+\frac{1}{2\sigma_0^2})(\mu-\xi)^2]^{-\frac{n+2p+1}{2}}\\ &= c(x)[1+\frac{(n+\frac{1}{2\sigma_0^2})(\mu-\xi)^2}{a+S^2+m(x)}]^{-\frac{(n+2p)+1}{2}}\\ &= c(x)[1+\frac{1}{n+2p}t^2]^{-\frac{(n+2p)+1}{2}}\sim c_1(x)t(n+2p),\end{aligned}$$

其中 $t^2=[(n+2p)(n+\frac{1}{2\sigma_0^2})/(a+S^2+m(x))](\mu-\xi)^2\triangleq K^2(\mu-\xi)^2$ ，而 $t=K(\mu-\xi)$ 为 μ 的一个线性变换。记 $\pi(\mu|x)=c_1(x)f(t)$ ，因为 $\pi(\mu|x)$ 关于 $t=0$ 对称，所以 μ 的 Bayes

估计可表示为

$$\begin{aligned}\hat{\mu} &= \int_{-\infty}^{\infty}\int_{0}^{\infty} \mu\ \pi(\mu,\delta|X)d\delta\ d\mu \\ &= \int_{-\infty}^{\infty} \mu\ \pi(\mu|X)d\mu = \int_{-\infty}^{+\infty}[(\mu-\xi)+\xi]\pi(\mu|X)d\mu \\ &= \int_{-\infty}^{+\infty} c_1(x)\frac{1}{K}tf(t)dt + \xi\int_{-\infty}^{+\infty}\pi(\mu|X)d\mu = \xi.\end{aligned}$$

∎

13. 设 $X_1,\cdots,X_n$ 为 *i.i.d.* 样本， $X_1\sim P(\lambda),\ \lambda\sim\Gamma(a,p)$ 。

(1) 在均方损失下，求 $g(\lambda)=\lambda^j\ \ (j\geq 1)$ 的 Bayes 估计;

(2) 在损失函数 $L(\lambda,d)=\frac{(d-\lambda)^2}{\lambda}$ 下，求 λ 的 Bayes 估计及其后验风险和 Bayes 风险。

解. (1) 由原书例 8.1.3 可知， λ 的后验分布为 $\pi(\lambda|X)\sim\Gamma(n+a,T+p)$ ，其中 $T=\sum_{i=1}^n X_i$ 。所以 $g(\lambda)=\lambda^j\ \ (j\geq 1)$ 的 Bayes 估计为

$$\begin{aligned}\hat{g}(\lambda) &= \mathrm{E}[g(\lambda)|X]=\mathrm{E}[\lambda^j|X] \\ &= \int_0^{\infty}\frac{(n+a)^{T+p}}{\Gamma(T+p)}\lambda^{T+p+j-1}e^{-(n+a)\lambda}d\lambda \\ &= \frac{\Gamma(T+p+j)}{(n+a)^{T+p+j}}\cdot\frac{(n+a)^{T+p}}{\Gamma(T+p)} \\ &= (n+a)^{-j}\prod_{i=0}^{j-1}(T+p+i).\end{aligned}$$

(2) 因为 $\pi(\lambda|X)\sim\Gamma(n+a,T+p)$ ，其中 $T=\sum_{i=1}^n X_i\sim P(n\lambda)$ ，所以 λ 的 Bayes 估计为

$$\hat{\lambda}=\frac{\mathrm{E}[\lambda\cdot\frac{1}{\lambda}|X]}{\mathrm{E}[\frac{1}{\lambda}|X]}=\frac{1}{\frac{n+a}{T+p-1}}=\frac{T+p-1}{n+a}.$$

其后验风险为

$$\begin{aligned}R_\pi(\hat{\lambda}|X) &= \mathrm{E}[\frac{(\hat{\lambda}-\lambda)^2}{\lambda}|X]=\mathrm{E}[\lambda-2\hat{\lambda}+\frac{\hat{\lambda}^2}{\lambda}|X] \\ &= \frac{T+p}{n+a}-\frac{2(T+p-1)}{n+a}+\frac{(T+p-1)^2}{(n+a)^2}\cdot\frac{n+a}{T+p-1}=\frac{1}{n+a}.\end{aligned}$$

其 Bayes 风险为

$$R_\pi(\hat{\lambda})=\int_x R_\pi(\hat{\lambda}|X)p(x)dx=\frac{1}{n+a}\int_x p(x)dx=\frac{1}{n+a}.$$

∎

注. 也可根据 Bayes 风险的定义直接进行计算，即先计算 $\hat{\lambda}$ 的风险函数，再计算 Bayes 风险

$$\begin{aligned}R(\lambda,\hat{\lambda}) &= \mathrm{E}[\frac{(\hat{\lambda}-\lambda)^2}{\lambda}]=\mathrm{E}_\lambda[\lambda-2\hat{\lambda}+\frac{\hat{\lambda}^2}{\lambda}] \\ &= \lambda-\frac{2(n\lambda+p-1)}{n+a}+\frac{n\lambda+n^2\lambda^2+2(p-1)n\lambda+(p-1)^2}{(n+a)^2\lambda} \\ &= \lambda-\frac{2n\lambda}{n+a}+\frac{n^2\lambda}{(n+a)^2}+\frac{(p-1)^2}{(n+a)^2\lambda}-\frac{2(p-1)}{n+a}+\frac{n(2p-1)}{(n+a)^2}.\end{aligned}$$

所以其 Bayes 风险为

$$\begin{aligned}
R_\pi(\hat{\lambda}) &= \int_0^\infty R(\hat{\lambda},\lambda)\frac{a^p}{\Gamma(p)}\cdot e^{-a\lambda}\lambda^{p-1}d\lambda \\
&= \frac{p}{a}-\frac{2n}{n+a}\cdot\frac{p}{a}+\frac{n^2}{(n+a)^2}\cdot\frac{p}{a}+\frac{(p-1)^2}{(n+a)^2}\cdot\frac{a}{p-1}-\frac{2(p-1)}{n+a}+\frac{n(2p-1)}{(n+a)^2} \\
&= \frac{1}{n+a}.
\end{aligned}$$

∎

14. 设 $X_1,\cdots,X_n$ 为 *i.i.d.* 样本， $X_1\sim b(1,p),\ 0<p<1$, p 的先验分布 $\pi(p)\sim R(0,1)$ 。在损失函数 $L(d,p)=\frac{(d-p)^2}{p(1-p)}$ 下，求 p 的 Bayes 估计，并求其 Bayes 风险。

解. 由例 8.1.1 可知 p 的后验分布为 $\pi(p|X)\sim BE(T+1,n-T+1)$ ，其中 $T=\sum_{i=1}^n X_i\sim b(n,p)$ 。记 $\lambda(p)=[p(1-p)]^{-1}$ ，则 p 的 Bayes 估计为

$$\hat{p}=\frac{\mathrm{E}[p\lambda(p)|X]}{\mathrm{E}[\lambda(p)|X]}=\frac{\mathrm{E}[(1-p)^{-1}|X]}{\mathrm{E}[p^{-1}(1-p)^{-1}|X]}.$$

若记 $\pi(p|X)\sim BE(a,b)$ ， $a=T+1,\ b=n-T+1$ ，则由 β 的定义可得 $\mathrm{E}[(1-p)^{-1}|X]=\beta(a,b)^{-1}\beta(a,b-1)$ ； $\mathrm{E}[p^{-1}(1-p)^{-1}|X]=\beta(a,b)^{-1}\beta(a-1,b-1)$ ，因此有

$$\hat{p}=\frac{\beta(a,b-1)}{\beta(a-1,b-1)}=\frac{\beta(T+1,n-T)}{\beta(T,n-T)}=\frac{T}{n}=\bar{X}.$$

$\hat{p}$ 的风险函数为

$$\begin{aligned}
R(p,\hat{p}) &= \mathrm{E}_p[L(\bar{X},p)] \\
&= \mathrm{E}_p[(T/n-p)^2/(p(1-p))]=\frac{1}{p(1-p)}\cdot\mathrm{E}_p[\frac{T^2}{n^2}-\frac{2p}{n}T+p^2] \\
&= \frac{1}{p(1-p)}\cdot\{\frac{1}{n^2}[np(1-p)+n^2p^2]-\frac{2p}{n}\cdot np+p^2\}=\frac{1}{n}.
\end{aligned}$$

其中第 3 步用到了 $T\sim b(n,p)$ 。所以 $\hat{p}$ 的 Bayes 风险为

$$R_\pi(\hat{p})=R_\pi(\bar{X})=\int_\Theta R(p,\bar{X})\pi(p)dp=\frac{1}{n}.$$

∎

15. 设 $X_1,\cdots,X_n,$ 为 *i.i.d.* 样本， X_1 服从均匀分布 $R(\theta-\frac{1}{2},\theta+\frac{1}{2})$ 。在无信息先验分布和均方损失下，求 θ 的 Bayes 估计。

解. 由于 X_1 服从位置参数分布族，所以 θ 的无信息先验分布为 $\pi(\theta)\propto 1$ 。因此 θ 的后验分布密度函数为

$$\begin{aligned}
\pi(\theta|x) &\propto I\{\theta-\frac{1}{2}\le x_{(1)}\le x_{(n)}\le\theta+\frac{1}{2}\} \\
&\propto I\{x_{(n)}-\frac{1}{2}\le\theta\le x_{(1)}+\frac{1}{2}\} \\
&\sim R(x_{(n)}-\frac{1}{2},\ x_{(1)}+\frac{1}{2}).
\end{aligned}$$

所以 θ 的 Bayes 估计为 $\hat{\theta}=\mathrm{E}[\theta|X]=\frac{1}{2}(X_{(1)}+X_{(n)})$ 。

∎

16. 设 $X_1,\cdots,X_n$ 为 $i.i.d.$ 样本， $X_1\sim\mu+\Gamma(\frac{1}{\sigma},1)$ 。在无信息先验分布下，求相应参数的后验期望估计： i) $\sigma=1$, μ 未知； ii) $\mu=0$, σ 未知； iii) $\theta=(\sigma,\mu)$ 都未知。

解. (1) 当 $\sigma=1,\mu$ 未知时， X_1 服从位置参数分布族，所以 μ 的无信息先验分布为 $\pi(\mu)\propto 1$ 。由此可得 μ 的后验分布为

$$\begin{aligned}\pi(\mu|x) &\propto \exp\{-\sum_{i=1}^n(x_i-\mu)\}I\{x_{(1)}\geq\mu\}\\ &\propto e^{n\mu}I\{\mu\leq x_{(1)}\}.\end{aligned}$$

所以 $\pi(\mu|x)=ne^{n(\mu-x_{(1)})}I\{\mu\leq x_{(1)}\}$ 。所以 μ 的 Bayes 估计为

$$\begin{aligned}\hat{\mu} &= \mathrm{E}[\mu|X]=\int_{-\infty}^{X_{(1)}}\mu\pi(\mu|X)d\mu\\ &= ne^{-nX_{(1)}}\cdot\{\frac{1}{n}e^{n\mu}\cdot\mu-\frac{1}{n^2}e^{n\mu}\}\mid_{-\infty}^{X_{(1)}}\\ &= X_{(1)}-\frac{1}{n}.\end{aligned}$$

(2) 当 $\mu=0,\sigma$ 未知时， X_1 服从尺度参数分布族，所以 σ 的无信息先验分布为 $\pi(\sigma)\propto\sigma^{-1}$ 。由此可得 σ 的后验分布为

$$\begin{aligned}\pi(\sigma|x) &\propto \sigma^{-n}\exp\{-\frac{1}{\sigma}\sum_{i=1}^n x_i\}\cdot\sigma^{-1}\\ &\propto \exp\{-\frac{1}{\sigma}\sum_{i=1}^n x_i\}\cdot(\frac{1}{\sigma})^{n+1}\\ &\sim \Gamma^{-1}(\sum_{i=1}^n x_i,\ n).\end{aligned}$$

所以 σ 的 Bayes 估计为 $\hat{\sigma}=\mathrm{E}[\sigma|X]=\frac{1}{n-1}\sum_{i=1}^n X_i$.

(3) 当 μ,σ 都未知时， X_1 服从位置尺度参数分布族。所以 $\theta=(\sigma,\mu)$ 的无信息先验分布为 $\pi(\mu,\sigma)\propto\sigma^{-2}$ ，因此 $\theta=(\sigma,\mu)$ 的后验分布为

$$\pi(\mu,\sigma|x)\propto\sigma^{-(n+2)}\exp\{-\frac{1}{\sigma}\sum_{i=1}^n(x_i-\mu)\}I\{x_{(1)}\geq\mu\}.$$

由此可得

$$\pi(\mu,\sigma|x)=n\frac{S^n}{\Gamma(n)}\exp\{-\frac{1}{\sigma}\sum_{i=1}^n(x_i-\mu)\}\sigma^{-(n+2)}I\{\mu\leq x_{(1)}\}.$$

其中 $S=\sum_{i=1}^n(X_i-X_{(1)})$ 。所以 σ,μ 的 Bayes 估计分别为

$$\begin{aligned}\hat{\sigma} &= \int_0^\infty\sigma\pi(\sigma|X)d\sigma=\int_0^\infty\sigma\int_{-\infty}^{X_{(1)}}\pi(\mu,\sigma|X)d\mu\cdot d\sigma\\ &= \int_0^\infty\sigma\frac{S^n}{\Gamma(n)}e^{-\frac{S}{\sigma}}\cdot(\frac{1}{\sigma})^{n+1}d\sigma\\ &= \frac{S}{n-1}.\end{aligned}$$

$$
\begin{aligned}
\hat{\mu} &= \int_{-\infty}^{X_{(1)}} \mu\pi(\mu|X)d\mu = \int_{-\infty}^{X_{(1)}} \mu \int_0^{\infty} \pi(\mu,\sigma|X)d\sigma \cdot d\mu \\
&= \int_{-\infty}^{X_{(1)}} \mu n^2 S^n \cdot [\sum_{i=1}^n (X_i-\mu)]^{-(n+1)} d\mu \\
&= n^2 S^n \{\frac{1}{n}\mu \cdot \frac{1}{n}[\sum_{i=1}^n X_i - n\mu]^{-n} - \frac{1}{n^3}\cdot\frac{1}{(n-1)}[\sum_{i=1}^n X_i - n\mu]^{-(n-1)}\}|_{-\infty}^{X_{(1)}} \\
&= S^n\{X_{(1)}S^{-n} - \frac{1}{n(n-1)}S^{-(n-1)}\} \\
&= X_{(1)} - \frac{S}{n(n-1)}.
\end{aligned}
$$

以上结果与经典的 UMRUE 完全一致。 ∎

17. 设 $X_1,\cdots,X_n$ 为 *i.i.d.* 样本，$X_1 \sim \Gamma(\frac{1}{\theta},1)$ 表示寿命分布，$\mathrm{E}(X_1)=\theta$ 为平均寿命。若只观测到前 r 个寿命值：$Y_1=X_{(1)},\cdots,Y_r=X_{(r)}$，取损失函数为 $L(\theta,d)=[(d-\theta)/\theta]^2$，求 θ 的 Bayes 估计。若 θ 的先验分布为：(1) 逆 Γ 分布 $\Gamma^{-1}(a,p)$；(2) $\pi(\theta)\propto\theta^{-1}$ (由 Jeffreys 准则确定的先验分布)。

解. (1) 由原书例 8.2.3 可知，θ 的后验分布为 $\pi(\theta|x)\sim\Gamma^{-1}(T_{n,r}+a,\ p+r)$，其中 $T_{n,r}=\sum_{i=1}^r Y_i+(n-r)Y_r$ 为总寿命。本题 $\lambda(\theta)=\theta^{-2}$，所以 θ 的 Bayes 估计为

$$
\hat{\theta}=\frac{\mathrm{E}[\theta^{-2}\cdot\theta|X]}{\mathrm{E}[\theta^{-2}|X]}=\frac{p+r}{T_{n,r}+a}\left[\frac{(p+r)(p+r+1)}{(T_{n,r}+a)^2}\right]^{-1}=\frac{T_{n,r}+a}{p+r+1}
$$

(2) 由于样本分布为 $f(y,\theta)=c\theta^{-r}e^{-T_{n,r}/\theta}$，所以 θ 的后验分布为

$$
\pi(\theta|x)=c_1\cdot\theta^{-(r+1)}e^{-T_{n,r}/\theta}\sim\Gamma^{-1}(T_{n,r},\ r).
$$

所以根据与 (1) 类似的公式可得 θ 的 Bayes 估计为

$$
\hat{\theta}=\frac{\mathrm{E}[\theta^{-2}\cdot\theta|X]}{\mathrm{E}[\theta^{-2}|X]}=\frac{r}{T_{n,r}}\left[\frac{r(r+1)}{(T_{n,r})^2}\right]^{-1}=\frac{T_{n,r}}{r+1}
$$

∎

18. 设 $X_1,\cdots,X_n$ 为 *i.i.d.* 样本，损失函数为均方损失，证明：以下参数的 Bayes 估计是渐近无偏的和相合的：

(1) $X_1\sim b(k,\theta)$, $\theta\in(0,1)$, θ 的先验分布 $\pi(\theta)\sim BE(p,q)$；

(2) $X_1\sim R(0,\theta)$, θ 的先验分布 $\pi(\theta)\sim PR(\alpha,\theta_0)\sim\alpha\theta_0^{\alpha}\theta^{-(\alpha+1)}I\{\theta\geq\theta_0\}$, 且 $\theta_0\leq X_{(n)}$；

(3) $X_1\sim P(\lambda)$, λ 的先验分布 $\pi(\lambda)\sim\Gamma(a,\ p)$。

证明. (1) θ 的后验分布为

$$
\begin{aligned}
\pi(\theta|x) &\propto \theta^{\sum_{i=1}^n x_i}(1-\theta)^{nk-\sum_{i=1}^n x_i}\cdot\theta^{p-1}(1-\theta)^{q-1} \\
&\propto \theta^{\sum_{i=1}^n x_i+p-1}(1-\theta)^{nk-\sum_{i=1}^n x_i+q-1} \\
&\sim BE(\sum_{i=1}^n x_i+p,\ \ nk-\sum_{i=1}^n x_i+q).
\end{aligned}
$$

所以在均方损失下， θ 的 Bayes 估计为 $\hat{\theta}=\mathrm{E}[\theta|X]=\frac{\sum_{i=1}^n X_i+p}{nk+p+q}$ 。又因为 $\sum_{i=1}^n X_i\sim b(nk,\theta)$ ，所以

$$\mathrm{E}_\theta(\hat{\theta})=\mathrm{E}\left[\frac{\sum_{i=1}^n X_i+p}{nk+p+q}\right]=\frac{nk\theta+p}{nk+p+q}\longrightarrow\theta.\ (n\to\infty)$$

由此可知 θ 的 Bayes 估计是渐近无偏的。由强大数定律可知 $n^{-1}\sum_{i=1}^n X_i\longrightarrow k\theta(a.e.)$ ，所以有

$$\hat{\theta}=\frac{\sum_{i=1}^n X_i+p}{nk+p+q}=\frac{\frac{\sum_{i=1}^n X_i}{nk}+\frac{p}{nk}}{1+\frac{p+q}{nk}}\longrightarrow\theta(a.e.)$$

由此可知 $\hat{\theta}$ 是强相合的。

(2) θ 的后验分布为 $\pi(\theta|x)\sim PR(n+\alpha,\ X_{(n)})$ ，所以在均方损失下， θ 的 Bayes 估计为 $\hat{\theta}=\mathrm{E}[\theta|X]=\frac{(n+\alpha)}{n+\alpha-1}X_{(n)}$ 。又因为 $\frac{X_{(n)}}{\theta}\sim BE(n,1)$ ，所以 $\mathrm{E}_\theta[X_{(n)}]=\frac{n}{n+1}\theta$ ，从而

$$\mathrm{E}_\theta(\hat{\theta})=\frac{(n+\alpha)}{n+\alpha-1}\cdot\frac{n}{n+1}\theta\longrightarrow\theta,(n\to\infty).$$

所以 θ 的 Bayes 估计 $\hat{\theta}$ 是渐近无偏的。

由第五章习题 17 可知， $X_{(n)}$ 是 θ 的强相合估计，即 $X_{(n)}\longrightarrow\theta.\ (a.e.)$ ， 所以也有 $\hat{\theta}=\frac{(n+\alpha)X_{(n)}}{n+\alpha-1}\longrightarrow\theta\ \ (a.e.)$ ，因此 $\hat{\theta}$ 是 θ 的强相合估计。

(3) 由于 $\pi(\lambda|x)\sim\Gamma(n+\alpha,T+p)$ ，其中 $T=\sum_{i=1}^n X_i$ ，所以在均方损失下 λ 的 Bayes 估计为 $\hat{\lambda}=\frac{T+p}{n+a}$ 。由

$$\mathrm{E}_\lambda(\hat{\lambda})=\frac{\mathrm{E}(T)+p}{n+\alpha}=\frac{n\theta+p}{n+\alpha}\longrightarrow\lambda,\quad(n\to\infty).$$

可知 $\hat{\lambda}$ 是 λ 的渐近无偏估计。又由强大数定律知 $T/n\longrightarrow\lambda\ \ (a.e.)$ ，所以

$$\hat{\lambda}=\frac{T+p}{n+\alpha}=\frac{T/n+p/n}{1+\alpha/n}\longrightarrow\lambda\ \ (a.e.).$$

因此 $\hat{\lambda}$ 是 λ 的强相合估计。 ∎

19. 设 $X_1,\cdots,X_n$ 为 *i.i.d.* 样本， $X_1\sim b(1,p),\ 0<p<1$ 。

(1) 当 $p\sim BE(\alpha,\beta)$ 时，在均方损失下，求 $g(p)=p(1-p)$ 的 Bayes 估计，并讨论其渐近无偏性和相合性；

(2) 设 p 服从广义先验分布 $\pi(p)=p^{-1}(1-p)^{-1}I\{0<p<1\}$ ，在均方误差损失下，求 p 和 $g(p)$ 的 Bayes 估计，并讨论其渐近无偏性和相合性。

解. (1) p 的后验分布为 $\pi(p|X)\sim BE(\sum_{i=1}^n X_i+\alpha,\ n-\sum_{i=1}^n X_i+\beta)$ ，所以 $g(p)$ 的 Bayes 估计为

$$\begin{aligned}\hat{g}(p)&=\mathrm{E}[g(p)|X]=\mathrm{E}[p(1-p)|X]\\&=\frac{\beta(\sum_{i=1}^n X_i+\alpha+1,\ n-\sum_{i=1}^n X_i+\beta+1)}{\beta(\sum_{i=1}^n X_i+\alpha,\ n-\sum_{i=1}^n X_i+\beta)}\\&=\frac{(T+\alpha)(n-T+\beta)}{(n+\alpha+\beta)(n+\alpha+\beta+1)}.\end{aligned}$$

其中 $\beta(a,b)$ 表示 β 函数。因为 $T=\sum_{i=1}^n X_i \sim b(n,p)$ ，所以

$$\begin{aligned}
\mathrm{E}[\hat{g}(p)] &= \frac{1}{(n+\alpha+\beta)(n+\alpha+\beta+1)}\mathrm{E}[-T^2+(n+\beta-\alpha)T+(n+\beta)\alpha] \\
&= (n+\alpha+\beta)^{-1}(n+\alpha+\beta+1)^{-1}\cdot \\
&\quad [-(np(1-p)+n^2p^2)+(n+\beta-\alpha)np+(n+\beta)\alpha] \\
&= (n+\alpha+\beta)^{-1}(n+\alpha+\beta+1)^{-1}\cdot \\
&\quad [n^2p(1-p)-np(1-p)+(\beta-\alpha)np+(n+\beta)\alpha] \\
&\longrightarrow p(1-p), \qquad (n\longrightarrow\infty).
\end{aligned}$$

所以 $\hat{g}(p)$ 是 $g(p)$ 的渐近无偏估计。由强大数定律知 $T/n\longrightarrow p\ \ (a.e.)$ ，所以

$$\hat{g}(p)=\frac{(\frac{T}{n}+\frac{\alpha}{n})(1-\frac{T}{n}+\frac{\beta}{n})}{(1+\frac{\alpha+\beta}{n})(1+\frac{\alpha+\beta+1}{n})}\longrightarrow p(1-p).\ \ (a.e.)$$

因此 $\hat{g}(p)$ 是 $g(p)$ 的强相合估计。

(2) p 的后验分布为

$$\pi(p|x)\propto p^{\sum_{i=1}^n x_i-1}(1-p)^{n-\sum_{i=1}^n x_i-1}\sim BE(\sum_{i=1}^n x_i, n-\sum_{i=1}^n x_i)=BE(T,n-T),$$

其中 $T=\sum_{i=1}^n X_i$ 。这一后验分布相当于 (1) 中 $\alpha=\beta=0$ 的情形，所以 p 和 $g(p)$ 的 Bayes 估计分别为

$$\hat{p}=\mathrm{E}[p|X]=\frac{T}{n};\quad \hat{g}(p)=\mathrm{E}[g(p)|X]=\frac{T(n-T)}{n(n+1)}.$$

显然，(1) 中的结论对 $\alpha=\beta=0$ 的情形也成立，因此 $\hat{p}$ 和 $\hat{g}(p)$ 是 p 和 $g(p)$ 的渐近无偏估计，也是强相合估计。 ∎

20. 设 $X_1,\cdots,X_n$ 为 *i.i.d.* 样本， X_1 服从负二项分布 $NB(r,p)$ ， $r>0$ 已知；又设 $p\sim BE(\alpha,\beta)$ 。

(1) 在均方损失下，求 p 和 p^{-1} 的 Bayes 估计；

(2) 证明 (1) 中得到的 Bayes 估计是相合的。

解. (1) p 的后验分布为

$$\pi(p|x)\propto p^{nr}(1-p)^{\sum_{i=1}^n x_i}\cdot p^{\alpha-1}(1-p)^{\beta-1}\sim BE(nr+\alpha,\ T+\beta),$$

其中 $T=\sum_{i=1}^n x_i$ 。所以 p 的 Bayes 估计为

$$\hat{p}=\frac{nr+\alpha}{\sum_{i=1}^n X_i+\alpha+\beta+nr},$$

p^{-1} 的 Bayes 估计为

$$\widehat{p^{-1}}=\frac{\beta(nr+\alpha-1,\ T+\beta)}{\beta(nr+\alpha,\ T+\beta)}=\frac{\sum_{i=1}^n X_i+\alpha+\beta+nr-1}{nr+\alpha-1}.$$

(2) 由强大数定律可知 $\sum_{i=1}^n X_i/n \longrightarrow rp^{-1}(1-p)$ $(a.e.)$，所以有

$$\hat{p} = \frac{nr+\alpha}{T+\alpha+\beta+nr} = \frac{1+\alpha/nr}{T/nr+(\alpha+\beta)/nr+1} \longrightarrow \frac{1}{p^{-1}(1-p)+1} = p \quad (a.e.).$$

因此 $\hat{p}$ 是 p 的强相合估计。又由于

$$\widehat{p^{-1}} = \frac{T+\alpha+\beta+nr-1}{nr+\alpha-1}. = \frac{T/nr+1+(\alpha+\beta-1)/nr}{1+(\alpha-1)/nr} \longrightarrow p^{-1}(1-p)+1 = p^{-1} \ (a.e.).$$

因此 $\widehat{p^{-1}}$ 是 p^{-1} 的强相合估计。 ∎

21. 设 $X \sim N(\mu, \sigma^2)$，$\mu > 0$ 未知，σ^2 已知，μ 的先验分布为 $\pi(\mu) = I\{\mu > 0\}$，证明：在均方损失下，μ 的 Bayes 估计为：$\widehat{\mu}_B = X + \sigma\varphi(\frac{X}{\sigma})/[1-\Phi(-\frac{X}{\sigma})]$, 其中 φ 和 Φ 分别是标准正态的密度函数和分布函数。

证明. μ 的后验分布密度函数可表示为

$$\begin{aligned}
\pi(\mu|x) &= \frac{1\cdot\frac{1}{\sqrt{2\pi}\sigma}\exp\{-\frac{(x-\mu)^2}{2\sigma^2}\}}{\int_0^\infty 1\cdot\frac{1}{\sqrt{2\pi}\sigma}\exp\{-\frac{(x-\mu)^2}{2\sigma^2}\}d\mu} I\{\mu>0\} \\
&= \frac{\frac{1}{\sqrt{2\pi}\sigma}\exp\{-\frac{(x-\mu)^2}{2\sigma^2}\}}{\int_0^\infty \frac{1}{\sqrt{2\pi}\sigma}\exp\{-\frac{(x-\mu)^2}{2\sigma^2}\}d\mu} I\{\mu>0\}
\end{aligned}$$

所以 μ 的 Bayes 估计为

$$\hat{\mu}_B(x) = \frac{\int_0^\infty \mu\frac{1}{\sqrt{2\pi}\sigma}\exp\{-\frac{(\mu-x)^2}{2\sigma^2}\}d\mu}{\int_0^\infty \frac{1}{\sqrt{2\pi}\sigma}\exp\{-\frac{(\mu-x)^2}{2\sigma^2}\}d\mu}$$

为了转化为标准正态分布的积分，可做变换 $t = (\mu - x)/\sigma$，则有

$$\hat{\mu}_B(x) = \frac{\int_{-x/\sigma}^\infty (\sigma t + x)\frac{1}{\sqrt{2\pi}}e^{-\frac{t^2}{2}}dt}{\int_{-x/\sigma}^\infty \frac{1}{\sqrt{2\pi}}e^{-\frac{t^2}{2}}dt} = x + \frac{\sigma\int_{-x/\sigma}^\infty t\frac{1}{\sqrt{2\pi}}e^{-\frac{t^2}{2}}dt}{\int_{-x/\sigma}^\infty \frac{1}{\sqrt{2\pi}}e^{-\frac{t^2}{2}}dt}$$

上式直接积分可得

$$\hat{\mu}_B(X) = X + \sigma\frac{\varphi(\frac{X}{\sigma})}{[1-\Phi(-\frac{X}{\sigma})]}.$$ ∎

22. 设 X_1 服从几何分布分布 $G(p)$，$0 < p \le 1$, $p \sim \pi(p)$。当损失函数为 $L(p,d) = (d-p)^2/p$ 时证明：p 的 Bayes 估计为

$$\widehat{p} = 1 - \frac{\int_0^1 (1-p)^x \pi(p)dp}{\int_0^1 (1-p)^{x-1}\pi(p)dp}, \qquad x = 1, 2, \ldots.$$

证明. p 的后验分布密度函数可表示为

$$\pi(p|x) = \frac{p(1-p)^{x-1}\pi(p)}{\int_0^1 p(1-p)^{x-1}\pi(p)dp}.$$

所以 p 的 Bayes 估计为

$$\begin{aligned}
\hat{p} &= \mathrm{E}[p^{-1}\cdot p|X]/\mathrm{E}[p^{-1}|X] = [\mathrm{E}[p^{-1}|X]]^{-1} \\
&= \left[\frac{\int_0^1 p^{-1}\cdot p(1-p)^{x-1}\pi(p)dp}{\int_0^1 p(1-p)^{x-1}\pi(p)dp}\right]^{-1} = \frac{\int_0^1 p(1-p)^{x-1}\pi(p)dp}{\int_0^1 (1-p)^{x-1}\pi(p)dp} \\
&= \frac{\int_0^1 [1-(1-p)](1-p)^{x-1}\pi(p)dp}{\int_0^1 (1-p)^{x-1}\pi(p)dp} \\
&= 1-\frac{\int_0^1 (1-p)^{x}\pi(p)dp}{\int_0^1 (1-p)^{x-1}\pi(p)dp}. \qquad \blacksquare
\end{aligned}$$

23.* 设 $X_1,\cdots,X_n$ 为 $i.i.d.$ 样本，$X_1\sim R(0,\theta)$，θ 的先验分布为逆 Γ 分布 $\theta\sim\Gamma^{-1}(a,p)$，证明：在均方损失下，$\theta$ 的 Bayes 估计为：

$$\widehat{\theta}_B = \frac{a}{n'}\frac{P\{\chi^2(2n')<2a/X_{(n)}\}}{P\{\chi^2(2n'+2)<2a/X_{(n)}\}}.$$

其中 $n'=n+p-1$，$X_{(n)}$ 为样本最大值。(提示：利用 Γ 分布与 χ^2 分布的关系)。

解. θ 的后验分布密度函数为

$$\begin{aligned}
\pi(\theta|x) &= c(x)\theta^{-n}I\{0\le x_{(1)}\le x_{(n)}\le\theta\}\cdot\frac{a^p}{\Gamma(p)}e^{-\frac{a}{\theta}}(\frac{1}{\theta})^{p+1}I\{\theta\ge 0\} \\
&= c(x)e^{-\frac{a}{\theta}}(\frac{1}{\theta})^{n+p+1}I\{\theta\ge x_{(n)}\}.
\end{aligned}$$

由 $\int_{x_{(n)}}^\infty \pi(\theta|x)d\theta=1$ 可得 $c(x)=(\int_{x_{(n)}}^\infty e^{-\frac{a}{\theta}}(\frac{1}{\theta})^{n+p+1}d\theta)^{-1}$。所以 θ 的 Bayes 估计为

$$\begin{aligned}
\widehat{\theta}_B &= \frac{\int_{x_{(n)}}^\infty e^{-a/\theta}(\frac{1}{\theta})^{n+p}d\theta}{\int_{x_{(n)}}^\infty e^{-a/\theta}(\frac{1}{\theta})^{n+p+1}d\theta} \\
&= \frac{\int_0^{1/x_{(n)}} e^{-at}t^{n'-1}dt}{\int_0^{1/x_{(n)}} e^{-at}t^{n'}dt} \\
&= \frac{\int_0^{1/x_{(n)}} \frac{a^{n'}}{\Gamma(n')}e^{-at}t^{n'-1}dt}{\int_0^{1/x_{(n)}} \frac{a^{n'+1}}{\Gamma(n'+1)}e^{-at}t^{(n'+1)-1}dt}\cdot\frac{a}{n'}.
\end{aligned}$$

其中第三个等号用到了变换 $t=1/\theta$。因为 $\frac{a^{n'}}{\Gamma(n')}e^{-at}t^{n'-1}$ 和 $\frac{a^{n'+1}}{\Gamma(n'+1)}e^{-at}t^{(n'+1)-1}$ 分别是分布 $\Gamma(a,n')$ 和 $\Gamma(a,n'+1)$ 的密度函数，所以由 Γ 分布和 χ^2 分布的关系可知，若 $Z\sim\Gamma(a,n')$，则有 $P\{Z<k\}=P\{2aZ<2ak\}=P\{\chi^2(2n')<2ak\}$。因此，以上 Bayes 估计可表示为

$$\widehat{\theta}_B = \frac{a}{n'}\frac{P\{\chi^2(2n')<2a/X_{(n)}\}}{P\{\chi^2(2n'+2)<2a/X_{(n)}\}}. \qquad \blacksquare$$

24. (1) 设 $\delta_i(X)$ 是 $g_i(\theta)$ 在均方损失下的 Bayes 估计，$i=1,\cdots,p$。证明：$\sum\limits_{i=1}^p c_i\delta_i(X)$ 是 $\sum\limits_{i=1}^p c_i g_i(\theta)$ 在均方损失下的 Bayes 估计；

(2) 设 $X_1,\cdots,X_n$ 为 *i.i.d.* 样本， $X_1\sim PR(\alpha,\theta_0)\sim \alpha\theta_0^{\alpha}\theta^{-(\alpha+1)}I\{\theta\geq\theta_0\}$, 其中 θ_0 已知， $\alpha\sim\Gamma(a,p)$ ，在均方损失下求 $g(\alpha)=\alpha+\alpha^2$ 的 Bayes 估计。

证明. (1) 因为 $\delta_i(X)$ 是 $g_i(\theta)$ 在均方损失下的 Bayes 估计，所以 $\mathrm{E}[g_i(\theta)|X]=\delta_i(X),\ \ i=1,2,\cdots,p$ 。由数学期望的线性性质，我们有

$$\mathrm{E}[\sum_{i=1}^{p}c_ig_i(\theta)|X]=\sum_{i=1}^{p}c_i\mathrm{E}[g_i(\theta)|X]=\sum_{i=1}^{p}c_i\delta_i(X).$$

所以 $\sum_{i=1}^{p}c_i\delta_i(X)$ 是 $\sum_{i=1}^{p}c_ig_i(\theta)$ 在均方损失下的 Bayes 估计.

(2) α 的后验分布为 $\pi(\alpha|x)\sim\Gamma(a+\sum_{i=1}^{n}\log\frac{X_i}{\theta_0},\ n+p)$ ，所以 α 和 α^2 的 Bayes 估计分别为

$$\begin{aligned}
\hat{\alpha} &= \mathrm{E}(\alpha|X)=(n+p)(a+\sum_{i=1}^{n}\log\frac{X_i}{\theta_0})^{-1},\\
\widehat{\alpha^2} &= \mathrm{E}[\alpha^2|X]=\mathrm{Var}(\alpha|X)+[\mathrm{E}(\alpha|X)]^2\\
&= (a+\sum_{i=1}^{n}\log\frac{X_i}{\theta_0})^{-2}(n+p)+(a+\sum_{i=1}^{n}\log\frac{X_i}{\theta_0})^{-2}(n+p)^2\\
&= (a+\sum_{i=1}^{n}\log\frac{X_i}{\theta_0})^{-2}(n+p)(n+p+1).
\end{aligned}$$

所以由 (1) 可得在均方损失下 $g(\alpha)$ 的 Bayes 估计为

$$\begin{aligned}
\widehat{g(\alpha)} &= \widehat{\alpha}+\widehat{\alpha^2}=\mathrm{E}(\alpha|X)+\mathrm{E}[\alpha^2|X]\\
&= (a+\sum_{i=1}^{n}\log\frac{X_i}{\theta_0})^{-1}(n+p)+(a+\sum_{i=1}^{n}\log\frac{X_i}{\theta_0})^{-2}(n+p)(n+p+1)\\
&= (n+p)(a+\sum_{i=1}^{n}\log\frac{X_i}{\theta_0})^{-1}\{1+(n+p+1)(a+\sum_{i=1}^{n}\log\frac{X_i}{\theta_0})^{-1}\}.
\end{aligned}$$

∎

25.* (1) 设 $\pi(\theta)$ 为正常的先验分布， $\delta(x)$ 是 $g(\theta)$ 在均方误差损失下的 Bayes 估计；估计的偏差是 $b(\theta)$ ，即 $E(\delta(X)|\theta)=g(\theta)+b(\theta)$ 。假设 $Eg^2(\theta)<\infty$ ，则 $\delta(X)$ 的 Bayes 风险 $R_\pi(\delta)$ 可表示为

$$R_\pi(\delta)=\mathrm{E}[\delta(X)-g(\theta)]^2=-\int_{\Theta}g(\theta)b(\theta)\pi(\theta)d\theta.$$

其中 $\mathrm{E}[\cdot]$ 表示对 (X,θ) 的联合分布求期望 (提示：参考定理 8.2.3 的证明) 。

(2) 设 $X_1,\cdots,X_n$ 为 *i.i.d.* 样本， X_1 服从 Poisson 分布 $P(\lambda)$ ，设 λ 的先验分布为 $\pi(\lambda)\sim\Gamma(a,p)$, 通过直接计算验证以上公式。

证明. (1) 因为 $(X,\theta)\sim p(x;\theta)=\pi(\theta)f(x;\theta)=p(x)\pi(\theta|x)$ ，其中 $f(x;\theta)$ 为样本分布，所以有

$$\begin{aligned}
R_\pi(\delta) &= \mathrm{E}[\delta(X)-g(\theta)]^2\\
&= \int_{\Theta}\int_{\mathcal{X}}[\delta(x)-g(\theta)]^2f(x;\theta)\pi(\theta)dxd\theta\\
&= \int_{\Theta}\int_{\mathcal{X}}[\delta(x)-g(\theta)]^2p(x)\pi(\theta|x)dxd\theta
\end{aligned}$$

又因为 $\mathrm{E}[g^2(\theta)]=\int_\Theta g^2(\theta)\pi(\theta)d\theta<\infty$ ，由假设可知，以下关系式成立：

$$\mathrm{E}[g(\theta)|x]=\int_\Theta g(\theta)\pi(\theta|x)d\theta=\delta(x),\quad \mathrm{E}[\delta(X)|\theta]=\int_{\mathcal{X}}\delta(x)f(x;\theta)dx=g(\theta)+b(\theta).$$

所以有

$$\begin{aligned}
R_\pi(\delta) &= \int_\Theta\int_{\mathcal{X}}[\delta^2(x)-\delta(x)g(\theta)]\pi(\theta|x)p(x)dxd\theta+\int_\Theta\int_{\mathcal{X}}[-\delta(x)g(\theta)+g^2(\theta)]f(x;\theta)\pi(\theta)d\theta dx\\
&= \int_{\mathcal{X}}\delta^2(x)p(x)dx-\int_{\mathcal{X}}\delta(x)\left[\int_\Theta g(\theta)\pi(\theta|x)d\theta\right]\cdot p(x)dx\\
&\quad+\int_\Theta g^2(\theta)\left[\int_{\mathcal{X}}f(x;\theta)dx\right]\pi(\theta)d\theta-\int_\Theta g(\theta)\left[\int_{\mathcal{X}}\delta(x)f(x;\theta)dx\right]\pi(\theta)d\theta\\
&= \int_{\mathcal{X}}\delta^2(x)p(x)dx-\int_{\mathcal{X}}\delta^2(x)p(x)dx+\int_\Theta g^2(\theta)\pi(\theta)d\theta-\int_\Theta g(\theta)[g(\theta)+b(\theta)]\pi(\theta)d\theta\\
&= -\int_\Theta g(\theta)b(\theta)\pi(\theta)d\theta.
\end{aligned}$$

(2) 由于 $\pi(\lambda|x)\sim\Gamma(a+n,\ p+T)$, 其中 $T=\sum_{i=1}^n X_i\sim P(n\lambda)$, 所以 λ 的 Bayes 估计为 $\hat\lambda=\mathrm{E}[\lambda|X]=\frac{T+p}{n+a}$ 。由于 $\mathrm{E}_\lambda[\hat\lambda]=\frac{n\lambda+p}{n+a}=\lambda+\frac{p-a\lambda}{n+a}$ ，因此 $b(\lambda)=\frac{p-a\lambda}{n+a}$ ，所以

$$-\int\lambda b(\lambda)\pi(\lambda)d\lambda=-\int_0^\infty\frac{p\lambda-a\lambda^2}{n+a}\pi(\lambda)d\lambda=-(\frac{p}{a+n}\cdot\frac{p}{a}-\frac{a}{a+n}\cdot\frac{p^2+p}{a^2})=\frac{p}{a(n+a)}.$$

又因为 $\hat\lambda$ 的风险函数为

$$\begin{aligned}
\mathrm{E}_\lambda[\hat\lambda-\lambda]^2 &= \mathrm{E}_\lambda[\hat\lambda-2\lambda\hat\lambda+\lambda^2]\\
&= \mathrm{E}_\lambda[\frac{T^2+2pT+p^2}{(n+a)^2}-2\lambda\frac{T+p}{n+a}+\lambda^2]\\
&= \frac{a^2}{(n+a)^2}\lambda^2+\frac{n-2ap}{(n+a)^2}\lambda+\frac{p^2}{(n+a)^2}.
\end{aligned}$$

其中 $\mathrm{E}_\lambda[\cdot]$ 表示对 X 的分布求期望。所以 Bayes 风险为

$$\begin{aligned}
R_\pi(\delta) &= \int_0^\infty\mathrm{E}_\lambda[\hat\lambda-\lambda]^2\pi(\lambda)d\lambda\\
&= \frac{a^2}{(n+a)^2}\cdot\frac{p^2+p}{a^2}+\frac{n-2ap}{(n+a)^2}\cdot\frac{p}{a}+\frac{p^2}{(n+a)^2}\\
&= \frac{p}{(n+a)a}=-\int\lambda b(\lambda)\pi(\lambda)d\lambda.
\end{aligned}$$

所以 (1) 中的等式成立。 ∎

注. 本题 (1) 亦可参照定理 8.2.3 的证明，直接求出相应的期望和条件期望，从而得到 $\delta(X)$ 的 Bayes 风险。证明如下：

由假设可知，以下关系式成立：

$$\mathrm{E}[g(\theta)|x]=\int_\Theta g(\theta)\pi(\theta|x)d\theta=\delta(x);\quad \mathrm{E}[\delta(X)|\theta]=\int_{\mathcal{X}}\delta(x)f(x;\theta)dx=g(\theta)+b(\theta).$$

由于 θ 具有非广义的先验分布 $\pi(\theta)$ ，因此对于 (X,θ) 的联合分布可应用条件期望的性质，所以有

$$\mathrm{E}\{\delta(X)g(\theta)\}=\mathrm{E}\{\mathrm{E}[g(\theta)\delta(X)|\theta]\}=\mathrm{E}\{g(\theta)\mathrm{E}[\delta(X)|\theta]\}=\mathrm{E}\{g^2(\theta)+g(\theta)b(\theta)\}.$$

同理，由条件期望的性质可得

$$\mathrm{E}\{\delta(X)g(\theta)\} = \mathrm{E}\{\mathrm{E}[g(\theta)\delta(X)|X]\} = \mathrm{E}\{\delta(X)\mathrm{E}[g(\theta)|X]\} = \mathrm{E}\{\delta^2(X)\}.$$

以上结果代入 Bayes 风险 $R_\pi(\delta)$ 可得

$$\begin{aligned} R_\pi(\delta) &= \mathrm{E}\{\delta(X)-g(\theta)\}^2 = \mathrm{E}\{\delta^2(X)\} + \mathrm{E}\{g^2(\theta)\} - 2\mathrm{E}\{\delta(X)g(\theta)\} \\ &= \mathrm{E}\{\delta^2(X)\} + \mathrm{E}\{g^2(\theta)\} - \mathrm{E}\{g^2(\theta)+g(\theta)b(\theta)\} - \mathrm{E}\{\delta^2(X)\} \\ &= -\mathrm{E}\{g(\theta)b(\theta)\} \end{aligned}$$

上式的积分形式即 (1) 要求的公式。 ∎

26. 设 $X_1,\cdots,X_n$ 为 *i.i.d.* 样本， $X_1 \sim P(\lambda),\ \lambda \sim \Gamma(a,p)$ 。设 $Y_1,\cdots,Y_m$ 为 *i.i.d.* 样本且与 $X_1,\cdots,X_n$ 独立， $Y_1 \sim P(\mu),\ \mu \sim \Gamma(b,q)$ ，且与 λ 独立。在均方损失下，求 $\rho=\lambda/\mu$ 的 Bayes 估计。

解. (λ,μ) 的联合后验分布为

$$\begin{aligned} \pi(\lambda,\mu|x,y) &\propto e^{-n\lambda}\cdot\frac{\lambda^{\sum_{i=1}^n x_i}}{\prod_{i=1}^n x_i!}\cdot\frac{a^p}{\Gamma(p)}e^{-a\lambda}\cdot\lambda^{p-1}\cdot e^{-m\mu}\cdot\frac{\mu^{\sum_{j=1}^m y_j}}{\prod_{j=1}^m y_j!}\cdot\frac{b^q}{\Gamma(q)}e^{-b\mu}\cdot\mu^{q-1} \\ &\propto e^{-(n+a)\lambda}\cdot\lambda^{\sum_{i=1}^n x_i+p-1}\cdot e^{-(m+b)\mu}\cdot\mu^{\sum_{j=1}^m y_j+q-1}. \end{aligned}$$

所以 λ 与 μ 的后验分布相互独立，且服从 Γ 分布，即

$$(\lambda|x,y) \sim \Gamma(n+a,\ \sum_{i=1}^n x_i+p);\quad (\mu|x,y) \sim \Gamma(m+b,\ \sum_{j=1}^m y_j+q).$$

因此 $\rho=\lambda/\mu$ 的 Bayes 估计为

$$\begin{aligned} \hat\rho &= \mathrm{E}[\rho|X,Y] = \mathrm{E}[\lambda|X,Y]\cdot\mathrm{E}[\mu^{-1}|X,Y] \\ &= \frac{\sum_{i=1}^n X_i+p}{n+a}\cdot\frac{m+b}{\sum_{j=1}^m Y_j+q-1} \\ &= \frac{(m+b)(\sum_{i=1}^n X_i+p)}{(n+a)(\sum_{j=1}^m Y_j+q-1)}. \end{aligned}$$ ∎

27. 设 $X_1 \sim f(x_1,\theta_1),\ X_2 \sim f(x_2,\theta_2)$, 且 X_1 与 X_2 独立； $\theta_1 \sim \pi(\theta_1),\ \theta_2 \sim \pi(\theta_2)$, 且 θ_1 与 θ_2 独立；又设 δ_i 是 θ_i 在均方损失下基于 X_i 的 Bayes 估计， $i=1,\ 2$ 。证明：

(1) $\delta_1-\delta_2$ 是 $\theta_1-\theta_2$ 在均方损失下基于 (X_1,X_2) 的 Bayes 估计；

(2) $\delta_1\delta_2$ 是 $\theta_1\theta_2$ 在均方损失下基于 (X_1,X_2) 的 Bayes 估计。

证明. (1) θ_1 和 θ_2 的后验密度分别为

$$\pi(\theta_1|x_1) = c_1(x_1)f(x_1,\theta_1)\pi(\theta_1),\quad \pi(\theta_2|x_2) = c_2(x_2)f(x_2,\theta_2)\pi(\theta_2).$$

由假设可知， (X_1,X_2) 的联合密度为 $f(x_1,\theta_1)\cdot f(x_2,\theta_2)$ ； (θ_1,θ_2) 的联合先验密度为 $\pi(\theta_1)\cdot\pi(\theta_2)$ ，因此 (θ_1,θ_2) 的联合后验密度为

$$\pi(\theta_1,\theta_2|X_1,X_2) = c(x_1,x_2)f(x_1,\theta_1)f(x_2,\theta_2)\pi(\theta_1)\pi(\theta_2) = \pi(\theta_1|X_1)\cdot\pi(\theta_2|X_2).$$

所以 θ_1 和 θ_2 的后验分布相互独立。由于 $\delta_i = \mathrm{E}(\theta_i|X_i),\ \ i=1,2$ ，因此有

$$\begin{aligned}\mathrm{E}(\theta_1|X_1,X_2) &= \int_{\Theta_1}\int_{\Theta_2}\theta_1\pi(\theta_1,\theta_2|X_1,X_2)d\theta_1 d\theta_2\\ &= \int_{\Theta_1}\theta_1\pi(\theta_1|X_1)d\theta_1\int_{\Theta_2}\pi(\theta_2|X_2)d\theta_2\\ &= \mathrm{E}(\theta_1|X_1)=\delta_1.\end{aligned}$$

所以 δ_1 是 θ_1 基于 (X_1,X_2) 的在均方损失下的 Bayes 估计。同理可得 δ_2 是 θ_2 在均方损失下基于 (X_1,X_2) 的 Bayes 估计，所以 $\mathrm{E}(\theta_1-\theta_2|X_1,X_2)=\mathrm{E}(\theta_1|X_1,X_2)-\mathrm{E}(\theta_2|X_1,X_2)=\delta_1-\delta_2$ 。所以 $\delta_1-\delta_2$ 是 $\theta_1-\theta_2$ 在均方损失下基于 (X_1,X_2) 的 Bayes 估计。

(2) 根据独立性可得

$$\begin{aligned}\mathrm{E}(\theta_1\theta_2|X_1,X_2) &= \int_{\Theta_1}\int_{\Theta_2}\theta_1\theta_2\pi(\theta_1,\theta_2|X_1,X_2)d\theta_1 d\theta_2\\ &= \int_{\Theta_1}\theta_1\pi(\theta_1|X_1)d\theta_1\cdot\int_{\Theta_2}\theta_2\pi(\theta_2|X_2)d\theta_2\\ &= \delta_1\delta_2.\end{aligned}$$

所以 $\delta_1\delta_2$ 是 $\theta_1\theta_2$ 在均方损失下基于 (X_1,X_2) 的 Bayes 估计。 ∎

28. 设 $X\sim f(x;\theta),\ \theta=(\theta_1,\theta_2),\ \theta_i\in\Theta_i,\ i=1,2$ ； $\theta\sim\pi(\theta)=\pi(\theta_1|\theta_2)\pi(\theta_2)$, 其中 $\pi(\theta_2)$ 是 Θ_2 上的密度函数，对任意给定的 $\theta_2,\pi(\theta_1|\theta_2)$ 是 Θ_1 上的密度函数，若在 θ_2 给定的条件下， $h(\theta_1)=g(\theta_1,\theta_2)$ 在均方损失下的 Bayes 估计是 $\delta(X,\theta_2)$, 则 $g(\theta_1,\theta_2)$ 在均方损失下的 Bayes 估计是 $\delta(X)$, 且满足 $\delta(X)=\int\limits_{\Theta_2}\delta(X,\theta_2)\pi(\theta_2|X)d\theta_2$, 其中 $\pi(\theta_2|X)$ 是 θ_2 的后验分布密度函数。把以上结果用于本章习题 4 ，求 μ,σ^2 及 $g(\mu,\delta)=\mu\sigma^2$ 在均方误差下的 Bayes 估计。

证明. 由条件分布密度函数的公式可得

$$\pi(\theta_1,\theta_2|x)=\pi(\theta_1|x,\theta_2)\cdot\pi(\theta_2|x),$$

其中 $\pi(\theta_2|x)$ 是 θ_2 的后验分布密度函数， $\pi(\theta_1|x,\theta_2)$ 是在给定 θ_2 的条件下 θ_1 的后验分布密度函数。因为在 θ_2 给定条件下， $h(\theta_1)$ 在均方损失下的 Bayes 估计是 $\delta(X,\theta_2)$ ，所以 $\delta(X,\theta_2)=\int_{\Theta_1}h(\theta_1)\pi(\theta_1|X,\theta_2)d\theta_1$ 。所以 $g(\theta_1,\theta_2)$ 在均方损失下的 Bayes 估计是

$$\begin{aligned}\delta(X) &= \int_{\Theta_2}\int_{\Theta_1}g(\theta_1,\theta_2)\pi(\theta_1,\theta_2|X)d\theta_1 d\theta_2\\ &= \int_{\Theta_2}\left\{\int_{\Theta_1}g(\theta_1,\theta_2)\pi(\theta_1|X,\theta_2)d\theta_1\right\}\pi(\theta_2|X)d\theta_2\\ &= \int_{\Theta_2}\delta(X,\theta_2)\pi(\theta_2|X)d\theta_2.\end{aligned}$$

对于本章习题 4 ，样本分布为 $N(\mu,\sigma^2)$ ，且有 $\theta_1=\mu$ ， $\theta_2=\delta=1/(2\sigma^2)$ 。这时 $\theta_2=\delta\sim\pi(\theta_2)\sim\Gamma(a,p)$ ； $\pi(\theta_1|\theta_2)=\pi(\mu|\delta)\sim N(\mu_0,\sigma_0^2/\delta)$ ，而 $\theta_2=\delta$ 的后验分布 (参见本章习题 4) 为 $\pi(\theta_2|X)\sim\Gamma(a+S^2+m(x),\ \frac{n}{2}+p),\ \sigma^2=\frac{1}{2\delta}$ ，其中 $\xi=(n+\frac{1}{2\sigma_0^2})^{-1}(n\bar{x}+\frac{1}{2\sigma_0^2}\mu_0),\ \ S^2=\sum_{i=1}^n(x_i-\bar{x})^2,\ \ m(x)=(2\sigma_0^2+1/n)^{-1}(\mu_0-\bar{x})^2$ 。以下对 $g(\theta_1,\theta_2)=\mu;\ \sigma^2$ 及 $\mu\sigma^2$ 的情形分别求其在均方损失下的 Bayes 估计。

(1) $g(\theta_1,\theta_2)=\mu=\theta_1$ 。这时样本分布为 $N(\mu,\sigma^2)$ ，先验分布为 $N(\mu_0,\sigma_0^2/\delta)$ ($\theta_2=\delta=1/(2\sigma^2)$ 为已知)，因而后验分布亦为正态分布 (见原书 p.347 (8.1.4) 式)，所以 $\mu=\theta_1$ 在 θ_2 给定的条件下的 Bayes 估计为后验均值，即

$$\begin{aligned}\delta(X,\theta_2) &= (\frac{n}{\sigma^2}+\frac{\delta}{\sigma_0^2})^{-1}(\frac{n}{\sigma^2}\bar{x}+\frac{\delta}{\sigma_0^2}\mu_0)\\ &= (n+\frac{1}{2\sigma_0^2})^{-1}(n\bar{x}+\frac{1}{2\sigma_0^2}\mu_0)=\xi.\end{aligned}$$

该式与 $\theta_2=\delta$ 无关，因此 $\mu=\theta_1$ 的 Bayes 估计为 $\hat{\mu}=\delta(X)=\int\limits_{\Theta_2}\xi\pi(\theta_2|X)d\theta_2=\xi$ ，这与习题 12 的结果一致。

(2) $g(\theta_1,\theta_2)=\sigma^2=(2\theta_2)^{-1}$ 。这时 $g(\theta_1,\theta_2)=(2\theta_2)^{-1}$ 与 θ_1 无关，因此在 θ_2 给定的条件下，其 Bayes 估计为 $\delta(X,\theta_2)=\int_{\Theta_1}(2\theta_2)^{-1}\pi(\theta_1|X,\theta_2)d\theta_1=(2\theta_2)^{-1}$ 。由于 $\theta_2|X$ 服从上述 Γ 分布，因此 $\sigma^2=(2\theta_2)^{-1}$ 的 Bayes 估计为

$$\hat{\sigma}^2=\frac{1}{2}\int_0^\infty\theta_2^{-1}\pi(\theta_2|X)d\theta_2=\frac{a+S^2+m(X)}{n+2p-2}.$$

(3) $g(\theta_1,\theta_2)=\mu\sigma^2=\theta_1(2\theta_2)^{-1}$ 。由于 $(2\theta_2)^{-1}$ 与 θ_1 无关，因此根据 (1)，在 θ_2 给定的条件下， $g(\theta_1,\theta_2)$ 的 Bayes 估计为 $\delta(X,\theta_2)=\xi(2\theta_2)^{-1}$ 。由于 ξ 与 θ_2 无关，因此由 (2) 可知， $g(\theta_1,\theta_2)$ 的 Bayes 估计为

$$\delta(X)=\int_0^\infty\xi(2\theta_2)^{-1}\pi(\theta_2|X)d\theta_2=\xi\frac{a+S^2+m(X)}{n+2p-2}.$$ ∎

29. 在均方损失函数 $L(\theta,d)=(d-g(\theta))^2$ 下证明： $g(\theta)$ 的 Bayes 解的后验风险为 $\mathrm{Var}(g(\theta)|X)$ ，其中 $\mathrm{Var}(\cdot|X)$ 表示关于后验分布 $\pi(\theta|X)$ 的方差。

证明. 在均方损失下， $g(\theta)$ 的 Bayes 解为 $\hat{g}(X)=\mathrm{E}[g(\theta)|X]$ ，其后验风险为

$$\begin{aligned}R_\pi(\hat{g}(X)|X) &= \int_\Theta(\hat{g}(X)-g(\theta))^2\pi(\theta|X)d\theta\\ &= \int_\Theta(g(\theta)-\mathrm{E}[g(\theta)|X])^2\pi(\theta|X)d\theta\\ &= \mathrm{Var}(g(\theta)|X).\end{aligned}$$

以上最后一式即为随机变量方差的定义。 ∎

30. 设 $X_1,\cdots,X_n$ 为 $i.i.d.$ 样本，求相应参数的后验极大似然估计：

(1) $X_1\sim f(x_1,\theta)=2x_1\theta^{-2}I\{0\le x_1\le\theta\}$ ， θ 服从 Pareto 分布 $PR(\alpha,\mu)$ ；

(2) $X_1\sim f(x_1,\lambda)=\lambda^2x_1e^{-\lambda x_1}I\{x_1\ge 0\}$ ， λ 服从 Γ 分布 $\Gamma(a,\ p)$ ；

(3) $X_1\sim\Gamma(1/\sigma;\nu)$, ν 已知， σ 服从逆 Γ 分布 $\Gamma^{-1}(a,\ p)$ ；

(4) $X_1\sim f(x_1;c)=cx_1^{c-1}I\{0\le x_1\le 1\}$ $(c>0)$. c 的先验分布为 Γ 分布 $\Gamma(a,p)$ 。

解. (1) 由本章习题 10 (1) 的结论知，

$$\pi(\theta|x)=(2n+\alpha)\theta_0^{2n+\alpha}\theta^{-(2n+\alpha+1)}I\{\theta\ge\theta_0\}\sim PR(2n+\alpha,\theta_0),$$

其中 $\theta_0=\max\{X_{(n)},\ \mu\}$ 。要使 $\pi(\theta|x)$ 最大，则须 θ 最小，而 θ 最小不小于 θ_0 ，所以 θ 的后验极大似然估计为 $\hat{\theta}=\theta_0$ 。

(2) 由本章习题 10 (2) 的结论知,

$$\pi(\lambda|x) \sim \Gamma(a+T,\ 2n+p) \sim \frac{(a+T)^{2n+p}}{\Gamma(2n+p)} \exp\{-(a+T)\lambda\}\lambda^{2n+p-1}.$$

其中 $T=\sum_{i=1}^n x_i$ ，其后验对数似然函数为

$$L(\lambda|x) = -(a+T)\lambda + (2n+p-1)\log\lambda + \text{常数项}.$$

所以由 $\partial L(\lambda|x)/\partial\lambda = -(a+T)+(2n+p-1)/\lambda = 0$ 可得， λ 的后验极大似然估计为 $\hat{\lambda} = (2n+p-1)/(a+\sum_{i=1}^n X_i)$ 。

(3) 由本章习题 10 (3) 的结论知,

$$\pi(\sigma|x) \sim \Gamma^{-1}(a+T,\ n\nu+p) \sim \frac{(a+T)^{n\nu+p}}{\Gamma(n\nu+p)} \exp\{-\frac{1}{\sigma}(a+T)\}\cdot(\frac{1}{\sigma})^{n\nu+p+1}.$$

其中 $T=\sum_{i=1}^n x_i$ ，其后验对数似然函数为

$$L(\sigma|x) = -\frac{1}{\sigma}(a+T) - (n\nu+p+1)\log\sigma + \text{常数项}.$$

所以由 $\partial L(\sigma|x)/\partial\lambda = (a+T)/\sigma^2 - (n\nu+p+1)/\sigma = 0$ 可得， σ 的后验极大似然估计为 $\hat{\sigma} = (a+\sum_{i=1}^n X_i)/(n\nu+p+1)$ 。

(4) 由本章习题 10 (4) 的结论知,

$$\pi(c|x) \sim \Gamma(a-T,\ n+p) \sim \frac{(a-T)^{n+p}}{\Gamma(n+p)} \exp\{-(a-T)c\}c^{n+p-1}.$$

其中 $T=\sum_{i=1}^n \log x_i$ ，由此易得 c 的后验极大似然估计为

$$\hat{c} = \frac{n+p-1}{a-T} = \frac{n+p-1}{a-\sum_{i=1}^n \log X_i}.$$

∎

31. 设 $X_1,\cdots,X_n$ 为 *i.i.d.* 样本， $X_1 \sim N(\mu,\sigma^2), \mu$ 已知

(1) 设 σ 的先验分布 $\pi(\sigma) \propto \frac{1}{\sigma}$, 求 σ 的后验极大似然估计,

(2) 记 $\delta=\sigma^2$, 设 δ 的先验分布 $\pi(\delta) \propto \frac{1}{\delta}$, 求 δ 的后验极大似然估计,

(3) 设 δ 的先验分布 $\pi(\delta) \sim \Gamma^{-1}(\alpha,p)$, 求 δ 的后验极大似然估计。

解. (1) σ 的后验密度函数为

$$\begin{aligned}\pi(\sigma|x) &= c(x)\cdot(\frac{1}{\sqrt{2\pi}\sigma})^n \exp\{-\frac{1}{2\sigma^2}\sum_{i=1}^n (x_i-\mu)^2\}\cdot\frac{1}{\sigma} \\ &= c(x)\cdot\sigma^{-(n+1)}\exp\{-\frac{1}{\sigma^2}\cdot\frac{S^2}{2}\},\end{aligned}$$

其中 $S^2=\sum_{i=1}^n (x_i-\mu)^2$ ，其后验对数似然函数为

$$L(\sigma|x) = -(n+1)\log\sigma - \frac{1}{\sigma^2}\cdot\frac{S^2}{2} + \log c^*(x).$$

由于

$$\frac{\partial L(\sigma|x)}{\partial\sigma} = -\frac{n+1}{\sigma} + \frac{2\sigma}{\sigma^4}\cdot\frac{S^2}{2} = 0,$$

因此可得 σ 的后验极大似然估计为 $\hat{\sigma}=\sqrt{\frac{S^2}{n+1}}$.

(2) δ 的后验密度函数和后验对数似然函数分别为

$$\begin{aligned}\pi(\delta|x) &= c(x)\cdot(\frac{1}{2\pi\delta})^{\frac{n}{2}}\exp\{-\frac{1}{\delta}\frac{S^2}{2}\}\cdot\frac{1}{\delta}.\\ L(\delta|x) &= -\frac{n+2}{2}\log\delta-\frac{1}{\delta}\cdot\frac{S^2}{2}+\log c(x)-\frac{n}{2}\log 2\pi.\end{aligned}$$

由于

$$\frac{\partial L(\delta|X)}{\partial\delta}=-\frac{n+2}{2}\frac{1}{\delta}+\frac{1}{\delta^2}\cdot\frac{S^2}{2}=0.$$

因此可得 δ 即 σ^2 的后验极大似然估计为 $\hat{\delta}=\hat{\sigma}^2=\frac{S^2}{n+2}$.

(3) 因为

$$\pi(\delta|x)\sim\Gamma^{-1}(\alpha+\frac{S^2}{2},\ \frac{n}{2}+p)$$

所以 δ 的后验密度函数和后验对数似然函数分别为

$$\begin{aligned}\pi(\delta|x) &= c(x)\cdot\exp\{-\frac{1}{\delta}(\alpha+\frac{S^2}{2})\}\cdot\delta^{-(\frac{n}{2}+p+1)},\\ L(\delta|x) &= -(\frac{n}{2}+p+1)\log\delta-\frac{1}{\delta}(\alpha+\frac{S^2}{2})+\log c(x).\end{aligned}$$

由于

$$\frac{\partial L(\delta|x)}{\partial\delta}=-(\frac{n}{2}+p+1)\cdot\frac{1}{\delta}+\frac{1}{\delta^2}\cdot(\alpha+\frac{S^2}{2})=0,$$

因此可得 δ 即 σ^2 的后验极大似然估计为

$$\hat{\delta}=\hat{\sigma}^2=\frac{S^2+2\alpha}{n+2p+2}.$$

∎

32. 设 $X_1,\cdots,X_n$ 为 $i.i.d.$ 样本，$X_1\sim N(\mu,\sigma^2)$, 其中 μ,σ^2 都未知, 记 $\delta=\sigma^2,\theta=(\mu,\delta)^T$, 又设 $\pi(\theta)\propto\delta^{-1}$, 求 θ 的后验极大似然估计。

解. θ 的后验密度函数为

$$\begin{aligned}\pi(\theta|x) &= c(x)\cdot(\frac{1}{\sqrt{2\pi}})^n\cdot\delta^{-\frac{n}{2}}\cdot\exp\{-\frac{1}{2\delta}\sum_{i=1}^n(x_i-\mu)^2\}\cdot\frac{1}{\delta}\\ &= c^*(x)\cdot\delta^{-\frac{n+2}{2}}\exp\{-\frac{S^2}{2\delta}-\frac{n(\mu-\bar{x})^2}{2\delta}\},\end{aligned}$$

其中 $S^2=\sum_{i=1}^n(x_i-\bar{x})^2$，其后验对数似然函数为

$$L(\theta|x)=-\frac{n+2}{2}\log\delta-\frac{S^2}{2\delta}-\frac{n(\mu-\bar{x})^2}{2\delta}+\log c^*(x).$$

解方程组

$$\begin{aligned}\frac{\partial L(\theta|x)}{\partial\mu} &= -\frac{n}{\delta}(\mu-\bar{x})^2=0\\ \frac{\partial L(\theta|x)}{\partial\delta} &= -\frac{n+2}{2}\cdot\frac{1}{\delta}+\frac{S^2}{2\delta^2}+\frac{n(\mu-\bar{x})^2}{2\delta^2}=0.\end{aligned}$$

便得 μ 和 δ 的后验极大似然估计

$$\hat{\mu} = \bar{X}; \quad \hat{\delta} = \frac{1}{n+2}\sum_{i=1}^{n}(X_i - \bar{X})^2. \qquad \blacksquare$$

33. 设 $X_1, \cdots, X_n$ 为 *i.i.d.* 样本， X_1 服从幂函数分布 $X_1 \sim f(x_1; c, \theta) = cx_1^{c-1}\theta^{-c}I\{0 \le x_1 \le \theta\}$ $(c > 0;\ \theta > 0)$. 求相应参数的后验极大似然估计： i) 若 θ 已知， c 的先验分布为 Γ 分布 $\Gamma(a, p)$ ； ii) 若 c 已知， θ 的先验分布为 Pareto 分布 $PR(\alpha, \mu)$ 。

解. (1) 由本章习题 3 知，当 θ 已知时，

$$\pi(c|x) \sim \Gamma(a - \sum_{i=1}^{n}(\log x_i - \log\theta),\ n+p).$$

由此易得 c 的后验极大似然估计为

$$\hat{c} = \frac{(n+p-1)}{a - \sum_{i=1}^{n}(\log X_i - \log\theta)}.$$

(2) 由本章习题 3 知，当 c 已知时，$\pi(\theta|x) \sim PR(nc+\alpha,\ \theta_0)$ ，其中 $\theta_0 = \max\{x_{(n)},\ \mu\}$ 。由此易得 θ 的后验极大似然估计为 $\hat{\theta} = \theta_0$ 。 $\blacksquare$

34. 设 $X_1, \cdots, X_n$ 为 *i.i.d.* 样本， $X_1 \sim \mu + \Gamma(\frac{1}{\sigma}, 1)$ 。若只观测到前 r 个寿命值： $Y_1 = X_{(1)}, \cdots, Y_r = X_{(r)}$ 。在以下三种无信息先验分布下，求相应参数的后验极大似然估计： i) $\sigma = 1,\ \mu$ 未知； ii) $\mu = 0,\ \sigma$ 未知； iii) $\theta = (\sigma, \mu)$ 都未知。

解. i) 当 $\sigma = 1,\ \mu$ 未知时， μ 的无信息先验分布为 $\pi(\mu) \propto 1$ 。 μ 的后验分布为

$$\pi(\mu|x) \propto \frac{n!}{(n-r)!}\exp\{-[\sum_{i=1}^{r} y_i + (n-r)y_r - n\mu]\}I\{y_1 \ge \mu\}.$$

由此可得 $\pi(\mu|x) = ne^{n(\mu - y_1)}I\{\mu \le y_1\}$ 。要使 $\pi(\mu|x)$ 达到最大，则须 μ 最大，而 $\mu \le y_1$ ，因而 $\mu = y_1$ 时最大，所以 μ 的后验极大似然估计为 $\hat{\mu} = Y_1 = X_{(1)}$ 。

ii) 当 $\mu = 0,\ \sigma$ 未知时， σ 的无信息先验分布为 $\pi(\sigma) \propto \sigma^{-1}$ 。所以 σ 的后验分布为

$$\pi(\sigma|x) = c(x) \cdot \sigma^{-(r+1)}\exp\{-\frac{1}{\sigma}[\sum_{i=1}^{r} y_i + (n-r)y_r]\}.$$

其后验对数似然函数为

$$L(\sigma|x) = -(r+1)\log\sigma - \frac{1}{\sigma}[\sum_{i=1}^{r} y_i + (n-r)y_r] + \text{常数项}.$$

所以由

$$\frac{\partial L}{\partial \sigma} = -\frac{r+1}{\sigma} + \frac{1}{\sigma^2}[\sum_{i=1}^{r} y_i + (n-r)y_r] = 0$$

可得 σ 的后验极大似然估计为

$$\hat{\sigma} = \frac{1}{r+1}[\sum_{i=1}^{r} Y_i + (n-r)Y_r].$$

iii) 当 $\theta=(\sigma,\mu)$ 都未知时， θ 的无信息先验分布为 $\pi(\mu,\sigma)\propto\sigma^{-2}$ 。所以 (μ,σ) 的后验密度函数为

$$\pi(\mu,\sigma|x)=c(x)\sigma^{-(r+2)}\exp\{-\frac{1}{\sigma}[\sum_{i=1}^{r}y_i+(n-r)y_r-n\mu]\}I\{y_1\geq\mu\}.$$

类似于 i)， ii) 的讨论可得 μ 和 σ 的后验极大似然估计分别为

$$\hat{\mu}=Y_1,\quad \hat{\sigma}=\frac{1}{r+2}[\sum_{i=1}^{r}Y_i+(n-r)Y_r-nY_1].$$ ∎

35.* 设 $X\sim f(x,\theta)$, $\theta\in\Theta$, θ 的先验分布为 $\theta\sim\pi(\theta)$ ，对 $g(\theta)$ 的估计，取损失函数为 $L(\theta,d)=\frac{d}{g(\theta)}-\log\frac{d}{g(\theta)}-1$ ；求 $g(\theta)$ 的 Bayes 估计。

解. 不妨设 θ 的后验分布为 $\pi(\theta|x)$ ，则 $\pi(\theta|x)=(\int_\Theta f(x;\theta)\pi(\theta)d\theta)^{-1}f(x;\theta)\pi(\theta)$ 。由定理 8.2.1 知 $g(\theta)$ 的 Bayes 估计 $\delta(X)$ 使得以下后验风险达到最小

$$\begin{aligned}R_\pi(\delta|x) &= \int_\Theta L(g(\theta),\delta(x))\pi(\theta|x)d\theta\\ &= \int_\Theta(\frac{\delta(x)}{g(\theta)}-\log\frac{\delta(x)}{g(\theta)}-1)\pi(\theta|x)d\theta\\ &= \delta(x)\int_\Theta g^{-1}(\theta)\pi(\theta|x)d\theta-\log\delta(x)+\int_\Theta\log g(\theta)\pi(\theta|x)d\theta-1.\end{aligned}$$

$R_\pi(\delta|x)$ 可看作变量 δ 的函数，其极小值可经过求导得到。由于

$$\frac{\partial R_\pi(\delta|x)}{\partial\delta}=\int_\Theta g^{-1}(\theta)\pi(\theta|x)d\theta-\frac{1}{\delta}=0;\quad \frac{\partial^2R_\pi(\delta|x)}{\partial\delta^2}=\frac{1}{\delta^2}>0.$$

因而有

$$\delta(x)=[\int_\Theta g^{-1}(\theta)\pi(\theta|x)d\theta]^{-1}.$$

这是 $R_\pi(\delta|x)$ 唯一的极小值点，因而也是最小值点，所以就是 $g(\theta)$ 的 Bayes 估计。 ∎

36. 设 $X_1,\cdots,X_n$ 为独立同分布样本，且有 $X_1\sim b(1,\theta)$, 损失函数为 $L(\theta,d)=\frac{(d-\theta)^2}{\theta(1-\theta)}$ ；证明： T/n 为 θ 的 Minimax 估计，其中 $T=\sum_{i=1}^n X_i$ 。

证明. T/n 的风险函数为 $R(\theta,\hat{\theta})=\mathrm{E}_\theta(\frac{T}{n}-\theta)^2/[\theta(1-\theta)]=1/n$ ，其值是常数。因此，若 T/n 为某一正常的先验分布下 θ 的 Bayes 估计，则由定理 8.2.6 可知， T/n 为 θ 的 Minimax 估计。事实上，若取 θ 的先验分布为 $\theta\sim BE(p,q)$ ，则 θ 的后验分布为 $\pi(\theta|x)\sim BE(p+T,n+q-T)$ 。所以在损失函数 $L(\theta,d)=(d-\theta)^2/[\theta(1-\theta)]$ 下， θ 的 Bayes 估计为 (参见第 14 题)

$$\hat{\theta}=\frac{\mathrm{E}[\theta\lambda(\theta)|X]}{\mathrm{E}[\lambda(\theta)|X]}=\frac{\mathrm{E}[\frac{1}{1-\theta}|X]}{\mathrm{E}[\frac{1}{\theta(1-\theta)}|X]}=\frac{p+T-1}{n+p+q-2}.$$

易见，当 $p=q=1$ 时， $\theta\sim BE(1,1)\sim R(0,1)$ 为正常的先验分布，而且有 $\hat{\theta}=T/n$ ， $R(\theta,\hat{\theta})=1/n$ 为常数。所以由定理 8.2.6 知 $\hat{\theta}=T/n$ 是 θ 的 Minimax 估计。 ∎

注. (1) 我们亦可仿照原书例 8.2.12，先基于先验分布 $\theta \sim BE(p,q)$ 计算出估计 $\hat{\theta}$ 的风险函数，并从中找出风险函数为常数的 Bayes 估计。该估计的风险函数为

$$\begin{aligned}
R(\theta,\hat{\theta}) &= \frac{1}{\theta(1-\theta)}\mathrm{E}_\theta[\hat{\theta}-\theta]^2 \\
&= \frac{1}{\theta(1-\theta)}\cdot\frac{1}{(n+p+q-2)^2}\mathrm{E}_\theta[(p+T)-(n+p+q)\theta-(1-2\theta)]^2 \\
&= \frac{1}{\theta(1-\theta)}\cdot\frac{1}{(n+p+q-2)^2}\{n\theta(1-\theta)+[p(1-\theta)-q\theta]^2 \\
&\quad -2(1-2\theta)(p(1-\theta)-q\theta)+(1-2\theta)^2\} \\
&= \frac{1}{(n+p+q-2)^2}\{n+\frac{1}{\theta(1-\theta)}[(p-1)(1-\theta)-(q-1)\theta]^2\} \\
&= \frac{1}{(n+p+q-2)^2}\{n+\frac{(p-1)^2}{\theta}-(p-1)^2-2(p-1)(q-1)-(q-1)^2+\frac{(q-1)^2}{1-\theta}\}.
\end{aligned}$$

这时，也只有 $p=q=1$ 时 $R(\theta,\hat{\theta})=1/n$ 是常数。并且有 $\theta\sim BE(1,1)\sim R(0,1)$ 以及 $\hat{\theta}=T/n$，所以 $\hat{\theta}=T/n$ 是 θ 的 Minimax 估计。

另外，我们亦可根据定理 8.2.7 来证明 T/n 是 θ 的 Minimax 估计。为此，可取 θ 的一列先验分布为 $\pi_k(\theta)\sim BE(1+\frac{1}{k},1+\frac{1}{k})$，在损失函数 $L(\theta,d)=(d-\theta)^2/[\theta(1-\theta)]$ 下，θ 的 Bayes 估计为 $\hat{\theta}_k=\frac{T+1/k}{n+2/k}$，其相应的 Bayes 风险为

$$\gamma_k=R_\pi(\hat{\theta}_k)=\frac{1}{(n+2/k)^2}[n+\frac{1}{k^2\theta}-\frac{4}{k^2}+\frac{1}{(1-\theta)k^2}]\to\frac{1}{n}=R(\theta,\hat{\theta})\quad(k\to\infty).$$

所以根据定理 8.2.7， T/n 是 θ 的 Minimax 估计。 ∎

37. 设 $X_1,\cdots,X_n$, 为 *i.i.d.* 样本， $X_1\sim R(\theta-\frac{1}{2},\theta+\frac{1}{2})$ (均匀分布) 。证明：在均方损失下， $\hat{\theta}=(X_{(1)}+X_{(n)})/2$ 为 θ 的 Minimax 估计。 (提示：取一列先验分布为 $(-k,+k)$ 上的均匀分布).

证明. 由第七章习题 6 可知， $T=\hat{\theta}-\theta$ 的密度函数为

$$f(t)=n(1-2|t|)^{n-1}I\{-\frac{1}{2}\le t\le\frac{1}{2}\}.$$

所以 $\hat{\theta}$ 的风险函数为

$$R(\theta,\hat{\theta})=\mathrm{E}[\hat{\theta}-\theta]^2=\mathrm{E}T^2=\int_{-\frac{1}{2}}^{\frac{1}{2}}t^2f(t)dt.$$

其值是与 θ 无关常数，不妨记其为 γ 。取 θ 的一列先验分布为 $\pi_k(\theta)\sim R(-k,k),\quad k=1,2,\cdots$. 则 θ 的后验分布为

$$\begin{aligned}
\pi_k(\theta|x) &= c(x)I\{-k\le\theta\le k\}I\{\theta-\frac{1}{2}\le x_{(1)}\le x_{(n)}\le\theta+\frac{1}{2}\} \\
&= c(x)I\{-k\le\theta\le k\}I\{x_{(n)}-\frac{1}{2}\le\theta\le x_{(1)}+\frac{1}{2}\} \\
&\propto I\{m_k\le\theta\le M_k\}.
\end{aligned}$$

其中 $m_k=\max\{X_{(n)}-\frac{1}{2},\ -k\}$, $M_k=\min\{X_{(1)}+\frac{1}{2},\ k\}$，即 θ 的后验分布为 $[m_k,\ M_k]$ 上的均匀分布。因此有

$$\hat{\theta}_k=\mathrm{E}(\theta|x)=\frac{1}{2}(m_k+M_k)$$

当 k 充分大时, 即 $k > X_{(1)}+\frac{1}{2}$; $-k < X_{(n)}-\frac{1}{2}$ 时，必有 $m_k = X_{(n)}-\frac{1}{2}$，$M_k = X_{(1)}+\frac{1}{2}$，这时有 $\hat{\theta}_k = \hat{\theta} = \frac{1}{2}(X_{(1)}+X_{(n)})$ 。所以当 $k \to \infty$ 时，我们有 $R(\theta,\hat{\theta}_k) = \gamma_k = R(\theta,\hat{\theta}) = \gamma$ 。由定理 8.2.7 可知，$\hat{\theta}$ 是 θ 的 Minimax 估计。 ∎

38. 设 $X_1,\cdots,X_n$ 为独立同分布样本，$X_1 \sim \Gamma(\frac{1}{\sigma},1)$ 。取损失为 $L(\theta,d) = [(d-\theta)/\theta]^2$, 证明：在此损失函数下，$T/(n+1)$ 为 θ 的 Minimax 估计，其中 $T = \sum_{i=1}^n X_i$ 。(提示：取一列先验分布为逆 Γ 分布：$\Gamma^{-1}(k^{-1},k^{-1})$).

证明. 由于 $T = \sum_{i=1}^n X_i \sim \Gamma(\frac{1}{\theta},n)$ ，所以 $\hat{\theta} = \frac{T}{n+1}$ 的风险函数为

$$R(\theta,\hat{\theta}) = \mathrm{E}_\theta[1-\frac{T}{(n+1)\theta}]^2 = \frac{1}{n+1}.$$

其值是常数。我们取 θ 的一列先验分布为 $\pi_k(\theta) \sim \Gamma^{-1}(k^{-1},k^{-1})$ ，由本章习题 2 的 (2) 知 θ 的后验分布也是一列逆 Γ 分布，即 $\pi_k(\theta|x) \sim \Gamma^{-1}(T+k^{-1},n+k^{-1})$ 。在损失函数 $L(\theta,d) = [(d-\theta)/\theta]^2$ 下，与 $\pi_k(\theta|x)$ 相应的 θ 的 Bayes 估计为

$$\hat{\theta}_k = \frac{\mathrm{E}(\theta^{-1}|X)}{\mathrm{E}(\theta^{-2}|X)} = \frac{T+k^{-1}}{n+k^{-1}+1}.$$

其相应的风险函数为

$$\begin{aligned} R(\theta,\hat{\theta}_k) &= \mathrm{E}_\theta[1-\frac{T+k^{-1}}{(n+k^{-1}+1)\theta}]^2 \\ &= 1-\frac{2(n\theta+k^{-1})}{(n+k^{-1}+1)\theta}+\frac{(n^2+n)\theta^2+2k^{-1}n\theta+k^{-2}}{(n+k^{-1}+1)^2\theta^2}. \end{aligned}$$

因此当 $k \to \infty$ 时，我们有 $R(\theta,\hat{\theta}_k) \to \frac{1}{n+1} = R(\theta,\hat{\theta})$ 。所以由定理 8.2.7 可知，$\frac{T}{n+1}$ 是 θ 的 Minimax 估计。 ∎

39. $X_1,\cdots,X_n$ 为独立同分布样本，求以下单边假设检验问题的 Bayes 解：$H_0 : \theta \le \theta_0 \longleftrightarrow H_1 : \theta > \theta_0$. (1) $X_1 \sim N(\theta,\sigma^2)$, 但 σ^2 已知，θ 服从无信息先验分布 $\pi(\theta) \propto 1$; (2) $X_1 \sim P(\theta)$ 为 Poisson 分布，θ 的先验分布 $\pi(\theta) \sim \Gamma(\alpha,p)$ 为 Γ 分布。

解. (1) θ 的后验分布密度函数为

$$\begin{aligned} \pi(\theta|x) &\propto (\frac{1}{\sqrt{2\pi\sigma^2}})^n \exp\{-\frac{1}{\sigma^2}\sum_{i=1}^n (x_i-\theta)^2\}\cdot 1 \\ &\propto \exp\{-\frac{n}{2\sigma^2}(\theta-\bar{x})^2\} \\ &\sim N(\bar{x},\frac{1}{n}\sigma^2). \end{aligned}$$

在本题中，$\Theta_0 = \{\theta \le \theta_0\}$，$\Theta_1 = \{\theta > \theta_0\}$ ，因而可以求出后验概率为

$$\pi_1(x) = P\{\theta > \theta_0|x\} = P\{\frac{\theta-\bar{x}}{\sigma^2/n} > \frac{\theta_0-\bar{x}}{\sigma^2/n}|x\}.$$

由于 $(\theta-\bar{x})/(\sigma^2/n) \sim N(0,1)$ ，因而有

$$\pi_1(x) = 1-\Phi(\frac{\theta_0-\bar{x}}{\sigma^2/n}),\quad \pi_0(x) = \Phi(\frac{\theta_0-\bar{x}}{\sigma^2/n}).$$

其中 $\Phi(.)$ 是标准正态分布的分布函数。根据原书 (8.3.12) 式，该假设检验问题的 Bayes 否定域为

$$R^* = \{x : \pi_1(x) > \frac{1}{2}\} = \{x : \Phi(\frac{\theta_0 - \bar{x}}{\sigma^2/n}) < \frac{1}{2}\} = \{x : \frac{\theta_0 - \bar{x}}{\sigma^2/n} < 0\} = \{x : \bar{x} > \theta_0\}.$$

(2) 由例 8.1.3 知， θ 的后验分布为 $\pi(\theta|x) \sim \Gamma(n+\alpha, T+p)$ ，其中 $T = \sum_{i=1}^n X_i$ 。在本题中， $\Theta_0 = \{\theta \le \theta_0\}$， $\Theta_1 = \{\theta > \theta_0\}$ ，且有 $2(n+\alpha)\theta|x \sim \chi^2(2T+2p)$ ，因而可以求出后验概率

$$\pi_1(x) = P\{\theta > \theta_0|x\} = P\{2(n+\alpha)\theta > 2(n+\alpha)\theta_0|x\}.$$

由于 $2(n+\alpha)\theta|X \sim \chi^2(2T+2p)$ ，若记 $\nu_0 = 2(n+\alpha)\theta_0$， $\chi^2(2T+2p, x)$ 表示自由度为 $2T+2p$ 的 χ^2 分布的密度函数，则有

$$\pi_1(x) = \int_{\nu_0}^{\infty} \chi^2(2T+2p, x)dx,$$

今记 $\chi^2(2T+2p)$ 分布的中位数为 $\mathrm{Mid}_{\chi^2}(2T+2p)$ ，则该假设检验问题的 Bayes 否定域可表示为

$$R^* = \{x : \pi_1(x) > \frac{1}{2}\} = \{x : \int_0^{\nu_0} \chi^2(2T+2p, x)dx < \frac{1}{2}\} = \{x : \nu_0 < \mathrm{Mid}_{\chi^2}(2T+2p)\}$$

注. 因为 χ^2 分布的中位数是其自由度的增函数，如果存在常数 k ，使之满足 $\mathrm{Mid}_{\chi^2}(2T+2p) = \nu_0 = 2(n+\alpha)\theta_0$ ，则 Bayes 否定域可表示为 $R^* = \{x : T > k\}$ 。

∎

40. 假设 X 服从二项分布 $B(5, \theta)$ ， θ 的先验分布为 $BE(1, 9)$ ，若观察值为 $x = 0$ ， $H_0 : \theta \le 0.1 \longleftrightarrow H_1 : \theta > 0.1$ ，求检验问题的后验概率和交比。

解. 由于 $x = 0$ ，所以 θ 的后验分布 $\pi(\theta|x) \sim BE(1+x, 14-x) \sim BE(1, 14)$ 。在本问题中，因为 $\Theta_0 = \{\theta \le 0.1\}$， $\Theta_1 = \{\theta > 0.1\}$ ，所以检验问题的后验概率分别为

$$\begin{aligned}
\pi_1(x) &= P\{\theta > 0.1|x\} = \int_{0.1}^{1} (1-x)^{13}dx = 0.9^{14}, \\
\pi_0(x) &= P\{\theta \le 0.1|x\} = \int_{0}^{0.1} (1-x)^{13}dx = 1 - 0.9^{14}.
\end{aligned}$$

因而交比为 $k_{10} = \frac{\pi_1(x)}{\pi_0(x)} = 0.9^{14}/(1-0.9^{14}) = 0.2288$ 。 ∎

注. 由于 $k_{10} < 1$ ，不应否定原假设，这是合理的。直观上看，当观察值为 $x = 0$ 时 (即事件没发生) ，我们没有足够的理由否定“事件发生的概率小于 1/10 ”。 ∎

41. 假设 X 服从正态分布 $N(\theta, \sigma^2)$ ，参数都未知， θ, σ^2 服从无信息先验分布 $\pi(\theta, \sigma^2) \propto \sigma^{-2}$ ，其 $i.i.d.$ 观察值为 (1.2, 1.6, 1.3, 1.4, 1.4), $H_0 : \theta \le 1 \longleftrightarrow H_1 : \theta > 1$ ，求检验问题的后验概率和交比。

由本章习题 5 的结论可知， θ 的后验边缘密度函数可表示为 $f((\theta - \bar{x})/\tau)$ ，其中 $\tau^2 = \frac{1}{n(n-1)} \sum_{i=1}^n (x_i - \bar{x})^2$， $f(\cdot)$ 是自由度为 $n-1$ 的 t 分布的密度函数。在本题中， 5 个

样本值分别为 $x_1=1.2,\ x_2=1.6,\ x_3=1.3,\ x_4=1.4,\ x_5=1.4$，由此算得 $\bar{x}=1.3800,\ \tau=0.0663$，而 t 分布的自由度为 4 。因为 $\Theta_0=\{\theta\le 1\},\ \ \Theta_1=\{\theta>1\}$，所以检验问题的后验概率分别为

$$\begin{aligned}\pi_1(x) &= P(\theta>1|x)=P(\frac{\theta-\bar{x}}{\tau}>\frac{1-\bar{x}}{\tau}|x)=\int_{-5.7287}^{\infty}f(t)dt=0.9977,\\ \pi_0(x) &= P(\theta\le 1|x)=P(\frac{\theta-\bar{x}}{\tau}\le\frac{1-\bar{x}}{\tau}|x)=\int_{-\infty}^{-5.7287}f(t)dt=0.0023.\end{aligned}$$

其中 $f(t)$ 是自由度为 4 的 t 分布的密度函数，$(1-\bar{x})/\tau=-5.7287$ 。从而交比为 $k_{10}=\frac{\pi_1(x)}{\pi_0(x)}=433.7826$ 。 ∎

注. 由于 $k_{10}>1$，应否定原假设，这是合理的。直观上看，5 个观察值都大于 1，因此我们有足够的理由否定“总体均值 $\theta\le 1$”这一假设。 ∎

42. 假设某公共汽车站的候车时间 X 服从均匀分布 $R(0,\theta)$，近日观察到的候车时间分别为 10, 3, 2, 5, 14 分钟。考虑假设检验问题 $H_0:0\le\theta\le 15\longleftrightarrow H_1:\theta>15$，假设 θ 的先验分布为 Pareto 分布 $PR(5,3)$，求检验问题的后验概率和交比。

解. 由原书例 8.1.6 可知，θ 的后验分布密度函数为 Pareto 分布 $PR(n+\alpha,\theta')$，其中 $n=5,\ \alpha=5$，而 $\theta'=14=x_{(n)}\ (>\theta_0=3)$，即 $\theta|x\sim PR(10,14)$：

$$\pi(\theta|x)=10\cdot 14^{10}\cdot\theta^{-11}I\{\theta\ge 14\}\sim PR(10,14).$$

在本题中，因为 $\Theta_0=\{0\le\theta\le 15\},\ \ \Theta_1=\{\theta>15\}$，所以检验问题的后验概率分别为

$$\begin{aligned}\pi_1(x) &= P(\theta>15|x)=\int_{15}^{\infty}\pi(\theta|x)d\theta=(\frac{14}{15})^{10}=0.5016,\\ \pi_0(x) &= P(\theta\le 15|x)=1-\pi_1(x)=0.4984.\end{aligned}$$

从而检验问题的交比为 $k_{10}=\frac{\pi_1(x)}{\pi_0(x)}=1.0064.$

43. 设 $X\sim f(x,\theta),\ \theta\in\Theta,\ \theta$ 的先验分布为 $\theta\sim\pi(\theta)$. 对于假设检验问题 $H_0:\theta\in\Theta_0\longleftrightarrow H_1:\theta\in\Theta_1,\ \ \Theta_0\cup\Theta_1=\Theta$ 。取损失函数为：

$$L(\theta,\delta(x))=\begin{cases}C_1, & \theta\in\Theta_0\ \text{且}\ \delta(x)=1\\ C_0, & \theta\in\Theta_1\ \text{且}\ \delta(x)=0\\ 0, & \theta\in\Theta_0\ \text{且}\ \delta(x)=0\ \text{或}\ \theta\in\Theta_1\ \text{且}\ \delta(x)=1\end{cases}$$

证明：以上假设检验问题 Bayes 解的否定域满足 $R^*=\{x:\pi_1(x)>C_1/(C_1+C_0)\}$，其中 $\pi_1(x)=\int_{\Theta_1}\pi(\theta|x)d\theta$ 。(提示：参考定理 8.3.1 和引理 8.3.1) 。

证明. 在原书定理 8.3.1 的证明中，其关键是求出 $0-1$ 损失下相应检验问题的后验风险，即引理 8.3.1 。本题的损失函数有所不同，但证明方法类似，我们首先可得到对应于引理 8.3.1 的公式，即求出对应于本题损失函数的后验风险，在此基础上即可找出使后验风险达到最小值的解，即本题假设检验问题的 Bayes 解。

与引理 8.3.1 相应的结论为：对于本题的假设检验问题的任一判决函数 $\delta(x)$，设其否定越为 R^+，则在本题的损失函数下，其后验风险可表示为

$$R_\pi(\delta|x)=\begin{cases}C_1\pi_0(x), & x\in R^+\\ C_0\pi_1(x), & x\in R^-.\end{cases}$$

其中 $\pi_i(x)=P(\Theta_i|x),\ i=0,1$ 。

下面我们来证明这一结论。根据本题中的损失函数， $R_\pi(\delta|x)$ 可表示为

$$\begin{aligned} R_\pi(\delta|x) &= \int_\Theta L(\theta,\delta(x))\pi(\theta|x)d\theta \\ &= \int_{\Theta_0} L(\theta,\delta(x))\pi(\theta|x)d\theta + \int_{\Theta_1} L(\theta,\delta(x))\pi(\theta|x)d\theta \end{aligned}$$

记上式第一项为 $R_0(x)$ ，第二项为 $R_1(x)$ ，则积分主要计算 $L(\theta,\delta(x))\neq 0$ 的部分。首先计算 $R_0(x)$ ，这时在 $\theta\in\Theta_0$ 上，我们有

$$L(\theta,\delta(x))=\begin{cases} C_1, & \delta(x)=1, \quad x\in R^+ \\ 0, & \delta(x)=0, \quad x\in R^-. \end{cases}$$

所以

$$R_0(x)=\int_{\Theta_0} L(\theta,\delta(x))\pi(\theta|x)d\theta=\begin{cases} \int_{\Theta_0} C_1\cdot\pi(\theta|x)d\theta=C_1\pi_0(x), & x\in R^+ \\ 0, & x\in R^-. \end{cases}$$

同理可得

$$R_1(x)=\begin{cases} 0, & x\in R^+, \\ C_0\pi_1(x), & x\in R^-, \end{cases}$$

两式相加即可得到后验风险 $R_\pi(\delta|x)$ 的公式。

下面证明：本题假设检验问题的 Bayes 解 $\delta^*(x)$ 对应的否定域 R^* 应满足关系

$$R^*=\{x: C_1\pi_0(x)<C_0\pi_1(x)\}=\{x:\pi_1(x)>\frac{C_1}{C_0+C_1}\}.$$

事实上，对任意的 $\delta(x)$ 及 x ，若 $x\in R^*$ ，则根据以上后验风险的公式， $R_\pi(\delta^*|x)=C_1\pi_0(x)$ 。而 $R_\pi(\delta|x)$ 可取 $C_1\pi_0(x)$ 或 $C_0\pi_1(x)$ 这两个值，但都有 $R_\pi(\delta^*|x)\le R_\pi(\delta|x)$ 。反之，若 $x\in\overline{R^*}$ ，则 $C_1\pi_0(x)\ge C_0\pi_1(x)$ 。这时 $R_\pi(\delta^*|x)=C_0\pi_1(x)$ ，而 $R_\pi(\delta|x)$ 仍可取 $C_1\pi_0(x)$ 或 $C_0\pi_1(x)$ 这两个值，也都有 $R_\pi(\delta^*|x)\le R_\pi(\delta|x)$ 。综上所述，对于任意的 $\delta(x)$ 及 x ，都有 $R_\pi(\delta^*|x)\le R_\pi(\delta|x)$ ，即对应于 R^* 的判决函数 $\delta^*(x)$ 使得后验风险 $R_\pi(\delta|x)$ 达到最小值，所以 $\delta^*(x)$ 为本题假设检验问题的 Bayes 解。 ∎

44. 对于假设检验问题 (8.3.19), 其先验分布如 (8.3.20) 所示。证明：

(1) $\pi_0(x)=\left[1+\frac{1-\pi_0}{\pi_0}\cdot\frac{m_1(x)}{f(x,\theta_0)}\right]^{-1}=[1+k_{10}(x)]^{-1}$;

(2) $\pi_0(x)\ge\left[1+\frac{1-\pi_0}{\pi_0}\cdot\frac{f(x,\hat\theta(x))}{f(x,\theta_0)}\right]^{-1}$;

其中 $\hat\theta(x)$ 为 $f(x,\theta)$ 在 $\Theta-\{\theta_0\}$ 上的最大值点。

(3) 对于例 8.3.5 的检验 ii) ，记 $Z=\sqrt{n}|\bar x-\theta_0|/\sigma$ ，证明：

$$\pi_0(x)\ge\left[1+\frac{1-\pi_0}{\pi_0}\cdot\exp\{\frac{1}{2}Z^2\}\right]^{-1}.$$

证明. (1) 由原书 (8.3.22) 式， (8.3.23) 式以及 (8.3.21) 式可得

$$\pi_0(x)=[\frac{m(x)}{\pi_0 f(x,\theta_0)}]^{-1}=[1+\frac{1-\pi_0}{\pi_0}\cdot\frac{m_1(x)}{f(x,\theta_0)}]^{-1}=[1+k_{10}(x)]^{-1}$$

(2) 因为

$$m_1(x)=\int_{\theta\neq\theta_0}g_1(\theta)f(x;\theta)d\theta\leq\int_{\theta\neq\theta_0}g_1(\theta)f(x;\hat{\theta}(x))d\theta\leq f(x,\hat{\theta}(x)).$$

所以由 (1) 可知 $\pi_0(x)\geq[1+\frac{1-\pi_0}{\pi_0}\cdot\frac{f(x,\hat{\theta}(x))}{f(x,\theta_0)}]^{-1}$.

(3) 在 (1) 中我们得到了 $\pi_0(x)=[1+k_{10}(x)]^{-1}$ 。由例 8.3.5 的结果可知

$$k_{10}(x)=\frac{\pi_1}{\pi_0}\cdot\frac{1}{\sqrt{1+n\sigma_0^2/\sigma^2}}\exp\{\frac{1}{2}\frac{n(\bar{x}-\theta_0)^2}{\sigma^2}\cdot\frac{n\sigma_0^2}{n\sigma_0^2+\sigma^2}\}<\frac{\pi_1}{\pi_0}\exp\{\frac{1}{2}Z^2\}.$$

所以 $\pi_0(x)>[1+\frac{1-\pi_0}{\pi_0}\exp\{\frac{1}{2}Z^2\}]^{-1}$ ，其中 $Z=\sqrt{n}|\bar{x}-\theta_0|/\sigma$ 。 ∎

45. 设 $X_1,\cdots,X_n$ 为 *i.i.d.* 样本， X_1 服从 Poisson 分布 $P(\theta)$ ， θ 的先验分布 $\pi(\theta)$ 为 Γ 分布 $\Gamma(a,\ p)$ ；求 θ 的一个水平为 $1-\alpha$ 的 Bayes 置信区间。

解. 由例 8.1.3 可知 θ 的后验分布 $\pi(\theta|x)\sim\Gamma(n+a,T+p)$ ，其中 $T=\sum_{i=1}^n x_i$ 。由此易得 $2(n+a)\theta|x\sim\Gamma(\frac{1}{2},T+p)\sim\chi^2(2(T+p))$ 。由

$$P(\chi^2(2T+2p,\frac{\alpha}{2})\leq 2(n+a)\theta\leq\chi^2(2T+2p,1-\frac{\alpha}{2})|X)=1-\alpha$$

可得

$$P(\frac{1}{2(n+a)}\chi^2(2T+2p,\frac{\alpha}{2})\leq\theta\leq\frac{1}{2(n+a)}\chi^2(2T+2p,1-\frac{\alpha}{2})|X)=1-\alpha.$$

所以 θ 的一个水平为 $1-\alpha$ 的 Bayes 置信区间为

$$\left[\frac{1}{2(n+a)}\chi^2(2T+2p,\frac{\alpha}{2}),\ \frac{1}{2(n+a)}\chi^2(2T+2p,1-\frac{\alpha}{2})\right].$$

46. 设 $X_1,\cdots,X_n$ 为 *i.i.d.* 样本， $X_1\sim N(\mu,\sigma^2)$ 。

(1) 当 μ 已知，且 $\pi(\sigma^2)\propto 1$ 时，求 σ^2 的水平为 $1-\alpha$ 的 Bayes 区间估计;

(2) 当 μ 未知，且 $\pi(\sigma^2)\propto\sigma^{-2}$ 时，求 σ^2 的水平为 $1-\alpha$ 的 Bayes 区间估计;

(3) 记 $\delta=\sigma^2,\theta=(\mu,\delta)$, 设 θ 的先验分布 $\pi(\theta)\propto\delta^{-1}$ ，求 μ 的水平为 $1-\alpha$ 的 Bayes 区间估计。

解. (1) σ^2 的后验分布为

$$\begin{aligned}\pi(\sigma^2|x) &= c(x)\cdot(\frac{1}{2\pi\sigma^2})^{\frac{n}{2}}\exp\{-\frac{1}{2\sigma^2}\sum_{i=1}^n(x_i-\mu)^2\}\cdot 1\\ &= c^*(x)\cdot(\sigma^2)^{-\frac{n}{2}}\exp\{-\frac{1}{2\sigma^2}\sum_{i=1}^n(x_i-\mu)^2\}\\ &\sim \Gamma^{-1}(\frac{S^2}{2},\ \frac{n}{2}-1),\end{aligned}$$

其中 $S^2=\sum_{i=1}^n(x_i-\mu)^2$ 。由 Γ 分布和逆 Γ 分布之间的关系可知 $\pi(\frac{1}{\sigma^2}|x)\sim\Gamma(\frac{S^2}{2},\ \frac{n}{2}-1)$ ，由 Γ 分布和 χ^2 分布之间的关系可知 $(S^2\cdot\frac{1}{\sigma^2})|x\sim\Gamma(\frac{1}{2},\ \frac{n}{2}-1)\sim\chi^2(n-2)$ 。因此有

$$P\{\chi^2(n-2,\ \frac{\alpha}{2})\leq S^2\cdot\frac{1}{\sigma^2}\leq\chi^2(n-2,\ 1-\frac{\alpha}{2})|x\}=1-\alpha.$$

由此可得

$$P\{\frac{S^2}{\chi^2(n-2,\ 1-\frac{\alpha}{2})} \le \sigma^2 \le \frac{S^2}{\chi^2(n-2,\ \frac{\alpha}{2})}|x\} = 1-\alpha.$$

所以 σ^2 的水平为 $1-\alpha$ 的 Bayes 区间估计为

$$\left[\frac{S^2}{\chi^2(n-2,\ 1-\frac{\alpha}{2})},\quad \frac{S^2}{\chi^2(n-2,\ \frac{\alpha}{2})}\right].$$

(2) (μ,σ^2) 的联合后验分布为

$$\begin{aligned}\pi(\mu,\sigma^2|x) &= c(x)\cdot(\frac{1}{2\pi\sigma^2})^{\frac{n}{2}}\exp\{-\frac{1}{2\sigma^2}\sum_{i=1}^{n}(x_i-\mu)^2\}\cdot\frac{1}{\sigma^2}\\ &= c^*(x)\cdot(\sigma^2)^{-\frac{n-1}{2}-1}\exp\{-\frac{S}{\sigma^2}\}\cdot\frac{1}{\sigma}\exp\{-\frac{n}{2\sigma^2}(\mu-\bar{x})^2\}.\end{aligned}$$

由此可得 σ^2 的边缘后验分布为

$$\pi(\sigma^2|x) = \int_{-\infty}^{\infty}\pi(\mu,\sigma^2|x)d\mu = c^*(x)(\sigma^2)^{-\frac{n-1}{2}-1}\exp\{-\frac{S}{\sigma^2}\} \sim \Gamma^{-1}(\frac{S^2}{2},\frac{n-1}{2}).$$

所以有与 (1) 类似的结果：

$$\pi(\frac{1}{\sigma^2}|x) \sim \Gamma(\frac{S^2}{2},\ \frac{n-1}{2}),\quad (S^2\cdot\frac{1}{\sigma^2})|x \sim \Gamma(\frac{1}{2},\ \frac{n-1}{2}) \sim \chi^2(n-1).$$

由于

$$P\{\chi^2(n-1,\frac{\alpha}{2}) \le S^2\cdot\frac{1}{\sigma^2} \le \chi^2(n-1,\ 1-\frac{\alpha}{2})|x\} = 1-\alpha$$

因此有

$$P\{\frac{S^2}{\chi^2(n-1,\ 1-\frac{\alpha}{2})} \le \sigma^2 \le \frac{S^2}{\chi^2(n-1,\ \frac{\alpha}{2})}|x\} = 1-\alpha.$$

所以 σ^2 的水平为 $1-\alpha$ 的 Bayes 区间估计为

$$\left[\frac{S^2}{\chi^2(n-1,\ 1-\frac{\alpha}{2})},\ \frac{S^2}{\chi^2(n-1,\ \frac{\alpha}{2})}\right].$$

(3) 由本章习题 5 可知 μ 的边缘后验分布为 $\pi(\mu|x) \sim \frac{1}{\tau}f(\frac{\mu-\bar{x}}{\tau})$，其中 $\tau^2 = \frac{S^2}{n(n-1)}$，$S^2 = \sum_{i=1}^{n}(x_i-\bar{x})^2$， $f(\cdot)$ 是自由度为 $n-1$ 的 t 分布的密度函数，因此有

$$P\{|\frac{\mu-\bar{x}}{\tau}| \le t(n-1,\ 1-\frac{\alpha}{2})|x\} = 1-\alpha.$$

由此可得

$$P\{\bar{x}-t(n-1,\ 1-\frac{\alpha}{2})\tau \le \mu \le \bar{x}+t(n-1,\ 1-\frac{\alpha}{2})\tau|x\} = 1-\alpha.$$

所以 μ 的水平为 $1-\alpha$ 的 Bayes 区间估计为

$$\left[\bar{X}-t(n-1,\ 1-\frac{\alpha}{2})\tau,\ \bar{X}+t(n-1,\ 1-\frac{\alpha}{2})\tau\right].$$

这与经典方法的结果一致，但这里是基于 μ 的后验分布而得到的。 ∎

47. 车间生产出大批零件，要检测其次品率。今从中抽出 6 件，假设次品数 X 服从二项分布 $B(6,\theta)$ ， θ 的先验分布为 $BE(1,10)$ ，若观察值为 $X=x=0$ ，求 θ 的水平为 95% 的 HPD 可信区间。

解. 与原书例 8.3.8 类似， θ 的后验分布为 $BE(X+p,\ n-X+q)$ 。对于本题，$n=6$ ， $X=0$ ； $p=1$ ， $q=10$ 。所以 θ 的后验分布为 $BE(1,16)$ ，即

$$\pi(\theta|x)=16(1-\theta)^{15}I\{0\le\theta\le 1\}.$$

易见，$\pi(\theta|x)$ 在区间 $[0,1]$ 上是 θ 的单调递减函数，从而 θ 的 95% HPD 可信区间为 $[0,a_2]$ (参见原书例 8.3.8) ，而 a_2 由水平条件 $\int_0^{a_2}\pi(\theta|x)d\theta=0.95$ 决定。由此可得 $a_2=0.1707$ ，所以 θ 的水平为 95% 的 HPD 可信区间为 $[0,\ 0.1707]$ 。 ∎

48. 用仪器观测某星体的质量 θ ，其 5 次 $i.i.d.$ 观察值为 1.2, 1.6, 1.3, 1.4, 1.4 质量单位。假设观察值 X 服从正态分布 $N(\theta,\sigma^2)$ ，参数都未知，且 θ,σ^2 服从无信息先验分布 $\pi(\theta,\sigma^2)\propto\sigma^{-2}$ 。求 θ 的水平为 90% 的 HPD 可信区间。

解. 由本章习题 5 的结论可知， θ 的边缘后验密度函数为 $\pi(\theta|x)=\frac{1}{\tau}f(\frac{\theta-\bar{x}}{\tau})$ ，其中 $\tau^2=\frac{1}{n(n-1)}\sum_{i=1}^n(x_i-\bar{x})^2$， $f(\cdot)$ 为自由度为 $n-1$ 的 t 分布的密度函数。由于 t 分布为关于原点对称的单峰函数，所以 $\pi(\theta|x)=\frac{1}{\tau}f(\frac{\theta-\bar{x}}{\tau})$ 为关于 $\theta=\bar{x}$ 对称的单峰函数。根据原书 (8.3.29) 式， θ 的水平为 $1-\alpha$ 的 HPD 可信区间可表示为 $[\bar{x}-a,\ \bar{x}+a]$ ，且满足

$$\int_{\bar{x}-a}^{\bar{x}+a}\pi(\theta|x)d\theta=\int_{\bar{x}-a}^{\bar{x}+a}\frac{1}{\tau}f(\frac{\theta-\bar{x}}{\tau})d\theta=1-\alpha.$$

为了确定 a ，可做变换 $\frac{\theta-\bar{x}}{\tau}=t$ ，因此有

$$\int_{\bar{x}-a}^{\bar{x}+a}\pi(\theta|x)d\theta=\int_{-a/\tau}^{a/\tau}f(t)dt=1-\alpha.$$

由于 $f(\cdot)$ 为自由度为 $n-1$ 的 t 分布的密度函数，因此可取 $a/\tau=t(n-1,1-\frac{\alpha}{2})$ ，从而 $a=\tau t(n-1,1-\frac{\alpha}{2})$ ，由此可得 θ 的水平为 $1-\alpha$ 的 HPD 可信区间为

$$[\bar{x}-\tau t(n-1,1-\frac{\alpha}{2}),\ \bar{x}+\tau t(n-1,1-\frac{\alpha}{2})].$$

对于本题数据，5 个样本值分别为 $x_1=1.2,\ x_2=1.6,\ x_3=1.3,\ x_4=1.4,\ x_5=1.4$ ，由此可算得 $\bar{x}=1.3800,\ \tau=0.0663,\ t(4,0.95)=2.1318$ 。代入上面的结果可得 θ 的水平为 90% 的 HPD 可信区间是 $[1.2386, 1.5214]$ 。 ∎