Note of Random Processes

Namae Nashi

2024 年 1 月 6 日

目录

第一章 概率的定义 **3**

1.1 概率测度 4

1.2 完备事件组 4

1.3 独立 4

1.3.1 条件概率 5

1.3.2 Bayers 公式 5

第二章 离散分布 **6**

2.1 分布函数 7

2.2 常见离散分布 8

2.2.1 二项分布 8

2.2.2 几何分布与负二项分布 9

2.3 离散多项分布 10

2.4 条件分布 11

第三章 连续分布 **13**

3.1 连续型分布 14

3.2 一些分布 15

3.3 联合分布 15

3.4 条件分布和条件期望 15

3.5 随机变量的函数 16

第四章 概率收敛 **17**

4.1 不等式 18

4.2 大数律 18

第五章 随机游走 **19**

5.1 轨道计数 20

5.1.1 固定单个中间点 21

5.1.2 游走范围 21

5.1.3 游走到达某点 22

5.1.4 反正弦律 22

5.2 其他简单随机游走 23

第六章 统计 **25**
6.1 统计学基础知识 26
6.1.1 常用分布 26
6.1.2 次序统计量的分布 27
6.1.3 指数族 27
6.1.4 充分统计量 28
6.1.5 完全统计量 28
6.2 点估计 28
6.2.1 点估计的方法 28
6.2.2 点估计/统计推断的评价方法 29
6.2.3 一致最小无偏估计 30
6.3 假设检验 31
6.3.1 假设检验的方法 31
6.3.2 功效函数 31
6.3.3 一致最大功效检验 32
6.4 区间估计 32
6.4.1 枢轴变量法 33
6.4.2 正态总体假设检验 33

第一章　概率的定义

教材: Grimmett 3rd Ed
参考资料：Concrete Mathematics 2nd Ed
关于古典概型的处理技巧请移步组合学

1.1　概率测度

称 **样本空间** Ω 是一个由 **基本事件** ω 的元素组成的集合。**事件** 则是样本空间 Ω 的一个子集 $A \subset \Omega$ 。

如果子集族 $\mathcal{F} \subset 2^{\Omega}$ 构成一个 $\sigma-$ Algebra ，我们称 $\mathcal{F}$ 是一个 **事件域** 。考虑两个事件域的乘积 $\Omega_1 \times \Omega_2$。简单地使用 $\mathcal{F}_1 \times \mathcal{F}_2$ 并不能得到乘积空间的 $\sigma-$代数。

概率函数 是一个函数 $P : \mathcal{F} \to [0, 1]$ ，满足

* 规范性 $P(\Omega) = 1$

* 可数可加性 (蕴含有限可加)

$$P(\bigsqcup_{n=1}^{\infty} B_n) = \sum_{k=1}^{\infty} P(B_k) \tag{1.1}$$

取 $A_n = \bigcup_{k=1}^{n} B_k$ ，得

$$P(\lim_{n\to\infty} A_n) = \lim_{n\to\infty} \sum_{k=1}^{n} P(B_k) = \lim_{n\to\infty} P(A_n) \tag{1.2}$$

这说明概率函数是连续的。可数可加蕴含连续，反之则不一定成立。连续性加上有限可加可以推出可数可加。

1.2　完备事件组

一组事件 $A_n \in S \subset \mathcal{F}$ 是 **完备** 的，是指

$$\forall A \in \mathcal{F}, P(A) = 0 \to A \in S \tag{1.3}$$

？待补充

设$\{A_k\}$ 构成完备事件组，即

$$\bigsqcup_{k=1}^{N} A_k = \Omega \tag{1.4}$$

则有 **全概率公式**

$$P(B) = \sum_{k=1}^{N} P(BA_k) = \sum_{k=1}^{N} P(B \mid A_k)P(A_k) \tag{1.5}$$

1.3　独立

一组事件 A_n **独立**，指的是

$$P(\bigcap_{n=1}^{N} A_n) = \prod_{n=1}^{N} P(A_n) \tag{1.6}$$

一组事件独立不等价于两两独立

1.3.1 条件概率

考虑 $P(AB) = P(A)P(B)$ 不一定成立，定义

$$P(B \mid A) = \frac{P(AB)}{P(A)} \tag{1.7}$$

有

$$P(AB) = P(A)P(B \mid A) = P(B)P(A \mid B) \tag{1.8}$$

以 $P(B \mid A)$ 表示在 A 发生的情况下 B 发生的 **条件概率**。当 A, B 独立时，有 $P(B \mid A) = P(B)$

条件概率 $P_A(B) = P(B \mid A)$ 是 $(\Omega \cap A, \mathcal{F})$ 上的概率函数。那么进一步可以定义 **条件独立**

$$P(\bigcap_{n=1}^{N} A_n \mid C) = \prod_{n=1}^{N} P(A_n \mid C) \tag{1.9}$$

1.3.2 Bayers 公式

由

$$P(A \mid B) = \frac{P(A)P(B \mid A)}{P(B)} \tag{1.10}$$

可得 **Bayers** **公式**

$$P(A_k \mid B) = \frac{P(A_k)P(B \mid A_k)}{\sum P(A_i)P(B \mid A_i)} \tag{1.11}$$

其中，事件 B 称为 Bayers 公式中的 **试验** 。Bayers 公式通常在条件概率中条件和事件互换的情况需要用到。

第二章　离散分布

2.1 分布函数

* **Definition 1.1** (Random Variable) : 概率空间 $(\Omega, \mathcal{F}, P)$ 上的 **随机变量** 是指一个函数 $X : \Omega \to \mathbb{R}$

$$\forall \lambda \in \mathbb{R}, \{\omega \mid X(\omega) \leq \lambda\} \in \mathcal{F} \tag{2.1}$$

$\mathcal{F}$ 是一个 σ 代数，所以这是一个 Borel 性质，等价于定义

$$\forall S \in \mathcal{B}, X^{-1}(S) \in \mathcal{F} \tag{2.2}$$

为方便，记

$$\{X \in U\} = \{\omega \mid X(\omega) \in U\} \tag{2.3}$$

其中，对 $A \in \mathcal{F}$ ，示性函数 $\chi_A(\omega) = [\omega \in A]$ 是一个随机变量。

* $X + Y, \lambda X, XY, X^k$ 是随机变量.

见实分析可测函数。

* **Definition 1.1(1)**(mass function) : 考虑退化形式。如果随机变量 $X : \mathcal{F} \to \mathbb{R}$ 只在离散的点上有值，称为 **离散随机变量** 。此时 P 关于 X 的函数退化成数列，通常我们直接称为 **离散型概率分布** (mass function)，记

$$X \sim P(X = x_k) = P_k \tag{2.4}$$

* **Definition 1.2** : 考虑和式

$$E(X) = \sum_k x_k P(X = x_k) \tag{2.5}$$

如果 $E(X)$ 绝对收敛，则称为 **数学期望**。$E([x \in A]) = P(A)$

* $E(g(X)) = \sum_k g(x_k) P(X = x_k)$

* 线性性 $E(aX + bY) = aE(X) + bE(Y)$

* 正定 $X \leq Y, E(X) \leq E(Y)$

* 三角不等式 $E(|X|) \geq |E(X)|$

* 柯西不等式 $(E(XY))^2 \leq E(X^2)E(Y^2)$ 。取等 $\exists t, E(tX + Y) = 0$

二次函数判别式立证。□

* 考虑 $P_k = \dfrac{2}{\pi^2}\dfrac{1}{k^2}, k \in \mathbb{Z} \setminus \{0\}$ ，期望不是绝对收敛的。此时重排会出现问题，方差也不收敛。

* **Definition 1.3(1)** (independent) : 称 $P(X = x)P(Y = y) = P(X = x, Y = y)$ X, Y 独立。

* **Definition 1.3(2)** (uncorrelated) : 称 $E(X)E(Y) = E(XY)$ X, Y 不相关。

独立 (Independent) $\Rightarrow$ 不相关 (uncorrelated)，反之不然。

有的组合题可以用 $E(X) > n \Rightarrow P(X > n) > 0 \Rightarrow \exists \omega, \text{s.t.} X(\omega) > n$ 。不过感觉画蛇添足。不过利用 $I_A = [x \in A], X = \sum I$ 再讨论 $P(X = k)$ 的分布，可以将自然语言改成式子，不用说那么多话。

e.g. 随机匹配

* **Definition 1.4** : **方差**

$$\mathrm{Var}(X) = E((X - E(X))^2) \tag{2.6}$$

由线性性立得 $\mathrm{Var}(X) = E(X^2) - E(X)^2$ 。标准差 $\sqrt{\mathrm{Var}(X)}$。

* $\mathrm{Var}(aX) = a^2\mathrm{Var}(X)$ * X, Y 不相关 $\mathrm{Var}(X+Y) = \mathrm{Var}(X) + \mathrm{Var}(Y)$

自证不难

* **Definition 1.5** : k 阶矩 $E(X^k)$ ， k 阶中心矩 $E((X - E(X))^k)$

注意到

* $G(s) = E(s^n)$

有

* $G^{(k)}(1) = E(s^{\underline{k}})$ * $E(X) = G'(1)$ * $\mathrm{Var}(X) = E(X(X-1)) + E(X) - E(X)^2 = G''(1) + G'(1) - G'(1)^2$

矩 GF / 累积量咕

$$P(X+Y=z) = \sum_{i+j=z} p(i,j) \overset{Indepent}{=} \sum_{i+j=z} p_1(i)p_2(j) = (p_1 * p_2)(z) \tag{2.7}$$

见具体数学P331 8.3

2.2　常见离散分布

和式生成函数及推导移步组合学。总之有任何记号或推导不懂出门左转组合学。

结论非常简单但建议读者手推。

离散分布 $X \sim P(X = x_k) = P_k$

* 均匀分布

$$P_k = \frac{1}{n} \tag{2.8}$$

$E(X) = \overline{x} = \frac{1}{n}\sum x_k, \mathrm{Var}(X) = 0, G(s) = \sum_{k=1}^{n} s^k$

2.2.1　二项分布

* Bernoulli 分布：随机变量仅有两项

$$P_1 = p, P_2 = 1 - p \tag{2.9}$$

$$E(X) = px_1 \tag{2.10}$$

$$\mathrm{Var}(X) = 0 \tag{2.11}$$

$$G(s) = p + (1-p)s \tag{2.12}$$

喜闻乐见的抽卡可以说成进行一次 Bernoulli 试验。

* **二项分布** 考虑独立重复 n 次 Bernoulli 试验，事件发生 k 次，统计乘积空间即得

$$P_k = \binom{n}{k} p^k (1-p)^{n-k} \tag{2.13}$$

称随机变量 X **服从二项分布** ，记作 $X \sim B(n,p)$ 。此时 $X = 1, 2, \cdots, n$ 。

$$E(X) = np \tag{2.14}$$

$$\mathrm{Var}(X) = np(1-p) \tag{2.15}$$

$$G(s) = (p + (1-p)s)^n \tag{2.16}$$

Poisson分布 考虑令 $n \to \infty$ ，单次概率为常数时显然不收敛，但设 $\lim_{n\to+\infty} np(n) = \lambda$ ，得

$$P_k = \binom{n}{k} p(n)^k (1-p(n))^{n-k} \to e^{-\lambda} \cdot \frac{1}{k!}\lambda^k \tag{2.17}$$

$$P_k = e^{-\lambda} \cdot \frac{1}{k!}\lambda^k \tag{2.18}$$

服从 Poisson 分布记作 $X \sim P(\lambda)$（也许可以记作） $X \sim B(\infty, \frac{\lambda}{n})$ 。

$$E(X) = \lambda \tag{2.19}$$

$$\mathrm{Var}(X) = \lambda \tag{2.20}$$

$$G(s) = e^{\lambda(1-s)} \tag{2.21}$$

验证独立性：增量全概率公式

* 例 $X + Y = N \sim P(\lambda)$ ，证明成功失败次数 X, Y 独立

$P(X = n, Y = m) = P(X = n, Y = m \mid N = n+m)P(N = n+m) = P(X = n)P(X = m)$

这里 $P(X = n) = \sum_{k=n}^{\infty} P(X = n \mid N = k)P(N = k) = \frac{(\lambda p)^n}{n!} e^{-\lambda p}$

2.2.2　几何分布与负二项分布

* **几何分布** 考虑事件发生第 1 次时，独立重复了 k 次 Bernoulli 试验的概率。

$$P_k = (1-p)^{k-1} p \tag{2.22}$$

记 $X \sim G(p)$ 。

$$E(X) = \frac{1}{p} \tag{2.23}$$

$$\mathrm{Var}(X) = \frac{1-p}{p^2} \tag{2.24}$$

$$G(s) = \frac{ps}{1-(1-p)s} \tag{2.25}$$

* **负二项分布** 考虑事件发生第 r 次时，独立重复了 k 次 Bernoulli 试验的概率。考虑确定最后一次结果的二项分布。有

$$P_k = p^r \binom{k-1}{r-1} (1-p)^{k-r} \tag{2.26}$$

服从负二项分布 记作 $X \sim f(r,p)$ ，此时 $X = r, r+1, \cdots$

$$E(X) = \frac{r}{p} \tag{2.27}$$

$$\mathrm{Var}(X) = \frac{r(1-p)}{p^2} \tag{2.28}$$

$$G(s) = \left(\frac{ps}{1-(1-p)s}\right)^r \tag{2.29}$$

2.3　离散多项分布

随机向量，即多个随机变量

* **Definition 3.1** : 对离散情况，X, Y 独立是指

$$\forall x_i, y_i, P(X = x_i, Y = y_i) = P(X = x_i)P(Y = y_i) \tag{2.30}$$

* **Definition 3.1′** : 由于是离散情况

$$\Leftrightarrow P(X \in A, Y \in B) = P(X \in A)P(Y \in B) \tag{2.31}$$

$$\Leftrightarrow P(X \le a, Y \le b) = P(X \le a)P(Y \le b) \tag{2.32}$$

* 协方差 (如果存在)

$$\mathrm{cov}(X,Y) = E((X - E(X))(Y - E(Y))) \tag{2.33}$$

* $\mathrm{cov}(X,X) = \mathrm{Var}(X)$ * $\mathrm{cov}(X,a) = 0$ * $\mathrm{cov}(X,Y) = E(XY) - E(X)E(Y)$ * $\mathrm{cov}(aX,bY) = ab\ \mathrm{cov}(X,Y)$ * $\mathrm{Var}(X+Y) = \mathrm{Var}(X) + \mathrm{Var}(Y) + 2\mathrm{cov}(X,Y)$，$X, Y$ 不相关 $\mathrm{Var}(X+Y) = \mathrm{Var}(X) + \mathrm{Var}(Y)$

* 相关系数

$$\rho(X,Y) = \frac{\mathrm{cov}(X,Y)}{\sqrt{\mathrm{Var}(X)}\sqrt{\mathrm{Var}(Y)}} \tag{2.34}$$

$\rho(X,Y) = 1 \Leftrightarrow \exists a, b, P(aX + bY = 1) = 1$

独立推不相关反之不然

* 协方差矩阵

$$\mathrm{Var}(\sum X) = \sum\sum \mathrm{cov}(X_i, X_j) \tag{2.35}$$

* **多项分布** 现在试验可能出现若干结果，可能性为 $p_1, p_2, \cdots, p_m, \sum_{l=1}^{m} p_l = 1$
重复 n 次试验，记 $k_1, k_2, \cdots, k_m$ 为各结果出现次数，$\sum k = n$ ，有

$$P(k_1, k_2, \cdots, k_m) = \binom{n}{k_1, k_2, \cdots, k_m} p_1^{k_1} p_2^{k_2} \cdots p_m^{k_m} \tag{2.36}$$

记作 $(X_1, X_2, \cdots, X_m) \sim (n, (p_1, p_2, \cdots, p_m))$ 。
其中有 $\sum X_i \sim B(n, \sum p_i)$ ，$i \in A \subset [n]$ 可以推得

$$\operatorname{cov}(X_i, X_j) = -np_ip_j \tag{2.37}$$

$$\rho(X, Y) = \frac{\operatorname{cov}(X, Y)}{\sqrt{\operatorname{Var}(X)}\sqrt{\operatorname{Var}(Y)}} = -\sqrt{\frac{p_ip_j}{(1-p_i)(1-p_j)}} \tag{2.38}$$

同样 $n \to \infty$

$$P(k_1, k_2, \cdots, k_m) = \frac{\alpha_1^{k_1}\alpha_2^{k_2}\cdots\alpha_m^{k_m}}{n!} e^{-\sum \alpha} \tag{2.39}$$

2.4　条件分布

* 条件分布

$$P_{X|Y}(x \mid y) = P(X = x \mid Y = y) = \frac{P(X = x, Y = y)}{P(Y = y)} \tag{2.40}$$

$$E(X \mid Y = y) = \sum_k x_k \cdot P(x_k \mid y) = \frac{\sum_k x_k P(X = x_k, Y = y)}{\sum_k P(X = x_k, Y = y)} \tag{2.41}$$

$E(X \mid Y = y)$ 是关于 y 求 x 期望的函数 $\mathcal{F} \to \mathbb{R}$ 。因此是一个随机函数。

$$\begin{aligned}
E(E(X \mid Y = y)) &= \sum_i E(X \mid Y = y) P(Y = y_i) \\
&= \sum_i \sum_j x_j \cdot P(x_j \mid y_i) P(Y = y_i) \\
&= \sum_j x_j \sum_i P(X = x_j, Y = y_i) \\
&= \sum_j x_j P(X = x_j) \\
&= E(X)
\end{aligned}$$

这个结论很有用。

$$E(X) = \sum_k E(X \mid Y = y_k) P(Y = y_k) \tag{2.42}$$

对比全概率公式

$$E([x \in A]) = \sum_k E([x \in A] \mid B_k) P(B_k) \tag{2.43}$$

* .

$$E(f(X)g(Y) \mid Y = y) = g(Y) E(f(X) \mid Y = y) \tag{2.44}$$

$$E(E(X \mid Y=y)g(X)) = E(Yg(X)) \tag{2.45}$$

* **例** 母鸡以 Poisson 分布下蛋，每个蛋以独立 p 概率破壳，即

$$X \sim P(\lambda), (Y|X=n) \sim B(n,p) \tag{2.46}$$

求 $E(X), E(Y \mid X), E(Y), E(X \mid Y)$ 。由定义立得

$$E(X) = \lambda, E(Y \mid X) = np \tag{2.47}$$

$$\begin{aligned} E(Y) &= E(E(Y \mid X=n)) \\ &= E(pX) \\ &= pE(X) = p\lambda \end{aligned}$$

$$\begin{aligned} P(X \mid Y) &= \frac{P(Y \mid X)P(X)}{\sum_n P(Y \mid X=n)P(X=n)} = \frac{\binom{n}{k} p^k (1-p)^{n-k} \cdot e^{-\lambda} \frac{\lambda^n}{n!}}{\sum_{n \geq k} \binom{n}{k} p^k (1-p)^{n-k} \cdot e^{-\lambda} \frac{\lambda^n}{n!}} \\ &= \frac{\frac{1}{(n-k)!}(1-p)^n \cdot \lambda^n}{\sum_n (1-p)^{n+k} \cdot \frac{\lambda^{n+k}}{n!}} \\ &= \frac{\frac{1}{(n-k)!}(1-p)^n \cdot \lambda^n}{(1-p)^k \lambda^k e^{(1-p)\lambda}} \\ &= \frac{1}{(n-k)!}(q\lambda)^{n-k} e^{-q\lambda} \end{aligned}$$

注意 $n \geq k$

$$E(X \mid Y) = \sum_{n \geq k} n \cdot P(X \mid Y) = e^{-q\lambda} \sum_n (n+k) \cdot \frac{1}{n!}(q\lambda)^n = q\lambda + k \tag{2.48}$$

第三章　连续分布

3.1　连续型分布

* **Definition 1.1** (Probability Distribution Function) : 函数 $F:\mathbb{R}\to(\mathcal{F}\to)[0,1]$

$$F(\lambda)=P(X\le\lambda) \tag{3.1}$$

称为 X 的 **分布函数** 。$F(-\infty)=0,F(+\infty)=1$ 。如果 $F\in C^1(\mathbb{R})$ a.e. $\subset C^0(\mathbb{R})$ ，则称 F 为 **连续型分布函数** 。此时有

$$P(X\le\lambda)=\int_{-\infty}^{\lambda}p(t)dt \tag{3.2}$$

称 $p(t)=F'(t)$ a.e. 为 **概率密度函数**。$p(t)\ge 0$ 。事实上，任何非负且在 $\mathbb{R}$ 上积分有限的函数归一化之后就可以视作一个概率密度函数。例如离散型变量的分布函数 $F(\lambda)=\sum_{k\le\lambda}P_k$ 此时是一个左闭右开的阶梯函数，且

$$P_k=F(x_k)-\lim_{x\to x_k^-}F(x) \tag{3.3}$$

这个时候因为 $F(\lambda)$ 不连续，概率密度函数 $p(t)$ 不存在。或者强行用 Dirac 函数 $p(t)=\sum_k P_k\delta(t-x_k)$ 。

* $P(X\in[t,t+dt])=\mathrm{d}F(t)=p(t)\mathrm{d}t$

* $P(X\in B)=\int_B p(t)dt$

和离散型类似，我们定义期望

* **Def 1.2** :

$$E(X)=\int_{\mathbb{R}}xp(x)\mathrm{d}x \tag{3.4}$$

注意，这个积分也需要绝对收敛。

* **Lem 1.1** : 如果 $x<0$ 的部分有 $p(x)=0$ ，则

$$E(X)=\int_0^{+\infty}xP(X=x)\mathrm{d}x=\int_0^{+\infty}P(X>y)\mathrm{d}y \tag{3.5}$$

Proof.

$$E(X)=\int_0^{+\infty}p(x)\mathrm{d}x\int_0^{y=x}\mathrm{d}y=\int_0^{+\infty}\mathrm{d}y\int_{x=y}^{+\infty}p(x)\mathrm{d}x=\int_0^{+\infty}P(X>y)\mathrm{d}y \tag{3.6}$$

□

* **Thm 1.1** :

$$E(g(X))=\int_{\mathbb{R}}g(x)p(x)\mathrm{d}x \tag{3.7}$$

同样有类似结论

* 线性性 $E(aX+bY)=aE(X)+bE(Y)$

* 正定 $X\le Y,E(X)\le E(Y)$

* 三角不等式 $E(|X|)\ge|E(X)|$

* 柯西不等式 $(E(XY))^2\le E(X^2)E(Y^2)$ 。取等 $\exists t,E(tX+Y)=0$

同样可以定义独立，但这里不能用单点，应该用 Borel 代数

* **Definition 1.3(1)** (independent) : 称 $P(X \leq x)P(Y \leq y) = P(X \leq x, Y \leq y)$ X, Y 独立。

* **Definition 1.3(2)** (uncorrelated) : 称 $E(X)E(Y) = E(XY)$ X, Y 不相关。

3.2　一些分布

均匀分布 $X \sim U(a, b)$

$$f(x) = \frac{1}{b-a} \tag{3.8}$$

指数分布 $X \sim Exp(\lambda)$

$$f(x) = \lambda e^{-\lambda x}, \quad x > 0 \tag{3.9}$$

正态分布 $X \sim N(\mu, \sigma^2)$

$$f(x) = \frac{1}{\sqrt{2\pi} \cdot \sigma} \exp(-\frac{(x-\mu)^2}{2\sigma^2}) \tag{3.10}$$

Γ 分布 $X \sim \Gamma(\alpha, \lambda)$

$$f(x) = \frac{\lambda^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-\lambda x}, \quad x > 0 \tag{3.11}$$

3.3　联合分布

* 联合分布函数

$$F(\vec{\lambda}) = P(X_k \leq \lambda_k) \tag{3.12}$$

增

四边形不等式（n维容斥前缀和）

边缘分布函数

$$f_x(x) = F(x, +\infty) = \int p(x, y) dy \tag{3.13}$$

$$f_x(x) = F(x, +\infty) = \sum_y p(x, y) \tag{3.14}$$

3.4　条件分布和条件期望

$$f(y \mid x) = \frac{f(x, y)}{\int_{\mathbb{R}} f(x, y) \mathrm{d}y} \tag{3.15}$$

3.5　随机变量的函数

$$F_Y(y) = P(g(X) \le y) = P(X \in g^{-1}(-\infty, y]) = \int_{g^{-1}(-\infty,y]} p_x(t)\mathrm{d}t \tag{3.16}$$

e.g.

$$F_{X^2}(y) = F_X(\sqrt{y}) - F_X(-\sqrt{y}) \tag{3.17}$$

事实上，当 g 是双射时，直接由微积分结论

$$p_y(y) = \frac{\mathrm{d}}{\mathrm{d}y} F_Y(y(x)) = \frac{\mathrm{d}x}{\mathrm{d}y}\frac{\mathrm{d}}{\mathrm{d}x} RHS = \frac{\mathrm{d}x}{\mathrm{d}y} p_x(x) \tag{3.18}$$

$$\int_{y \in A_y} p_y(y_1, \cdots)\mathrm{d}y = \int_{x \in g^{-1}(A_y)} p_x(x_1(y_1, \cdots), \cdots) \left| \frac{\partial(x_1, \cdots)}{\partial(y_1, \cdots)} \right| \mathrm{d}x \tag{3.19}$$

第四章　概率收敛

4.1　不等式

* **Thm 1.1** (Markov) : 设随机变量 $X \geq 0$ ，那么

$$\forall a > 0, \quad P(X \geq a) \leq \frac{1}{a} E(X) \tag{4.1}$$

Proof.　由 $[x \geq a] \leq \frac{x}{a}$ ，两边取期望立证。□

作为直接推论，有

* **Thm 1.2** (Chebyshev) : 设随机变量 X 的期望和方差为 μ, σ^2 ，则

$$P(|X - \mu| \geq a) \leq \frac{\sigma^2}{a^2} \tag{4.2}$$

$$P(X - \mu \geq a) \leq \frac{\sigma^2}{a^2 + \sigma^2} \tag{4.3}$$

Proof.　(1)左式括号内平方立得。(2)左右同时 $+C$，用不等式后求右式min □

我们发现morkov非常好用，尝试代入矩母函数

这个不等式告诉我们离均值一定距离外的总概率小于某个值。切比雪夫不等式可以推得

* **Inf 1.2** : $X \equiv \mu \Leftrightarrow \sigma = 0$

4.2　大数律

* **Thm 1.3** : （弱大数律）当 σ 有限时，$\forall l > 0$ ，

$$P\left(\left|\frac{1}{n}\sum_{k=1}^{n} X_k - \mu\right| \geq l\right) \to 0, \quad n \to \infty \tag{4.4}$$

Proof.

$$P\left(\left|\frac{1}{n}\sum_{k=1}^{n} X_k - \mu\right| \geq l\right) \leq \frac{\sigma^2}{nl^2} \tag{4.5}$$

□

* **Thm 1.3** : （强大数律）当 μ 有限时，

$$P\left(\lim_{n\to\infty} \frac{1}{n}\sum_{k=1}^{n} X_k = \mu\right) = 1, \tag{4.6}$$

* **Thm 1.5** : 中心极限定律

$$\frac{\sum_{k=1}^{n} X_k - n\mu}{\sqrt{n}\sigma} \xrightarrow{\sim} N(0,1) = \frac{1}{\sqrt{2\pi}} \exp(\frac{x^2}{2}), \quad n \to \infty \tag{4.7}$$

第五章　随机游走

5.1　轨道计数

考虑在整数轴上进行游走。记 $N_n(a,b)$ 为恰好 n 步从 a 到 b 的轨道数，形式化地，

$$N_n(a,b) = \left|\{\{c_k\}_{k=1}^n \mid c_n = -1, 1, \quad a + \sum_{k=1}^n c_k = b\}\right| \tag{5.1}$$

由定义立知 $N_n(a+c,c) = N_n(a,0) = N_n(0,a) = \binom{l+r}{l}$

$$\begin{cases} r+l=n \\ r-l=a \end{cases} \Rightarrow \begin{cases} r = \frac{n+a}{2} \\ l = \frac{n-a}{2} \end{cases}$$

得到

$$N_n(0,a) = \begin{cases} \binom{n}{(n+a)/2} & 2 \mid (n+a) \\ 0 & 2 \nmid (n+a) \end{cases} \tag{5.2}$$

假如每步游走相当于一次 Bernoulli 试验，其中

$$P(X_i = 1) = p, \quad P(X_i = -1) = 1 - p \tag{5.3}$$

设经过 n 次游走后位置为 S_n ，那么

$$S_n = S_0 + \sum_{i=1}^n X_i \tag{5.4}$$

* **Example 1.1** : 无限制。$P(S_0 = 0) = 1$ ，求 $P(S_n = a \mid S_0 = 0)$

$$P(S_n = a) = \binom{l+r}{l} p^l (1-p)^r = \binom{n}{(n+a)/2} p^{(n+a)/2} (1-p)^{(n-a)/2} \tag{5.5}$$

n, a 奇偶性不同时，无法到达。
* 易见平移性空间 / 时间

$$P(S_n = j \mid S_0 = a) = P(S_n = j + b \mid S_0 = a + b) \tag{5.6}$$

$$P(S_{n+m} = j \mid S_m = a) = P(S_n = j \mid S_0 = a) \tag{5.7}$$

* Markov 性：（无后效性）只由最后一个状态决定。

$$P(S_{n+m} = j \mid S_0, S_1 \cdots, S_m) = P(S_{n+m} = j \mid S_m) \tag{5.8}$$

OIers 应该能发现这就是 dp 中常常强调的无后效性。
这意味着任何条件概率取其中一个条件即可。

5.1.1 固定单个中间点

设 $a,b>0$ ，记 $N_n^0(a,b)$ 为经过 0 的轨道，即

$$\exists n_0, \text{s.t. } a+\sum_{k=1}^{n_0} c_k = 0 \tag{5.9}$$

* 反射对应得

$$N_n^0(a,b) = N_n(-a,b) = N_n(0,a+b) = \sum_k N_k(0,a)N_{n-k}(0,b) \tag{5.10}$$

推广得到，若 $m>a$ ，有

$$N_n^m(0,a) = N_n^0(m,m-a) = N_n(0,2m-a) \tag{5.11}$$

再由 $P(S_n=a)=\binom{l+r}{l}p^l(1-p)^r$ ，考虑翻转前后 l,r 的变化。由于

$$P(S_n=a) = N_n(0,a)p^{(n+a)/2}(1-p)^{(n-a)/2} \tag{5.12}$$

$$P(S_n=2m-a) = N_n(0,2m-a)p^{(n+2m-a)/2}(1-p)^{(n+a-2m)/2} \tag{5.13}$$

可以写出

$$\begin{aligned}
P(S_n=a,\exists S_k=m) &= N_n^m(0,a)p^{(n+a)/2}(1-p)^{(n-a)/2} \\
&= N_n(0,2m-a)p^{(n+a)/2}(1-p)^{(n-a)/2} \\
&= N_n(0,2m-a)p^{(n+2m-a)/2-(m-a)}(1-p)^{(n+a-2m)/2+(m-a)} \\
&= \left(\frac{1-p}{p}\right)^{m-a} P(S_n=2m-a)
\end{aligned}$$

5.1.2 游走范围

对 $N_n(0,a)$ 中的路径，考虑 $\max S_k \geq m$ 的路径计数。
* 对 $m\leq a$ ， $N_n(0,a)$ 全部均满足。于是运用上节结论

$$P(S_n=a,\max S_k\geq m) = \begin{cases} \left(\frac{1-p}{p}\right)^{m-a} P(S_n=2m-a) & m>a \\ P(S_n=a) & m\leq a \end{cases}$$

再考虑枚举终点

$$\begin{aligned}
P(\max S_k\geq m) &= \sum_{a=-\infty}^{+\infty} P(S_n=a,\max S_k\geq m) \\
&= \sum_{a=-\infty}^{m-1} \left(\frac{1-p}{p}\right)^{m-a} P(S_n=2m-a) + \sum_{a=m}^{+\infty} P(S_n=a)
\end{aligned}$$

在左边的求和中令 $b=m-a$

$$
\begin{aligned}
P(\max S_k \geq m) &= \sum_{b=1}^{+\infty} \left(\frac{1-p}{p}\right)^b P(S_n = m+b) + \sum_{a=m}^{+\infty} P(S_n = a) \\
&= P(S_n = m) + \sum_{b=1}^{+\infty} \left(1 + \left(\frac{1-p}{p}\right)^b\right) P(S_n = m+b)
\end{aligned}
$$

如果 $p = \dfrac{1}{2}$ ，右边的括号内成为常数 2 ，可以提出求和符号，

$$
P(\max S_k \geq m) = P(S_n = m) + 2P(S_n \geq m+1) \tag{5.14}
$$

5.1.3　游走到达某点

* 不妨从 0 出发。考虑出发后不重复经过 0 ，记 $N_n^{\emptyset}(0,a)$ 。第一步必向右，且之后不再经过 0 ，于是

$$
\begin{aligned}
N_n^{\emptyset}(0,a) &= N_{n-1}(1,a) - N_{n-1}^{0}(1,a) \\
&= N_{n-1}(0,a-1) - N_{n-1}(0,a+1) \\
&= \frac{a}{n} N_n(0,a)
\end{aligned}
$$

注意，这个 a/n 是关于 l, r 数量的简并。于是有推论，不妨 $P(S_0 = 0) = 1$

$$
P(S_n = a, S_1 \cdots S_n \neq 0) = \frac{|a|}{n} P(S_n = a) \tag{5.15}
$$

两边对 a 求和，得到

$$
P(S_1 \cdots S_n \neq 0) = \frac{1}{n} E|S_n| = \sum_{k=1}^{n} \frac{2k}{n} P(S_n = k) \tag{5.16}
$$

反过来考虑，从 0 到 a ，n 步后首次到达的概率就是

$$
P(S_n = a, S_0 \cdots S_{n-1} \neq a) = \frac{|a|}{n} P(S_n = a) \tag{5.17}
$$

此时， n 是首次到达 a 的时间。

5.1.4　反正弦律

在第 $2k$ 步游走回 0 的轨道数是 $N_{2k}(0,0) = \dbinom{2k}{k}$ ，概率是

$$
P(S_{2k} = 0) = \binom{2k}{k} p^k (1-p)^k \tag{5.18}
$$

由斯特林公式

$$
n! \sim \sqrt{2\pi n} \left(\frac{n}{e}\right)^n \tag{5.19}
$$

得

$$
P(S_{2k} = 0) \sim \frac{1}{\sqrt{\pi k}} 2^{2k} p^k (1-p)^k \tag{5.20}
$$

当 $p=\dfrac{1}{2}$ 时，

$$P(S_{2k}=0)\sim\frac{1}{\sqrt{\pi k}} \tag{5.21}$$

考虑 $2n$ 步

$$\begin{aligned}
P(S_1\cdots S_{2n}\neq 0)&=\sum_{k=1}^{n}\frac{2\cdot 2k}{2n}P(S_{2n}=2k)\\
&=\sum_{k=1}^{n}\frac{2k}{n}\binom{2n}{n+k}p^{n+k}(1-p)^{n-k}\\
&=2^{-2n}\sum_{k=1}^{n}\frac{2k}{n}\binom{2n}{n+k}\\
&=2^{-2n+1}\sum_{k=1}^{n}\left(\frac{n+k}{2n}-\frac{n-k}{2n}\right)\binom{2n}{n+k}\\
&=2^{-2n+1}\sum_{k=1}^{n}\binom{2n-1}{n+k-1}-\binom{2n-1}{n+k}\\
&=2^{-2n+1}\left(\binom{2n-1}{n}-0\right)=2^{-2n}\binom{2n}{n}
\end{aligned}$$

可以计算在 $2n$ 时间内，最后一次回到 0 的时间是 T_{2n} ，有

$$\begin{aligned}
P(T_{2n}=2k)&=P(S_{2k}=0)P(S_1S_2\cdots S_{2n-2k}\neq 0)\\
&=P(S_{2k}=0)2^{-2n+2k}\binom{2n-2k}{n-k}\\
&\sim\frac{1}{\pi\sqrt{k(n-k)}}
\end{aligned}$$

接下来计算一个分布

考虑 $2n$ 步内最后一次回到 0 点时至多走了 $2xn$ 步 $(x<1)$ ，$n\to+\infty$ ，有

$$F(x)=P(\frac{T_{2n}}{2n}\leq x)\simeq\sum_{k\leq xn}\frac{1}{\pi\sqrt{k(n-k)}}\sim\int_{u=0}^{xn}\frac{1}{\pi\sqrt{k(n-k)}}du\sim\frac{2}{\pi}\arcsin\sqrt{x} \tag{5.22}$$

整不太懂，就这样算了

5.2　其他简单随机游走

* **Example 1.2** : 赌徒破产问题。即带吸收壁随机游走，有吸收壁 $0,N$ ，计算被 0 吸收概率及被吸收时步数期望。

$$P(X_i=1)=p,\quad P(X_i=-1)=1-p \tag{5.23}$$

吸收壁条件

$$P(S_{n+m}=0\mid S_m=0)=1 \tag{5.24}$$

$$P(S_{n+m}=0 \mid S_m=N)=0 \tag{5.25}$$

计算初始位置为 k 时被 0 吸收的概率 $P_k=P(S_n=0 \mid S_0=k), n\to\infty$。

Solution.　由全概率公式写出

$$P_k=pP_{k+1}+(1-p)P_{k-1} \tag{5.26}$$

整理得到

$$P_{k+1}-P_k=\frac{1-p}{p}(P_k-P_{k-1}) \tag{5.27}$$

设 $r=\dfrac{1-p}{p}$ ，注意到 $P_0=1$ ，求和得

$$\begin{cases} P_k=1+\frac{1-r^k}{1-r}(P_1-1) & p\neq\frac{1}{2} \\ P_k=1+k(P_1-1) & p=\frac{1}{2} \end{cases} \tag{5.28}$$

代入 $P_N=0$ 解得

$$P_k=\begin{cases} 1-\frac{1-r^k}{1-r^N} & p\neq\frac{1}{2} \\ 1-(k/N) & p=\frac{1}{2} \end{cases} \tag{5.29}$$

也可由二阶特征方程 $(x-1)(x-r)=0$ 解得。

计算从 k 出发被吸收时步数 T_k 期望

$$\begin{aligned} ET_k &= p(1+ET_{k+1})+(1-p)(1+ET_{k-1}) \\ &= 1+pET_{k+1}+(1-p)ET_{k-1} \end{aligned}$$

由前一问的特征方程差分，即乘 $(x-1)$ 后得到三阶特征方程 $(x-1)^2(x-r)=0$ ，代入 $E_0=0, E_N=0(\neq+\infty!!!)$ 解得

$$ET_k=\begin{cases} Ak-\frac{AN}{r^N-1}(r^k-1) & p\neq\frac{1}{2} \\ Ck(N-k) & p=\frac{1}{2} \end{cases} \tag{5.30}$$

令 $N=2$ ，得到 $E_1|_{N=2}=1$ ，解得

$$ET_k=\begin{cases} \frac{1}{1-2p}\left(k-N\frac{1-r^k}{1-r^N}\right) & p\neq\frac{1}{2} \\ kN-k^2 & p=\frac{1}{2} \end{cases} \tag{5.31}$$

也可以用二阶差分方程来解。

第六章　统计

6.1　统计学基础知识

涉及多个分布均默认设 $X_i(i=1,\cdots n)$ 独立

6.1.1　常用分布

正态分布

Def 1 (正态分布)**.** $X \sim N(\mu,\sigma^2)$

$$(2\pi\sigma^2)^{-1/2}\exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right)$$

$EX=\mu, Var(X)=\sigma^2, E(e^{itX})=\exp(i\mu t-\frac{1}{2}\sigma^2t^2)$

Thm 1 (正态分布的线性组合)**.** $X=\sum_{i=1}^n c_iX_i, X_i\sim N(\mu_i,\sigma_i^2)$ ，则

$$EX=\sum_{i=1}^n c_i\mu_i, Var(X)=\sum_{i=1}^n c_i^2\sigma_i^2$$

这是变量间的加和卷积，注意和常数倍一个随机变量的不同

推论: 令 $X=\frac{1}{n}\sum_{i=1}^n X_i, X_i\sim N(\mu,\sigma^2)$

$$EX=\mu, Var(X)=\frac{1}{n}\sigma^2$$

卡方分布

Def 2 (卡方分布)**.** $X\sim\chi_n^2=\Gamma(\frac{1}{2},\frac{n}{2})$

$$\frac{1}{\Gamma(n/2)\cdot 2^{n/2}}\cdot x^{n/2-1}e^{-x/2}$$

$EX=n, Var(X)=2n$

Thm 2 (卡方分布的导出)**.**

$$\sum_{i=1}^n(X_i-\mu)^2/\sigma^2\sim\chi_n^2$$

Thm 3 (自由度公式)**.**

$$\sum_{i=1}^n(X_i-\overline{X})^2/\sigma^2\sim\chi_{n-1}^2$$

证明. 使用第一行全为 $n^{-1/2}$ 的正交变换构造另一组正态分布，再由导出式得证。 □

Thm 4 (卡方分布的和)**.** $X_i\sim\chi_{r_i}^2, X=\sum_{i=1}^n X_i, r=\sum_{i=1}^n r_i$ ，则

$$X\sim\chi_r^2$$

Thm 5 (指数分布的和)**.** $X_i\sim Exp(\lambda), X=\sum_{i=1}^n X_i$ ，则

$$2\lambda X\sim\chi_{2n}^2$$

求矩时通常利用 $Gamma$ 函数的定义式和性质

$$\Gamma(\alpha+1)/\Gamma(\alpha)=\alpha,\Gamma(n+1)=n!$$

归一化系数本身就是积分结果

$$\frac{\Gamma(\alpha)}{\lambda^\alpha}=\int_0^{+\infty}x^{\alpha-1}e^{-\lambda x}dx$$

卷积的话有可能会出现 $B(\alpha,\beta)=\frac{\Gamma(\alpha+\beta)}{\Gamma(\alpha)\Gamma(\beta)}$

t分布

$$\frac{N(0,1)}{\sqrt{\chi_n^2/n}}\sim t_n$$

$$\frac{\sqrt{n}(\overline{X}-\mu)}{S_X}\sim t_{n-1}$$

F分布

$$\frac{\chi_m^2/m}{\chi_n^2/n}\sim F_{m,n}$$

$$\frac{S_X^2/\sigma_1^2}{S_Y^2/\sigma_2^2}\sim F_{m-1,n-1}$$

6.1.2　次序统计量的分布

记 $X_{(m)}$ 为从小到大第 m 个，则

$$F_{X_{(m)}}(t)=P(X_{(m)}<t)=P(\sum_{k=1}^n bool(X_k<t)\geq m)$$

于是

$$F_{(m)}(t)=\sum_{j=m}^n P(\sum_{k=1}^n bool(t\geq X_k)=j)=\sum_{j=m}^n\binom{n}{j}F^j(t)(1-F(t))^{n-j}$$

再求导即得密度函数。特别地

$$F_{(1)}(t)=1-(1-F(t))^n,\quad F_{(n)}(t)=F^n(t)$$

6.1.3　指数族

从这里开始的随机变量 X 可能是多维的，懒得加箭头

对于函数 $f(x;\theta)$ ，我们将其定义域空间分为两部分，$x\in A$ 是样本空间，对于 $\forall\theta\in\Theta$ 确定一个 $x\mapsto f(x)$ 的函数。我们称 Θ 为参数空间，$\{f_\theta(x):\theta\in\Theta\}$ 就称为参数族。

Def 3 (指数族)**.** 如果一个参数族中的函数满足

$$f(x;\theta)=C(\theta)\exp\left(\sum_i T_i(x)Q_i(\theta)\right)h(x)$$

自然参数空间 $\phi_i=Q_i(\theta)$

参数族是一个依赖于参数空间的概念。注意分清变量、参数、已知量。

指数族有很多好性质。

6.1.4　充分统计量

令 $T(X)$ 是随机变量的函数，那么会有 $F(t) = P(X = x|T(X) = t)$ 这一条件概率。假如 $F(x;\theta)$ 在 $A_t = \{x, \theta : T(x) = t\}$ 上不依赖于参数 θ ，则称 $T(X)$ 为充分统计量。如果 $Q(X)$ 的分布不依赖于 θ ，则称 $Q(X)$ 为辅助统计量。

Thm 6 (因子分解定理)**.** *T 是充分统计量等价于 $\forall x, \theta$ ，*

$$f(x;\theta) = g(t;\theta)h(x)$$

指数族的**一组** T_i 是充分统计量。

在一一映射意义下，存在唯一的极小充分统计量，使得它对所有充分统计量有单射。

如果 $f(x;\theta)/f(y;\theta)$ 不依赖于 θ 当且仅当 $T(x) = T(y)$ 成立，则 $T(x)$ 为极小充分统计量。

6.1.5　完全统计量

$\forall\theta$ ，如果 $\forall\phi(x), E(\phi(T(x))) = 0$ 都有 $\phi(x) \equiv 0$ ，则称 $T(x)$ 是完全统计量。

如果存在非平凡可测函数 $V(t)$ 使 $V(T(x))$ 是辅助统计量，则 $T(x)$ 不是完全统计量。

进一步，有

Thm 7 (Basu)**.** *充分完全统计量和辅助统计量独立。*

如果指数族的自然参数空间是欧氏空间中有内点的区域，则该指数族的一组 T_i 是完全统计量。

因此易证 $S_X^2, \overline{X}$ 独立

6.2　点估计

设我们需要得到参数 θ ，由于不知道参数 θ 而使用试验结果的函数 $\hat{\theta}(X)$ 代替，就是参数估计问题。如果 $\hat{\theta}(X)$ 给出了一个值，称为点估计。如果 $\hat{g}(X) = \pi(\theta)$ 给出了一个上下界，称为区间估计。

参数的函数视作参数时也是同理，直接代入即可。

6.2.1　点估计的方法

矩估计MoM

计算总体的的原点矩和中心矩，反解出 $g(\theta)$ 的关于矩的表达式，使用样本矩代替总体矩。

$$\frac{1}{n}\sum X_i^k \Leftrightarrow EX^k$$

$$\frac{1}{n}\sum (X_i - \overline{X})^k \Leftrightarrow E(X - EX)^k$$

$$f(\alpha_{n,k}, m_{n,k})$$

这个方法很粗暴

极大似然估计MLE

将分布函数看成试验结果已知时 θ 的函数，称为似然函数

$$L(\theta \mid \vec{x}) = f(\vec{x} \mid \theta)$$

求得似然函数的最大值点作为 θ 的估计值。

$$\hat{\theta} = \arg\max_{\theta} L$$

通常来说会使用 $l = \log L$ 简化求最值运算。参数空间形状奇怪时也可能直接按定义找。

贝叶斯估计BE

设参数也是随机变量，有一个先验分布，那么 x, θ 的地位相同。利用贝叶斯公式求得样本已知时的条件分布，称为后验分布。

$$\pi(\theta \mid \vec{x}) = \frac{f(\theta, \vec{x})}{\int f(\vec{x}, \theta) d\theta} = \frac{f(\vec{x} \mid \theta)\pi(\theta)}{\int f(\vec{x} \mid \theta)\pi(\theta) d\theta}$$

求期望就得到点估计。

共轭先验分布族：先验分布和后验分布同族

6.2.2　点估计/统计推断的评价方法

Def 4. 设 $P \in \mathcal{P}$ 是一个分布族中的一个总体，X 观测值，$A(X) \in \mathbb{A}$ 行动准则是观测值决定的函数。规定损失函数 $L(P, A(X)) > 0$ ，则可以定义风险

$$R(P, A) = E(L(P, A)) = \int L(P, A(x)) dP(x)$$

于是我们可以由损失函数定义期望意义下的最优决策准则 $A_0(X)$ 。

Def 5. 称 A_1 优于 A_2 ，当且仅当

$$\forall P \in \mathcal{P}, R(P, A_1) < R(P, A_2)$$

称 A_0 是最优的，当且仅当它比所有准则更优称 A_0 是容许的，当且仅当不存在更优的准则

Remark. 如果最优准则存在，则容许准则和最优准则等价。如果有两个不等价的容许准则，由于它们互相不更优，不存在最优准则。

Remark. 以点估计为例，$P(\theta) \in \mathcal{P}$ 是参数族中的一个总体， $T(X) : \mathcal{X} \to \Theta$ 是 $g(\theta)$ 的一个估计，我们可以令 $L(P(\theta), T(x)) = (g(\theta) - T(x))^2$ ，那么

$$R(P(\theta), T(X)) = \int (g(\theta) - T(x))^2 dP(x)$$

称为 **均方差(MSE)** 损失。

而最小均方差的无偏估计就称为**一致最小无偏估计(UMVUE)**。可证唯一，但我不会。

6.2.3 一致最小无偏估计

Thm 8 (Rao-Blackwell)**.** 设 $\mathbb{A} \subset \mathbb{R}^n$ 是一个凸集，$L(P,a)$ 是 a 的凸函数

设 T 是 $P \in \mathcal{P}$ 的一个充分统计量，A_0 是一个非随机化的决策准则，且 $E(\|A_0(x)\|) < +\infty$ ，那么

$$R(P, E(A_0(x)|T)) \leq R(P, A_0(x))$$

如果 L 严格凸且 A_0 不是 T 的函数，则不等号严格

证明. Jensen 立证？？？ □

也就是说，对任意一个无偏估计 $A_0(x)$ ，都有 $E(A_0(x)|T=t) = A'(t(x))$ 不比它差。注意，由于 T 是充分统计量， $E(A_0(x)|T)$ 和 θ 无关，因此仍是统计量。

充分完全变量法

设 T 是充分完全统计量，则对任一无偏估计 $A_0(x)$，$E(A_0(x)|T=t) = A'(t(x))$ 是 UMVUE

零无偏估计法

Thm 9 (零无偏估计法)**.** 设 $\hat{g}(X)$ 是某无偏估计，$\mathcal{U}$ 是方差有限的零的全体无偏估计

$$\forall U(X), E(\hat{g}(X)U(X)) \equiv 0 \Leftrightarrow \hat{g}(X) : UMVUE$$

如果 $\hat{g}$ 是充分统计量 T 的函数，那么只需验证 $\mathcal{U}$ 中 T 的函数即可。

证明. □

C-R 下界法

Thm 10 (Cramer-Rao)**.** 设 $\hat{g}(X)$ 是 $g(\theta)$ 的无偏估计量，如果满足一坨正则条件，则

$$Var(\hat{g}(X)) \geq \frac{(g'(\theta))^2}{I(\theta)}$$

其中

$$I(\theta) = E\left[(\partial_\theta \log f(x,\theta))^2\right]$$

称为 *Fisher* 信息量。对于多次试验的总体

$$Var(\hat{g}(\vec{X})) \geq \frac{(g'(\theta))^2}{nI(\theta)}$$

证明. 本质只是一个期望的柯西不等式

$$Var(\hat{g}(X)) \cdot Var\left(\frac{\partial \log f(x,\theta)}{\partial \theta}\right) \geq Cov^2\left(\hat{g}(X), \frac{\partial \log f(x,\theta)}{\partial \theta}\right)$$

两者分别是 $g(\theta)$ 和 0 的无偏估计
中间某些变形由正则条件提供。若不满足，则不等式不成立。
而恰好这些条件对指数族成立。 □

注意明确 θ ，在求导时可能出现问题。

Thm 11. *若偏差函数满足* $\exists a(\theta)$

$$a(\theta) = \frac{\partial_\theta \log f(x,\theta)}{\hat{g}(\vec{X}) - g(\theta)}$$

且满足正则条件，则 $\hat{g}$ *是* $UMVUE$

Def 6 (估计效率)**.**

$$e(\theta) = \frac{(g'(\theta))^2}{I(\theta)Var(\hat{g}(X))} \in [0,1]$$

称为无偏估计 $\hat{g}$ 的效率，若 $e=1$ 称为有效估计，$e \to 1$ 称为渐近有效估计。$UMVUE$ 不一定满足正则条件，故不一定有效。

6.3 假设检验

一个假设检验会在参数空间给定一个子集 $\Theta_0 \in \Theta$ 。我们要做的就是根据样本给出是否有 $\theta \in \Theta_0$ 的判断。也就是将样本空间划分出接受域和拒绝域两部分。

6.3.1 假设检验的方法

似然比检验

拒绝域为

$$\lambda(x) = \frac{\sup_0 L}{\sup L} \le c \in [0,1]$$

称为似然比函数 LRT

贝叶斯检验

拒绝域为

$$\lambda(x) = \frac{P(\theta \in \Theta_0 | x)}{P(\theta \in \Theta_1 | x)} \le c$$

使用后验分布积分可得。默认取 $c=1$

6.3.2 功效函数

第一类错误：对判错

第二类错误：错判对

上面两种关于比例的检验中显然可以发现第一类和第二类错误通常不能同时降低。于是我们一般采用保证其一的方式。

Def 7 (功效函数)**.** 参数空间上的拒绝概率函数称为功效函数

$$\beta(\theta) = \begin{cases} P(Error1) & \theta \in \Theta_0 \\ 1 - P(Error2) & \theta \in \Theta_1 \end{cases}$$

一般来说，在 Θ_0 我们希望尽量判非拒绝，β 接近 0 。在 Θ_1 我们希望尽量判拒绝，β 接近 1 。

水平为 α 的检验：第一类错误概率 $\leq \alpha$

$$\sup_0 \beta(\theta) \leq \alpha$$

真实水平为 α 的检验：取等。

6.3.3 一致最大功效检验

只考虑真实水平为 α 的 UMPT ，称 UMPT 为犯第二类错误一致最小

单边假设UMPT

Thm 12 (N-P引理)**.** *如果一个真实水平为 α 的检验满足存在常数 k 使*

$$\begin{cases} f(x|\theta_1) > kf(x|\theta_0) \Rightarrow x \in R \\ f(x|\theta_0) < kf(x|\theta_1) \Rightarrow x \notin R \end{cases}$$

那么该检验是一个 UMPT

对 $\forall \theta_2 > \theta_1$ ，如果 $\frac{f(x|\theta_2)}{f(x|\theta_1)}$ 分子分母任一 > 0 时是 t 的单调函数，称随机变量 X 关于 θ 具有单调似然比 (MLR)

指数族的自然参数是给定参数 θ 的非降函数，则关于 θ 具有 MLR

Thm 13 (K-R定理)**.** *设 T 是一个充分统计量，且具有**非降** MLR ，则*

$$T > t_0 \Rightarrow x \in R$$

是一个水平为 $P_0(T > t_0)$ 的 UMPT

p值

6.4 区间估计

区间估计是给出一个统计量确定的区间 $L(X), U(X)$ 。

$$\inf_\theta P(\theta \in (L, U))$$

称为置信系数

$$E(U - L)$$

称为精度

我们令 $1 - \alpha$ 为置信系数。

分别令 $U \to +\infty / L \to -\infty$ ，同时保证置信系数为 $1 - \alpha$ ，那么可以求得单侧置信区间。

合并，即可得到置信系数为 $1 - \alpha_1 - \alpha_2$ 的双侧置信区间。

6.4.1 枢轴变量法

找到一个点估计 T

将其通过某函数化为 $T' = \varphi(T, \theta)$ ，其分布与 θ 无关。

选取上下限，解不等式即得。

6.4.2 正态总体假设检验

σ 已知，求 μ

$$\frac{\sqrt{n}(\overline{X} - \mu_0)}{\sigma} \mid_{\mu=\mu_0} \sim N(0,1)$$

σ 未知，求 μ

$$\frac{\sqrt{n}(\overline{X} - \mu_0)}{S} \mid_{\mu=\mu_0} \sim t_{n-1}$$

$N(0,1), t$ 分布都是对称的，可以直接利用 $\Phi^{-1}(\alpha), \pm\Phi^{-1}(\alpha/2)$ 作为接受域的界

μ 已知，求 σ

$$\frac{nS_n^2}{\sigma_0^2} \mid_{\sigma^2=\sigma_0^2} \sim \chi_n^2$$

μ 未知，求 σ

$$\frac{(n-1)S^2}{\sigma_0^2} \mid_{\sigma^2=\sigma_0^2} \sim \chi_{n-1}^2$$

χ^2 分布就稍麻烦些。接受域上下界应该是 $\chi^{-1}(1-\alpha/2), \chi^{-1}(\alpha/2)$